No.

Date

决策方法论 Final

①基本概念

条件概率 $P(B|A)$ B在A发生条件下发生 $P(B|A)=\frac{P(AB)}{P(A)}$

全概率 $P(A)=\sum_i P(B_i)P(A|B_i)$ $P(A_1\cdots A_n)=P(A_1)P(A_2|A_1)P(A_3|A_1A_2)\cdots P(A_n|A_1\cdots A_{n-1})$

贝叶斯公式 $P(B_i|A)=\frac{P(AB_i)}{P(A)}=\frac{P(B_i)P(A|B_i)}{\sum P(B_j)P(A|B_j)}$

②马氏决策的定义

马尔科夫性未来与previous无关，即状态转移概率的无后效性（仅与当下选择有关）

七要素：
- 阶段T，一般以t，t作为参数
- 状态S，$x_t\in S$
- 决策（方案）$a_t\in A_{xt}$ 在各阶段可用的方案
- 状态转移概率 $P_a(x,y)$ 在方案a下从状态x转到y的概率
- 成本 $g_{at}(x_t)$ 每一阶段
- 策略：$u=a_{ti}\in A_{xt}$ 对策的选择
- 代降价函数J：衡量指标

③最优准则的数学表达式

有限阶段总成本 $E[\sum_{t=0}^{T-1} g_{at}(x_t)|x_0=x]$

平均成本 $\limsup_{T\to\infty} E[\frac{1}{T}\sum_{t=0}^{T-1} g_{at}(x_t)|x_0=x]$

无限折扣成本 $E[\sum_{t=0}^{\infty}\alpha^t g_{at}(x_t)|x_0=x]$

④贝尔曼方程

有限阶段：$J^*(x,t)=\min_{a\in A_x}\{g_a(x)+\sum_{y\in S}P_a(x,y)J^*(y,t+1)\}$

折扣成本：$J^*(x)=\min_{a\in A_x}\{g_a(x)+\alpha\sum_{y\in S}P_a(x,y)J^*(y)\}$

KOKUYO

扫描全能王 3亿人都在用的扫描App

No

Data

⑤动态规划算子的三大特性：

单调性： $J \le \bar{J} \Rightarrow TJ \le T\bar{J}$

偏移性： $T(J+ke) = TJ + \alpha ke$

最大模收缩： $\|TJ - T\bar{J}\|_\infty \le \alpha \|J - \bar{J}\|_\infty$

⑥动态规划与数值迭代

普通 $J_{k+1} = TJ_k$ $\lim_{k\to\infty} J_k = J^*$

Gauss-Seidel $J_{k+1} = FJ_k$ $\lim_{k\to\infty} J_k = J^*$ 小于 x $J_{(x)}$ 更新

Jacobi $AX = b$ $x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{\substack{j=1 \\ j\neq i}}^{n} a_{ij} x_j^{(k)}\right)$

⑦策略迭代

收敛点： $\lim_{k\to\infty} U_k = U^*$

对比数值迭代 都评估代价；状态空间需小，迭代速度快； argmin ← min

异步策略迭代 结合两者，做迭代

⑧线性回归

回归分析：因变量与自变量的关系

线性回归：最基本的回归分析

$Y = X \cdot \beta + \varepsilon$ → 剩余误差向量

回归系数向量

因变向量

自变矩阵

⑨普通最小二乘法

目标：寻找最小化剩余方差的回归系数 β

假设：线性函数形式： $Y \sim X$

剩余误差独立同分布：我们就认为同分布的独立随机变量

剩余误差呈正态分布，

剩余误差同方差，

Campus 剩余误差方差： $Var(\varepsilon|X) = \frac{(\varepsilon - E(\varepsilon|X))^T (\varepsilon - E(\varepsilon|X))}{n-k} = \frac{\varepsilon'\varepsilon}{n-k} = \cdots$

扫描全能王
3亿人都在用的扫描App

No.

Date

① 离散数据

类型：定类（数值无意义）

定序（比较大小，但差值无意义）

定量（数值有意义）{定距 相减；定比 相乘除}

概率质量函数 离散变量 $f(x)=P(X=x)$ 参数θ：$f(x|\theta)$ / $f(x;\theta)$

概率密度函数 连续变量

② 分布

伯努利分布 概率质量函数 $f(x)=\begin{cases}\pi & x=1\\ 1-\pi & x=0\end{cases}$

期望 $E(X)=\pi$

方差 $Var(X)=E(X^2)-(E(X))^2=\pi-\pi^2$

二项分布 $X=X_1+\cdots+X_n$（为伯努利变量）

$X\sim Bin(n,\pi)$

$f(x)=\frac{n!}{x!(n-x)!}\pi^x(1-\pi)^{n-x}$

$E(X)=\sum_{i=1}^{n}E(X_i)=n\pi$

$Var(X)=\sum_{i=1}^{n}Var(X_i)=n\pi(1-\pi)$

泊松分布 取 $n\to\infty$，$\pi=\frac{\lambda}{n}$

$$P(X=k)=\lim_{n\to\infty}C_n^k\pi^k(1-\pi)^{n-k}$$
$$=\lim_{n\to\infty}\frac{n!}{(n-k)!n^k!}\left(\frac{\lambda}{n}\right)^k\left(1-\frac{\lambda}{n}\right)^n\left(1-\frac{\lambda}{n}\right)^{-k}$$
$$=\frac{\lambda^k e^{-\lambda}}{k!}$$

$f(x)=\frac{\lambda^x e^{-\lambda}}{x!}$

$E(X)=\lambda$

$Var(X)=\lambda$

KOKUYO

CS 扫描全能王
3亿人都在用的扫描App

No.

Date

⑬最大似然估计

似然函数 对观测数据的联合概率与统计模型参数的函数

$L(B|A) = P(A|B)$ A为数据生成后，B为参数

似然性与概率 前者 模型、参数已知，估计观测出现的可能性

后者 模型、观测已定，估计参数导致观测的可能性

最大似然估计 似然函数最大化的参数

伯努利分布 $L(\lambda) = f(x_1, \cdots x_n; \lambda) = \lambda^{\sum x_i}(1-\lambda)^{n-\sum x_i}$

$\frac{\partial \log(L(\lambda))}{\partial \lambda} = 0 \Rightarrow \frac{\sum x_i}{\lambda} - \frac{n-\sum x_i}{1-\lambda} = 0$

伯-最大似然估计 $\hat{\lambda} = \frac{\sum x_i}{n}$

伯-方差 $Var(\hat{\lambda}) = Var(\frac{\sum x_i}{n}) = \frac{1}{n^2} Var(\sum x_i) = \frac{1}{n^2}\sum Var(x_i) = \frac{\lambda(1-\lambda)}{n}$

⑭广义线性模型与回归

广义线性模型 打破普通最小二乘法，解决离散因变量非正态分布因变量的回归分析

因变量Y来自某个指数族分布

三个主要成分 随机成分：因变量的统计分布

系统性成分：自变量(解释变量)及其组合

连接函数：$g(\mu) = X'\beta$ 前两者的关系

与普通最小二乘 随机成分：Y正态分布

系统性成分：以X线性组合表示Y的期望

连接函数：$\eta = g(\mu) = \mu = E(Y)$

二元逻辑回归 适用：受多变量影响的事件发生/不发生（病，灾害…）

成分：Y服从伯努利分布，$E(Y) = \lambda$

多个自变量，线性估计Y的期望

$\eta = g(\lambda) = \log\frac{\lambda}{1-\lambda}$

似然函数 $L(\beta_0, \vec{\beta}) = \log(\prod_{i=1}^{n} \pi_i^{y_i}(1-\pi_i)^{1-y_i})$

$\frac{\partial L}{\partial \beta_i} = 0 \Rightarrow \hat{\beta_i}: \hat{\beta}$

泊松回归 适用：计数数据（如车数，人数）

似然函数：$L(\vec{\beta}) = \prod_{i=1}^{n} \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}$

$\log L(\vec{\beta}) = \sum_{i=1}^{n}(y_i \log(\lambda_i) - \lambda_i - \log(y_i!))$

$= \sum(y_i x_i^T\beta - e^{x_i^T\beta} - \log(y_i!))$

Campus

扫描全能王
3亿人都在用的扫描App

No.

Date

最大似然函数求导 $\frac{\partial \log(L(\vec{\beta}))}{\partial \vec{\beta}} = \frac{\partial}{\partial \vec{\beta}}\left(\sum_{i=1}^{n}(y_i \vec{x}_i^T\vec{\beta} - e^{\vec{x}_i^T\vec{\beta}} - \log(y_i!))\right)$

$= \sum_{i=1}^{n}(y_i - e^{\vec{x}_i^T\vec{\beta}})\vec{x}_i = 0$

成分 T服从泊松分布，期望为λ

...

$\log(\lambda) = \vec{x}^T\vec{\beta}$

要求 $V(x) = E(x)$，拟合效果差

负二项回归 适用范围泊松

成分：T服从负二项分布

...

使用 $\log(\mu_i) = \vec{x}_i^T\vec{\beta}$

似然函数 $L(\vec{\beta}) = \prod_{i=1}^{n} C_{r+y_i-1}^{y_i}\left(\frac{r}{r+\mu_i}\right)^r\left(\frac{\mu_i}{r+\mu_i}\right)^{y_i}$

$\log L(\vec{\beta}) = \sum_{i=1}^{n}\log\left(C_{r+y_i-1}^{y_i}\right) - (y_i+r)\log(\mu_i+r) - y_i\log(r)$

$+ y_i\log(\mu_i)$

KOKUYO

CS 扫描全能王
3亿人都在用的扫描App

No.

Date

For calculation

① 有限阶段问题：逆推归纳动态规划

代价方程：$J^*(x,t_0) = \min_{a\in A_x}\{g_a(x) + \sum_{y\in S} P_a(x,y) J^*(y,t_0+1)\}$

代价函数 J 一状态，t_0 阶段的代价函数

② 无限阶段折扣成本问题

代价方程 $J^*(x,t) = \min_{a\in A_x}\{g_a(x) + \alpha\sum_{y\in S} P_a(x,y) J^*(y,t+1)\}$

贝尔曼方程 $J^*(x) = \min_{a\in A_x}\{g_a(x) + \alpha\sum_{y\in S} P_a(x,y) J^*(y)\}$

动态规划算子 $T_u J = g_u + \alpha P_u J$

$TJ = \min_u T_u J$

③ 数值迭代

算法：$J_0, k=0, \varepsilon>0 \Rightarrow J_{k+1} = TJ_k, k\to k+1 \Rightarrow \|J_{k+1} - J_k\| < \varepsilon$

贝尔曼方程的解 $\lim_{k\to\infty} J_k = J^*$，能收敛

思路：J^* 收敛

④ 高斯-塞得尔迭代

$(FJ)(x) = \min_a\{g_a(x) + \alpha\sum_{y<x} P_a(x,y)(FJ)(y) + \alpha\sum_{y\ge x} P_a(x,y) J(y)\}$

最大模收缩 $\|FJ - F\bar{J}\|_\infty \le \alpha\|J - \bar{J}\|_\infty$

固定点 J^*，$FJ^* = J^*$ 唯一

⑤ Jacobi 迭代

对于线性方程组 $AX = b$

算法 $x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{\substack{j=1\\ j\neq i}}^{n} a_{ij} x_j^{(k)}\right)$ 即主项化为移项方程式

对比 Gauss-Seidel $x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)}\right)$

G-S $\begin{pmatrix} x^{(k+1)} \end{pmatrix} = \begin{pmatrix} 0 & & \\ x^{(k+1)} & 0 & \\ & \ddots & 0 \end{pmatrix}$ Jacobi $\begin{pmatrix} x^{(k+1)} \end{pmatrix} \begin{pmatrix} 0 & & \\ x^{(k)} & 0 & \\ & \ddots & 0 \end{pmatrix}$

KOKUYO

扫描全能王
3亿人都在用的扫描App

⑥ 策略迭代

算法：$u_0, k=0 \Rightarrow J_{u_k} = g_{u_k} + \alpha P_{u_k} J_{u_k} \Rightarrow u_{k+1} = u J_{u_k} \Rightarrow u_{k+1} = u_k$

固定点：u^*

⑦ 异步策略迭代

算法：$u_0, J_0, k=0 \Rightarrow \begin{cases} J_{k+1}(x) = T_{u_k} J_k(x) \\ u_{k+1}(x) = u_{J_k}(x) \end{cases}$ or $\Rightarrow k = k+1 \Rightarrow$ 收敛

⑧ 线性回归

最小二乘：$Var(E|X) = \frac{\varepsilon'\varepsilon}{n-k} = \frac{(Y-X\hat{\beta})'(Y-X\hat{\beta})}{n-k}$

$\frac{\partial Var}{\partial \hat{\beta}} = 0 \Rightarrow \frac{\partial (Y'Y - Y'X\hat{\beta} - \hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta})}{\partial \hat{\beta}} = 0 \Rightarrow \hat{\beta} = (X'X)^{-1}X'Y = \beta + (X'X)^{-1}X\varepsilon$

$\Rightarrow -X'Y - X'Y + 2X'X\hat{\beta} = 0$

协方差矩阵：$Var(\hat{\beta}|X) = E((\hat{\beta} - E(\hat{\beta}))(\hat{\beta} - E(\hat{\beta}))')$

$= E((\hat{\beta} - \beta)(\hat{\beta} - \beta)')$

$= E((\varepsilon' X (X'X)^{-1})(X'X)^{-1}\varepsilon)$

$= (X'X)^{-1} X' E(\varepsilon\varepsilon') X (X'X)^{-1}$

$E(\varepsilon - \varepsilon') = \sigma^2 I$

$Var(\hat{\beta}|X) = \sigma^2 (X'X)^{-1}$

$= s^2 (X'X)^{-1}$

⑨ 离散数据

负二项分布 在发现固定失败次数 r 之前的成功次数

$f(x) = C_{r+x-1}^{x} \pi^r (1-\pi)^x$

$E(x) = \frac{r(1-\pi)}{\pi} = \mu$

$Var(x) = \mu + \frac{1}{r}\mu^2$

超几何分布 从 n_1 个中抽 x 个，有 n_2 个 2，$n_1 + n_2 = n$，抽 m 个

$f(x) = \frac{C_{n_1}^{x} C_{n_2}^{m-x}}{C_n^m}$ $Var(X) = \frac{n_1 n_2 m(n-m)}{n^2(n-1)}$

$E(x) = \frac{n_1 m}{n}$

Campus

扫描全能王 3亿人都在用的扫描App

No.

Date

多项式分布：多重二项分布

$$f(x_1, x_2 \cdots x_k) = \frac{n!}{x_1! x_2! \cdots x_k!} \pi_1^{x_1} \cdots \pi_k^{x_k}$$

$$E(X_j) = n\pi_j$$

$$Var(X_j) = n\pi_j(1-\pi_j)$$

⑩ 最大似然估计

二项分布 $L(\pi) = \prod_{i=1}^{m} C_n^{x_i} \pi^{x_i} (1-\pi)^{n-x_i}$

$$\log L(\pi) = \sum_{i=1}^{m} \log C_n^{x_i} + \log \pi \sum_{i=1}^{m} x_i + \log(1-\pi) \sum_{i=1}^{m} (n - x_i)$$

$$\frac{\partial \log L(\pi)}{\partial \hat{\pi}} = 0 \Rightarrow \hat{\pi} = \frac{\sum_{i=1}^{m} x_i}{mn}$$

泊松分布 $L(\pi) = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{x_1! x_2! \cdots x_n!}$ $\log(L(\pi)) = \sum_{i=1}^{n} x_i \log\lambda - n\lambda \sum_{i=1}^{n} \log(x_i!)$

$$\frac{\partial \log(L(\pi))}{\partial \lambda} = \frac{\sum x_i}{\lambda} - n = 0 \quad \hat{\lambda} = \frac{\sum x_i}{n}$$

方差 $Var(\hat{\pi})$ 示代入

or $Var(\hat{\theta}; X) = -L''(\theta)^{-1}$

⑪ 广义线性回归

发生比 $odds = \frac{p}{1-p}$ $p = \frac{odds}{1+odds}$

⑫ 多目标优化问题

三要素：$\min_x \{f_1(x), f_2(x) \cdots f_n(x)\}$

$x \rightarrow$ 决策变量

$f \rightarrow$ 目标函数

约束条件

占优性 目标函数不劣于其他，且存在严格优的目标函数 → 帕累托最优解

帕累托最优解集合：帕累托前缘

KOKUYO

CS 扫描全能王
3亿人都在用的扫描App