决策方法论

Decision Making Technology

课程老师：张辉、陈涛、张小乐
E-mail：zhhui@tsinghua.edu.cn
chentao.a@Tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn

回顾

基础与概念：

概率：随机事件、统计规律

条件概率：$P(B|A)$

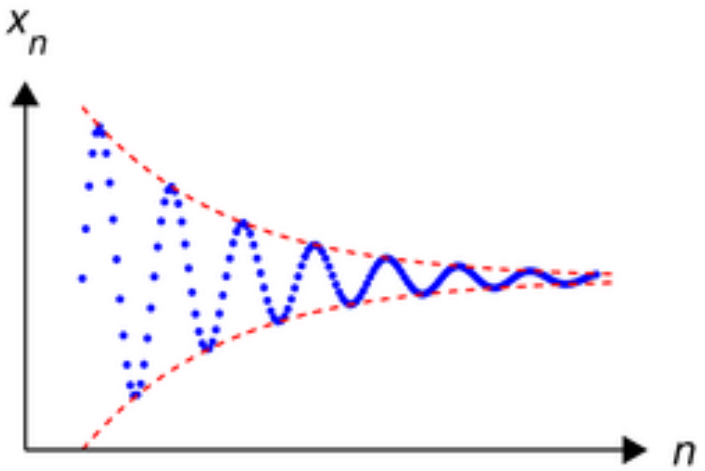
全概率公式：$P(A) = \Sigma P(B_i)P(A|B_i)$

期望：$E(X)$

寻找参量：$y = \arg\min f(t)$

柯西序列

范数：$||\cdot||$

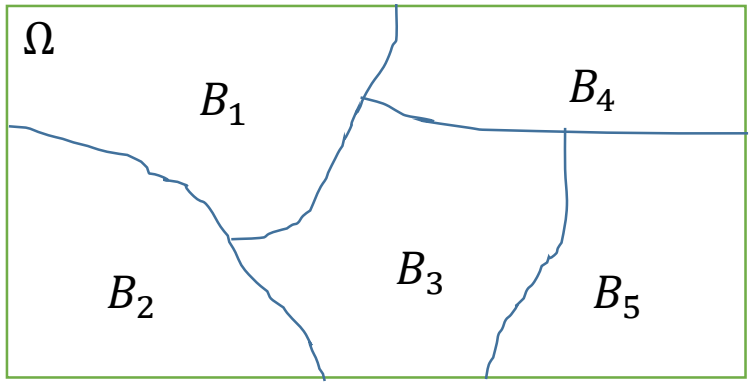


回顾

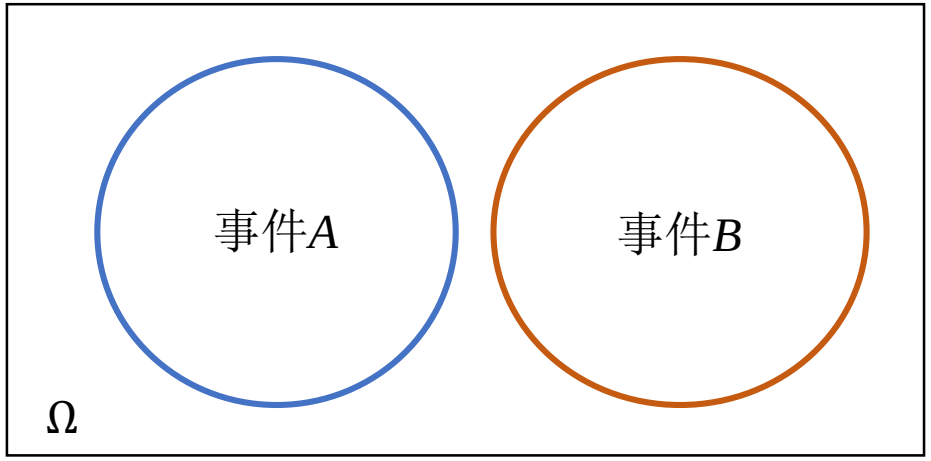
全概率公式：

设$B_1, B_2, \ldots, B_n$是样本空间Ω的一个分割，即B_i之间~~相互独立~~**互斥**，且$\cup_{i=1}^{n} B_i = \Omega$，若有$P(B_i) > 0$，则对于任意事件$A$有：

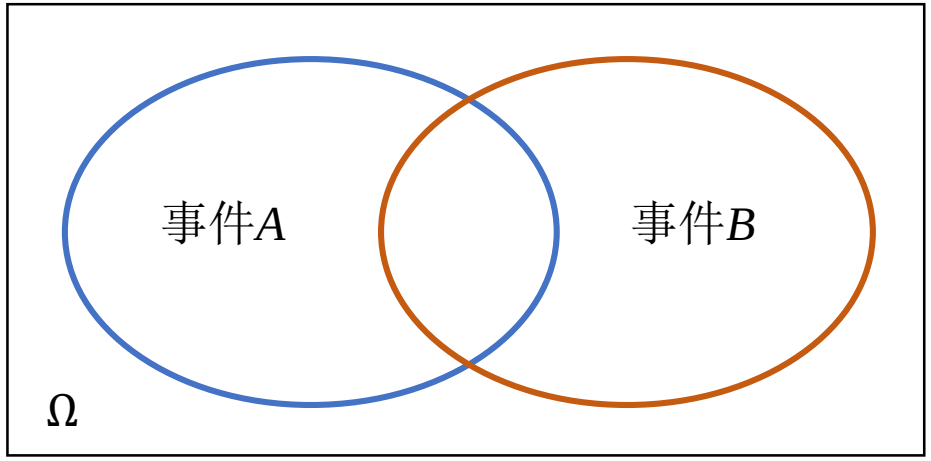
$$P(A) = \Sigma P(B_i)P(A|B_i)$$



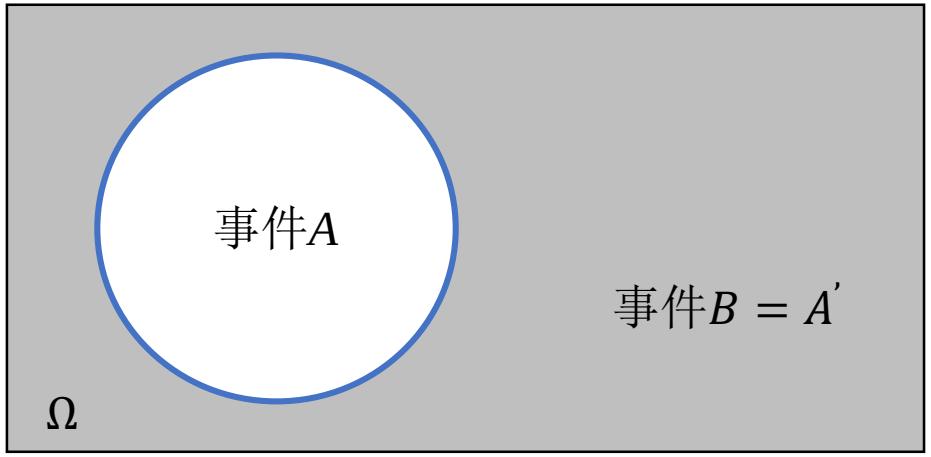
回顾



事件A和B互斥，$A \cap B = \emptyset$，$P(AB) = 0$

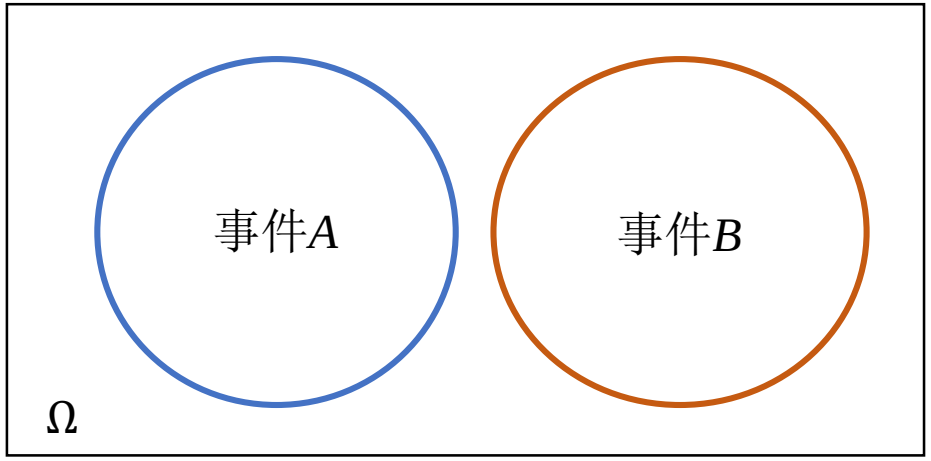


事件A和B独立：$P(AB) = P(A)P(B|A) = P(A)P(B)$

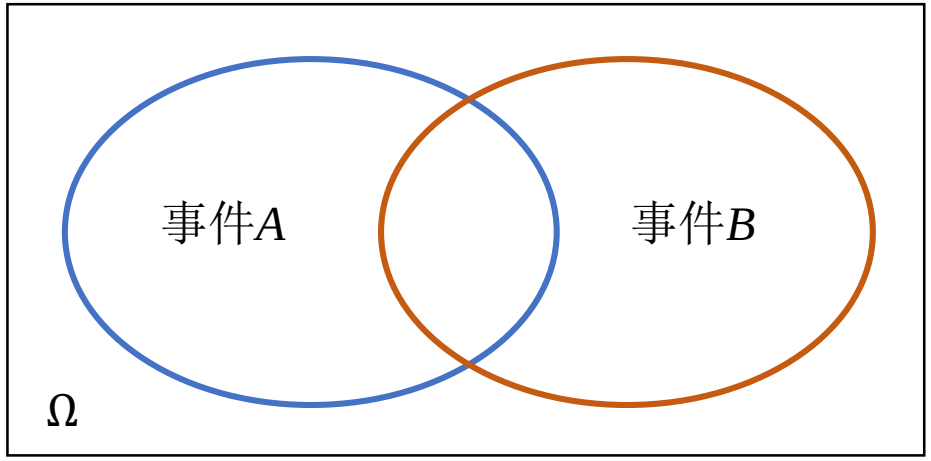


事件B是事件A的对立事件，$A \cap B = \emptyset$，$P(B) = 1 - P(A)$

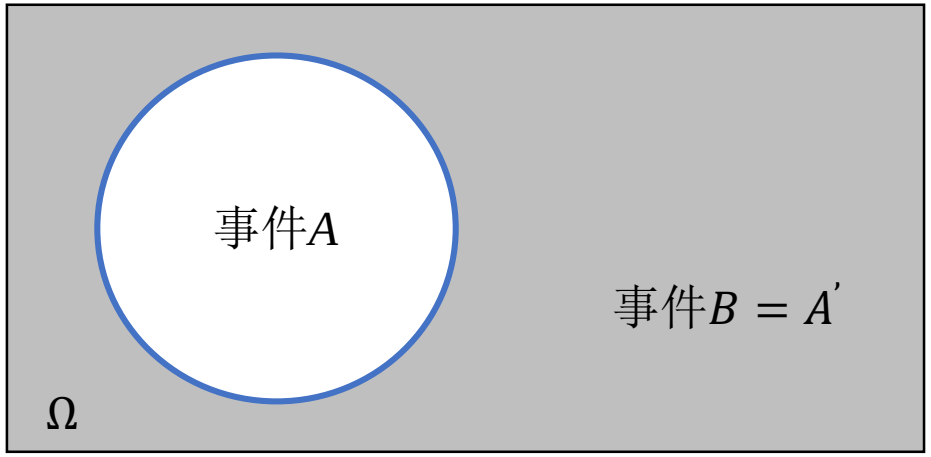
回顾



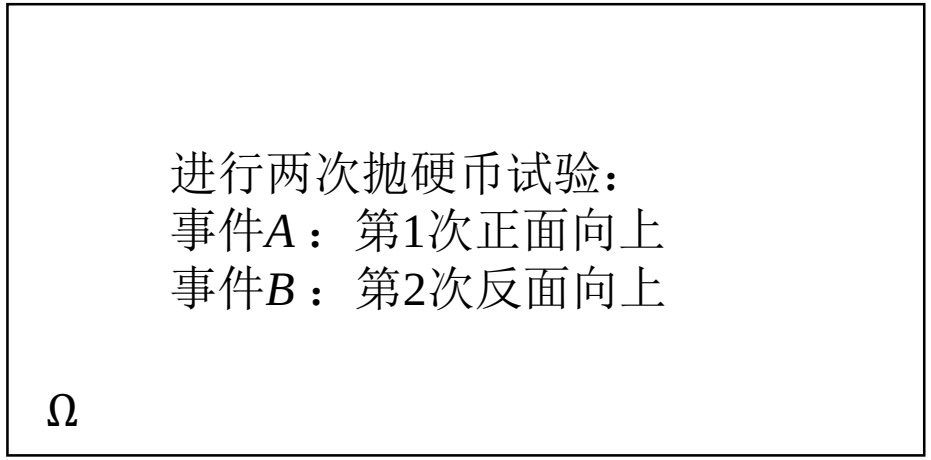
事件A和B互斥，$A \cap B = \emptyset$，$P(AB) = 0$



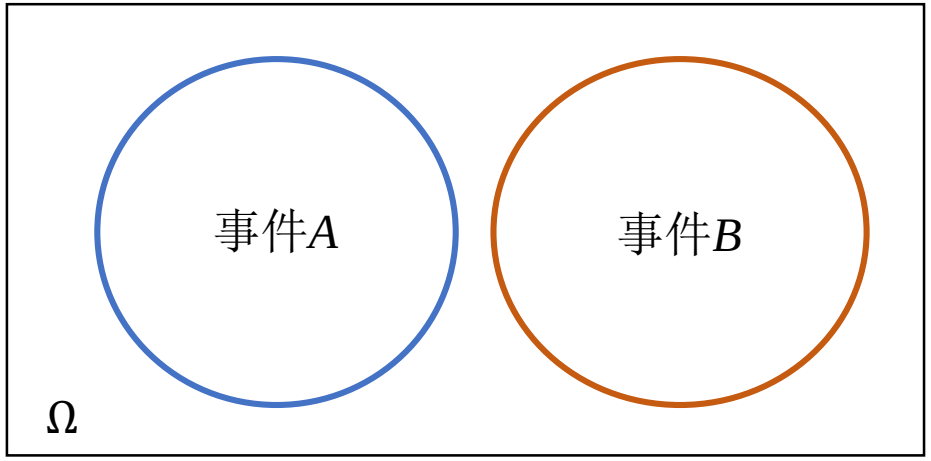
事件A和B独立：$P(AB) = P(A)P(B|A) = P(A)P(B)$



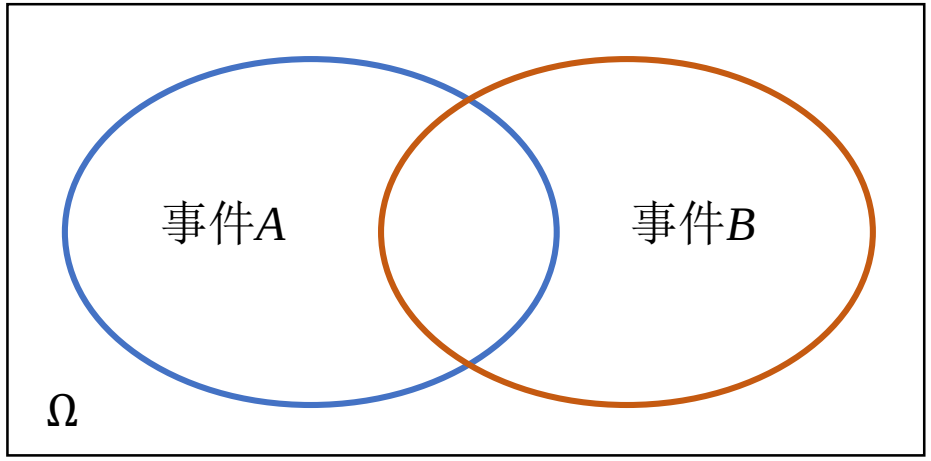
事件B是事件A的对立事件，$A \cap B = \emptyset$，$P(B) = 1 - P(A)$



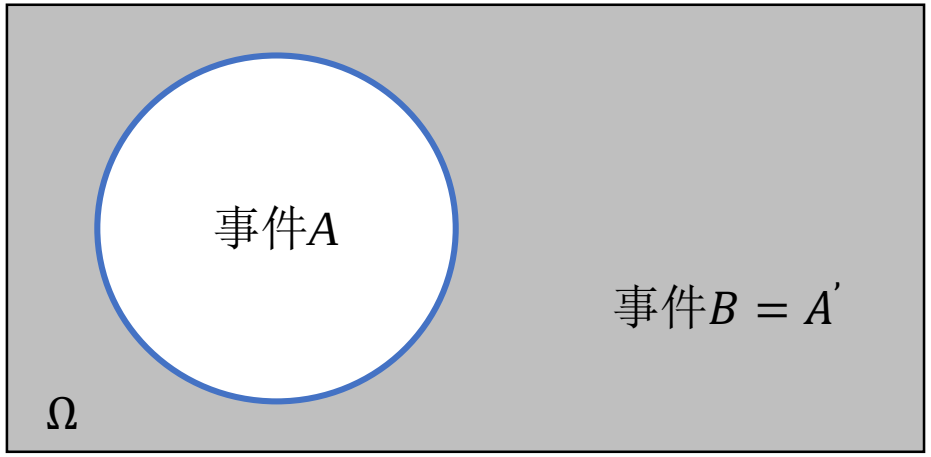
回顾



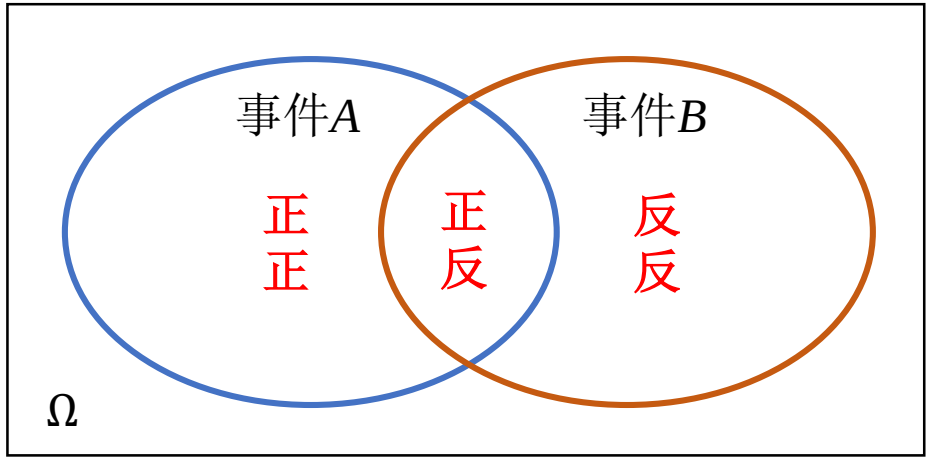
事件A和B互斥，$A \cap B = \emptyset$，$P(AB) = 0$



事件A和B独立：$P(AB) = P(A)P(B|A) = P(A)P(B)$



事件B是事件A的对立事件，$A \cap B = \emptyset$，$P(B) = 1 - P(A)$



- 基础与概念
- **马尔科夫决策过程**
- 有限阶段问题：逆推归纳法
- 折扣成本问题：代价函数和贝尔曼方程

马尔科夫决策过程

概述——

马尔科夫性是指一个随机过程未来发展的概率规律与观察之前的历史无关的性质。马尔科夫性又可简单叙述为状态转移概率的无后效性。

状态转移概率具有马尔科夫性的随机过程即为马尔科夫过程。马尔科夫决策过程又可看作随机对策的特殊情形，在这种随机对策中对策的一方是无意志的。马尔科夫决策过程还可作为马尔科夫型随机最优控制，其决策变量就是控制变量。

马尔科夫决策过程

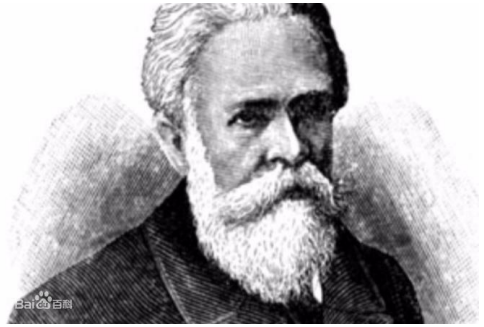
概述——

马尔科夫性是指一个随机过程未来发展的概率规律与观察之前的历史无关的性质。马尔科夫性又可简单叙述为状态转移概率的无后效性。

状态转移概率具有马尔科夫性的随机过程即为马尔科夫过程。马尔科夫决策过程又可看作随机对策的特殊情形，在这种随机对策中对策的一方是无意志的。马尔科夫决策过程还可作为马尔科夫型随机最优控制，其决策变量就是控制变量。

马尔科夫决策过程是指决策者周期地或连续地观察具有马尔科夫性的随机动态系统，连续地作出决策。即根据每个时刻观察到的状态，从可用的行动集合中选用一个行动作出决策，系统下一步（未来）的状态是随机的，并且其状态转移概率具有马尔科夫性。

这不是个一次性的决策问题 。
随着时间推移必须一直采取行动，被称为渐进的决策过程。



马尔科夫决策过程

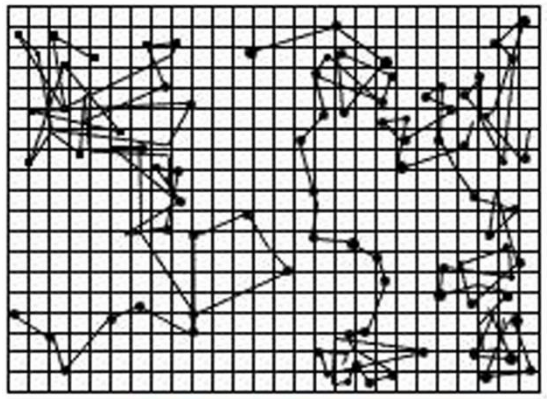
例如：

传染病感染人数；

布朗运动；

车站排队人数；

……







马尔科夫决策过程

马尔科夫特性：

当系统的未来状态x_{t+1}，x_{t+2}，……仅与当前状态x_t有关，而与历史状态x_{t-1}，x_{t-2}，……无关，则该系统具有*马尔科夫特性*。

马尔科夫决策过程

马尔科夫特性：

当系统的未来状态x_{t+1}，x_{t+2}，……仅与当前状态x_t有关，而与历史状态x_{t-1}，x_{t-2}，……无关，则该系统具有*马尔科夫特性*。

从概率角度：

对任意的$t_1 < t_2 < \cdots < t_n < t_{n+1} \in T$，将时刻$t_n$作为“现在”，那么时刻$t_{n+1}$就表示“将来”，而时刻$t_1, t_2, \ldots, t_{n-1}$则表示“过去”，以下条件概率特性：

$$\boldsymbol{P(X(t_{n+1}) = j | X(t_1) = i_1, X(t_2) = i_2, \cdots, X(t_n) = i_n) = P(X(t_{n+1}) = j | X(t_n) = i_n),}$$

$\forall i_1, i_2, \cdots, i_n, j \in I$　　I为状态空间

马尔科夫决策过程

马尔科夫特性：

当系统的未来状态x_{t+1}，x_{t+2}，……仅与当前状态x_t有关，而与历史状态x_{t-1}，x_{t-2}，……无关，则该系统具有*马尔科夫特性*。

从概率角度：

对任意的$t_1 < t_2 < \cdots < t_n < t_{n+1} \in T$，将时刻$t_n$作为“现在”，那么时刻$t_{n+1}$就表示“将来”，而时刻$t_1, t_2, \ldots, t_{n-1}$则表示“过去”，以下条件概率特性：

$$\boldsymbol{P(X(t_{n+1}) = j | X(t_1) = i_1, X(t_2) = i_2, \cdots, X(t_n) = i_n) = P(X(t_{n+1}) = j | X(t_n) = i_n),}$$

$\forall i_1, i_2, \cdots, i_n, j \in I$　　I为状态空间

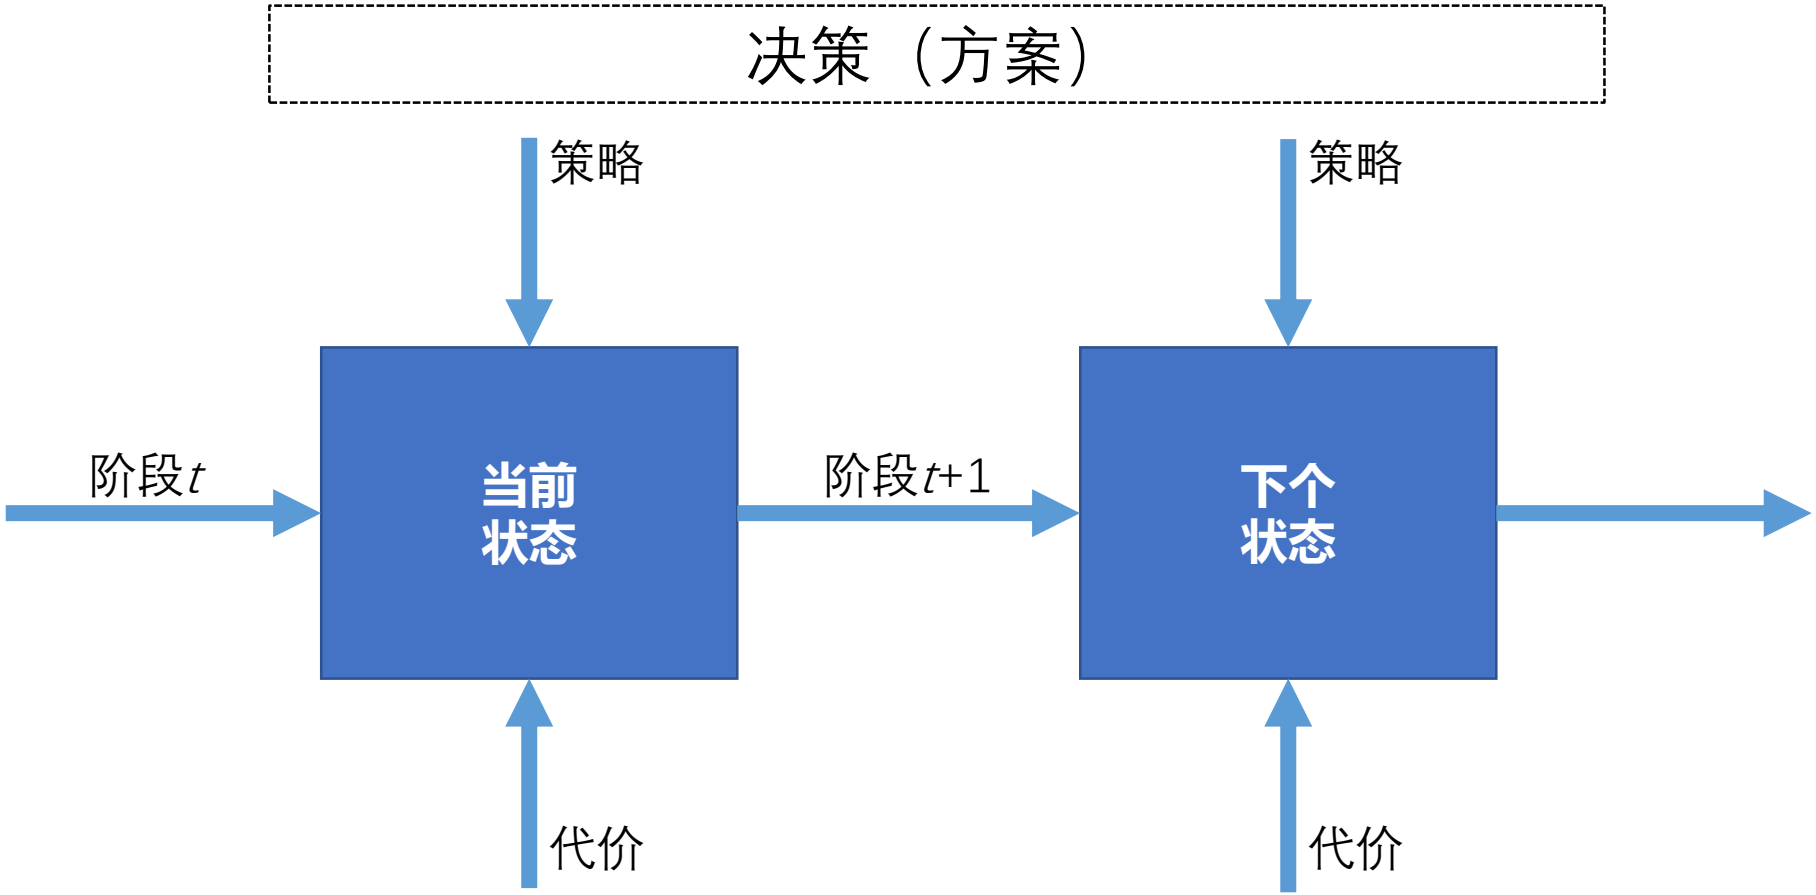
在已知“现在”的条件下，“将来”与“过去”彼此独立的特性就被称为马尔科夫性，具有这种性质的随机过程就叫做马尔科夫过程。

马尔科夫决策过程

马尔科夫决策过程七要素：

- **阶段**：对于一个过程可以按一定的标准分为若干阶段，通常可以用时间作为参数，有时也用位置等。阶段的集合记为T
- **状态**：描述系统特征的变量，状态的集合记为S
- **决策（方案）**：决策者在每个阶段可采取的行动方案，记为a_t，所有可供选择的决策方案的集合记为A_{x_t}
- **状态转移概率**：在一定方案下，系统经过一个阶段从某一状态转移到另一状态的可能性，记为$P_a(x,y)$
- **成本**：在每一时刻都会产生成本，记为$g_{a_t}(x_t)$
- **策略**：根据当前时刻t和当前状态x，从可选行为集A_{x_t}中指定一个行为，记为u
- **代价函数**：衡量各方案好坏的指标，记为J

马尔科夫决策过程



序列决策模型的过程示意

马尔科夫决策过程

马尔科夫决策过程的表示方法

1. 系统方程：

$$x_{t+1} = f(x_t, a_t, w_t)$$

其中，$x_t \in S$，$a_t \in A_{x_t}$，$w_t \in W$分别表示t时刻的系统状态、决策和随机干扰。也就是说，$t+1$时刻的系统状态是t时刻的系统状态、决策和随机干扰的某个函数f。

重要假设：当系统的未来状态x_{t+1}，x_{t+2}，…仅与当前状态x_t有关，而与历史状态x_{t-1}，x_{t-2}，…无关，即该系统具有马尔科夫性。

2. 转移概率矩阵：

给定当前状态为x，当前行为为a，则对于每一对“状态-行为”(x, a)，$P_a(x, y)$表示下一个状态为y的概率。

马尔科夫决策过程

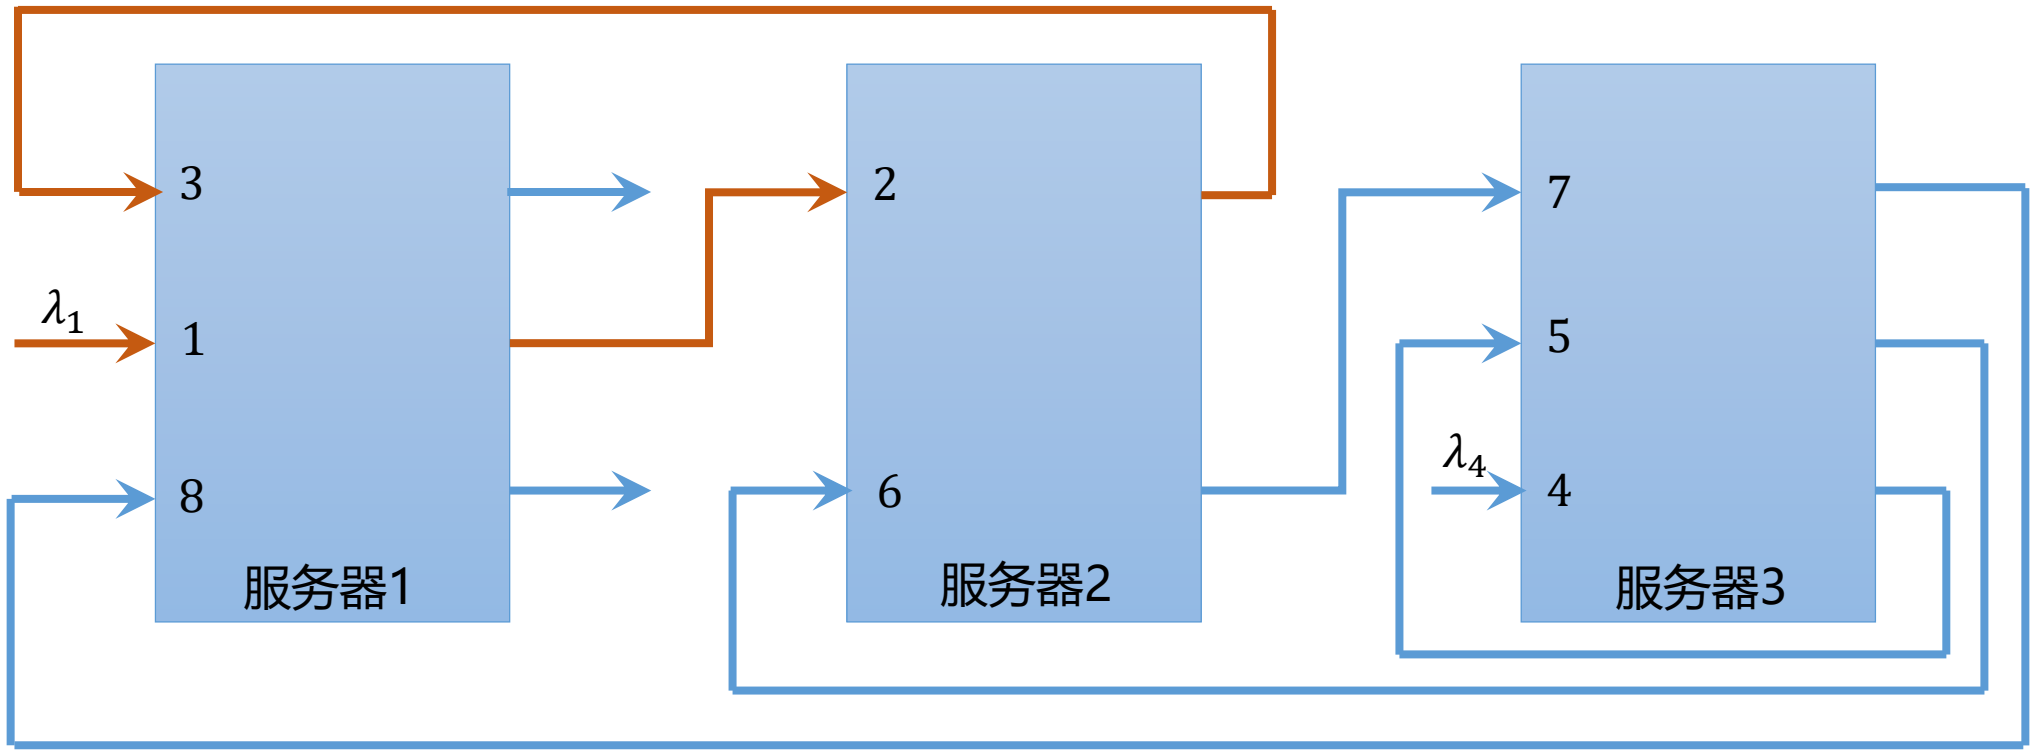
马尔科夫决策过程：

由数组$(\boldsymbol{S}, \boldsymbol{A}_{\cdot}, \boldsymbol{P}_{\cdot}(\cdot,\cdot), \boldsymbol{g}_{\cdot}(\cdot))$来确定

注意：为方便起见，在整个课程中，**假定$\boldsymbol{S}$和$\boldsymbol{A}_{x_t}$为有限集合**。

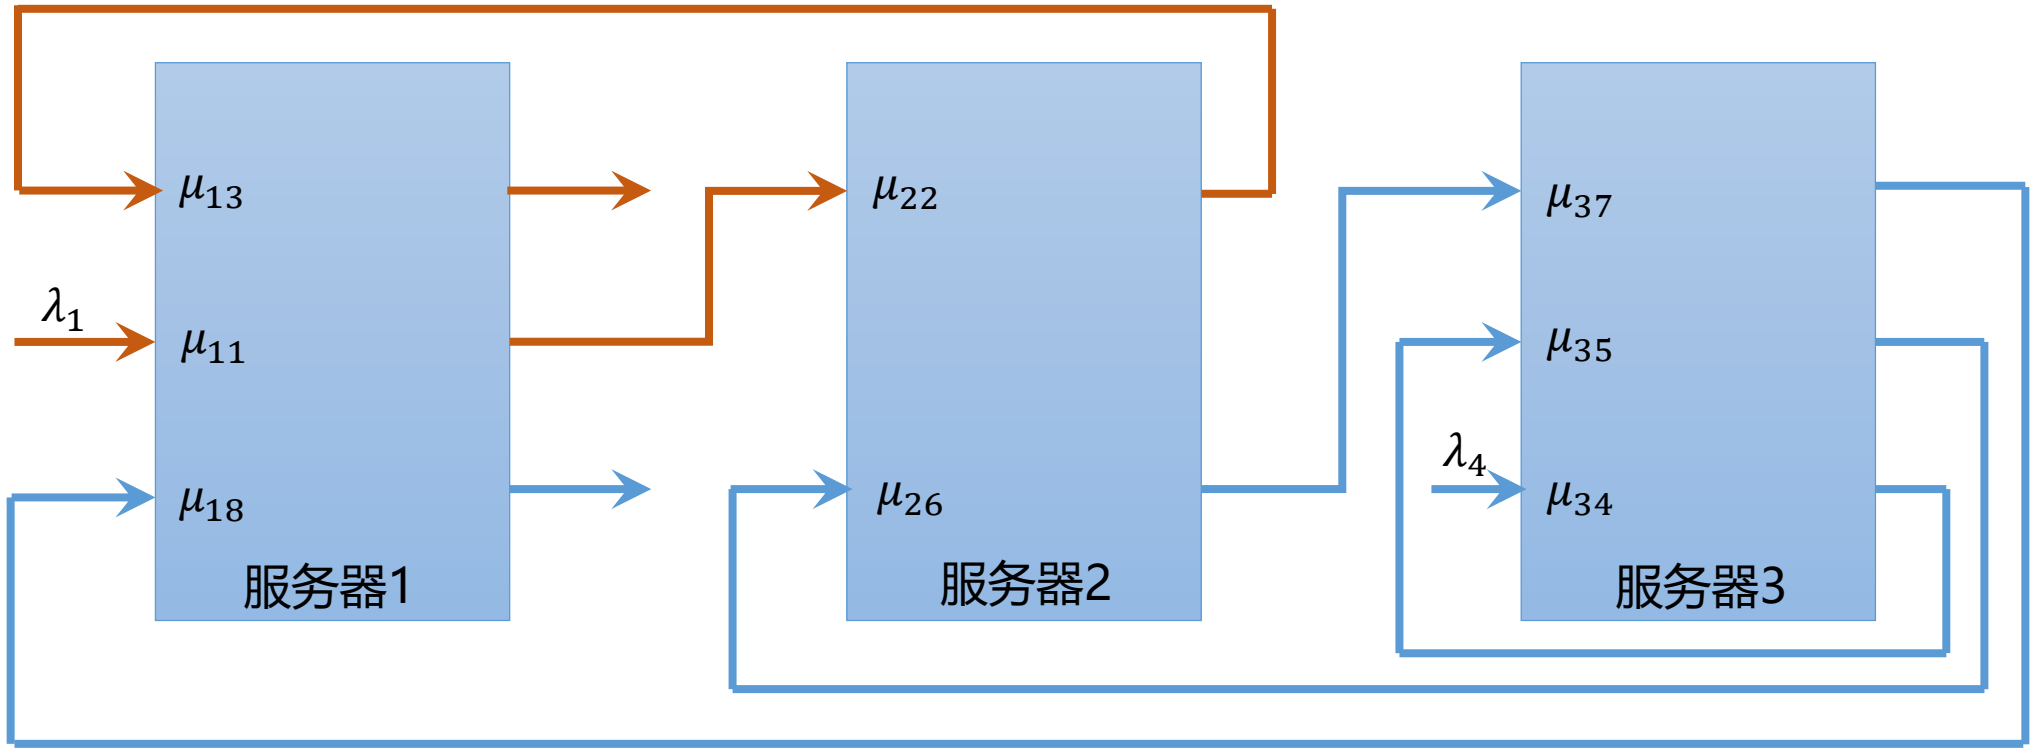
举例：排队网络模型

假设网络模型包括**3台服务器**，2个不同的外部任务入口，**2条固定的工作流程**1,2,3和4,5,6,7,8，在不同处理阶段的形成**8个排队任务**。



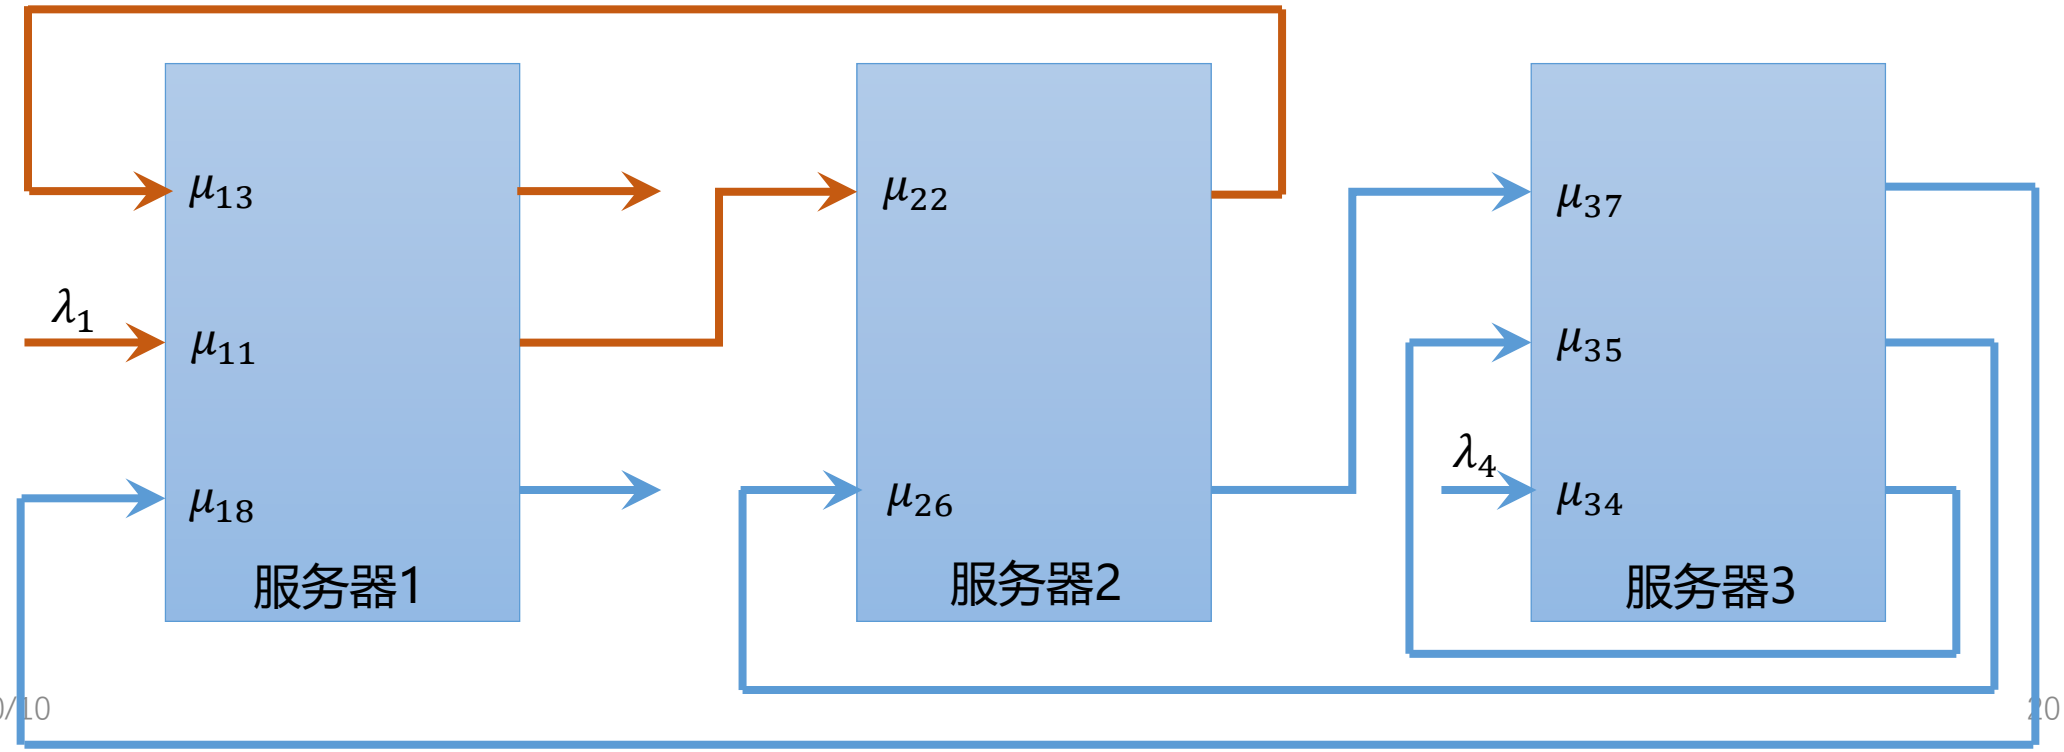
举例：排队网络模型

我们假设服务时间满足几何随机变量：当服务器 i 在一个时间步内服务于队列 j 中的某一单元时，在本时间步内结束服务的概率为 μ_{ij}，并独立于之前对该单元的服务。



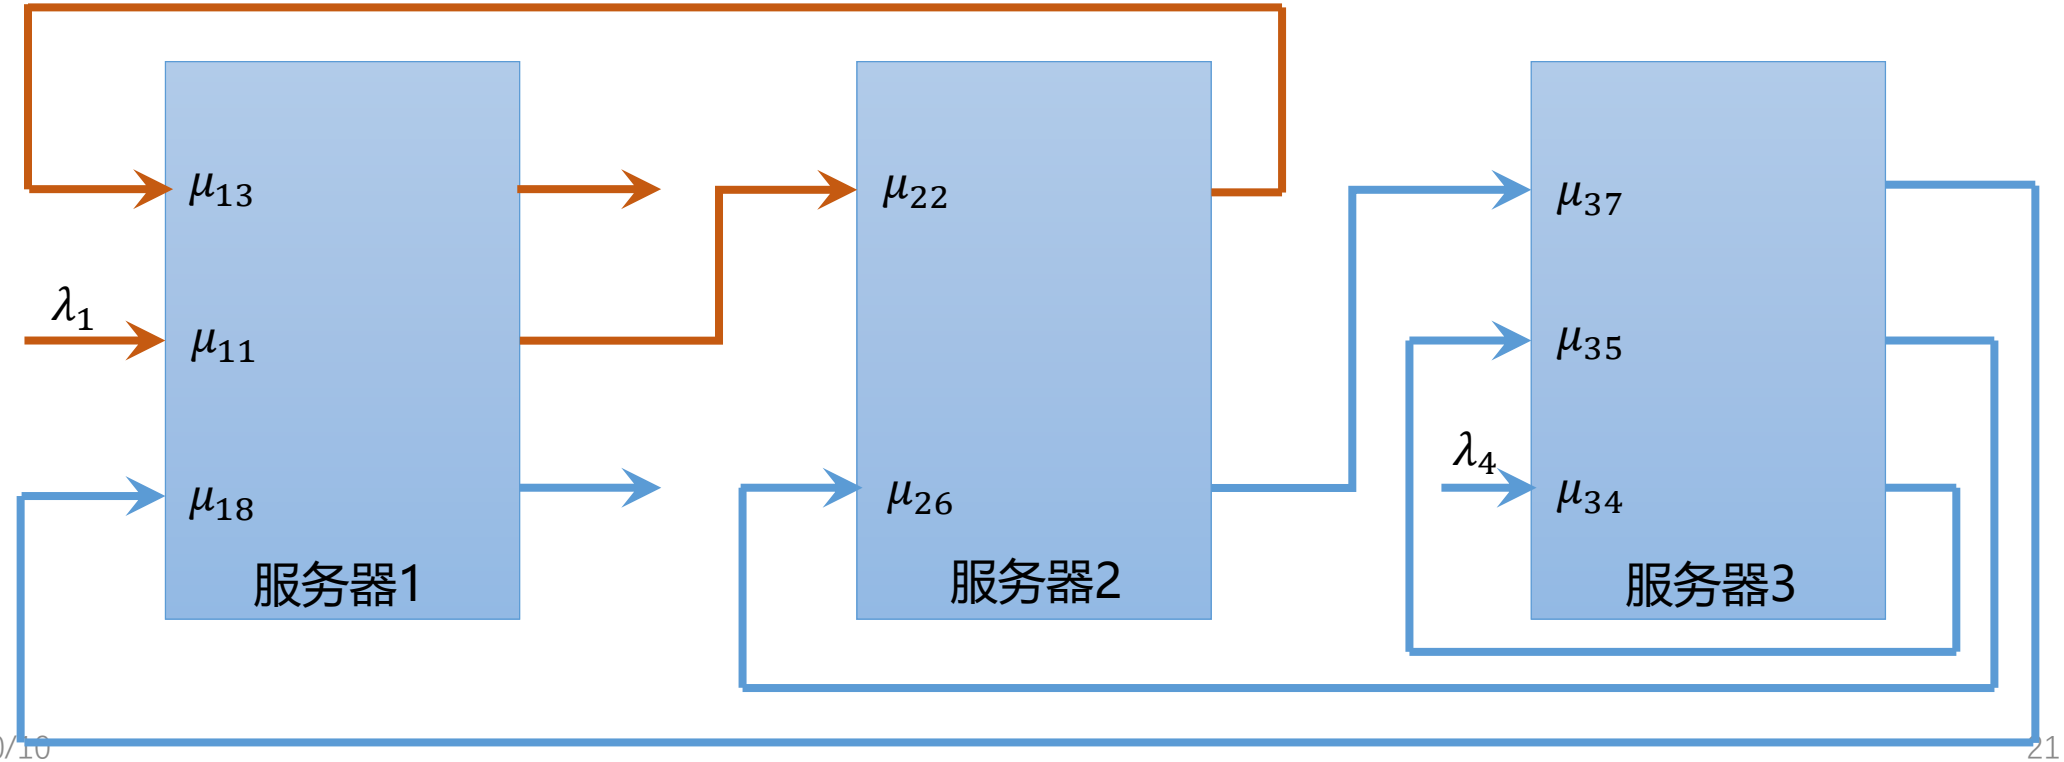
举例：排队网络模型

- 任一时间步内，新的工作单元可以概率λ_j从队列$j=1,4$加入本系统
- 新的工作单位独立于之前到达的工作单元
- 某工作流程完成后，此工作单元将被移送到整个流程的下一队列
- 当所有流程已完成则该工作单元直接退出系该统



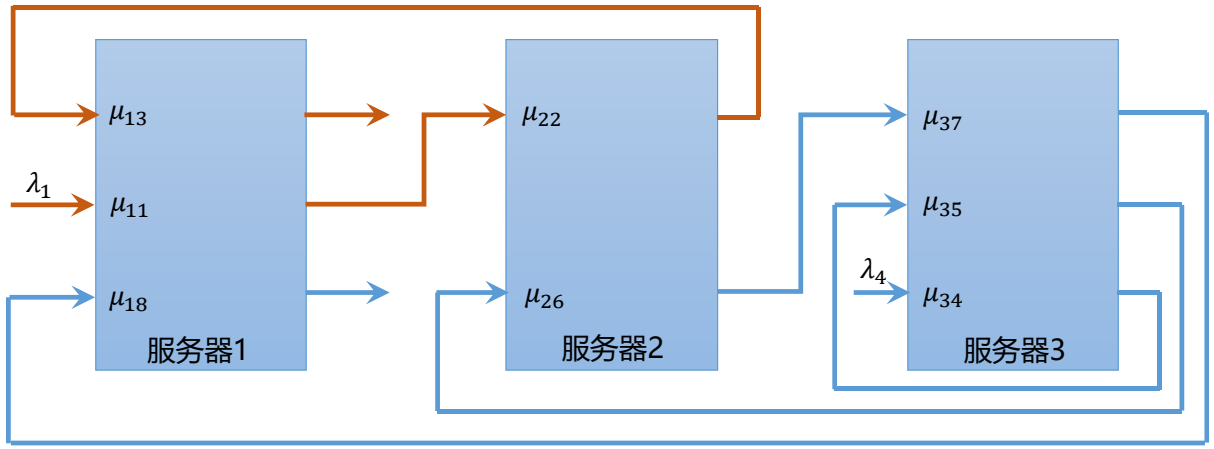
举例：排队网络模型

由于每个服务器都服务于多个队列，则在单个时间步内，必须选择确定服务器为哪个队列服务。这种选择可用八维向量代码a编码，说明正接受服务的队列，并满足每个服务器只为单个队列服务的条件，即$a_i \in \{0,1\}$，且 $a_1+a_3+a_8 \leq 1$， $a_2+a_6 \leq 1$，$a_4+a_5+a_7 \leq 1$



举例：排队网络模型

我们用对系统x的函数u来表述这个策略，该策略返回服务器工作分配情况。我们可用转移概率来表示队列的长度的变化——下一状态队列长度$x(t+1)$的条件概率由当前系统状态队列长度$x(t)$和行为$a(t)$确定，例如：



到达队列1：

$$P(x_1(t+1) = x_1(t) + 1 | x(t), a(t)) = \lambda_1$$

离开队列1且到达队列2：

$$P(x_2(t+1) = x_2(t) + 1, x_1(t+1) = x_1(t) - 1 | x(t), a(t)) = \mu_{11} I(x_1(t) > 0, a_1(t) = 1)$$

离开队列2且到达队列3：

$$P(x_3(t+1) = x_3(t) + 1, x_2(t+1) = x_2(t) - 1 | x(t), a(t)) = \mu_{22} I(x_2(t) > 0, a_2(t) = 1)$$

离开队列3：

$$P(x_3(t+1) = x_3(t) - 1 | x(t), a(t)) = \mu_{13} I(x_3(t) > 0, a_3(t) = 1)$$

其中$I(\cdot)$为指示函数，其他事件的转移概率与此处定义相似。

最优准则

最优准则——用以定义如何对不同时刻 t 的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

最优准则

最优准则——用以定义如何对不同时刻 t 的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

2. 平均成本：

$$\limsup_{T\to\infty} \mathrm{E}\left[\frac{1}{T}\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

最优准则

最优准则——用以定义如何对不同时刻 t 的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

2. 平均成本：

$$\limsup_{T\to\infty} \mathrm{E}\left[\frac{1}{T}\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

3. 无限折扣成本：

$$\mathrm{E}\left[\sum_{t=0}^{\infty} \alpha^t g_{a_t}(x_t)\middle| x_0 = x\right]$$

最优准则

最优准则——用以定义如何对不同时刻 t 的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

2. 平均成本：

$$\limsup_{T\to\infty} \mathrm{E}\left[\frac{1}{T}\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

3. 无限折扣成本：

$$\mathrm{E}\left[\sum_{t=0}^{\infty} \alpha^t g_{a_t}(x_t)\middle| x_0 = x\right]$$

为什么要用期望E[ ]表示

原因：

在某个状态下，在不同的阶段可能需要的成本都是不同的，或者说获得的收益是不同的。

最优准则

最优准则——用以定义如何对不同时刻 t 的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

2. 平均成本：

$$\limsup_{T\to\infty} \mathrm{E}\left[\frac{1}{T}\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

3. 无限折扣成本：

$$\mathrm{E}\left[\sum_{t=0}^{\infty} \alpha^t g_{a_t}(x_t)\middle| x_0 = x\right]$$

为什么要使用折扣因子用期望α

$\alpha \in (0,1)$是表示即时优先的折扣因子，特别的，当状态矢量空间和行为空间位有限集时，$\bar{\alpha} < 1$足够大，从而对于所有的$\alpha > \bar{\alpha}$折扣成本问题的最优策略对于平均成本问题也是最优。

最优准则

最优准则——用以定义如何对不同时刻 t的成本进行求和。

1. 有限阶段总成本：

$$\mathrm{E}\left[\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

2. 平均成本：

$$\limsup_{T\to\infty} \mathrm{E}\left[\frac{1}{T}\sum_{t=0}^{T-1} g_{a_t}(x_t)\middle| x_0 = x\right]$$

3. 无限折扣成本：

$$\mathrm{E}\left[\sum_{t=0}^{\infty} \alpha^t g_{a_t}(x_t)\middle| x_0 = x\right]$$

•

为什么要使用折扣因子用期望α

$\alpha \in (0,1)$是表示即时优先的折扣因子，特别的，当状态矢量空间和行为空间位有限集时，$\bar{\alpha} < 1$足够大，从而对于所有的$\alpha > \bar{\alpha}$折扣成本问题的最优策略对于平均成本问题也是最优。

采用折扣因子简化了分析和计算方法
- 数学表达上的方便
- 避免产生无限回报的情况
- 可以体现即时回报比延迟回报优先性

谢谢！

Thanks !

课程老师：**张辉、陈涛、张小乐**
E-mail：zhhui@tsinghua.edu.cn
chentao.a@Tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：**胡祥敏、张妍、蹇姚宇蝶**
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn