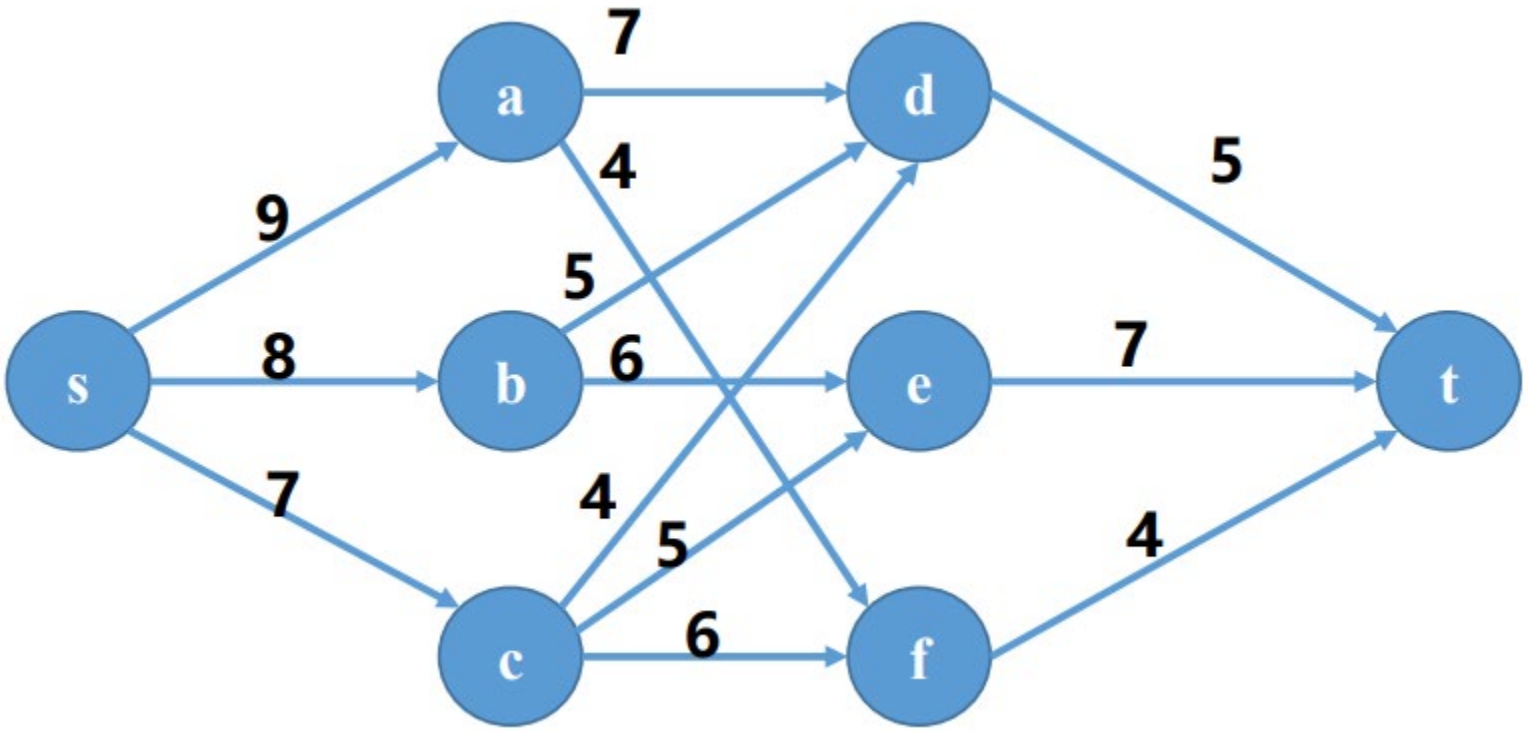
决策方法论

Decision Making Technology

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn

数据驱动的风险量化分析与建模

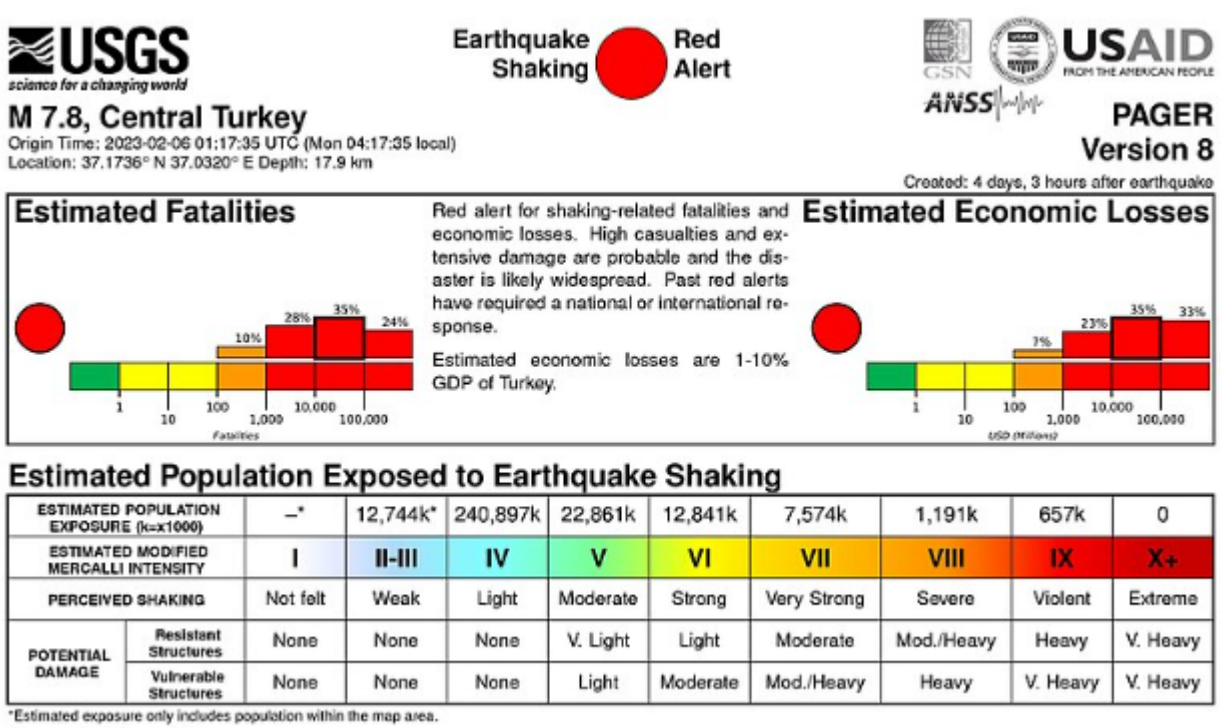
回顾



地震伤亡的影响因素

影响地震伤亡的因素?

- 震级
- 发生时间
- 建筑质量
- 人员年龄结构
- 防灾经验
- ....



USGS science for a changing world

Earthquake Shaking — Red Alert

USAID FROM THE AMERICAN PEOPLE

GSN ANSS

M 7.8, Central Turkey

Origin Time: 2023-02-06 01:17:35 UTC (Mon 04:17:35 local)

Location: 37.1736° N 37.0320° E Depth: 17.9 km

PAGER Version 8

Created: 4 days, 3 hours after earthquake

Estimated Fatalities

Red alert for shaking-related fatalities and economic losses. High casualties and extensive damage are probable and the disaster is likely widespread. Past red alerts have required a national or international response.

Estimated economic losses are 1-10% GDP of Turkey.

Estimated Economic Losses

Estimated Population Exposed to Earthquake Shaking

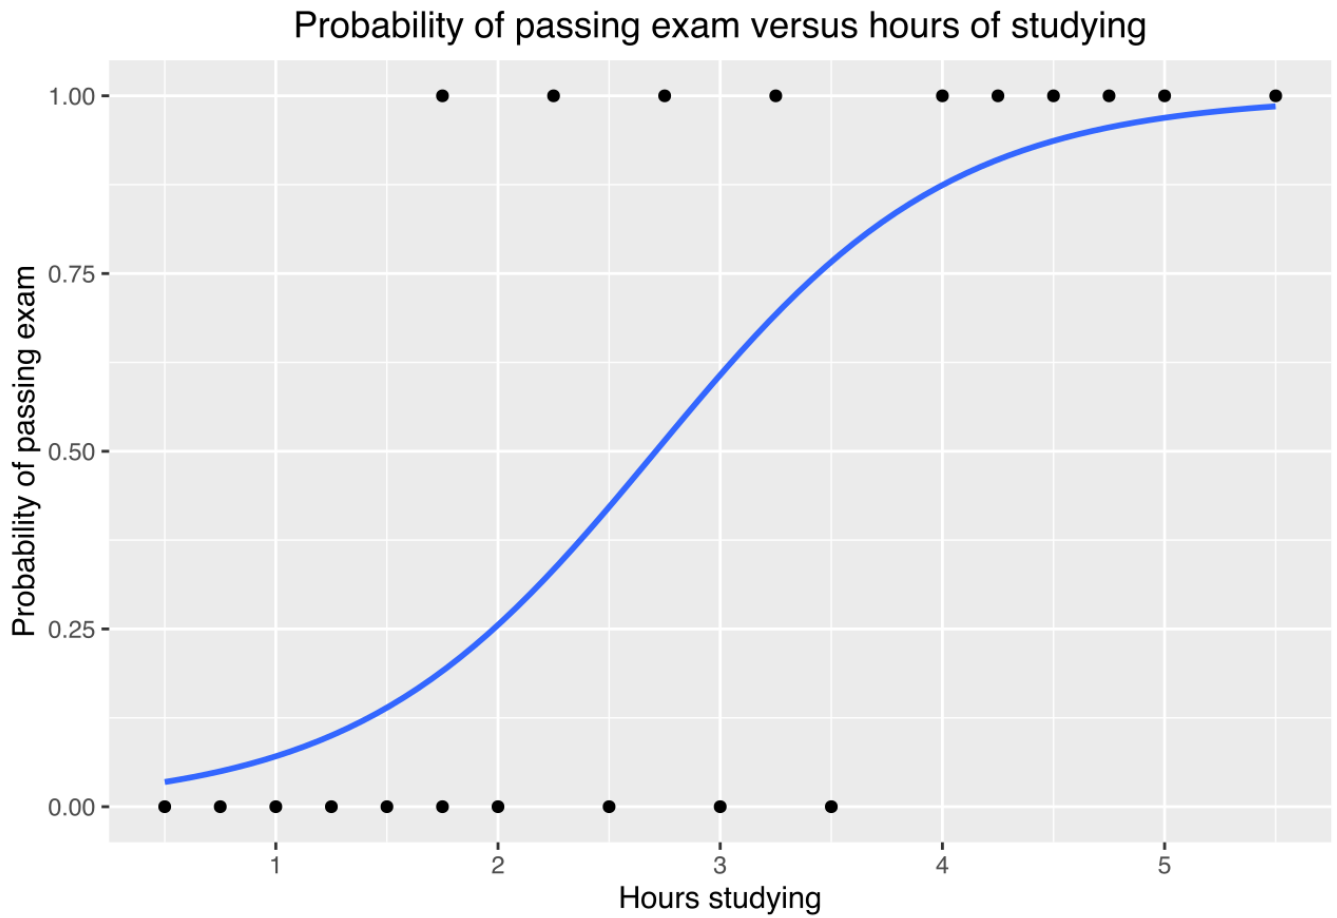
ESTIMATED POPULATION EXPOSURE (k=x1000)		–*	12,744k*	240,897k	22,861k	12,841k	7,574k	1,191k	657k	0
ESTIMATED MODIFIED MERCALLI INTENSITY		I	II-III	IV	V	VI	VII	VIII	IX	X+
PERCEIVED SHAKING		Not felt	Weak	Light	Moderate	Strong	Very Strong	Severe	Violent	Extreme
POTENTIAL DAMAGE	Resistant Structures	None	None	None	V. Light	Light	Moderate	Mod./Heavy	Heavy	V. Heavy
	Vulnerable Structures	None	None	None	Light	Moderate	Mod./Heavy	Heavy	V. Heavy	V. Heavy

*Estimated exposure only includes population within the map area.

影响考试通过率的因素

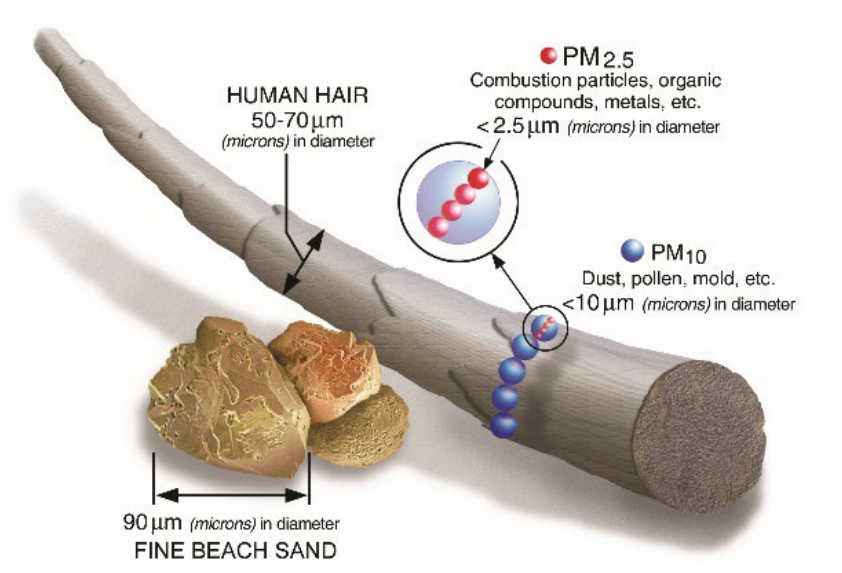
影响考试通过率的因素?

- 学习投入时间
- 试题难度
- 考试时间
- 身体状况
- ….

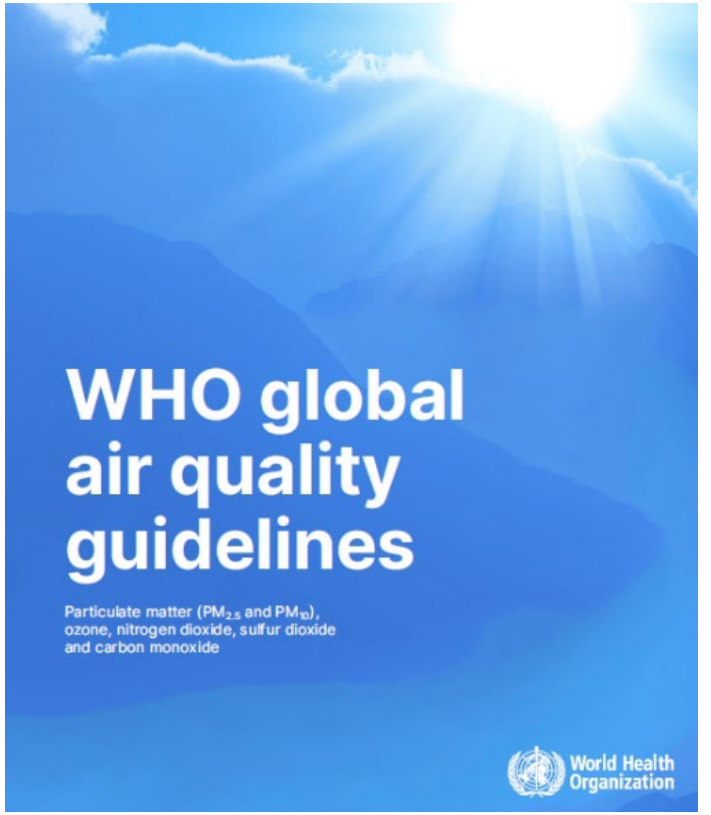


空气污染与健康风险

Particulate Matter 2.5 ($PM_{2.5}$)



Source: US EPA



The WHO updated guidelines (2021) state that **annual average concentrations of $PM_{2.5}$ should not exceed 5 µg/m ^{3}**

空气污染与健康风险

- **Integrated Exposure-Response model (IER)** (2014)
  - Adopted by global burden of disease (GBD) study;
  - World Health Organization (WHO)

Burnett, et al., EHP, 2014

- **Global Exposure Mortality Model (GEMM)** (2018)

Burnett, et al., PNAS, 2018

低暴露水平

北美和欧洲的队列研究

(cohort studies)

高暴露水平

室内空气污染



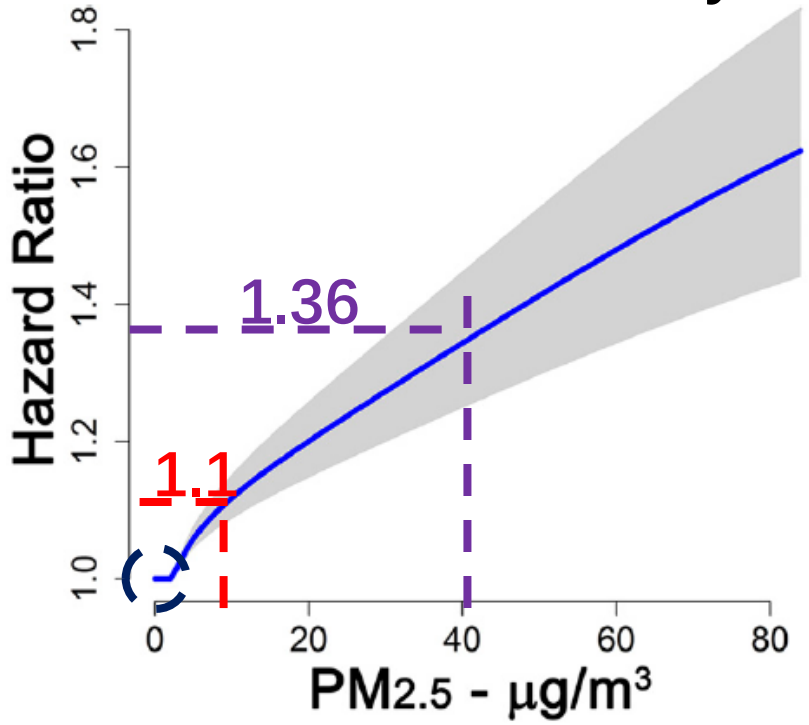
中国队列研究

A cohort study in China

空气污染与健康风险

Global Exposure Mortality Model (GEMM)

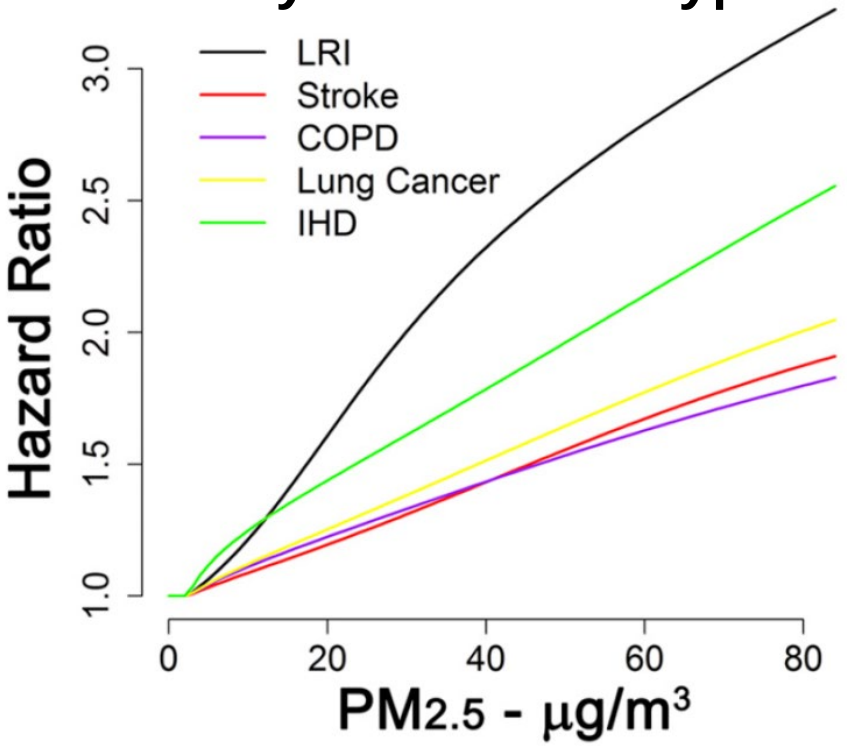
All-cause mortality *



* 由于非传染性疾病和下呼吸道感染导致的死亡

Source: Burnett, et al., PNAS, 2018

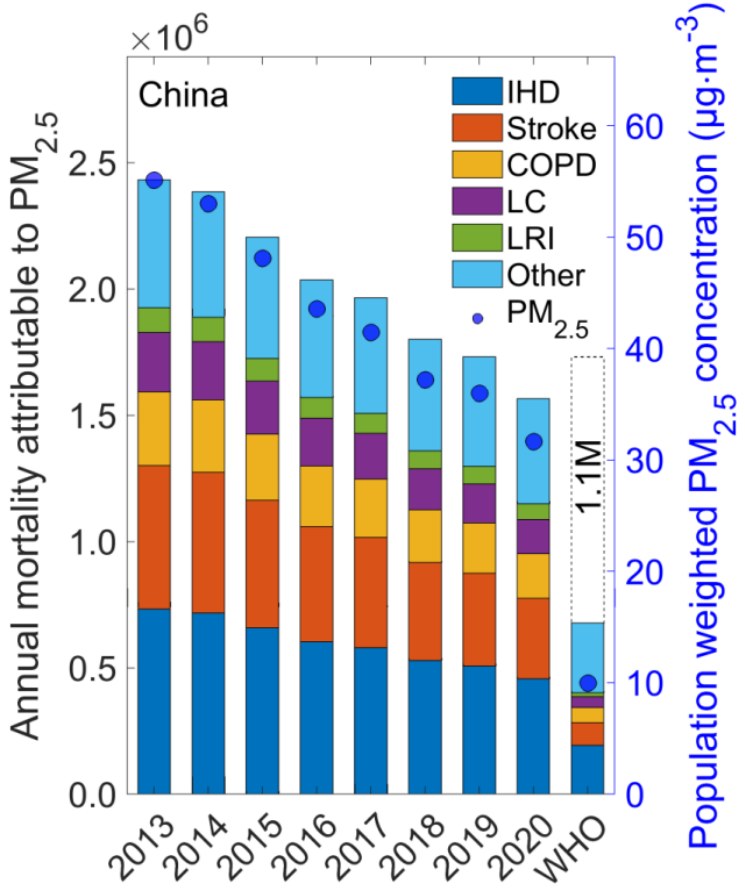
Mortality due to five types of diseases



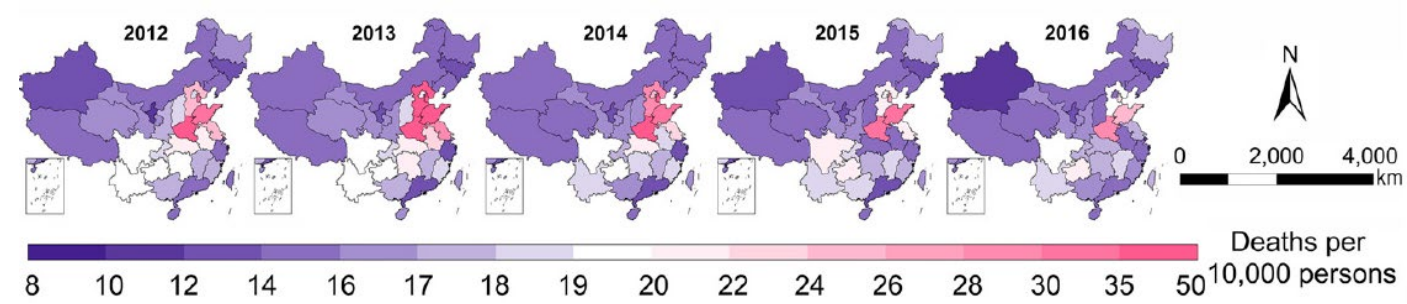
- LRI: lower respiratory infection;
- Stroke;
- COPD: chronic obstructive pulmonary disease
- Lung cancer
- IHD: Ischemic heart disease

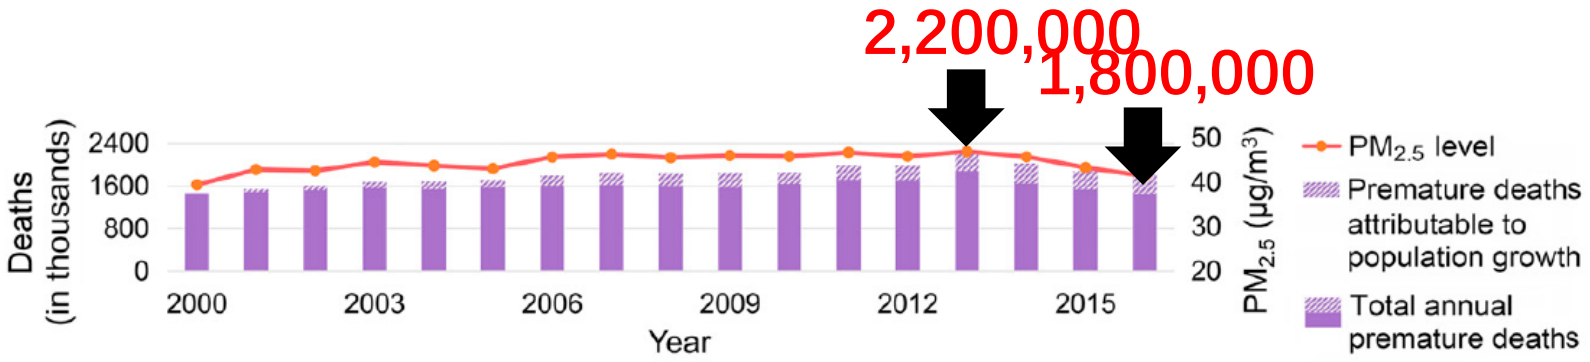
Source: Burnett, et al., PNAS, 2018

空气污染与健康风险



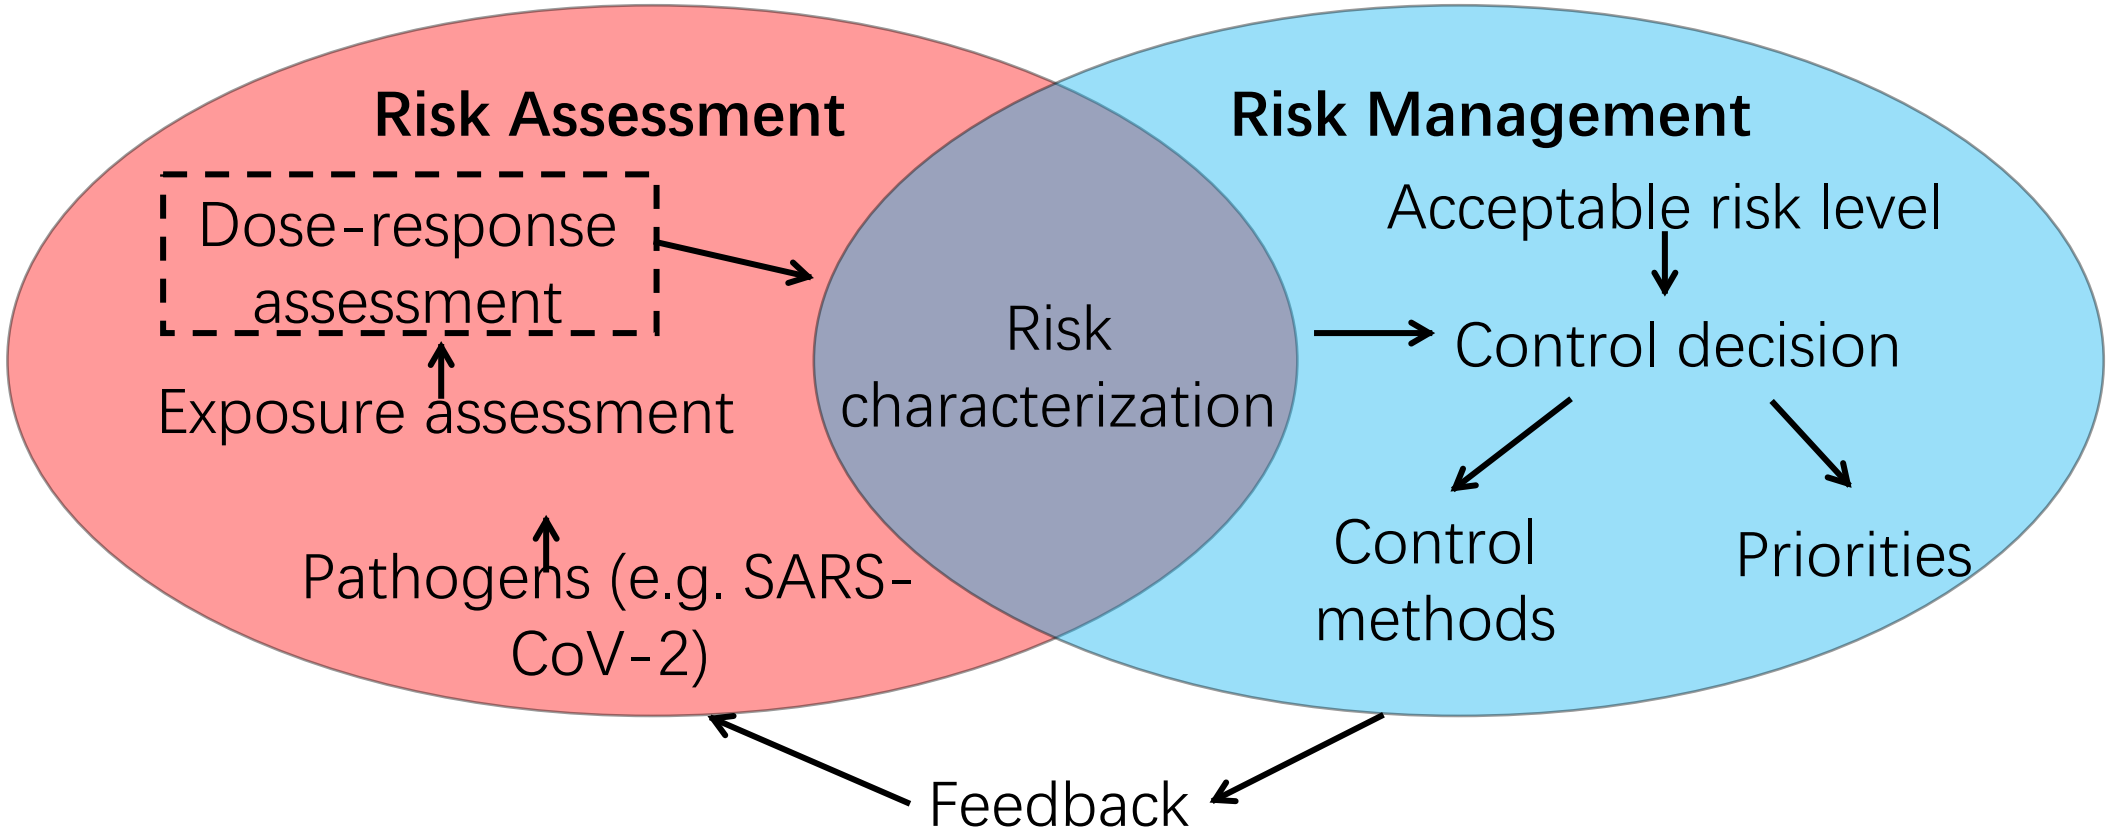
Study from Chinese Academy of Medical Sciences





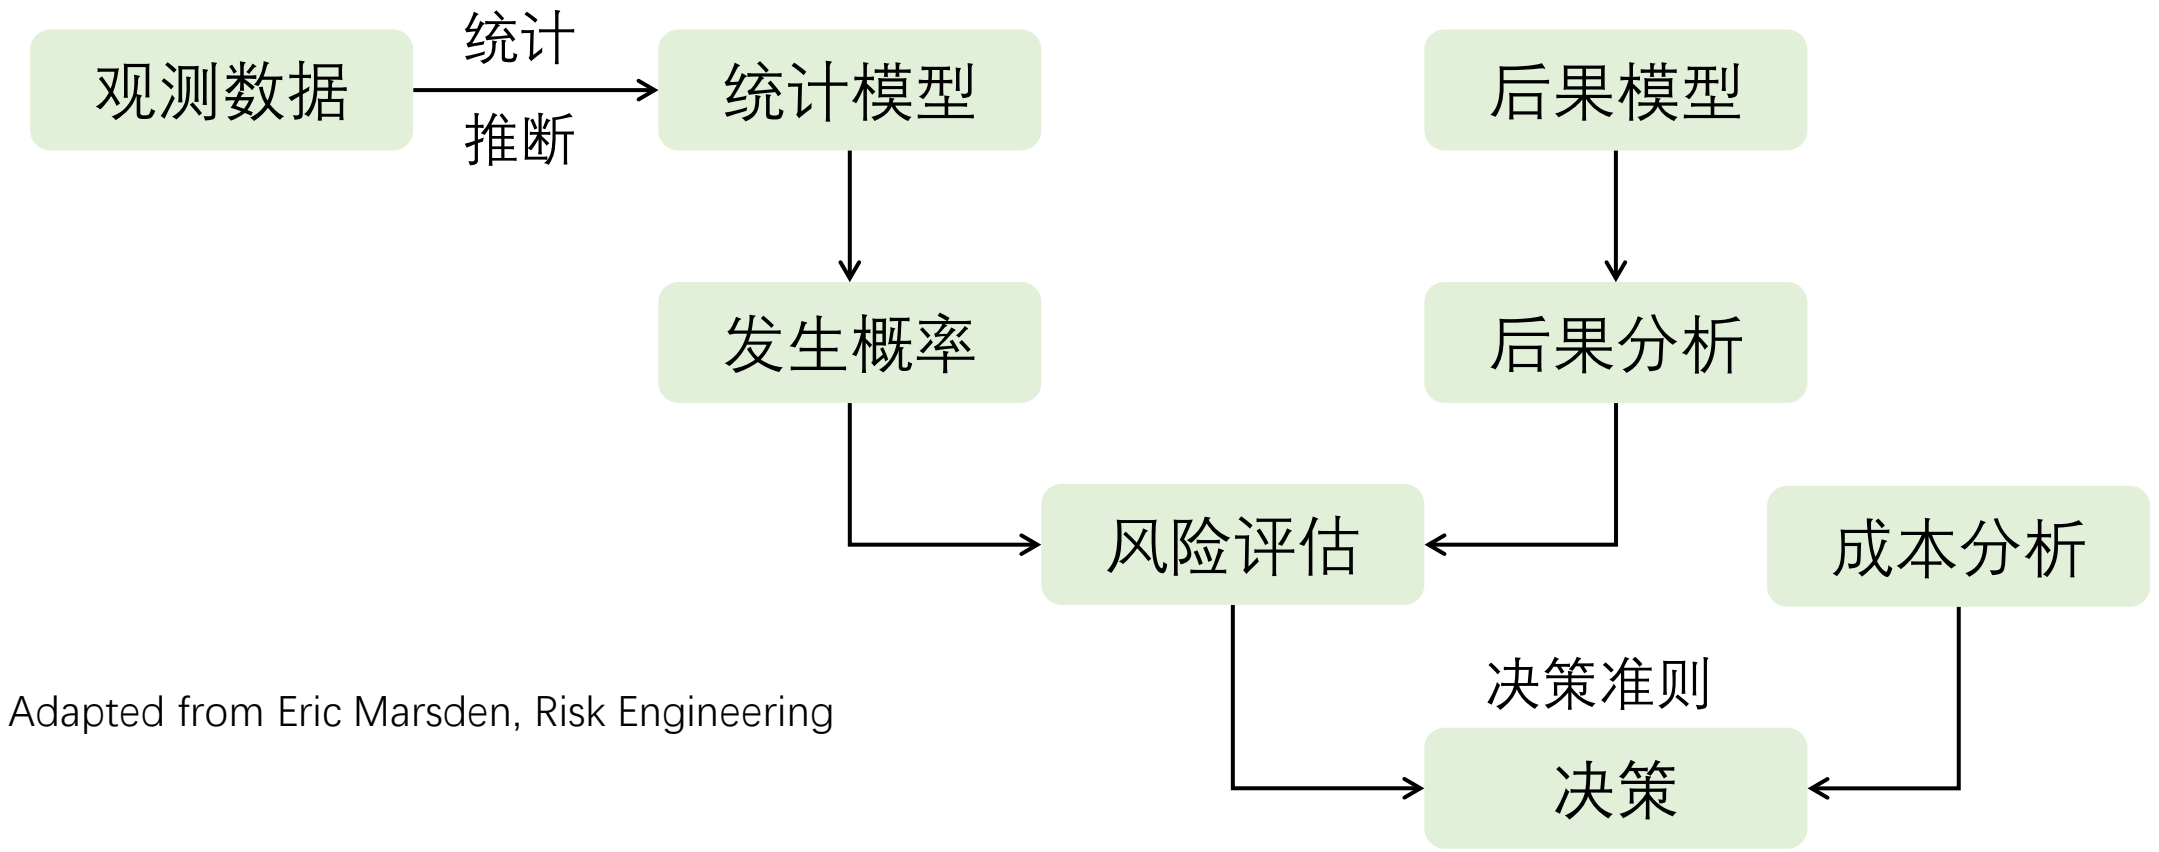
Source： Liang et al., PNAS, 2020

风险导向的疾病控制



Adapted from National Institutes of Health (NIH)

决策过程的主要环节

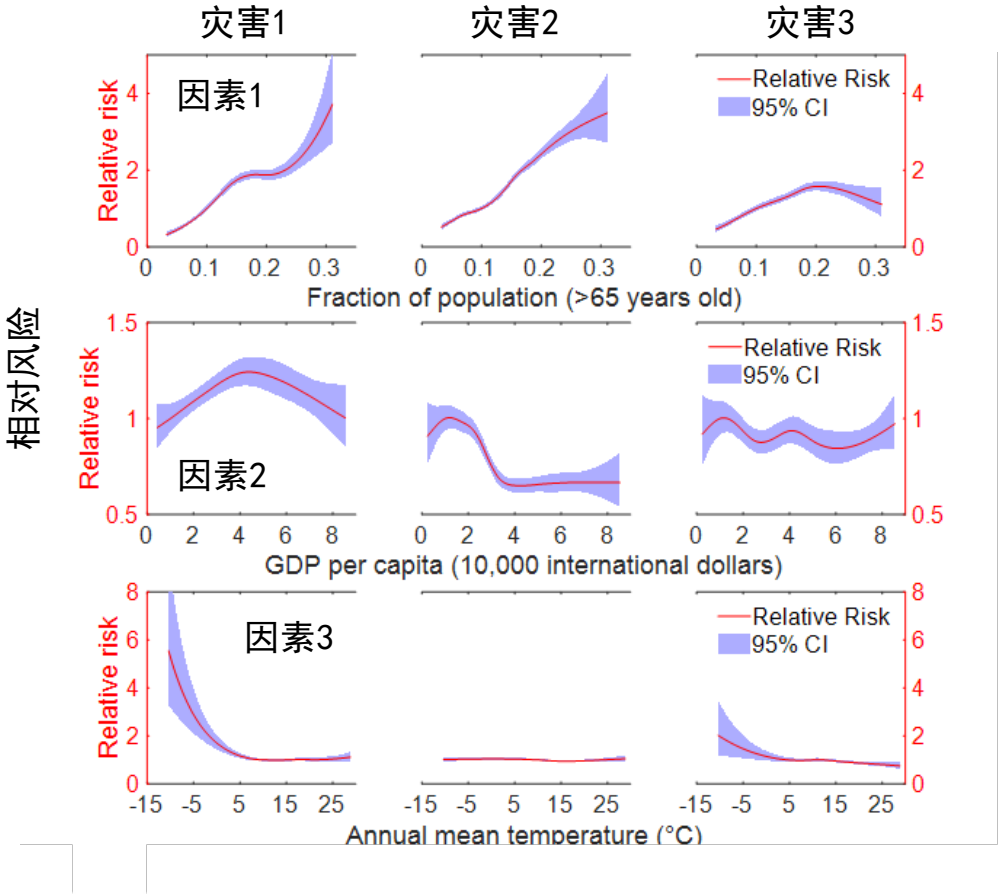


Adapted from Eric Marsden, Risk Engineering

数据驱动的风险量化分析与建模

数据驱动的风险量化分析与建模

- 基于历史灾害数据，通过学习统计分析等多因素分析方法
- 实现对环境、社会等多种因素致灾风险的定量评估
- 构建相应风险评估模型，为决策制定提供数据基础



主要内容

- 线性回归
- 离散数据类型
- 离散数据建模

主要内容

- **线性回归**
- 离散数据类型
- 离散数据建模

1. 线性回归（Linear Regression）

- **回归分析：**研究**因变量**（dependent variable）与**自变量**（independent variable）之间关联关系
- **线性回归（Linear Regression）是最基本的回归分析方法**

$$Y = X \cdot \beta + \varepsilon$$

***Y*为因变量向量**，也被称为响应变量（response variable），被解释变量（explained variable）等

1. 线性回归（Linear Regression）

- **回归分析：**研究**因变量**（dependent variable）与**自变量**（independent variable）之间关联关系
- **线性回归（Linear Regression）是最基本的回归分析方法**

$$Y = X\beta + \varepsilon$$

***X*为自变量矩阵**，也被称为解释变量（explanatory variable），预测变量“predictor variable”，协变量（covariate variable）等

1. 线性回归（Linear Regression）

- **回归分析**：研究**因变量**（dependent variable）与**自变量**（independent variable）之间关联关系
- **线性回归（Linear Regression）是最基本的回归分析方法**

$$Y = X \cdot \beta + \varepsilon$$

β 为回归系数向量（vector of regression coefficients）

1. 线性回归（Linear Regression）

- **回归分析：**研究**因变量**（dependent variable）与**自变量**（independent variable）之间关联关系
- **线性回归（Linear Regression）是最基本的回归分析方法**

$$Y = X \cdot \beta + \varepsilon$$

ε为剩余误差向量（residual errors），也称残差、残余误差等，包含了因变量Y无法被自变量X解释的部分

1. 线性回归（Linear Regression）

$$Y = X \cdot \beta + \varepsilon$$

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

1.1 普通最小二乘法

普通最小二乘法（Ordinary Least Square Regression, OLSR）是线性回归的基本方法

$$Y = X \cdot \beta + \varepsilon$$

通常使用普通最小二乘方法估计回归系数β

即需寻找回归系数β，该系数最小化剩余误差方差

1.2 普通最小二乘法主要假设

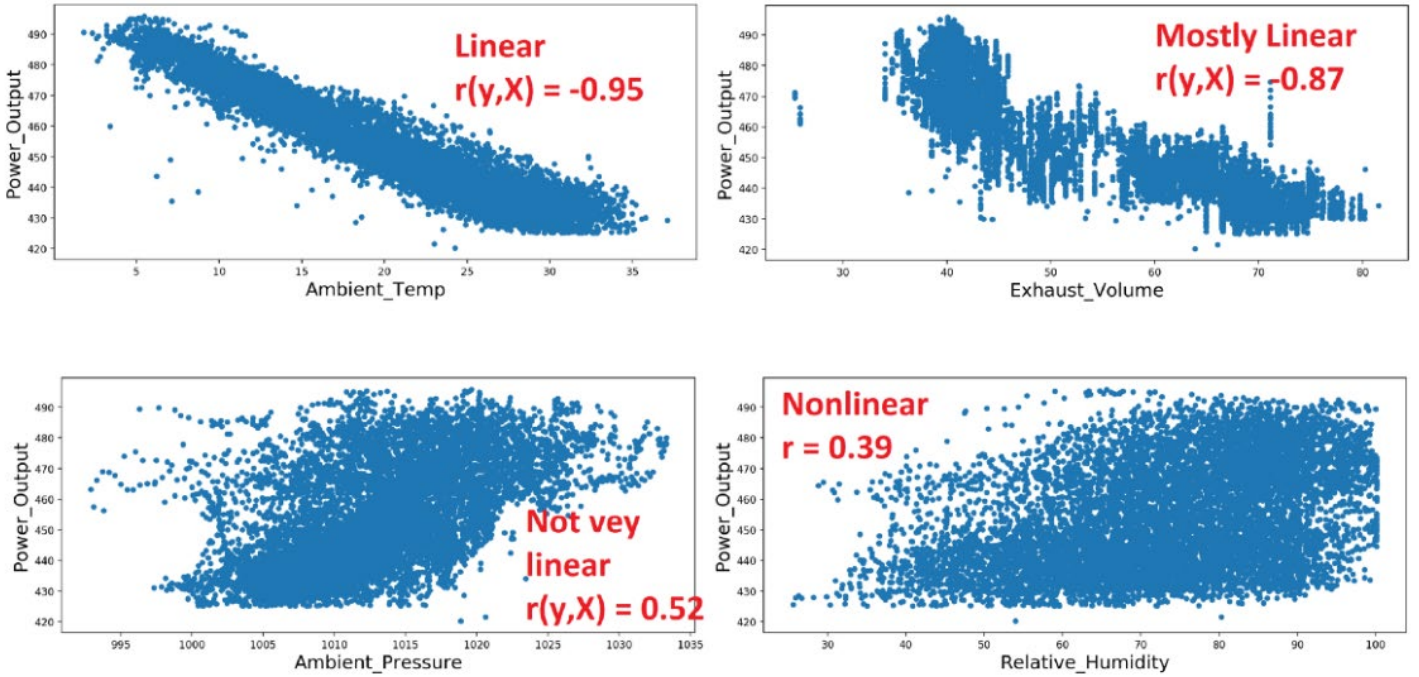
普通最小二乘法主要基于以下假设：

- **线性函数形式：**因变量*Y*与自变量*X*之间为线性关系；
- **剩余误差独立同分布：**利用数据进行模型拟合后，模型的剩余误差应该为独立同分布的随机变量；
- **剩余误差呈正态分布：**剩余误差应该呈现正态分布；
- **剩余误差同方差（homoscedastic）：**剩余误差应该有近似常数的方差，方差不依赖自变量变化。

1.2 普通最小二乘法主要假设

（1）线性函数形式假设

- 可以通过因变量与自变量之间的散点图观测；
- 可以计算因变量与自变量之间的线性相关系数。

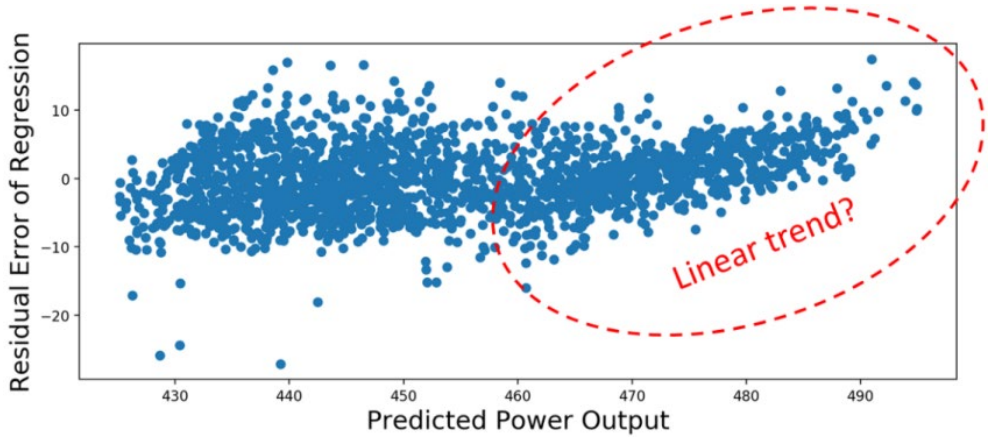


图片来源：Sachin Date, The Assumptions of Linear Regression, And How To Test Them

1.2 普通最小二乘法主要假设

（2）剩余误差独立同分布假设

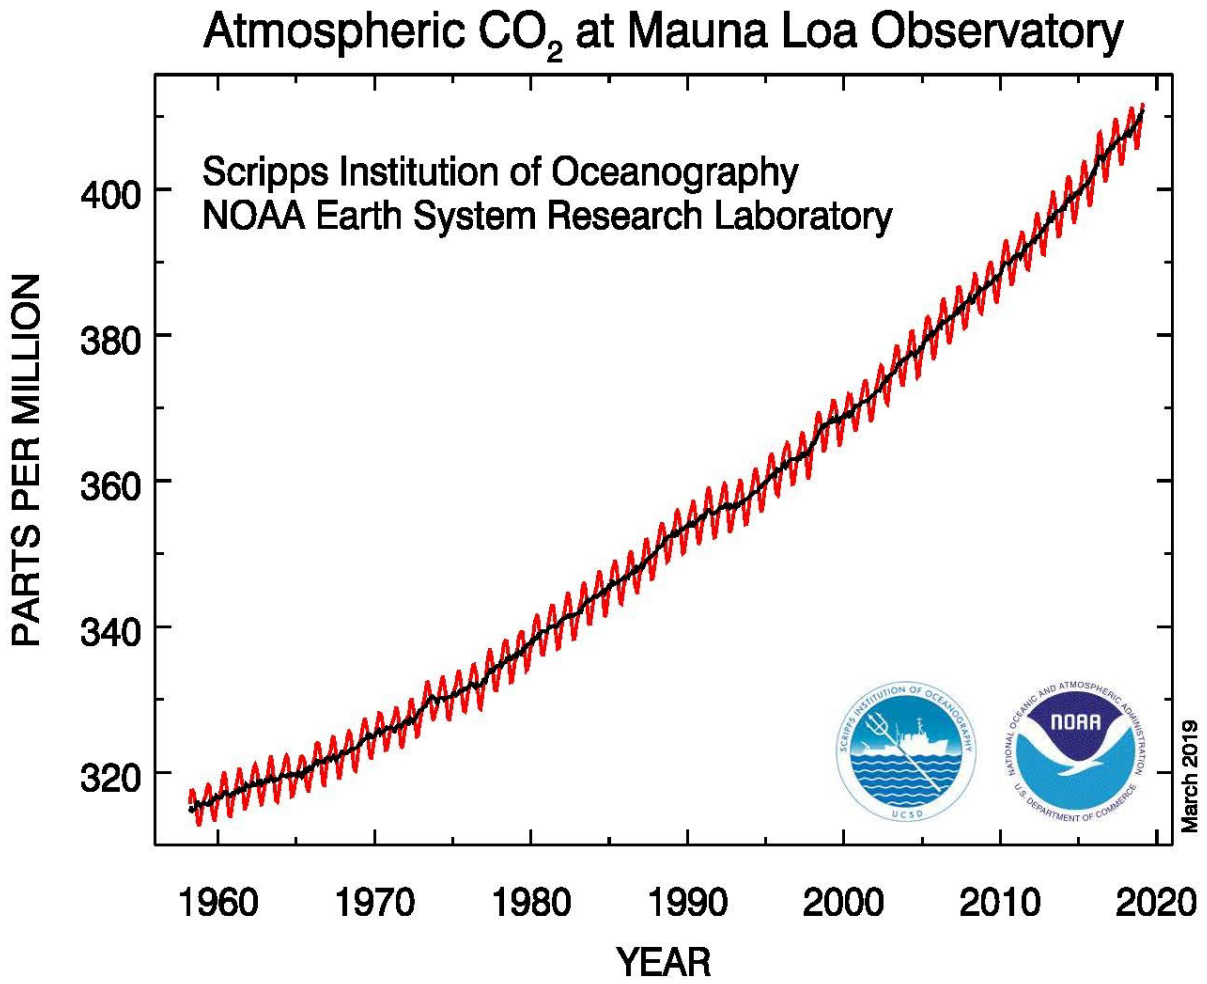
- 剩余误差应该为随机变量，使用不同数据拟合模型后的剩余误差是随机的，因此为随机变量
- 残余误差应相互独立，可以通过残余误差与自变量，或者残余误差与因变量之间的散点图进行观测
- 不同观测值的残余误差应该服从相同的分布

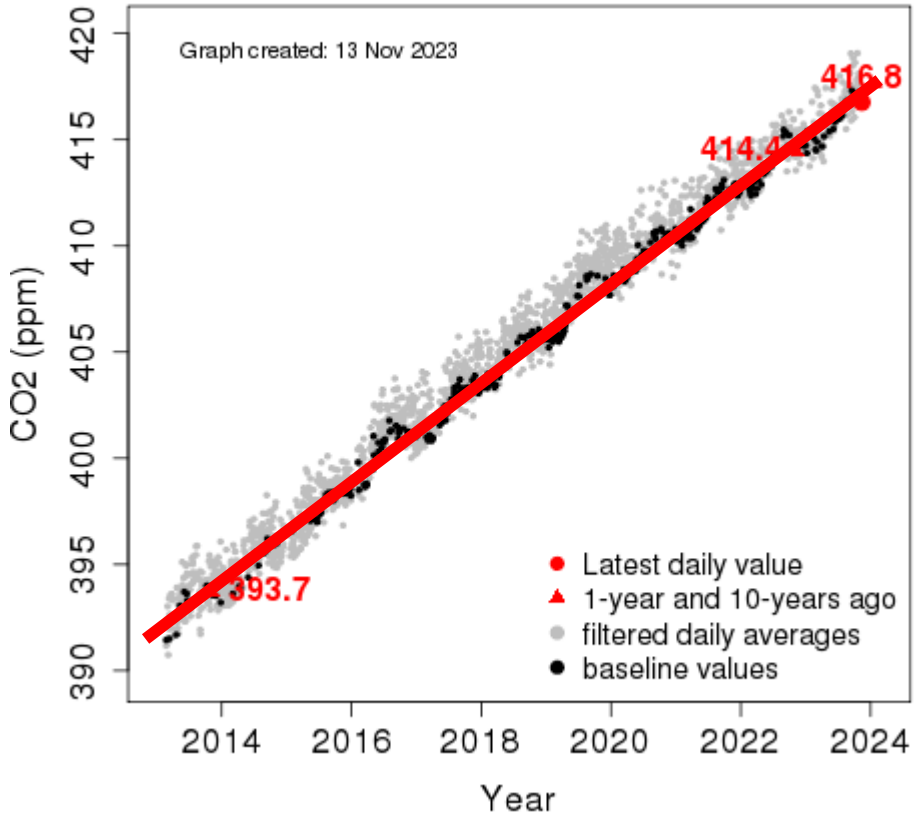


图片来源：Sachin Date, The Assumptions of Linear Regression, And How To Test Them

1.2 普通最小二乘法主要假设

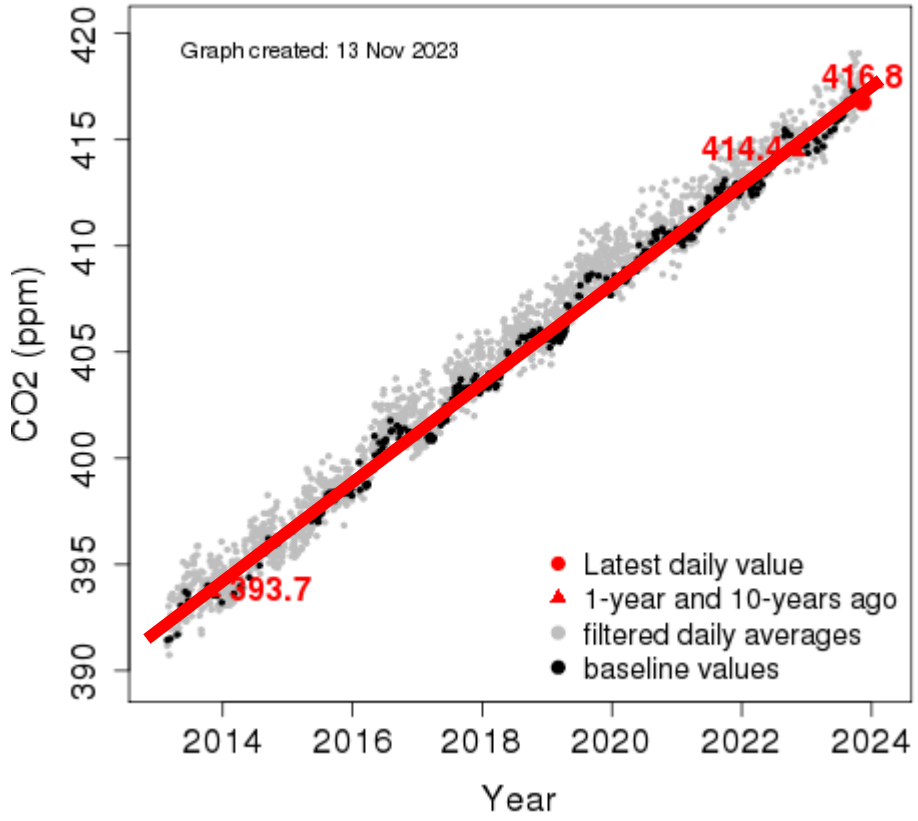
（2）剩余误差独立同分布假设

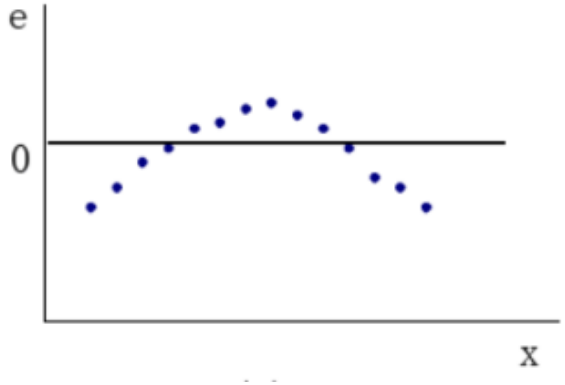


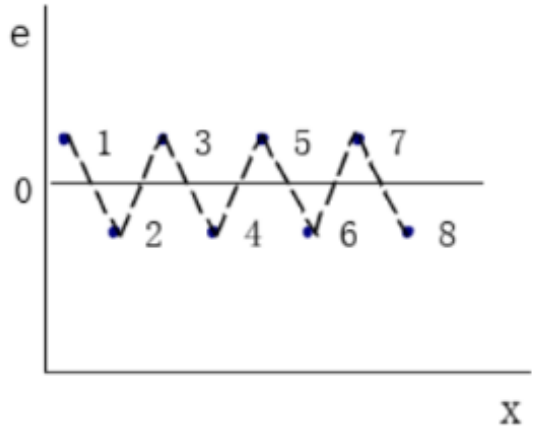


1.2 普通最小二乘法主要假设

（2）剩余误差独立同分布假设



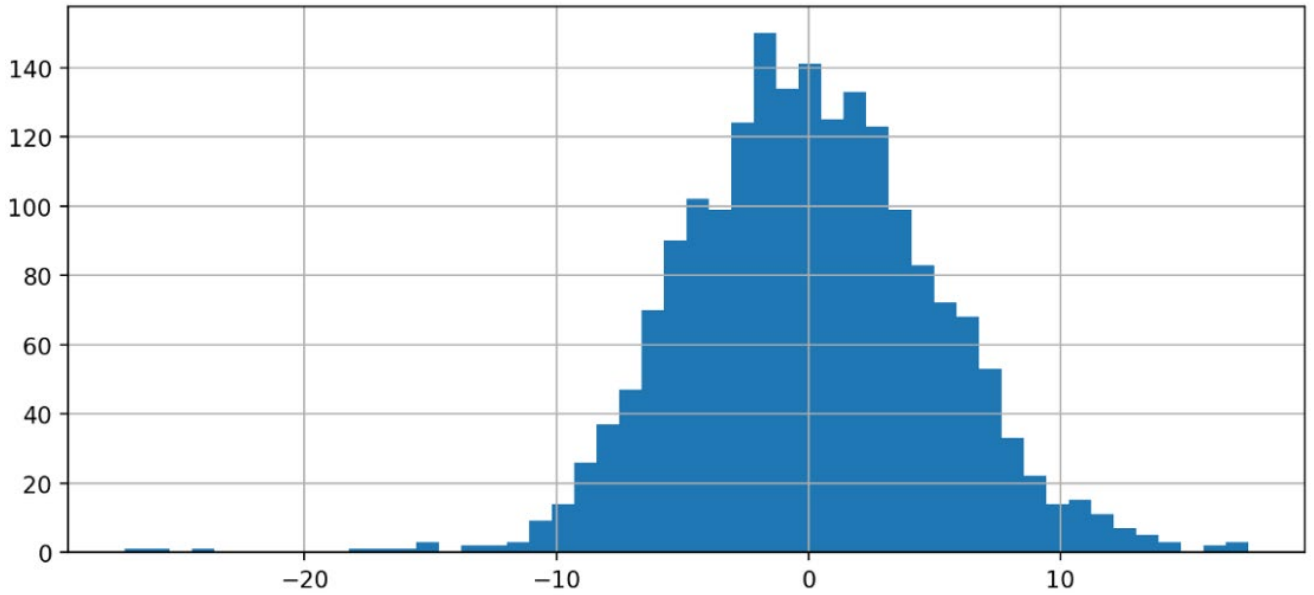




1.2 普通最小二乘法主要假设

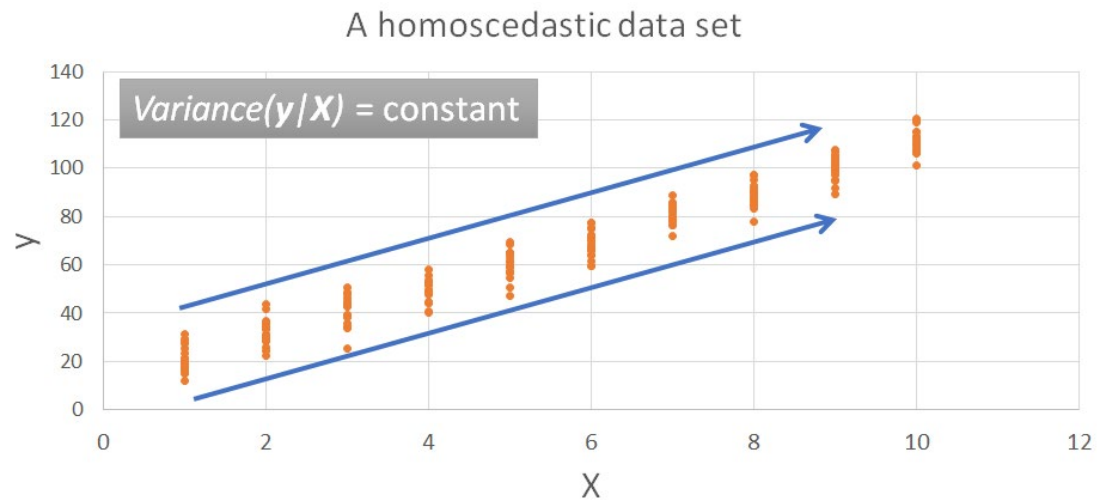
（3）剩余误差呈正态分布假设

- 普通最小二乘法的统计检验和显著性分析都基于正态分布假设

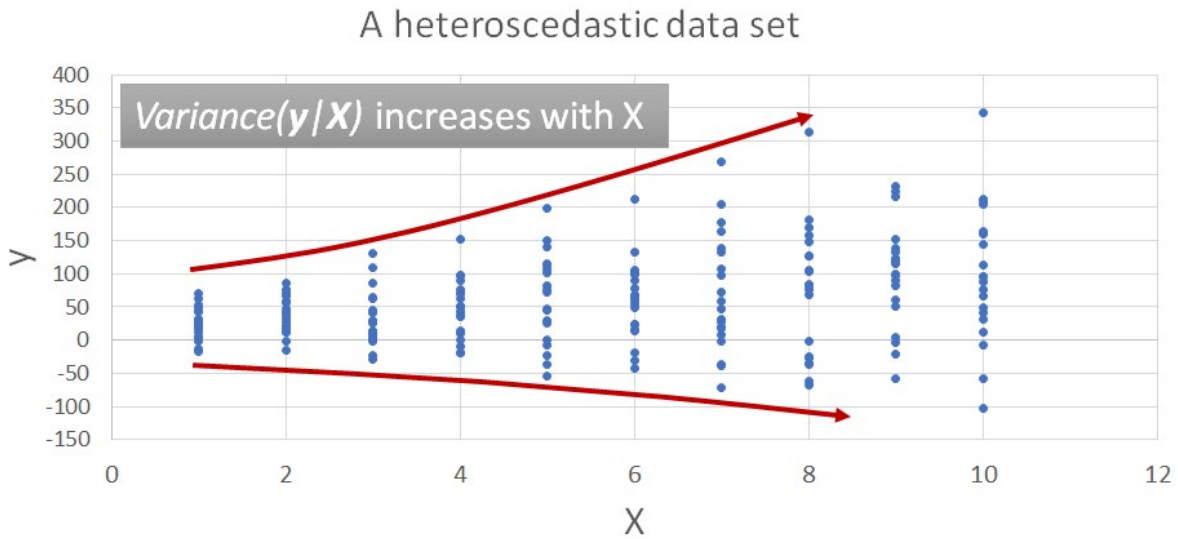


1.2 普通最小二乘法主要假设

（4）剩余误差同方差（homoscedastic）



同方差性



异方差性

1.3 普通最小二乘法推导

$$Y = X \cdot \beta + \varepsilon$$

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

1.3 普通最小二乘法推导

$$Y = X \cdot \beta + \varepsilon$$

- 通常使用普通最小二乘方法估计回归系数β，即需寻找回归系数β，该系数最小化剩余误差方差；
- 剩余误差方差估计为

$$Var(\varepsilon \mid X) = \frac{\left(\varepsilon - E(\varepsilon \mid X)\right)' \left(\varepsilon - E(\varepsilon \mid X)\right)}{n-k}$$

- 从前面普通最小二乘法假设可知，剩余误差呈均值为0的正态分布，并且与任何自变量无关，因此有

$$E(\varepsilon \mid X) = 0$$

1.3 普通最小二乘法推导

- 剩余误差方差可以表示为

$$Var(\varepsilon \mid X) = \frac{\varepsilon'\varepsilon}{n-k}$$

- 设$\hat{\beta}$为对拟合参数的最优估计，e为观测值与拟合模拟预测值的差

$$e = Y - X\hat{\beta}$$

- 进一步假设，e是对剩余误差ε的无偏估计，则有

$$Var(\varepsilon \mid X) = \frac{\varepsilon'\varepsilon}{n-k} = \frac{e'e}{n-k} = \frac{\left(Y - X\hat{\beta}\right)'\left(Y - X\hat{\beta}\right)}{n-k}$$

1.3 普通最小二乘法推导

- 最小化剩余误差方差，等效于最小化e′ e

$$e'e = \left(Y - X\hat{\beta}\right)' \left(Y - X\hat{\beta}\right)$$

- 对目标方程求导，令其等于0，进行求解

$$\frac{\partial e'e}{\partial \hat{\beta}} = \frac{\partial \left(Y - X\hat{\beta}\right)' \left(Y - X\hat{\beta}\right)}{\partial \hat{\beta}}$$

1.3 普通最小二乘法推导

- 标量对向量求导，设标量为y，向量为$\boldsymbol{x}=(x_1,x_2,\ldots,x_n)'$

$$\frac{\partial y}{\partial \boldsymbol{x}}=\left(\frac{\partial y}{\partial x_1}\quad\frac{\partial y}{\partial x_2}\quad\cdots\quad\frac{\partial y}{\partial x_n}\right)'$$

- 标量对向量求导常用关系1

$$f(\boldsymbol{x})=\boldsymbol{a}'\boldsymbol{x},\ \boldsymbol{a}=\left(a_1\quad a_2\quad\cdots\quad a_n\right)'$$

$$\frac{\partial f}{\partial \boldsymbol{x}}=\boldsymbol{a}$$

1.3 普通最小二乘法推导

- 标量对向量求导，设标量为y，向量为$\boldsymbol{x}=(x_1,x_2,\ldots,x_n)'$

$$\frac{\partial y}{\partial \boldsymbol{x}}=\left(\begin{array}{ccc}\frac{\partial y}{\partial x_1} & \frac{\partial y}{\partial x_2} & \cdots & \frac{\partial y}{\partial x_n}\end{array}\right)'$$

- 标量对向量求导常用关系2

$$f\left(\boldsymbol{x}\right)=\boldsymbol{x}'\boldsymbol{A}\boldsymbol{x},\ \boldsymbol{A}=\left(\begin{array}{ccc}a_{11} & \cdots & a_{1n}\\ \vdots & \ddots & \vdots\\ a_{n1} & \cdots & a_{nn}\end{array}\right)$$

$$\frac{\partial f}{\partial \boldsymbol{x}}=\left(\boldsymbol{A}+\boldsymbol{A}'\right)\boldsymbol{x}$$

1.3 普通最小二乘法推导

- 将目标函数展开

$$\frac{\partial \boldsymbol{e}'\boldsymbol{e}}{\partial \hat{\boldsymbol{\beta}}} = \frac{\partial \left(\boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}}\right)' \left(\boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}}\right)}{\partial \hat{\boldsymbol{\beta}}}$$

$$= \frac{\partial \left(\boldsymbol{Y}'\boldsymbol{Y} - \boldsymbol{Y}'\boldsymbol{X}\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{Y} + \hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)}{\partial \hat{\boldsymbol{\beta}}}$$

- 利用以上常用关系可得

$$\frac{\partial \boldsymbol{e}'\boldsymbol{e}}{\partial \hat{\boldsymbol{\beta}}} = \frac{\partial \left(\boldsymbol{Y}'\boldsymbol{Y} - \boldsymbol{Y}'\boldsymbol{X}\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{Y} + \hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)}{\partial \hat{\boldsymbol{\beta}}}$$

$$= -\boldsymbol{X}'\boldsymbol{Y} - \boldsymbol{X}'\boldsymbol{Y} + 2\boldsymbol{X}'\boldsymbol{X}\hat{\boldsymbol{\beta}} = \boldsymbol{0}$$

$$\hat{\boldsymbol{\beta}} = \left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{Y}$$

线性回归的
普通最小二乘估计

1.3 普通最小二乘法推导

- 除最优估计量$\hat{\boldsymbol{\beta}}$以外，还需要估计其协方差矩阵（ covariance matrix)

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'(\boldsymbol{X}\cdot\boldsymbol{\beta}+\boldsymbol{\varepsilon}) \qquad \boldsymbol{Y} = \boldsymbol{X}\cdot\boldsymbol{\beta}+\boldsymbol{\varepsilon}$$

$$= \boldsymbol{\beta} + (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}$$

- 其协方差矩阵为

$$Var(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = E\left(\left(\hat{\boldsymbol{\beta}} - E(\hat{\boldsymbol{\beta}})\right)\left(\hat{\boldsymbol{\beta}} - E(\hat{\boldsymbol{\beta}})\right)'\right)$$

$$Var(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = E\left(\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)'\right) = E\left(\left((\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)\left((\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)'\right)$$

1.3 普通最小二乘法推导

- 其协方差矩阵为

$$Var\left(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}\right) = E\left(\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)'\right)$$

$$= \left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'E\left(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\right)\boldsymbol{X}\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

- 根据剩余误差独立同分布、同方差（homoscedastic）假设

$$E\left(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\right) = \begin{pmatrix} \sigma^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma^2 \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix} = \sigma^2 \boldsymbol{I}$$

1.3 普通最小二乘法推导

- 其协方差矩阵为

$$Var\left(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}\right) = E\left(\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)'\right)$$

$$= \left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'E\left(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\right)\boldsymbol{X}\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

- 根据剩余误差独立同分布、同方差（homoscedastic）假设

$$E\left(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\right) = \begin{pmatrix} \sigma^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma^2 \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix} = \sigma^2 \boldsymbol{I}$$

1.3 普通最小二乘法推导

- 其协方差矩阵为

$$Var\left(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}\right) = E\left(\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)\left(\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon}\right)'\right)$$

$$= \left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'E\left(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\right)\boldsymbol{X}\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

$$= \left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\sigma^2\boldsymbol{I}\boldsymbol{X}\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

$$= \sigma^2\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}\boldsymbol{X}'\boldsymbol{X}\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

$$= \sigma^2\left(X'X\right)^{-1}$$

1.3 普通最小二乘法推导

- 为了最终获得回归系数$\hat{\boldsymbol{\beta}}$协方差矩阵，需要进一步估计剩余误差方差σ；

- 前面已经假设，e是对剩余误差ε的无偏估计

$$Var\left(\boldsymbol{\varepsilon} \mid \boldsymbol{X}\right)=\frac{\boldsymbol{\varepsilon}'\boldsymbol{\varepsilon}}{n-k}=\frac{\boldsymbol{e}'\boldsymbol{e}}{n-k}=\frac{\left(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)'\left(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)}{n-k}$$

- 因此，可以根据拟合结果的残差估计σ

$$\sigma^2=\boldsymbol{s}^2=\frac{\boldsymbol{e}'\boldsymbol{e}}{n-k}=\frac{\left(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)'\left(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{\beta}}\right)}{n-k}$$

回归系数协方差矩阵：

$$Var\left(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}\right)=\boldsymbol{s}^2\left(\boldsymbol{X}'\boldsymbol{X}\right)^{-1}$$

1.3 普通最小二乘法推导

估计归回系数的置信区间（Confidence interval）

- 回归系数协方差矩阵对角线元素的平方根即为对应的回归系数估计$\hat{\boldsymbol{\beta}}$的标准差（standard error），记为se_{ii}；
- 标准差可用来评估回归系数估计$\hat{\boldsymbol{\beta}}$的置信区间；
- 设置信水平为α（如0.05），则对应的（1- α）100%置信区间（如95%置信区间）为

$$\hat{\boldsymbol{\beta}} \pm \left(t_{\left(1-\frac{\alpha}{2}\right)(n-k)} \cdot se_{ii} \right)$$

- 其中，$t_{(1-\alpha/2)(n-k)}$为n-k自由度的学生分布(*Student's t*-distribution) 相应置信度的对应值；
- n为样本数据个数，k是回归系数个数。

1.3 普通最小二乘法推导

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	49.9877	3.731	13.397	0.000	42.482	57.494
Curb_Weight	-0.0093	0.002	-3.884	0.000	-0.014	-0.004
Engine_Size	-0.0012	0.027	-0.044	0.965	-0.055	0.053

1.3 普通最小二乘法推导

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}$$

$$Var(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = s^2(\boldsymbol{X}'\boldsymbol{X})^{-1}$$

$$\sigma^2 = s^2 = \frac{\boldsymbol{e}'\boldsymbol{e}}{n-k} = \frac{(\boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}})'(\boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}})}{n-k}$$

普通最小二乘法的四个主要假设

1. 线性函数关系，
2. 剩余误差应该为独立同分布；
3. 剩余误差应该为正态分布
4. 剩余误差同方差

1.3 普通最小二乘法推导

如果数据和拟合结果不满足上面的条件，会发生什么呢?

- 拟合结果不能很好地描述我们的数据特征，比如如果数据的方差随均值变化，那么我们使用普通最小二乘法，剩余误差很难满足独立同分布和同方差假设，我们选用的方法就是不最优的方法。
- 在推导置信区间时，我们使用了以上假设，无法使用以上关系获得置信区间。

谢谢！

Thanks !

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn