决策方法论

Decision Making Technology

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn

数据驱动的风险量化分析与建模

3.2.4 负二项分布 (Negative binomial distribution)

负二项分布（Negative-Binomial distribution）

- 二项分布描述的是在固定的*n*次试验中，“成功”的次数，例如将一枚均质的硬币抛100次，正面出现的次数
- 负二项分布与二项分布类似，但其描述的是在出现固定“失败”次数*r*之前，成功的次数*x*，例如，同样是抛硬币，负二项分布描述的是在出现100次背面之前，正面出现次数的分布
- 负二项分布的概率质量函数PMF为

$$f(x) = C_{r+x-1}^{x} \pi^{r} (1-\pi)^{x}, \text{ for } x = 0,1,2,3,\ldots$$

似然函数（Likelihood function）

似然性（Likelihood）与概率（Probability）

似然性（Likelihood）与**概率（Probability）**在字面上具有相似的含义，都是指某事件发生的可能性，但是统计学中，二者有显著的区别：

- **概率（Probability）**：假设观测数据服从某种概率密度分布，在相应的概率模型参数已知的情况下，获得的某一特定观测结果出现的可能性，即**统计模型和参数已知，估计观测出现的可能性**

- **似然性（Likelihood）**：同样假设观测数据服从某种概率密度分布，相应的概率模型参数未知，但具有观测数据，即具有服从该分布的采样数据，衡量某种统计模型参数导致所获得的观测数据出现的可能性，即**统计模型和观测数据已知，估计模型参数导致观测结果的可能性**

最大似然估计 (Maximum Likelihood Estimation)

最大似然估计（Maximum Likelihood Estimation）

- 将能够**使似然函数最大化**的未知参数的值最为对**该参数的估计**
- 直观上来讲，该参数可以**使得观测数据最容易出现**，因为观测值已经出现，那么使得其最容易发生的概率模型参数值便成为一种“最合理”的估计
- 这种**最大化似然函数**的估计方法被称为**最大似然估计**

最大似然估计 (Maximum Likelihood Estimation)

伯努利分布参数π的最大似然估计

$$L(\pi)=f(x_1,x_2,\cdots x_n;\pi)=\pi^{\sum_{i=1}^{n}x_i}(1-\pi)^{n-\sum_{i=1}^{n}x_i}$$

- 将似然函数取为对数形式

$$\log\left(L(\pi)\right)=\sum_{i=1}^{n}x_i\log\pi+\left(n-\sum_{i=1}^{n}x_i\right)\log(1-\pi)$$

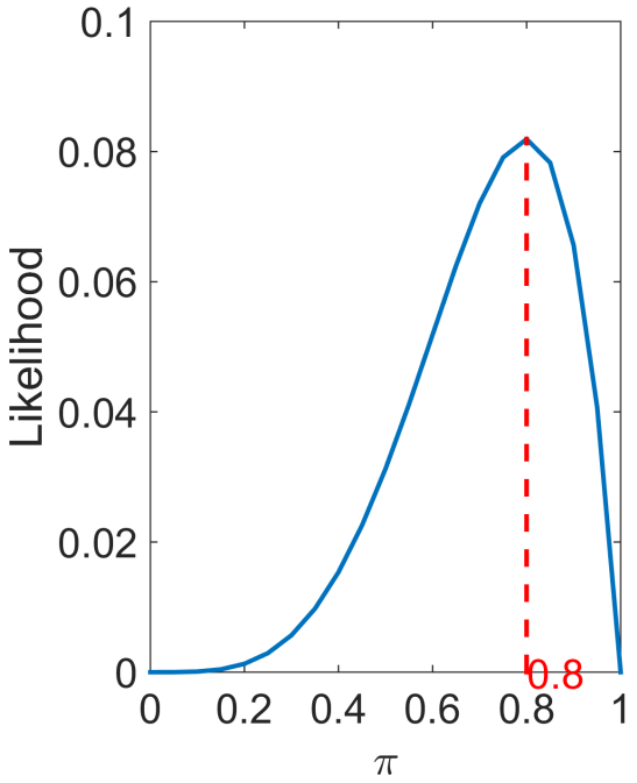
- 可以对似然函数求导取0，获得极大值

$$\frac{\partial\log\left(L(\pi)\right)}{\partial\pi}=\frac{\sum_{i=1}^{n}x_i}{\pi}-\frac{n-\sum_{i=1}^{n}x_i}{1-\pi}=0 \quad\Rightarrow\quad \hat{\pi}=\frac{\sum_{i=1}^{n}x_i}{n}$$

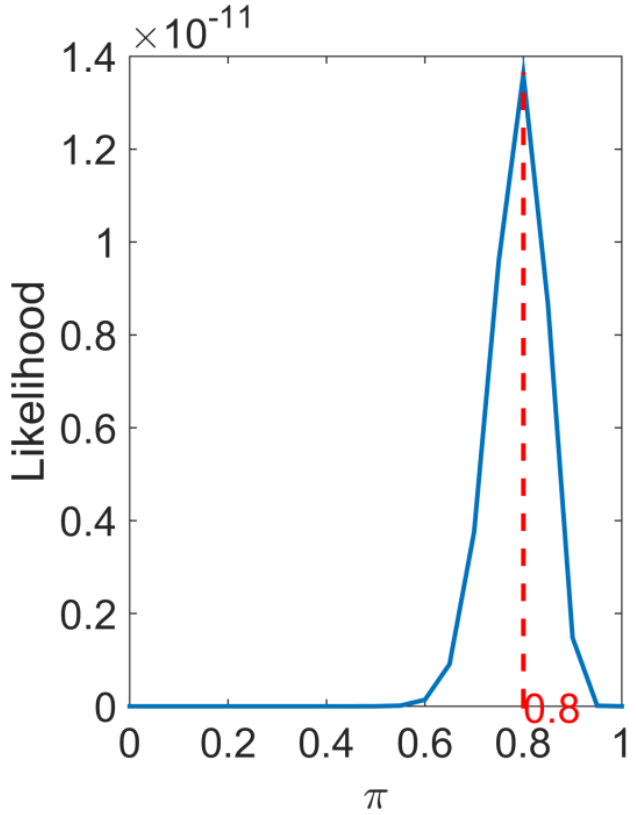
最大似然估计 (Maximum Likelihood Estimation)

伯努利分布参数π的最大似然估计

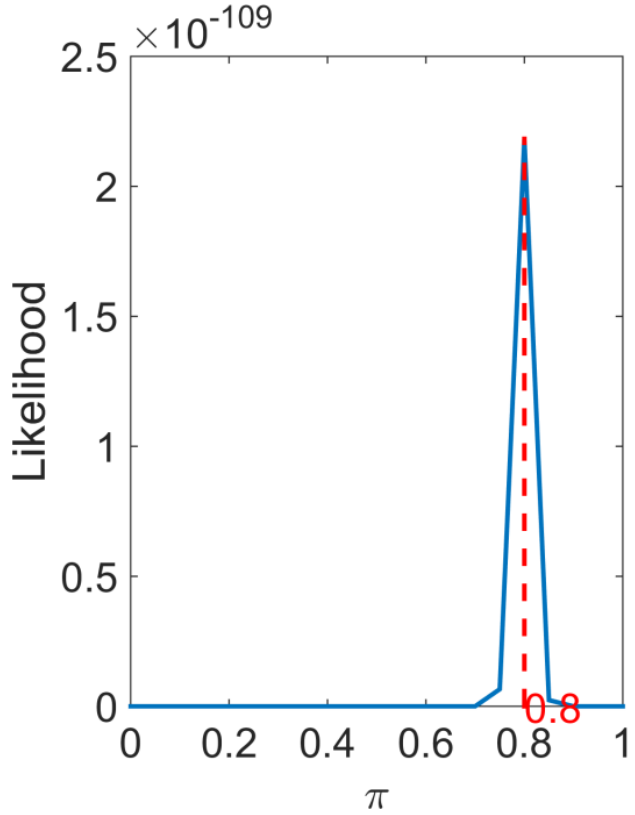
抛5次硬币
4次为正面，1次为背面；



抛50次硬币
40次为正面，10次为背面；



抛500次硬币
400次为正面，100次为背面；



主要内容

- 1 线性回归
- 2 离散数据类型
- 3 离散数据建模
- **4 最大似然估计**
- 5 广义线性模型
- 6 典型的广义线性模型

4.4 关于最大似然方差

- 设n个样本x_1，x_2，…，x_n，**独立同分布**，均服从具有参数θ的概率分布函数$f_\theta(x)$，样本x_i时，其**对数形式的似然函数**可以表示为

$$L_i(\boldsymbol{\theta}) = \log\left(f(x_i;\boldsymbol{\theta})\right) = \log\left(f_\theta(x_i)\right)$$

- n个样本的**联合概率分布函数**为

$$f_\theta(x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f_\theta(x_i)$$

- **对数形式的似然函数**

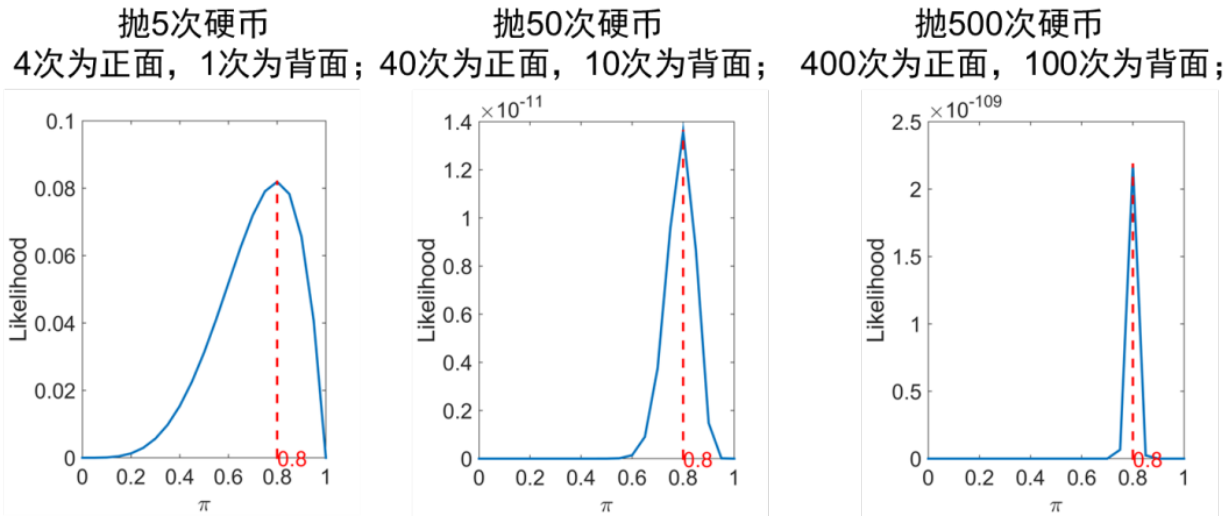
$$L(\boldsymbol{\theta}) = L(\boldsymbol{\theta}; x_1, x_2, \cdots x_n) = \log\left(f(x_1, x_2, \cdots x_n;\boldsymbol{\theta})\right) = \log\left(\prod_{i=1}^{n} f_\theta(\boldsymbol{x}_i;\boldsymbol{\theta})\right)$$

$$L(\boldsymbol{\theta}) = \sum_{i=1}^{n} \log\left(f_\theta(\boldsymbol{x}_i;\boldsymbol{\theta})\right) = \sum_{i=1}^{n} L_i(\boldsymbol{\theta})$$

4.4 关于最大似然方差

- 似然函数在最大似然估计处的二阶导数对应于似然平面（或者曲线）的曲率
- 当曲率较小时，似然平面在最大似然估计附近比较平坦，最大似然估计的方差就比较大
- 当曲率较大时，似然平面在最大似然估计附近有比较剧烈的弯曲变化，最大似然估计的方差就比较小

$$Var\left(\hat{\boldsymbol{\theta}};\boldsymbol{X}\right)=-L''\left(\hat{\boldsymbol{\theta}}\right)^{-1}$$



4.4 关于最大似然方差

伯努利分布参数π的最大似然估计

$$L(\pi)=\log\left(f(x_1,x_2,\cdots x_n;\pi)\right)=\log\left(\pi^{\sum_{i=1}^{n}x_i}(1-\pi)^{n-\sum_{i=1}^{n}x_i}\right)$$

$$=\sum_{i=1}^{n}x_i\log\pi+\left(n-\sum_{i=1}^{n}x_i\right)\log(1-\pi)$$

- 可以对似然函数求导取0，获得极大值

$$\frac{\partial L(\pi)}{\partial\pi}=\frac{\sum_{i=1}^{n}x_i}{\pi}-\frac{n-\sum_{i=1}^{n}x_i}{1-\pi}=0 \quad\Rightarrow\quad \hat{\pi}=\frac{\sum_{i=1}^{n}x_i}{n}$$

4.4 关于最大似然方差

伯努利分布参数π的最大似然估计

$$\hat{\pi} = \frac{\sum_{i=1}^{n} x_i}{n}$$

伯努利分布参数π的最大似然估计方差

$$Var(\hat{\pi}) = Var\left(\frac{\sum_{i=1}^{n} x_i}{n}\right) = \frac{1}{n^2} Var\left(\sum_{i=1}^{n} x_i\right) = \frac{1}{n^2}\sum_{i=1}^{n} Var(x_i)$$

$$= \frac{n\pi(1-\pi)}{n^2} = \frac{\pi(1-\pi)}{n}$$

4.4 关于最大似然方差

伯努利分布参数π的对数形式的似然函数为

$$L(\pi)=\log\left(f(x_1,x_2,\cdots x_n;\pi)\right)=\log\left(\pi^{\sum_{i=1}^{n}x_i}(1-\pi)^{n-\sum_{i=1}^{n}x_i}\right)$$

$$=\sum_{i=1}^{n}x_i\log\pi+\left(n-\sum_{i=1}^{n}x_i\right)\log(1-\pi)$$

对似然函数进行求导

$$L(\pi)'=\frac{\sum_{i=1}^{n}x_i}{\pi}-\frac{n-\sum_{i=1}^{n}x_i}{1-\pi}$$

$$L(\pi)''=-\frac{\sum_{i=1}^{n}x_i}{\pi^2}+\frac{n-\sum_{i=1}^{n}x_i}{(1-\pi)^2}$$

4.4 关于最大似然方差

对似然函数进行求导

$$L(\pi)' = \frac{\sum_{i=1}^{n} x_i}{\pi} - \frac{n - \sum_{i=1}^{n} x_i}{1-\pi}$$

$$L(\pi)'' = -\frac{\sum_{i=1}^{n} x_i}{\pi^2} + \frac{n - \sum_{i=1}^{n} x_i}{(1-\pi)^2}$$

由最大似然估计可知

$$\sum_{i=1}^{n} x_i = n\hat{\pi}$$

$$L(\hat{\pi})'' = -\frac{n\hat{\pi}}{\hat{\pi}^2} + \frac{n - n\hat{\pi}}{(1-\hat{\pi})^2} = \frac{-n}{\hat{\pi}(1-\hat{\pi})}$$

$$Var(\hat{\theta}; X) = -L''(\hat{\theta})^{-1}$$

$$Var(\hat{\pi}) = \frac{\hat{\pi}(1-\hat{\pi})}{n}$$

主要内容

- 1 线性回归
- 2 离散数据类型
- 3 离散数据建模
- 4 最大似然估计
- **5 广义线性模型**
- 6 典型的广义线性模型

5 广义线性模型 Generalized Linear Models

□**广义线性模型（Generalized Linear Models，GLM）**是普通最小二乘法的扩展，是用以解决离散因变量、非正态分布因变量的回归分析与建模方法，最早由 Peter McCullagh 和John Nelder提出（Generalized Linear Models， 1982， 1989 2nd edition）

□广义线性模型假设**观测数据因变量*Y*来自某个指数族**（exponential family）分布，该分布的均值为μ，均值可以由对应的自变量（解释变量）***X***解释

因变量*Y*服从某分布，均值为：$E(\boldsymbol{Y})=\mu$

均值可被自变量***X***解释：$g(\mu)=\boldsymbol{X}'\boldsymbol{\beta}$

$$\mu=g^{-1}(\boldsymbol{X}'\boldsymbol{\beta})$$

函数*g*(.)通常是非线性的，但解释变量是通过线性组合***X′ β***来影响观测值的，基于此种考虑，称其为**广义线性模型**

5 广义线性模型 Generalized Linear Models

广义线性模型的**三个主要成分：**

□随机成分（Random Component），因变量的统计分布，例如普通最小二乘法假设因变量服从正态分布、二值逻辑回归假设因变量服从伯努利分布，随机部分是广义线性模型中唯一的随机性来源

□系统性成分（Systematic Component），模型的自变量，即解释变量$(x_1,x_2,\ldots,x_n)$，以及他们的线性组合，例如$\beta_0+\beta_1x_1+\beta_2x_2+\ldots+\beta_nx_n$

□连接函数（Link Function），η或者$g(\mu)$用以连接广义线性模型的随机成分和系统性成分，表示因变量（响应变量）的均值与自变量（解释变量）之间的关系，例如，在普通最小二乘法中$\eta=g(\mu)=E(Y)$，在逻辑回归中$\eta=g(\pi)=\log(\pi/(1-\pi))=\text{logit}(\pi)$

5 广义线性模型 Generalized Linear Models

广义线性模型主要假设：

- 观测数据因变量 Y_1，Y_2，…，Y_n 是相互独立的；
- 因变量 Y_i 不必服从正态分布，但通常假设其服从某一指数族分布，例如二项分布、泊松分布、负二项分布等；
- 因变量与自变量之间不必为线性关系，但一般假设响应变量期望的某种变换（通过连接函数变换）与解释变量之间为线性关系，例如在二值逻辑回归假设 $\text{logit}(\pi) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n$；可以将原始解释变量的非线性变换作为模型的解释变量；
- 响应变量的方差不必是恒定的常数；
- 剩余误差需要满足独立条件，但不必为正态分布；
- 模型参数利用最大似然估计获得。

5 广义线性模型 Generalized Linear Models

普通最小二乘线性回归可以视为广义线性模型的特例，响应变量 Y 为连续变量

$$\mu = \beta_0 + \sum_{i=1}^{n} \beta_i x_i$$

- **随机成分：** 因变量 Y 服从正态分布，正态分布的均值为 μ，方差为常数 σ^2；
- **系统性部分：** 可以包含多个解释变量，利用解释变量的线性组合来估计响应变量 Y 的期望；
- **连接函数：** 线性本体连接（identity），$\eta = g(\mu) = \mu = E(Y)$，为最简单的连接函数。

主要内容

- 1 线性回归
- 2 离散数据类型
- 3 离散数据建模
- 4 最大似然估计
- 5 广义线性模型
- **6 典型的广义线性模型**

典型的广义线性模型

介绍三种典型的广义线性模型：

- 5.1 二元逻辑回归（Binary Logistic Regression）
- 5.2 泊松回归（Poisson Regression）
- 5.3 负二项回归（Negative Binomial Regression）

典型的广义线性模型

介绍三种典型的广义线性模型：

- **5.1 二元逻辑回归（Binary Logistic Regression）**
- 5.2 泊松回归（Poisson Regression）
- 5.3 负二项回归（Negative Binomial Regression）

5.1 二元逻辑回归 Binary Logistic Regression

二元逻辑回归（Binary Logistic Regression），主要基于解释变量x_1，x_2，…，x_k，建立某一事件发生概率（π）的模型。例如，

$$\pi\left(x_1, x_2, \ldots, x_k\right) = P\left(Y = 1; x_1, x_2, \ldots, x_k\right)$$

- 根据年龄、血压、收入水平、婚姻状况、吸烟、酗酒情况，估计患有心血管疾病的可能性；
- 根据植被覆盖、地表坡度、降雨、土地类型等参数，估计发生滑坡的可能性。

5.1 二元逻辑回归 Binary Logistic Regression

二元逻辑回归（Binary Logistic Regression）的主要假设包括：

- 因变量（响应变量）Y为服从伯努利分布的随机变量，具有“成功”和“失败”两种结果，Y=1对应“成功”，出现的概率为π，Y=0对应“失败”，出现的概率为1-π;
- 自变量（解释变量）$\boldsymbol{x}$= （x_1，x_2，…，x_k）是固定变量（fixed），可以包含离散变量或者连续变量;
- 每一个观测样本，例如样本i，包含因变量和自变量的值（x_{1i}，x_{2i}，…，x_{ki}，Y_i），i=1,…, n，样本数为n个;
- 不同样本之间相互独立。

5.1 二元逻辑回归 Binary Logistic Regression

口 发生比（odds），指事件发生的次数/未发生的次数=事件发生的概率/未发生的概率

$$odds = \frac{P}{1-P} \qquad P = \frac{odds}{1+odds}$$

- 中国乒乓球队赢阿根廷乒乓球队的发生比：　100：1=100
- 中国男足赢阿根廷男足的发生比：　1：100=0.01

口 对数发生比，log(odds)，指取e为底，真数为odds的自然对数

5.1 二元逻辑回归
Binary Logistic Regression

- 概率的取值：[0,1]
- 发生比的取值：[0 +∞)
- 对数发生比的取值：(-∞，+∞)

5.1 二元逻辑回归 Binary Logistic Regression

- 二元逻辑回归模型可以表示为

$$\log\left(\frac{\pi_i}{1-\pi_i}\right)=\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}$$

- 下标对应第i个观测值，通过整理可得事件出现概率为

$$\pi_i=\frac{\exp\left(\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}\right)}{1+\exp\left(\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}\right)}$$

- n个Y_1，…，Y_n观测的联合概率，即似然函数为

$$L\left(\beta_0,\boldsymbol{\beta}\right)=\log\left(\prod_{i=1}^{n}\pi_i^{Y_i}\left(1-\pi_i\right)^{1-Y_i}\right)$$

- 通过最大化似然函数，获得最大似然估计$\hat{\beta}_0$和$\hat{\boldsymbol{\beta}}$

5.1 二元逻辑回归 Binary Logistic Regression

对照广义线性模型，对于二元逻辑回归

口随机成分，因变量（响应变量）Y为服从伯努利分布的随机变量，成功概率为π，期望$E(Y)=\pi$

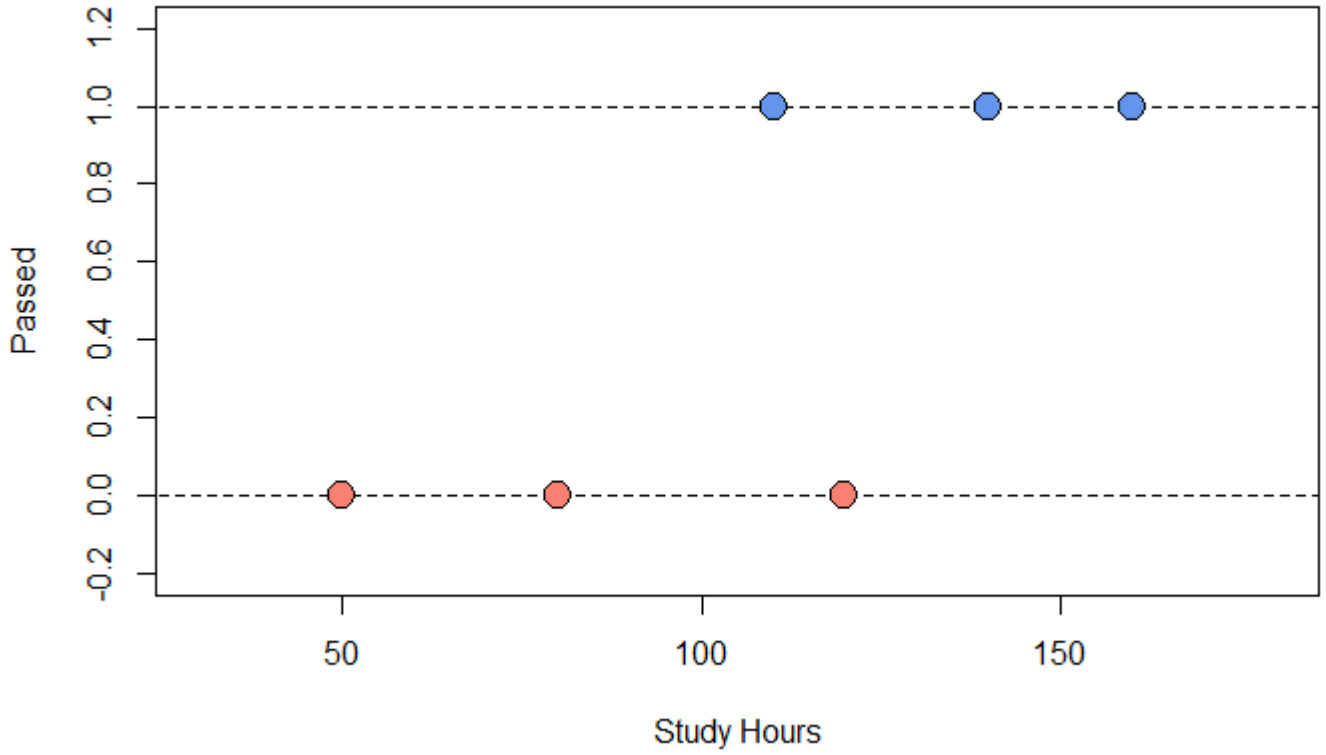
口系统性成分，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量Y的期望

口连接函数，使用logit函数$\eta=g(\pi)=\log(\pi/(1-\pi))$

5.1 二元逻辑回归 Binary Logistic Regression

- 研究学习投入时间对考试通过机会的影响
- 收集6位同学的投入时间和考试结果

学生序号	投入时间(hours)	是否通过考试
1	50	0
2	80	0
3	110	1
4	120	0
5	140	1
6	160	1

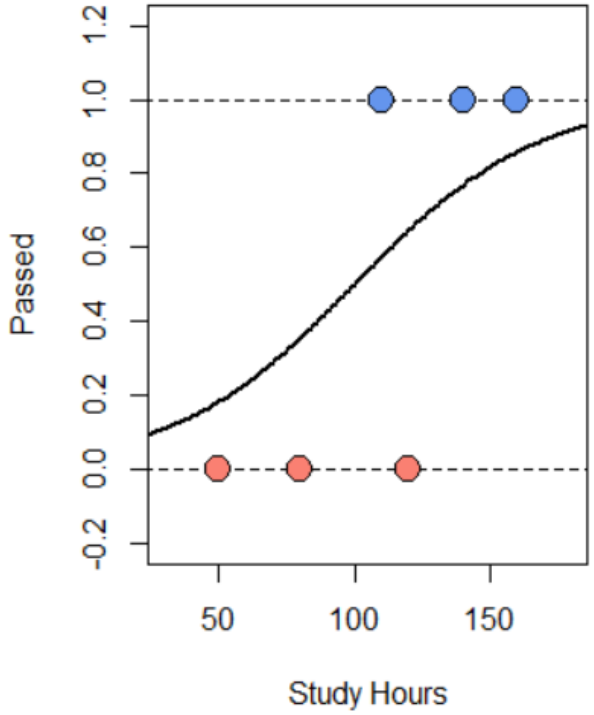


RPubs - 4.1 - Logistic Regression

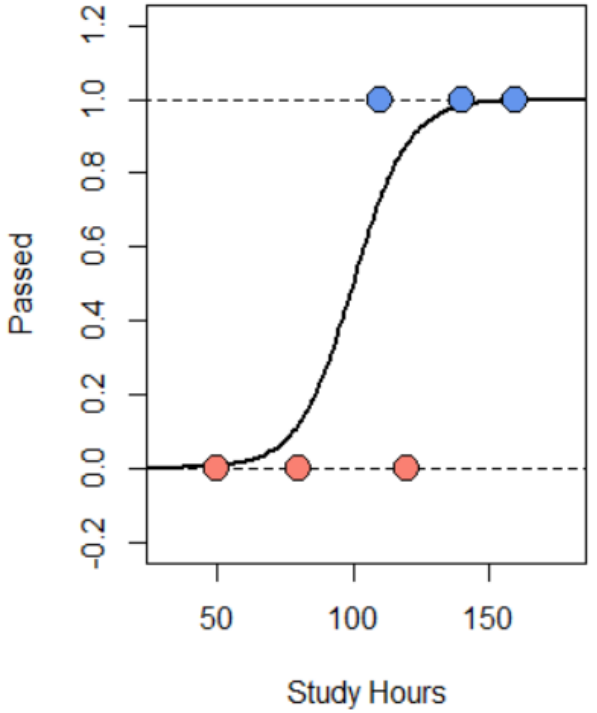
5.1 二元逻辑回归
Binary Logistic Regression

模型1： $\log\left(\frac{\pi_i}{1-\pi_i}\right) = -3 + 0.03x_i$

模型2： $\log\left(\frac{\pi_i}{1-\pi_i}\right) = -10 + 0.1x_i$



$$f(x_1, x_2, \cdots x_n; \pi)$$
$$= \pi^{\sum_{i=1}^{n} x_i} (1-\pi)^{n-\sum_{i=1}^{n} x_i}$$
$$= 0.0709$$



$$f(x_1, x_2, \cdots x_n; \pi)$$
$$= \pi^{\sum_{i=1}^{n} x_i} (1-\pi)^{n-\sum_{i=1}^{n} x_i}$$
$$= 0.0747$$

5.1 二元逻辑回归
Binary Logistic Regression

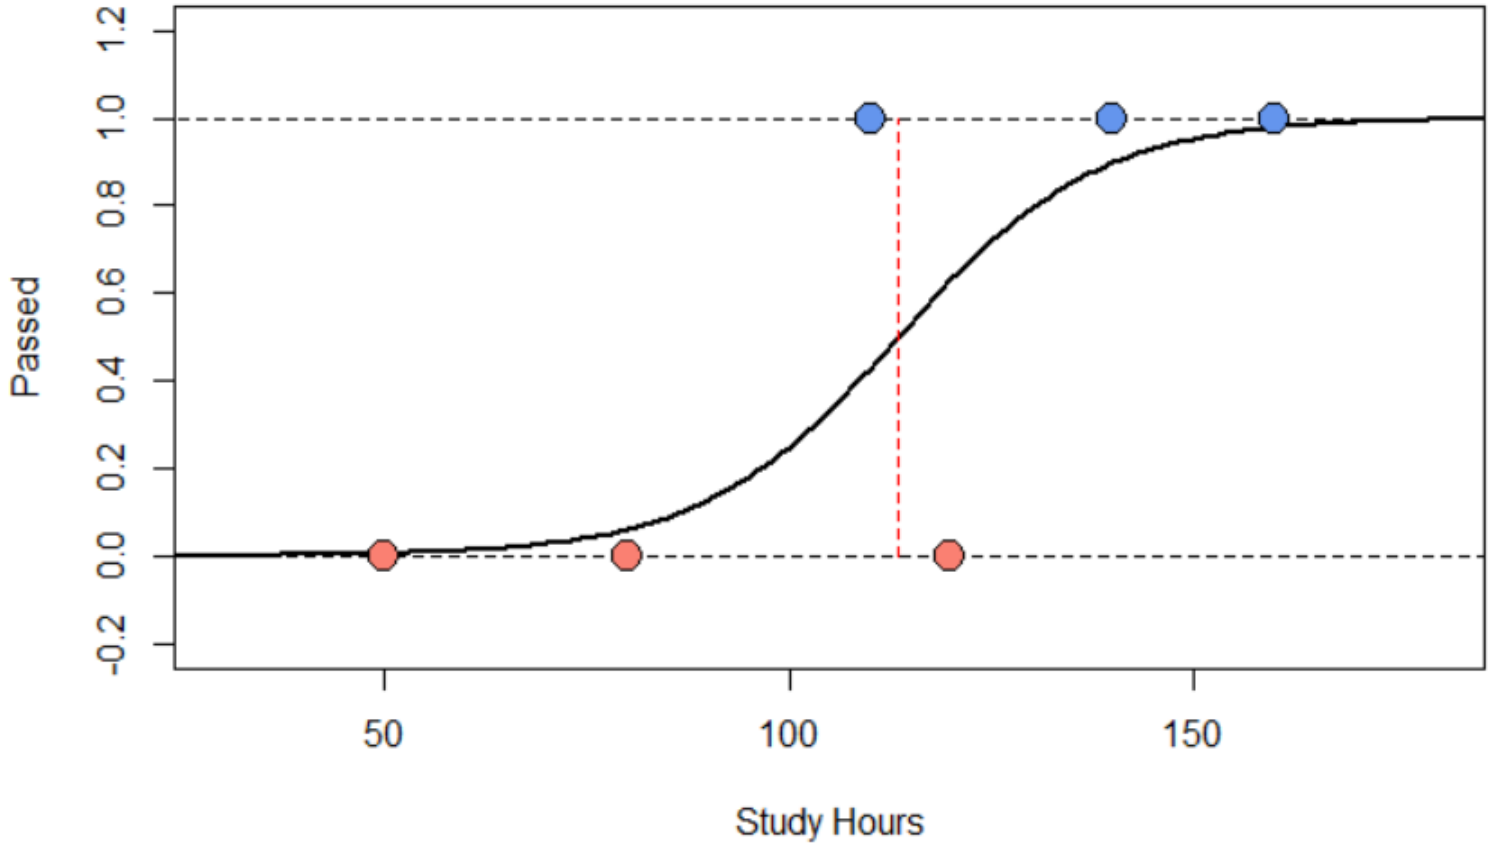
$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = -9.3 + 0.082x_i$$

$$\pi_i = \frac{1}{1+\exp\left(9.3-0.082x_i\right)}$$

$$f\left(x_1, x_2, \cdots x_n; \pi\right)$$

$$= \pi^{\sum_{i=1}^{n} x_i} \left(1-\pi\right)^{n-\sum_{i=1}^{n} x_i}$$

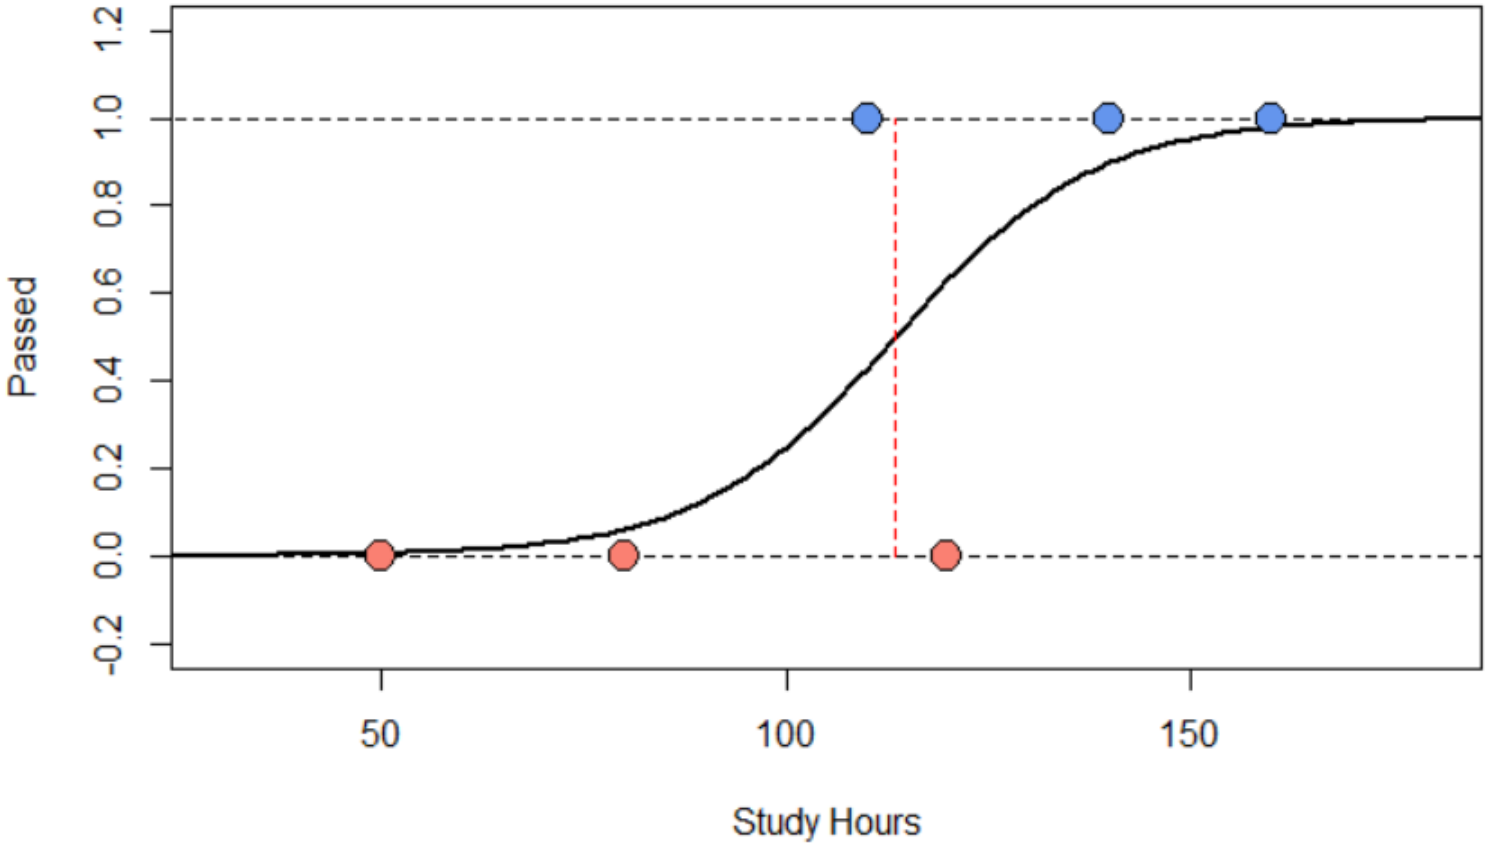
$$= 0.1302$$



5.1 二元逻辑回归
Binary Logistic Regression

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = -9.3 + 0.082x_i$$

每增加一个小时的学习时间，考试通过的发生比就增长exp(0.082)倍，即1.086



5.1 二元逻辑回归
Binary Logistic Regression

基于未来地震情景下中国四川省阿坝州和成都平原地区地震诱发滑坡概率危险性制图

Shao et al. Geoscience Letters (2023) 10:55
https://doi.org/10.1186/s40562-023-00307-5

Geoscience Letters

RESEARCH LETTER Open Access

Seismically-induced landslide probabilistic hazard mapping of Aba Prefecture and Chengdu Plain region, Sichuan Province, China for future seismic scenarios

Xiaoyi Shao[1,2,3], Siyuan Ma[4], Chong Xu[1,2,3*], Jia Cheng[1,2] and Xiwei Xu[5]

Xiaoyi Shao, Siyuan Ma, Chong Xu*, Jia Cheng and Xiwei Xu (2023) Seismically-induced landslide probabilistic hazard mapping of Aba Prefecture and Chengdu Plain region, Sichuan Province, China for future seismic scenarios. Geoscience Letters. 10:55

5.1 二元逻辑回归 Binary Logistic Regression

- 逻辑回归(LR)模型是评估地震诱发的滑坡灾害的首选方法
- 该模型可以对不同类型的自变量(包括连续变量和离散变量)建模
- 根据LR模型中各影响因素的回归系数，将各影响因素的层数叠加得到预测概率

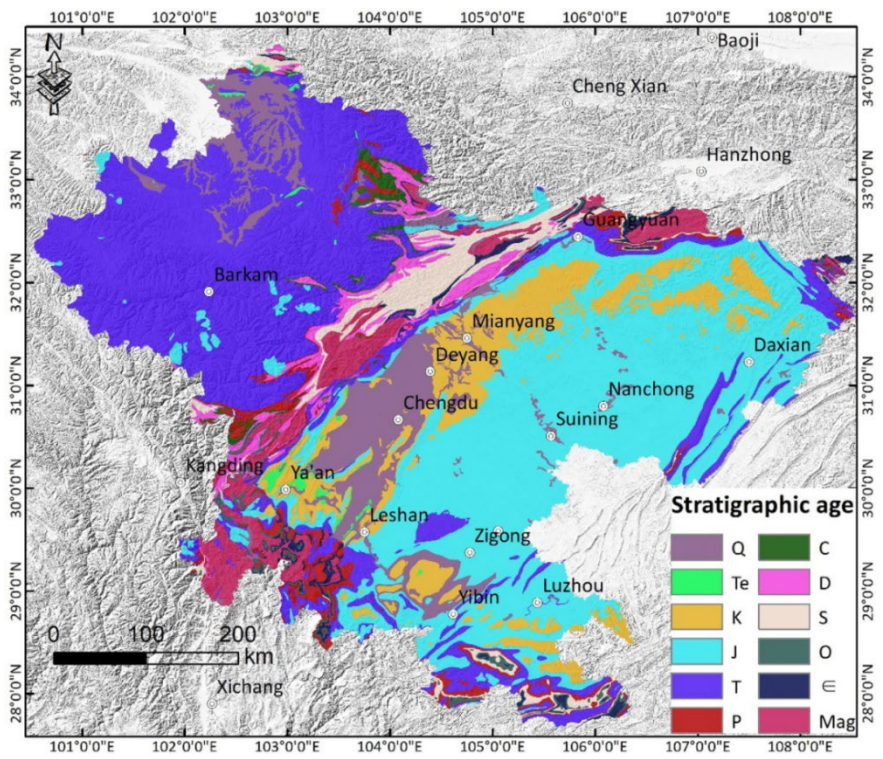
$$Z = \beta_0 + \beta_1 \chi_1 + \beta_2 \chi_2 + \beta_3 \chi_3 \ldots \beta_i \chi_i \qquad (1)$$

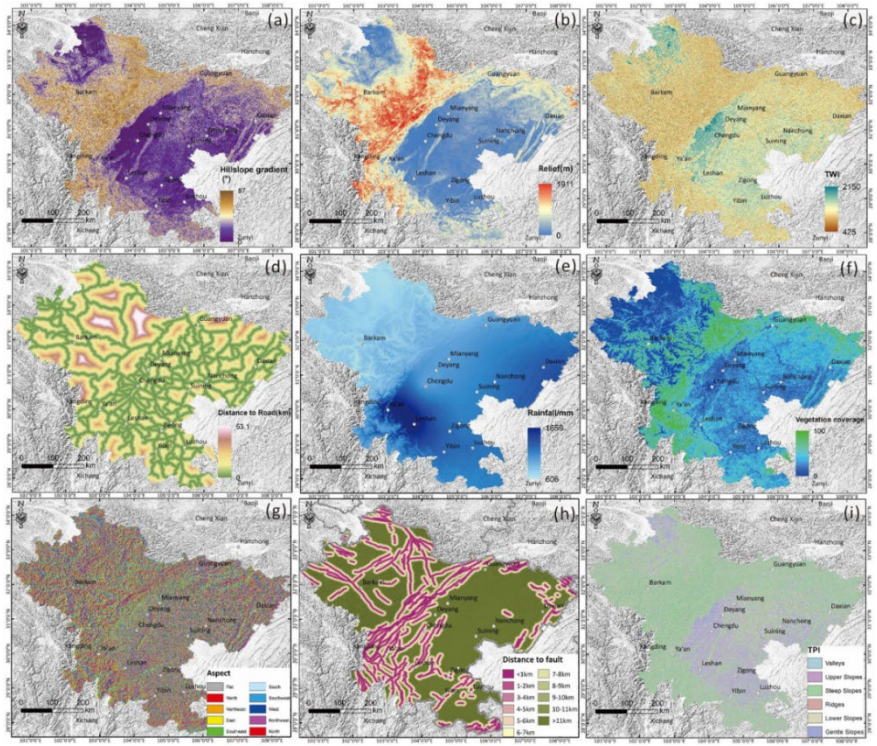
$$P = 1/\left(1 + e^{-z}\right), \qquad (2)$$

- P为滑坡发生概率，取值范围为[0,1]
- Z表示变量叠加后的线性权值之和
- χ_i表示各影响因素，β_i为logistic回归系数

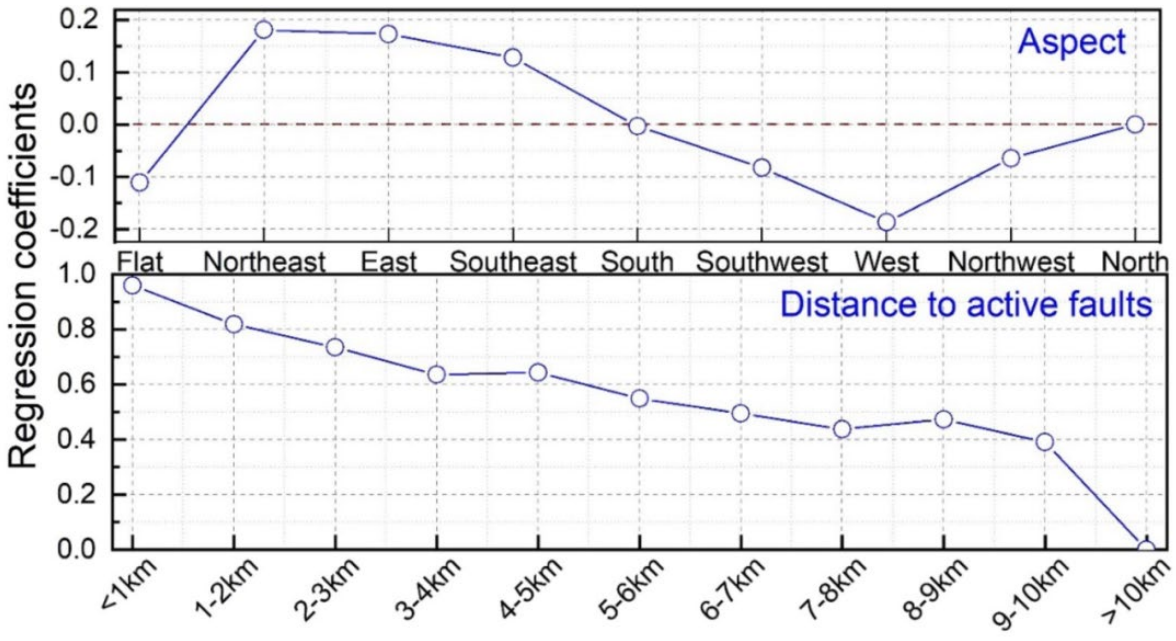
5.1 二元逻辑回归
Binary Logistic Regression

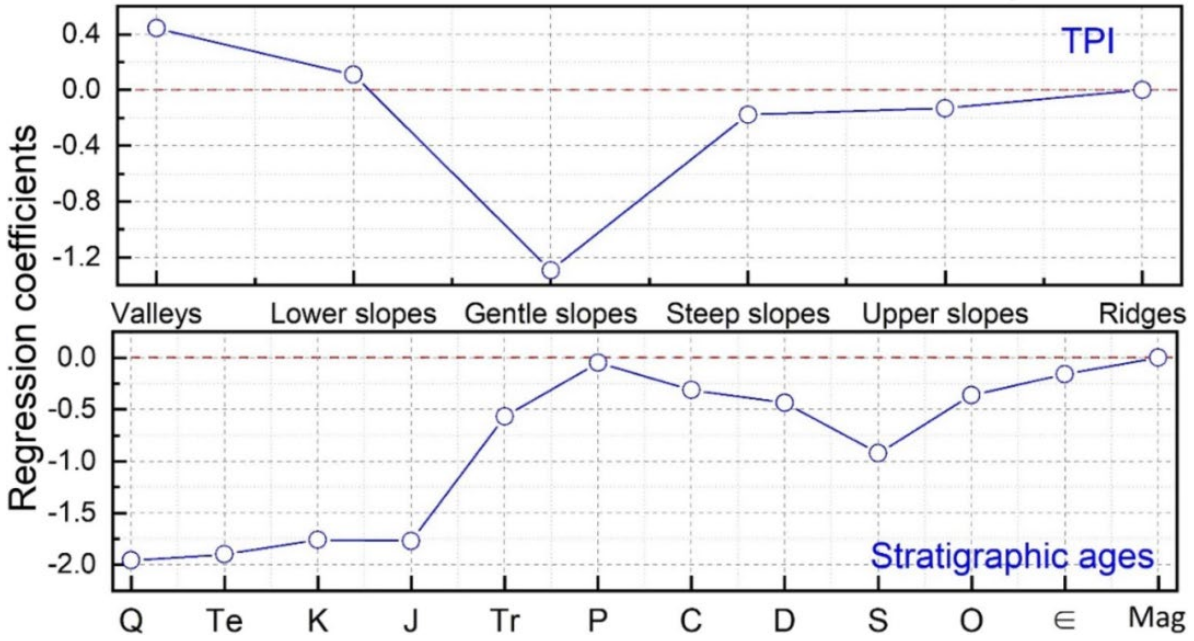
- 地震诱发滑坡主要受地震运动、地形、地质、水文等不同影响因素的综合影响
- 该研究选取高程、坡度、坡向、地形起伏、地形湿度指数(TWI)、地形位置指数(TPI)、地表运动峰值、与活动断层的距离、植被覆盖率、与道路的距离、岩性、年降雨量等12个因子建立LR模型



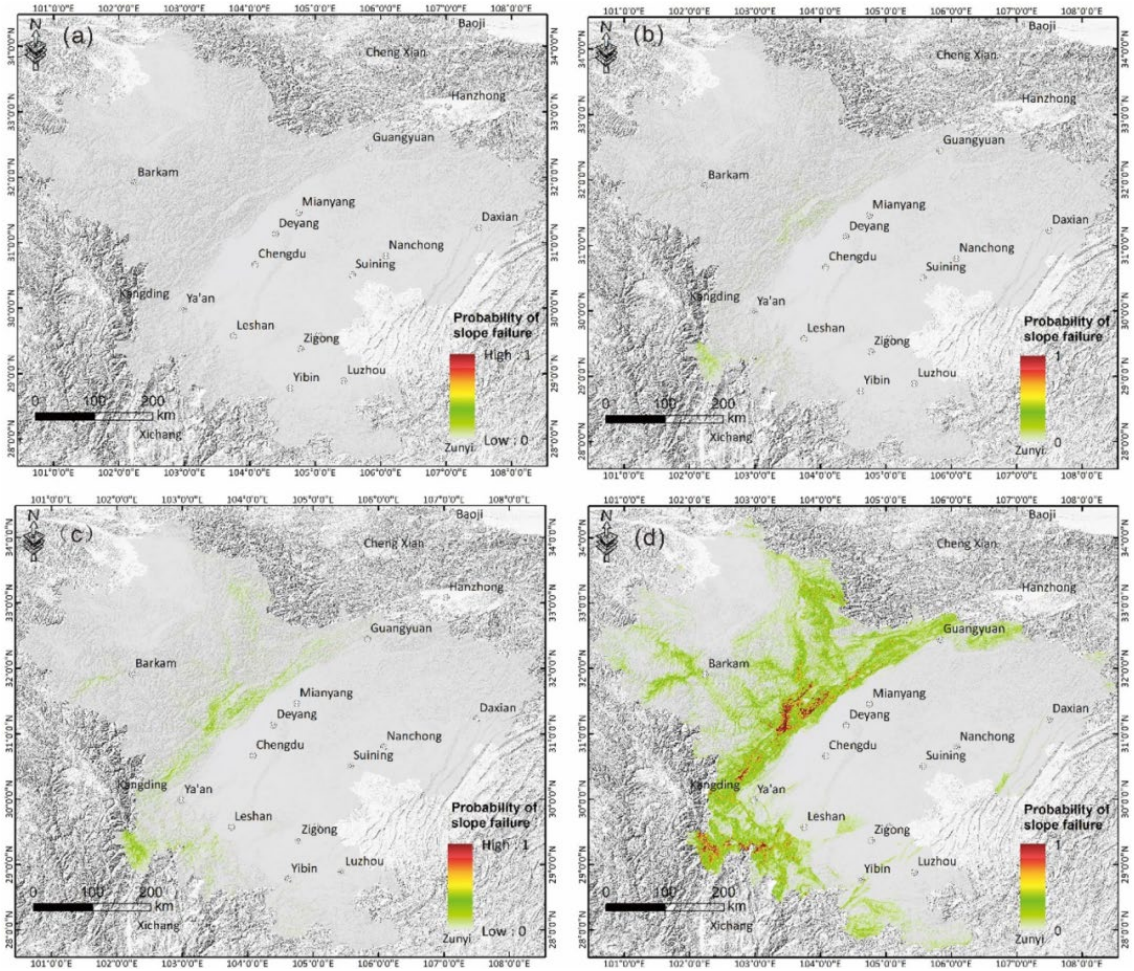


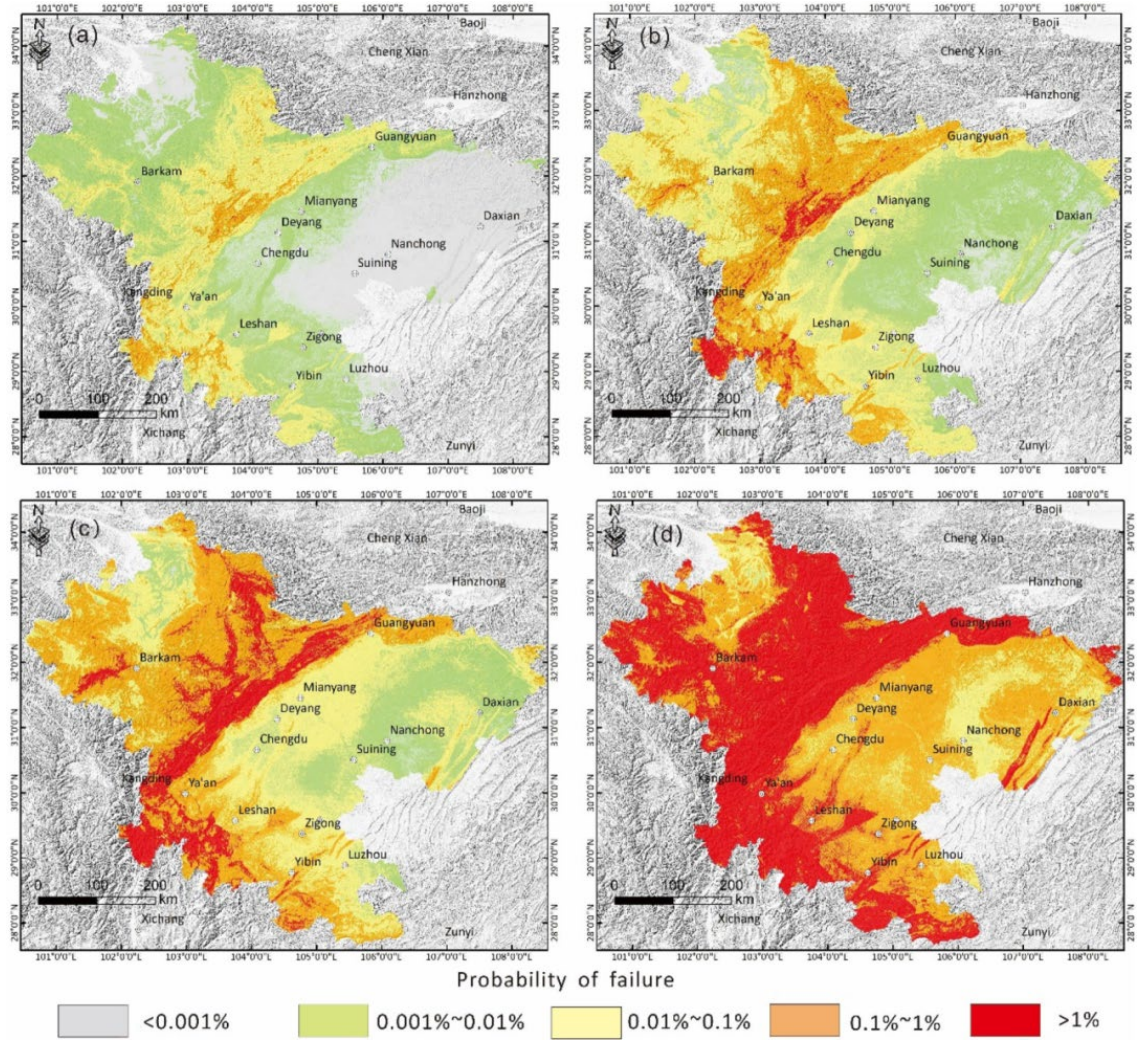
5.1 二元逻辑回归
Binary Logistic Regression





5.1 二元逻辑回归
Binary Logistic Regression





典型的广义线性模型

介绍三种典型的广义线性模型：

- 5.1 二元逻辑回归（Binary Logistic Regression）
- **5.2 泊松回归（Poisson Regression）**
- 5.3 负二项回归（Negative Binomial Regression）

5.2 泊松回归
Poisson Regression

- 主要针对**计数数据（count based data）**进行拟合；
- **计数数据（count based data）**：计数数据记录具有一定发生率事件，在一段时间内的出现次数，例如
  - 一小时内，通过交叉路口的车辆数量；
  - 一月内，到医院就诊人数；
  - 一年内，北京地区交通事故数量；
  - …

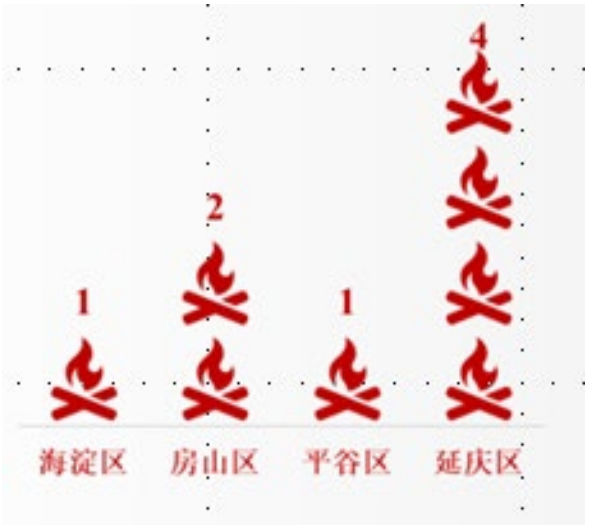
需要注意，事件的发生率可能会**随时间或者外界条件的变化而不同**

5.2 泊松回归
Poisson Regression

计数数据的主要特征：

口离散数据集，数据包含非负整数[0，+∞]，一般回归方法（例如普通最小二乘法等）主要针对实数数据，对离散整数数据的回归分析并非完全合适

口偏态分布（Skewed distribution），可能在某几个类别中存在大量数据，导致数据出现明显的偏态分布



5.2 泊松回归 Poisson Regression

计数数据的主要特征：

- **离散数据集**，数据包含非负整数[0，+∞]，一般回归方法（例如普通最小二乘法等）主要针对实数数据，对离散整数数据的回归分析并非完全合适
- **偏态分布（Skewed distribution）**，可能在某几个类别中存在大量数据，导致数据出现明显的偏态分布
- **稀疏性（Sparsity）**，事件出现的频次比较低，比如事故灾害数据，因此数据稀少，呈现稀疏性
- **发生率（Rate of occurrence）**，在对数据建模时，通常假设存在某一发生率λ导致观测数据的产生，该发生率可能随时间或者条件的变化而改变。

5.2 泊松回归
Poisson Regression

- **泊松分布**是对一段时间或某一区域内，事件发生频次统计建模的重要离散分布；通常**首先使用泊松回归模型对计数数据进行建模**，并将其作为基准模型与其他复杂模型进行对比

- 首先回顾泊松分布的概率质量函数PMF为

$$f(x)=\frac{\lambda^{x}e^{-\lambda}}{x!},\ x=0,1,2,\ldots,\ \text{and},\lambda>0$$

- 随机变量x为事件出现的次数；λ为时间发生率

- 泊松分布的一个特点是期望与方差相等，均为λ

$$E(X)=V(X)=\lambda$$

5.2 泊松回归
Poisson Regression

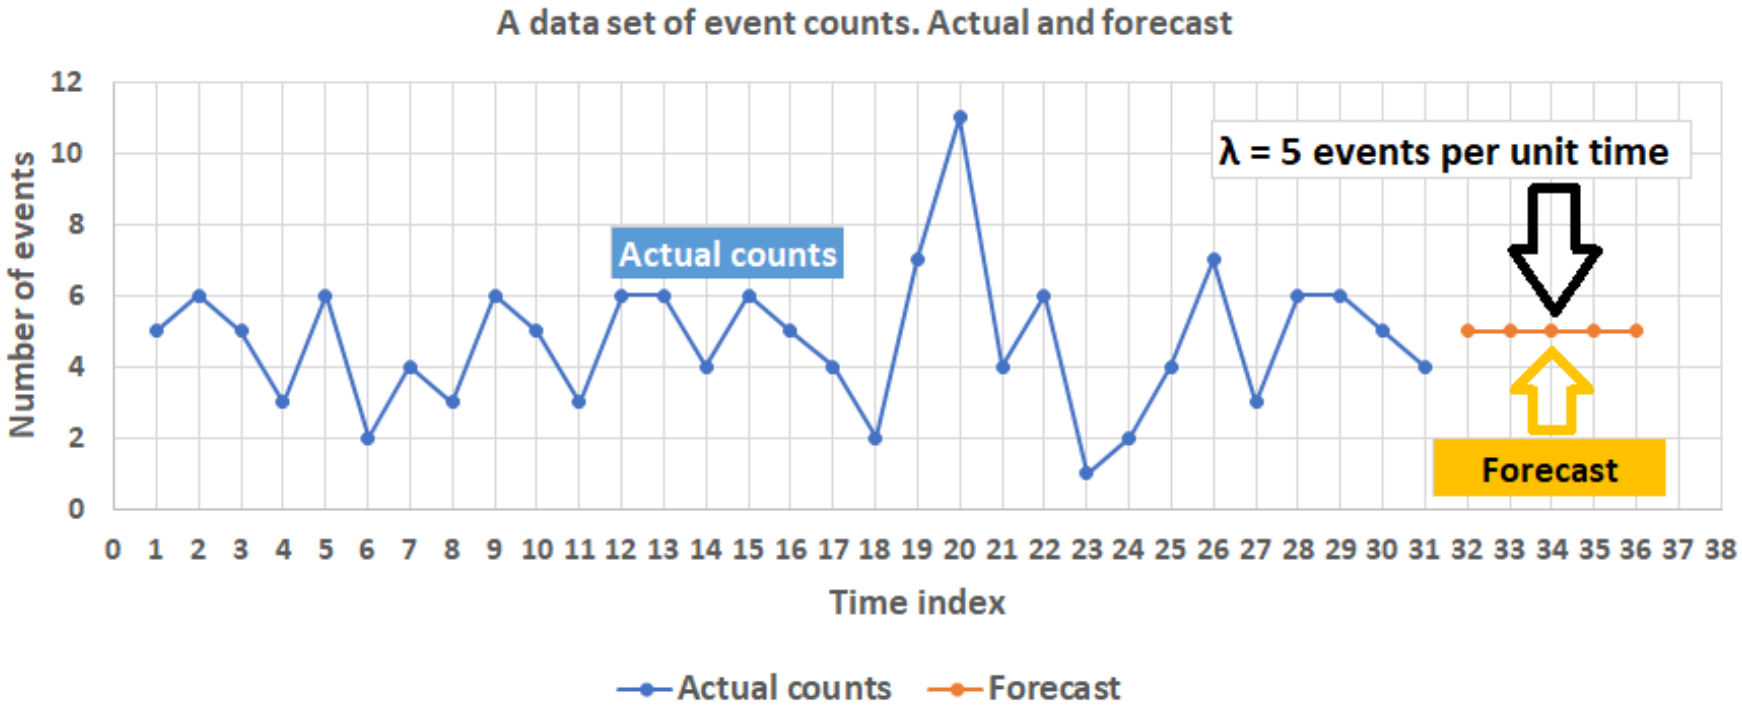
- 纽约布鲁克林大桥每日自行车计数数据

Date	Day	High Temp (°F)	Low Temp (°F)	Precipitation	Brooklyn Bridge	Manhattan Bridge	Williamsburg Bridge	Queensboro Bridge	Total
6/1	Thursday	78.1	62.1	0.00	3,468	7,328	8,461	6,184	25,441
6/2	Friday	73.9	60.1	0.01	3,271	7,007	7,968	5,293	23,539
6/3	Saturday	72.0	55	0.01	2,589	4,510	6,210	4,084	17,393
6/4	Sunday	68.0	60.1	0.09	1,805	3,127	4,023	3,023	11,978
6/5	Monday	66.9	60.1	0.02	2,171	4,552	5,276	3,359	15,358
6/6	Tuesday	55.9	53.1	0.06	1,193	3,021	3,807	2,572	10,593
6/7	Wednesday	66.9	54	0.00	3,211	7,180	7,632	5,072	23,095
6/8	Thursday	68.0	59	0.00	3,253	7,083	7,778	5,288	23,402
6/9	Friday	80.1	59	0.00	3,401	6,859	7,744	5,155	23,159

图片来源：Sachin Date, The Poisson Regression Model

5.2 泊松回归
Poisson Regression

- 若事件发生率λ为常数，那么可以直接使用均值λ进行预测，如下图所示



图片来源：Sachin Date, The Poisson Regression Model

5.2 泊松回归
Poisson Regression

- 若事件发生率λ为常数，那么可以直接使用均值λ进行预测，如下图所示
- 但实际情况中，**事件发生率通常会发生变化，并不为常数**，例如，天气条件、节假日等因素会影响骑行通过大桥的人数，即事件发生率

自变量X
（解释变量）

Date	Day	High Temp (°F)	Low Temp (°F)	Precipitation	Brooklyn Bridge
6/1	Thursday	78.1	62.1	0.00	3,468
6/2	Friday	73.9	60.1	0.01	3,271
6/3	Saturday	72.0	55	0.01	2,589
6/4	Sunday	68.0	60.1	0.09	1,805
6/5	Monday	66.9	60.1	0.02	2,171
6/6	Tuesday	55.9	53.1	0.06	1,193
6/7	Wednesday	66.9	54	0.00	3,211
6/8	Thursday	68.0	59	0.00	3,253
6/9	Friday	80.1	59	0.00	3,401
6/10	Saturday	84.0	68	0.00	3,066
6/11	Sunday	90.0	73	0.00	2,465
6/12	Monday	91.9	77	0.00	2,854

因变量Y
（响应变量）

5.2 泊松回归
Poisson Regression

- 在泊松回归中，一般选用**log函数作为连接函数**，即

$$\log(\lambda_i) = \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}$$

$$\lambda_i = e^{\boldsymbol{x}_i\boldsymbol{\beta}} \qquad \boldsymbol{x}_i = (x_{1i}, x_{2i}, \ldots, x_{ki})^{\mathrm{T}} \qquad \boldsymbol{\beta} = (\beta_{1i}, \beta_{2i}, \ldots, \beta_{ki})^{\mathrm{T}}$$

- 似然函数，即n个观测的联合概率为

$$L(\boldsymbol{\beta}) = \prod_{i=1}^{n} \frac{\lambda_i^{\,y_i} e^{-\lambda_i}}{y_i!}$$

$$\log(L(\boldsymbol{\beta})) = \sum_{i=1}^{n} (y_i \log(\lambda_i) - \lambda_i - \log(y_i!))$$

$$\log(L(\boldsymbol{\beta})) = \sum_{i=1}^{n} \left(y_i \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta} - e^{\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}} - \log(y_i!)\right)$$

5.2 泊松回归 Poisson Regression

- 对对数形式的似然函数求导，并令其等于0

$$\frac{\partial \log\left(L(\boldsymbol{\beta})\right)}{\partial \boldsymbol{\beta}} = \frac{\partial}{\partial \boldsymbol{\beta}}\left(\sum_{i=1}^{n}\left(y_i \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta} - e^{\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}} - \log(y_i!)\right)\right)$$

$$= \sum_{i=1}^{n}\left(y_i \boldsymbol{x}_i - e^{\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}}\boldsymbol{x}_i\right) = \sum_{i=1}^{n}\left(y_i - e^{\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}}\right)\boldsymbol{x}_i = 0$$

- 通过求解以上方程组，获得回归系数的最大似然估计$\hat{\boldsymbol{\beta}}$

5.2 泊松回归
Poisson Regression

对照广义线性模型，对于泊松回归

- **随机成分**，因变量（响应变量）Y为服从泊松分布的随机变量，期望为λ；
- **系统性成分**，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量Y的期望；
- **连接函数**，使用对数函数log。

5.2 泊松回归 Poisson Regression

- 利用Python statsmodels package求解输出结果

Generalized Linear Model Regression Results

Dep. Variable:	BB_COUNT	No. Observations:	170
Model:	GLM	Df Residuals:	163
Model Family:	Poisson	Df Model:	6
Link Function:	log	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-12335.
Date:	Fri, 20 Sep 2019	Deviance:	23030.
Time:	20:11:31	Pearson chi2:	2.33e+04
No. Iterations:	5	Covariance Type:	nonrobust

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	6.9515	0.012	564.893	0.000	6.927	6.976
DAY	9.858e-06	0.000	0.057	0.955	-0.000	0.000
DAY_OF_WEEK	-0.0182	0.001	-24.531	0.000	-0.020	-0.017
MONTH	0.0176	0.001	22.469	0.000	0.016	0.019
HIGH_T	0.0246	0.000	73.508	0.000	0.024	0.025
LOW_T	-0.0147	0.000	-39.611	0.000	-0.015	-0.014
PRECIP	-0.7578	0.008	-93.439	0.000	-0.774	-0.742

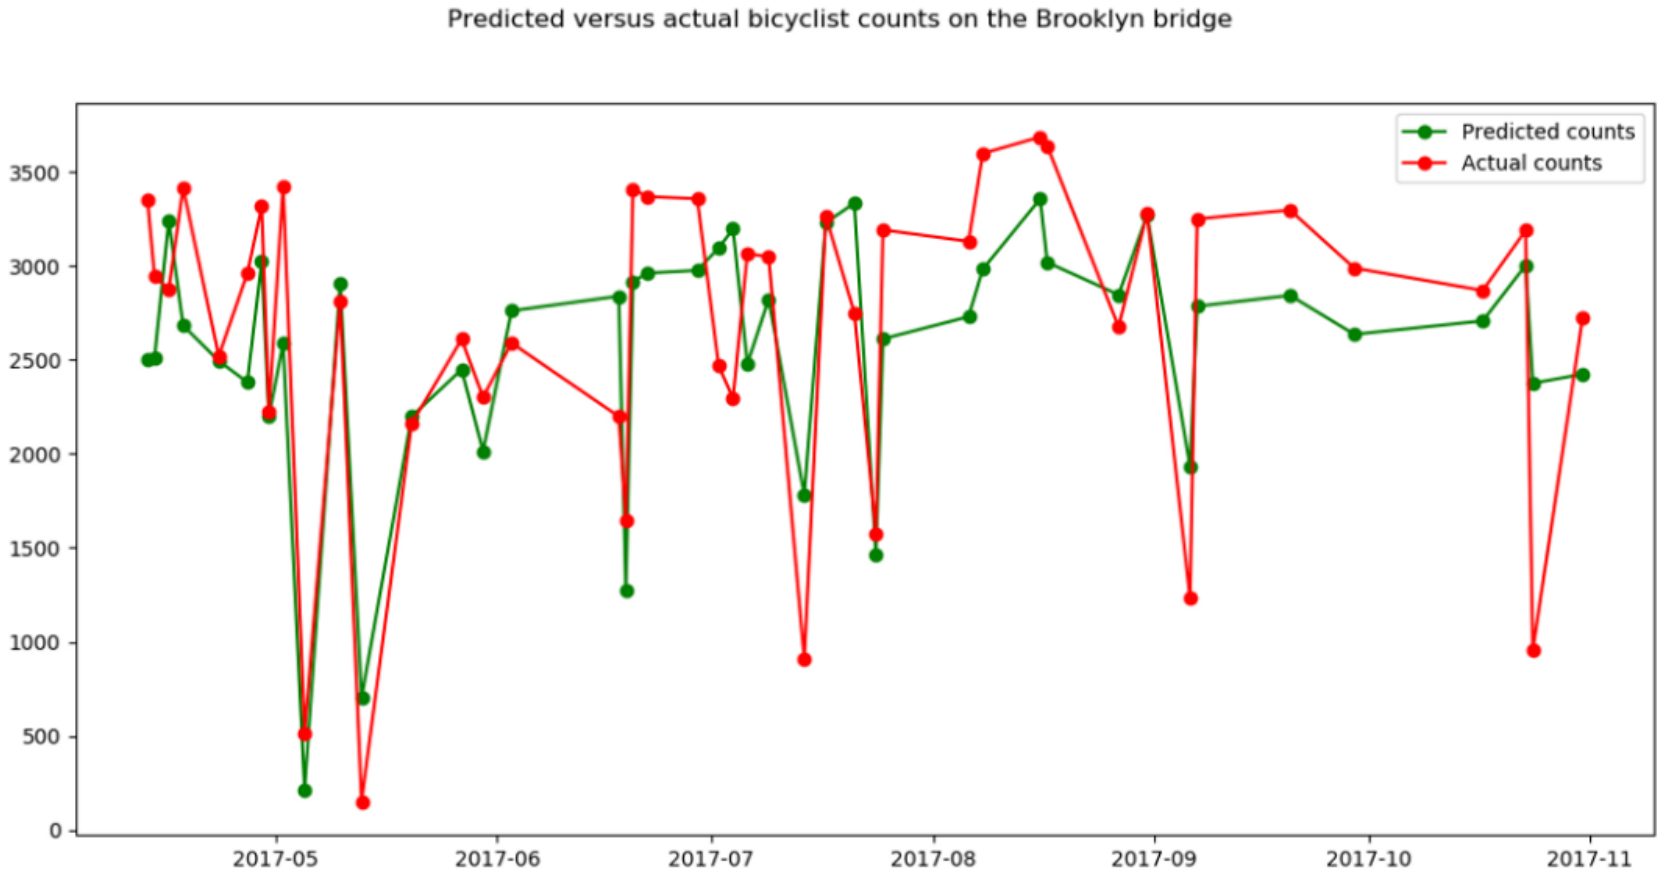
Regression Coefficients $\boldsymbol{\beta}$

p value

95% confidence interval

5.2 泊松回归
Poisson Regression

- 使用训练数据集建立回归模型，使用测试数据验证如下



5.2 泊松回归 Poisson Regression

泊松回归模型的**拟合优度（Goodness-of-fit）**

- 拟合结果的Deviance和Pearson chi2值都非常高；
- 该拟合的自由度为163（观测数量 — 模型自由度），0.05置信水平，163自由度的标准Chi-Squared值为193.791，远远低于23030和23300，说明泊松分布不能很好地描述该数据集；
- 泊松分布要求均值与方差相等，数据一般很难满足要求，导致拟合效果较差。

Generalized Linear Model Regression Results

Dep. Variable:	BB_COUNT	No. Observations:	170
Model:	GLM	Df Residuals:	163
Model Family:	Poisson	Df Model:	6
Link Function:	log	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-12335.
Date:	Fri, 20 Sep 2019	Deviance:	23030.
Time:	20:11:31	Pearson chi2:	2.33e+04
No. Iterations:	5	Covariance Type:	nonrobust

典型的广义线性模型

介绍三种典型的广义线性模型：

- 5.1 二元逻辑回归（Binary Logistic Regression）
- 5.2 泊松回归（Poisson Regression）
- **5.3 负二项回归（Negative Binomial Regression）**

负二项分布
Negative binomial distribution

负二项分布（Negative-Binomial distribution）

- 二项分布描述的是在固定的*n*次试验中，“成功”的次数，例如将一枚均质的硬币抛100次，正面出现的次数；
- 负二项分布与二项分布类似，但其描述的是在出现固定“失败”次数*r*之前，成功的次数，例如，同样是抛硬币，负二项分布描述的是在出现100次背面之前，正面出现次数的分布；
- 负二项分布的概率质量函数PMF为

$$f(x) = C_{r+x-1}^{x} \pi^{r} (1-\pi)^{x}, \text{ for } x = 0,1,2,3,\ldots$$

5.3 负二项分布 Negative binomial distribution

负二项分布（Negative-Binomial distribution）

- 与泊松分布类似，负二项分布同样是对一段时间或某一区域内，事件发生频次统计建模的重要离散分布；
- 但负二项分布包含两个参数，r和π，其期望和方差分别为：

$$E(x)=\frac{r(1-\pi)}{\pi}=\mu \quad \text{and} \quad V(X)=\mu+\frac{1}{r}\mu^2$$

- 负二项分布不再要求均值和方差相同，相对较弱的限制条件，也使得负二项分布可以对数据进行较好的拟合。

5.3 负二项分布 Negative binomial distribution

- 将发生概率π用均值μ表示

$$E(x)=\frac{r(1-\pi)}{\pi}=\mu \qquad \pi=\frac{r}{r+\mu}$$

- 负二项分布的概率质量函数PMF为

$$f(x)=C_{r+x-1}^{x}\pi^{r}(1-\pi)^{x},\ \text{for}\ x=0,1,2,3,\ldots$$

$$f(Y=y_i\mid\mu_i,r)=C_{r+y_i-1}^{y_i}\left(\frac{r}{r+\mu_i}\right)^{r}\left(\frac{\mu_i}{r+\mu_i}\right)^{y_i},\ \text{for}\ y_i=0,1,2,3,\ldots$$

5.3 负二项分布 Negative binomial distribution

- 在**负二项回归**中，一般也选用**log函数作为连接函数**，即

$$\log\left(\mu_i\right)=\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}$$

- 似然函数，即n个观测的联合概率为

$$L\left(\boldsymbol{\beta}\right)=\prod_{i=1}^{n}C_{r+y_i-1}^{y_i}\left(\frac{r}{r+\mu_i}\right)^{r}\left(\frac{\mu_i}{r+\mu_i}\right)^{y_i}$$

- 对数形式的似然函数为

$$\log\left(L\left(\boldsymbol{\beta}\right)\right)=\sum_{i=1}^{n}\left(\log\left(C_{r+y_i-1}^{y_i}\right)-r\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(r\right)+y_i\log\left(\mu_i\right)\right)$$

$$\log\left(L\left(\boldsymbol{\beta}\right)\right)=\sum_{i=1}^{n}\left(\log\left(C_{r+y_i-1}^{y_i}\right)-\left(y_i+r\right)\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(r\right)+y_i\log\left(\mu_i\right)\right)$$

负二项分布
Negative binomial distribution

对照广义线性模型，对于**负二项分布**

- **随机成分**，因变量（响应变量）*Y*为**服从负二项分布**的随机变量；
- **系统性成分**，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量*Y*的期望；
- **连接函数**，使用对数函数log。

负二项分布
Negative binomial distribution

- 利用Python statsmodels package求解输出结果

Generalized Linear Model Regression Results

Dep. Variable:	BB_COUNT	No. Observations:	172
Model:	GLM	Df Residuals:	165
Model Family:	NegativeBinomial	Df Model:	6
Link Function:	log	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-1383.2
Date:	Sun, 15 Nov 2020	Deviance:	330.99
Time:	17:11:30	Pearson chi2:	310.
No. Iterations:	8		
Covariance Type:	nonrobust		

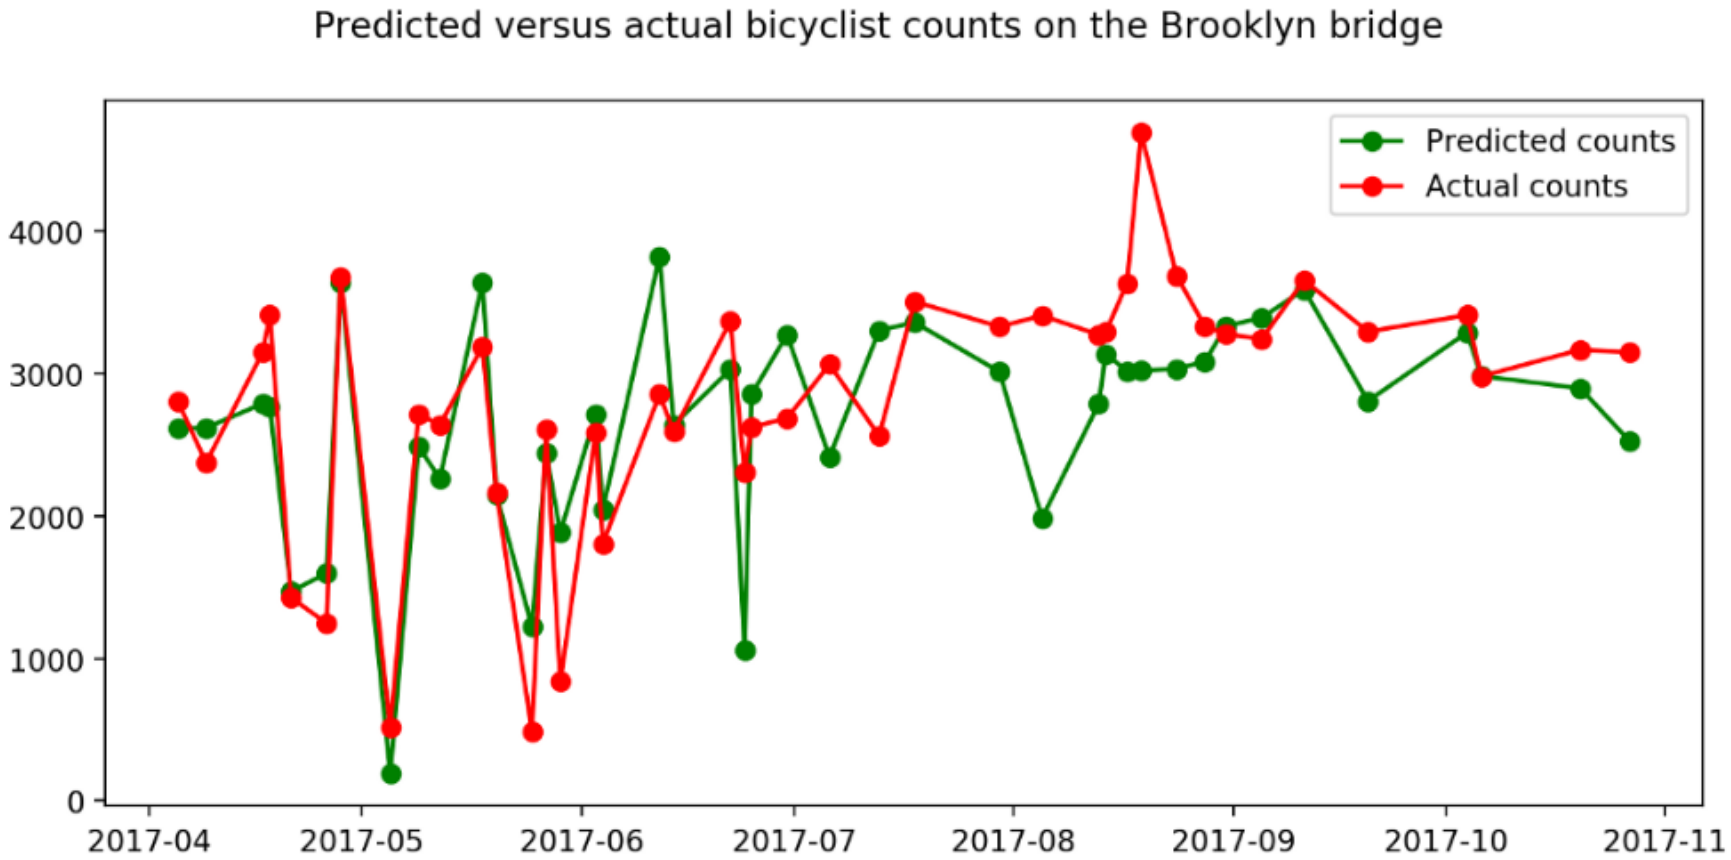
	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	6.8650	0.116	59.216	0.000	6.638	7.092
DAY	0.0008	0.002	0.484	0.628	-0.003	0.004
DAY_OF_WEEK	-0.0256	0.007	-3.505	0.000	-0.040	-0.011
MONTH	0.0092	0.008	1.186	0.236	-0.006	0.024
HIGH_T	0.0281	0.003	8.384	0.000	0.022	0.035
LOW_T	-0.0164	0.004	-4.327	0.000	-0.024	-0.009
PRECIP	-0.7851	0.044	-17.786	0.000	-0.872	-0.699

Regression Coefficients β

p value of each coefficient a significance of 95%

95% confidence interval for each coefficient

负二项分布
Negative binomial distribution



负二项分布
Negative binomial distribution

负二项回归模型的拟合优度（Goodness-of-fit）

- 拟合结果的Deviance和Pearson chi2值相较于泊松分布显著下降；
- 该拟合的自由度为163（观测数量 — 模型自由度），0.05置信水平，163自由度的标准Chi-Squared值为193.791，依然低于310，说明负二项分布可提高对数据的描述程度，但依然有可能被进一步提升。

Generalized Linear Model Regression Results

Dep. Variable:	BB_COUNT	No. Observations:	172
Model:	GLM	Df Residuals:	165
Model Family:	NegativeBinomial	Df Model:	6
Link Function:	log	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-1383.2
Date:	Sun, 15 Nov 2020	Deviance:	330.99
Time:	17:11:30	Pearson chi2:	310.
No. Iterations:	8		
Covariance Type:	nonrobust		

谢谢！

Thanks !

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn