决策方法论

Decision Making Technology

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn

主要内容

- 1 线性回归
- 2 离散数据类型
- 3 离散数据建模
- 4 最大似然估计
- 5 广义线性模型
- 6 典型的广义线性模型

5 广义线性模型 Generalized Linear Models

- **广义线性模型（Generalized Linear Models，GLM）**是普通最小二乘法的扩展，是用以解决离散因变量、非正态分布因变量的回归分析与建模方法
- 广义线性模型假设**观测数据因变量*Y*来自某个指数族**（exponential family）分布，该分布的均值为μ，均值可以由对应的自变量（解释变量）***X***解释

因变量*Y*服从某分布，均值为：$E(\boldsymbol{Y}) = \mu$

均值可被自变量***X***解释：$g(\mu) = \boldsymbol{X}'\boldsymbol{\beta}$

$$\mu = g^{-1}(\boldsymbol{X}'\boldsymbol{\beta})$$

函数*g*(.)通常是非线性的，但解释变量是通过线性组合***X′ β***来影响观测值的，基于此种考虑，称其为**广义线性模型**

5 广义线性模型 Generalized Linear Models

广义线性模型的**三个主要成分：**

□随机成分（Random Component），因变量的统计分布，例如普通最小二乘法假设因变量服从正态分布、二值逻辑回归假设因变量服从伯努利分布，随机部分是广义线性模型中唯一的随机性来源

□系统性成分（Systematic Component），模型的自变量，即解释变量$(x_1,x_2,\ldots,x_n)$，以及他们的线性组合，例如$\beta_0+\beta_1x_1+\beta_2x_2+\ldots+\beta_nx_n$

□连接函数（Link Function），η或者$g(\mu)$用以连接广义线性模型的随机成分和系统性成分，表示因变量（响应变量）的均值与自变量（解释变量）之间的关系，例如，在普通最小二乘法中$\eta=g(\mu)=E(Y)$，在逻辑回归中$\eta=g(\pi)=\log(\pi/(1-\pi))=\text{logit}(\pi)$

5 广义线性模型 Generalized Linear Models

普通最小二乘线性回归可以视为广义线性模型的特例，响应变量 Y 为连续变量

$$\mu = \beta_0 + \sum_{i=1}^{n} \beta_i x_i$$

- **随机成分：** 因变量 Y 服从正态分布，正态分布的均值为 μ，方差为常数 σ^2；
- **系统性部分：** 可以包含多个解释变量，利用解释变量的线性组合来估计响应变量 Y 的期望；
- **连接函数：** 线性本体连接（identity），$\eta = g(\mu) = \mu = E(Y)$，为最简单的连接函数。

6.1 二元逻辑回归
Binary Logistic Regression

- 二元逻辑回归模型可以表示为

$$\log\left(\frac{\pi_i}{1-\pi_i}\right)=\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}$$

- 下标对应第i个观测值，通过整理可得事件出现概率为

$$\pi_i=\frac{\exp\left(\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}\right)}{1+\exp\left(\beta_0+\boldsymbol{x}_i'\boldsymbol{\beta}\right)}$$

- n个Y_1，…，Y_n观测的联合概率，即似然函数为

$$L\left(\beta_0,\boldsymbol{\beta}\right)=\log\left(\prod_{i=1}^{n}\pi_i^{Y_i}\left(1-\pi_i\right)^{1-Y_i}\right)$$

- 通过最大化似然函数，获得最大似然估计$\hat{\beta}_0$和$\hat{\boldsymbol{\beta}}$

6.1 二元逻辑回归 Binary Logistic Regression

对照广义线性模型，对于二元逻辑回归

口随机成分，因变量（响应变量）Y为服从伯努利分布的随机变量，成功概率为π，期望$E(Y)=\pi$

口系统性成分，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量Y的期望

口连接函数，使用logit函数$\eta=g(\pi)=\log(\pi/(1-\pi))$

6.2 泊松回归 Poisson Regression

- 在泊松回归中，一般选用**log函数作为连接函数**，即

$$\log(\lambda_i) = \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}$$

$$\lambda_i = e^{\boldsymbol{x}_i\boldsymbol{\beta}} \qquad \boldsymbol{x}_i = (x_{1i}, x_{2i}, \ldots, x_{ki})^{\mathrm{T}} \qquad \boldsymbol{\beta} = (\beta_{1i}, \beta_{2i}, \ldots, \beta_{ki})^{\mathrm{T}}$$

- 似然函数，即n个观测的联合概率为

$$L(\boldsymbol{\beta}) = \prod_{i=1}^{n} \frac{\lambda_i^{\,y_i} e^{-\lambda_i}}{y_i!}$$

$$\log(L(\boldsymbol{\beta})) = \sum_{i=1}^{n} (y_i \log(\lambda_i) - \lambda_i - \log(y_i!))$$

$$\log(L(\boldsymbol{\beta})) = \sum_{i=1}^{n} \left(y_i \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta} - e^{\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}} - \log(y_i!)\right)$$

6.2 泊松回归
Poisson Regression

对照广义线性模型，对于泊松回归

- **随机成分**，因变量（响应变量）*Y*为服从泊松分布的随机变量，期望为λ；
- **系统性成分**，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量*Y*的期望；
- **连接函数**，使用对数函数log。

6.3 负二项回归 Negative Binomial Regression

- 在**负二项回归**中，一般也选用**log函数作为连接函数**，即

$$\log\left(\mu_i\right)=\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{\beta}$$

- 似然函数，即n个观测的联合概率为

$$L\left(\boldsymbol{\beta}\right)=\prod_{i=1}^{n}C_{r+y_i-1}^{y_i}\left(\frac{r}{r+\mu_i}\right)^{r}\left(\frac{\mu_i}{r+\mu_i}\right)^{y_i}$$

- 对数形式的似然函数为

$$\log\left(L\left(\boldsymbol{\beta}\right)\right)=\sum_{i=1}^{n}\left(\log\left(C_{r+y_i-1}^{y_i}\right)-r\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(r\right)+y_i\log\left(\mu_i\right)\right)$$

$$\log\left(L\left(\boldsymbol{\beta}\right)\right)=\sum_{i=1}^{n}\left(\log\left(C_{r+y_i-1}^{y_i}\right)-\left(y_i+r\right)\log\left(1+\frac{1}{r}\mu_i\right)-y_i\log\left(r\right)+y_i\log\left(\mu_i\right)\right)$$

6.3 负二项回归 Negative Binomial Regression

对照广义线性模型，对于**负二项分布**

- **随机成分**，因变量（响应变量）*Y*为**服从负二项分布**的随机变量；
- **系统性成分**，可以包含多个解释变量，利用解释变量的线性组合来估计响应变量 *Y*的期望；
- **连接函数**，使用对数函数log。

泊松回归：举例

Date	HIGH_T	LOW_T	PRECIP	BB_COUNT
1-Apr-17	46	37	0	606
2-Apr-17	62.1	41	0	2021
3-Apr-17	63	50	0.03	2470
4-Apr-17	51.1	46	1.18	723
5-Apr-17	63	46	0	2807
6-Apr-17	48.9	41	0.73	461
7-Apr-17	48	43	0.01	1222
8-Apr-17	55.9	39.9	0	1674
9-Apr-17	66	45	0	2375
10-Apr-17	73.9	55	0	3324
11-Apr-17	80.1	62.1	0	3887
12-Apr-17	73.9	57.9	0.02	2565
13-Apr-17	64	48.9	0	3353
14-Apr-17	64.9	48.9	0	2942
15-Apr-17	64.9	52	0	2253
16-Apr-17	84.9	62.1	0.01	2877



Environmental Health Risk Assessment

Environmental Health Risk Assessment

Epidemiology

- Analysis of the distribution and determinants of health related states or events **in human populations.**

Toxicology

- Analysis of the distribution and determinants of health related states or events in **lab experiments, typically on animals and with control groups.**

Individual based study

- Cohort study
- Cross-sectional study
- Case-control study

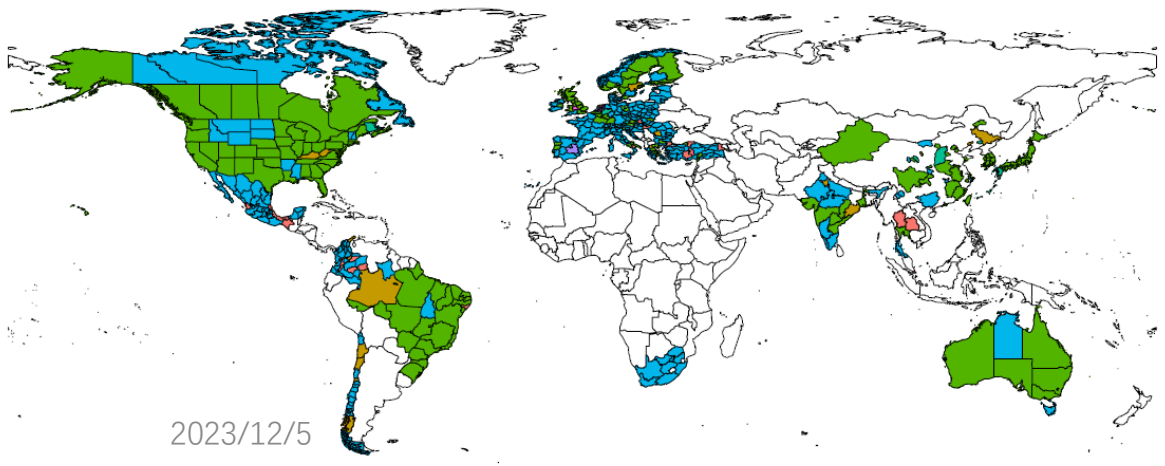
Population based study

- Ecological study

- ✓ Cost of ecological studies is lower than individual based study
- ✓ Wide range of populations and regions can be collected, enhancing the variation in exposure
- ✓ Exposure measurement error could be alleviated by aggregate data

Cause-specific mortality data

- About 40,000 records of 10th version of International Statistical Classification of Diseases and Related Health Problems (ICD-10) compliant cause-specific mortality data from 528 administrative regions of about 50 countries;
- Three types of key air pollution related health impacts: diseases of the circulatory system (ICD-10: I00-I99); chronic lower respiratory diseases (ICD-10: J40-J47) and lung cancer (ICD-10: C33-C34);
- The data were mainly from the official databases of the health or statistical bureau of the governments
- The means of the annual averages of the years between 2012 and 2015 were utilized in the analysis.



Filter

	year	name_1	name_1_code	icd	death.standard	name_0	pop.total	pop.ge65	pop.registered	gdp.lcu	gdp.ppp	gc.ratio
22215	2014	Vorarlberg	AT34	I60_I69	196.23496	Austria	375282	61487	375282	15861.00	19040.816	0.0123886296
22216	2014	Brussels Capital Region	BE1	I60_I69	521.52193	Belgium	1172750	154637	1172750	72680.10	88204.005	0.0668840443
22217	2014	Flemish Region	BE2	I60_I69	4180.68945	Belgium	6421950	1222480	6421950	236045.00	286462.379	0.0427224091
22218	2014	Wallonia	BE3	I60_I69	2082.83011	Belgium	3586140	617057	3586140	94007.20	114086.408	0.0463922604
22219	2014	North West	BG31	I60_I69	3764.79889	Bulgaria	810401	196552	810401	5959.96	9415.419	0.0245210377
22220	2014	North Central	BG32	I60_I69	2311.19011	Bulgaria	835813	181689	835813	6924.64	10939.400	0.0190846292
22221	2014	North East	BG33	I60_I69	3229.76801	Bulgaria	954536	173752	954536	9311.00	14709.321	0.0169836273
22222	2014	South East	BG34	I60_I69	3807.26562	Bulgaria	1063690	202131	1063690	10623.30	16782.464	0.0188215493
22223	2014	South West	BG41	I60_I69	4195.45388	Bulgaria	2127620	381208	2127620	39623.20	62595.893	0.0184850538
22224	2014	South Central	BG42	I60_I69	5259.05180	Bulgaria	1453620	282335	1453620	11415.10	18033.333	0.0298070200
22225	2014	Lake Geneva Region	CH01	I60_I69	584.31996	Switzerland	1545820	257415	1545820	117471.00	86758.493	0.0526483036
22226	2014	Espace Mittelland	CH02	I60_I69	848.90051	Switzerland	1808480	335112	1808480	132597.00	97929.838	0.0291229455
22227	2014	Northwestern Switzerland	CH03	I60_I69	487.12878	Switzerland	1104350	200917	1104350	91805.40	67803.102	0.0324658369
22228	2014	Zurich	CH04	I60_I69	560.94999	Switzerland	1425540	238835	1425540	139179.00	102790.990	0.0271172819
22229	2014	Eastern Switzerland	CH05	I60_I69	514.73621	Switzerland	1134780	198516	1134780	79698.40	58861.448	0.0302924574
22230	2014	Central Switzerland	CH06	I60_I69	285.49656	Switzerland	774123	128262	774123	60062.30	44359.158	0.0173224588
22231	2014	Ticino	CH07	I60_I69	149.18504	Switzerland	346539	73690	346539	28905.20	21348.006	0.0227811256
22232	2014	Prague	CZ01	I60_I69	964.84752	Czech Republic	1243200	225042	1243200	1043720.00	77611.541	0.0053386163
22233	2014	Central Bohemian Region	CZ02	I60_I69	1147.23131	Czech Republic	1302340	212030	1302340	493250.00	36678.316	0.0041644865
22234	2014	Southwest	CZ03	I60_I69	1086.01553	Czech Republic	1210180	213658	1210180	442518.00	32905.488	0.0093921549

Statistical method

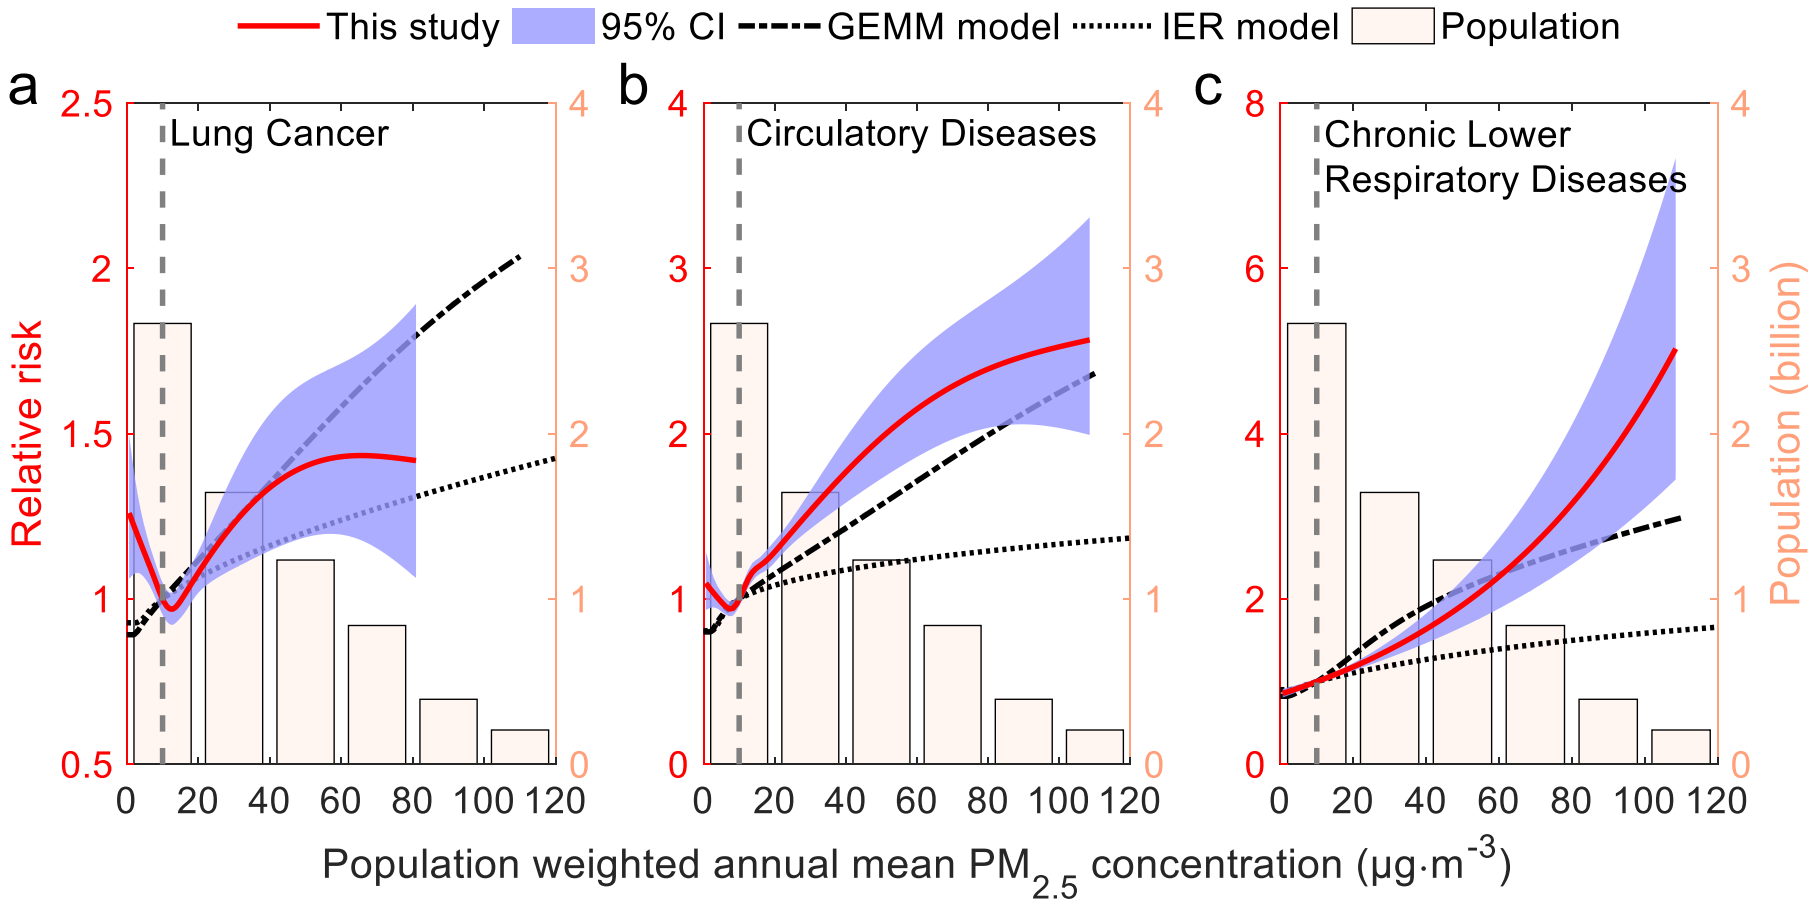
- The Generalized Additive Model (GAM) was utilized to analyse the relation between the mortality risk and various factors;

$$\log(Mortality) = \beta_0 + f_1(PM_{2.5}) + f_2(O_3) + f_3(NO_2) + f_4(T_{avg}) + f_5(GDP) + f_6(GE65) + f_7(BMI30) + f_8(SMK)$$

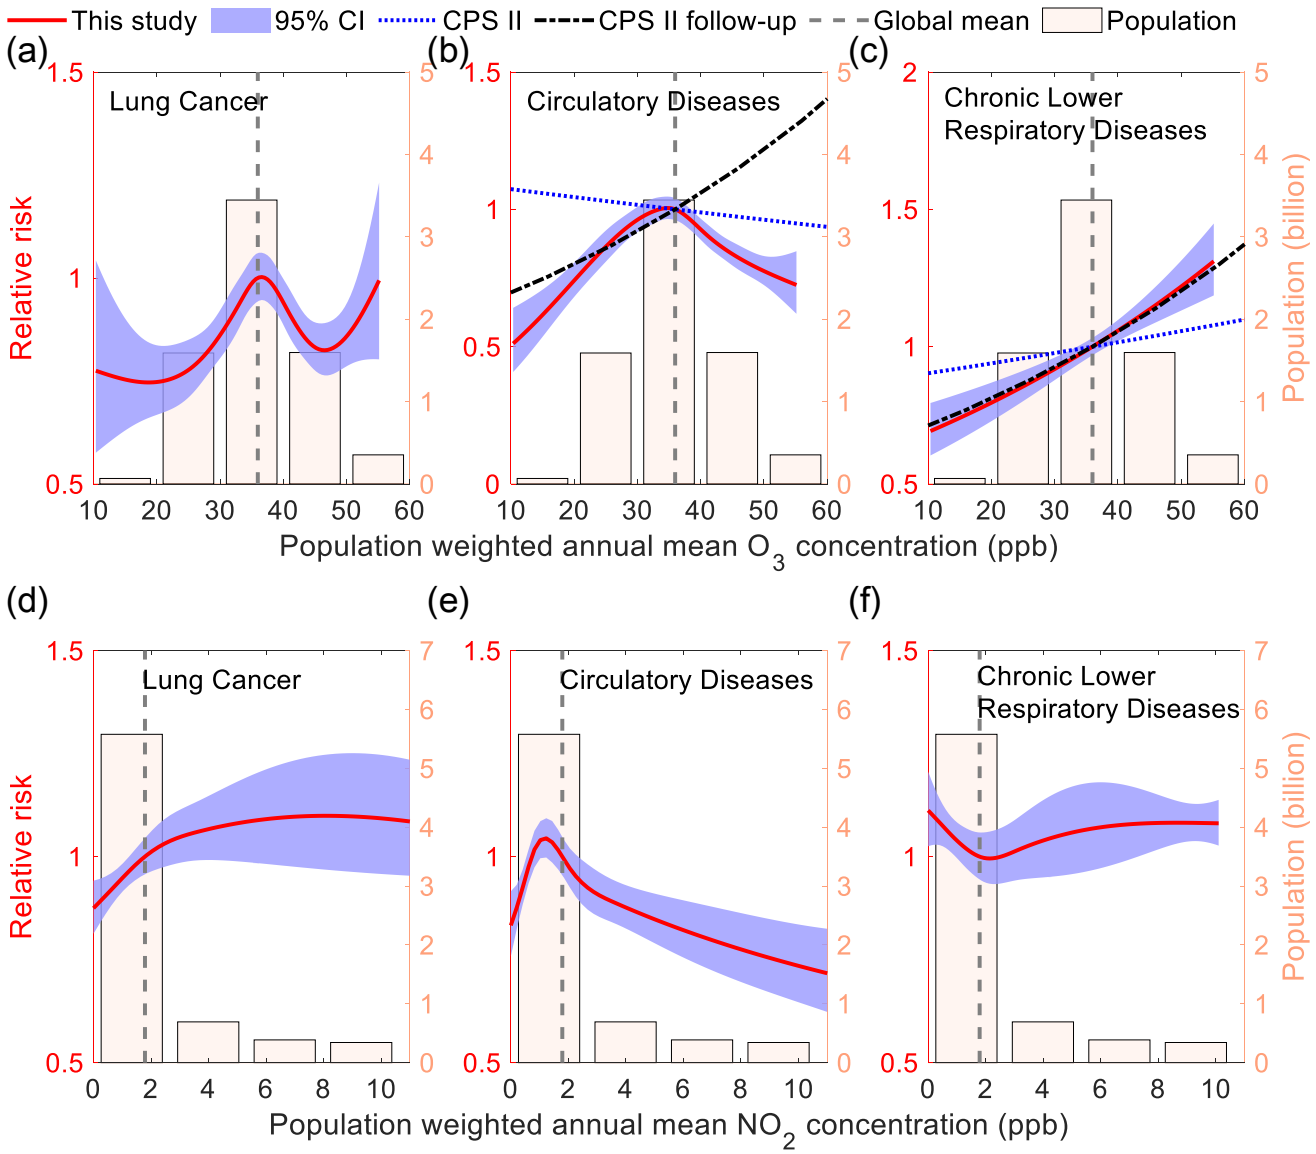
T_{avg}: Averaged temperature;
GE65: Fraction of population (>65 years old)
BMI30: Body mass index over 30 years old
SMK: Smoking prevalence

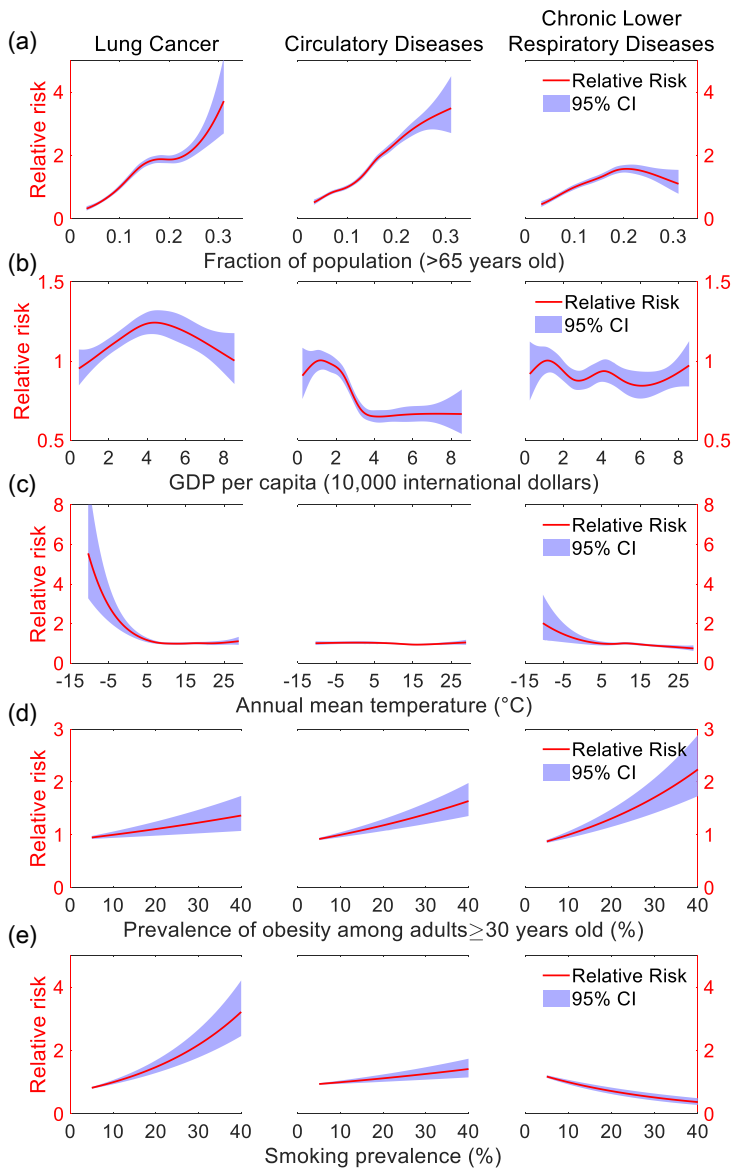
Cubic spline basis was used for all the smooth terms (f) except BMI and SMK, which utilized linear relation due to the relatively low data quality

Relative risk – $PM_{2.5}$



Relative risk – $PM_{2.5}$





Relative risk – $PM_{2.5}$

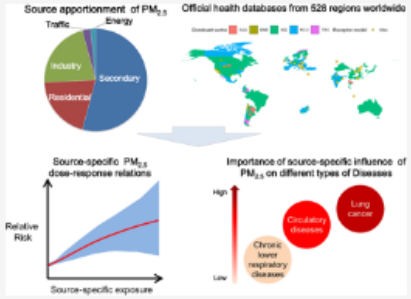
Environmental Science & Technology
pubs.acs.org/est
Article

Ecological Study on Global Health Effects due to Source-Specific Ambient Fine Particulate Matter Exposure

Xiaole Zhang,[#] Xi Chen,[#] Yang Yue, Shuxiao Wang, Bin Zhao, Xinmei Huang, Tiantian Li, Qinghua Sun, and Jing Wang*

Cite This: *Environ. Sci. Technol.* 2023, 57, 1278–1291
Read Online
ACCESS | Metrics & More | Article Recommendations | Supporting Information

ABSTRACT: Ambient air pollution of fine particulate matter with diameters less than 2.5 μm ($PM_{2.5}$) is associated with millions of premature deaths per year, recognized as a leading global health concern. The dose–response relation between ambient $PM_{2.5}$ exposure and mortality risk is the most fundamental information for assessments of the health effects of $PM_{2.5}$. The existing dose–response relations were generally developed based on the assumption of equal contribution to toxicity from various sources. However, the sources of $PM_{2.5}$ may significantly influence health effects. In this study, we conducted an ecological study to investigate the global long-term correlation between source-specific $PM_{2.5}$ exposure and cause-specific mortality risk (SPECM) based on the regional aggregate data of the publically available official health databases from 528 regions worldwide with a total registered population of 3.2 billion. The results provided preliminary epidemiological evidence for differing chronic health effects across various sources. The relative mortality risks of lung cancer and circulatory diseases were closely correlated with the primary emissions from industrial and residential combustion sources. Chronic lower respiratory diseases were mostly associated with the mass concentration of particulate matter.



KEYWORDS: *fine particulate matter, dose–response relation, source apportionment, mortality risk*

数据驱动的风险量化分析与建模

多目标决策

在现实生活和实际工作中，我们遇到的问题**常常会有多个目标**，例如，

- 综合利用水利工程的建设，通常要在适当地点修建一个水坝，并具有下述效益：
  - 形成高水头以便发电、拦蓄洪水以防下游洪涝灾害、水库蓄水位提高后有利上游段的航运等
  - 工程建设也要大量投资、会有淹没损失、需要安置移民
  - 在选择水库库容(即确定坝高)的时候，就应综合考察发电、防洪、淹没(移民)、投资等多个目标



多目标决策问题的特点

多目标决策问题的特点：

□决策问题的目标多于一个

□多目标决策问题的目标间不可公度(Non-commensurable)，即各目标没有统一的衡量标准或计量单位，因而难以进行比较。例如，水利工程建设问题中的发电这一目标可以用年发电量（亿度/年）或装机容量（万千瓦）来描述，而防洪效益只能用下游免遭洪涝灾害的面积（亩）来表征

□各目标间的矛盾性，绝大部分多目标决策问题的各个备选方案在各目标之间存在某种矛盾，即如果采用一种方案去改进某一目标的值，很可能会使另一目标的值变坏。例如，水利工程建设问题，想要提高发电和防洪效益，就要提高水头，增加大坝高度，但是同时也需要增加投资，加大淹没损失和移民数量

主要内容

- 1 线性回归
- 2 离散数据类型
- 3 离散数据建模
- 4 最大似然估计
- 5 广义线性模型
- 6 典型的广义线性模型
- **7 多目标优化问题**

多目标优化问题
Multi-Objective Optimization Problems, MOOP

7.1 多目标优化问题（MOOP）

实际生活中面临的决策问题，往往涉及多个目标

- 修建大坝：提高洪涝灾害防治能力，保护生态环境，改善生活质量等
- 疫情防控：保护生命健康降低感染人数，维持社会正常运行，保障经济发展
- 汽车生产：最大化燃油效率，加速性能，最小化价格

这些目标之间通常是相互矛盾的（ conflicting objectives ），我们需要在不同的目标之间进行权衡，从而做出最终的决策。

如果所面对的决策问题，虽然具有多个目标，但是目标之间不存在矛盾竞争关系，那么我们可以称之为**退化的多目标优化问题**。在此情况下，不同目标可以同时达到最优解，因此，不需要将其转化为多目标优化问题进行求解。

7.1 多目标优化问题（MOOP）

多目标优化问题（Multi-Objective Optimization Problems, MOOP）：

- 多目标优化需要**同时优化两个或者两个以上的目标函数**，且不能显式地平衡它们，即**不存在同时优化每个目标函数的解**
- 多目标优化的结果是**一组解集（set of solutions）**，其中的每个解都是在不同目标之间折衷的结果，每个解相对其他解都有其独特的优势

7.1 多目标优化问题（MOOP）

- 多目标优化问题的数学表达

$$\min_{\boldsymbol{x}} \left\{ f_1(\boldsymbol{x}),\quad f_2(\boldsymbol{x}),\quad \ldots,\quad f_M(\boldsymbol{x}) \right\}$$

决策变量

目标函数集

$$\text{Subject to}\quad g_j(\boldsymbol{x}) \le 0,\ j = 1,2,\ldots,J$$

$$h_k(\boldsymbol{x}) = 0,\ k = 1,2,\ldots,K$$

约束条件

多目标优化问题是由的三要素（**决策变量**，**目标函数**，**约束条件**）

7.1 多目标优化问题（MOOP）

◘ 多目标优化问题的数学表达

$$\min_{\boldsymbol{x}} \left\{ f_1(\boldsymbol{x}),\quad f_2(\boldsymbol{x}),\quad \ldots,\quad f_M(\boldsymbol{x}) \right\}$$

决策变量

目标函数集

$$\text{Subject to}\quad g_j(\boldsymbol{x}) \le 0,\ j = 1,2,\ldots,J$$

$$h_k(\boldsymbol{x}) = 0,\ k = 1,2,\ldots,K$$

约束条件

多目标优化问题是由的三要素（**决策变量**，**目标函数**，**约束条件**）

- **决策变量：** $\boldsymbol{x}=\{x_1, x_2, \ldots, x_N\}^T$ 是N维决策变量，决策变量是可以被认为控制的，并能对指标属性产生影响，**决策变量的不同取值对应不同决策方案**；

7.1 多目标优化问题（MOOP）

◘ 多目标优化问题的数学表达

$$\min_{\boldsymbol{x}} \left\{ f_1(\boldsymbol{x}),\quad f_2(\boldsymbol{x}),\quad \ldots,\quad f_M(\boldsymbol{x}) \right\}$$

决策变量

目标函数集

$$\text{Subject to}\quad g_j(\boldsymbol{x}) \le 0,\ j = 1,2,\ldots,J$$

$$h_k(\boldsymbol{x}) = 0,\ k = 1,2,\ldots,K$$

约束条件

多目标优化问题是由的三要素（**决策变量**，**目标函数**，**约束条件**）

- **目标函数：** 是决策指标的数学表达，为连续函数。决策者希望所有指标同时达到最优，但在现实中一般无法满足。所有目标函数构成了多目标优化问题的目标函数集合（向量）

7.1 多目标优化问题（MOOP）

◘ 多目标优化问题的数学表达

$$\min_{\boldsymbol{x}} \left\{ f_1(\boldsymbol{x}),\quad f_2(\boldsymbol{x}),\quad \ldots,\quad f_M(\boldsymbol{x}) \right\}$$

决策变量

目标函数集

$$\text{Subject to}\quad g_j(\boldsymbol{x}) \le 0,\ j = 1,2,\ldots,J$$

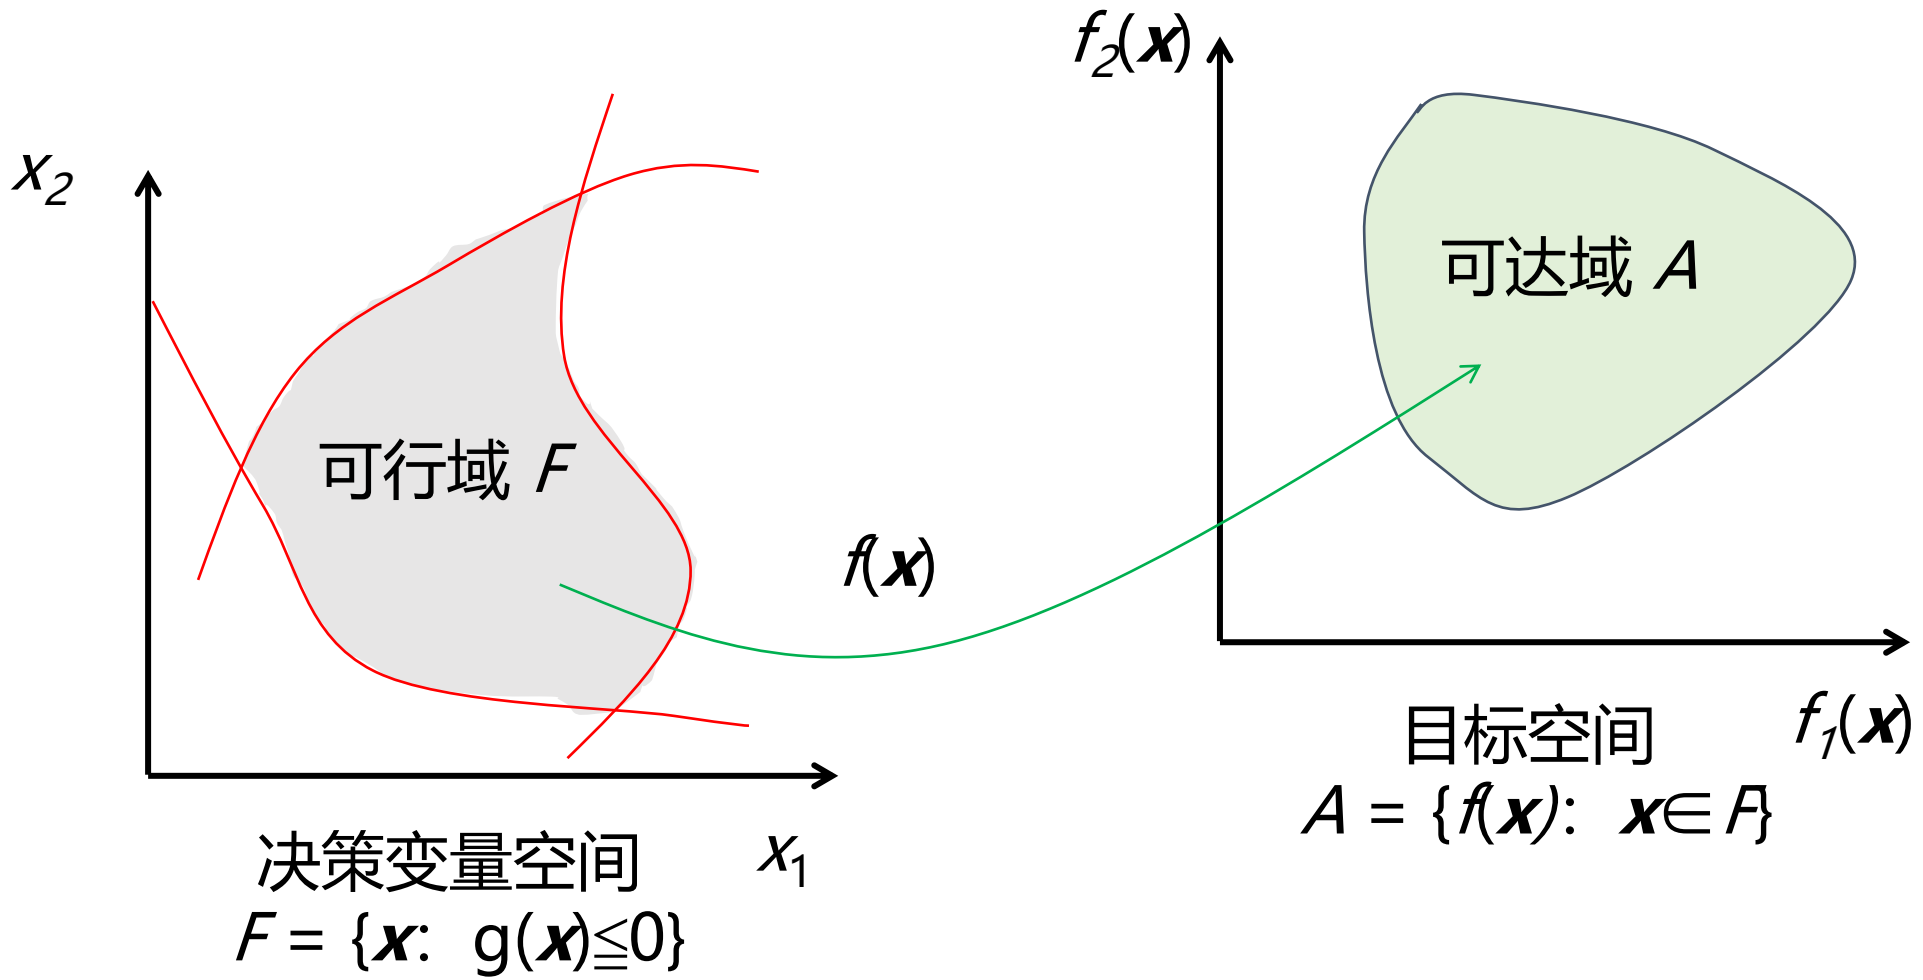
$$h_k(\boldsymbol{x}) = 0,\ k = 1,2,\ldots,K$$

约束条件

多目标优化问题是由的三要素（**决策变量**，**目标函数**，**约束条件**）

- **约束条件：** 为决策变量需要满足的限制条件，使用还有等式和不等式的约束函数来表示，**满足所有所有约束条件的一组决策变量可以称之为一个“可行解”**，多目标优化问题中所有可行解构成了整个可行域。

7.1 多目标优化问题（MOOP）



7.2 占优性（Dominance）

在单目标优化问题中，通过比较目标函数值可以确定一种决策方案是否比另一种方案优越，因此最优解只有一个，然而

- **多目标优化问题中**，目标函数集合组成一个向量，各目标之间相互制约，试图改善一个目标往往以损失其他目标为代价，**无法直接比较不同方案之间的优劣**

- 多目标优化问题中，一般采用**占优性（Dominance）**的概念来衡量一组解的适用性

7.2 占优性（Dominance）

占优性检验

- 可行域中的两个决策向量$\boldsymbol{a}$，$\boldsymbol{b} \in \boldsymbol{X}$，**$\boldsymbol{a}$占优（dominates）$\boldsymbol{b}$**，当且仅当
  - $\boldsymbol{a}$的**所有目标函数都不劣于**对应的$\boldsymbol{b}$的目标函数
  - $\boldsymbol{a}$**至少有一个目标函数严格优于**对应的$\boldsymbol{b}$的目标函数
- 占优性的数学描述定义为

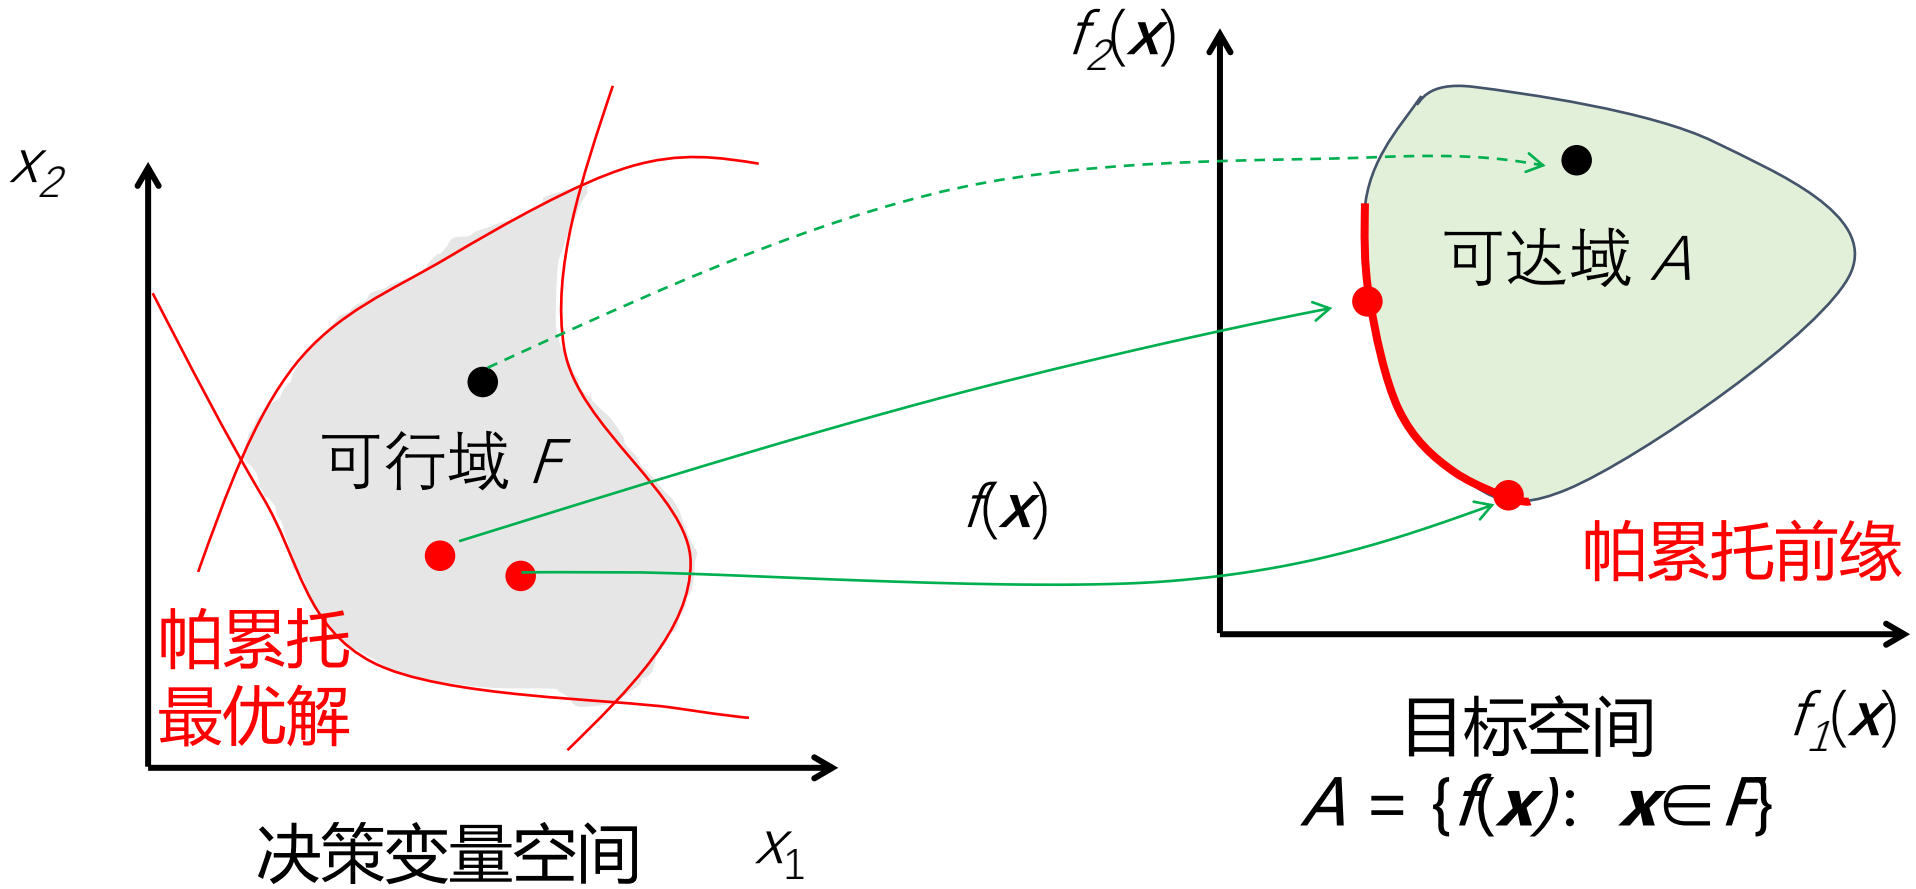
$$\{\forall i \in \{1,2,\ldots,M\}\, f_i(\boldsymbol{a}) \leq f_i(\boldsymbol{b})\} \wedge \{\exists i \in \{1,2,\ldots,M\}\, f_i(\boldsymbol{a}) < f_i(\boldsymbol{b})\}$$

7.2 占优性（Dominance）

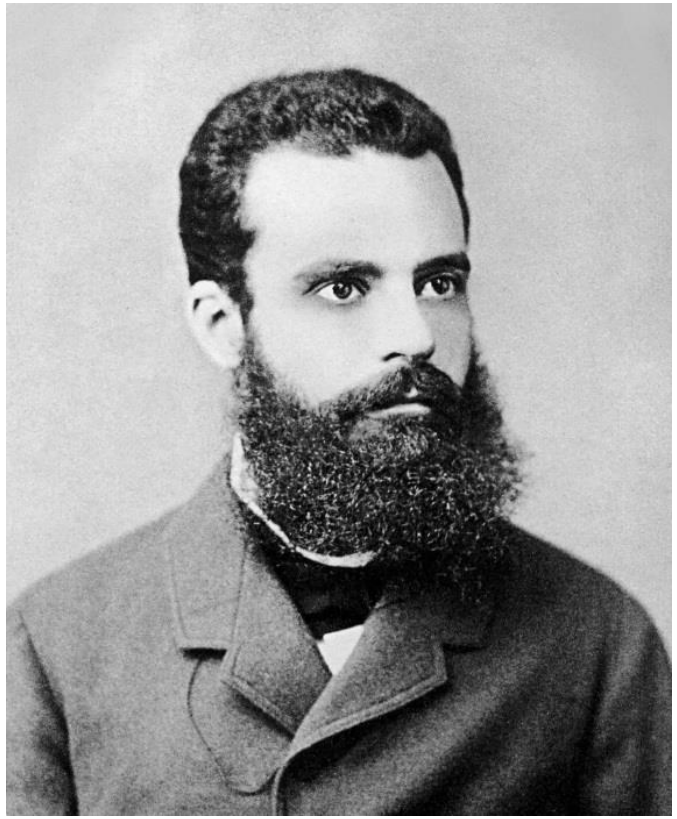
- **帕累托最优解（Pareto Optimal Solution）：**如果存在某个决策向量，在整个可行域中，不存在任何决策向量占优该决策向量，则称该决策向量为**帕累托最优解（Pareto Optimal Solution），**或被称为非支配解(Non-dominated Solution)，或者非劣解（Non-inferior Solution）
- **帕累托最优解集合（Pareto Optimal Set）：**可行域中所有帕累托最优解组成的集合
- **帕累托前缘（Pareto Front）：**所有帕累托最优解对应的目标函数构成了多目标优化问题的帕累托前缘(Pareto Front)，即将帕累托最优解集合投射到目标函数空间，所组成的边界。

7.2 占优性（Dominance）

多目标最优问题的目标是寻找所有逼近帕累托前缘的解，即寻找所有帕累托最优解



7.2 占优性（Dominance）



Vilfredo Pareto
维尔弗雷多·帕累托
(1848年7月15日 - 1923年8月19日)

意大利经济学家、社会学家

- 帕累托最优（Pareto Optimality）；
- Pareto principle，也被称为 80/20 法则、关键少数法则、八二法则

7.3 多目标最优问题的求解方法

- 标量化求解策略（Scalarization）
  - **加权求和法（weighted sum）**
  - **epsilon约束求解方法（epsilon-constraint）**
  - Compromise programming
  - …

7.3 标量化求解策略（Scalarization）

□标量化求解策略（Scalarization）：将多目标优化问题转化为一组单目标优化问题

□参数化搜索（Parametric sweep）：利用一组参数$\{\boldsymbol{p}_1, \boldsymbol{p}_2, \ldots, \boldsymbol{p}_{Np}\}$，每一个参数都将多目标问题转化为唯一的单目标优化子问题，可以寻找到帕累托前缘（Pareto Front）上的Np个点。

可采用的方法如：

✓ 改变每一个目标函数的重要性

✓ 其他系统化的搜索方案

7.3 标量化求解策略（Scalarization）

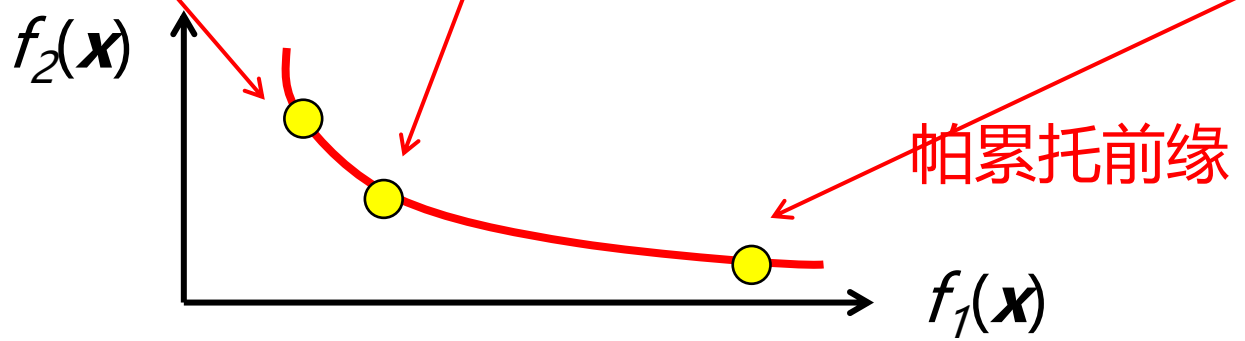
$$\{\boldsymbol{p}_1,\ \boldsymbol{p}_2,\ \ldots,\ \boldsymbol{p}_{Np}\}$$

$$\min_{\boldsymbol{x}} J_{p_1}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_1}(\boldsymbol{x}) \le 0,\ h_{p_1}(\boldsymbol{x}) = 0$$

$$\min_{\boldsymbol{x}} J_{p_2}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_2}(\boldsymbol{x}) \le 0,\ h_{p_2}(\boldsymbol{x}) = 0$$

…

$$\min_{\boldsymbol{x}} J_{p_{Np}}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_{Np}}(\boldsymbol{x}) \le 0,\ h_{p_{Np}}(\boldsymbol{x}) = 0$$



7.3 标量化求解策略（Scalarization）

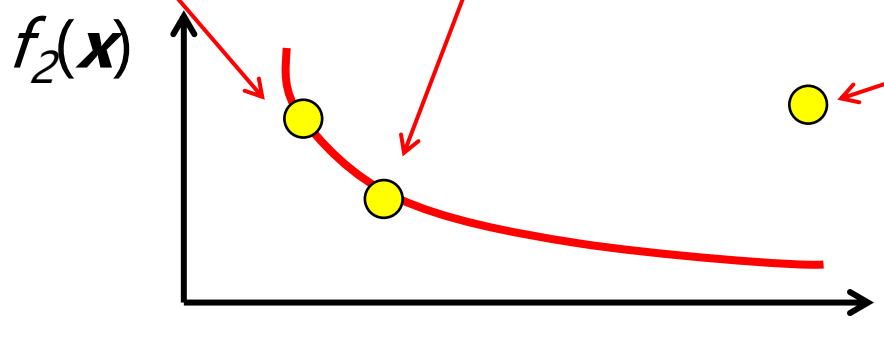
$$\{\boldsymbol{p}_1,\ \boldsymbol{p}_2,\ \ldots,\ \boldsymbol{p}_{Np}\}$$

$$\min_{\boldsymbol{x}} J_{p_1}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_1}(\boldsymbol{x}) \le 0,\ h_{p_1}(\boldsymbol{x}) = 0$$

$$\min_{\boldsymbol{x}} J_{p_2}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_2}(\boldsymbol{x}) \le 0,\ h_{p_2}(\boldsymbol{x}) = 0$$

…

$$\min_{\boldsymbol{x}} J_{p_{Np}}(\boldsymbol{x}) \quad \text{s.t.} \quad g_{p_{Np}}(\boldsymbol{x}) \le 0,\ h_{p_{Np}}(\boldsymbol{x}) = 0$$



帕累托前缘

单目标子问题可能求解失败，导致占优解的出现

7.3.1 加权求和法（weighted sum）

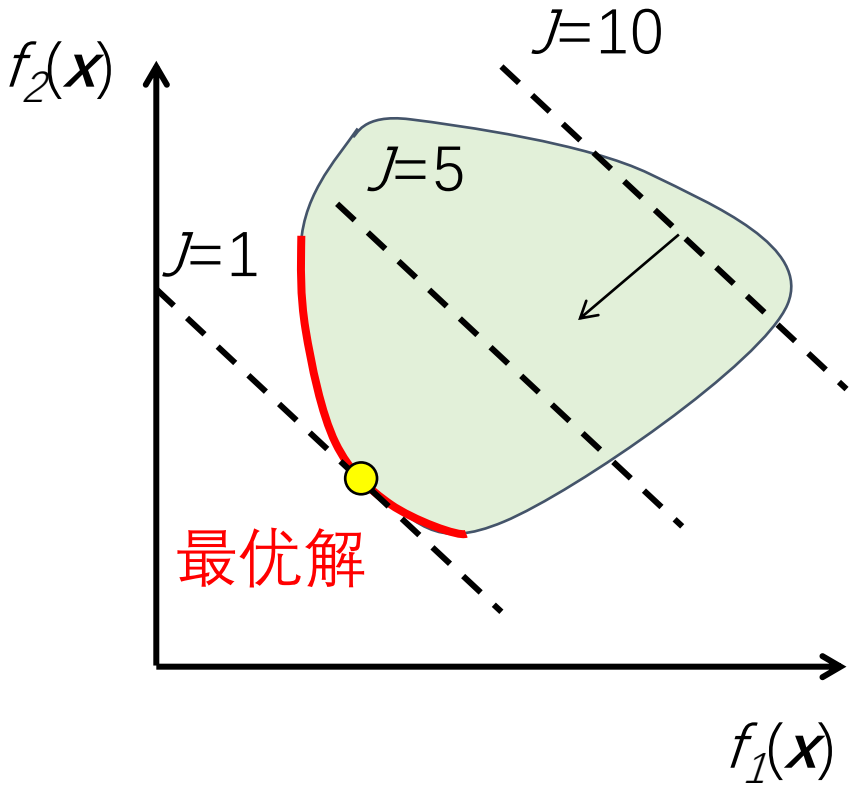
口加权求和法（Weighted sum）：通过各个目标函数的线性组合来构建一个集成的新目标函数$J(\boldsymbol{x})$，因此也被称为线性加权求和法，是最基础和简单的标量化方法

每一种权重w对应一组具有相同斜率的平行线，代表新目标函数的等值线

$$\min_{\boldsymbol{x}} \ J(\boldsymbol{x}) = w_1 f_1(\boldsymbol{x}) + w_2 f_2(\boldsymbol{x})$$

Subject to $\quad g(\boldsymbol{x}) \le 0$

$$h(\boldsymbol{x}) = 0$$



7.3.1 加权求和法（weighted sum）

口加权求和法（Weighted sum）：通过各个目标函数的线性组合来构建一个集成的新目标函数$J(\boldsymbol{x})$，因此也被称为线性加权求和法，是最基础和简单的标量化方法

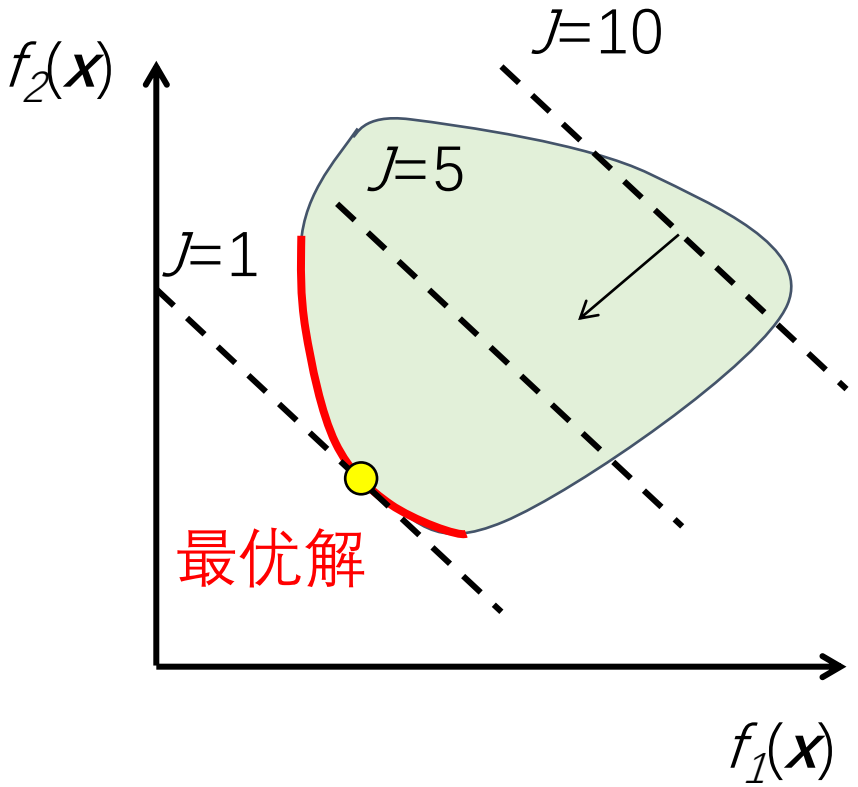
对于权重，通常采用归一化策略，即

$$0 \le w_i \le 1, \sum_{i=1}^{N} w_i = 1$$ 自由度为N-1

$$\min_{\boldsymbol{x}} \; J(\boldsymbol{x}) = w_1 f_1(\boldsymbol{x}) + w_2 f_2(\boldsymbol{x})$$

Subject to $g(\boldsymbol{x}) \le 0$

$h(\boldsymbol{x}) = 0$



加权求和法（weighted sum）

口加权求和法（Weighted sum）：通过各个目标函数的线性组合来构建一个集成的新目标函数$J(\boldsymbol{x})$，因此也被称为线性加权求和法，是最基础和简单的标量化方法

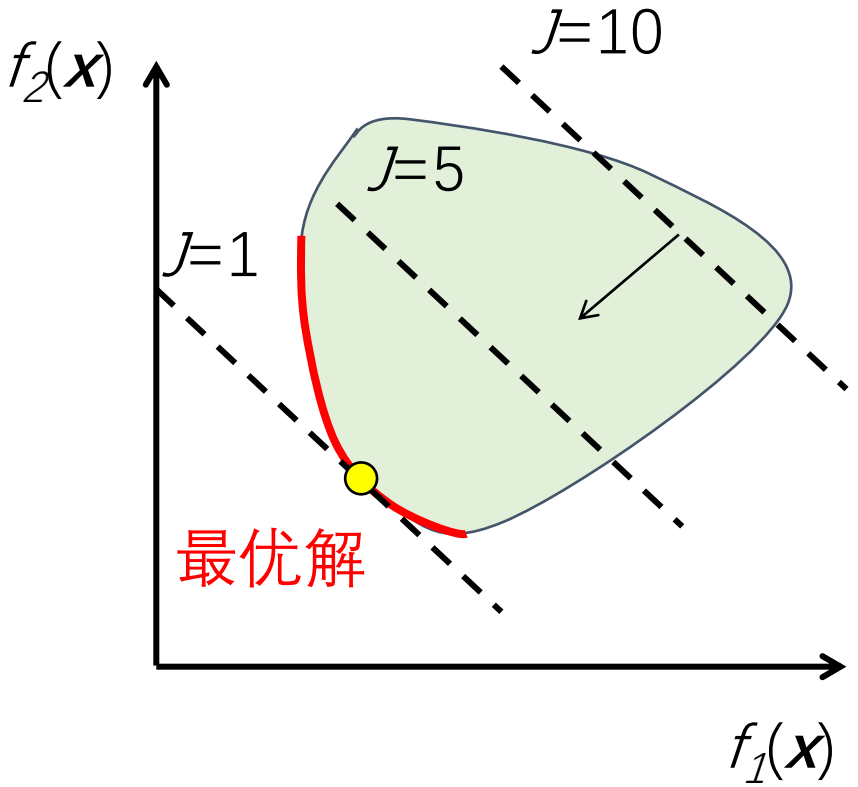
这里的权重组合就是之前提到的变换参数$\boldsymbol{p}$

$$\boldsymbol{w} = (w_1, w_2, \ldots, w_N)^{\mathrm{T}}$$

$$\min_{\boldsymbol{x}} \; J(\boldsymbol{x}) = w_1 f_1(\boldsymbol{x}) + w_2 f_2(\boldsymbol{x})$$

Subject to $\quad g(\boldsymbol{x}) \le 0$

$$h(\boldsymbol{x}) = 0$$



7.3.1 加权求和法（weighted sum）

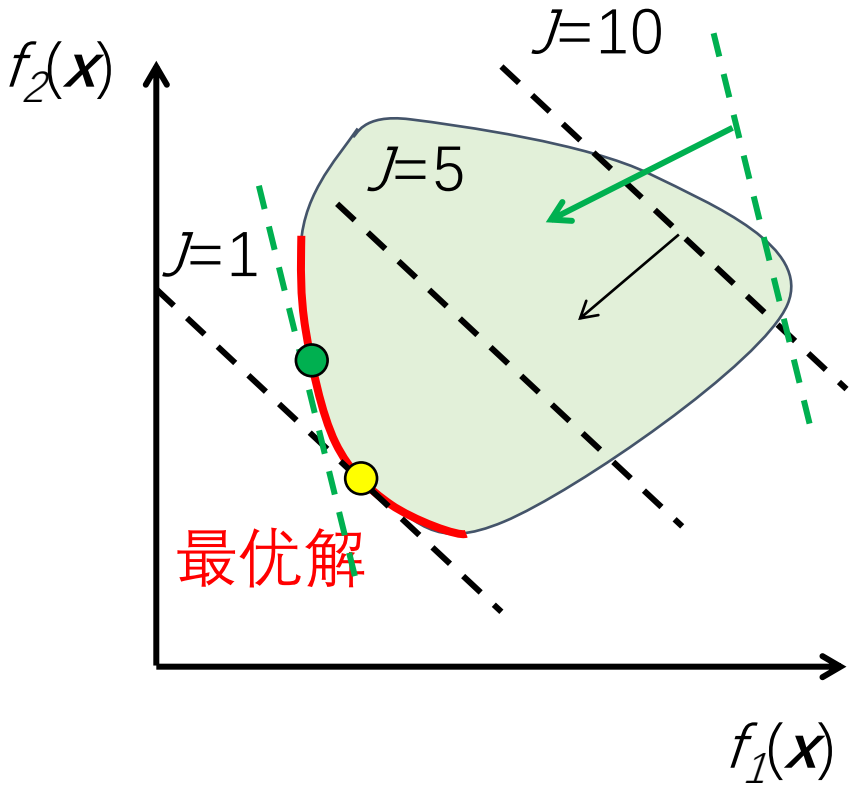
口加权求和法（Weighted sum）：通过各个目标函数的线性组合来构建一个集成的新目标函数$J(\boldsymbol{x})$，因此也被称为线性加权求和法，是最基础和简单的标量化方法

使用不同权重组合，构成新的单目标最优化子问题，通过最优化子问题，获得帕累托前缘上不同的点

$$\min_{\boldsymbol{x}} \; J(\boldsymbol{x}) = w_1 f_1(\boldsymbol{x}) + w_2 f_2(\boldsymbol{x})$$

Subject to $\quad g(\boldsymbol{x}) \le 0$

$$h(\boldsymbol{x}) = 0$$

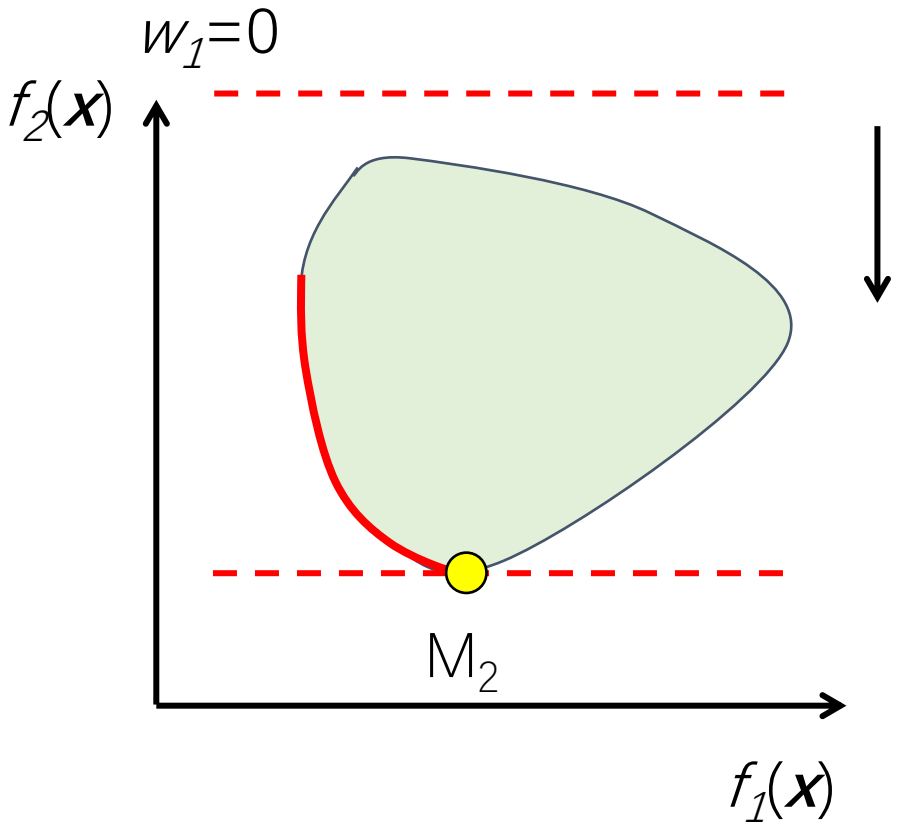


7.3.1 加权求和法（weighted sum）

- 以双目标问题为例，当使用加权求和方法时，如果将**目标函数$f_1(x)$的权重设为0，$f_2(x)$的权重即为1**

$$\min_{x} \; J(x) = 0 \cdot f_1(x) + 1 \cdot f_2(x)$$
$$\text{Subject to} \quad g(x) \le 0$$
$$h(x) = 0$$

- 此时，获得的帕累托前缘上的点（M_2）被称为一个**锚点（anchor point）**

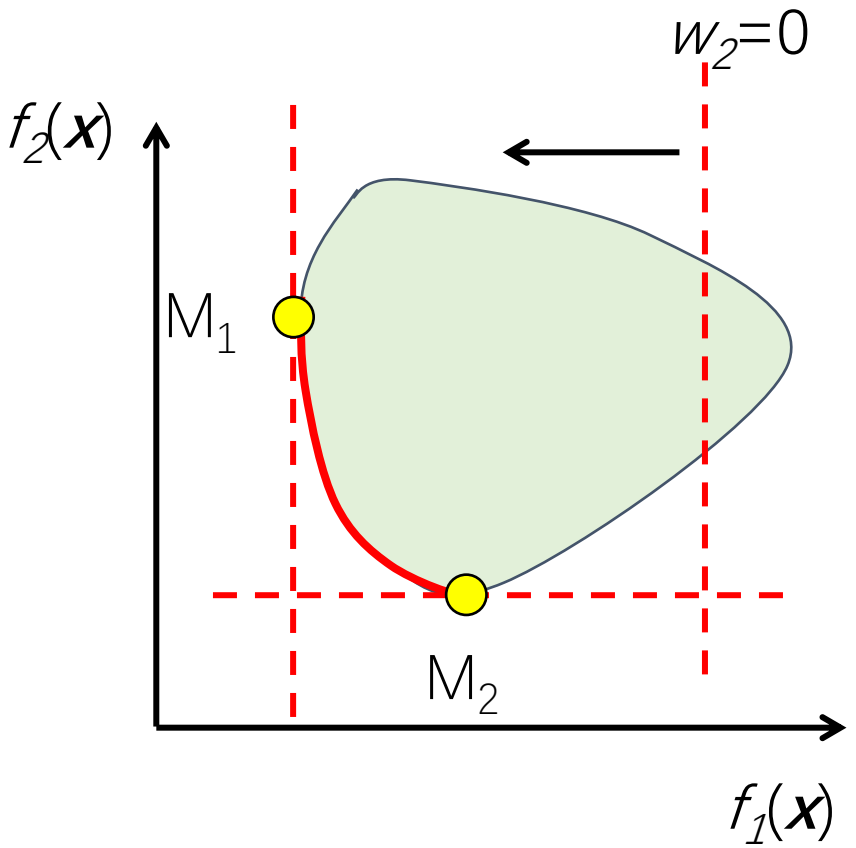


7.3.1 加权求和法（weighted sum）

- 以双目标问题为例，当使用加权求和方法时，如果将**目标函数$f_1(x)$的权重设为1，$f_2(x)$的权重即为0**

$$\min_{x} \ J(x) = 1 \cdot f_1(x) + 0 \cdot f_2(x)$$
$$\text{Subject to} \quad g(x) \le 0$$
$$h(x) = 0$$

- 此时，获得的帕累托前缘上的点（M_1）**为另一个锚点**

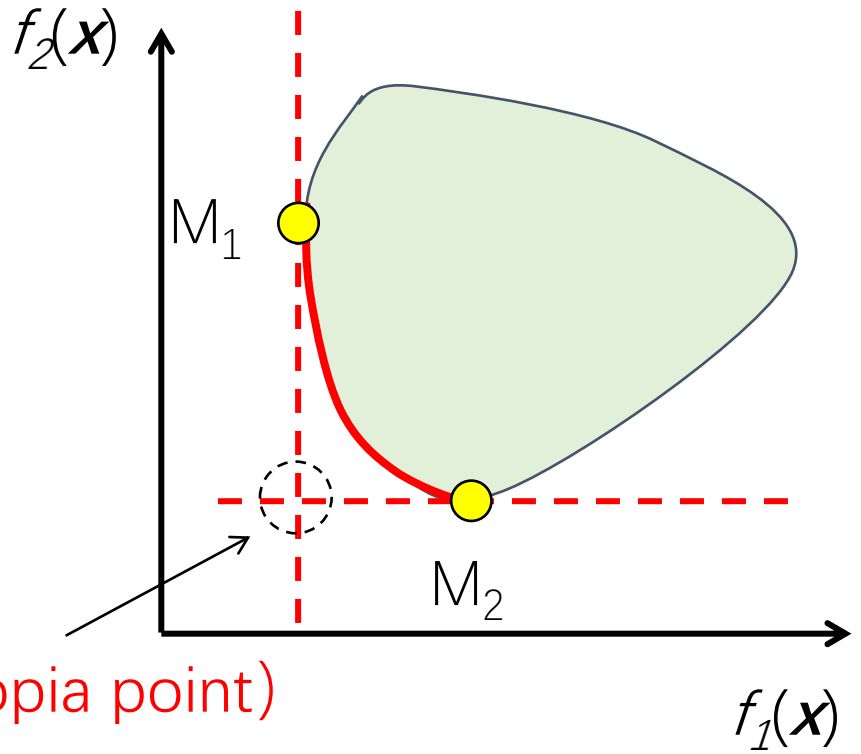


7.3.1 加权求和法（weighted sum）

- w_1=0：一组平行于f_1的等值线，获得锚点M_2；
- w_2=0：一组平行于f_2的等值线，获得锚点M_1；

这两条线的交点被称为理想点（Utopia point）

- 该点可使**目标函数同时达到最优解**，但是**该点一般不在可达域内**，即在可行域内，不存在这样的点，通过目标函数投影后位于理想点位置
- 对于**退化多目标优化问题**，目标函数可以同时达到最优，**此时理想点存在**，但是退化多目标优化问题一般不需要采用复杂求解方法

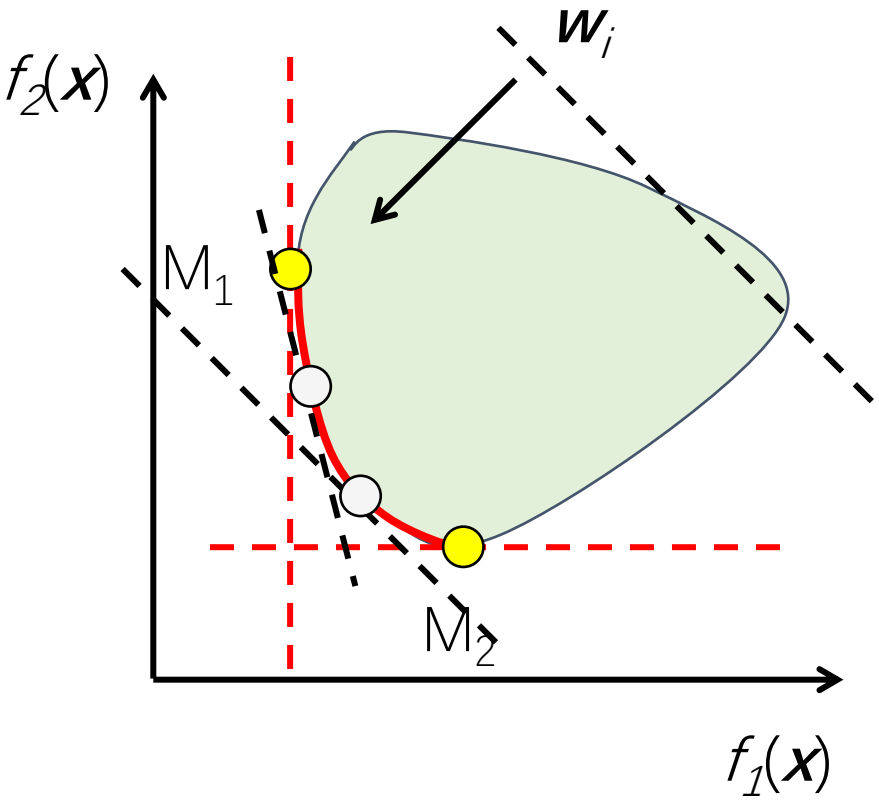


理想点（Utopia point）

7.3.1 加权求和法（weighted sum）

- w_1=0：一组平行于f_1的等值线，获得锚点M_2；
- w_2=0：一组平行于f_2的等值线，获得锚点M_1；

- 对于其他任意的权重组合w_i 产生的帕累托前缘上的点都位于锚点M1与M2之间



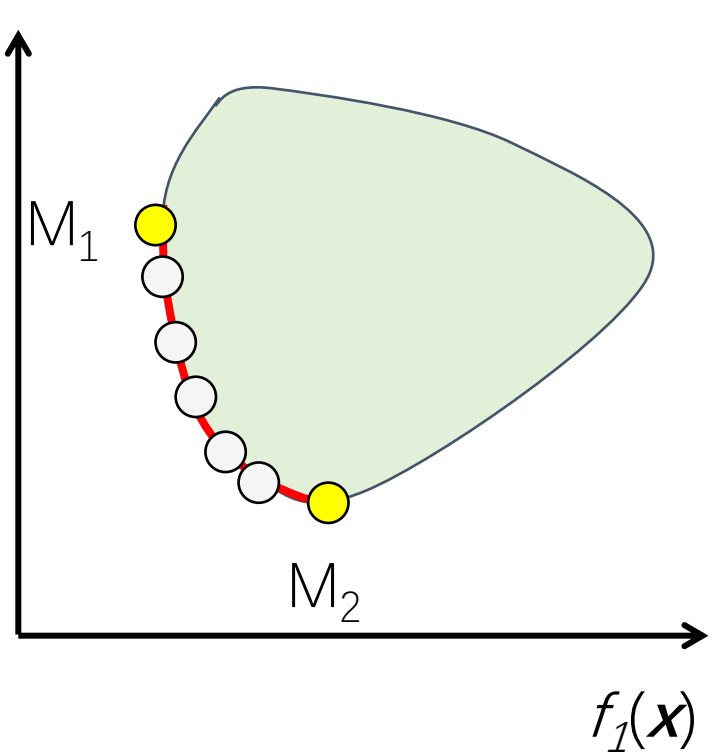
7.3.1 加权求和法（weighted sum）

- w_1=0：一组平行于f_1的等值线，获得锚点M_2；
- w_2=0：一组平行于f_2的等值线，获得锚点M_1；

- 对于其他任意的权重组合$\boldsymbol{w}_i$ 产生的帕累托前缘上的点都位于锚点M1与M2之间

- 通过系统化地改变权重组合可以**获得帕累托前缘上的多个点**

$$0 \le w_i \le 1, \sum_{i=1}^{N} w_i = 1$$



7.3.1 加权求和法（weighted sum）

口加权求和法优势

- **概念上简单，**容易理解；
- **构建方式简单，**保持线性，易于实现。

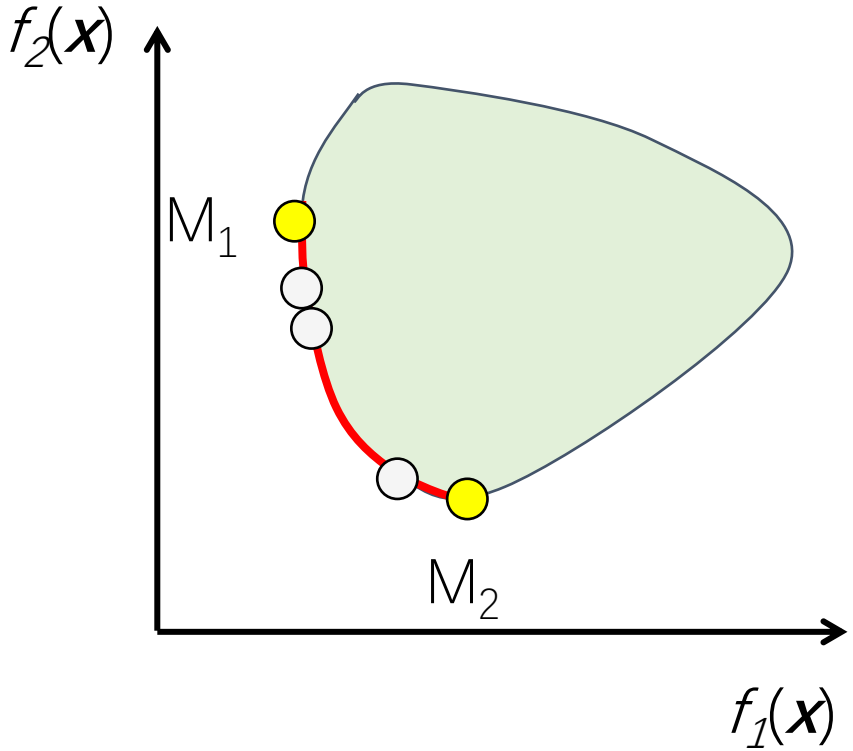
口加权求和法缺点

- 目标函数空间中，获得的帕累托前缘上的点分布可能不均匀；
- 无法获得**非凸区域（non-convex regions）**的帕累托非支配点（帕累托前缘）

7.3.1 加权求和法缺点

目标函数空间中，获得的**帕累托前缘上的点分布可能不均匀**

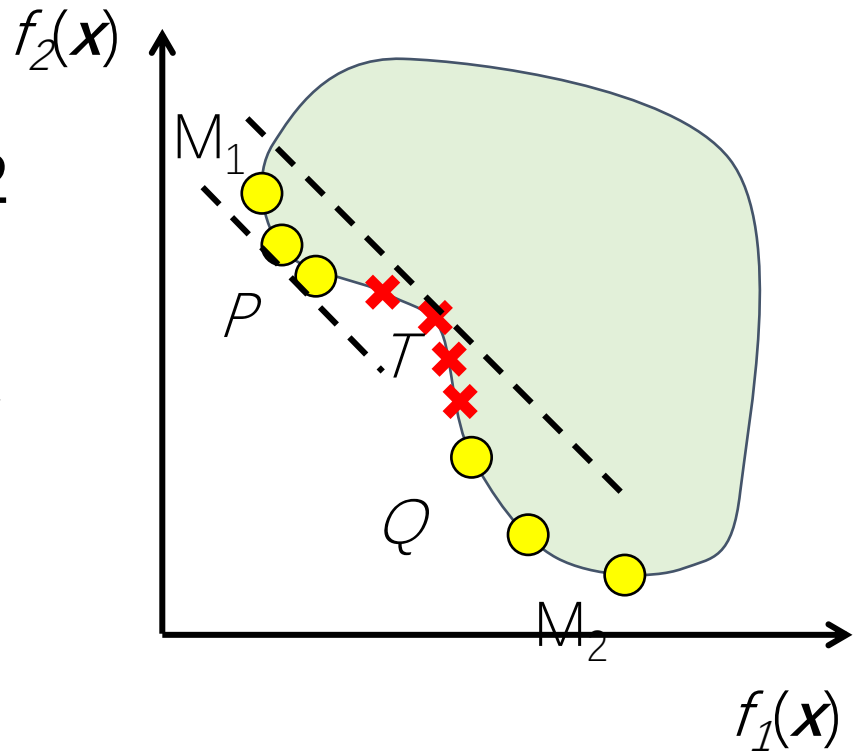
- 在使用加权求和法时，即使我们均匀地变化权重组合，最终在目标函数空间获得的非占优点可能分布不均匀，形成密集和稀疏区域
- 较大的稀疏区域可能无法较好地描述帕累托前缘，需要对针对区域加密权重组合的变化，增加计算量



7.3.1 加权求和法缺点

无法获得**非凸区域**的帕累托非支配点（帕累托前缘）：

- **非凸区域**：*P*和*Q*点的连线不在可达域内；
- 加权求和方法只能获得M1与P之间，以及Q与M2之间的非支配点；
- 无法获取非凸区域P与Q点之间的非支配点，即不存在一种权重组合，可以获得P与Q之间的非支配点。



7.3.2 epsilon约束求解方法 epsilon-constraint

□ **epsilon约束求解方法**：仅保留一个多目标优化问题中的目标函数构成单目标优化问题，将其他目标函数转化为具有边界的约束条件

$$\min_{\boldsymbol{x}} \left\{ f_1(\boldsymbol{x}), \quad f_2(\boldsymbol{x}), \quad \ldots, \quad f_M(\boldsymbol{x}) \right\}$$

Subject to $g_j(\boldsymbol{x}) \le 0, \ j = 1, 2, \ldots, J$

$$h_k(\boldsymbol{x}) = 0, \ k = 1, 2, \ldots, K$$

$$\min_{\boldsymbol{x}} \ f_n(\boldsymbol{x})$$

Subject to $g_j(\boldsymbol{x}) \le 0, \ j = 1, 2, \ldots, J$

$$h_k(\boldsymbol{x}) = 0, \ k = 1, 2, \ldots, K$$

$$f_m(\boldsymbol{x}) \le \varepsilon_m, \ m = 1, 2, \ldots, M \text{ and } m \ne n$$

7.3.2 epsilon约束求解方法 epsilon-constraint

- 以双目标优化问题为例

$$\min_{x} \{f_1(x), f_2(x)\}$$
$$\text{Subject to} \quad g_j(x) \le 0,\ j = 1,2,\ldots,J$$

采用一组ε:

$$\varepsilon_1 < \varepsilon_2 < \ldots < \varepsilon_{Np}$$

构建Np个单目标优化子问题:

$$\min_{x} f_1(x) \quad \text{s.t.} \quad g(x) \le 0,\ f_2(x) \le \varepsilon_1$$

$$\min_{x} f_1(x) \quad \text{s.t.} \quad g(x) \le 0,\ f_2(x) \le \varepsilon_2$$

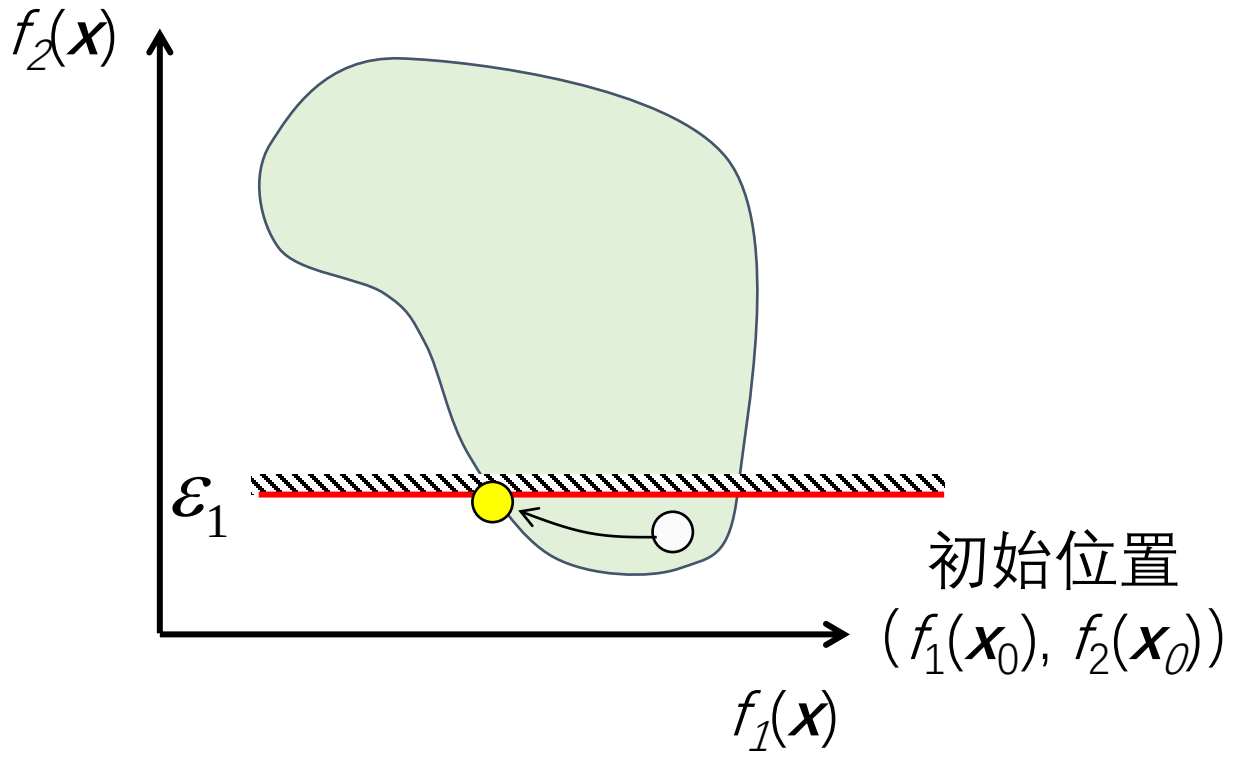
…

$$\min_{x} f_1(x) \quad \text{s.t.} \quad g(x) \le 0,\ f_2(x) \le \varepsilon_{Np}$$

7.3.2 epsilon约束求解方法 epsilon-constraint

- 求解第一个单目标最优化子问题

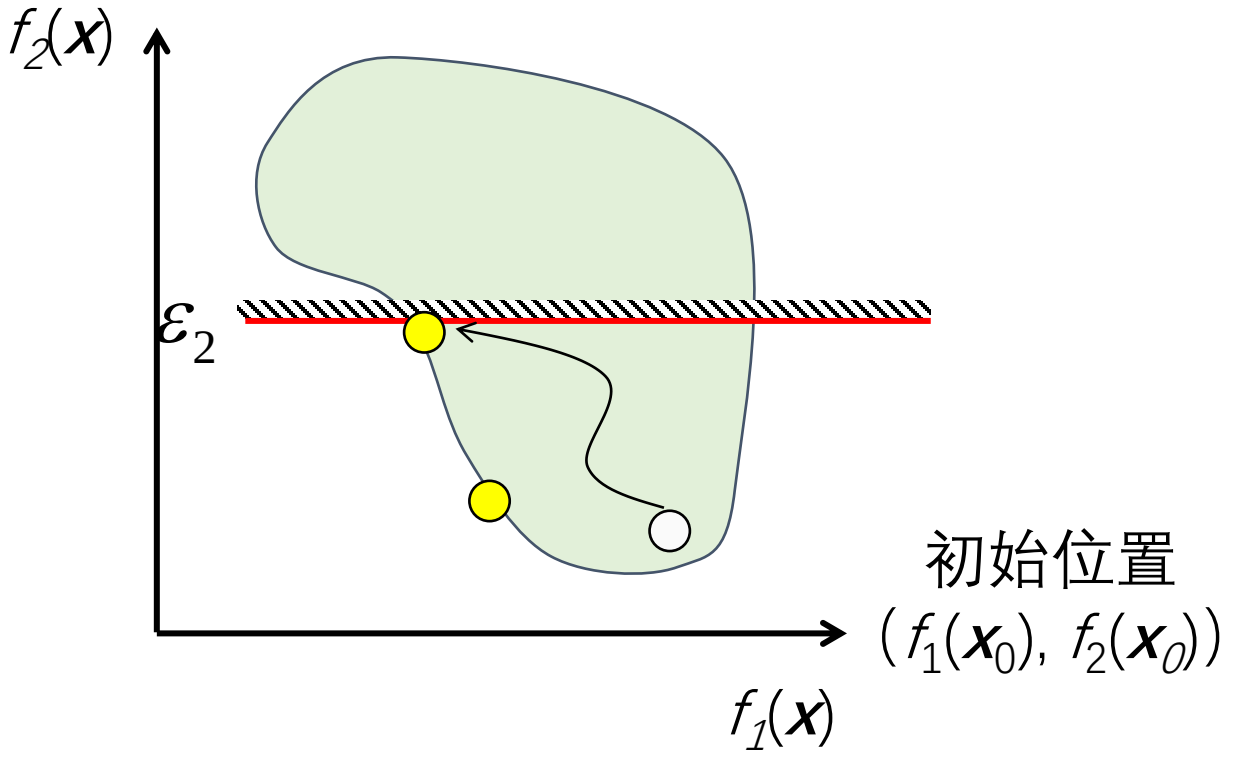
$$\begin{aligned} \min_{x} \quad & f_1(x) \\ \text{s.t.} \quad & g(x) \le 0 \\ & f_2(x) \le \varepsilon_1 \end{aligned}$$



7.3.2 epsilon约束求解方法 epsilon-constraint

- 求解第一个单目标最优化子问题

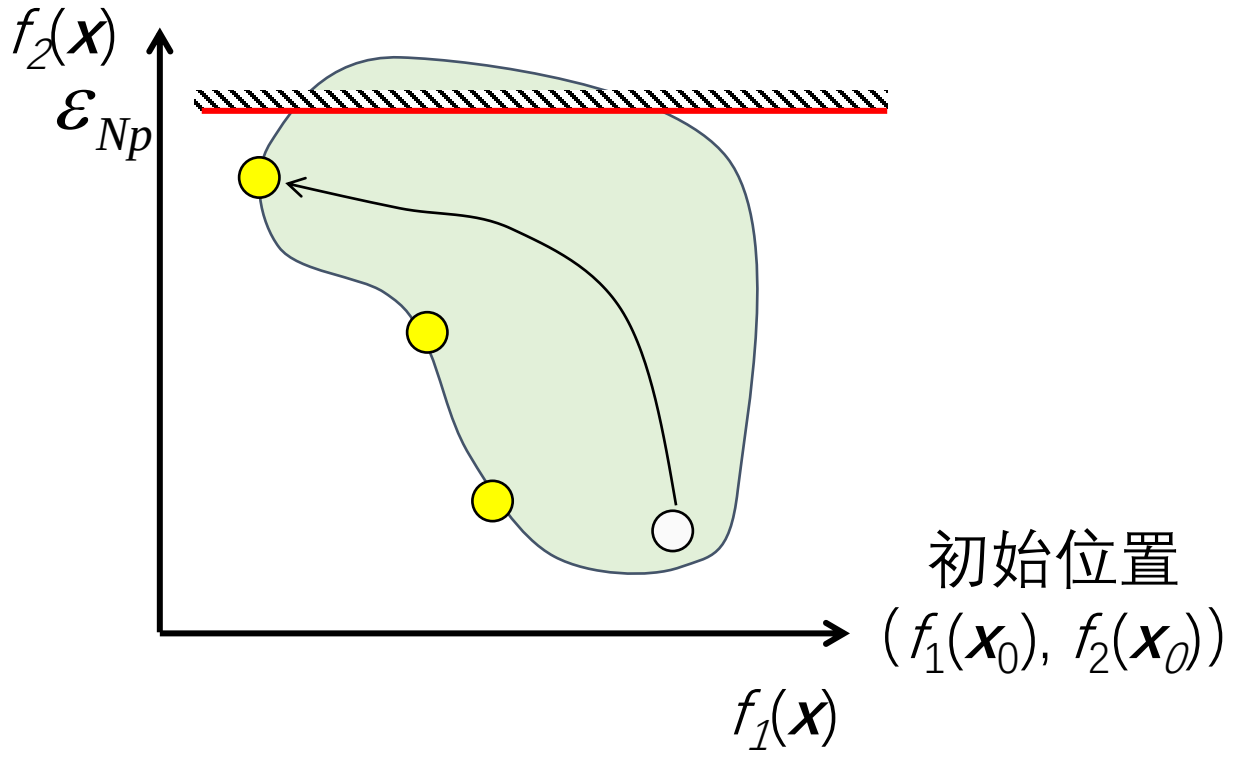
$$\begin{aligned} &\min_{x} \quad f_1(\boldsymbol{x}) \\ \text{s.t.} \quad &g(\boldsymbol{x}) \le 0 \\ &f_2(\boldsymbol{x}) \le \varepsilon_2 \end{aligned}$$



7.3.2 epsilon约束求解方法 epsilon-constraint

- 求解第一个单目标最优化子问题

$$\begin{aligned} &\min_{x} \quad f_1(\boldsymbol{x}) \\ &\text{s.t.} \quad g(\boldsymbol{x}) \le 0 \\ &\qquad f_2(\boldsymbol{x}) \le \varepsilon_{Np} \end{aligned}$$



7.3.2 epsilon约束求解方法 epsilon-constraint

- **epsilon约束求解方法**：仅保留一个多目标优化问题中的目标函数构成单目标优化问题，将其他目标函数转化为具有边界的约束条件
- 通过系统性地改变约束条件的边界，生成帕累托前缘
- 与加权求和法不同，epsilon约束求解方法不是一种集成目标函数方法，因为只保留一个目标函数，并没有对多目标函数进行组合

7.3.2 epsilon约束求解方法 epsilon-constraint

- epsilon约束求解方法的优势
  - 可以较为可靠地获得非凸区域的帕累托前缘；
  - 在目标函数空间中，可以产生较为均与的非支配点，构成帕累托前缘；
  - 保持求解问题的线性性。

作业

决策方法论：数据驱动的风险量化分析与建模部分作业

谢谢！

Thanks !

课程老师：张辉 、陈涛 、张小乐
E-mail：chentao.a@Tsinghua.edu.cn
zhhui@tsinghua.edu.cn
zhangxiaole@tsinghua.edu.cn
助　　教：胡祥敏、张妍、蹇姚宇蝶
E-mail：hxm20@mails.tsinghua.edu.cn
zhang-y21@mails.tsinghua.edu.cn
jyyd23@mails.tsinghua.edu.cn