第五章 求解线性方程组的迭代法

殷东生
yindongsheng@tsinghua.edu.cn

清华大学数学基础教学中心

2025年秋季学期

直接法的优缺点

求解线性方程组 $Ax = b$ 的直接法有下面的两个共同特征：

1. 方法是针对满矩阵设计；
2. 方法的计算量为 $O(n^3)$。

$A=LU$ 矩阵乘法

但在科学和工程计算等导出的线性方程组具有下面的特征：

1. 矩阵 A 的结构很好，大部分元素为零(A 是稀疏阵)；
2. 问题的规模很大，$n = 10^6 \sim 10^{10}$。

$x^{(k+1)} = Bx^{(k)} + f$

求解这种问题一般有两种方法：

1. 针对矩阵的特殊结构设计适合于稀疏矩阵求解的直接法。
2. 用迭代法求解近似解 $\tilde{x}$，在实际计算的时候只需要一定精度的解。

数值求解二维正方形区域上的 Poisson 方程

$$-u_{xx} - u_{yy} = f(x,y).$$

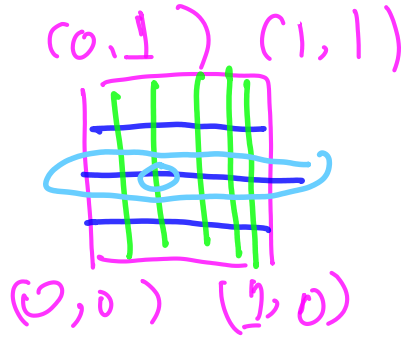

用数值差商代替微商

$$\frac{\partial^2 u}{\partial x^2} = \frac{1}{h^2}[u(x_{i+1},y_j) - 2u(x_i,y_j) + u(x_{i-1},y_j)] + O(h^2),$$

$$\frac{\partial^2 u}{\partial y^2} = \frac{1}{h^2}[u(x_i,y_{j+1}) - 2u(x_i,y_j) + u(x_i,y_{j-1})] + O(h^2)$$

略去 $O(h^2)$ 项，用 $u_{ij} \approx u(x_i,y_j)$，$f_{ij} = f(x_i,y_j)$，则可得对应的差分方程

$$-\frac{u_{i+1,j} - 2u_{ij} + u_{i-1,j}}{h^2} - \frac{u_{i,j+1} - 2u_{ij} + u_{i,j-1}}{h^2} = f_{ij}$$

$$\Rightarrow 4u_{ij} - u_{i+1,j} - u_{i-1,j} - u_{i,j+1} - u_{i,j-1} = h^2 f_{ij},$$

这称为二维 Poisson 方程的五点差分格式。

把网格点按逐行自左至右和自下而上的自然次序排列，

$$\begin{aligned} \boldsymbol{u} &= (u_{11}, u_{21}, \cdots, u_{N1}, \cdots, u_{N2}, \cdots, u_{1N}, \cdots, u_{NN})^T, \\ \boldsymbol{b} &= h^2(f_{11}, \cdots, f_{N1}, f_{12}, \cdots, f_{N2}, \cdots, f_{1N}, \cdots, f_{NN}) \end{aligned}$$

则差分方程可写为

$$A_N \boldsymbol{u} = \boldsymbol{b}.$$

其中

$$A_N = \begin{bmatrix} T_N & -I_N & & & \\ -I_N & T_N & -I_N & & \\ & \ddots & \ddots & \ddots & \\ & & & & -I_N \\ & & & -I_N & T_N \end{bmatrix} \in \mathbb{R}^{N^2 \times N^2}.$$

矩阵 A 的每行最多只有五个非零元，$N \gg 1$ 时是稀疏矩阵。

而 T_N 是三对角矩阵：

$A_N = LU$

L, U 是否保持稀疏性？

$$T_N = \begin{bmatrix} 4 & -1 & & & \\ -1 & 4 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & & & -1 \\ & & & -1 & 4 \end{bmatrix}_{N\times N}$$

$N = 3,$

$$\left[\begin{array}{ccc|ccc|ccc} 4 & -1 & 0 & -1 & & & & & \\ -1 & 4 & -1 & & -1 & & & & \\ & -1 & 4 & & & -1 & & & \\ \hline -1 & & & 4 & -1 & & -1 & & \\ & -1 & & -1 & 4 & -1 & & -1 & \\ & & -1 & & -1 & 4 & & & -1 \\ \hline & & & -1 & & & 4 & -1 & \\ & & & & -1 & & -1 & 4 & -1 \\ & & & & & -1 & & -1 & 4 \end{array}\right]$$

数学家简介 (Poisson)

泊松（*1781*～*1840*）法国数学家、几何学家和物理学家。泊松的科学生涯开始于研究微分方程及其在摆的运动和声学理论中的应用。 他工作的特色是应用数学方法研究各类物理问题，并由此得到数学上的发现。他对积分理论、行星运动理论、热物理、弹性理论、电磁理论、位势理论和概率论都有重要贡献。 他还是*19*世纪概率统计领域里的卓越人物。 他改进了概率论的运用方法，特别是用于统计方面的方法，建立了描述随机现象的一种概率分布–泊松分布。他推广了“大数定律”， 并导出了在概率论与数理方程中有重要应用的泊松积分。

Poisson 证.

大型稀疏矩阵

定义 (稀疏矩阵 Sparse matrix)

一个矩阵 $A \in \mathbb{R}^{n\times m}$ 是稀疏的，若它只有 $\mathcal{O}(\min\{m,n\})$ 或 $\mathcal{O}(n^{1+\gamma})$, $0 \le \gamma < 1$ 个非零元素。

spy(A)

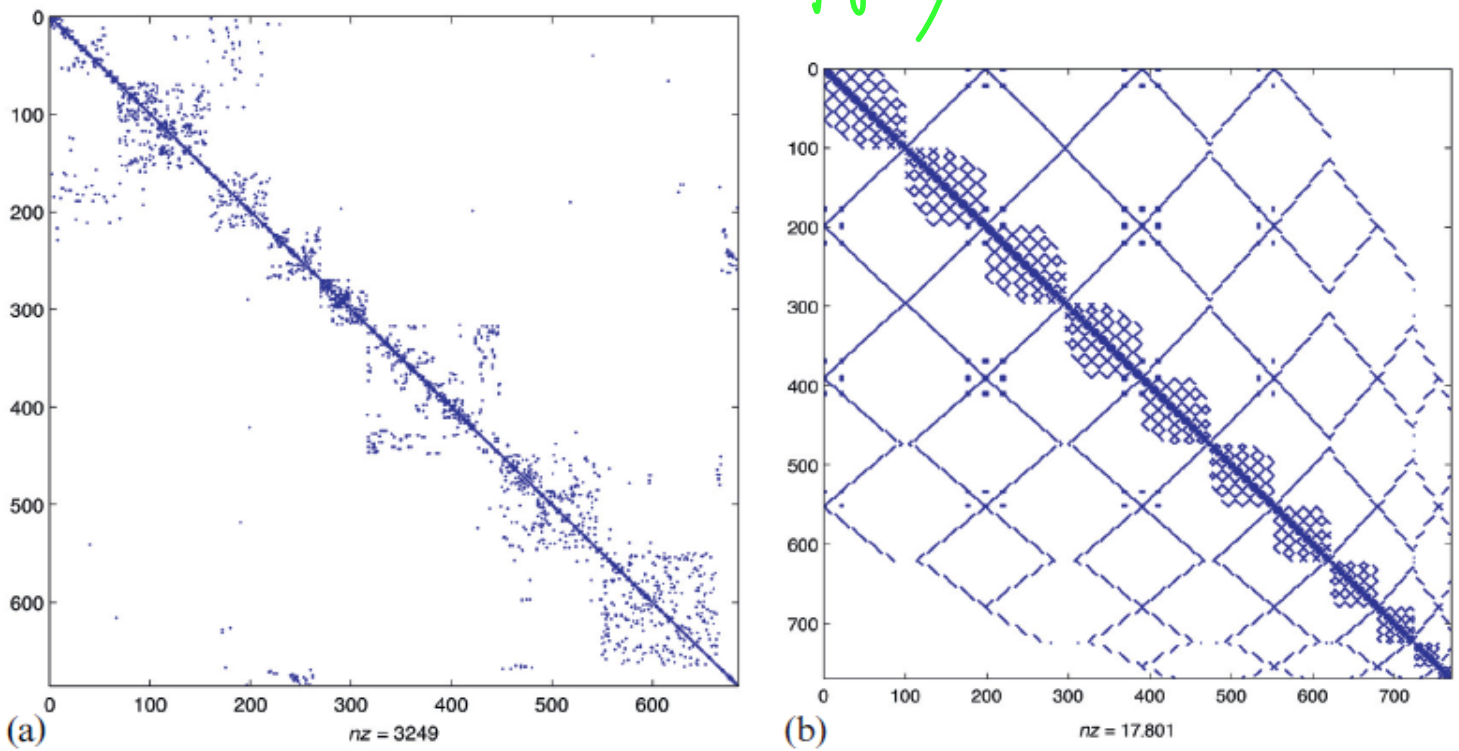

Resource for Sparse Matrices

1. Matrix Market

http://math.nist.gov/MatrixMarket/

2. Florida collection

http://www.cise.ufl.edu/research/sparse/matrices/

3. SPARSKIT, etc.

http://www.cs.umn.edu/ saad/software

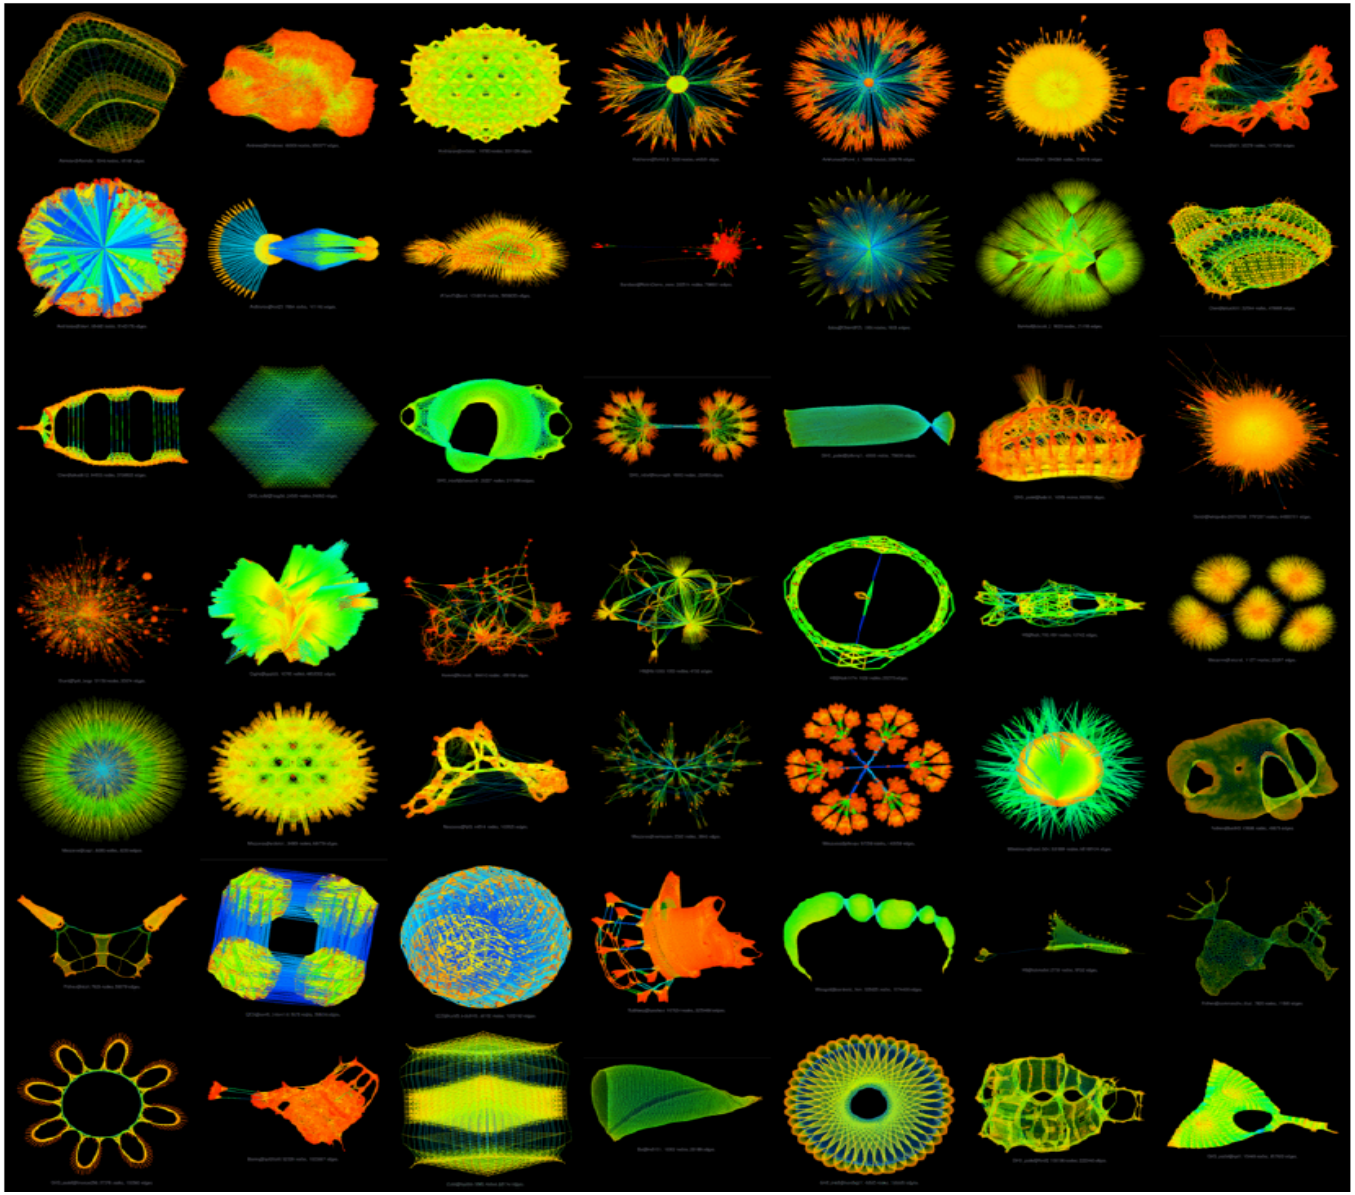

稀疏求解器(Sparse solver)

- 需要直接法的稀疏版本：稀疏运算；
- 最大的问题：填充。

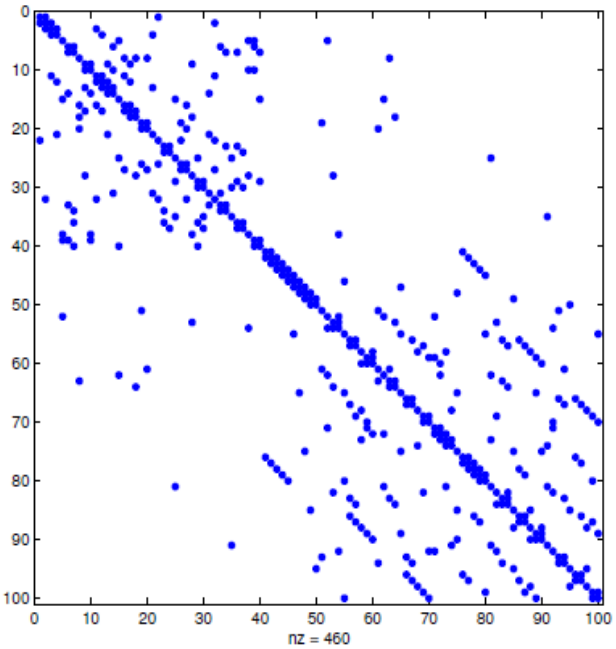

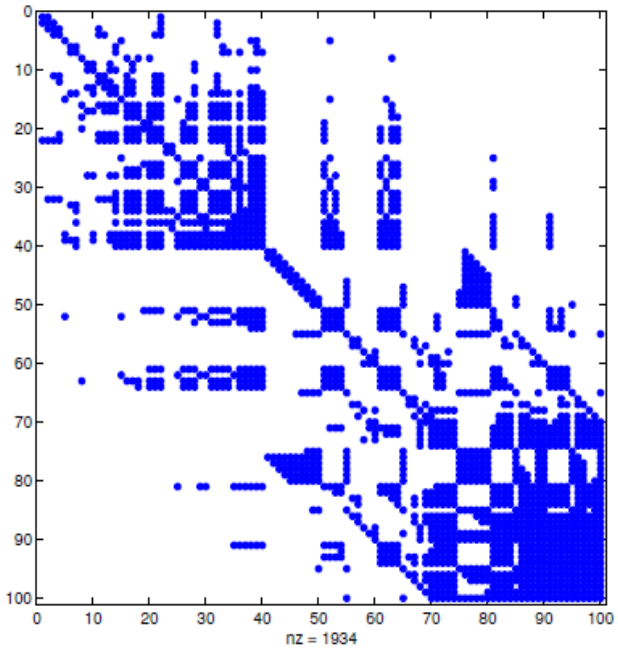

图：稀疏矩阵和LU分解后的矩阵

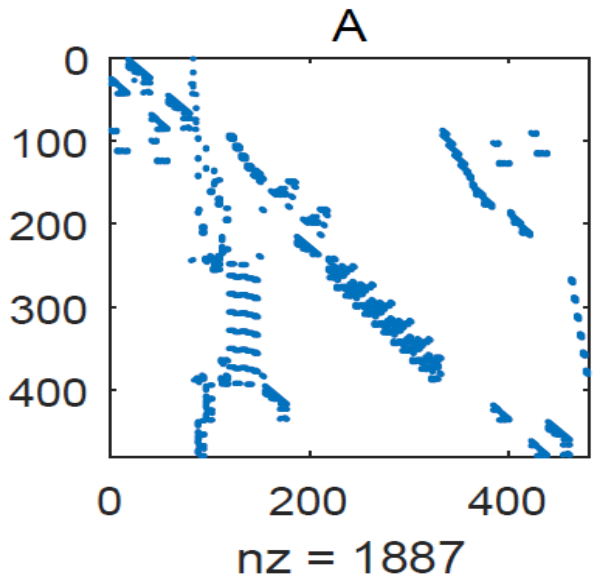
A
0
100
200
300
400
0
200
400
nz = 1887

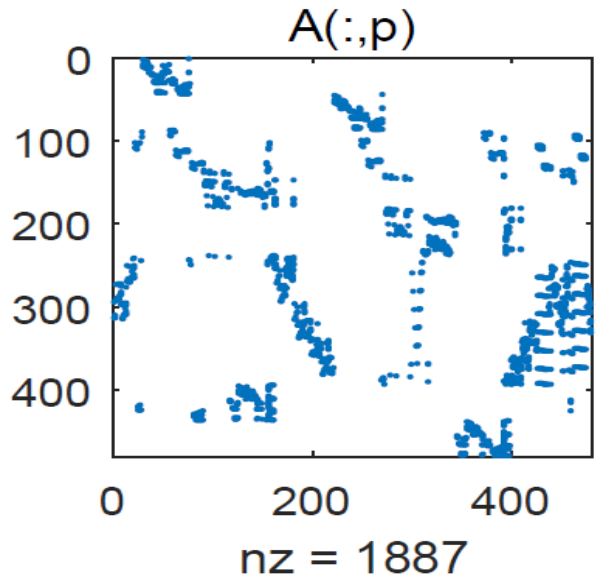
A(:,p)
0
100
200
300
400
0
200
400
nz = 1887

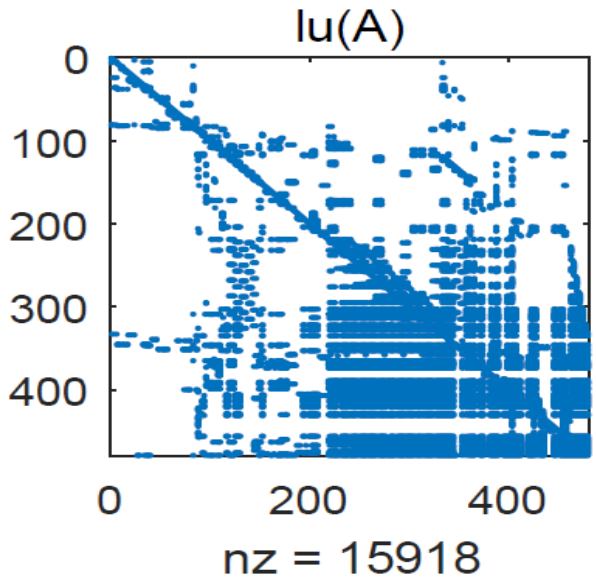
lu(A)
0
100
200
300
400
0
200
400
nz = 15918

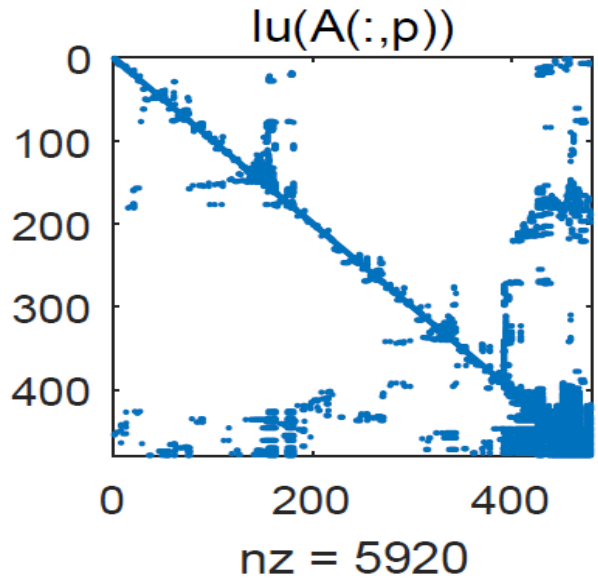
lu(A(:,p))
0
100
200
300
400
0
200
400
nz = 5920

线性方程组的迭代法

设线性代数方程组

$$A\boldsymbol{x} = \boldsymbol{b}, \qquad A \in \mathbb{R}^{n\times n}, \quad \boldsymbol{b} \in \mathbb{R}^n$$

A非奇异,

有唯一解。

理论上, $Q^{-1} = A^{-1}$ 最佳.

如果 Q 非奇异，则

$x = A^{-1}b$ (直接法)

$$\begin{aligned} A\boldsymbol{x} = \boldsymbol{b} &\Leftrightarrow Q^{-1}(\boldsymbol{b} - A\boldsymbol{x}) = 0 \\ &\Leftrightarrow (I - Q^{-1}A)\boldsymbol{x} + Q^{-1}\boldsymbol{b} = \boldsymbol{x} \end{aligned}$$

令 $\phi(\boldsymbol{x}) = (I - Q^{-1}A)\boldsymbol{x} + Q^{-1}\boldsymbol{b}$,

$x^{(k+1)} = \phi(x^{(k)})$

则求解线性方程组等价于下面的不动点问题

$$A\boldsymbol{x} = \boldsymbol{b} \Longleftrightarrow \boldsymbol{x}^* = \phi(\boldsymbol{x}^*).$$

线性定常单步迭代法

定义 (迭代法)

假定方程

$$\boldsymbol{x} = B\boldsymbol{x} + \boldsymbol{f} = \phi(x) \Leftrightarrow A\boldsymbol{x} = \boldsymbol{b}$$

存在唯一解，且与 $A\boldsymbol{x} = \boldsymbol{b}$ 同解，则可以构造迭代公式

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}, \quad k = 0, 1, \cdots,$$

其中 $\boldsymbol{x}^{(0)}$ 是给定的初始向量，B 称为迭代矩阵。若如此产生的序列 $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$ 有极限 $\boldsymbol{x}^*$，则 $\boldsymbol{x}^*$ 为方程 $A\boldsymbol{x} = \boldsymbol{b}$ 的解，称迭代法收敛。

注记

考虑一般的迭代法收敛性时，初值的选择是一个重要的因素。但对于线性迭代法，不存在类似的问题。

把解线性方程组问题转化为等价的不动点问题：

$$A\boldsymbol{x} = \boldsymbol{b} \Longleftrightarrow (I - Q^{-1}A)\boldsymbol{x} + Q^{-1}\boldsymbol{b} = \boldsymbol{x},$$

此处 Q^{-1} 要容易得到。

Richardson 迭代法

最简单

$$Q = I \Rightarrow B = I - A$$

相应的迭代法为

$$\boldsymbol{x}^{(k+1)} = (I - A)\boldsymbol{x}^{(k)} + \boldsymbol{b},$$

称为Richardson迭代法。

定常线性迭代法的收敛性

由压缩映像原理，若映射 $\phi(\boldsymbol{x}) : \mathbb{R}^n \to \mathbb{R}^n$ 是压缩的：

即 $\exists 0 < \alpha < 1$ 使得

$$\|\phi(\boldsymbol{x}) - \phi(\boldsymbol{y})\| \leq \alpha \|\boldsymbol{x} - \boldsymbol{y}\|, \quad \forall \boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n,$$

则迭代法收敛。

另一方面

$$\|\phi(\boldsymbol{x}) - \phi(\boldsymbol{y})\| = \|B\boldsymbol{x} - B\boldsymbol{y}\| \leq \|B\| \|\boldsymbol{x} - \boldsymbol{y}\|$$

相容性.

因而若存在某种从属矩阵范数使得

$$\|B\| < 1,$$

压缩映射.

则迭代法一定收敛。

定常迭代法

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$$

方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 的解 $\boldsymbol{x}^*$ 满足：

$$\boldsymbol{x}^* = B\boldsymbol{x}^* + \boldsymbol{f},$$

定义 $\boldsymbol{e}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^*$，两式相减有

$$\boldsymbol{e}^{(k+1)} = \boldsymbol{x}^{(k+1)} - \boldsymbol{x}^* = B(\boldsymbol{x}^{(k)} - \boldsymbol{x}^*) = B\boldsymbol{e}^{(k)} \Longrightarrow \boldsymbol{e}^{(k)} = B^k\boldsymbol{e}^{(0)}.$$

若迭代法收敛：

$$\lim_{k\to\infty} \boldsymbol{e}^{(k)} = \lim_{k\to\infty} B^k\boldsymbol{e}^{(0)} = \boldsymbol{0}, \quad \forall \boldsymbol{e}^{(0)} \in \mathbb{R}^n.$$

亦即

$$\lim_{k\to\infty} B^k = \mathbf{O} \in \mathbb{R}^{n\times n}.$$

线性方程组迭代法的收敛性定理

下面的命题等价

$Ax=b \Leftrightarrow x=Bx+f$

$x^{(k+1)}=Bx^{(k)}+f$

1. 迭代法 $\boldsymbol{x}^{(k+1)}=\boldsymbol{B}\boldsymbol{x}^{(k)}+\boldsymbol{f}$ 收敛。
2. $\lim\limits_{k\to\infty} B^k=\mathbf{O}$。
3. $\rho(B)<1$。
4. 至少存在一种从属的矩阵范数$\|\cdot\|$，使得$\|B\|<1$。

证明：①⇒②已证！

②⇒③

设 $Bx=\lambda x$，$x\neq 0\in\mathbb{R}^n$，

$B^k x=\lambda^k x$，$x\neq 0\in\mathbb{R}^n$，

若 $\rho(B)\geq 1$，即 $\exists\ \lambda$，s.t. $|\lambda|\geq 1$，满足

$B^k x=\lambda^k x$，$|\lambda|\geq 1$.

有: $\lim_{k\to\infty} B^k x = \lambda^k x \to 0 \in \mathbb{R}^n$.

$\Rightarrow \lim_{k\to\infty} B^k = 0$ 矛盾.

则 $\rho(B) < 1$.

③⇒④ $\forall \varepsilon > 0$, 存在一种从属矩阵的范数, s.t

$$\|B\| < \rho(B) + \varepsilon.$$

取 $\varepsilon = \frac{1-\rho(B)}{2}$, 则

$$\|B\| < \frac{1-\rho(B)}{2} + \rho(B) = \frac{\rho(B)+1}{2} < 1.$$

④⇒①.

$x = Bx + f$, $y = By + f$, 则

$$\|\phi(x) - \phi(y)\| = \|Bx - By\| \le \|B\| \, \|x - y\| < \alpha \|x - y\|$$

压缩.

Damping Richardson 迭代法

若 A 对称正定，则 Richardson 迭代法：$x^{(k+1)} = (I-A)x^{(k)} + b$

$$\rho(B) = \rho(I-A) = \max\left\{|1-\lambda_{\max}(A)|, |1-\lambda_{\min}(A)|\right\}.$$

迭代法收敛的充要条件是 A 对称正定 $\lambda_{max} \geq \lambda_2 \geq \cdots \geq \lambda_{min} > 0$.

$$\rho(B) < 1 \Longleftrightarrow \lambda_{\max}(A) < 2.$$

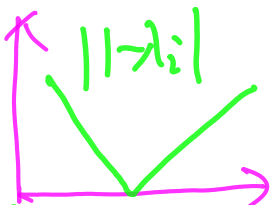

如何改进，使得迭代法对对称正定A收敛？

Damping Richardson

$Ax=b \Longleftrightarrow \frac{1}{\alpha}Ax = \frac{b}{\alpha}$, $\alpha \neq 0$.

取 α, s.t $\rho(\frac{1}{\alpha}A) < 2$. 则 $x^{(k+1)} = (I - \frac{1}{\alpha}A)x^{(k)} + \frac{b}{\alpha}$

收敛！ 2取 $\|A\|_1$ 或 $\|A\|_\infty$. $(\rho(B) \leq \|B\|)$

最好选 $\alpha = \text{trace}(A) = \sum_{j=1}^{n} \lambda_j$, $\lambda_j > 0$, $\rho(A) < \alpha$.

数学家简介 (Richardson)

Lewis Fry Richardson（*1881-1953*）是英国数学家、物理学家、气象学家、心理学家和和平主义者， 现代天气预报先驱 *"Weather prediction by numerical processes" (1922)*, 用数学建模来研究战争的原因以及如何防止战争。*Richardson* 外推法。 地球物理中的 *Richardson* 数*(*流体对流稳定性有关的无量纲数*)*也是以他命名。在研究英国的海岸线时发现了分形结构。 他在剑桥获得物理、数学、化学、生物学和动物学学士学位，并在*47*岁时获得了数学心理学博士学位。

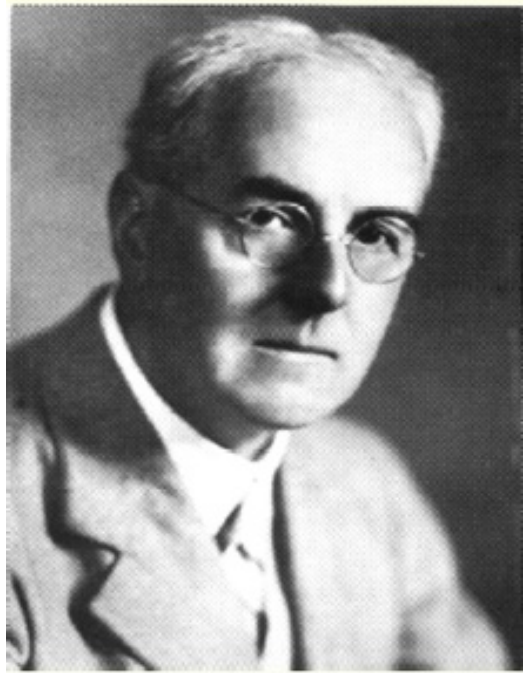

矩阵分裂

一般的迭代公式如何构造，考虑矩阵分裂

$$A = M - N,$$

其中 M 非奇异。则由

$$Ax = (M - N)x = b,$$

得到

$$x = M^{-1}Nx + M^{-1}b.$$

令

$$B = M^{-1}N, \quad f = M^{-1}b \Longrightarrow x = Bx + f,$$

即得到一个定常的线性迭代法。显然，A 的不同的分裂方法得到不同的迭代法。

设 $A=(a_{ij})$，可以把 A 分裂为

$$A = D - L - U,$$

其中 $D=\operatorname{diag}(a_{11},a_{22},\cdots,a_{nn})$，

$$L = -\begin{bmatrix} 0 & 0 & \cdots & 0 & 0 \\ a_{21} & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n-1,1} & a_{n-1,2} & \cdots & 0 & 0 \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & 0 \end{bmatrix}$$

$$U = -\begin{bmatrix} 0 & a_{12} & \cdots & a_{1,n-1} & a_{1n} \\ 0 & 0 & \cdots & a_{2,n-1} & a_{2n} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & a_{n-1,n} \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix}$$

Jacobi 迭代

若 D 非奇异，即 $a_{ii} \neq 0, i = 1, 2, \cdots, n$，则令

$$M = D, \quad N = L + U,$$

可得迭代法

$$\boldsymbol{x}^{(k+1)} = B_J \boldsymbol{x}^{(k)} + \boldsymbol{f}, \quad k = 0, 1, \cdots$$

其中向量 $\boldsymbol{f}$ 和迭代矩阵 B_J 为

$$\begin{aligned} \boldsymbol{f} &= D^{-1}\boldsymbol{b} \\ B_J &= D^{-1}(L + U) = I - D^{-1}A \end{aligned}$$

上述迭代法称为Jacobi迭代法，简称J法。其分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)} \right).$$

直接对求解二维 Poisson 方程的差分方程

$$4u_{ij} - u_{i+1,j} - u_{i-1,j} - u_{i,j+1} - u_{i,j-1} = h^2 f_{ij}$$

设计Jacobi迭代法，有

算法 (求解二维Poisson方程的Jacobi方法)

for $i = 1$ *to* N

  for $j = 1$ *to* N

$$u_{ij}^{(k+1)} = (u_{i-1,j}^{(k)} + u_{i+1,j}^{(k)} + u_{i,j+1}^{(k)} + u_{i,j-1}^{(k)} + h^2 f_{ji})/4$$

  end for

end for

简言之，迭代的每一步，u_{ij} 的新的值是通过和它相邻的四个值的上一步迭代所得的值和 $h^2 f$ 做平均得到的。$u_{ij}^{(k+1)}$ 可以独立计算。

数学家简介 (Jacobi)

卡尔·雅可比（*1804–1851*），德国数学家。雅可比是数学史上最勤奋的学者之一，与欧拉一样也是一位在数学上多产的数学家，是被广泛承认的历史上最伟大的数学家之一。 雅可比善于处理各种繁复的代数问题，在纯粹数学和应用数学上都有非凡的贡献， 在他逝世后，狄利克雷称他为拉格朗日以来德国科学院成员中最卓越的数学家。他几乎与阿贝尔同时各自独立地发现了椭圆函数，是椭圆函数理论的奠基人。还有*Jacobi*行列式， *Jacobi*矩阵，*Hamilton-Jacobi*方程等。

Riemann

Gauss-Seidel 迭代法

取 $M = D - L,\quad N = U,$

对应的迭代法

$$\begin{aligned} \boldsymbol{x}^{(k+1)} &= B_G \boldsymbol{x}^{(k)} + \boldsymbol{f}, \\ B_G &= (D-L)^{-1}U = I - (D-L)^{-1}A, \\ \boldsymbol{f} &= (D-L)^{-1}\boldsymbol{b}. \end{aligned}$$

称为Gauss-Seidel迭代法，简称 GS 法。其分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \underbrace{\sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)}}_{\text{新的}\boldsymbol{x}\text{的分量}} - \underbrace{\sum_{j=i+1}^{n} a_{ij} x_j^{(k)}}_{\text{旧的}\boldsymbol{x}\text{的分量}} \right).$$

- 理论上，N^2 个变量的Poisson方程的近似方程组有很多种方法实现Gauss-Seidel迭代；
- 但是在这些排序方式中，最常用的有两种：自然排序和红黑排序；
- Gauss-Seidel 迭代法求解模型问题，红黑排序是最优的。

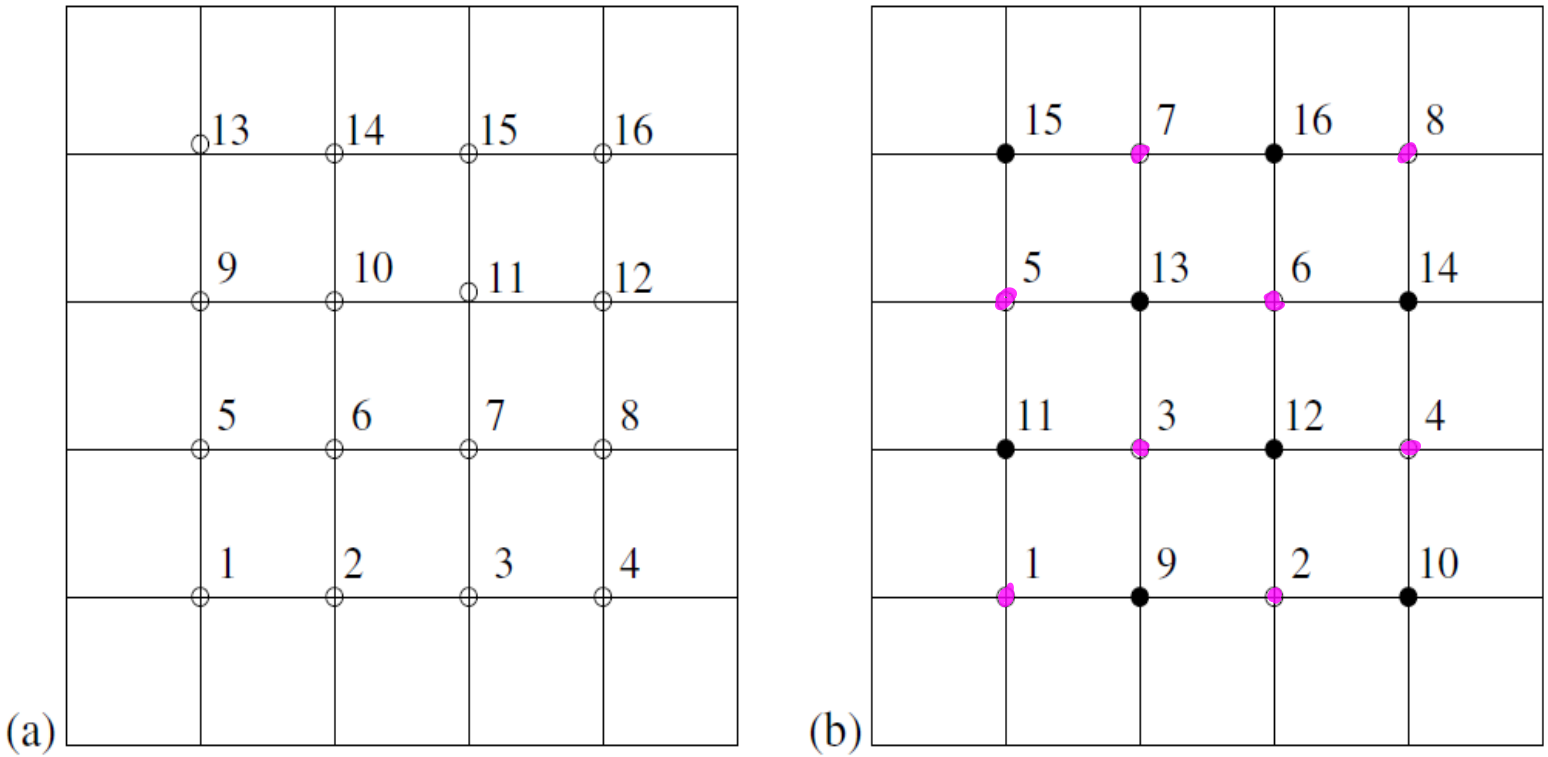

红黑排序的 G-S 方法

- 在上面的图中，○表示编号为红色的节点，●表示编号为黑色的点。
- 红黑排序的原则是红色的节点要排在黑色节点之前。
- 红黑排序有什么特点？

算法 (求解基于红黑排序的2维Poisson方程的G-S法)

for 所有的红色节点 **R**, i,j

$$u_{ij}^{(k+1)} = (u_{i-1,j}^{(k)} + u_{i+1,j}^{(k)} + u_{i,j+1}^{(k)} + u_{i,j-1}^{(k)} + h^2 f_{ij})/4$$

end for

for 所有的黑色节点 **B**, i,j

$$u_{ij}^{(k+1)} = (u_{i-1,j}^{(k+1)} + u_{i+1,j}^{(k+1)} + u_{i,j+1}^{(k+1)} + u_{i,j-1}^{(k+1)} + h^2 f_{ij})/4$$

end for

二维Poisson 方程自然排序和红黑排序的稀疏结构

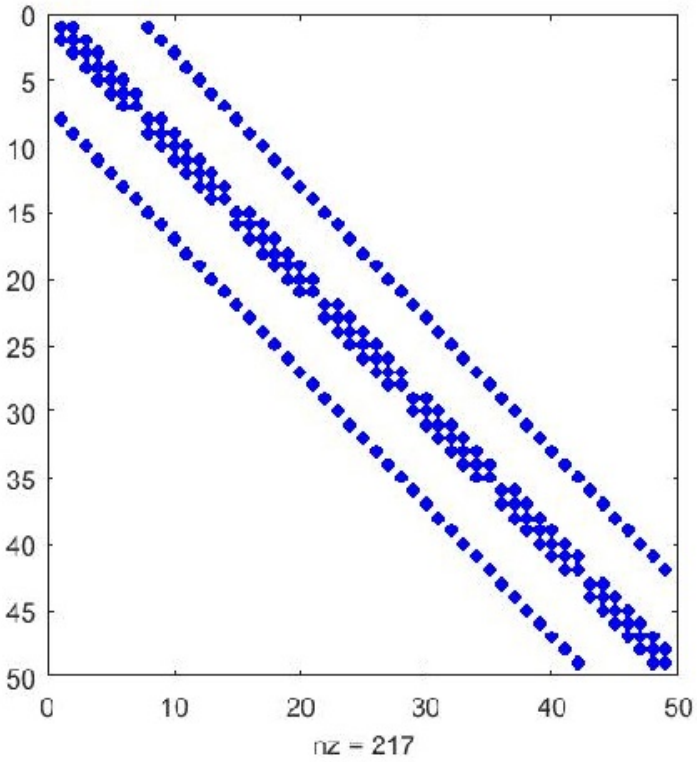

自然排序

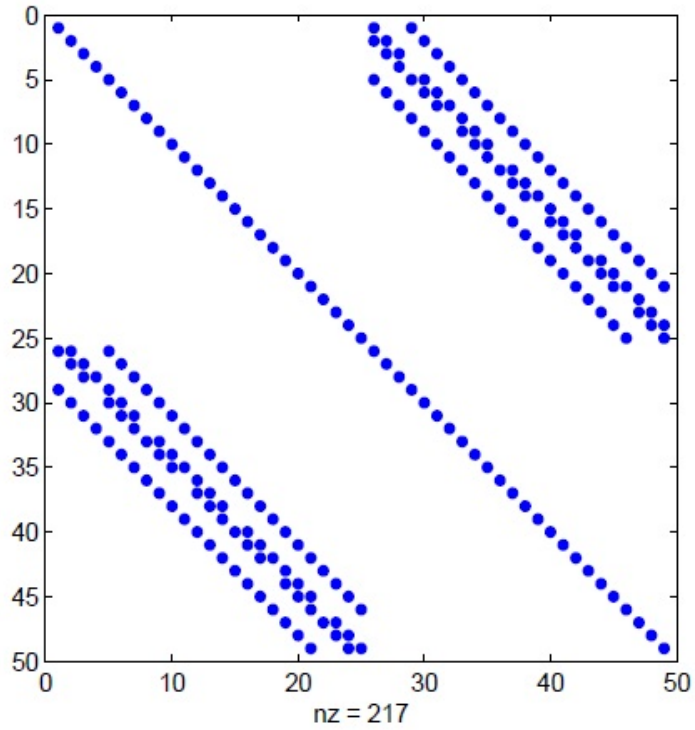

红黑排序

定理

设 $\boldsymbol{x}^*$ 是方程 $\boldsymbol{x} = B\boldsymbol{x} + \boldsymbol{f}$ 的唯一解，$\|\cdot\|_\nu$ 是一种向量范数，对应的从属矩阵范数 $\|B\|_\nu < 1$，则由迭代法

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}, \quad k = 0, 1, \cdots$$

产生的向量序列 $\{\boldsymbol{x}^{(k)}\}$ 满足

$$\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_\nu \leq \frac{\|B\|_\nu}{1 - \|B\|_\nu} \|\boldsymbol{x}^{(k)} - \boldsymbol{x}^{(k-1)}\|_\nu$$

$$\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_\nu \leq \frac{\|B\|_\nu^k}{1 - \|B\|_\nu} \|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\|_\nu$$

$x^{(k)} = Bx^{(k-1)} + f$
$x^{(k-1)} = Bx^{(k-2)} + f$
$\Rightarrow x^{(k)} - x^{(k-1)} = B(x^{(k-1)} - x^{(k-2)})$
$= B^2(x^{(k-2)} - x^{(k-3)}) = \cdots = B^{k-1}(x^{(1)} - x^{(0)})$

证明：$x^{(k)} = Bx^{(k-1)} + f$

$x^* = Bx^* + f$，

两式相减有：$x^{(k)} - x^* = B(x^{(k-1)} - x^*) \Leftrightarrow e^{(k)} = Be^{(k-1)}$

$\frac{\|e^{(k)}\|_v}{\|e^{(k-1)}\|_v} \le \|B\|_v$ 一般不是.

即 $x^{(k)} - x^* = B(x^{(k-1)} - x^{(k)} + x^{(k)} - x^*)$

则：$(I - B)(x^{(k)} - x^*) = B(x^{(k-1)} - x^{(k)})$

因为 $\|B\|_v < 1$，则 $I - B$ 可逆，且

$$\|(I-B)^{-1}\|_v \le \frac{1}{1 - \|B\|_v}$$

由此：$x^{(k)} - x^* = (I-B)^{-1} B(x^{(k-1)} - x^{(k)})$

两边取范数有：

$$\|x^{(k)} - x^*\|_v \le \|(I-B)^{-1}B\|_v \, \|x^{(k-1)} - x^{(k)}\|_v$$

(事后估计)

(次可乘性) $\leq \|(I-B)^{-1}\|_v \|B\|_v \|x^{(k)}-x^{(k-1)}\|_v$

$\leq \dfrac{\|B\|_v}{1-\|B\|_v} \|x^{(k)}-x^{(k-1)}\|_v$

即: $\|x^{(k)}-x^*\|_v \leq \dfrac{\|B\|_v}{1-\|B\|_v} \|x^{(k)}-x^{(k-1)}\|_v$ 证毕

迭代终止条件:

① $r^{(k)}=b-Ax^{(k)}$, $\|r^{(k)}\|<\varepsilon$, 终止, A良态.

② $\|x^{(k)}-x^{(k-1)}\|<\varepsilon$, 终止.

若 $\|B\|_v=1-\sigma$, $\sigma<<1$, $\sigma=10^{-12}$

$\|x^{(k)}-x^{(k-1)}\|\leq 10^{-6}$, $\|x^{(k)}-x^*\|_v \sim 10^6$

迭代法收敛太慢!

若 $\rho(B) < 1$，则迭代法

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$$

收敛，考虑收敛速度的问题。设 $\boldsymbol{e}^{(0)} \neq \boldsymbol{0}$，则有

$$\|\boldsymbol{e}^{(k)}\| \leq \|B^k\| \cdot \|\boldsymbol{e}^{(0)}\| \Longrightarrow \frac{\|\boldsymbol{e}^{(k)}\|}{\|\boldsymbol{e}^{(0)}\|} \leq \|B^k\|$$

迭代 k 次后，平均每次迭代误差范数的放大倍数为

$$\|B^k\|^{1/k}.$$

如果要求迭代 k 次后

$$\|\boldsymbol{e}^{(k)}\| \leq \sigma \|\boldsymbol{e}^{(0)}\|$$

其中 $\sigma > 0$ 为一小数。可以选择足够大的 k，使得

$$\|B^k\| \leq \sigma.$$

收敛速度

对于所有使 $\|B^k\| < 1$ 的 k，上式等价于

$$k \geq -\frac{\ln \sigma}{-\frac{1}{k}\ln \|B^k\|} = -\frac{\ln \sigma}{\ln \|B^k\|^{1/k}},$$

因而有

定义 (平均收敛率（average convergence rate）)

$$R_k(B) \overset{def}{=} -\ln \|B^k\|^{1/k}$$

称为迭代法的平均收敛率。

迭代法的平均收敛率依赖于矩阵范数和迭代次数，无论是理论上还是实际计算都不好处理。希望能找到一个只跟迭代矩阵相关的量来衡量收敛速度。

注意到如下定理

对任意矩阵范数都有

$$\lim_{k\to\infty} \|B^k\|^{1/k} = \rho(B).$$

证明：设 $Bx=\lambda x$，$x\neq 0\in\mathbb{R}^n$，则 $B^k x=\lambda^k x$，

则 $[\rho(B)]^k=\rho(B^k)\le\|B^k\|$，即：$\rho(B)\le\|B^k\|^{\frac{1}{k}}$

$\forall\varepsilon>0$，定义矩阵 $B_\varepsilon=\frac{B}{\rho(B)+\varepsilon}$ 则 $\rho(B_\varepsilon)<1$.

则 $\lim_{k\to\infty} B_\varepsilon^k=O\in\mathbb{R}^{n\times n}$.

则 $\exists K\in\mathbb{N}$，s.t. $\forall k>K$，有：$\|B_\varepsilon^k\|<1$

即 $\|B^k\|\le(\rho(B)+\varepsilon)^k\Rightarrow\|B^k\|^{\frac{1}{k}}\le\rho(B)+\varepsilon$,

则：$\rho(B)\le\|B^k\|^{\frac{1}{k}}\le\rho(B)+\varepsilon$，即：$\lim_{k\to\infty}\|B^k\|^{\frac{1}{k}}=\rho(B)$.

定义 (渐近收敛率（asymptotic convergence rate）)

$$R(B) \overset{def}{=} -\ln \rho(B)$$

称为迭代法的渐近收敛率，或渐近收敛速度。

显然

$$R(B) = \lim_{k\to\infty} R_k(B).$$

且 $R(B)$ 与 B 上取何种范数及迭代次数无关，它反映迭代次数趋于无穷时迭代法的渐近性质。为了达到所 需要的精度，可用

$$k \approx -\ln \sigma / R(B)$$

作为迭代次数的估计。

注记

从以上的讨论可以看出，对于不同的迭代法，其迭代矩阵谱半径较小者收敛要快些。

对角占优阵

定义

若 $A = (a_{ij}) \in \mathbb{R}^{n\times n}$，满足

$$|a_{ii}| > \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|$$

称 A 为严格对角占优矩阵。若 A 满足

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|$$

且其中至少有一个严格不等式成立，则称 A 为弱对角占优矩阵。

定理

若 $A=(a_{ij})$ 严格对角占优，则 $a_{ii}\neq 0, i=1,2,\cdots,n$，且 A 非奇异。

证明：$a_{ii}\neq 0$ 显然成立，下证 A 非奇异，若不然，$\exists x\in\mathbb{R}^n, x\neq 0$.

s.t $Ax=0$.

记 $\|x\|_\infty=|x_i|=\max_j|x_j|>0$.

$(Ax)_i=\sum_{j=1}^n a_{ij}x_j=0 \Leftrightarrow a_{ii}x_i=-\sum_{j=1,j\neq i}^n a_{ij}x_j$

取绝对值：$|a_{ii}||x_i|\leq\sum_{j=1,j\neq i}^n|a_{ij}||x_j|\leq\sum_{j=1,j\neq i}^n|a_{ij}||x_i|$

即：$|a_{ii}|\leq\sum_{j=1,j\neq i}^n|a_{ij}|$，矛盾.

A 非奇异.

□

定理

若 A 不可约弱对角占优，则 $a_{ii} \neq 0, i = 1, 2, \cdots, n$，且 A 非奇异。

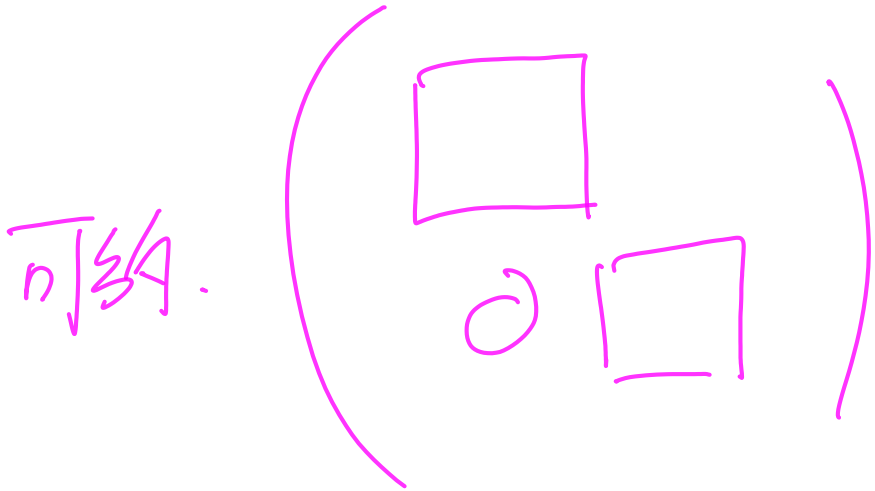

定理

若 A 为严格对角占优或不可约弱对角占优矩阵，则方程组 $Ax = b$ 的 J 法和 GS 法均收敛。

证明：A 严格对角占优，$B_J = D^{-1}(L+U)$

$$\|B_J\|_\infty = \max_i \frac{1}{|a_{ii}|}\left(\sum_{j=1,j\neq i}^{n} |a_{ij}|\right) < 1 \text{ 收敛.}$$

$$\det(\lambda I - B_J) = \det(\lambda I - D^{-1}(L+U)) = \det(D^{-1}[\lambda D - (L+U)])$$

$$= \det D^{-1} \det(\lambda D - (L+U)] \quad (\det D^{-1} \neq 0)$$

若 $|\lambda| \geq 1$，则 $\lambda D - (L+U)$ 严格对角占优，非奇异，

$\det(\lambda I - B_J) \neq 0$

即若 λ 满足 $\det(\lambda I - B_J) = 0$，则 $|\lambda| < 1$，

所以 $\rho(B_J) < 1$. 收敛.

定理

设 A 对称，且有正的对角元，即 $a_{ii} > 0, i = 1, 2, \cdots, n$。方程组 $Ax = b$ 的 J 法迭代收敛 的充分必要条件是 A 及 $2D - A$ 均正定。自己补全证明.

Gauss-Seidel:

$$\det(\lambda I - B_G) = \det(\lambda I - (D-L)^{-1}U)$$
$$= \det((D-L)^{-1}(\lambda(D-L) - U))$$
$$= \det(D-L)^{-1} \det(\lambda(D-L) - U)$$
$$= \det D^{-1} \det(\lambda(D-L) - U)$$

若 $|\lambda| \geq 1, \lambda$ $\lambda(D-L)-U$ 严格对角占优，非奇异，

$\det(\lambda I - B_G) \neq 0$, $\Rightarrow \rho(B_G) < 1$, 收敛.

证毕

定理

若 A 对称正定，则 $Ax = b$ 的 GS 迭代法收敛。

超松弛迭代法(successive overrelaxation)

GS法

$$\boldsymbol{x}_{GS}^{(k+1)} = D^{-1}(\boldsymbol{b} + L\boldsymbol{x}_{GS}^{(k+1)} + U\boldsymbol{x}_{GS}^{(k)}).$$

设

$$\boldsymbol{x}^{(k+1)} = \omega\boldsymbol{x}_{GS}^{(k+1)} + (1-\omega)\boldsymbol{x}^{(k)},$$

写成分量形式有

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}x_j^{(k)}\right), 1 \le i \le n.$$

其中 ω 称为松弛因子。显然当 $\omega = 1$ 时，SOR法即为GS法。

SOR 对应于 A 的分裂

$$A = \frac{1}{\omega}(D - \omega L) - \frac{1}{\omega}[(1-\omega)D + \omega U].$$

亦可得超松弛迭代法

$$\boldsymbol{x}^{(k+1)} = (D-\omega L)^{-1}[(1-\omega)D+\omega U]\boldsymbol{x}^{(k)} + \omega(D-\omega L)^{-1}\boldsymbol{b}$$

或

$$(D-\omega L)\boldsymbol{x}^{(k+1)} = [(1-\omega)D+\omega U]\boldsymbol{x}^{(k)} + \omega\boldsymbol{b}$$

或

$$D\boldsymbol{x}^{(k+1)} = (1-\omega)D\boldsymbol{x}^{(k)} + \omega(\boldsymbol{b} + L\boldsymbol{x}^{(k+1)} + U\boldsymbol{x}^{(k)})$$

或

$$\boldsymbol{x}^{(k+1)} = (1-\omega)\boldsymbol{x}^{(k)} + \omega D^{-1}(\boldsymbol{b} + L\boldsymbol{x}^{(k+1)} + U\boldsymbol{x}^{(k)})$$

SOR方法的预处理矩阵为

$$M_{SOR} = \frac{1}{\omega}(D-\omega L),$$

其迭代矩阵为

$$\mathcal{L}_\omega = I - M_{SOR}^{-1}A.$$

算法 (SOR求解基于红黑排序的Poisson方程的差分方程组)

for 所有的红色节点 **R**, i,j

$$u_{ij}^{(k+1)} = (1-\omega)u_{ij}^{(k)} + \omega(u_{i-1,j}^{(k)} + u_{i+1,j}^{(k)} + u_{i,j+1}^{(k)} + u_{i,j-1}^{(k)} + h^2 f_{ij})/4$$

end for

for 所有的黑色节点 **B**, i,j

$$u_{ij}^{(k+1)} = (1-\omega)u_{ij}^{(k)} + \omega(u_{i-1,j}^{(k+1)} + u_{i+1,j}^{(k+1)} + u_{i,j+1}^{(k+1)} + u_{i,j-1}^{(k+1)} + h^2 f_{ij})/4$$

end for

超松弛迭代法的收敛性

定理

对任意的 $A \in \mathbb{R}^{n\times n}$，设其对角元素皆非零，则对所有实数 ω，有

$$\rho(\mathcal{L}_\omega) \geq |\omega - 1|.$$

证明：$\det \mathcal{L}_\omega = \det\left((D-\omega L)^{-1}[(1-\omega)D+\omega U]\right)$

$= \det(D-\omega L)^{-1} \det((1-\omega)D+\omega U)$

$= \det D^{-1} \det((1-\omega)D+\omega U)$

$= \det D^{-1} \det((1-\omega)D)$

$= (1-\omega)^n$

$= \lambda_1 \lambda_2 \cdots \lambda_n$

则 $\rho(\mathcal{L}_\omega) = \max_i |\lambda_i| \geq |1-\omega|$.

定理

SOR收敛的必要条件是 $|1-\omega|<1$，即 $0<\omega<2$。

SOR收敛 $\Leftrightarrow \rho(\mathcal{L}_\omega)<1$，$\rho(\mathcal{L}_\omega)\geq|1-\omega|$

定理

设 $A\in\mathbb{R}^{n\times n}$ 为对称正定矩阵，且 $0<\omega<2$，则 SOR 方法收敛。

证明：设 $\mathcal{L}_\omega x=\lambda x$，$\lambda\in\mathbb{C}$，$x\in\mathbb{C}^n$，$x\neq 0$

即，$(D-\omega L)^{-1}((1-\omega)D+\omega U)x=\lambda x$，

等价有：$[(1-\omega)D+\omega U]x=\lambda(D-\omega L)x$，

两边与 x 作内积，有

$$([(1-\omega)D+\omega U]x,x)=\lambda((D-\omega L)x,x)$$

记 $p=(Dx,x)>0$，（D 正定，$e_i^TAe_i=a_{ii}>0$）

$(Ux,x)=\alpha+i\beta$, $i=\sqrt{-1}$, 于

$(Lx,x)=(U^Tx,x)=\overline{x}^TU^Tx=(\overline{Ux})^Tx$

$=(x,Ux)=\overline{(Ux,x)}=\alpha-i\beta$

则 $\lambda=\dfrac{(1-\omega)p+\omega(\alpha+i\beta)}{p-\omega(\alpha-i\beta)}=\dfrac{(1-\omega)p+\omega\alpha+i\omega\beta}{p-\omega\alpha+i\omega\beta}$

想证明 $|\lambda|<1$, 分子分母虚部相同, 比较实部

$(p-\omega\alpha)^2-((1-\omega)p+\omega\alpha)^2=(p-\omega\alpha+(1-\omega)p+\omega\alpha)\cdot$

$(p-\omega\alpha-(1-\omega)p-\omega\alpha)=(2-\omega)p\,\omega(p-2\alpha)$, $0<\omega<2$

$p-2\alpha=((D-L-U)x,x)$

$=(Ax,x)>0$, $\forall x\neq 0$

$((L+U)x,x)=2\alpha$

$=\alpha+i\beta+\alpha-i\beta$

A对称正定.

则 $|\lambda|<1$, $\rho(L_\omega)<1$, 收敛. 证毕

最优松弛因子

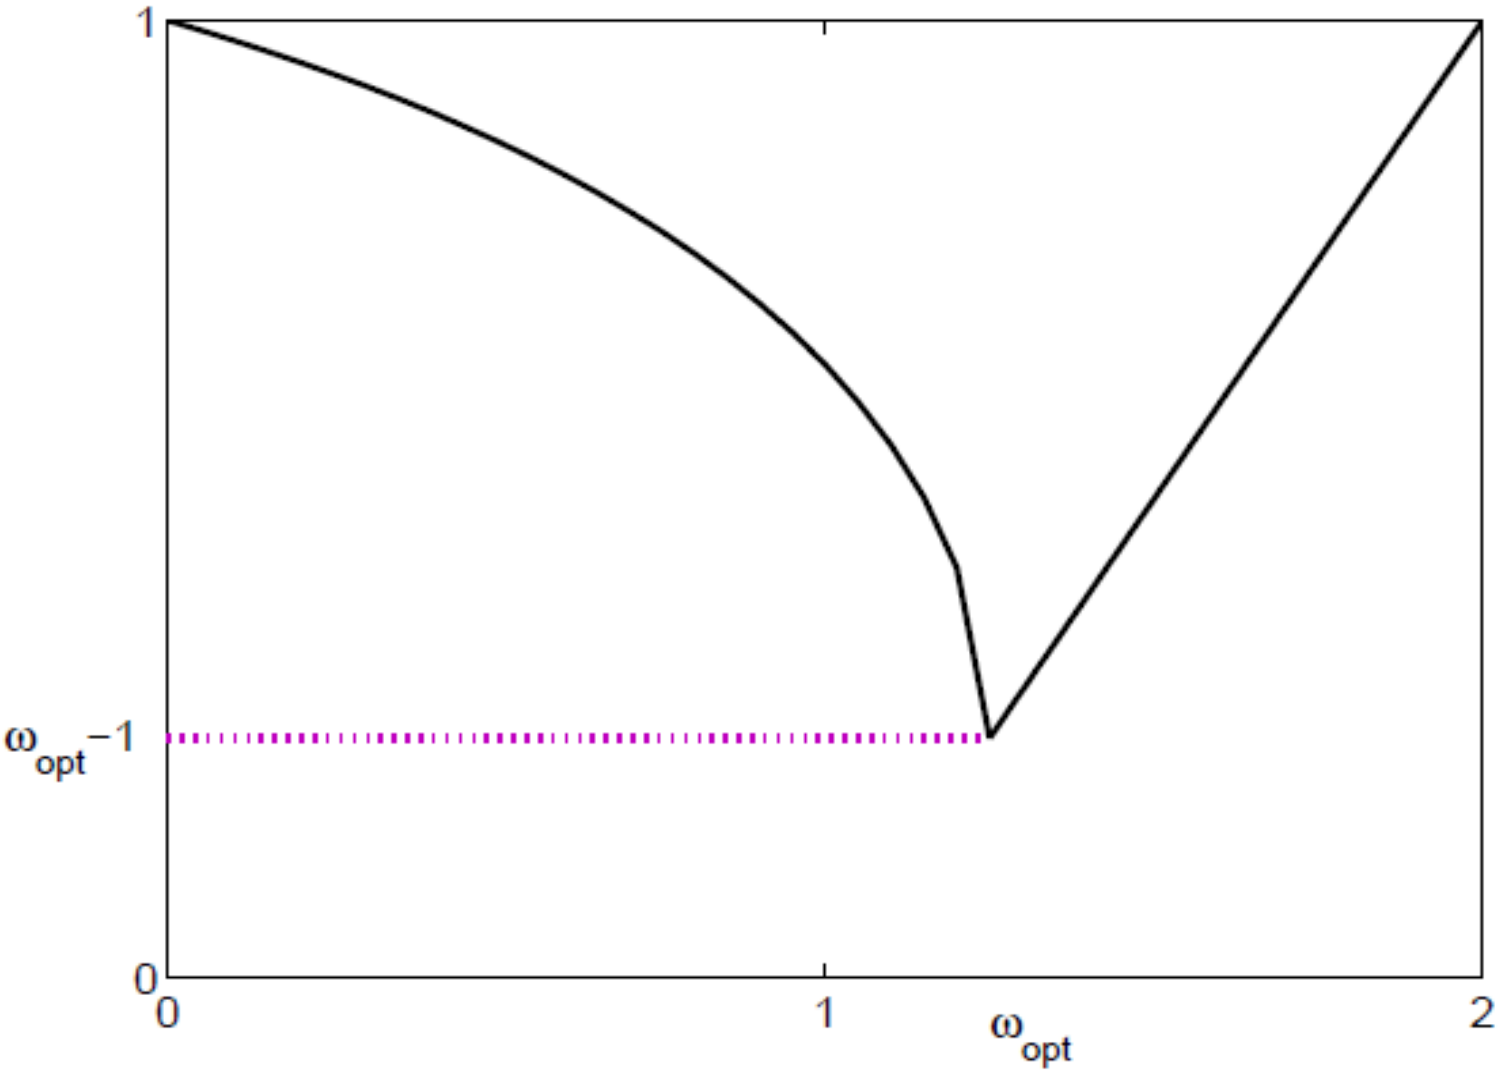

考虑方程组

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix} \Longrightarrow \boldsymbol{x} = \begin{bmatrix} 3 \\ 4 \\ -5 \end{bmatrix}.$$

下表列出不同迭代法所需要的迭代次数

	J	GS	SOR($\omega = 0.8$)	SOR($\omega = \omega_{opt}$)	SOR($\omega = 1.8$)
ρ	0.791	0.625	0.746	0.240	0.800
$\frac{1}{-\log_{10}\rho}$	9.8	4.9	7.9	1.6	10.3
$< 10^{-3}$	37	14	18	7	41
$< 10^{-5}$	56	23	34	11	61
$< 10^{-7}$	76	33	50	14	82
$< 10^{-9}$	95	43	65	17	102

$$\omega_{opt} = \frac{2}{1 + \sqrt{1 - [\rho(B_J)]^2}} \approx 1.24$$

对称超松弛迭代法(SSOR法)的一步迭代由SOR的一步迭代再跟着向后的SOR的一步迭代组成，即

$$\begin{aligned}(D-\omega L)\boldsymbol{x}^{(k+\frac{1}{2})} &= [(1-\omega)D+\omega U]\boldsymbol{x}^{(k)}+\omega\boldsymbol{b}\\ (D-\omega U)\boldsymbol{x}^{(k+1)} &= [(1-\omega)D+\omega L]\boldsymbol{x}^{(k+\frac{1}{2})}+\omega\boldsymbol{b}\end{aligned}$$

因而

$$\begin{aligned}B_{SSOR} &= (D-\omega U)^{-1}[(1-\omega)D+\omega L](D-\omega L)^{-1}[(1-\omega)D+\omega U]\\ &= (D-\omega U)^{-1}[\omega L-D+(2-\omega)D](D-\omega L)^{-1}[(1-\omega)D+\omega U]\\ &= (D-\omega U)^{-1}[-I+(2-\omega)D(D-\omega L)^{-1}][(1-\omega)D+\omega U]\\ &= (D-\omega U)^{-1}[-I+(2-\omega)D(D-\omega L)^{-1}][(2-\omega)D+\omega U-D]\\ &= I-(2-\omega)(D-\omega U)^{-1}D\left(I-(D-\omega L)^{-1}[(1-\omega)D+\omega U]\right)\\ &= I-(2-\omega)\omega(D-\omega U)^{-1}D(D-\omega L)^{-1}A\end{aligned}$$

因而SSOR的分裂矩阵 M 为

若 $A=A^T$，则 $B_{SSOR}=B_{SSOR}^T$

$$M_{SSOR}=\frac{1}{\omega(2-\omega)}(D-\omega L)D^{-1}(D-\omega U).$$

例

比较二维 *Poisson* 方程的五点格式的差分方程按自然排序得到的矩阵在三种经典迭代法下的渐进收敛速度和计算量。

解： 对于一般的 $h = \frac{1}{N+1}$，可以计算出 $B = D^{-1}(L+U)$ 的特征值为

$$\mu_{ij} = \frac{\cos i\pi h + \cos j\pi h}{2}, i,j = 1,\cdots,N.$$

则三种经典迭代法的谱半径：

$$\begin{aligned}
\mu &= \rho(B_J) = \cos \pi h = 1 - \frac{1}{2}\pi^2 h^2 + O(h^4), \\
\rho(\mathcal{L}_1) &= \rho(B_G) = \cos^2 \pi h = 1 - \pi^2 h^2 + O(h^4), \\
\omega_b &= \frac{1}{1+\sin \pi h}, \\
\rho(\mathcal{L}_{\omega_b}) &= \omega_b - 1 = \frac{\cos^2 \pi h}{(1+\sin \pi h)^2}.
\end{aligned}$$

可以看到 $\lim_{h\to 0} \rho \to 1$，当 h 很小时，这几种迭代法收敛很慢。

J法、GS法和最优松弛因子的SOR法收敛速度分别为

$$\begin{aligned} R(J) &= -\ln \rho(B_J) = \frac{1}{2}\pi^2 h^2 + O(h^4), \\ R(G) &= -\ln \rho(B_G) = \pi^2 h^2 + O(h^4), \\ R(\mathcal{L}_{\omega_b}) &= -\ln(\omega_b - 1) = -2[\ln\cos \pi h - \ln(1+\sin \pi h)] \\ &= 2\pi h + O(h^3) \end{aligned}$$

估计一下方法的计算量，若要求计算的精度为 ϵ，则所需迭代的次数为

$$k \approx \frac{-\ln \epsilon}{R},$$

对于现在考虑的这个问题，只需要 ϵ 和偏微分方程的离散误差同阶，亦即 $\epsilon = Ch^2$。所以迭代次数为

$$k = |(\ln C + 2\ln h)/R|.$$

$$\frac{\partial^2 u}{\partial x^2} \to \frac{u_{i+1} - 2u_i + u_{i+1}}{h^2}$$

$$|\ln h| = \left|\ln \frac{1}{N+1}\right| = |\ln(N+1)| \sim \ln N.$$

Jacobi 迭代 $R = \frac{1}{2}\pi^2 h^2$，所以迭代次数为

$$k = O(N^2 \log N), \quad N \to \infty.$$

而每次迭代所需的计算量为 $O(N^2)$，所以总的计算量为

$$O(N^4 \ln N),$$

而针对带状的稀疏矩阵设计的 Gauss 消去法的计算量为 $O(N^4)$，其他的直接法的计算量则更少， 所以Jacobi迭代法无优势。

G-S方法迭代次数是J法的一半，所以总的计算量和J法是同阶的。

对于最优因子的SOR法，迭代次数为

$$k = O(N \ln N),$$

所以总的计算量为

$$O(N^3 \ln N),$$

比直接法要快。

预处理矩阵

迭代法 $\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$ 是求解不动点问题

$$(I - B)\boldsymbol{x} = \boldsymbol{f},$$

而 $B = I - M^{-1}A$, 所以方程变为

$$M^{-1}A\boldsymbol{x} = M^{-1}\boldsymbol{b},$$

相当于对 A 进行了预处理。

Jacobi，Gauss-Seidel和 SOR迭代的预处理矩阵分别为

$$\begin{aligned} M_J &= D, \\ M_{GS} &= D - L, \\ M_{SOR} &= \frac{1}{\omega}(D - \omega L), \\ M_{SSOR} &= \frac{1}{\omega(2-\omega)}(D - \omega L)D^{-1}(D - \omega U). \end{aligned}$$

大多数迭代方法都只计算矩阵–向量积。

如对给定的 v，计算 $w = M^{-1}Av$。

- 首先计算 $r = Av$，然后求解 $Mw = r$：

$$\begin{aligned} r &= Av, \\ w &= M^{-1}r \Longleftrightarrow Mw = r. \end{aligned}$$

不求逆解方程.

- 在有些情况下，用矩阵的分解 $A = M - N$ 计算可能效果更好，即计算 $w = M^{-1}Av$ 等价于通过下面的 程序计算 $w = (I - M^{-1}N)v$：

$$\begin{aligned} r &= Nv, \\ w &= M^{-1}r, \\ w &:= v - w \end{aligned}$$

N 可能比 A 稀疏，可以减少矩阵–向量积的运算量。

$ABx = A(Bx)$

$\neq (AB)x$

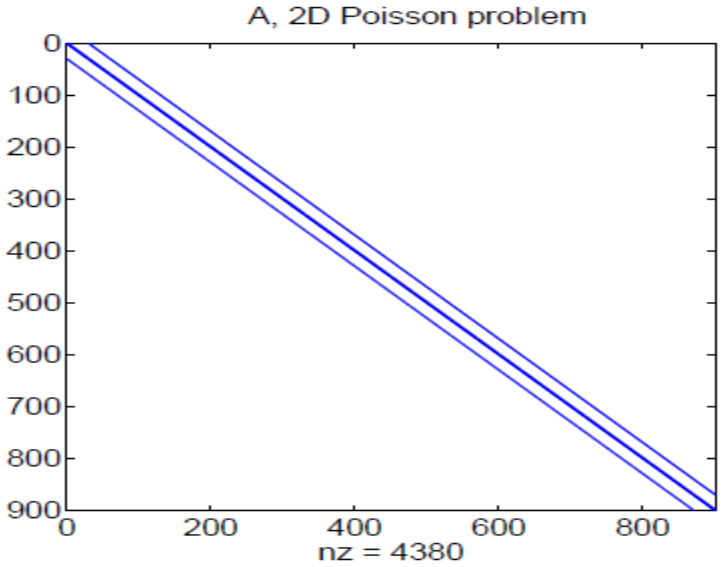

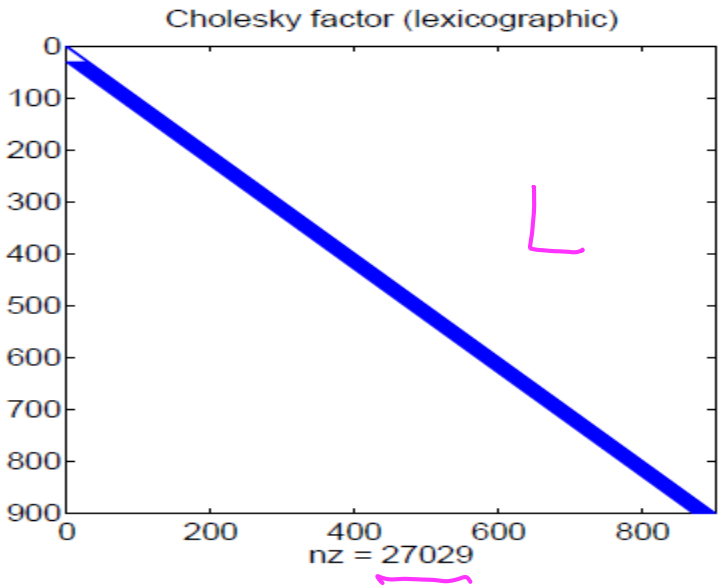

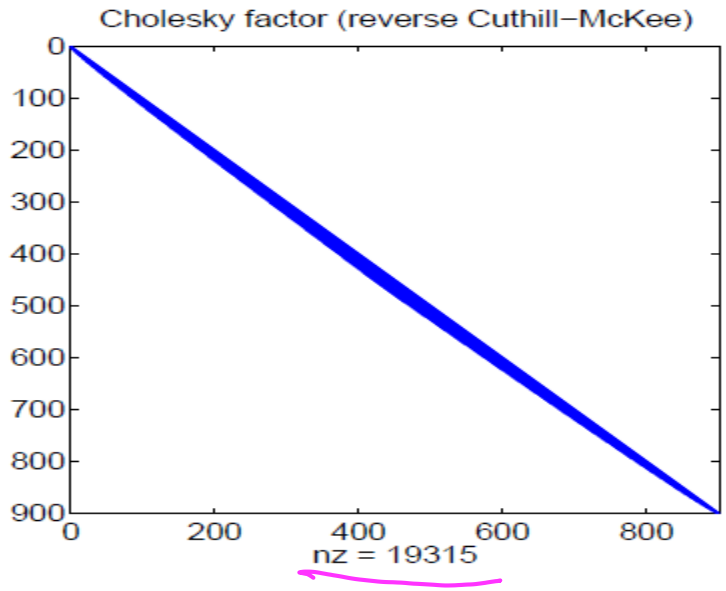

图: 五点差分格式的差分方程的直接法

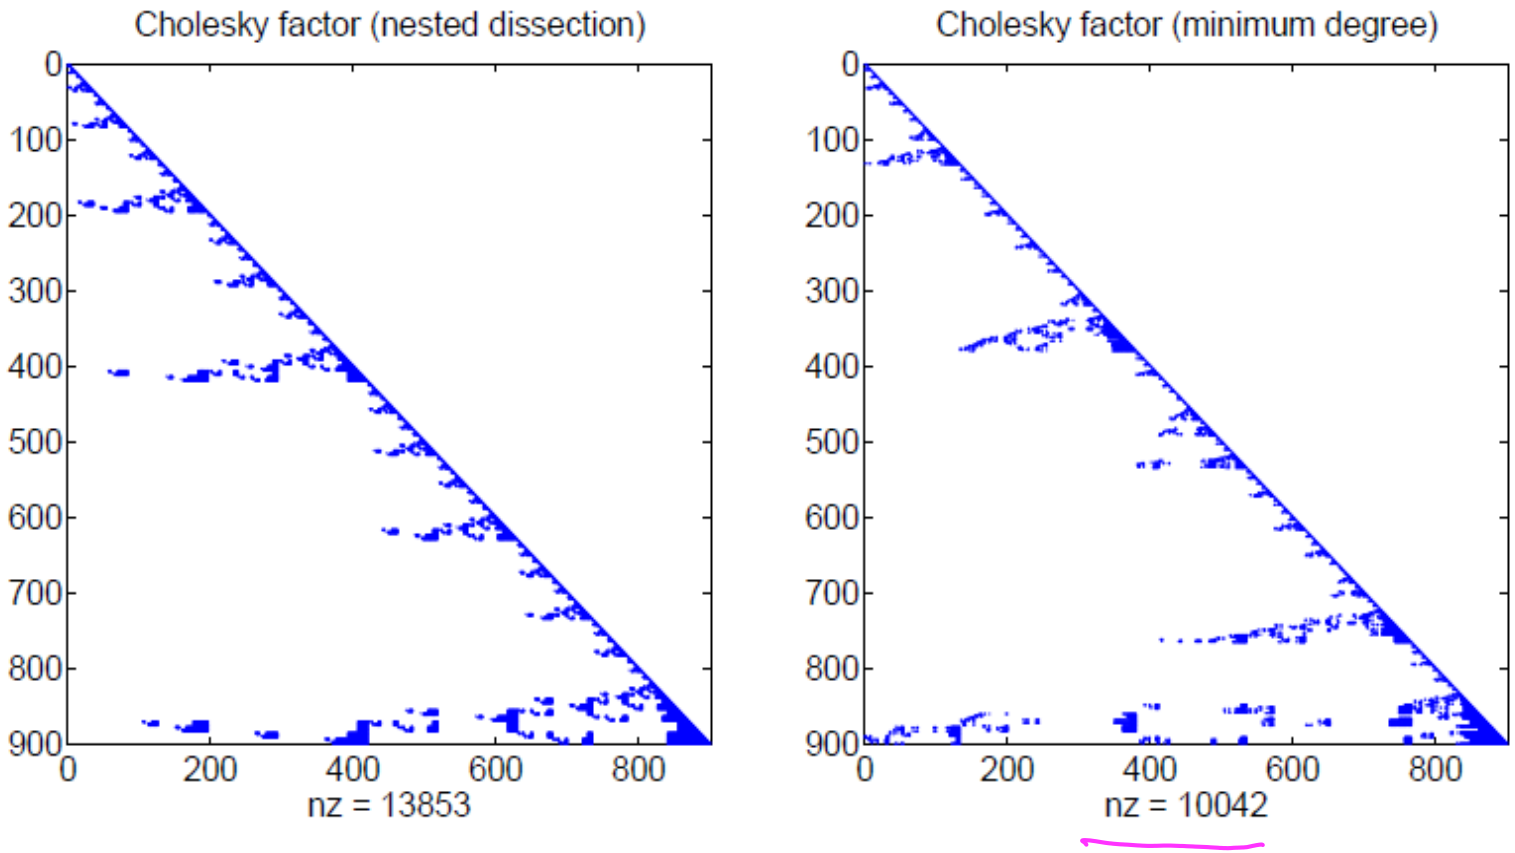

图: 五点差分格式的差分方程的直接法

变分格式–共轭梯度法

- 主要介绍共轭梯度法。它是一种变分方法，对应于求解一个2次函数的极值。它出现于 50年代；80∼90年代预处理共轭梯度法的发展，使得它成为求解大型稀疏方程组的有效方法。

- 考虑一类特殊的线性代数方程组 $A\boldsymbol{x} = \boldsymbol{b}$。 设其系数矩阵 $A = (a_{ij})_{n\times n} \in \mathbb{R}^{n\times n}$ 是对称正定阵。

$$\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^{\mathsf{T}},\ \boldsymbol{b} = (b_1, b_2, \cdots, b_n)^{\mathsf{T}} \in \mathbb{R}^n.$$

考虑2次函数 $\varphi : \mathbb{R}^n \to \mathbb{R}$，定义为

$$\begin{aligned} \varphi(\boldsymbol{x}) &= \frac{1}{2}(A\boldsymbol{x}, \boldsymbol{x}) - (\boldsymbol{b}, \boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x} - \boldsymbol{b}^{\mathsf{T}}\boldsymbol{x} \\ &= \frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}x_i x_j - \sum_{j=1}^{n} b_j x_j. \end{aligned}$$

容易验证 φ 有如下性质

1. 对一切 $\boldsymbol{x} \in \mathbb{R}^n$,

$$\nabla \varphi(\boldsymbol{x}) = A\boldsymbol{x} - \boldsymbol{b}.$$

2. 对一切$\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$, $\alpha \in \mathbb{R}$:

$$\begin{aligned}
\varphi(\boldsymbol{x}+\alpha\boldsymbol{y}) &= \frac{1}{2}\left(A(\boldsymbol{x}+\alpha\boldsymbol{y}), \boldsymbol{x}+\alpha\boldsymbol{y}\right) - (\boldsymbol{b}, \boldsymbol{x}+\alpha\boldsymbol{y}) \\
&= \frac{1}{2}(A\boldsymbol{x}, \boldsymbol{x}) + \frac{1}{2}(\alpha A\boldsymbol{y}, \boldsymbol{x}) + \frac{1}{2}(\boldsymbol{x}, \alpha A\boldsymbol{y}) \\
&\quad + \frac{\alpha^2}{2}(A\boldsymbol{y}, \boldsymbol{y}) - (\boldsymbol{b}, \boldsymbol{x}) - \alpha(\boldsymbol{b}, \boldsymbol{y}) \\
&= \varphi(\boldsymbol{x}) + \alpha(A\boldsymbol{x} - \boldsymbol{b}, \boldsymbol{y}) + \frac{\alpha^2}{2}(A\boldsymbol{y}, \boldsymbol{y}).
\end{aligned}$$

即

$$\varphi(\boldsymbol{x}+\alpha\boldsymbol{y}) = \varphi(\boldsymbol{x}) + \alpha(A\boldsymbol{x} - \boldsymbol{b}, \boldsymbol{y}) + \frac{\alpha^2}{2}(A\boldsymbol{y}, \boldsymbol{y}).$$

另一方面，若

$$\boldsymbol{x}^* = A^{-1}\boldsymbol{b}$$

为 $A\boldsymbol{x} = \boldsymbol{b}$ 的解，则

$$\varphi(\boldsymbol{x}^*) = -\frac{1}{2}(\boldsymbol{b}, A^{-1}\boldsymbol{b}) = -\frac{1}{2}(A\boldsymbol{x}^*, \boldsymbol{x}^*)$$

且对一切 $\boldsymbol{x} \in \mathbb{R}^n$，有

$$\begin{aligned}
\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{x}^*) &= \frac{1}{2}(A\boldsymbol{x}, \boldsymbol{x}) - (A\boldsymbol{x}^*, \boldsymbol{x}) + \frac{1}{2}(A\boldsymbol{x}^*, \boldsymbol{x}^*) \\
&= \frac{1}{2}(A(\boldsymbol{x} - \boldsymbol{x}^*), \boldsymbol{x} - \boldsymbol{x}^*) \\
&\geq 0.
\end{aligned}$$

即线性方程组的解 $\boldsymbol{x}^*$ 是 $\varphi(\boldsymbol{x})$ 的极小值点。

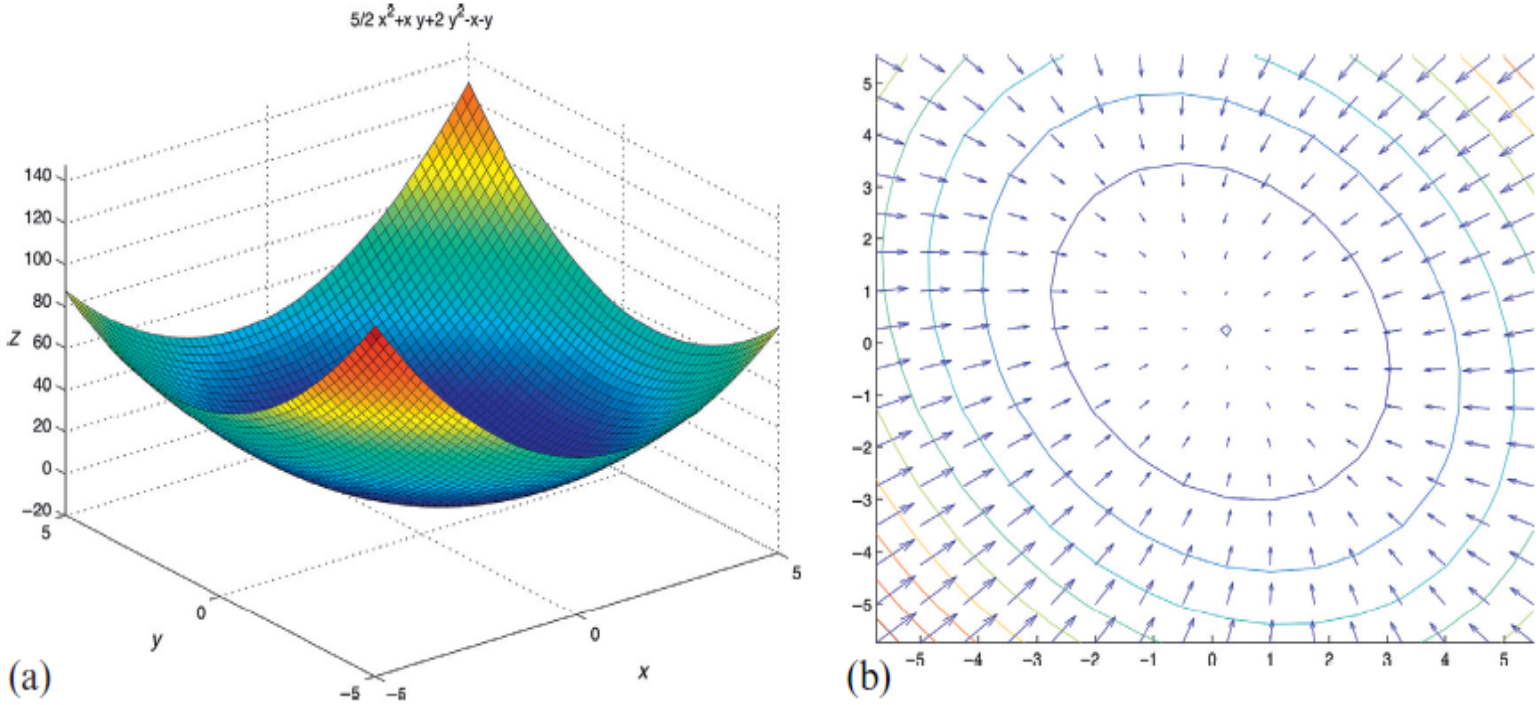

图: $\varphi(\boldsymbol{x})$的图像

定理

设 A 对称正定，则 $\boldsymbol{x}^*$ 为 $A\boldsymbol{x}=\boldsymbol{b}$ 的解的充分必要条件是 $\boldsymbol{x}^*$ 满足

$$\varphi(\boldsymbol{x}^*)=\min_{\boldsymbol{x}\in\mathbb{R}^n}\varphi(\boldsymbol{x}).$$

证明：$\Leftarrow$ "若 $\varphi(x^*)=\min_{x\in\mathbb{R}^n}\varphi(x)$，则

$\nabla\varphi(x^*)=Ax^*-b=0 \Leftrightarrow Ax^*=b.$

$\Rightarrow$ "若 $Ax^*=b$，则 $\varphi(x)\geq\varphi(x^*)$, $\forall x\in\mathbb{R}^n$

$Ax=b \Leftrightarrow \min_{x\in\mathbb{R}^n}\varphi(x)$ → 如何求无约束问题

梯度下降法.

最速下降法

设 $\boldsymbol{x}^{(k)}$ 是某种“近似值”，试图从 $\boldsymbol{x}^{(k)}$ 出发得到一个新的向量，使得它更加“近似于”方程的解。

因为方程的解是2次函数 $\varphi(\boldsymbol{x})$ 的极小值点，一个自然的想法 是构造一个新的向量 $\boldsymbol{x}^{(k+1)}$，使得

$$\varphi(\boldsymbol{x}^{(k+1)}) \leq \varphi(\boldsymbol{x}^{(k)})$$

函数 $\varphi(\boldsymbol{x})$ 在 $\boldsymbol{x} = \boldsymbol{x}^{(k)}$ 点，其值下降最快的方向是其负梯度方向

$$-\nabla\varphi(\boldsymbol{x}^{(k)}) = \boldsymbol{b} - A\boldsymbol{x}^{(k)} \stackrel{def}{=} \boldsymbol{r}^{(k)},$$

可在过 $\boldsymbol{x} = \boldsymbol{x}^{(k)}$ 点，沿 $\boldsymbol{r}^{(k)}$ 的方向上找到一点，使得 $\varphi(\boldsymbol{x})$ 在这条线上取极小，亦即找实数 α_k，使得

$$\varphi(\boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{r}^{(k)}) = \min_{\alpha} \varphi(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{r}^{(k)}).$$

这称为沿方向 $\boldsymbol{r}^{(k)}$ 的一维极小搜索。

1. 取极小值的必要条件（一阶条件）：

$$\frac{d}{d\alpha}\varphi(\boldsymbol{x}^{(k)}+\alpha\boldsymbol{r}^{(k)})=\alpha(A\boldsymbol{r}^{(k)},\boldsymbol{r}^{(k)})-(\boldsymbol{r}^{(k)},\boldsymbol{r}^{(k)})=0$$

由此得到

$$\alpha_k=\frac{(\boldsymbol{r}^{(k)},\boldsymbol{r}^{(k)})}{(A\boldsymbol{r}^{(k)},\boldsymbol{r}^{(k)})}=\frac{\|r^{(k)}\|_2^2}{\|r^{(k)}\|_A^2}$$

$$\varphi(x^{(k)}+\alpha r^{(k)})=\varphi(x^{(k)})+\alpha(Ax^{(k)}-b,r^{(k)})+\frac{\alpha^2}{2}(Ar^{(k)},r^{(k)})$$

$$=\varphi(x^{(k)})-\alpha(r^{(k)},r^{(k)})+\frac{\alpha^2}{2}(Ar^{(k)},r^{(k)})$$

2. 二阶条件：

$$\frac{d^2}{d\alpha^2}\varphi(\boldsymbol{x}^{(k)}+\alpha\boldsymbol{r}^{(k)})=(A\boldsymbol{r}^{(k)},\boldsymbol{r}^{(k)})>0.$$

（A对称正定，若 $r^{(k)}\neq 0$）

3. 因此有

$$\min_{\alpha}\varphi(\boldsymbol{x}^{(k)}+\alpha\boldsymbol{r}^{(k)})=\varphi(\boldsymbol{x}^{(k)}+\alpha_k\boldsymbol{r}^{(k)}).$$

α_k 步长

梯度下降法结合一维极小搜索就可以得到最速下降法。

算法 (最速下降法：steepest descent method)

1. 选取 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$,
2. 对 $k = 0, 1, \cdots$

$$\begin{aligned} \boldsymbol{r}^{(k)} &= \boldsymbol{b} - A\boldsymbol{x}^{(k)} \\ \alpha_k &= \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})}{(A\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})} \\ \boldsymbol{x}^{(k+1)} &= \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{r}^{(k)} \end{aligned}$$

负梯度

步长

$x^{(k+1)} = x^{(k)} - \alpha_k (b - Ax^{(k)})$

$= (I - \alpha_k A)x^{(k)} - \alpha_k b,$

在最速下降法中，每次迭代要做两次矩阵–向量乘法：

$$A\boldsymbol{x}^{(k)} \longrightarrow \boldsymbol{r}^{(k)}, \quad A\boldsymbol{r}^{(k)} \longrightarrow \alpha_k.$$

$r^{(k)} = r^{(k-1)} - \alpha_{k-1} A r^{(k-1)}$

实际上

$$\begin{aligned} \boldsymbol{r}^{(k)} &= \boldsymbol{b} - A\boldsymbol{x}^{(k)} = \boldsymbol{b} - A(\boldsymbol{x}^{(k-1)} + \alpha_{k-1}\boldsymbol{r}^{(k-1)}) \\ &= \boldsymbol{r}^{(k-1)} - \alpha_{k-1} A\boldsymbol{r}^{(k-1)}, \end{aligned}$$

改进的最速下降法

为了得到 α_{k-1} 需要计算 $A\boldsymbol{r}^{(k-1)}$，同样 $A\boldsymbol{r}^{(k-1)}$ 可以用来计算 $\boldsymbol{r}^{(k)}$，所以一个更好的算法为：

算法 (改进的最速下降法)

1. 选取 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$，计算 $\boldsymbol{r}^{(0)} = \boldsymbol{b} - A\boldsymbol{x}^{(0)}$，
2. 对 $k = 1, 2, \cdots$

$$
\begin{aligned}
\boldsymbol{\omega}^{(k-1)} &= A\boldsymbol{r}^{(k-1)} \\
\alpha_{k-1} &= \frac{(\boldsymbol{r}^{(k-1)}, \boldsymbol{r}^{(k-1)})}{(\boldsymbol{\omega}^{(k-1)}, \boldsymbol{r}^{(k-1)})} \\
\boldsymbol{x}^{(k)} &= \boldsymbol{x}^{(k-1)} + \alpha_{k-1}\boldsymbol{r}^{(k-1)} \\
\boldsymbol{r}^{(k)} &= \boldsymbol{r}^{(k-1)} - \alpha_{k-1}\boldsymbol{\omega}^{(k-1)}.
\end{aligned}
$$

最速下降法有如下性质

1. 相邻两次搜索方向是正交的，即 $(\boldsymbol{r}^{(k+1)}, \boldsymbol{r}^{(k)}) = 0.$

2. $\{\varphi(\boldsymbol{x}^{(k)})\}$ 是单调下降有下界的序列，它存在极限，并且

$$\lim_{k\to\infty} \boldsymbol{x}^{(k)} = \boldsymbol{x}^* = A^{-1}\boldsymbol{b}.$$

3. $$\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_A \le \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right)^k \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^*\|_A.$$

其中 λ_1 和 λ_n 分别是对称正定阵 A 的最大最小特征值，

$$\|\boldsymbol{u}\|_A = (A\boldsymbol{u}, \boldsymbol{u})^{1/2}$$

称为能量模(energy norm)。

(1) $r^{(k+1)} = r^{(k)} - \alpha_k A r^{(k)}$,

$(r^{(k+1)}, r^{(k)}) = (r^{(k)} - \alpha_k A r^{(k)}, r^{(k)}) = (r^{(k)}, r^{(k)}) - \alpha_k (A r^{(k)}, r^{(k)})$

其中, $\alpha_k = \dfrac{(r^{(k)}, r^{(k)})}{(A r^{(k)}, r^{(k)})}$ 时: $(r^{(k+1)}, r^{(k)}) = 0$

(2) $\varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha_k r^{(k)})$

$= \varphi(x^{(k)}) - \alpha_k (r^{(k)}, r^{(k)}) + \dfrac{\alpha_k^2}{2} (A r^{(k)}, r^{(k)})$

$= \varphi(x^{(k)}) - \alpha_k (r^{(k)}, r^{(k)}) + \dfrac{1}{2}\alpha_k (r^{(k)}, r^{(k)})$

$= \varphi(x^{(k)}) - \dfrac{1}{2}\alpha_k (r^{(k)}, r^{(k)})$ ($\alpha_k > 0$)

$< \varphi(x^{(k)})$, 若 $r^{(k)} \neq 0 \in \mathbb{R}^n$

两种极端情况

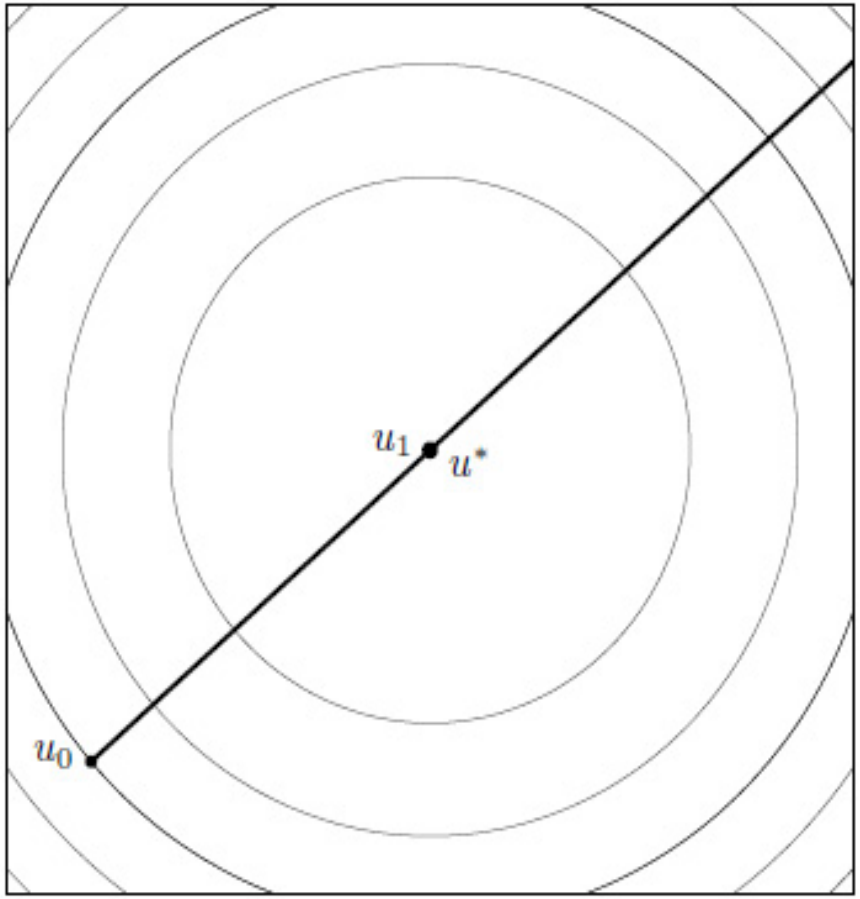

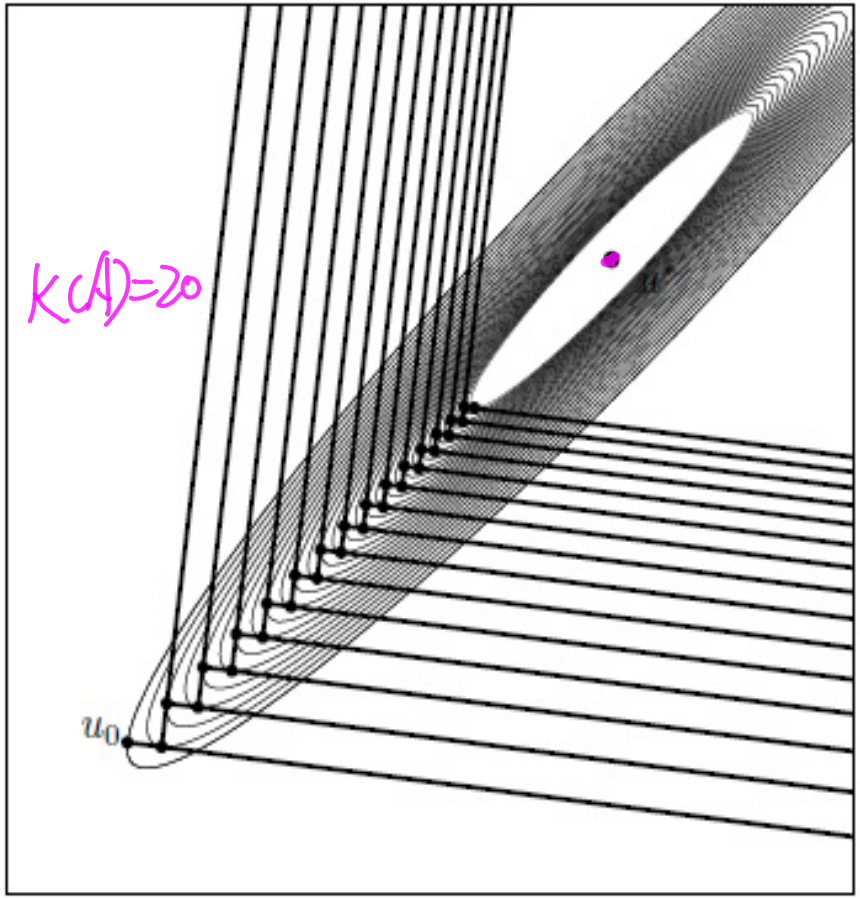

最速下降法和经典迭代法

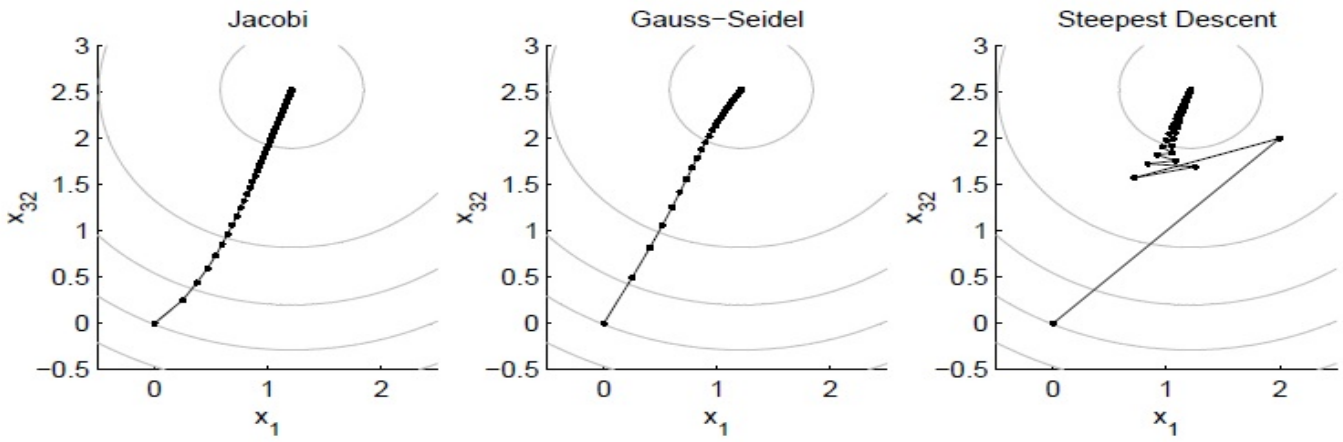

未知数个数为49

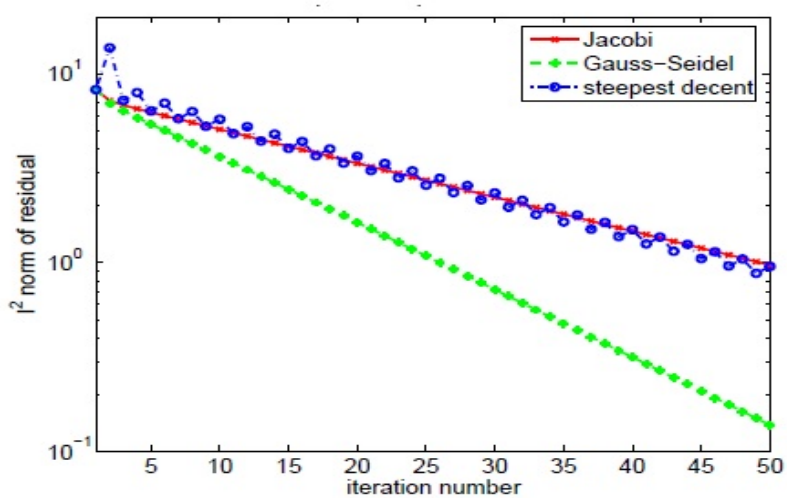

未知数个数为100

共轭梯度法

共轭梯度法又称共轭斜量法，简称CG法(Conjugate Gradient)。

还是采用一维极小搜索的想法：

1. 不再沿着 $\boldsymbol{r}^{(0)},\boldsymbol{r}^{(1)},\cdots$ 方向进行搜索。而是沿着另一组满足某种正交性的向量方向 $\boldsymbol{p}^{(0)},\boldsymbol{p}^{(1)},\cdots$。
2. 设已经沿 $\boldsymbol{p}^{(0)},\boldsymbol{p}^{(1)},\cdots,\boldsymbol{p}^{(k-1)}$ 做了k 次一维搜索，求得了 $\boldsymbol{x}^{(k)}$，$\boldsymbol{r}^{(k)}=\boldsymbol{b}-A\boldsymbol{x}^{(k)}$，确定搜索方向 $\boldsymbol{p}^{(k)}$，再通过求解一维极小问题 $\min\limits_{\alpha}\varphi(\boldsymbol{x}^{(k)}+\alpha\boldsymbol{p}^{(k)})$ 来确定 $\boldsymbol{x}^{(k+1)}$。

亦即

$$\begin{aligned}\frac{d}{d\alpha}\varphi(\boldsymbol{x}^{(k)}+\alpha\boldsymbol{p}^{(k)}) &= 0\Longrightarrow\alpha=\alpha_k=\frac{(\boldsymbol{r}^{(k)},\boldsymbol{p}^{(k)})}{(A\boldsymbol{p}^{(k)},\boldsymbol{p}^{(k)})},\\ \boldsymbol{x}^{(k+1)} &= \boldsymbol{x}^{(k)}+\alpha_k\boldsymbol{p}^{(k)},\\ \boldsymbol{r}^{(k+1)} &= \boldsymbol{b}-A\boldsymbol{x}^{(k+1)}=\boldsymbol{r}^{(k)}-\alpha_kA\boldsymbol{p}^{(k)}.\end{aligned}$$

基本想法

不妨假设 $\boldsymbol{x}^{(0)} = \boldsymbol{0}$, 因而

$$\boldsymbol{x}^{(k+1)} = \alpha_0 \boldsymbol{p}^{(0)} + \alpha_1 \boldsymbol{p}^{(1)} + \cdots + \alpha_k \boldsymbol{p}^{(k)},$$

现在考虑搜索方向 $\boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots$ 的确定方法。

初始取 $\boldsymbol{p}^{(0)} = \boldsymbol{r}^{(0)}$, 一般 $k \geq 1$ 时 $\boldsymbol{p}^{(k)}$ 的确定，不但希望

$$\varphi\left(\boldsymbol{x}^{(k+1)}\right) = \min_{\alpha} \varphi\left(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{p}^{(k)}\right)$$

线搜索 (服前的苟且)

而且希望 $\boldsymbol{p}^{(k)}$ 的选择使得

$$\varphi\left(\boldsymbol{x}^{(k+1)}\right) = \min_{\boldsymbol{x} \in \operatorname{span}\{\boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots, \boldsymbol{p}^{(k)}\}} \varphi(\boldsymbol{x}).$$

全局最优 (诗和远方)

但是

$$\varphi\left(\boldsymbol{x}^{(k+1)}\right) = \frac{1}{2}\left(A\sum_{i=0}^{k}\alpha_i\boldsymbol{p}^{(i)}, \sum_{j=0}^{k}\alpha_j\boldsymbol{p}^{(j)}\right) - \left(\boldsymbol{b}, \sum_{i=0}^{k}\alpha_i\boldsymbol{p}^{(i)}\right)$$

$$= \frac{1}{2}\sum_{i=0}^{k}\sum_{j=0}^{k}\alpha_i\alpha_j(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(j)}) - \sum_{i=0}^{k}\alpha_i(\boldsymbol{b}, \boldsymbol{p}^{(i)}).$$

其中交叉项

$$\alpha_i\alpha_j(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(j)}), \quad i \neq j$$

的存在使得不能直接用线搜索方法来求解，如何去掉这项？

勾股定理？

A-共轭

矩阵 $A \in \mathbb{R}^{n\times n}$ 对称正定，则

$$(\boldsymbol{x},\boldsymbol{y})_A = (A\boldsymbol{x},\boldsymbol{y})$$

定义了一个内积。

定义 (A-共轭)

设 A 对称正定，若 $\mathbb{R}^n$ 中向量组 $\{\boldsymbol{p}^{(0)},\boldsymbol{p}^{(1)},\cdots,\boldsymbol{p}^{(l)}\}$ 满足

$$(A\boldsymbol{p}^{(i)},\boldsymbol{p}^{(j)}) = 0,\ i \neq j.$$

则称它为$\mathbb{R}^n$中的一个*A-共轭向量组*，或称为*A-正交向量组*。

若搜索方向 $\boldsymbol{p}^{(i)}, 0 \leq i \leq k$ 是 A-共轭的，则

$$\varphi(\boldsymbol{x}^{(k+1)}) = \sum_{i=0}^{k}\left(\frac{1}{2}\alpha_i^2(A\boldsymbol{p}^{(i)},\boldsymbol{p}^{i}) - \alpha_i(\boldsymbol{b},\boldsymbol{p}^{(i)})\right).$$

$$
\begin{aligned}
\text{即} \quad & \min_{\boldsymbol{x}\in \mathrm{span}\{\boldsymbol{p}^{(0)},\boldsymbol{p}^{(1)},\cdots,\boldsymbol{p}^{(k)}\}} \varphi(\boldsymbol{x}) \\
= \quad & \sum_{i=0}^{k} \min_{\alpha_i} \left\{ \frac{1}{2}\alpha_i^2 (A\boldsymbol{p}^{(i)},\boldsymbol{p}^{(i)}) - \alpha_i (\boldsymbol{b},\boldsymbol{p}^{(i)}) \right\} \\
= \quad & \sum_{i=0}^{k} \min_{\alpha_i} \varphi_i, \\
\text{这里} \quad \varphi_i \quad = \quad & \frac{1}{2}\alpha_i^2 (A\boldsymbol{p}^{(i)},\boldsymbol{p}^{(i)}) - \alpha_i (\boldsymbol{b},\boldsymbol{p}^{(i)}), \quad 1 \le i \le n.
\end{aligned}
$$

这样就把原来的极小问题分解为 $k+1$ 个一维极小搜索问题。每个一维搜索问题的解为

$$
\min_{\alpha} \varphi_i \Longrightarrow \alpha_i = \frac{(\boldsymbol{b},\boldsymbol{p}^{(i)})}{(A\boldsymbol{p}^{(i)},\boldsymbol{p}^{(i)})}.
$$

注意到 $\boldsymbol{x}^{(k)} \in \operatorname{span}\{\boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots, \boldsymbol{p}^{(k-1)}\}$，而

$$(A\boldsymbol{p}^{(k)}, \boldsymbol{p}^{(i)}) = 0, \quad 0 \le i \le k-1, \Longrightarrow (A\boldsymbol{x}^{(k)}, \boldsymbol{p}^{(k)}) = 0,$$

所以

$$\alpha_k = \frac{(\boldsymbol{b}, \boldsymbol{p}^{(k)})}{(A\boldsymbol{p}^{(k)}, \boldsymbol{p}^{(k)})} = \frac{(\boldsymbol{b} - A\boldsymbol{x}^{(k)}, \boldsymbol{p}^{(k)})}{(A\boldsymbol{p}^{(k)}, \boldsymbol{p}^{(k)})} = \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{p}^{(k)})}{(A\boldsymbol{p}^{(k)}, \boldsymbol{p}^{(k)})}.$$

因此从 $\boldsymbol{x}^{(k)}$ 出发，沿着 $\boldsymbol{p}^{(k)}$ 方向做一维极小搜索，得到

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{p}^{(k)};$$

计算

$$\boldsymbol{r}^{(k+1)} = \boldsymbol{r}^{(k)} - \alpha_k A\boldsymbol{p}^{(k)}.$$

若能确定 $\boldsymbol{p}^{(k+1)}$：使得它与所有 $\boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots, \boldsymbol{p}^{(k)}$ A-正交，则算法可以继续迭代。

动量（Momentum）

- 如何确定 $\boldsymbol{p}^{(k+1)}$？
- Gram-Schmidt 正交化，计算量巨大。

动量

- 在传统的梯度下降法如最速下降法，算法在更新参数时只考虑了当前的梯度，导致在在梯度变化缓慢或出现震荡时收敛很慢。为了解决这个问题，引入了动量的概念。
- 动量方法借鉴了物理中的动量概念，它允许算法积累之前梯度方向的动量，从而加速收敛。动量方法不是仅仅使用当前梯度的信息来更新参数，而是将当前梯度和之前的梯度进行加权平均，这样可以让算法更快地穿越一些平坦的区域，同时还能减少震荡，使得更稳定地收敛。

动量方法的基本思想

1. 累积动量：在每一次迭代中，根据当前的梯度计算一个速度（或动量），这个速度是当前梯度与之前速度的加权和。
2. 更新参数：使用累积的速度来更新参数，而不是直接使用当前的梯度。

动量梯度下降法的更新公式为：

$$\boldsymbol{p}^{(k)} = -\nabla\varphi(\boldsymbol{x}^{(k)}) + \beta_{k-1}\boldsymbol{p}^{(k-1)} = \boldsymbol{r}^{(k)} + \beta_{k-1}\boldsymbol{p}^{(k-1)}.$$

- 通过引入动量，梯度下降法可以更好地利用历史梯度信息，从而提高收敛速度和稳定性，这对于解决复杂的优化问题特别有帮助。
- 在深度学习中，动量方法被广泛应用于各种神经网络模型训练中，以加快模型的收敛速度。

CG 法的搜索方向

CG法中取其为 $\boldsymbol{r}^{(k)}$ 和 $\boldsymbol{p}^{(k-1)}$ 的线性组合：

$$\boldsymbol{p}^{(k)} = \boldsymbol{r}^{(k)} + \beta_{k-1}\boldsymbol{p}^{(k-1)}.$$

而由 $(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k-1)}) = 0$ 可得

$$\beta_{k-1} = -\frac{(\boldsymbol{r}^{(k)}, A\boldsymbol{p}^{(k-1)})}{(\boldsymbol{p}^{(k-1)}, A\boldsymbol{p}^{(k-1)})}.$$

负梯度方向.

$p^{(0)} = r^{(0)}$, $x^{(1)} = x^{(0)} + r^{(0)}$,

$r^{(1)} = b - Ax^{(1)}$, $p^{(1)} = ?$

$p^{(1)} = r^{(1)} + \beta_0 p^{(0)}$

下面是一些有用的性质

$$(\boldsymbol{r}^{(k+1)}, \boldsymbol{p}^{(k)}) = (\boldsymbol{r}^{(k)}, \boldsymbol{p}^{(k)}) - \alpha_k (A\boldsymbol{p}^{(k)}, \boldsymbol{p}^{(k)}) = 0,$$

即剩余向量与一维搜索方向正交。

另外

$$(\boldsymbol{r}^{(k)}, \boldsymbol{p}^{(k)}) = (\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)} + \beta_{k-1}\boldsymbol{p}^{(k-1)}) = (\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)}).$$

于是还有

$$\alpha_k = \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})}.$$

还需验证所有的搜索方向满足

$$(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(j)}) = 0, \quad i \neq j.$$

定理

CG 法有如下的性质

1. $(\boldsymbol{r}^{(i)}, \boldsymbol{r}^{(j)}) = 0, i \neq j$; 即剩余向量构成一个正交向量组。
2. $(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(j)}) = 0, i \neq j$; 即 $\{\boldsymbol{p}^{(k)}\}$ 构成一个A-正交向量组。

证明：归纳法，

$(r^{(1)}, r^{(0)}) = (r^{(1)}, p^{(0)}) = 0$.

$(Ap^{(1)}, p^{(0)}) = 0$ (β_0 待选取)

现假定 $(r^{(i)}, r^{(j)}) = 0$, $(Ap^{(i)}, p^{(j)}) = 0$, $0 \le i, j \le k$, $i \neq j$,

下证 $(r^{(k+1)}, r^{(j)}) = 0$, $(Ap^{(k+1)}, p^{(j)}) = 0$, $0 \le j \le k$.

先证 $(r^{(k+1)}, r^{(j)}) = 0$, $0 \le j \le k$. ($x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$)

$(r^{(k+1)}, r^{(j)}) = (r^{(k)} - \alpha_k A p^{(k)}, r^{(j)})$

$= (r^{(k)}, r^{(j)}) - \alpha_k (Ap^{(k)}, r^{(j)})$.

先考虑 $j=k$, 则

$(r^{(k+1)}, r^{(k)}) = (r^{(k)}, r^{(k)}) - \alpha_k (r^{(k)}, Ap^{(k)})$

令: $\alpha_k = \dfrac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})}$, 若 $(r^{(k)}, Ap^{(k)}) = (p^{(k)}, Ap^{(k)})$

则 $(r^{(k+1)}, r^{(k)}) = 0$ ($p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)}$) ($(p^{(k-1)}, Ap^{(k)}) = 0$)

$(r^{(k)}, Ap^{(k)}) = (p^{(k)} - \beta_{k-1} p^{(k-1)}, Ap^{(k)}) = (p^{(k)}, Ap^{(k)})$

若 $j < k$, 则: $(r^{(k+1)}, r^{(j)}) = (r^{(k)}, r^{(j)}) - \alpha_k (r^{(j)}, Ap^{(k)})$ ($=0$ (归纳假设))

$= -\alpha_k (r^{(j)}, Ap^{(k)}) = -\alpha_k (p^{(j)} - \beta_{j-1} p^{(j-1)}, Ap^{(k)})$

$= 0$ (归纳假设 $j < k$)

则 $(r^{(k+1)}, r^{(j)}) = 0$, $0 \le j \le k$.

$$(p^{(k+1)}, Ap^{(j)}) = (r^{(k+1)} + \beta_k p^{(k)}, Ap^{(j)})$$

$$= (r^{(k+1)}, Ap^{(j)}) + \beta_k (p^{(k)}, Ap^{(j)})$$

首先：$(p^{(k+1)}, Ap^{(k)}) = 0$，（$\beta_k$ 待定）

若 $j < k$，则

$$(p^{(k+1)}, Ap^{(j)}) = (r^{(k+1)}, Ap^{(j)}) + \beta_k (p^{(k)}, Ap^{(j)})$$

（归纳假设）

$$= (r^{(k+1)}, Ap^{(j)})$$

因为：$Ap^{(j)} = \frac{1}{\alpha_j}(r^{(j)} - r^{(j+1)})$ $\left(r^{(j+1)} = r^{(j)} - \alpha_j Ap^{(j)}\right)$

则：$(r^{(k+1)}, Ap^{(j)}) = \frac{1}{\alpha_j}(r^{(k+1)}, r^{(j)} - r^{(j+1)}) = 0$，$j < k$.

则：$(Ap^{(k+1)}, p^{(j)}) = 0$，$0 \le j \le k$.

证

由上面的推导，还可以简化 β_k 的计算

$$\begin{aligned}\beta_k &= -\frac{(\boldsymbol{r}^{(k+1)}, A\boldsymbol{p}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})} \\ &= -\frac{(\boldsymbol{r}^{(k+1)}, \alpha_k^{-1}(\boldsymbol{r}^{(k)} - \boldsymbol{r}^{(k+1)}))}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})} \\ &= \frac{\alpha_k^{-1}(\boldsymbol{r}^{(k+1)}, \boldsymbol{r}^{(k+1)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})}.\end{aligned}$$

$Ap^{(k)} = \frac{1}{\alpha_k}(r^{(k)} - r^{(k+1)})$

$(r^{(k+1)}, r^{(k)}) = 0.$

由于

$$\alpha_k = \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})},$$

故而

$$\beta_k = \frac{(\boldsymbol{r}^{(k+1)}, \boldsymbol{r}^{(k+1)})}{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})} = \frac{\|\boldsymbol{r}^{(k+1)}\|_2^2}{\|\boldsymbol{r}^{(k)}\|_2^2}.$$

算法 (共轭梯度法)

1. 任取 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$,
2. $\boldsymbol{r}^{(0)} = \boldsymbol{b} - A\boldsymbol{x}^{(0)}$, $\boldsymbol{p}^{(0)} = \boldsymbol{r}^{(0)}$;
3. 对 $k = 0, 1, \cdots$

$$
\begin{aligned}
\alpha_k &= \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})} \\
\boldsymbol{x}^{(k+1)} &= \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{p}^{(k)} \\
\boldsymbol{r}^{(k+1)} &= \boldsymbol{r}^{(k)} - \alpha_k A\boldsymbol{p}^{(k)} \\
\beta_k &= \frac{(\boldsymbol{r}^{(k+1)}, \boldsymbol{r}^{(k+1)})}{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})} \\
\boldsymbol{p}^{(k+1)} &= \boldsymbol{r}^{(k+1)} + \beta_k \boldsymbol{p}^{(k)}
\end{aligned}
$$

在计算的过程中，当 $\|\boldsymbol{r}^{(k)}\| \leq \epsilon$ 时计算中止。

经过 CG 法的迭代，近似解

$$\boldsymbol{x}^{(k)} = \boldsymbol{x}^{(0)} + \sum_{i=0}^{k-1} \alpha_i \boldsymbol{p}^{(i)} = \boldsymbol{x}^{(0)} + \sum_{i=0}^{k-1} \frac{(\boldsymbol{r}^{(i)}, \boldsymbol{r}^{(i)})}{(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(i)})} \boldsymbol{p}^{(i)}.$$

因此

$$\boldsymbol{e}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^* = \boldsymbol{e}^{(0)} + \sum_{i=0}^{k-1} \frac{(\boldsymbol{r}^{(i)}, \boldsymbol{r}^{(i)})}{(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(i)})} \boldsymbol{p}^{(i)}.$$

又

$$\begin{aligned} (\boldsymbol{r}^{(i)}, \boldsymbol{r}^{(i)}) &= (\boldsymbol{r}^{(i)}, \boldsymbol{p}^{(i)}) = (\boldsymbol{r}^{(i-1)} - \alpha_{i-1} A\boldsymbol{p}^{(i-1)}, \boldsymbol{p}^{(i)}) \\ &= (\boldsymbol{r}^{(i-1)}, \boldsymbol{p}^{(i)}) = \cdots = (\boldsymbol{r}^{(0)}, \boldsymbol{p}^{(i)}) \\ &= -(A\boldsymbol{e}^{(0)}, \boldsymbol{p}^{(i)}). \end{aligned}$$

所以

$$\alpha_i = -\frac{(A\boldsymbol{e}^{(0)}, \boldsymbol{p}^{(i)})}{(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(i)})}.$$

亦即

$$\begin{aligned} \boldsymbol{e}^{(k)} &= \boldsymbol{e}^{(0)} + \sum_{i=0}^{k-1} \alpha_i \boldsymbol{p}^{(i)} \\ &= \boldsymbol{e}^{(0)} - \sum_{i=0}^{k-1} \frac{(A\boldsymbol{e}^{(0)}, \boldsymbol{p}^{(i)})}{(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(i)})} \boldsymbol{p}^{(i)}, \end{aligned}$$

而

$$\frac{(A\boldsymbol{e}^{(0)}, \boldsymbol{p}^{(i)})}{(A\boldsymbol{p}^{(i)}, \boldsymbol{p}^{(i)})} \boldsymbol{p}^{(i)}$$

是初始误差 $\boldsymbol{e}^{(0)} = \boldsymbol{x}^{(0)} - \boldsymbol{x}^*$ 在 $\boldsymbol{p}^{(i)}$ 上的 A-内积下的正交投影。

$\boldsymbol{e}^{(k)}$ 是初始误差 $\boldsymbol{e}^{(0)}$ 依次减去在 $\boldsymbol{p}^{(0)}, \cdots, \boldsymbol{p}^{(k-1)}$ 上的正交投影得到的。 这说明 $\boldsymbol{x}^{(k)}$ 是 $\boldsymbol{x}^*$ 在子空间 $\mathrm{span}\{\boldsymbol{p}^{(0)}, \cdots, \boldsymbol{p}^{(k-1)}\}$ 上的 A-内积下的正交投影。

作为迭代法的CG法

- 由于剩余向量相互正交，而 $\mathbb{R}^n$ 中至多只有 n 个相互正交的非零向量，所以 $\boldsymbol{r}^{(0)}, \boldsymbol{r}^{(1)}, \cdots, \boldsymbol{r}^{(n)}$ 中至少有一个为零。
- 若 $\boldsymbol{r}^{(k)} = \boldsymbol{0}$，则有 $\boldsymbol{x}^{(k)} = \boldsymbol{x}^* = A^{-1}\boldsymbol{b}$ 为精确解。所以理论上用 CG 法求解，至多 n 步便可得到精确解。
- 实际上理论上CG法只需要 m 步即可收敛，其中 m 是矩阵 $A \in \mathbb{R}^{n\times n}$ 的不同的特征值的数目。但由于舍入误差的存在，只能把它作为一个迭代法来处理。
- 另一方面在实际计算的时候在一定的精度要求下，CG只需要远远少于 n 的迭代次就可以收敛到 $\boldsymbol{x}^*$。
  - 如用5点格式在 100×100 的网格上求解 Poisson方程得到阶数为 $n = 10000$ 的矩阵 A，A 有 $m \approx 5000$ 个不同的特征值。得到和差分方程的离散误差同阶的近似解只需要144次迭代。

定理

设 $A \in \mathbb{R}^{n\times n}$ 对称正定，$\boldsymbol{x}^{(0)} = \boldsymbol{0}$，则由*CG*法生成的下面的几个 $\mathbb{R}^n$ 的子空间相等：

$$\operatorname{span}\{\boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots, \boldsymbol{p}^{(k-1)}\}, \qquad \operatorname{span}\{\boldsymbol{r}^{(0)}, \boldsymbol{r}^{(1)}, \cdots, \boldsymbol{r}^{(k-1)}\},$$

$$\operatorname{span}\{\boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \cdots, \boldsymbol{x}^{(k)}\}, \qquad \operatorname{span}\{\boldsymbol{b}, A\boldsymbol{b}, A^2\boldsymbol{b}, \cdots, A^{k-1}\boldsymbol{b}\}.$$

证明：$x^{(k)} = \sum_{i=0}^{k-1} \alpha_i p^{(i)}$，$x^{(1)} = \alpha_0 p^{(0)}$，$x^{(2)} = \alpha_0 p^{(0)} + \alpha_1 p^{(1)}$

则：$\operatorname{span}(p^{(0)}, p^{(1)}, \cdots p^{(k-1)}) = \operatorname{span}(x^{(1)}, x^{(2)}, \cdots x^{(k)})$

同理：$p^{(0)} = r^{(0)}$，

$p^{(i)} = r^{(i)} - \beta_{i-1} p^{(i-1)}$.

则：$\operatorname{span}(p^{(0)}, \cdots p^{(k-1)}) = \operatorname{span}(r^{(0)}, r^{(1)}, \cdots r^{(k-1)})$.

$p^{(0)} = r^{(0)} = b$.

$x^{(0)} = 0$

因为 $x^{(0)} = 0$，则

$r^{(0)} = b - Ax^{(0)} = b$,

$r^{(1)} = b - Ax^{(1)} = b - A(x^{(0)} + \alpha_0 p^{(0)})$

$= b - \alpha_0 A p^{(0)} = b - \alpha_0 A b$

$r^{(2)} = r^{(1)} - \alpha_1 A p^{(1)} = b - \alpha_0 Ab - \alpha_1 A(r^{(1)} + \beta_0 r^{(0)})$

$= b - \alpha_0 Ab - \alpha_1 A(b - \alpha_0 Ab + \beta_0 b)$

$= b - (\alpha_0 + \alpha_1 + \alpha_1\beta_0)Ab + \alpha_1\alpha_0 A^2 b$.

$\cdots$

$r^{(k-1)} = b - \cdots Ab + \cdots + A^{k-1} b$

$= \mathcal{P}_{k-1}(A)\, b$

定义 (Krylov子空间)

由向量 $\boldsymbol{b}$ 和矩阵 A 生成的子空间

$$\mathcal{K}_k = \mathrm{span}\{\boldsymbol{b}, A\boldsymbol{b}, A^2\boldsymbol{b}, \cdots, A^{k-1}\boldsymbol{b}\}$$

称为*Krylov子空间*。

Krylov子空间方法的理论基础是Cayley-Hamilton定理。

定义 (零化多项式–annihilation polynomial)

设 $A \in \mathbb{C}^{n\times n}$，若多项式 $g(z)$ 使得 $g(A) = \mathbf{O}$，则称 $g(z)$ 为 A 的零化多项式。

定理 (Cayley-Hamilton)

设 $A \in \mathbb{C}^{n\times n}$，则 A 的特征多项式 $\chi(z)$ 是A 的零化多项式。

$\chi(A)=0$.

若 A 的特征多项式 $\chi(z)$ 为：

$$\chi(z) = z^n + c_{n-1}z^{n-1} + \cdots + c_1 z + c_0, \quad c_0 = (-1)^n \det(A).$$

若 A 非奇异，则 $c_0 \neq 0$：

$$\chi(A) = A^n + c_{n-1}A^{n-1} + \cdots + c_1 A + c_0 I = 0,$$

有

$$A^{-1} = -\frac{1}{c_0}A^{n-1} - \frac{c_{n-1}}{c_0}A^{n-2} - \cdots - \frac{c_1}{c_0}I. = P_{n-1}(A)$$

因此方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 的解 $\boldsymbol{x}$ 可表示为

$$\begin{aligned} \boldsymbol{x} &= A^{-1}\boldsymbol{b} = -\frac{1}{c_0}A^{n-1}\boldsymbol{b} - \frac{c_{n-1}}{c_0}A^{n-2}\boldsymbol{b} - \cdots - \frac{c_1}{c_0}\boldsymbol{b} \\ &= P_{n-1}(A)\boldsymbol{b} \in \mathcal{K}_{n-1}. \end{aligned}$$

Krylov 子空间方法

但是 $\dim \mathcal{K}_{n-1} = n$ 太大，考虑用 Krylov 子空间方法得到的近似解：

$$A^{-1}\boldsymbol{b} \approx \boldsymbol{x}^{(k)} = \boldsymbol{x}^{(0)} + P_{k-1}(A)\boldsymbol{r}^{(0)},$$

这里 P_{k-1} 是次数 $k-1$ 的多项式，若 $\boldsymbol{x}^{(0)} = \boldsymbol{0}$，则

$$A^{-1}\boldsymbol{b} \approx P_{k-1}(A)\boldsymbol{b}.$$

换言之，用 $k-1$ 次多项式逼近 $n-1$ 次多项式，即

$$\boldsymbol{x}^{(k)} = P_{k-1}(A)\boldsymbol{b} \approx \boldsymbol{x}^{*} = P_{n-1}(A)\boldsymbol{b} = A^{-1}\boldsymbol{b}.$$

注记

*CG*法等价于在 *Krylov* 子空间 $\mathcal{K}_k$ 上极小化 $\varphi(\boldsymbol{x})$。

定义 (A-范数)

设 $A \in \mathbb{R}^{n\times n}$ 是对称正定矩阵(SPD)，则 $\boldsymbol{x} \in \mathbb{R}^n$ 的A-范数定义为

$$\|\boldsymbol{x}\|_A = (A\boldsymbol{x}, \boldsymbol{x})^{1/2}.$$

这是一个很自然的范数定义，因为

$$\begin{aligned} \|\boldsymbol{e}\|_A^2 &= \|\boldsymbol{x} - \boldsymbol{x}^*\|_A^2 \\ &= (A(\boldsymbol{x} - \boldsymbol{x}^*), \boldsymbol{x} - \boldsymbol{x}*) \\ &= (A\boldsymbol{x}, \boldsymbol{x}) - 2(A\boldsymbol{x}, \boldsymbol{x}^*) + (A\boldsymbol{x}^*, \boldsymbol{x}^*) \\ &= 2\varphi(\boldsymbol{x}) + (A\boldsymbol{x}^*, \boldsymbol{x}^*). \end{aligned}$$

注记

因为 $(A\boldsymbol{x}^*, \boldsymbol{x}^*)$ 是常数，因而极小化 $\|\boldsymbol{e}\|_A$ 和极小化 $\varphi(\boldsymbol{x})$ 等价。

共轭梯度法的迭代次数

对共轭梯度法有

$$\|\boldsymbol{e}_k\|_A \le 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k \|\boldsymbol{e}_0\|_A, \qquad \kappa = \frac{\lambda_n}{\lambda_1} = \mathrm{cond}_2(A).$$

当 $\kappa \gg 1$ 时渐近有

$$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k = 2\left(1-\frac{2}{\sqrt{\kappa}}\right)^k \approx 2e^{-2k/\sqrt{\kappa}}.$$

迭代解要有精度，则

$$e^{-2k/\sqrt{\kappa}} \ll 1,$$

所以在实际计算的时迭代次数应该为

$$k = O(\sqrt{\kappa}).$$

$K = 10^{20}$

$k \sim 10^{10}$

数学家简介 (哈密尔顿(Hamilton))

哈密尔顿 *(1805–1865)*，英国数学家，物理学家，力学家。他的研究工作涉及不少领域，成果最大的是光学、力学和四元数。哈密顿主要是数学家，但在科学史中影响最大的却是他对力学的贡献。

哈密顿量是现代物理最重要的量。哈密顿发展了分析力学。*1834*年，建立了著名的哈密顿原理，使各种动力学定律都可以从一个变分式推出。根据这一原理，力学与几何光学有相似之处。后来发现，这一原理又可推广到物理学的许多领域，如电磁学等。他把广义坐标和广义动量都作为独立变量来处理动力学方程获得成功，这种方程现称哈密顿正则方程。他还建立了一个与能量有密切联系的哈密顿函数。他解释了锥形折射现象，对现代矢量分析方法的建立作出了贡献。他还创立了四元数。这些成果在现代物理学中都有广泛应用。

哈密顿在数学上的成就，以微分方程和泛函分析两个领域最为突出，如哈密顿算符、哈密顿—雅可比方程等；此外，他对波形曲面的研究，对伽罗瓦理论的补充以及在数学中引入结合律等也都是他的功绩。

四种迭代法收敛速度比较

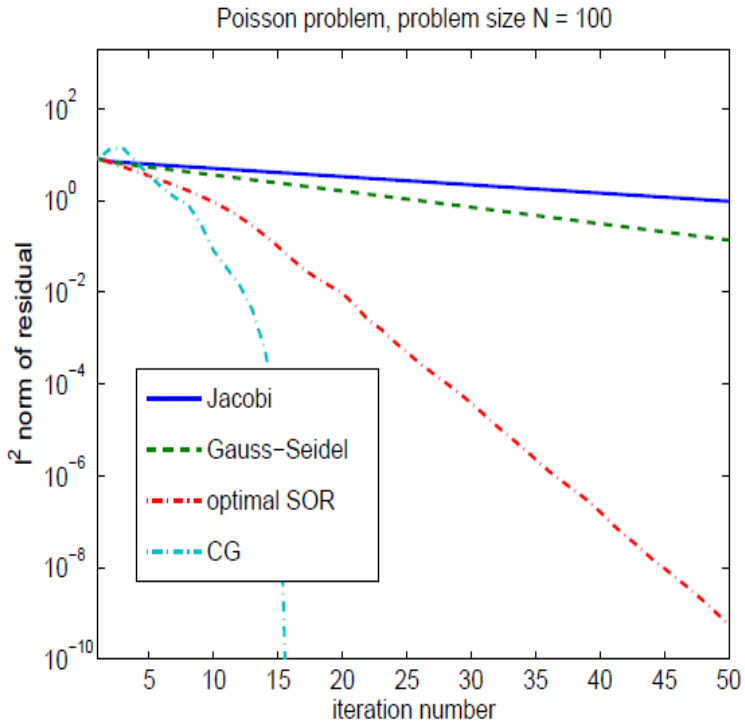

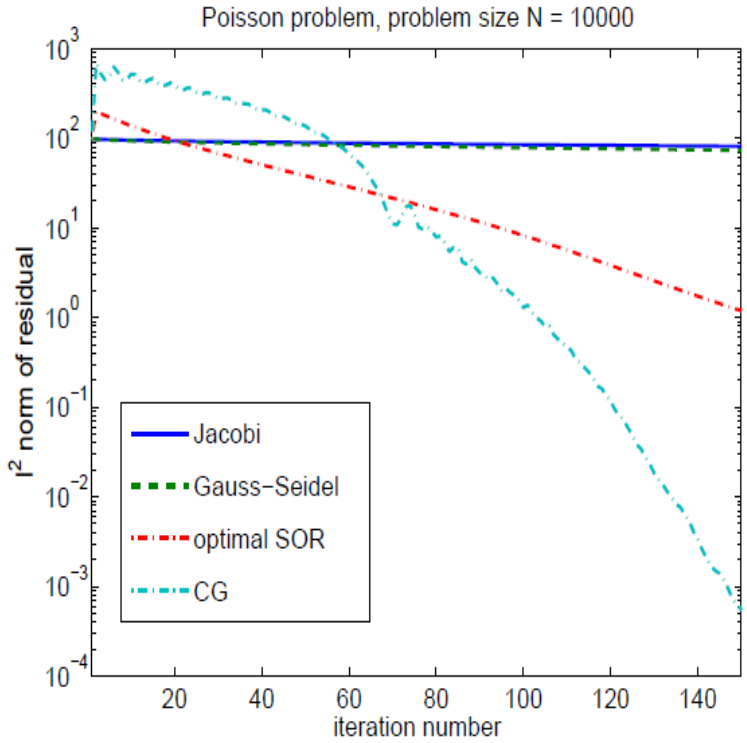

预处理CG法

CG法的收敛速度依赖于矩阵的条件数，当条件数很大时收敛速度很慢，此时需要做预处理。

$$Ax = b \Leftrightarrow M_1^{-1}AM_2^{-1}y = M_1^{-1}b,\ x = M_2^{-1}y.$$

预处理 CG 法一个可能的问题为 $M^{-1}A$ 可能不是对称正定的即使 M^{-1} 和 A 是，此时CG法对 预处理后的系统不适用。

因此考虑和原方程等价的方程组：

$$L^{-1}AL^{-\mathsf{T}}(L^{\mathsf{T}}x) = L^{-1}b \Leftrightarrow Fy = g$$

其中

$$y = L^{\mathsf{T}}x,\quad g = L^{-1}b,\quad F = L^{-1}AL^{-\mathsf{T}}.$$

预处理后的系数矩阵仍然是对称正定阵，CG法适用。但在实际计算的时候，一般不显式计算 F。

形式上，预处理的共轭梯度法可写为：

- 任取初值 $\boldsymbol{y}^{(0)}$，$\tilde{\boldsymbol{r}}^{(0)} = \boldsymbol{g} - F\boldsymbol{y}^{(0)}$；
- 对 $k = 1, 2, \cdots,$

$$
\begin{aligned}
\tilde{\alpha}_k &= \frac{(\tilde{\boldsymbol{r}}^{(k)}, \tilde{\boldsymbol{r}}^{(k)})}{(\tilde{\boldsymbol{p}}^{(k)}, F\tilde{\boldsymbol{p}}^{(k)})}, \\
\boldsymbol{y}^{(k+1)} &= \boldsymbol{y}^{(k)} + \tilde{\alpha}_k \tilde{\boldsymbol{p}}^{(k)}, \\
\tilde{\boldsymbol{r}}^{(k+1)} &= \tilde{\boldsymbol{r}}^{(k)} - \tilde{\alpha}_k F\tilde{\boldsymbol{p}}^{(k)}, \\
\tilde{\beta}_k &= \frac{(\tilde{\boldsymbol{r}}^{(k+1)}, \tilde{\boldsymbol{r}}^{(k+1)})}{(\tilde{\boldsymbol{r}}^{(k)}, \tilde{\boldsymbol{r}}^{(k)})}, \\
\tilde{\boldsymbol{p}}^{(k+1)} &= \tilde{\boldsymbol{r}}^{(k+1)} + \tilde{\beta}_k \tilde{\boldsymbol{p}}^{(k)}.
\end{aligned}
$$

$Fy = g$

$F = L^{-1} A L^{-T}$

$y = L^T x$

$g = L^{-1} b$

注记

从形式上看需要计算 L^{-1} 及 L，但是把上面的计算过程变回到原来的变量发现只需要计算 $M = LL^T$。

考察原变量和预处理后的量之间的关系，令 $\boldsymbol{x}^{(k)} = L^{-T}\boldsymbol{y}^{(k)}$，则

$$\begin{aligned}\tilde{\boldsymbol{r}}^{(k)} &= \boldsymbol{g} - F\boldsymbol{y}^{(k)} = L^{-1}(\boldsymbol{b} - AL^{-T}L^{T}\boldsymbol{x}^{(k)}) \\ &= L^{-1}\boldsymbol{r}^{(k)},\end{aligned}$$

再令

$$\begin{aligned}\boldsymbol{p}^{(k)} &= L^{-T}\tilde{\boldsymbol{p}}^{(k)} \Longleftrightarrow \tilde{\boldsymbol{p}}^{(k)} = L^{\mathsf{T}}\boldsymbol{p}^{(k)}, \\ \boldsymbol{p}^{(0)} &= L^{-T}L^{-1}\boldsymbol{r}^{(0)}.\end{aligned}$$

记

$$\boldsymbol{z}^{(k)} = L^{-T}L^{-1}\boldsymbol{r}^{(k)} = M^{-1}\boldsymbol{r}^{(k)} \Longleftrightarrow M\boldsymbol{z}^{(k)} = \boldsymbol{r}^{(k)}.$$

实际上可以把预处理共轭梯度法改写为原变量的表达式。

$$(\tilde{\boldsymbol{r}}^{(k)}, \tilde{\boldsymbol{r}}^{(k)}) = (L^{-1}\boldsymbol{r}^{(k)}, L^{-1}\boldsymbol{r}^{(k)}) = (L^{-\mathsf{T}}L^{-1}\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)}) = (\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)}).$$

同时

$$\begin{aligned}(\tilde{\boldsymbol{p}}^{(k)}, F\tilde{\boldsymbol{p}}^{(k)}) &= (L^{\mathsf{T}}\boldsymbol{p}^{(k)}, L^{-1}AL^{-\mathsf{T}}L^{\mathsf{T}}\boldsymbol{p}^{(k)}) = (L^{\mathsf{T}}\boldsymbol{p}^{(k)}, L^{-1}A\boldsymbol{p}^{(k)}) \\ &= (\boldsymbol{p}^{(k)}, LL^{-1}A\boldsymbol{p}^{(k)}) = (\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)}).\end{aligned}$$

则

$$\tilde{\alpha}_k = \frac{(\tilde{\boldsymbol{r}}^{(k)}, \tilde{\boldsymbol{r}}^{(k)})}{(\tilde{\boldsymbol{p}}^{(k)}, F\tilde{\boldsymbol{p}}^{(k)})} = \frac{(\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})}.$$

$M\boldsymbol{z}^{(k)} = \boldsymbol{r}^{(k)}$

$\boldsymbol{z}^{(k)} = M^{-1}\boldsymbol{r}^{(k)}$

同理

$$\tilde{\beta}_k = \frac{(\tilde{\boldsymbol{r}}^{(k+1)}, \tilde{\boldsymbol{r}}^{(k+1)})}{(\tilde{\boldsymbol{r}}^{(k)}, \tilde{\boldsymbol{r}}^{(k)})} = \frac{(\boldsymbol{z}^{(k+1)}, \boldsymbol{r}^{(k+1)})}{(\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)})}.$$

则预处理共轭梯度法可改写为更好的形式。

预处理共轭梯度法

算法 (预处理共轭梯度法)

1. 任取 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$,
2. $\boldsymbol{r}^{(0)} = \boldsymbol{b} - A\boldsymbol{x}^{(0)}$, $\boldsymbol{z}^{(0)} = M^{-1}\boldsymbol{r}^{(0)}$, $\boldsymbol{p}^{(0)} = \boldsymbol{z}^{(0)}$,
3. 对 $k = 1, 2, \cdots$ 有

$$
\begin{aligned}
\alpha_k &= \frac{(\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{p}^{(k)}, A\boldsymbol{p}^{(k)})}, \\
\boldsymbol{x}^{(k+1)} &= \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{p}^{(k)}, \\
\boldsymbol{r}^{(k+1)} &= \boldsymbol{r}^{(k)} - \alpha_k A\boldsymbol{p}^{(k)}, \\
\text{求解 } M\boldsymbol{z}^{(k+1)} &= \boldsymbol{r}^{(k+1)}, \quad \rightarrow \text{预处理}. \\
\beta_k &= \frac{(\boldsymbol{z}^{(k+1)}, \boldsymbol{r}^{k+1})}{(\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)})}, \\
\boldsymbol{p}^{(k+1)} &= \boldsymbol{z}^{(k+1)} + \beta_k \boldsymbol{p}^{(k)}.
\end{aligned}
$$

不完全Cholesky分解

当 $LL^{\mathsf{T}} \approx A$ 时有

$$F \approx L^{-1}(LL^{\mathsf{T}})L^{-\mathsf{T}} = I \Rightarrow cond(F) \approx 1.$$

一般可以考虑 A 的一种分裂

$$A = M - N, \quad M = LL^{\mathsf{T}} \quad (SPD),$$

N 尽可能小，这称为 A 的不完全Cholesky分解。

M 的最简单的选择是对角阵。

$$A = D - L - U,$$

令 $M = D$ 为Jacobi迭代的预处理矩阵，则

$$L = L^{\mathsf{T}} = \mathrm{diag}(\sqrt{a_{11}}, \sqrt{a_{22}}, \cdots, \sqrt{a_{nn}}).$$

Incomplete Cholesky factorization

无填充的不完全 Cholesky分解是只有相对应 A 的非零元处非零的分解。虽然 LL^T 和不一样，但是 $\|A - LL^T\|$ 一般比较小。

- L = ichol(A) performs the incomplete Cholesky factorization of A with zero-fill.
- L = ichol(A,opts) performs the incomplete Cholesky factorization of A with options specified by opts.

```
A = delsq(numgrid('S',100));
» condest(A)
ans =5.7750e+03
» L=ichol(A);
» L1=inv(L);
» B=L1*A*L1';
» condest(B)
ans =828.3369
```

Matlab的ichol函数

```
>> n = size(A,1);
ntols = 20;
droptol = logspace(-8,0,ntols);
nrm = zeros(1,ntols);
nz = zeros(1,ntols);
nzComplete = nnz(chol(A,'lower'));
for k = 1:ntols
    L = ichol(A,struct('type','ict','droptol',droptol(k)));
    nz(k) = nnz(L);
    nrm(k) = norm(A-L*L','fro')./norm(A,'fro');
end
figure
loglog(droptol,nrm,'LineWidth',2)
title('Drop tolerance vs norm(A-L*L'',''fro'')./norm(A,''fro'')')
figure
semilogx(droptol,nz./nzComplete,'LineWidth',2)
title('Drop tolerance vs fill ratio ichol/chol')
```

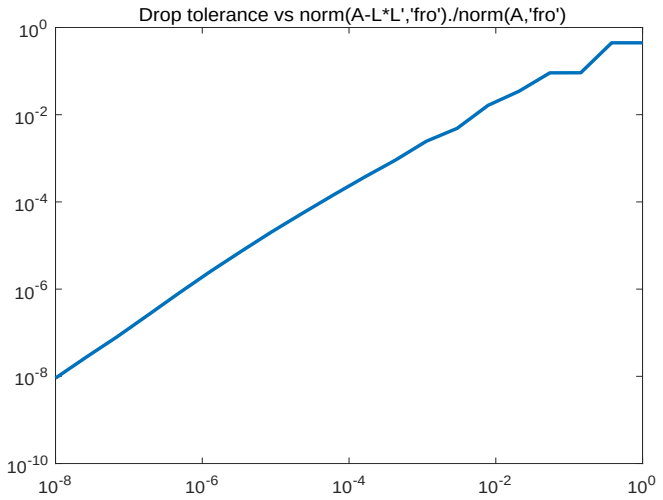

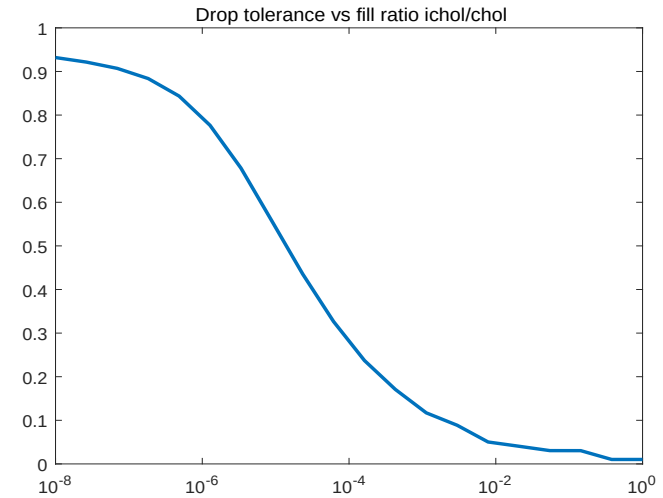

Matlab的pcg

```
>> A = delsq(numgrid('S',100));
b = ones(size(A,1),1);
[x0,fl0,rr0,it0,rv0] = pcg(A,b,1e-8,100);
>> L = ichol(A);
[x1,fl1,rr1,it1,rv1] = pcg(A,b,1e-8,100,L,L');
>> L = ichol(A,struct('michol','on'));
[x2,fl2,rr2,it2,rv2] = pcg(A,b,1e-8,100,L,L');
>> figure;
semilogy(0:it0,rv0/norm(b),'b.');
hold on;
semilogy(0:it1,rv1/norm(b),'r.');
semilogy(0:it2,rv2/norm(b),'k.');
legend('No Preconditioner','IC(0)','MIC(0)');
xlabel('iteration number');
ylabel('relative residual');
hold off;
```

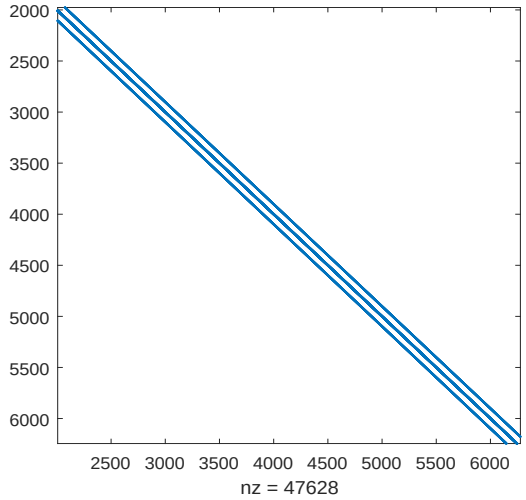

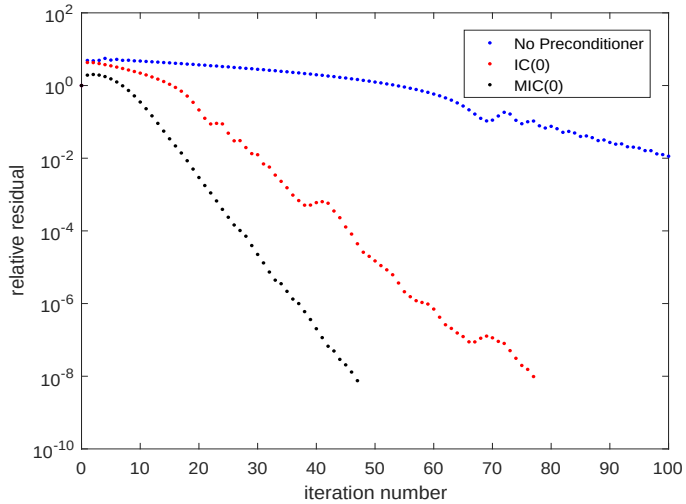

SSOR 预处理

可取 M 为 SSOR 迭代法的预处理矩阵

$$M_{SSOR} = SS^{\mathsf{T}},$$

其中

$$S = [\omega(2-\omega)]^{-1/2}(D - \omega L)D^{-1/2},$$

则 $F = S^{-1}AS^{-\mathsf{T}}$ 的条件数大约为 $O(\sqrt{\kappa})$， κ 是 A 的条件数。

注记

在预处理时，求解 $M\boldsymbol{z} = \boldsymbol{r}$ 要比 $A\boldsymbol{x} = \boldsymbol{b}$ 容易求解得多。

当 $M = I$ 时，$\boldsymbol{z}^{(k)} = \boldsymbol{r}^{(k)}$。 $M = A$ 时，CG 法一步收敛，但

$$M\boldsymbol{z} = \boldsymbol{r} \Longleftrightarrow A\boldsymbol{x} = \boldsymbol{b}.$$

不完全LU分解

» load west0479;
A=west0479;
» condest(A)
ans =
1.4244e+12
» [L,U] = ilu(A,struct('type','ilutp','droptol',1e-5));
错误使用 ilu
存在等于零的主元。请考虑减小调降公差或考虑使用 'udiag' 选项。
» [L,U,P]= ilu(A,struct('type','ilutp','droptol',1e-6));
» L1=inv(L);
U1=inv(U);
» B=L1*P*A*U1; » condest(B)
ans =
42.7119

图: 用 ilu作预处理

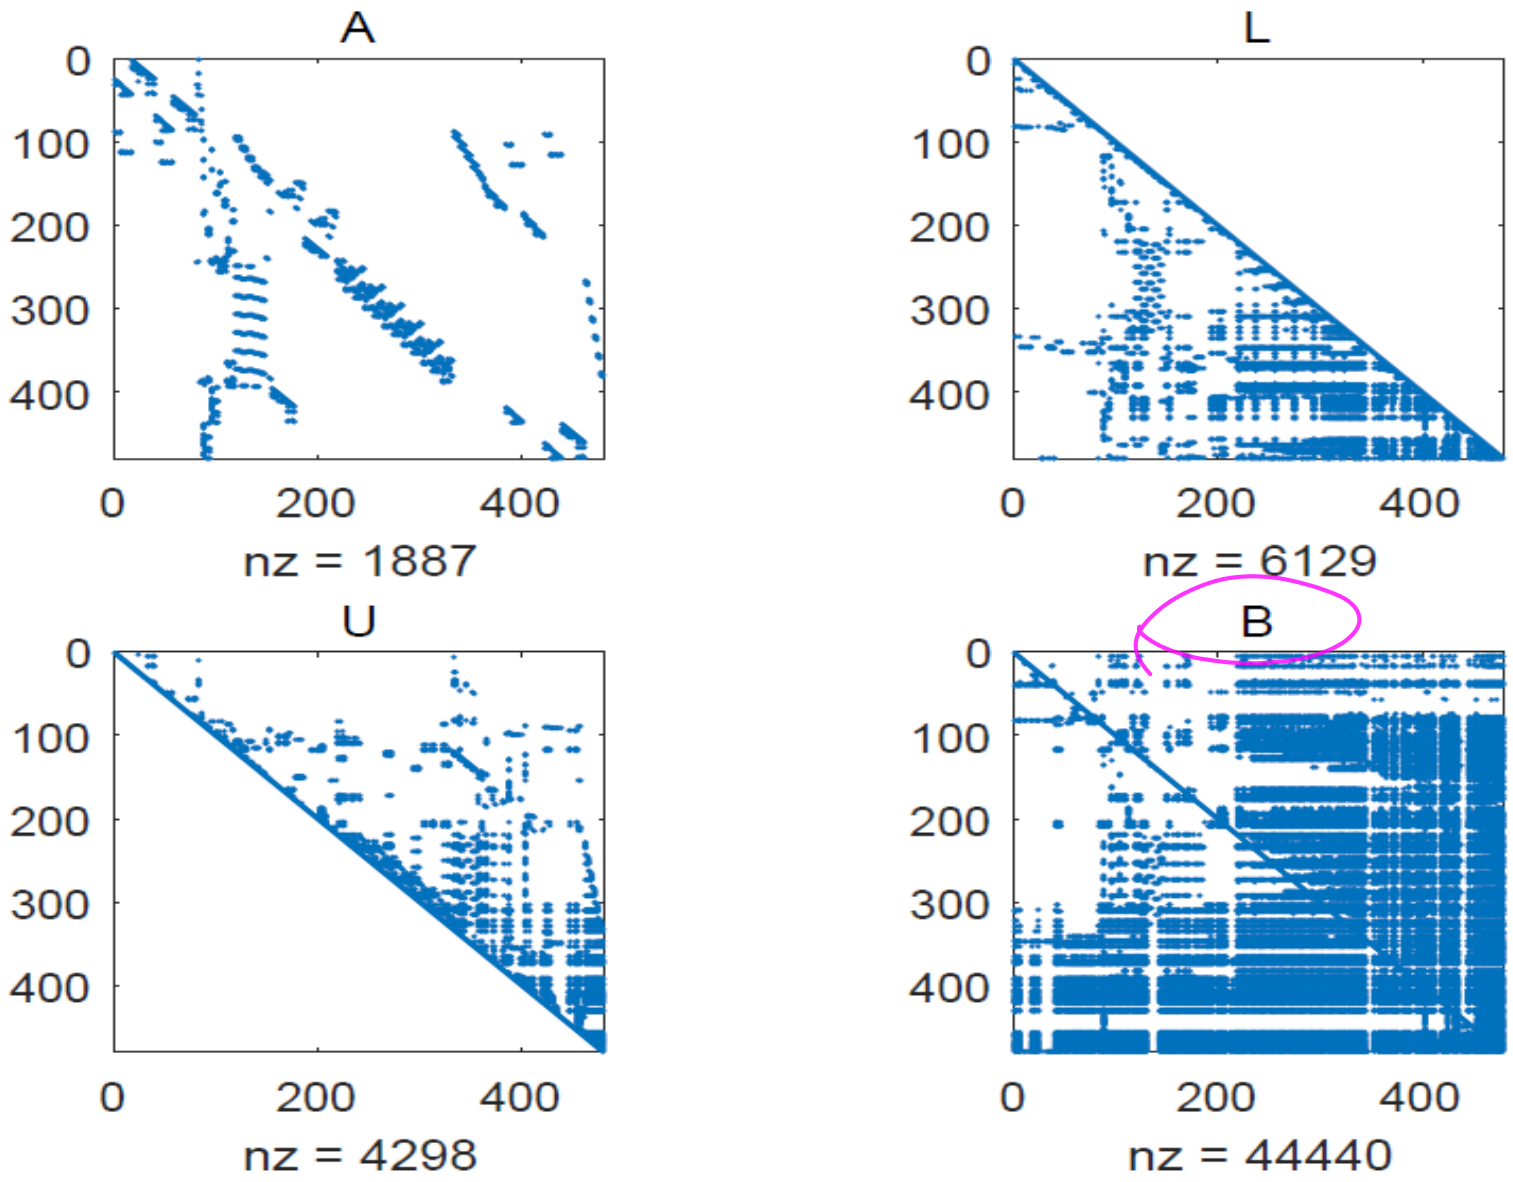
A
0
100
200
300
400
0
200
400
nz = 1887
L
0
100
200
300
400
0
200
400
nz = 6129
U
0
100
200
300
400
0
200
400
nz = 4298
B
0
100
200
300
400
0
200
400
nz = 44440