第八章 函数逼近

殷东生
yindongsheng@tsinghua.edu.cn

清华大学数学基础教学中心

2025年秋季学期

函数逼近

函数逼近指的是用简单的函数（通常是易于计算或者具有良好数学性质的函数）来近似复杂的函数，使得在某个特定的意义下（在某种范数下），近似函数与原函数的误差足够小。

数学上，设 X 是区间 $[a,b]$ 某类函数组成的线性空间，M 为 X 的一个子空间。函数逼近问题可以叙述如下：

函数逼近

设 $f \in X$，求 $p \in M$ 使得

$$\|p - f\| = \min_{s \in M} \|f - s\|.$$

其中 $\|\cdot\|$ 是一种范数。

函数逼近在数据分析和系统建模中发挥着关键作用：

1) 数据拟合与回归分析：

- 在统计学中，函数逼近用于回归分析，以预测或估计因变量与自变量之间的关系。
- 用于曲线拟合，通过找到最佳拟合曲线来描述数据点之间的关系。

2) 时间序列预测：

- 在经济学、金融学和气象学等领域，函数逼近用于预测时间序列数据，如股票价格、气温变化等。

3) 信号处理：

- 在数字信号处理中，函数逼近用于信号重建、去噪和压缩。
- 用于滤波器设计，以逼近理想的频率响应。

4) 系统控制：在控制工程中，函数逼近用于建立系统的数学模型，以便进行控制器设计。用于非线性系统的控制和仿真。

5) 机器学习与人工智能：

- 在机器学习中，函数逼近是许多算法的核心，如神经网络、支持向量机（SVM）和核方法。
- 用于分类、聚类、降维和特征学习。

6) 图像处理：

- 在图像处理中，函数逼近用于图像重建、图像压缩和图像识别。
- 用于边缘检测、图像分割和图像增强。

7) 工程设计与模拟：

- 在工程设计中，函数逼近用于模拟和分析系统的行为，如结构分析、流体动力学模拟等。

8) 经济学与社会科学：

- 在经济学中，函数逼近用于建立经济模型，预测经济指标。
- 在社会科学研究中，用于分析社会现象和人类行为。

函数逼近方法

1. 多项式： $M = \mathcal{P}_n([a,b])$；
2. 三角函数：e^{ikx}, $sinkx$, $coskx$, $k = 0, 1, \cdots$， 傅里叶级数；
3. 有理多项式：

$$\frac{p_m(x)}{q_n(x)}, p_m \in \mathcal{P}_m([a,b]),\ q_n \in \mathcal{P}_n([a,b]).$$

4. 样条函数逼近：样条函数来逼近原函数；
5. 小波逼近：使用小波函数的线性组合来逼近函数，小波函数具有良好的时频局部化特性；
6. 神经网络逼近：人工神经网络构建的近似模型有很好的通用性和灵活性，能够处理各种类型的数据，并学习数据中的复杂模式；但需要海量的数据进行大量的计算来进行训练。

在 $C[a,b]$ 上常用的范数逼近有：

常见逼近

- 极大范数逼近：一致逼近–uniform approximation：

$$\|f-p\|_\infty = \max_{a\le x\le b} |f(x)-p(x)|.$$

- 平方范数逼近：称为平方逼近–least-squares approximation：

$$\|f-p\|_2 = \left\{\int_a^b |f(x)-p(x)|^2 dx\right\}^{\frac{1}{2}}.$$

$\min_s \|f-s\|_2 \Leftrightarrow \min_s \|f-s\|_2^2$ 为凹问题.

- 1-范数逼近

$$\|f-p\|_1 = \int_a^b |f(x)-p(x)|dx.$$

设 $\rho(x)$ 是 $[a,b]$ 上的权函数，定义

$$L^2_\rho[a,b] = \left\{ f : \|f\|_2 = \sqrt{\int_a^b \rho(x)[f(x)]^2 dx} < +\infty. \right\}$$

$L^2_\rho[a,b]$ 是 $\mathbb{R}$ 上的线性空间，若 $\rho(x) \equiv 1$，则为 $L^2[a,b]$。

定义 (函数系的线性无关)

设 $\varphi_0, \varphi_1, \cdots, \varphi_n \in L^2_\rho[a,b]$，若不存在 $n+1$ 个不全为零的数 $c_j, 0 \le j \le n$ 使得

$$\|c_0\varphi_0 + c_1\varphi_1 + \cdots + c_n\varphi_n\|_2 = 0,$$

则称函数系 $\{\varphi_j, j = 0, 1 \cdots, n\}$ 在 $L^2_\rho[a,b]$ 上线性无关。

设 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 是 $L_\rho^2[a,b]$ 上线性无关的函数，记

$$\Phi = \operatorname{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}.$$

选取合适的逼近空间.

则 $\forall s \in \Phi$ 有

$$s(x) = \sum_{j=0}^{n} a_j \varphi_j(x).$$

$a_j, 0 \le j \le n$ 是拟合参数.

定义 (最佳平方逼近)

设 $f \in L_\rho^2[a,b]$，若 $\exists s^* \in \Phi$ 使得

$$\|f - s^*\|_2 = \min_{s \in \Phi} \|f - s\|_2,$$

则称 s^* 为 f 在 Φ 中的最佳平方逼近函数。

求最佳平方逼近 $s^*(x)$ 等价于求下面的多元函数

$$F(a_0, a_1, \cdots, a_n) = \int_a^b \rho(x)\left[f(x) - \sum_{j=0}^{n} a_j\varphi_j(x)\right]^2 dx = \|f - s\|_2^2$$

的极小值，则由多元函数函数取极值的必要条件有

$$\nabla F(\boldsymbol{a}) = \mathbf{0} \Longleftrightarrow \frac{\partial F(a_0, a_1, \cdots, a_n)}{\partial a_k} = 0, \quad 0 \le k \le n,$$

$$\Longleftrightarrow 2\int_a^b \rho(x)\left[f(x) - \sum_{j=0}^{n} a_j\varphi_j(x)\right]\varphi_k(x)dx = 0, \quad 0 \le k \le n.$$

由此可得

$$\Longleftrightarrow \sum_{j=0}^{n} \int_a^b \rho(x)\varphi_j(x)\varphi_k(x)dx\, a_j = \int_a^b \rho(x) f(x)\varphi_k(x)dx$$

$$\sum_{j=0}^{n} (\varphi_j, \varphi_k)a_j = (f, \varphi_k), k = 0, 1, \cdots, n. \tag{0.1}$$

$$(\varphi_j, \varphi_k) = \int_a^b \rho(x)\varphi_j(x)\varphi_k(x)dx$$

称为法方程（normal equation）。

法方程

Gram矩阵.

写成矩阵形式有：

$$\begin{bmatrix} (\varphi_0,\varphi_0) & (\varphi_0,\varphi_1) & \cdots & (\varphi_0,\varphi_n) \\ (\varphi_1,\varphi_0) & (\varphi_1,\varphi_1) & \cdots & (\varphi_1,\varphi_n) \\ \vdots & \ddots & \ddots & \vdots \\ (\varphi_n,\varphi_0) & (\varphi_n,\varphi_1) & \cdots & (\varphi_n,\varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \vdots \\ d_n \end{bmatrix}$$

A

$\nabla f(\vec{a}) = 2(\vec{d} - A\vec{a}) = 0$

$A\vec{a} - \vec{d} = 0$

其中内积定义为

$$(\varphi_k,\varphi_j) = \int_a^b \rho(x)\varphi_k(x)\varphi_j(x)dx,$$

$$(f,\varphi_k) = \int_a^b \rho(x)f(x)\varphi_k(x)dx = d_k.$$

系数矩阵A是否可逆

若A非奇异，则法方程有唯一解.

事实上，若 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 线性无关，则法方程的系数矩阵对称正定。

$$\vec{a}^T A \vec{a} = [a_0, a_1, \cdots, a_n] \begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \ddots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix}$$

$\vec{a} = \begin{bmatrix} a_0 \\ \vdots \\ a_n \end{bmatrix}$

$$= \left[\left(\sum_{j=0}^{n} a_j \varphi_j, \varphi_0 \right), \left(\sum_{j=0}^{n} a_j \varphi_j, \varphi_1 \right), \cdots, \left(\sum_{j=0}^{n} a_j \varphi_j, \varphi_n \right) \right] \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix}$$

$$= \left(\sum_{j=0}^{n} a_j \varphi_j, \sum_{j=0}^{n} a_j \varphi_j \right) \geq 0.$$

若上式为零当且仅当

$$\sum_{j=0}^{n} a_j \varphi_j(x) = 0 \Longleftrightarrow a_j = 0, 0 \leq j \leq n.$$

φ_j 线性无关

定理

设 $\mathbb{X}$ 是内积空间，$(\cdot,\cdot)$ 是其上的内积，对 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n \in \mathbb{X}$，若

$$G_n = \Big(G_{ij} = (\boldsymbol{x}_i,\boldsymbol{x}_j)\Big)_{n\times n},$$

则 $\det G_n \neq 0 \Longleftrightarrow \boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$ 线性无关。

$\nabla^2 F(a) = A$ 一对称正定，

$F(a)$ 凸函数.

Galerkin 正交性

因为 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 线性无关，则法方程的系数矩阵非奇异， 法方程 (0.1) 存在唯一解：

$$a_k = a_k^*,\ k = 0, 1, \cdots, n \Longrightarrow s^* = \sum_{j=0}^{n} a_j^* \varphi_j(x).$$

且有

引理

若 $s^*(x) = \sum_{k=0}^{n} a_k^* \varphi_k(x)$ 是法方程 (0.1) 的解，则有如下正交关系

$$(f(x) - s^*(x), s(x)) = 0, \quad \forall s(x) \in \Phi.$$

证明：$s^*(x)=\sum_{k=0}^{n} a_k^* \varphi_k(x)$ 是法方程的解，则

$$\sum_{k=0}^{n} (\varphi_k, \varphi_j) a_k^* = (f, \varphi_j), \quad 0 \le j \le n.$$

s^*

即：$(f - \sum_{k=0}^{n} a_k^* \varphi_k, \varphi_j) = 0, \quad 0 \le j \le n.$

$\forall s \in \Phi$, $s(x)=\sum_{j=0}^{n} \alpha_j \varphi_j(x)$, $\{\varphi_j\}_{j=0}^{n}$ 是 Φ 的一组基.

则：$(f - s^*, s) = 0, \quad \forall s \in \Phi.$

s^* 是 f 在 Φ 上的正交投影.

定理

$s^*(x)$ 是 $f(x)$ 在 Φ 中的最佳平方逼近，即

$$\|f - s^*\|_2 \le \|f - s\|_2, \quad \forall s \in \Phi.$$

证明：$\|f-s^*\|_2^2 = (f-s^*, f-s^*)$

$= (f-s^*, f-s+s-s^*)$ $\forall s \in \Phi$

$= (f-s^*, f-s) + (f-s^*, s-s^*)$, $s-s^* \in \Phi$

$= 0$ 正交性.

Cauchy-Schwarz $\le \|f-s^*\|_2 \|f-s\|_2$

若 $\|f-s^*\|_2 \neq 0$，则

$\|f-s^*\|_2 \le \|f-s\|_2$ $\forall s \in \Phi$.

定理

$s^*(x)$ 是 $f(x)$ 在 Φ 中的最佳平方逼近当且仅当 $s^*(x)$ 是 $f(x)$ 在 Φ 中的正交投影，即

$$(f(x)-s^*(x),s(x))=0,\quad \forall s(x)\in\Phi.$$

令

$$\delta(x)=f(x)-s^*(x),$$

则 $\|\delta\|_2$ 称为最佳平方逼近的误差，

$$\|\delta\|_2^2=\|f\|_2^2-\sum_{j=0}^{n}a_j^*(\varphi_j,f).$$

$\|\delta\|_2^2=(\delta,\delta)$

$=(f-s^*,f-s^*)$

$=(f-s^*,f)$

$=(f,f)-(s^*,f)$

$=\|f\|_2^2-\sum_{j=0}^{n}a_j^*(\varphi_j,f)$

正交性 $(f-s^*,s^*)=0$

$s^*=\sum_{j=0}^{n}a_j^*\varphi_j$

有限元方法

考虑一维Poisson方程：

$$-u''(x) = f(x), \quad 0 < x < 1,$$
$$u(0) = u(1) = 0.$$

设 $v(x)$ 是定义在 $[0,1]$ 上满足 $v(0) = v(1) = 0$ 的函数，在Poisson方程两边同乘于 $v(x)$ 并分部积分：

$$-\int_0^1 u''v dx = -\int_0^1 v du' = -u'v\Big|_0^1 + \int_0^1 u'v'dx$$
$$= \int_0^1 u'v'dx = \int_0^1 fvdx$$

令

$$a(u,v) = \int_0^1 u'v'dx, \quad (f,v) = \int_0^1 fvdx$$

引理

如上定义的 $a(u,v)$ 是一个内积。

证明：① $a(u_1+u_2,v)=\int_a^b (u_1+u_2)'v'dx$ $\quad a=0,\ b=1$

$=\int_a^b u_1'v'dx+\int_a^b u_2'v'dx$

$=a(u_1,v)+a(u_2,v)$

② $a(\alpha u,v)=\int_a^b (\alpha u)'v'dx=\alpha\int_a^b u'v'dx=\alpha\, a(u,v)$

③ $a(u,v)=\int_a^b u'v'dx=\int_a^b v'u'dx=a(v,u)$

④ $a(u,u)=\int_a^b (u')^2dx\geq 0$,

若 $=0$，则 $u'\equiv 0 \Leftrightarrow u\equiv C \quad \forall x\in[0,1]$

但 $u(0)=u(1)=0$，则 $C=0$.

定义空间 $\int_a^b v^2 dx < +\infty$, $\int_a^b (v')^2 dx < +\infty$

$$V = \{v \in L^2([0,1]),\ a(v,v) < +\infty,\ v(0) = v(1) = 0\},$$ H_0^1空间.

则 Poisson 方程等价的转化为如下的变分问题：

求 $u(x) \in V$,

使得 $a(u,v) = (f,v)$, $\forall v(x) \in V$

跟 $-u'' = f$ 相比，u的光滑性要求更低.

此处 V 是无穷维空间，无法直接求解，必须考虑其有限维子空间 V_h 中的近似问题：

求 $u_h(x) \in V_h$,

使得 $a(u_h, v_h) = (f, v_h)$, $\forall v_h(x) \in V_h$ (0.2)

有Galerkin正交关系 $a(u, v_h) = (f, v_h)$, $\forall v_h \in V_h$

$$a(u - u_h, v_h) = 0, \quad \forall v_h \in V_h.$$

u_h是u在V_h上的投影.

有限元空间

分片多项式空间.

有限元方法就是选取 V_h 为有限元空间，考虑 $[0,1]$ 的一个剖分

$$0 = x_0 < x_1 < x_2 < \cdots < x_{i-1} < x_i < \cdots < x_n = 1,$$

其中 x_i 称为网格节点，$h_i = x_i - x_{i-1}, 1 \le i \le n$，而 $h = \max_{1\le i\le n} h_i$。定义线性有限元空间

分片线性

$$V_h = \left\{ v \in C([0,1]), v(0) = v(1) = 0, v\big|_{[x_{i-1},x_i]} \in \mathcal{P}_1 \right\},$$

此空间其实是分片线性函数空间，其基函数即为分片线性插值的节点基函数 $\phi_i, 1 \le i \le n-1$。

$u(0)=u(1)=0$，不需要 ϕ_0, ϕ_n.

$$\phi_i(x) = \begin{cases} \dfrac{x - x_{i-1}}{h_i}, & x \in [x_{i-1}, x_i], \\ \dfrac{x_{i+1} - x}{h_{i+1}}, & x \in [x_i, x_{i+1}], \end{cases}$$

$$\phi_i(x) = 0,\ x \notin [x_{i-1}, x_{i+1}]$$

$\phi_i(0)=\phi_i(1)=0,\ 1\le i\le n$

对 $\forall v_h \in V_h$，令

$$v_i = v_h(x_i), \quad 1 \le i \le n-1,$$

则

$$v_h(x) = v_1\phi_1(x) + v_2\phi_2(x) + \cdots + v_{n-1}\phi_{n-1}(x).$$

同理有

$$u_h(x) = \sum_{i=1}^{n-1} u_i\phi_i(x), \quad \text{其中 } u_i = u_h(x_i).$$

(0.2) 对任意的 $v_h \in V_h$ 成立，只需基底 $\phi_i(x), 1 \le i \le n-1$ 成立：

$$a(u_h, \phi_i) = (f, \phi_i), \quad 1 \le i \le n-1.$$

亦即

$$a(\phi_1, \phi_i)u_1 + a(\phi_2, \phi_i)u_2 + \cdots + a(\phi_{n-1}, \phi_i)u_{n-1} = (f, \phi_i),$$
$$1 \le i \le n-1.$$

令

$$k_{ij} = a(\phi_j, \phi_i) = \int_0^1 \phi_j' \phi_i' dx,$$

$$f_i = (f, \phi_i) = \int_0^1 f \phi_i dx$$

和

$$K = (k_{ij}) \in \mathbb{R}^{(n-1)\times(n-1)}, \quad F = (f_i) \in \mathbb{R}^{n-1}, \quad U = (u_i) \in \mathbb{R}^{n-1}$$

可得法方程

$$KU = F \tag{0.3}$$

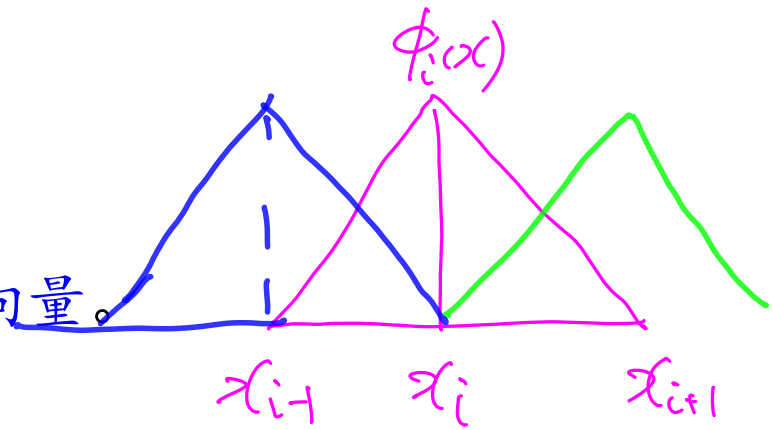

此处 K 称为刚度矩阵，F 为荷载向量。
当 x_i 和 x_j 不相邻时

$$a(\phi_i, \phi_j) = 0,$$

三对角.

所以 K 是稀疏矩阵。

刚度矩阵的计算

经过简单的计算有

$$\begin{aligned}
\int_{x_{i-1}}^{x_i} \phi_i' \phi_i' dx &= \int_{x_{i-1}}^{x_i} \frac{1}{h_i^2} dx = \frac{1}{h_i}, \\
\int_{x_{i-1}}^{x_i} \phi_{i-1}' \phi_{i-1}' dx &= \int_{x_{i-1}}^{x_i} \frac{1}{h_i^2} dx = \frac{1}{h_i}, \\
\int_{x_{i-1}}^{x_i} \phi_i' \phi_{i-1}' dx &= \int_{x_{i-1}}^{x_i} -\frac{1}{h_i^2} dx = -\frac{1}{h_i}.
\end{aligned}$$

则

$$\begin{aligned}
\int_0^1 \phi_i' \phi_i' dx &= \int_{x_{i-1}}^{x_i} \phi_i' \phi_i' dx + \int_{x_i}^{x_i+1} \phi_i' \phi_i' dx = \frac{1}{h_i} + \frac{1}{h_{i+1}}, \\
\int_0^1 \phi_i' \phi_{i-1}' dx &= \int_{x_{i-1}}^{x_i} \phi_i' \phi_{i-1}' dx = -\frac{1}{h_i}.
\end{aligned}$$

刚度矩阵

$$a(\phi_i,\phi_i) = \int_0^1 \phi_i'\phi_i' dx = \frac{1}{h_i}+\frac{1}{h_{i+1}},$$

$$a(\phi_i,\phi_{i-1}) = \int_0^1 \phi_i'\phi_{i-1}' dx = -\frac{1}{h_i}.$$

刚度矩阵

若 $h_i = h$, 则 $K = \frac{1}{h}\begin{bmatrix} 2 & -1 & & \\ -1 & 2 & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 2 \end{bmatrix}$

$$K = \begin{bmatrix} \frac{1}{h_1}+\frac{1}{h_2} & -\frac{1}{h_2} & & & & \\ -\frac{1}{h_2} & \frac{1}{h_2}+\frac{1}{h_3} & -\frac{1}{h_3} & & & \\ & \ddots & \ddots & \ddots & & \\ & & -\frac{1}{h_i} & \frac{1}{h_i}+\frac{1}{h_{i+1}} & -\frac{1}{h_{i+1}} & \\ & & & \ddots & \ddots & \ddots \\ & & & -\frac{1}{h_{n-2}} & \frac{1}{h_{n-2}}+\frac{1}{h_{n-1}} & \end{bmatrix}$$

周期函数的最佳平方逼近

设 $f \in C(\mathbb{R})$ 是周期函数，即 $f(x+2\pi)=f(x), x \in \mathbb{R}$，这样的函数全体构成一个线性空间 $X_{2\pi}$。$X_{2\pi}$ 上可定义内积，从而诱导出2-范数。

$$(f,g)=\int_0^{2\pi} f(x)g(x)\mathrm{d}x, \quad \|f\|_2=\sqrt{(f,f)}.$$

逼近空间可取三角函数空间

$$\Phi=\{1,\cos x,\sin x,\cdots,\cos nx,\sin nx\} \subset X_{2\pi}.$$

f 在 Φ 中的最佳平方逼近多项式为

$$s_n^*(x)=\frac{1}{2}a_0+\sum_{j=1}^{n}(a_j\cos jx+b_j\sin jx).$$

因为

$$\int_0^{2\pi}\cos kx\sin lx\mathrm{d}x=0.$$

$$\int_0^{2\pi} \cos kx \cos lx \mathrm{d}x = \begin{cases} 2\pi, & k = l = 0, \\ \pi, & k = l \neq 0, \\ 0, & k \neq l, \end{cases}$$

$$\int_0^{2\pi} \sin kx \sin lx \mathrm{d}x = \begin{cases} \pi, & k = l \neq 0, \\ 0, & k \neq l \end{cases}$$

$(f, \varphi_j) = \int_0^{2\pi} f(x)\varphi_j(x)dx$

定理

s_n^* 是 f 在 Φ 中的最佳平方逼近当且仅当

$$a_j = \frac{1}{\pi}\int_0^{2\pi} f(x)\cos jx \mathrm{d}x, \quad j = 0, 1, \cdots, n,$$

$$b_j = \frac{1}{\pi}\int_0^{2\pi} f(x)\sin jx \mathrm{d}x, \quad j = 1, 2, \cdots, n.$$

τ

$\frac{(f, \sin jx)}{(\sin jx, \sin jx)}$

考虑周期边界条件的一维 Poisson 方程：

$$\begin{aligned} -u''(x) &= f(x), \\ u(0) &= u(2\pi) = 0. \end{aligned}$$

可定义空间

$$V = \left\{ v \in L^2([0,2\pi]), \quad a(v,v) < +\infty, \quad v(0) = v(2\pi) = 0 \right\},$$

则 Poisson 方程等价的转化为如下的变分问题：

$$\begin{aligned} &\text{求} \quad u(x) \in V, \\ &\text{使得} \quad a(u,v) = (f,v) \quad \forall v(x) \in V, \end{aligned}$$

这里

$$\begin{aligned} a(u,v) &= \int_0^{2\pi} u'(x)v'(x)\mathrm{d}x, \\ (f,v) &= \int_0^{2\pi} f(x)v(x)\mathrm{d}x. \end{aligned}$$

谱方法

若令子空间 V_h 为三角函数空间，方法为谱方法，近似问题为

$$\begin{aligned} &\text{求} \quad u_h(x) \in V_h, \\ &\text{使得} \quad a(u_h, v_h) = (f, v_h), \quad \forall v_h(x) \in V_h. \end{aligned} \tag{0.4}$$

因为 $u(0) = u(2\pi) = 0$，则

$$V_h = \operatorname{span}\{\sin kx, \ k = 1, \cdots, n\}.$$

则 $u_h \in V_h$ 可写为

$$u_h = \sum_{k=1}^{n} u_k \sin kx, \quad \text{其中} \quad u_k = \frac{1}{\pi} \int_0^{2\pi} u(x) \sin kx \mathrm{d}x$$

(0.4)对任意的 $v_h \in V_h$ 成立，只需基底 $\phi_j(x) = \sin jx, 1 \le j \le k$ 成立：

$$a(u_h, \phi_j) = (f, \phi_j) = \pi b_j, \quad 1 \le j \le n.$$

亦即

$$a(\phi_1,\phi_j)u_1+\cdots+a(\phi_n,\phi_j)u_n=(f,\phi_j)=\pi b_j,\quad 1\le j\le n.$$

计算可得

$$\begin{aligned} a(\phi_k,\phi_l) &= \int_0^{2\pi}(\sin kx)'(\sin lx)'\mathrm{d}x \\ &= kl\int_0^{2\pi}\cos kx\cos lx\mathrm{d}x \\ &= \begin{cases} k^2\pi, & k=l\neq 0, \\ 0, & k\neq 0. \end{cases} \end{aligned}$$

计算 f 的 Fourier 系数

FFT

因此

$$u_k=\frac{b_k}{k^2},\quad b_k=\frac{1}{\pi}\int_0^{2\pi}f(x)\sin kx\mathrm{d}x,\quad 1\le k\le n.$$

实际上，也可以把表达式

$$u(x)=\sum_{k=1}^{\infty}u_k\sin kx,\qquad f(x)=\sum_{k=1}^{\infty}b_k\sin kx,$$

代入

$$-u''(x)=f(x),$$

得到

$$\sum_{k=1}^{\infty}k^2u_k\sin kx=\sum_{k=1}^{\infty}b_k\sin kx.$$

由 $\{\sin kx, k\geq 1\}$ 的正交性知

$$u_k=\frac{b_k}{k^2},\quad k=1,\cdots.$$

如果直接用多项式逼近，选择自然基底会怎样？

例

考虑 $[0,1]$ 上连续函数 $f(x)$ 的最佳平方逼近，取 $\rho(x)=1$，

$$\varphi_k(x)=x^k, k=0,1\cdots,n.$$

求 f 在 $\mathcal{P}_n[0,1]$ 中的最佳平方逼近多项式。

计算法方程的系数矩阵和右端，有

$$\begin{aligned}(\varphi_j,\varphi_k) &= \int_0^1 x^{j+k}dx=\frac{1}{j+k+1},\ k,j=0,1\cdots,n,\\ (f,\varphi_k) &= \int_0^1 f(x)x^k dx=d_k, k=0,1,\cdots,n.\end{aligned}$$

个数值积分.

则法方程的系数矩阵为

$$H_{n+1}(0,1)=\begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n+1} \end{bmatrix}$$

满矩阵.

H_{n+1} 是Hilbert矩阵。
求解法方程可得最佳平方逼近函数：

$$P_n^*(x)=a_0^*+a_1^*x+\cdots+a_n^*x^n.$$

Hilbert矩阵是病态的，因此直接从法方程求

$$a_j^*,\quad j=0,1\cdots,$$

是相当困难的。

数学家简介 (Hilbert)

希尔伯特（*1862–1943*），德国数学家，於代数不变量、代数数论、几何基础、变分法、*Hilbert* 空间等方面都有了不起的贡献，堪称他那时代最伟大的数学家。他提倡数学公理化，还有提出「*Hilbert 23*问题」，对於二十世纪的数学发展影响甚大。希尔伯特去世时，德国《自然》杂志发表过这样的观点：现在世界上难得有一位数学家的工作不是以某种途径导源于希尔伯特的工作。他像是数学世界的亚历山大，在整个数学版图上，留下了他那显赫的名字。*1900*年，希尔伯特在巴黎数学家大会上提出了*23*个最重要的问题供二十世纪的数学家们去研究，这就是著名的"希尔伯特*23*个问题"。*1976*年，在美国数学家评选的自*1940*年以来美国数学的十大成就中，有三项就是希尔伯特第*1*、第*5*、第*10*问题的解决。由此可见，能解决希尔伯特问题，是当代数学家的无上光荣。

他的学生有：Hermann Weyl, Richard Courant等。

Mathematics Genealogy

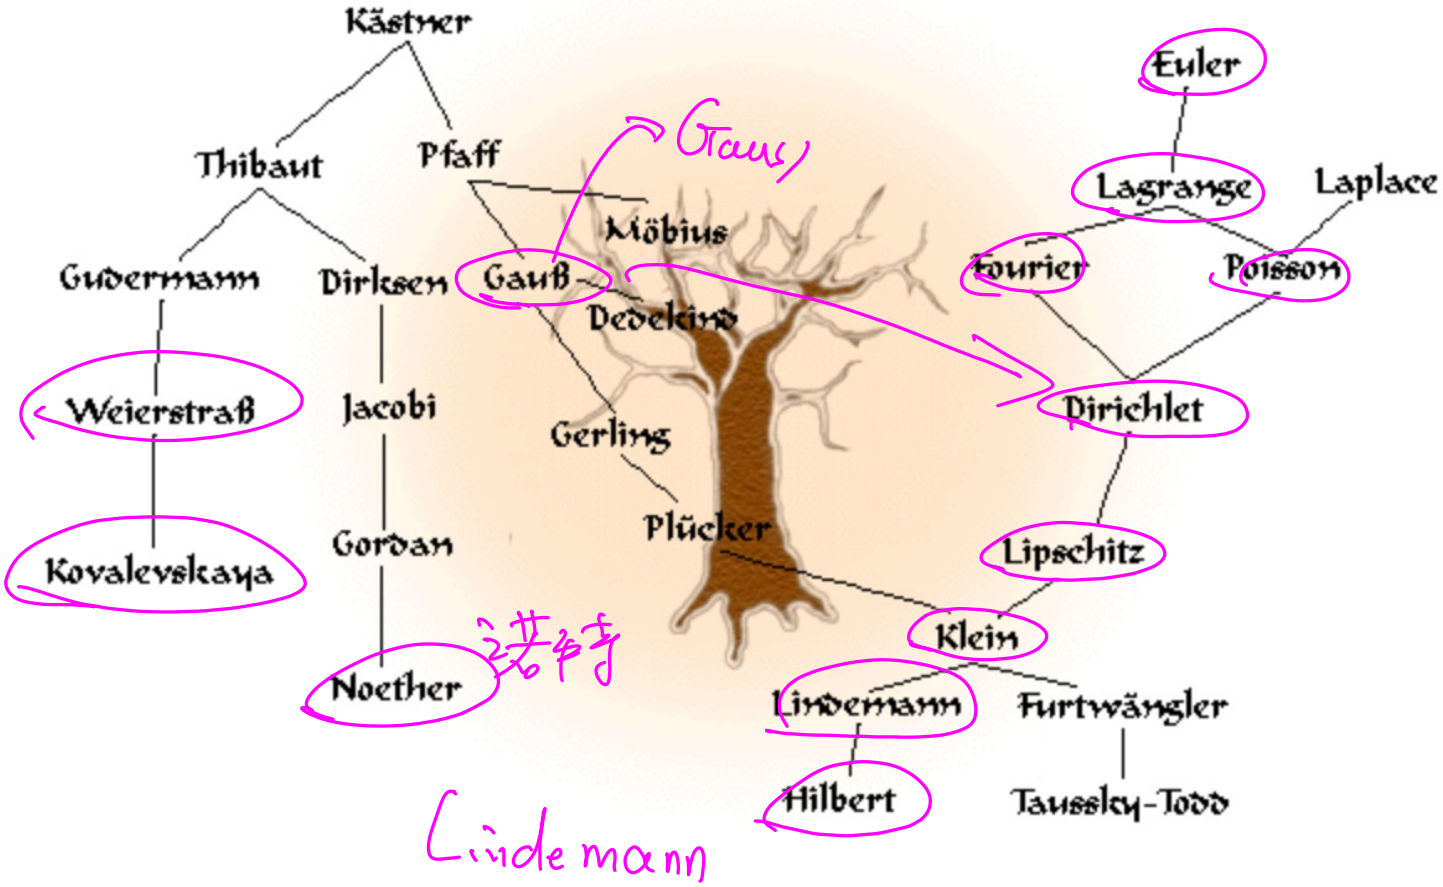

正交多项式逼近

设

$$f(x) \in L_\rho^2[a,b], \Phi = \text{span}\{\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)\},$$

其中 $\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$ 是满足如下关系的多项式族：

$$(\varphi_i, \varphi_j) = \int_a^b \rho(x)\varphi_i(x)\varphi_j(x)dx = \begin{cases} 0 & i \neq j \\ A_j > 0 & i = j \end{cases}$$

所以法方程 (0.1) 的系数矩阵为

$$G_n = \begin{bmatrix} (\varphi_0, \varphi_0) & 0 & \cdots & 0 \\ 0 & (\varphi_1, \varphi_1) & \cdots & 0 \\ \cdots & \cdots & \ddots & \vdots \\ 0 & 0 & \cdots & (\varphi_n, \varphi_n) \end{bmatrix}$$

对角矩阵呀

广义Fourier系数

直接求解可得

$$a_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}, \qquad k = 0, 1, \cdots, n.$$

此处的 a_k^* 有时也称为广义 Fourier 系数。

因此 f 在 Φ 中的最佳平方逼近函数为

$$s_n^*(x) = \sum_{j=0}^{n} \frac{(f, \varphi_j)}{\|\varphi_j\|_2^2} \varphi_j(x).$$

采用具有正交性的多项式为基底进行逼近可以避免自然基底得到病态矩阵。

定义 (权函数)

设定义在 $[a,b]$ 上的函数 ρ 满足：

1. $\rho(x) \geq 0,\ \forall x \in (a,b)$。
2. $\int_a^b x^k \rho(x)dx$ 存在且是有限的（$k = 0, 1 \cdots$）。
3. 若对 $[a,b]$ 上连续的 $g \geq 0$ 有

$$\int_a^b \rho(x)g(x)dx = 0,$$

则 $g(x) \equiv 0$。

则称 $\rho(x)$ 是 $[a,b]$ 上的一个权函数–*weight function*。

定义 (带权内积)

设 $f, g \in C[a,b]$, ρ 是 $[a,b]$ 上的权函数，由下式定义的内积：

$$(f,g) = \int_a^b \rho(x) f(x) g(x) dx$$

称为带权 ρ 的内积，而相应的 L^2 范数

$$\|f\|_2 = \sqrt{(f,f)} = \left[\int_a^b \rho(x) f^2(x) dx \right]^{\frac{1}{2}}$$

称为带权的 L^2 范数。

$(f,g) = \int_0^{2\pi} f(x) g(x) dx$ $\{\sin kx, \cos kx\}$.

定义

设 $f, g \in C[a,b]$, ρ 为 $[a,b]$ 上的权函数，若

$$(f,g) = \int_a^b \rho(x) f(x) g(x) dx = 0$$

则称 f 与 g 在 $[a,b]$ 上带权正交。

$\int_0^{2\pi} \sin kx \sin jx \, dx = 0, \quad k \neq j$

$\int_0^{2\pi} \sin kx \cos jx \, dx = 0$

$\int_0^{2\pi} \cos kx \cos jx \, dx = 0, \quad k \neq j.$

定义 (正交多项式–orthogonal polynomial)

设 φ_n 是 $[a,b]$ 上的首项系数 $a_n \neq 0$ 的 n 次多项式，ρ 为 $[a,b]$ 上的权函数，如果多项式序列 $\{\varphi_n, n \geq 0\}$ 满足

$$(\varphi_i, \varphi_j) = \int_a^b \rho(x)\varphi_i(x)\varphi_j(x)dx = \begin{cases} 0, & i \neq j, \\ A_i > 0, & i = j, \end{cases}$$

则称多项式序列 $\{\varphi_n, n \geq 0\}$ 在 $[a,b]$ 上带权 ρ 正交，并称 φ_n 为 $[a,b]$ 上带权 ρ 的 n 次正交多项式。

利用Gram-Schmidt方法可以构造出在 $[a,b]$ 上带权 ρ 正交的多项式序列 $\{\varphi_n, n \geq 0\}$，设

$$\psi_j(x) = x^j, j = 0, 1, \cdots, n.$$

令

$$\begin{cases} \varphi_0(x) = 1, \\ \varphi_k(x) = \psi_k(x) - \sum_{j=0}^{k-1} \dfrac{(\psi_k, \varphi_j)}{(\varphi_j, \varphi_j)} \varphi_j(x), \quad k = 1, 2, \cdots, n. \end{cases}$$

这样构造的 $\{\varphi_k : k \geq 0\}$ 具有下面的基本性质：

1. φ_k 是最高次项的系数为 1 的 k 次多项式，首项系数为1。
2. 任何 k 次多项式均可表示成前 $k+1$ 个 $\varphi_0, \varphi_1, \cdots, \varphi_k$ 的线性组合，
3. $\forall k \neq l$ 有 $(\varphi_k, \varphi_l) = 0$，并且 φ_k 与任一次数小于 k 的多项式正交。

正交多项式的三项递推关系

但是 Gram-Schmidt 正交化计算量大，而且由于舍入误差的影响，精度不能保证。正交多项式有如下的三项递推关系可以用来数值计算。

定理 (三项递推关系)

设 $\{\varphi_n, n \geq 0\}$是 $[a,b]$ 上带权 ρ 的正交多项式序列，则有

$$\begin{aligned}
\varphi_{n+1}(x) &= (\alpha_n x + \beta_n)\varphi_n(x) + \gamma_{n-1}\varphi_{n-1}(x), \\
\varphi_n(x) &= a_n x^n + a_{n-1}x^{n-1} + \cdots + a_0, \\
\alpha_n &= \frac{a_{n+1}}{a_n}, \quad \beta_n = -\frac{a_{n+1}}{a_n}\frac{(\varphi_n, x\varphi_n)}{(\varphi_n, \varphi_n)}, \\
\gamma_{n-1} &= -\frac{a_{n+1}a_{n-1}}{a_n^2}\frac{(\varphi_n, \varphi_n)}{(\varphi_{n-1}, \varphi_{n-1})}.
\end{aligned}$$

1. 用 Gram-Schmidt 正交化求出前 n 次正交多项式
2. 计算对应的 α_n, β_n, γ_{n-1},
3. 写出一般的递推关系
4. 用归纳法证明.

定理

设 $\{\varphi_n, n \geq 0\}$ 是 $[a,b]$ 上带权 ρ 的正交多项式序列，则 φ_n 在区间 (a,b) 内恰有 n 个不同的实零点。

证明：$\int_a^b \rho(x)\varphi_k(x)\cdot 1\,dx = 0$，$k \geq 1$，先证明 $\varphi_n(x)$ 在 (a,b) 上必有奇数重根，若不然，则 $\varphi_n(x)$ 时根：

(1) 在 (a,b) 上是偶数重根 x_i，则 $(x-x_i)^{2m} \geq 0$，$\forall x \in [a,b]$

(2) 零根 x_j 在 (a,b) 外，则 $(x-x_j)$ 在 $[a,b]$ 上不变号。

(3) 一对共轭复根 $x_j = \alpha + i\beta$，$\bar{x}_j = \alpha - i\beta$，

则 $(x-x_j)(x-\bar{x}_j) = (x-\alpha-i\beta)(x-\alpha+i\beta)$

$= (x-\alpha)^2 + \beta^2 \geq 0$。

则 $\varphi_n(x)$ 在 (a,b) 上不变号，但：

$\int_a^b \rho(x)\varphi_n(x)dx = 0 \Rightarrow \varphi_n(x) = 0$, 矛盾.

则 $\varphi_n(x)$ 在 (a,b) 上必有奇数重根.

设 $x_1, x_2, \cdots, x_l$ 是 $\varphi_n(x)$ 的奇数重根(不计重数),

令 $q_l(x) = \prod_{j=1}^{l}(x - x_j)$. 则 $\varphi_n(x)q_l(x)$ 在 (a,b) 上不变号.

若 $l < n$, 则: $\int_a^b \rho(x)\varphi_n(x)q_l(x)dx \neq 0$ (φ_n 与 $\leq n-1$ 次多项式带权正交),

$$\int_a^b \rho(x)\varphi_n(x)q_l(x)dx = 0$$

矛盾, 则 $l = n$,

$$\int_a^b \rho(x)\varphi_n(x)q_n(x)dx \neq 0$$

$\varphi_n(x)$ 在 (a,b) 上有 n 个不同的零点 ∎

Legendre多项式

区间 $[-1,1]$ 上权函数 $\rho=1$ 的正交多项式

$$\begin{cases} P_0(x)=1, \\ P_n(x)=\dfrac{1}{2^n n!}\dfrac{d^n}{dx^n}[(x^2-1)^n], n\geq 1, \end{cases}$$

为 Legendre多项式。

显然P_n的首项系数为$\frac{(2n)!}{2^n(n!)^2}$。令

$$\begin{cases} \tilde{P}_0=1, \\ \tilde{P}_n=\dfrac{n!}{(2n)!}\dfrac{d^n}{dx^n}[(x^2-1)^n], \end{cases}$$

则 $\tilde{P}_n$ 中 x^n 的系数为1，称 $\tilde{P}_n$ 为首项系数为1的Legendre多项式。

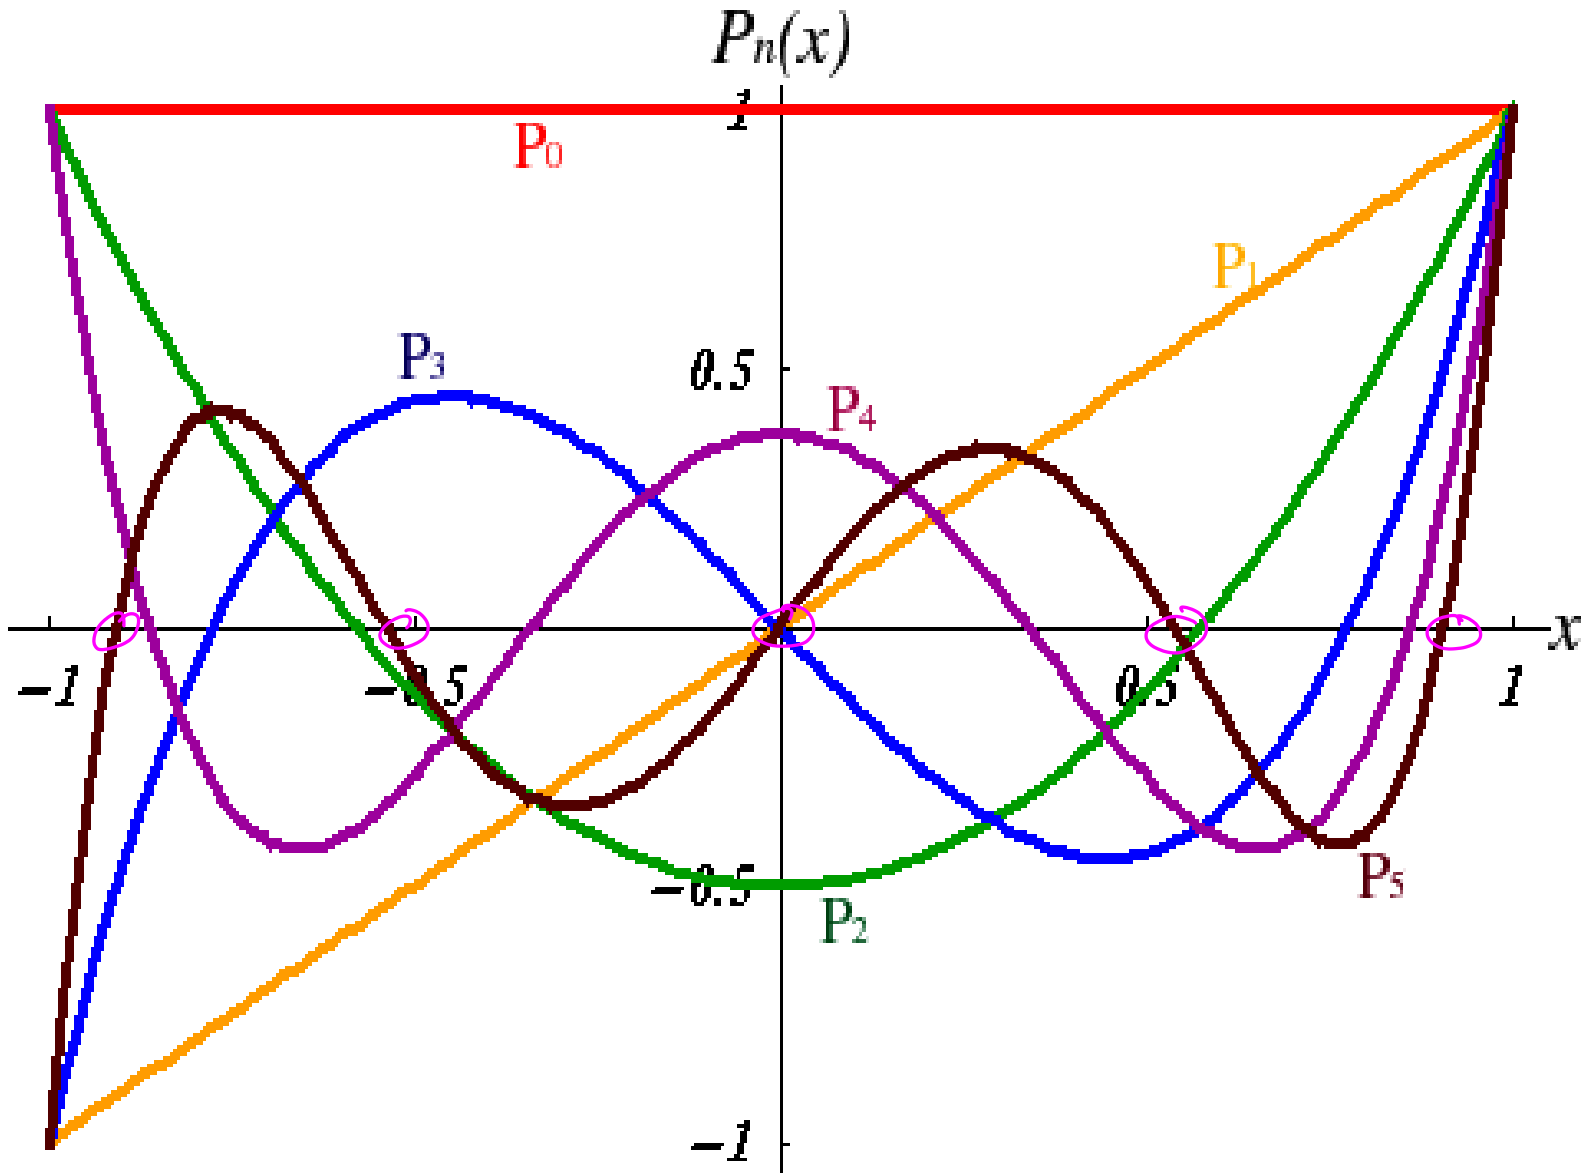
$P_n(x)$
1
P_0
P_1
P_3
0.5
P_4
x
−1
−0.5
0.5
1
P_5
−0.5
P_2
−1

Legendre多项式的性质

1. 正交性：

$$\int_{-1}^{1} P_n(x)P_m(x)dx = \begin{cases} 0, & n \neq m, \\ \frac{2}{2n+1}, & n = m. \end{cases}$$

2. 三项递推关系：

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x),\ n = 1, 2, \cdots$$

3. 奇偶性：

$$P_n(-x) = (-1)^n P_n(x)$$

可用归纳法证明。

首1的Legendre多项式

首项系数为1的Legendre多项式的递推关系：

递推关系依赖于首项系数。

$$\begin{cases} \tilde{P}_0 = 1, \tilde{P}_1(x) = x, \\ \tilde{P}_{n+1}(x) = x\tilde{P}_n(x) - \dfrac{n^2}{(2n+1)(2n-1)}\tilde{P}_{n-1}(x), n = 1, 2, \cdots \end{cases}$$

利用 $\tilde{P}_0 = 1$ 以及上面的递推公式有：

$$\begin{cases} \tilde{P}_1(x) = x, \\ \tilde{P}_2(x) = x^2 - \frac{1}{3} \\ \tilde{P}_3(x) = x^3 - \frac{3}{5}x \\ \tilde{P}_4(x) = x^4 - \frac{6}{7}x^2 + \frac{3}{35} \\ \cdots \end{cases}$$

也可以用Gram-Schmidt正交化来得到首1的正交多项式：

$$
\begin{aligned}
\tilde{P}_0(x) &= 1, \\
(\tilde{P}_0, \tilde{P}_0) &= \int_{-1}^{1} 1dx = 2, (x, \tilde{P}_0) = \int_{-1}^{1} x \cdot 1dx = 0, \\
\tilde{P}_1(x) &= x - \frac{(x, \tilde{P}_0)}{(\tilde{P}_0, \tilde{P}_0)} = x, \\
(x^2, \tilde{P}_0) &= \int_{-1}^{1} x^2 dx = \frac{2}{3}, \ (x^2, \tilde{P}_1) = \int_{-1}^{1} x^3 dx = 0, \\
(\tilde{P}_1, \tilde{P}_1) &= \int_{-1}^{1} x^2 dx = \frac{2}{3}, \\
\tilde{P}_2(x) &= x^2 - \frac{(x^2, \tilde{P}_1)}{(\tilde{P}_1, \tilde{P}_1)} \tilde{P}_1(x) - \frac{(x^2, \tilde{P}_0)}{(\tilde{P}_0, \tilde{P}_0)} = x^2 - \frac{1}{3},
\end{aligned}
$$

数学家简介 (Legendre)

勒让德（*1752-1833*），法国数学家。提出了对素数定理和二次互反律的猜测并发表了初等几何教科书。将几何理论算术化、代数化，证明了圆周率π的无理性，《数论》论述了二次互反律及其应用，给出连分数理论及素数个数的经验公式等，使他成为解析数论的先驱者之一；提出三类基本椭圆积分，证明每个椭圆积分可以表示为这三类积分的组合，并编制了详尽的椭圆积分数值表，使他成为椭圆积分理论的奠基人之一。其他贡献有：确定极值函数存在的“勒让德条件”，创立并发展了测地线（大地测量）理论（*1787*），提出球面三角形的有关定理，还发表了关於彗星轨道的著作。*1805*年独立发现高斯（*Gauss*）不久前使用过的最小二乘法原理等等。

Legendre 函数
Legendre 变换
Gauss－Legendre algorithm等

Chebyshev多项式

于$x \in [-1,1]$，称n次多项式

$$T_n(x) = \cos(n \arccos x), n = 0, 1, \cdots.$$

为Chebyshev多项式。 等价的有

$$\begin{cases} T_0(x) = 1, \ T_1(x) = x, \\ T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x), k = 1, 2, \cdots. \end{cases}$$

则$\left\{T_n, n \geq 0\right\}$是$[-1,1]$上带权$\rho(x) = \dfrac{1}{\sqrt{1-x^2}}$的正交多项式序列。

$$\int_{-1}^{1} \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \begin{cases} 0, & n \neq m, \\ \frac{\pi}{2}, & n = m \neq 0 \\ \pi, & n = m = 0. \end{cases}$$

Chebyshev多项式的性质

1. $T_n(-x) = (-1)^n T_n(x), n = 0, 1, 2, \cdots$.
2. T_n 的首项系数为 $2^{n-1}, n = 1, 2, \cdots$。
3. $T_n(x)$ 在 $(-1, 1)$ 上有 n 个不同的零点 $\quad n \ \arccos x = k\pi + \frac{\pi}{2}$

$$x_k = \cos \frac{(2k-1)\pi}{2n}, \ k = 1, 2, \cdots, n$$

4. $T_n(x)$ 的极值点为 $\quad n+1$ 个正负交错的相对值点。

$$\bar{x}_k = \cos\left(\frac{k\pi}{n}\right), \ k = 0, 1, \cdots, n,$$

并且

$$T_n(\bar{x}_k) = (-1)^k, k = 0, 1, \cdots, n.$$

Lagurre多项式

在区间 $(0,+\infty]$ 上权函数为 $\rho(x)=e^{-x}$ 的正交多项式为Lagurre多项式

$$L_n(x)=e^x\frac{\mathrm{d}^n}{\mathrm{d}x^n}(x^ne^{-x}),n=0,1,\cdots,$$

可递推定义为

$$\begin{cases}L_0(x)=1,L_1(x)=1-x,\\ L_{n+1}(x)=(1+2n-x)L_n(x)-n^2L_{n-1}(x),n=1,2,\cdots,\end{cases}$$

其正交性为

$$\int_0^\infty e^{-x}L_n(x)L_m(x)=\begin{cases}0, & m\neq n,\\ (n!)^2, & m=n.\end{cases}$$

Hermite多项式

在 $(-\infty,\infty)$ 上带权 $\rho(x)=\exp(-x^2)$ 的正交多项式是Hermite多项式

$$H_n(x)=(-1)^n e^{x^2}\frac{\mathrm{d}^n}{\mathrm{d}x^n}e^{-x^2},\ n=0,1,\cdots.$$

其递推关系为

$$\begin{cases} H_0(x)=1,\ \ H_1(x)=2x, \\ H_{n+1}(x)=2xH_n(x)-2nH_{n-1}(x), n=1,2,\cdots, \end{cases}$$

正交性

$$\int_{-\infty}^{\infty} e^{-x^2}H_m(x)H_n(x)dx=\begin{cases} 0, & m\neq n \\ 2^n n!\sqrt{\pi}, & m=n. \end{cases}$$

在 $[0,1]$ 上用权 $\rho(x)=1$ 的正交多项式对 $f(x)=\sin \pi x, x \in [0,1]$ 做二次最佳逼近。

解：用Gram-Schmidt正交化构造正交多项式 $\varphi_0, \varphi_1, \varphi_2$，

$$\varphi_0(x) = 1,$$

$$(\varphi_0,\varphi_0) = 1, \quad (x,\varphi_0)=\frac{1}{2},$$

$$\varphi_1(x) = x-\frac{1}{2}$$

$$(\varphi_1,\varphi_1) = \frac{1}{12}, \quad (x^2,\varphi_1)=\frac{1}{12}, \quad (x^2,\varphi_0)=\frac{1}{3},$$

$$\varphi_2(x) = x^2-\frac{(x^2,\varphi_1)}{(\varphi_1,\varphi_1)}\varphi_1-\frac{(x^2,\varphi_0)}{(\varphi_0,\varphi_0)}\varphi_0 = x^2-x+\frac{1}{6}.$$

$$(f,\varphi_0) = \int_0^1 \sin \pi x dx = \frac{2}{\pi},$$

$$(f,\varphi_1) = \int_0^1 (x-\frac{1}{2}\sin \pi x) dx = 0,$$

$$(f,\varphi_2) = \int_0^1 (x^2 - x + \frac{1}{6}) \sin \pi x dx = -\frac{4}{\pi^3} + \frac{1}{3\pi},$$

$$(\varphi_2,\varphi_2) = \int_0^1 (x^2 - x + \frac{1}{6})^2 dx = \frac{1}{180}$$

所以

$$a_0^* = \frac{(f,\varphi_0)}{\|\varphi_0\|_2^2} = \frac{2}{\pi}$$

$$a_1^* = \frac{(f,\varphi_1)}{\|\varphi_1\|_2^2} = 0,$$

$$a_2^* = \frac{(f,\varphi_2)}{(\varphi_2,\varphi_2)} = 180\Big(\frac{1}{3\pi} - \frac{4}{\pi^3}\Big).$$

因此其2次最佳平方逼近函数为：

$$
\begin{aligned}
s_2^* &= a_0^*\varphi_0(x) + a_1^*\varphi_1(x) + a_2^*\varphi_2(x) \\
&= \frac{2}{\pi} + 180\left(\frac{1}{3\pi} - \frac{4}{\pi^3}\right)\left(x^2 - x + \frac{1}{6}\right) \\
&= 180\left(\frac{1}{3\pi} - \frac{4}{\pi^3}\right)x^2 - 180\left(\frac{1}{3\pi} - \frac{4}{\pi^3}\right)x \\
&\quad + \frac{2}{\pi} + 30\left(\frac{1}{3\pi} - \frac{4}{\pi^3}\right)
\end{aligned}
$$

定理 (最佳平方逼近的收敛性)

设 $f \in C[a,b], s_n^*$ 是 f 的最佳平方逼近多项式，而 $\{\varphi_j\}_{j\geq 0}$ 是正交多项式组，则有

$$\lim_{n\to\infty} \|f - s_n^*\|_2 = 0.$$

对于 $f \in C[a,b]$ 由 Parseval等式

$$\|f\|_2^2 = \sum_{j=0}^{\infty} \left(\frac{(f,\varphi_j)}{\|\varphi_j\|_2} \right)^2.$$

对于首项系数为 1 的Legendre多项式 $\tilde{P}_n(x)$ 有

定理

在所有首项系数为 *1* 的 n 次多项式中，*Legendre*多项式在 $[-1,1]$ 上与零的平方误差最小。 $\|\tilde{P}_n(x)\|_2^2$

证明：设 $Q_n(x)$ 是另一个 n 次首1的多项式，则

$$Q_n(x) = \tilde{P}_n(x) + \sum_{j=0}^{n-1} \alpha_j \tilde{P}_j(x)$$

$$\|Q_n\|_2^2 = (Q_n, Q_n) = (\tilde{P}_n + \sum_{j=0}^{n-1}\alpha_j \tilde{P}_j,\ \tilde{P}_n + \sum_{j=0}^{n-1}\alpha_j \tilde{P}_j)$$

$$= (\tilde{P}_n, \tilde{P}_n) + \sum_{j=0}^{n-1} \alpha_j^2 (\tilde{P}_j, \tilde{P}_j) \quad ((\tilde{P}_j, \tilde{P}_i) = 0 \ (i \neq j))$$

$$= \|\tilde{P}_n\|_2^2 + \sum_{j=0}^{n-1} \alpha_j^2 \|\tilde{P}_j\|_2^2$$

$$\geq \|\tilde{P}_n\|_2^2 \qquad \text{“}=\text{”} \Leftrightarrow Q_n = \tilde{P}_n$$

用Legendre多项式展开求 $f(x)=e^x$ 在 $[-1,1]$ 上的最佳平方逼近多项式 (取 $n=1,3$)。

解:

$$\begin{aligned} P_0(x) &= 1, \quad P_1(x)=x, \\ P_2(x) &= \frac{3}{2}x^2-\frac{1}{2}, \quad P_3(x)=\frac{5}{2}x^3-\frac{3}{2}x. \end{aligned}$$

则

$$\begin{aligned} (f,P_0) &= \int_{-1}^{1} e^x dx \approx 2.3504, \ (f,P_1)=\int_{-1}^{1} xe^x dx \approx 0.7358, \\ (f,P_2) &= \int_{-1}^{1} (\frac{3}{2}x^2-\frac{1}{2})e^x dx \approx 0.1432 \\ (f,P_3) &= \int_{-1}^{1} (\frac{5}{2}x^3-\frac{3}{2}x)e^x dx \approx 0.02013. \end{aligned}$$

$$\int_{-1}^{1}[P_j(x)]^2dx=\frac{2}{2j+1},\ j=0,1,2,\cdots,$$

所以

$$\begin{aligned}a_0^* &= 1.1752,\ a_1^*=1.1036,\\ a_2^* &= 0.3578,\ a_3^*=0.07046.\end{aligned}$$

所以

$$\begin{aligned}S_1^*(x) &= 1.1752+1.1036x,\\ S_3^*(x) &= 1.1752+1.1036x+0.3578(\frac{3}{2}x^2-\frac{1}{2})\\ &\quad +0.07046(\frac{5}{2}x^3-\frac{3}{2}x)\\ &\approx 0.9963+0.9979x+0.5367x^2+0.1761x^3\end{aligned}$$

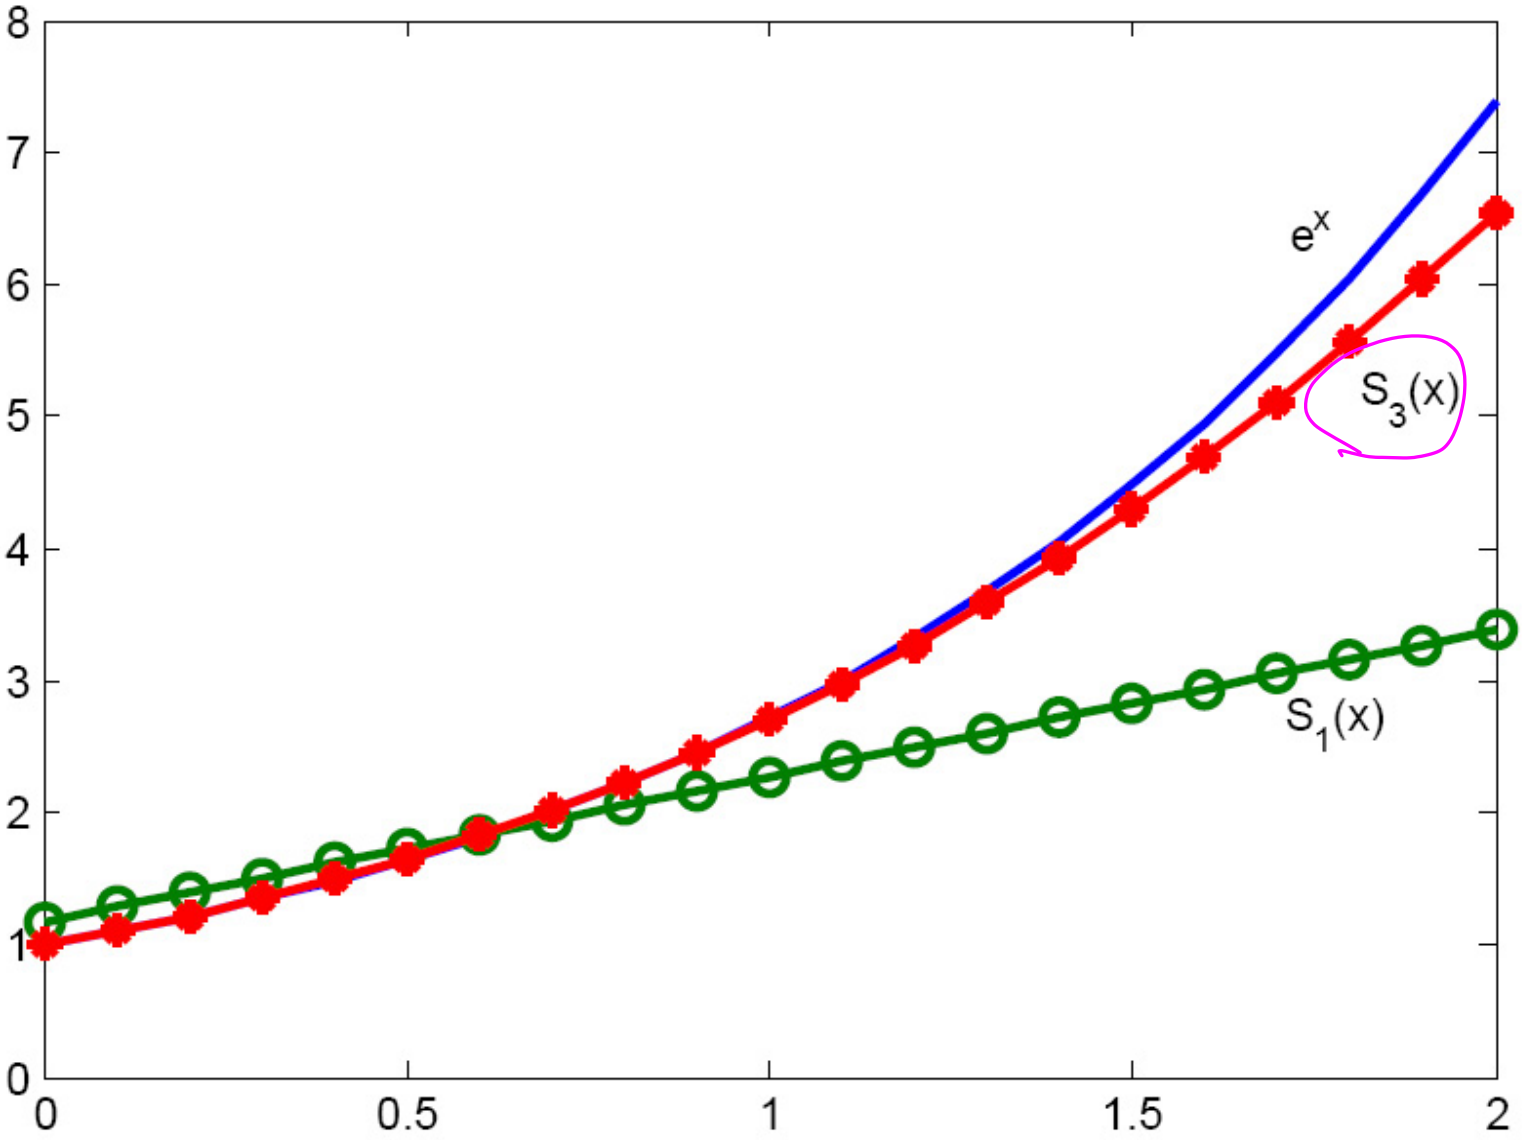
8
7
6
5
4
3
2
1
0
0
0.5
1
1.5
2
e^x
$S_3(x)$
$S_1(x)$

Chebyshev多项式零点插值

n 次Lagrange插值的余项为

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!}\omega_{n+1}(x), \quad x \in [a,b],$$

这里 $\xi(x) \in (a,b)$，节点多项式

$$\omega_{n+1}(x) = \prod_{i=0}^{n}(x - x_i) \in \mathcal{P}_{n+1}.$$

1. 等距节点的高次多项式插值当 $f(x)$ 的性质不够好的时候，有Runge现象，方法的相容性得不到保证。
2. 等距节点高次插值数值上不稳定。

在微分方程数值解等计算中，插值节点 x_i, $0 \le i \le n$ 可以自由选取，此时是否能取合适的插值节点使得

$$\|f(x) - L_n(x)\|_\infty = \frac{1}{(n+1)!} \max_{x_i} |f^{(n+1)}(\xi)\omega_{n+1}(x)|,$$

能达到极小，即

$$\|f(x) - \tilde{L}_n(x)\|_\infty = \min \|R_n(x)\|_\infty.$$

1. 其中$f^{(n+1)}(\xi)$和f 本身的性质有关，很难精确估算；
2. 但 $\omega_{n+1}(x)$ 可以通过Chebyshev多项式零点插值达到极小：

$$\|\tilde{\omega}_{n+1}(x)\|_\infty = \min \|\omega_{n+1}(x)\|_\infty.$$

Chebyshev多项式

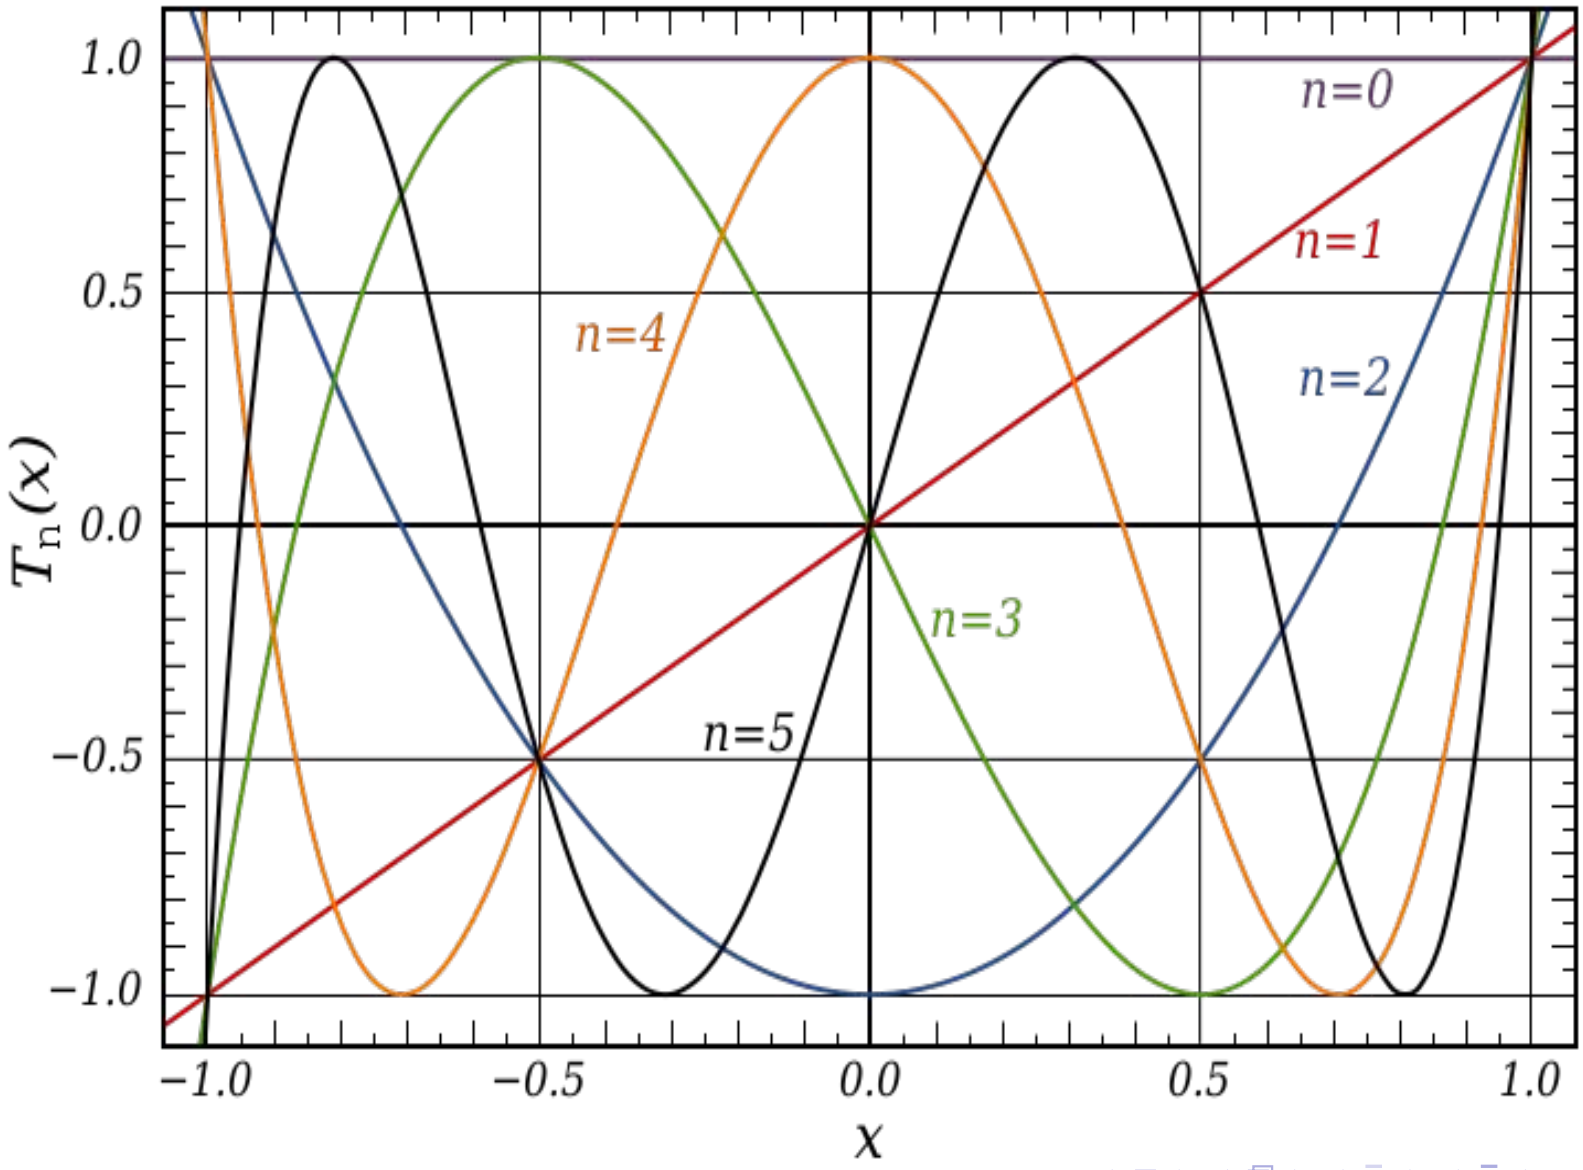

定理

若$p_n(x)$是首项系数为1的n次多项式，则

$$\|p_n\|_\infty = \max_{-1\le x\le 1} |p_n(x)| \ge 2^{1-n}.$$

$T_n(x)$首项系数2^{n-1}，

$\tilde{T}_n(x) = \frac{1}{2^{n-1}} T_n(x)$是首1的，

$\|T_n\|_\infty = 1$，$\|\tilde{T}_n\|_\infty = 2^{1-n}$

证明：$\tilde{T}_n(x) = \frac{1}{2^{n-1}} T_n(x)$，$\|\tilde{T}_n\|_\infty = 2^{1-n}$，令$x_j = \cos\frac{j}{n}\pi$，$0\le j\le n$，

则$\tilde{T}_n(x_j) = (-1)^j 2^{1-n}$，$0\le j\le n$，即$(-1)^j \tilde{T}_n(x_j) = 2^{1-n}$，$0\le j\le n$.

若$\exists$首1的多项式$q_n(x)$，s.t. $\|q_n\|_\infty < 2^{1-n}$，则

$q_n(x_j) \le \|q_n\|_\infty < 2^{1-n}$，$0\le j\le n$.

因此：$(-1)^j(\tilde{T}_n - q_n)(x_j) > 0$，$0\le j\le n$，有$n+1$个交错点，

则$\tilde{T}_n - q_n$有n个零点，但$\tilde{T}_n - q_n \in \mathcal{P}_{n-1}$，矛盾，则

$$\|q_n\|_\infty \ge 2^{1-n}.$$

∎

由Chebyshev多项式的性质知：

$$\max_{-1\le x\le 1} |\tilde{T}_n| = \max_{-1\le x\le 1} |\frac{1}{2^{n-1}} T_n| = 2^{1-n}.$$

因此在插值时，有：

$$\max_{x\in[-1,1]} |\tilde{T}_{n+1}(x)| \le \max_{x\in[-1,1]} |(x-x_0)(x-x_1)\cdots(x-x_n)|.$$

若要使得 $\max|\omega_{n+1}(x)|$ 达到极小，则 $x_i,\ 0\le i\le n$ 应为 $T_{n+1}(x)$ 的零点

$$x_i = \cos\left(\frac{2i+1}{2n+2}\pi\right),\quad 0\le i\le n.$$

$\|\omega_{n+1}(x)\|_\infty = 2^{-n}$

此时

$$|f(x)-L_n(x)| \le \frac{1}{2^n(n+1)!}\max_{|\xi|\le 1}|f^{(n+1)}(\xi)|,\quad \forall -1\le x\le 1.$$

Chebyshev多项式的零点

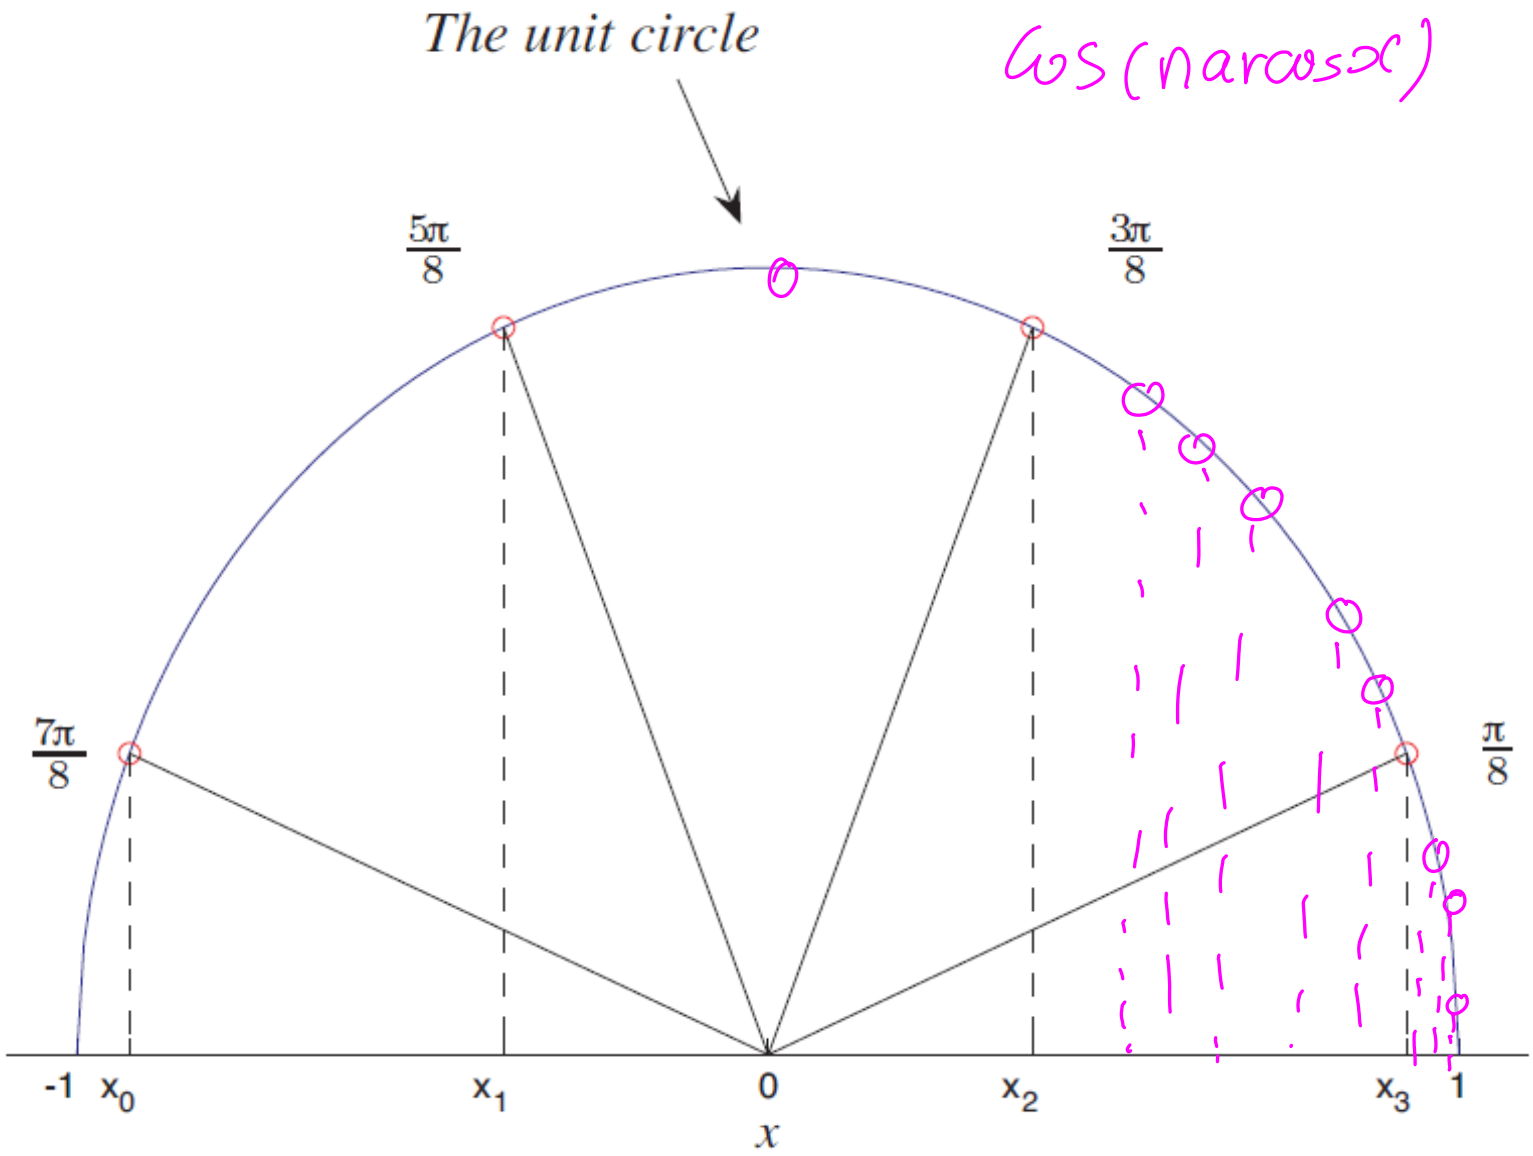

更一般的，若 $x \in [a,b]$，可通过变换

$$x = \frac{(b-a)t}{2} + \frac{a+b}{2}, \quad t \in]-1,1]$$

来实现Chebyshev零点插值。

定理

设 $f \in C^{n+1}[a,b]$，$L_n(x) \in \mathcal{P}_n$ 是 $f(x)$ 的 n 次Lagrange插值多项式，插值节点为

$$x_i = \frac{1}{2}(b-a)\cos\frac{(i+1/2)\pi}{n+1} + \frac{1}{2}(b+a), \quad 0 \le i \le n,$$

则有

$$\|f(x) - L_n(x)\|_\infty \le \frac{(b-a)^{n+1}}{2^{2n+1}(n+1)!}\|f^{(n+1)}\|_\infty.$$

等距节点插值

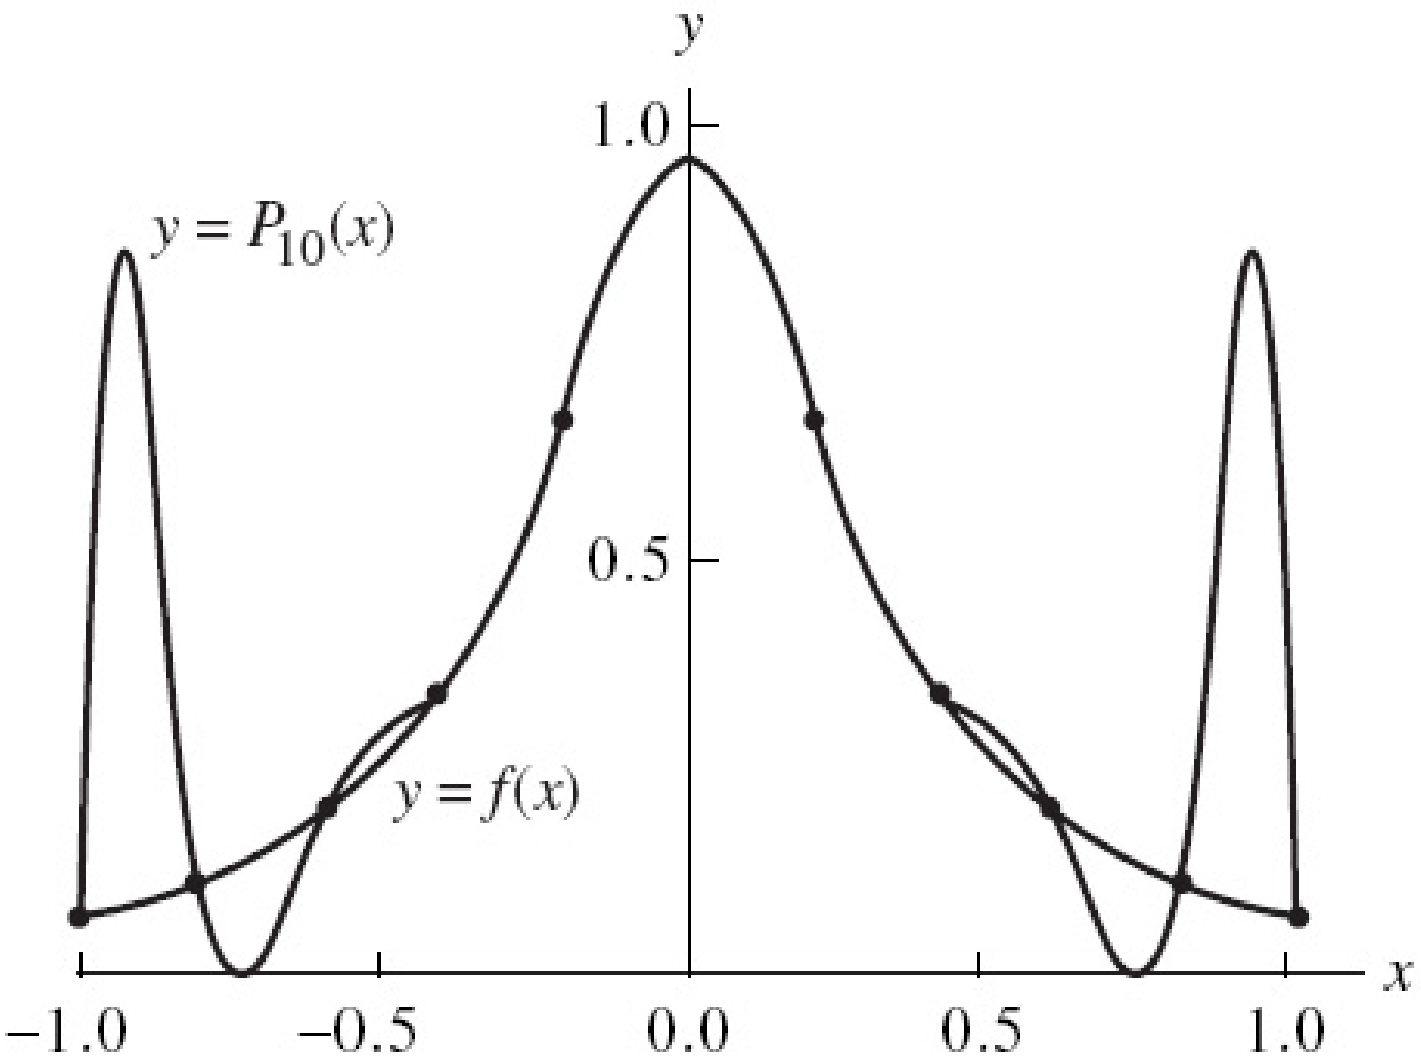

Chebyshev多项式零点插值

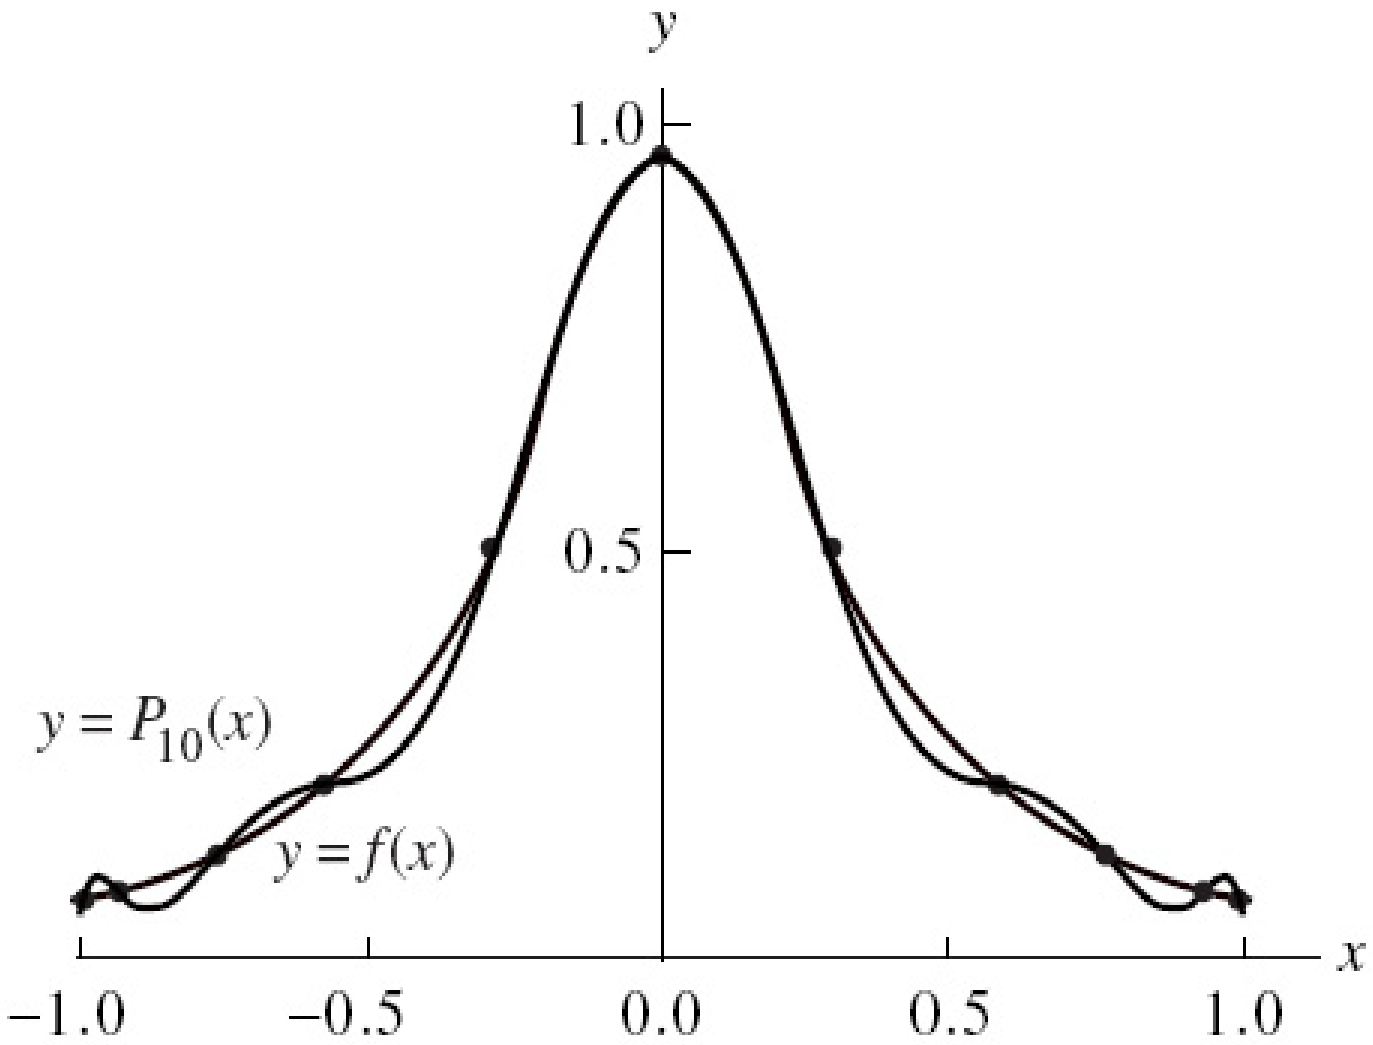

数学家简介 (Chebyshev)

卡切比雪夫（*1821–1894*），俄罗斯数学家、力学家，俄罗斯数学的奠基人之一。他的学生有*Lyapunov*和*Markov*等。他的研究内容涉及数论、概率论、函数逼近论、积分学等方面。他证明了贝尔特兰公式，自然数列中素数分布的定理，大数定律的一般公式以及中心极限定理。在力学方面，他主要从事这些数学问题的应用研究。他在一系列专论中对最佳近似函数进行了解析研究，并把成果用来研究机构理论。他首次解决了直动机构（将旋转运动转化成直线运动的机构）的理论计算方法，并由此创立了机构和机器的理论，提出了有关传动机械的结构公式。

最小二乘法（回归）

已知函数 $f(x)$ 在一些离散点上的值

$$(x_k, f(x_k)), \quad k = 0, 1, \cdots, n,$$

来构造 $f(x)$ 的逼近多项式除了前面的插值法外还有最小二乘多项式拟合法。这种方法对具有下列特点的数据非常有效：

1. 数据本身就有误差(如物理试验中的观测数据就不可避免的会有误差)。
2. 数据量很大。
3. 数据的采样分布能基本反映函数的变化趋势。

对于这样的数据，插值法是不合适的，亦即放弃让所构造的逼近函数 $p(x)$ 满足插值条件 $p(x_i) = f(x_i)$ 的要求。

设 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 是 $L^2_\rho[a,b]$ 上的线性无关函数组。令

$$\Phi = \mathrm{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}, \qquad s(x) = \sum_{j=0}^{n} a_j \varphi_j(x)$$

而 f 为在 $m+1$ 个节点 $a = x_0 < x_1 < \cdots < x_m = b$ 给定的离散函数，亦即 f 有函数表

$$(x_k, f(x_k)),\ k = 0, 1, \cdots, m,\quad \boldsymbol{f} = [f(x_0), f(x_1), \cdots, f(x_m)]^{\mathsf{T}} \in \mathbb{R}^{m+1}.$$

则有如下的定义：

定义 (最小二乘法–least square method)

设 f 为在 $m+1$ 个节点上给定的离散函数，最小二乘法为求 $s^* \in \Phi$ 使得

$$\|f - s^*\|_2^2 = \min_{s\in\Phi} \|f - s\|_2^2$$

$$\sum_{j=0}^{m} \rho(x_j)[f(x_j) - s^*(x_j)]^2 = \min_{s\in\Phi} \sum_{j=0}^{m} \rho(x_j)[f(x_j) - s(x_j)]^2$$

s^* 称为 f 在 $m+1$ 个节点上的最小二乘解，也称为最小二乘曲线拟合。

上述定义中

$$s(x)=\sum_{k=0}^{n} a_k\varphi_k(x), x\in[a,b],$$

是待求的 $a_0,a_1,\cdots,a_n$ 的线性函数，因而亦称上述问题为线性最小二乘问题。

定义离散函数 $\boldsymbol{f},\boldsymbol{g}$ 的内积和范数为

$$\vec{f}=\begin{bmatrix} f(x_0)\\ \vdots\\ f(x_m)\end{bmatrix}\in\mathbb{R}^{m+1},\quad \vec{g}=\begin{bmatrix} g(x_0)\\ \vdots\\ g(x_m)\end{bmatrix}\in\mathbb{R}^{m+1}$$

$$(\boldsymbol{f},\boldsymbol{g})=\sum_{j=0}^{m}\rho(x_j)f(x_j)g(x_j),\qquad \|f\|_2=\sqrt{\sum_{j=0}^{m}\rho(x_j)[f(x_j)]^2}.$$

则最小二乘问题实际上是一个最佳平方逼近：

求 $s^*\in\Phi$ 使得

$$\|f-s^*\|_2=\min_{s\in\Phi}\|f-s\|_2.$$

因此 $a_0, a_1, \cdots, a_n$ 满足法方程

$$\sum_{i=0}^{n}(\varphi_k, \varphi_i)a_i = d_k, \quad k = 0, 1, \cdots, n. \tag{0.5}$$

其中 $d_k = (f, \varphi_k) = \sum_{j=0}^{m} \rho(x_j) f(x_j) \varphi_k(x_j)$，具体写成方程组的形式为

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \ddots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \vdots \\ d_n \end{bmatrix}$$

这个方程组即为法方程，记其系数矩阵为 B，其中

$$(\varphi_i, \varphi_j) = \sum_{k=0}^{m} \rho(x_k) \varphi_i(x_k) \varphi_j(x_k).$$

记

$$A = \begin{bmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_n(x_1) \\ \vdots & \ddots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \cdots & \varphi_n(x_m) \end{bmatrix} \in \mathbb{R}^{(m+1)\times n},$$

$A\vec{x} = \vec{b}$
$m \gg n$, 方程超定.

$$\Lambda = \mathrm{diag}(\rho(x_0), \rho(x_1), \cdots, \rho(x_m)),$$

则法方程的系数矩阵

$$B = A^{\mathsf{T}}\Lambda A$$

若 $\rho(x) = 1$ 则

(φ_0, φ_0)

$$B = A^{\mathsf{T}}A = \begin{bmatrix} \varphi_0(x_0) & \varphi_0(x_1) & \cdots & \varphi_0(x_m) \\ \varphi_1(x_0) & \varphi_1(x_1) & \cdots & \varphi_1(x_m) \\ \vdots & \ddots & \ddots & \vdots \\ \varphi_n(x_0) & \varphi_n(x_1) & \cdots & \varphi_n(x_m) \end{bmatrix} \begin{bmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_n(x_1) \\ \vdots & \ddots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \cdots & \varphi_n(x_m) \end{bmatrix}$$

记

$$\begin{aligned} \boldsymbol{b} &= (f(x_0), f(x_1), \cdots, f(x_m))^{\mathsf{T}} \in \mathbb{R}^{m+1}, \\ \boldsymbol{x} &= (a_0, a_1, \cdots, a_n)^{\mathsf{T}} \in \mathbb{R}^n \end{aligned}$$

因为 $d_k = (f, \varphi_k) = \sum_{j=0}^{m} \rho(x_j) f(x_j) \varphi_k(x_j)$，记

$$\boldsymbol{d} = (d_0, d_1, \cdots, d_n)^{\mathsf{T}} = A^{\mathsf{T}} \Lambda \boldsymbol{b},$$

且对 $s(x) = \sum_{k=0}^{n} a_k \varphi_k(x)$ 有

$$\sum_{j=0}^{m} \rho(x_j)[f(x_j) - s(x_j)]^2 = \|\boldsymbol{b} - A\boldsymbol{x}\|_2^2.$$

则最小二乘问题有如下等价定义：

定义 (线性最小二乘)

给定矩阵 $A \in \mathbb{R}^{m\times n}$ 及向量 $\boldsymbol{b} \in \mathbb{R}^m$，确定 $\boldsymbol{x}$ 使得

$$\|\boldsymbol{b} - A\boldsymbol{x}\|_2 = \|\boldsymbol{r}(x)\|_2 = \min_{\boldsymbol{y}\in\mathbb{R}^n} \|\boldsymbol{r}(\boldsymbol{y})\|_2 = \min_{\boldsymbol{y}\in\mathbb{R}^n} \|A\boldsymbol{y} - \boldsymbol{b}\|_2.$$

称该问题为线性最小二乘问题。

定理

设 $A \in \mathbb{R}^{m\times n}, m \geq n$，若 A 列满秩，则 $\forall \boldsymbol{x} \in \mathbb{R}^n$ 有

$$\|A\boldsymbol{x}^* - \boldsymbol{b}\|_2 \leq \|A\boldsymbol{x} - \boldsymbol{b}\|_2 \Longleftrightarrow A^{\mathsf{T}}A\boldsymbol{x}^* = A^{\mathsf{T}}\boldsymbol{b}.$$

取 $\Phi = \text{span}\{1, x, x^2, \cdots, x^n\}$，此时称为多项式曲线拟合.

定理

多项式拟合中，法方程有唯一解。

证明：$\varphi_i(x) = x^i$，$0 \le i \le n$

$$A = \begin{bmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & & x_m^n \end{bmatrix},$$ Vandermonde矩阵.

若 x_i，$0 \le i \le m$ 互异，则 A 列满秩.

$B = A^T A$ 对称正定，法方程有唯一解.

例

由下列数据，试用一次、二次、三次和四次多项式进行曲线拟合，并给出相应的误差

j	0	1	2	3	4
x_j	0.00	0.25	0.50	0.75	1.00
$f(x_j)$	1.0000	1.2840	1.6487	2.1170	2.7183

先考虑二次多项式逼近，此时 $n=2, m=4$，法方程为

$$\begin{bmatrix} 5 & 2.5 & 1.875 \\ 2.5 & 1.875 & 1.562 \\ 1.875 & 1.562 & 1.382 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 8.7680 \\ 5.4514 \\ 4.4015 \end{bmatrix}$$

解得

$$a_0 = 1.0051, a_1 = 0.86468, a_2 = 0.84316.$$

则二次拟合多项式为

$$s^* = P_2^* = 1.0051 + 0.86468x + 0.84316x^2$$

其误差为

$$\delta_2^* = \sqrt{\sum_{j=0}^{4} [f(x_j) - P_2^*(x_j)]^2} = 1.66 \times 10^{-2}.$$

用一次多项式进行拟合，$n=1, m=4$，可得

$$P_1^*(x) = 0.8997 + 1.7078x.$$

类似的 $n=3, m=4$有

$$P_3^*(x) = 1.0000 + 1.0141x + 0.4253x^2 + 0.2789x^3.$$

同样地 $n=4, m=4$ 有

$$P_4^* = 1.0000 + 0.99868x + 0.5101x^2 + 0.1403x^3 + 0.0693x^4,$$

相应的误差为

$$\begin{aligned} \delta_1^* &= 0.916 \\ \delta_3^* &= 7.769 \times 10^{-3}. \end{aligned}$$

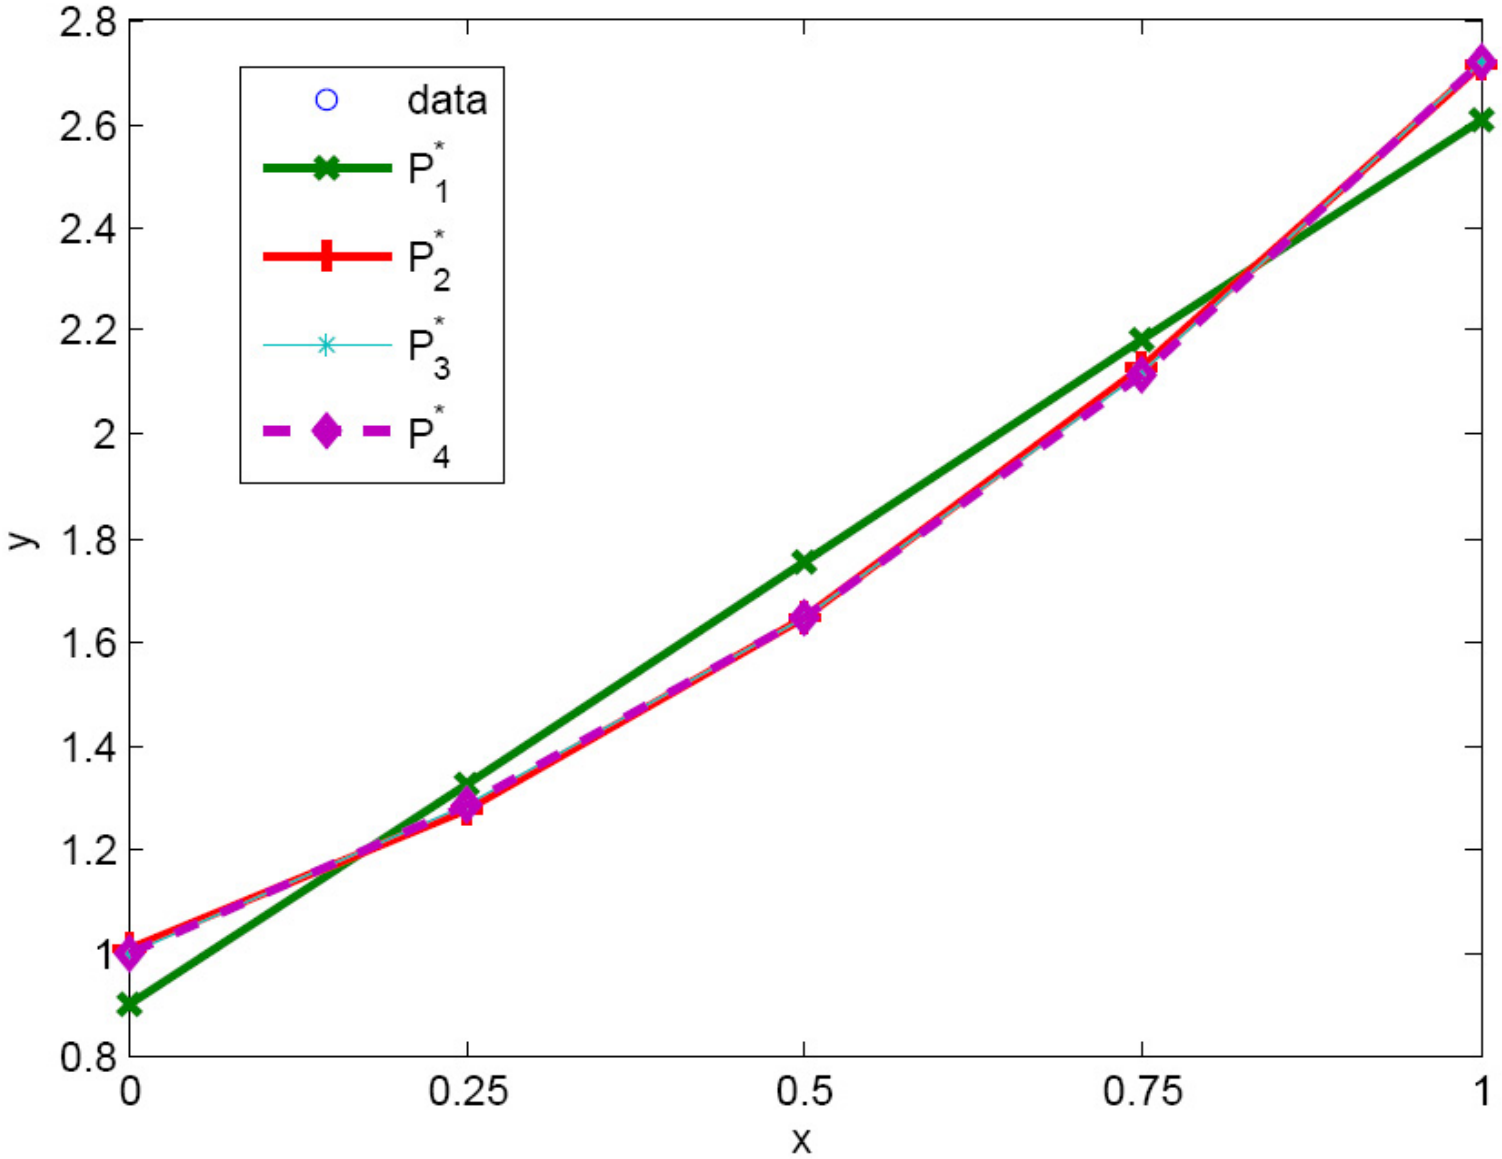
data
P_1^*
P_2^*
P_3^*
P_4^*
2.8
2.6
2.4
2.2
2
1.8
1.6
1.4
1.2
1
0.8
y
0
0.25
0.5
0.75
1
x

当 A 列满秩时，$A^{\mathsf{T}}A$ 为对称正定矩阵，因此可以用Cholesky方法求解。

1. 计算 $C = A^{\mathsf{T}}A, \boldsymbol{d} = A^{\mathsf{T}}\boldsymbol{b}$；
2. 作Cholesky分解 $C = LL^{\mathsf{T}}$；
3. 求解三角方程组 $L\boldsymbol{y} = \boldsymbol{d}$ 和 $L^{\mathsf{T}}\boldsymbol{x} = \boldsymbol{y}$。

计算量为 $n^2m + \frac{1}{3}n^3$，一般 $m \gg n$，所以主要的计算量为 n^2m。

算法的精度比较差，

$$A = \begin{bmatrix} 1 & 1 & 1 \\ \epsilon & 0 & 0 \\ 0 & \epsilon & 0 \\ 0 & 0 & \epsilon \end{bmatrix} \Rightarrow A^{\mathsf{T}}A = \begin{bmatrix} 1+\epsilon^2 & 1 & 1 \\ 1 & 1+\epsilon^2 & 1 \\ 1 & 1 & 1+\epsilon^2 \end{bmatrix}$$

当 $\epsilon = 10^{-8}$ 时，

$$\mathrm{cond}_2(A^{\mathsf{T}}A) \approx 2.7022 \times 10^{15}.$$

若 $A \in \mathbb{R}^{n\times n}$，从条件数的角度考虑

$$\mathrm{cond}_2(A^{\mathsf{T}}A) = [\mathrm{cond}_2(A)]^2.$$

一般来说最小二乘问题条件数不会很好！

很多时候借助于直接对矩阵 A 进行 QR 分解来求解最小二乘问题。

定理

设 $A \in \mathbb{R}^{m\times n}, m \geq n$ 列满秩，则存在唯一的列正交阵 $Q \in \mathbb{R}^{m\times n}$ 和唯一的具有正对角元 $r_{ii} > 0$ 的上三角阵 $R \in \mathbb{R}^{n\times n}$ 使得

$Q^TQ = I_{n\times n}$

$$A = QR$$

$A^TA = (QR)^TQR = R^TQ^TQR = R^TR$, → cholesky 分解.

QQ^T 是往 A 的列向量的正交投影矩阵

$A(A^TA)^{-1}A^Tb$

$A(A^TA)^{-1}A^T$

设 $A \in \mathbb{R}^{m\times n}, m \geq n$ 列满秩，$A = QR$，将 $Q \in \mathbb{R}^{m\times n}$ 加上 $m-n$ 个相互正交的列得到

$$[\underbrace{Q}_{n}, \underbrace{\tilde{Q}}_{m-n}] \in \mathbb{R}^{m\times m}$$

$Q \in Col(A) \to A$ 的列空间

$N(A^T)^\perp = Col(A)$

则

$$\begin{aligned}
\|Ax-b\|_2^2 &= \left\|[Q,\tilde{Q}]^\mathsf{T}(Ax-b)\right\|_2^2 \quad \text{正交变换保2-范数} \\
&= \left\|\begin{bmatrix}Q^\mathsf{T}\\ \tilde{Q}^\mathsf{T}\end{bmatrix}(QRx-b)\right\|_2^2 \quad A=QR \\
&= \left\|\begin{bmatrix}I^{n\times n}\\ O^{(m-n)\times n}\end{bmatrix}Rx - \begin{bmatrix}Q^\mathsf{T}b\\ \tilde{Q}^\mathsf{T}b\end{bmatrix}\right\|_2^2 \quad \tilde{Q}^\mathsf{T}Q=O \\
&= \left\|\begin{bmatrix}Rx-Q^\mathsf{T}b\\ \tilde{Q}^\mathsf{T}b\end{bmatrix}\right\|_2^2 \quad \text{与 } x \text{ 无关} \\
0 = &= \|Rx-Q^\mathsf{T}b\|_2^2 + \left\|\tilde{Q}^\mathsf{T}b\right\|_2^2 \\
&\geq \left\|\tilde{Q}^\mathsf{T}b\right\|_2^2
\end{aligned}$$

因而 $\boldsymbol{x}^*$ 是原最小二乘问题的解当且仅当 $\boldsymbol{x}^*$ 是如下问题的解

$$R\boldsymbol{x} = \boldsymbol{c}_1 = Q^\top \boldsymbol{b}.$$

有了 $A = QR$，利用法方程也可以导出最小二乘解

$$\begin{aligned}
\boldsymbol{x} &= (A^\top A)^{-1} A^\top \boldsymbol{b} \\
&= (R^\top Q^\top QR)^{-1} R^\top Q^\top \boldsymbol{b} \\
&= (R^\top R)^{-1} R^\top Q^\top \boldsymbol{b} \\
&= R^{-1} R^{-\top} R^\top Q^\top \boldsymbol{b} \\
&= R^{-1} Q^\top \boldsymbol{b}.
\end{aligned}$$

亦即

$$R\boldsymbol{x} = Q^\top \boldsymbol{b}.$$

基于QR分解的最小二乘法

从上面的推导得到利用 QR 分解求解最小二乘法的算法。

基于QR分解的最小二乘问题

1. 计算 A 的QR分解 $A = QR$;
2. 计算 $\boldsymbol{c}_1 = Q^T\boldsymbol{b}$;
3. 求解上三角方程 $R\boldsymbol{x} = \boldsymbol{c}_1$ 来得到线性最小二乘解。

QR分解求解线性最小二乘问题的计算量为

$$2n^2m - \frac{2}{3}n^3.$$

天下没有免费的午餐.

如果 $m \gg n$，其计算量为法方程的2倍；若 $m = n$ 则计算量相同。

模型与参数的选取

1. 线性最小二乘拟合的成功与否，与所选取的模型有很大的关系。
   - 模型参数太少，方法的精度不高（欠拟合）；
   - 模型所含的参数越多，平方误差会越小；若参数个数等于数据点个数，平方误差为零，但这并不意味模型很准，因为数据有噪音，此时会过拟合，方法的泛化能力很差。
2. 完全吻合数据的模型亦代表此模型受噪音的影响最大，预测的准确度也会很差(过拟合)。
3. 「模型复杂度」（即可变参数的个数）和「预测准确度」是相互抗衡的两个因素。

美国人口预测

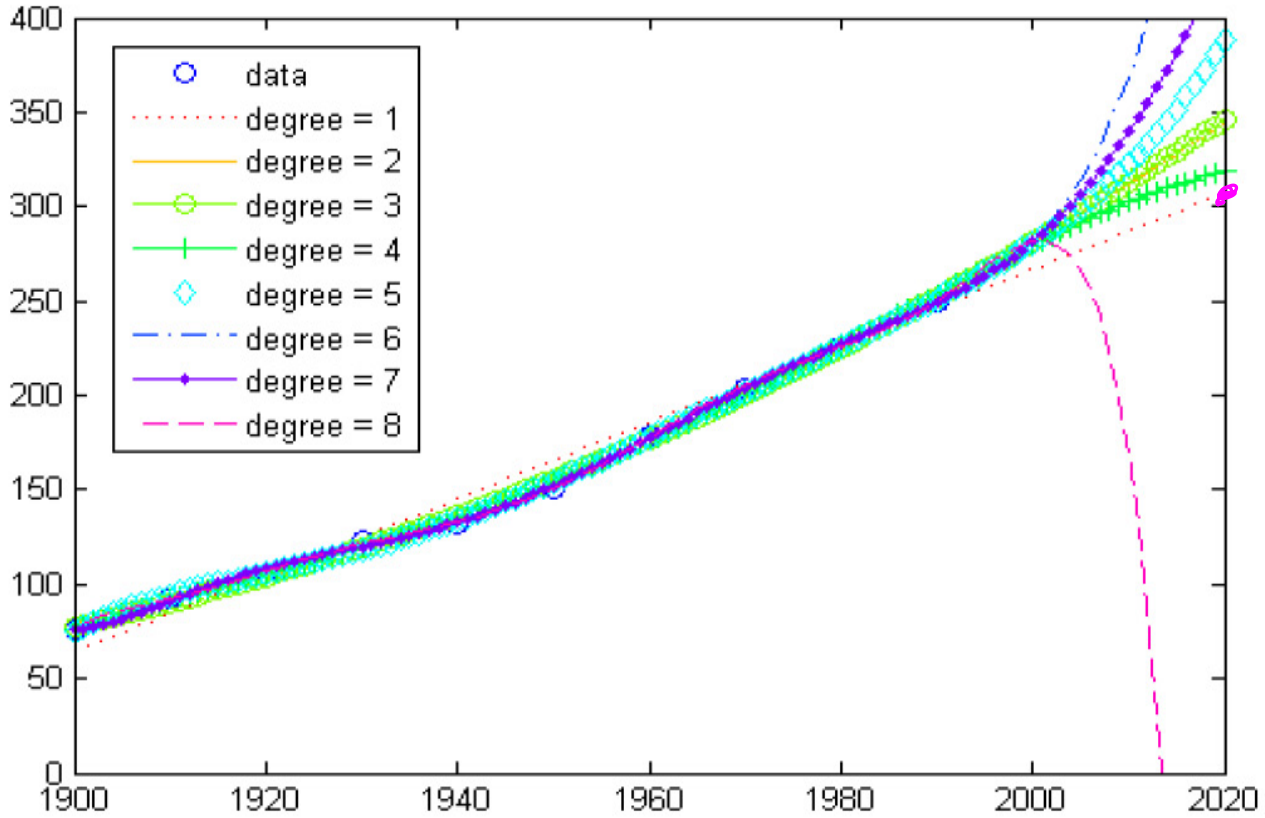

从上图可以看出，当多项式的次数越来越高时，「外插」(预测)常会出现不可信的结果。这说明选用的模型参数太多，虽然误差的平方和变小了，但是预测的可靠度也下降了

正则化

随着模型复杂度的增加，即逼近空间的基底的个数增长，模型会过拟合。一个克服过拟合的方法是正则化，误差函数加上正则项

$$E(\boldsymbol{x}) = \|\boldsymbol{b} - A\boldsymbol{x}\|_2^2 + \lambda E_r(\boldsymbol{x}).$$

$\min \|b-Ax\|_2^2$

$E_r(x) = 1$

其中$E_r(\boldsymbol{x})$是正则项，λ是正则参数。通常

$$E_r(\boldsymbol{x}) = \|\boldsymbol{x}\|_2^2, \quad \text{岭回归(ridge regression)}$$

此时法方程的系数矩阵变为

$$A^TA + \lambda I$$

$Cond_2(A^TA) = \frac{\lambda_{max}}{\lambda_{min}}$

$Cond_2(A^TA) = \frac{\lambda_{max}+\lambda}{\lambda_{min}+\lambda}$

为了得到稀疏解，可取

$$E_r(\boldsymbol{x}) = \|\boldsymbol{x}\|_1, \quad \text{Lasso}$$

稀疏正则化

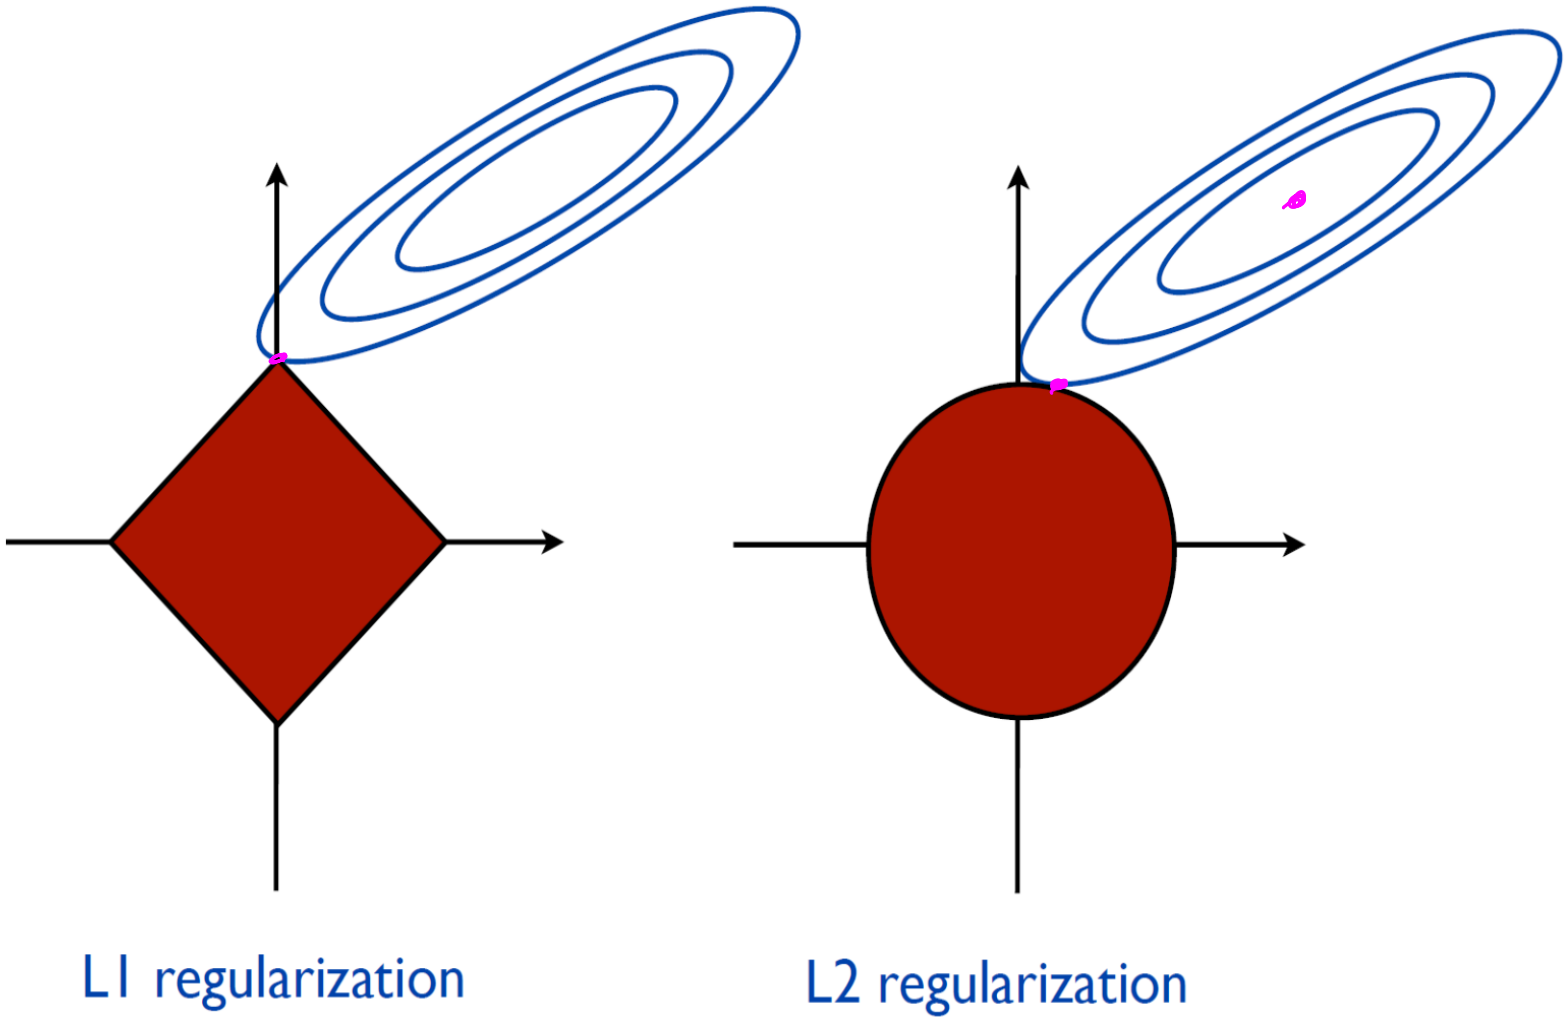

合适的模型

从上面的推导和例子看出，对于给定的数据 $(x_k, f(x_k))$，$k = 0, 1, \cdots, m$，选择合适的模型，亦即合适的函数空间 Φ 以及参数的个数至关重要。如果对给定的数据分布有一个大致的了解，对选用合适的模型有很大的帮助。

如果数据呈指数分布，即

$$s(x) = be^{ax},$$

这是一个非线性的模型。如果直接用曲线拟合的最小二乘法确定 a, b：

$$F(a,b) = \sum_{j=0}^{m} \rho(x_j)[f(x_j) - be^{ax_j}]^2.$$

极值的必要条件

$$\frac{\partial F}{\partial b} = 2\sum_{j=0}^{m}\rho(x_j)[f(x_j)-be^{ax_j}](-e^{ax_j}) = 0,$$

$$\frac{\partial F}{\partial a} = 2\sum_{j=0}^{m}\rho(x_j)[f(x_j)-be^{ax_j}](-bx_je^{ax_j}) = 0,$$

得到一个非线性方程组

$$\begin{cases} \sum_{j=0}^{m}\rho(x_j)[f(x_j)-be^{ax_j}]e^{ax_j} = 0, \\ \sum_{j=0}^{m}\rho(x_j)[f(x_j)-be^{ax_j}]bx_je^{ax_j} = 0. \end{cases}$$

线性化

若数据呈指数分布的情况，可两边取对数

$$\ln s(x) = \ln b + ax,$$

求出 a 和 $\ln b$ 是一个线性问题，取 $\Phi = \mathrm{span}(1, x)$，用线性最小二乘拟合得到 $\ln s^*(x)$，变换回去得到

$$s^*(x) = e^{\ln s^*(x)}.$$

注记

非线性的模型形式多样，在很多情况下可以通过变换变成线性模型，以及数据线性化，然后对线性化的数据有线性的最小二乘拟合。教材*P263*表*7.4* 给出了一些常用的可线性化的模型。

神经网络

前馈神经网络或多层感知机是用如下的函数复合形式

$$\hat{\boldsymbol{y}} = f^{(L)}(\cdots f^{(2)}(f^{(1)}(\boldsymbol{x}, \boldsymbol{\theta}^{(1)}); \boldsymbol{\theta}^{(2)}); \boldsymbol{\theta}^{(L)}).$$

来近似目标函数 $f^*(\boldsymbol{x})$。
参数 $\boldsymbol{\theta}^{(1)}, \cdots \boldsymbol{\theta}^{(L)}$ 需从数据集 $\mathbb{X}$ 学习得到。

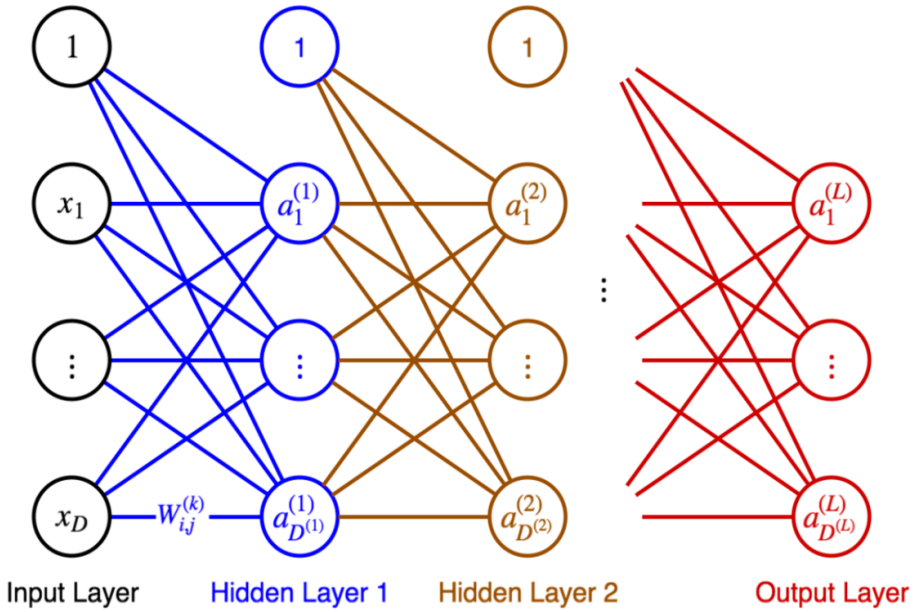

激发函数

在每层 k，函数 $f^{(k)}(\cdot; W^{(k)}, \boldsymbol{b}^{(k)})$ 是非线性的，其输出形式为

$$\boldsymbol{a}^{(k)} = \mathrm{act}^{(k)}\left(W^{(k)\mathsf{T}}\boldsymbol{a}^{(k-1)} + \boldsymbol{b}^{(k)}\right).$$

此处 $\mathrm{act}^{(i)}$ 被称为激发函数。

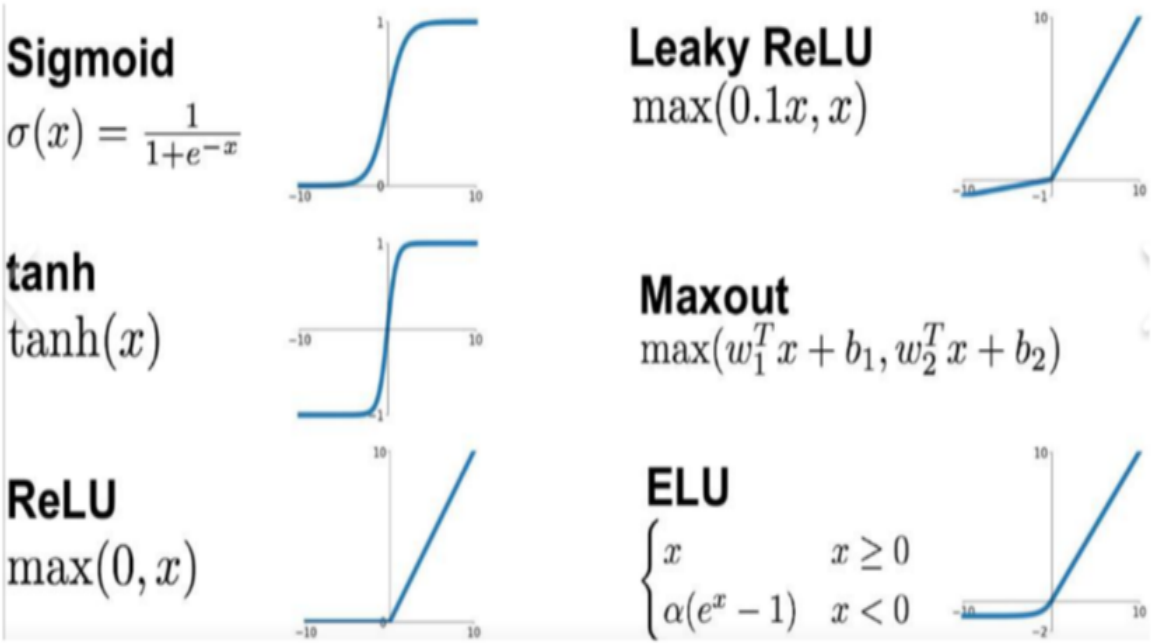

深度学习(deep learning)

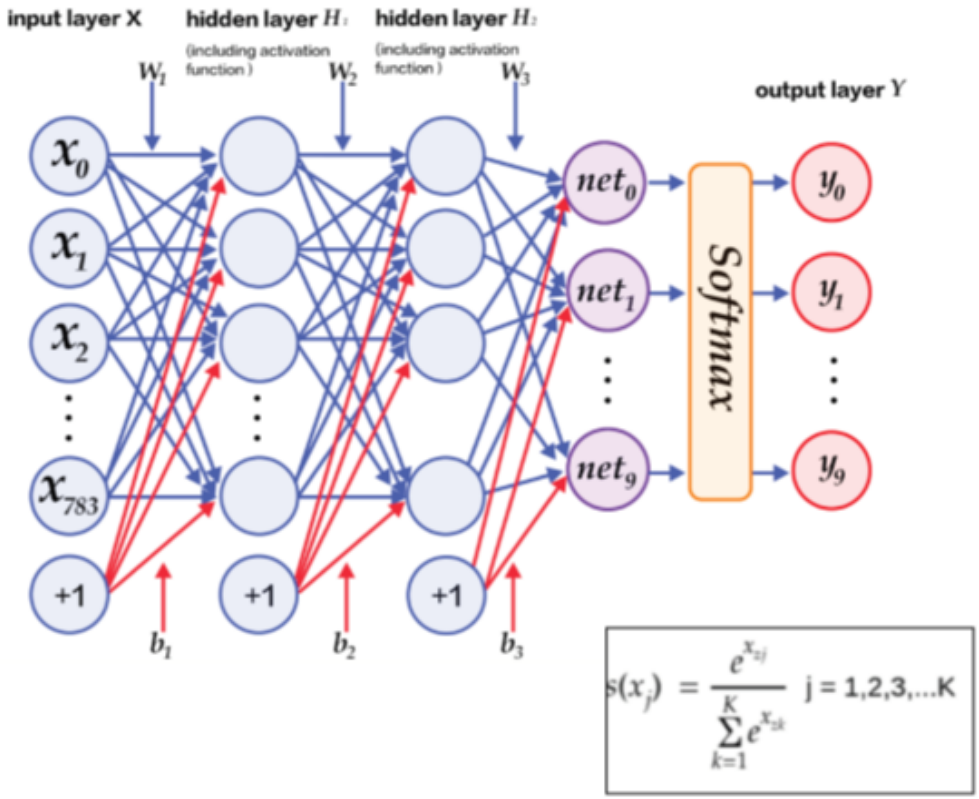

对线性的最小二乘问题，有

定理

设 $A \in \mathbb{R}^{m\times n}, m \geq n$，假定 A 为列满秩的，则 $\forall \boldsymbol{x} \in \mathbb{R}^n$ 有

$$\|A\boldsymbol{x}^* - \boldsymbol{b}\|_2 \leq \|A\boldsymbol{x} - \boldsymbol{b}\|_2 \Longleftrightarrow A^\intercal A\boldsymbol{x}^* = A^\intercal \boldsymbol{b}.$$

若A不是列满秩的，法方程的解不唯一。此时则转而求解下面的极小化问题

$$\begin{aligned} &\text{given} && A \in \mathbb{R}^{m\times n}, \boldsymbol{b} \in \mathbb{R}^m, \\ &\min_{\boldsymbol{x}\in\mathbb{R}^m} \|\boldsymbol{x}\|_2 && \text{使得 } \|A\boldsymbol{x} - \boldsymbol{b}\|_2 \leq \|A\hat{\boldsymbol{x}} - \boldsymbol{b}\|_2, \forall \hat{\boldsymbol{x}} \in \mathbb{R}^m \end{aligned}$$

最短解.

这个问题可以用奇异值分解（SVD, singular value decomposition）来求解。

定理 (奇异值分解)

任意矩阵 $A \in \mathbb{R}^{m\times n}$，令 $r = rank(A)$，则存在正交矩阵 $U \in \mathbb{R}^{m\times r}$ 和 $V \in \mathbb{R}^{n\times r}$ 使得

$$A = U\Sigma V^{\mathsf{T}},$$

这里 $\Sigma \in \mathbb{R}^{r\times r}$ 是对角阵，其对角元

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0,$$

- $\sigma_i, i = 1, \cdots, r$ 称为 A 的奇异值；
- 相应的分解称为奇异值分解；
- U 的列向量称为左奇异向量；
- V 的列向量称为右奇异向量。

证明：A^TA 是对称半正定阵，其特征值 $\sigma_1^2 \geq \sigma_2^2 \geq \cdots \geq \sigma_r^2 > \sigma_{r+1}^2 = 0$；

正交矩阵 V, s.t $V^TA^TAV = \Lambda = \begin{bmatrix} \Sigma_r^2 & \\ & 0 \end{bmatrix}$ $\Sigma_r = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$

令 $V = [V_1, V_2]$ $V_1 \in \mathbb{R}^{n\times r}$, $V_2 \in \mathbb{R}^{n\times(n-r)}$

$V_1 = [v_1, \cdots v_r]$ 是 $\sigma_1^2, \cdots \sigma_r^2$ 对应的特征向量.

$$V^TA^TAV = \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^TA [V_1, V_2] = \begin{bmatrix} V_1^TA^TAV_1 & V_1^TA^TAV_2 \\ V_2^TA^TAV_1 & V_2^TA^TAV_2 \end{bmatrix}$$

$V_2^TA^TAV_2 = 0$

即：$V_1^TA^TAV_1 = \Sigma_r^2$, $AV_2 = 0$

$\|AV_2\|_F^2 = \mathrm{trace}(V_2^TA^TAV_2) = 0$

$V_1^TA^TAV_1 = \Sigma_r^2$

定义 $U_1 = AV_1\Sigma_r^{-1}$, 则

$$U_1^TU = (AV_1\Sigma_r^{-1})^TAV_1\Sigma_r^{-1} = \Sigma_r^{-1}V_1^TA^TAV_1\Sigma_r^{-1}$$
$$= \Sigma_r^{-1}\Sigma_r^2\Sigma_r^{-1} = I$$

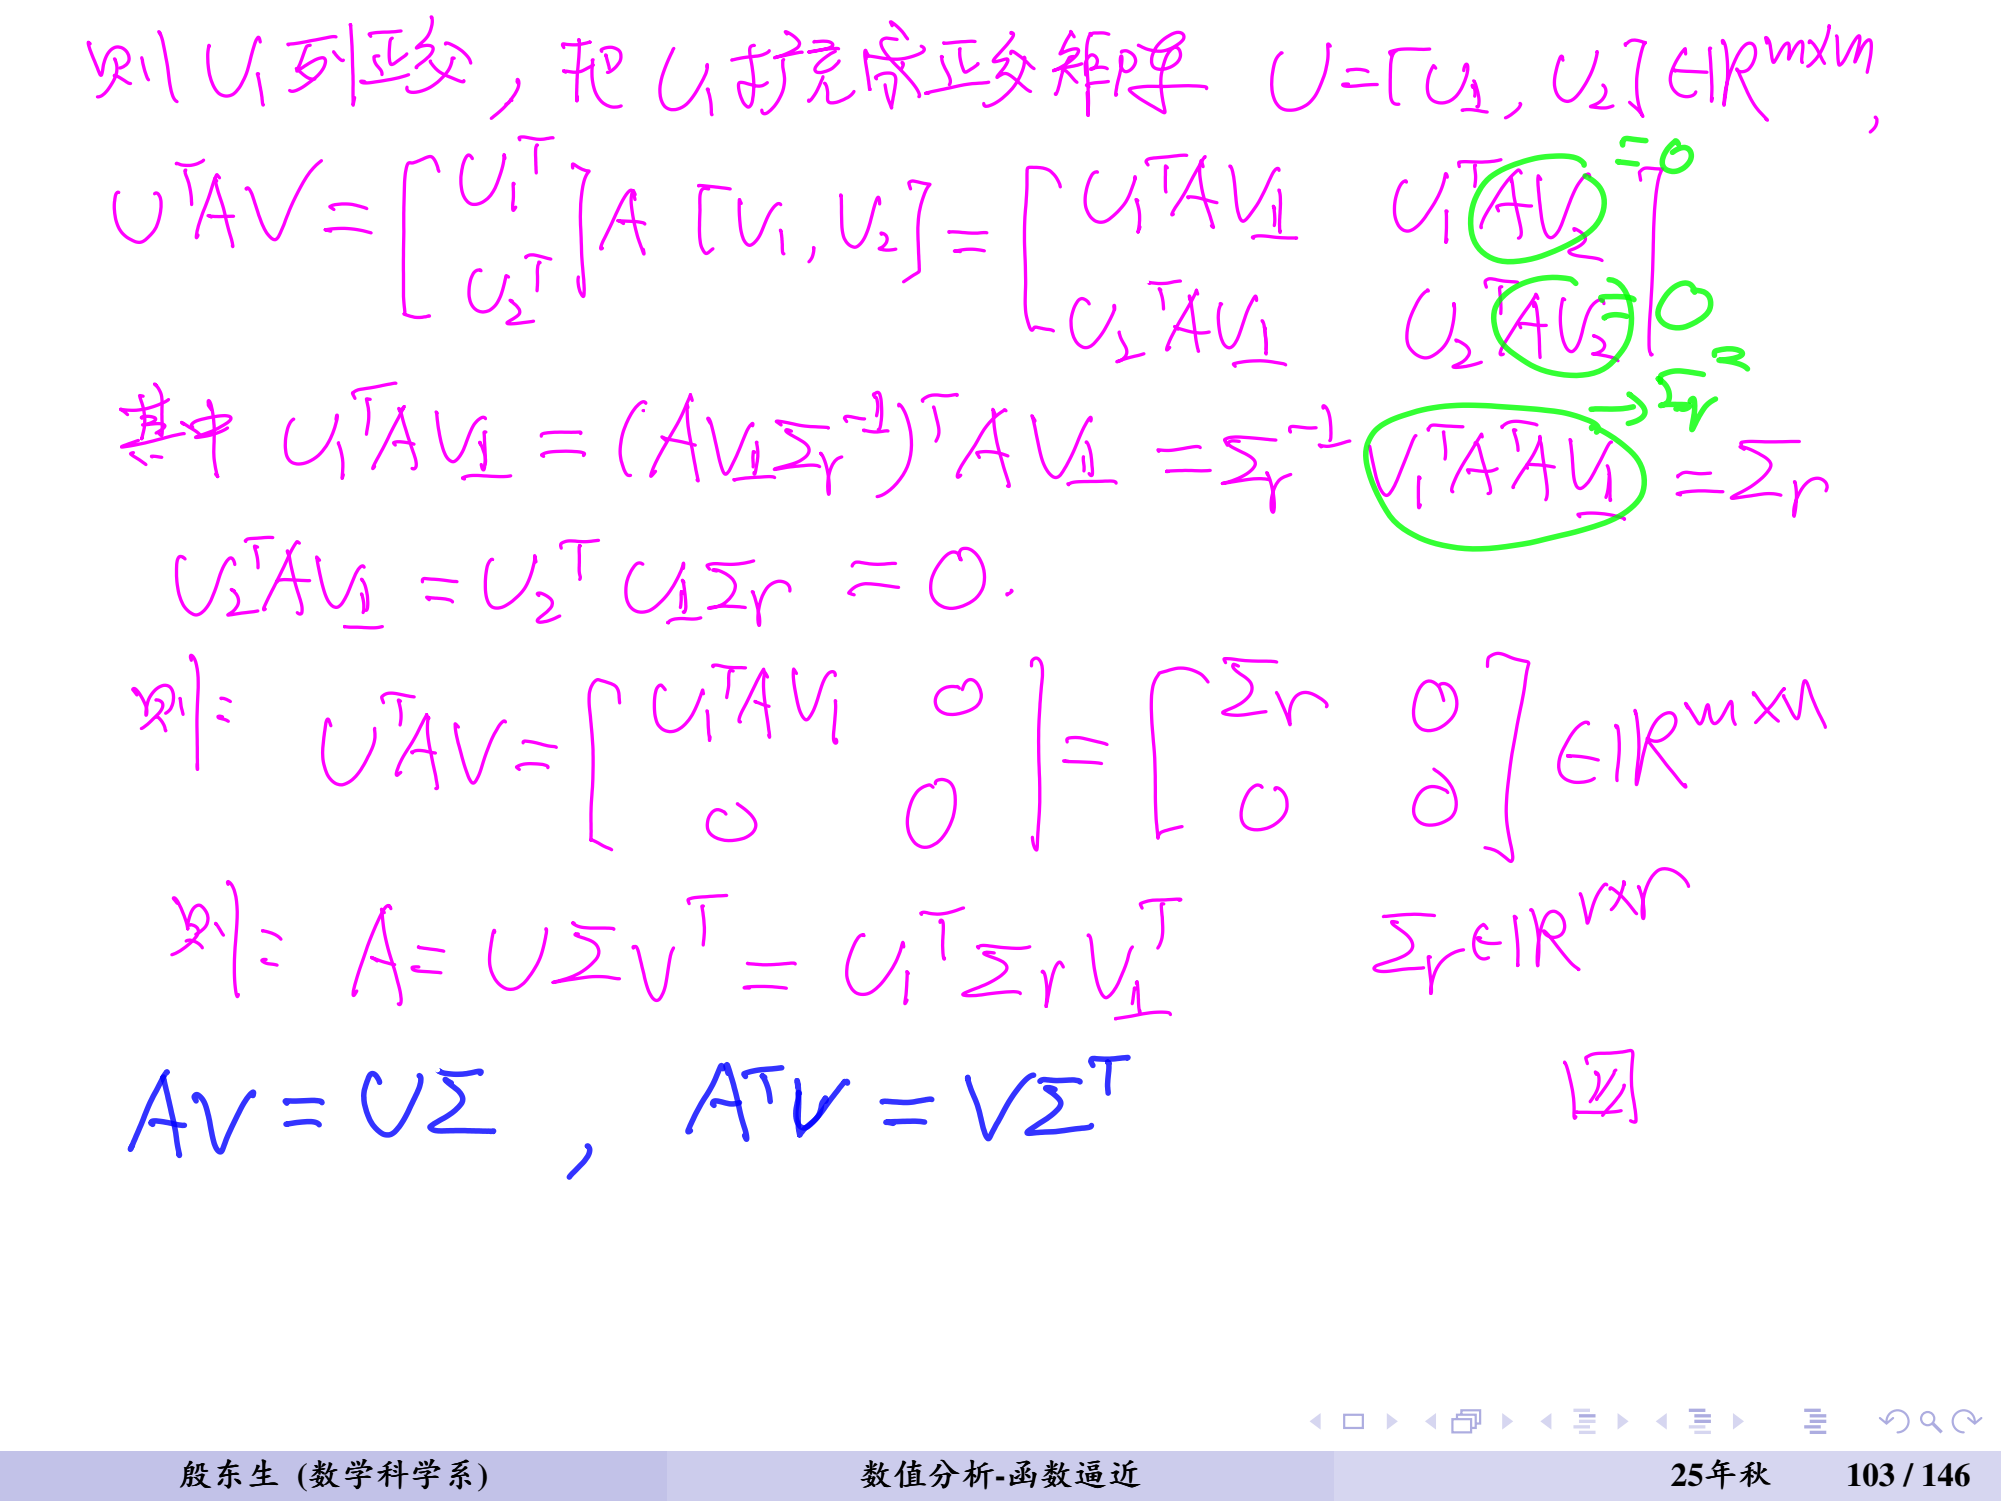
因 U_1 列正交，把 U_1 扩充成正交矩阵 $U=[U_1, U_2]\in\mathbb{R}^{m\times m}$，
$U^TAV=\begin{bmatrix}U_1^T\\U_2^T\end{bmatrix}A[U_1,U_2]=\begin{bmatrix}U_1^TAV_1 & U_1^TAV_2\\U_2^TAV_1 & U_2^TAV_2\end{bmatrix}$
$=0$
$=0$
$=\Sigma_r^2$
其中 $U_1^TAV_1=(AV_1\Sigma_r^{-1})^TAV_1=\Sigma_r^{-1}V_1^TA^TAV_1=\Sigma_r$
$U_2^TAV_1=U_2^TU_1\Sigma_r=0$.
则：$U^TAV=\begin{bmatrix}U_1^TAV_1 & 0\\0 & 0\end{bmatrix}=\begin{bmatrix}\Sigma_r & 0\\0 & 0\end{bmatrix}\in\mathbb{R}^{m\times n}$
则：$A=U\Sigma V^T=U_1\Sigma_rV_1^T$ $\Sigma_r\in\mathbb{R}^{r\times r}$
$AV=U\Sigma$，$A^TV=V\Sigma^T$
证

A 的SVD把 $\mathbb{R}^n$ 中的球变为椭球，椭球的半径就是奇异值。

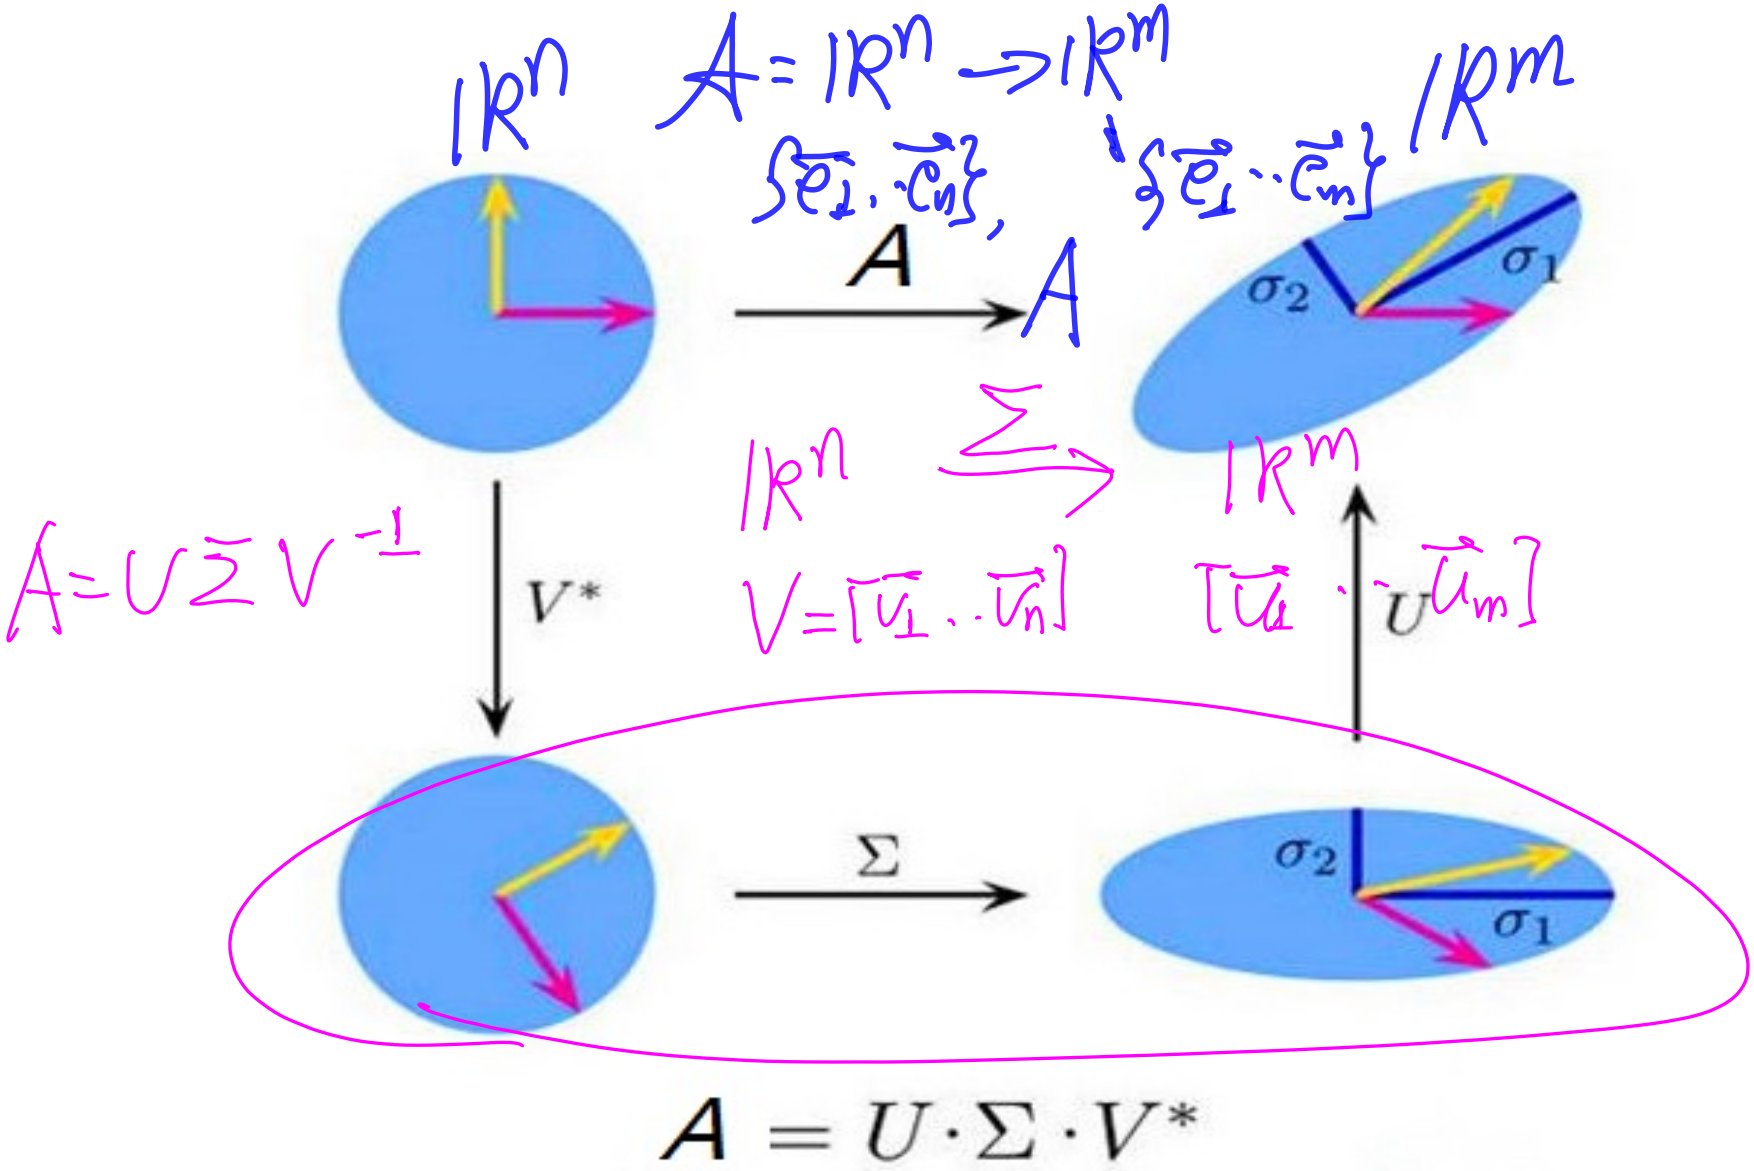

$$A = U \cdot \Sigma \cdot V^*$$

SVD的性质

1. $\mathrm{rank}(A) = r$，r 是非零奇异值的个数。
2. 矩阵 A 有奇异值展开

$$A = \sum_{i=1}^{r} \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

3. $\|A\|_2 = \sigma_1$ 为最大的奇异值。
4. $\|A\|_F = (\sum_{i=1}^{r} \sigma_i^2)^{1/2}$。
5. 若 $A \in \mathbb{R}^{n\times n}$ 非奇异，则 $\|A^{-1}\|_2 = 1/\sigma_r$。

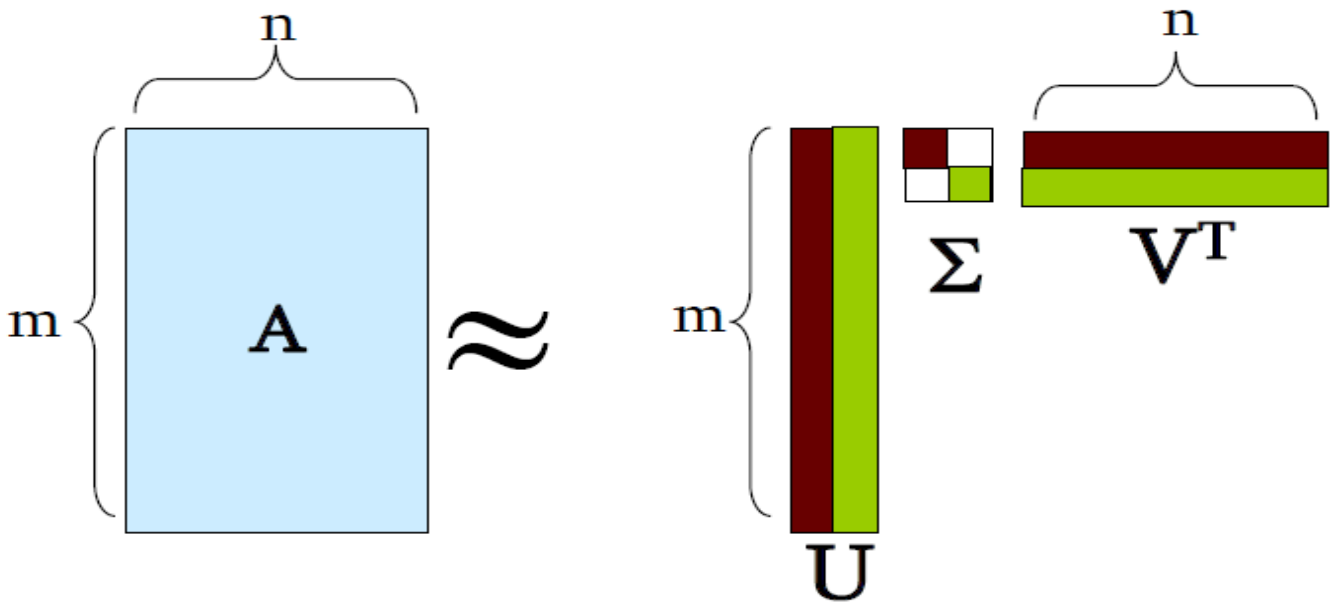
n
m
A
≈
n
m
U
Σ
V^T

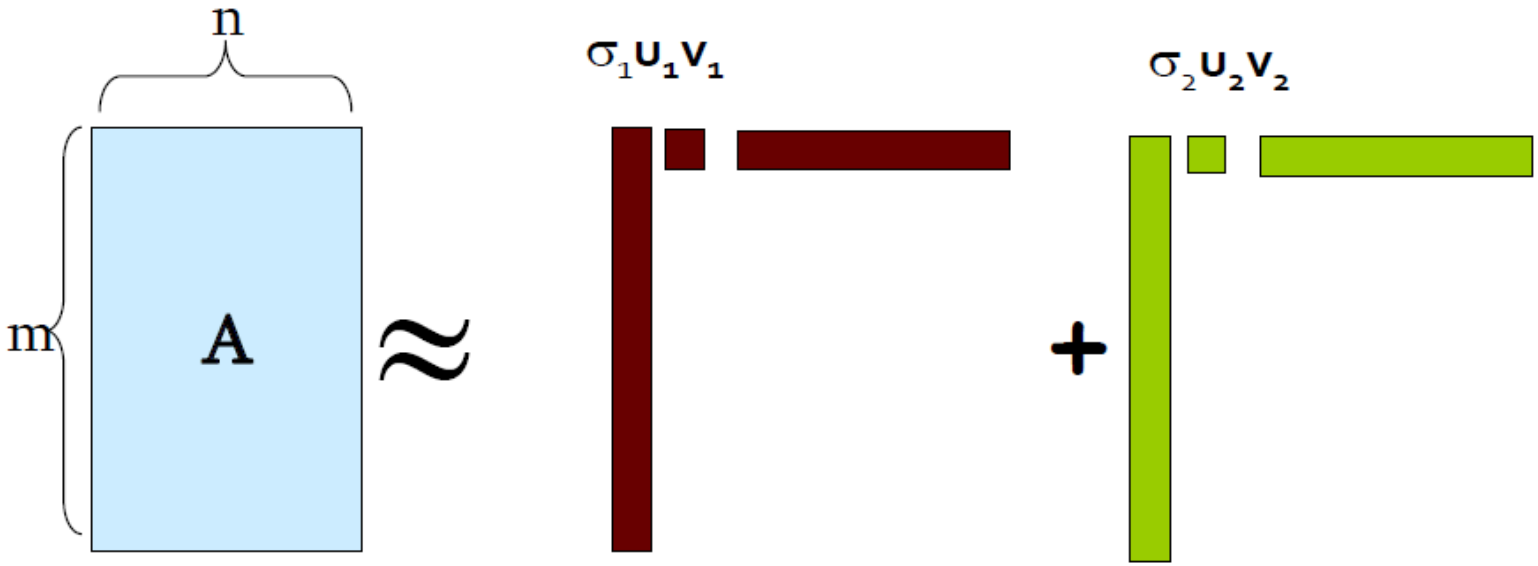
n
m
A
≈
σ1u1v1
σ2u2v2
+

奇异向量

左奇异向量和右奇异向量分别满足

$$\begin{aligned} A\boldsymbol{v}_i &= \sigma_i \boldsymbol{u}_i, \\ A^\top \boldsymbol{u}_j &= \sigma_j \boldsymbol{v}_j. \end{aligned}$$

则有

$$\begin{aligned} A^\top A\boldsymbol{v}_i &= V\Sigma U^\top U\Sigma V^\top \boldsymbol{v}_i = \sigma_i^2 \boldsymbol{v}_i, \\ AA^\top \boldsymbol{u}_i &= U\Sigma V^\top V\Sigma U^\top \boldsymbol{u}_i = \sigma_i^2 \boldsymbol{u}_i. \end{aligned}$$

- 右奇异向量 $\boldsymbol{v}_i$ 是 $A^\top A$ 的特征向量。
- 左奇异向量 $\boldsymbol{u}_i$ 是 $AA^\top$ 的特征向量。
- 可以通过求解 $A^\top A$ 和 $AA^\top$ 的特征值问题来得到奇异值分解。但是？

最小二乘问题中，若A是秩亏损的有下面的结论

推论

假定 $A \in \mathbb{R}^{m\times n}, m \geq n,$而 $rank(A) = r < n$。则存在一个 $n-r$ 维的向量 $\boldsymbol{x}$ 的集合极小化 $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$。

证明： 因为满足方程 $A\boldsymbol{z} = 0$ 的解空间为 $n-r$ 维，如果 $\boldsymbol{x}$ 极小化 $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$，则

$$\|A(\boldsymbol{x}+\boldsymbol{z}) - \boldsymbol{b}\|_2 = \|A\boldsymbol{x} - \boldsymbol{b}\|_2$$

同样也是极小解。

注记

这说明当A不满秩时，最小二乘解不唯一。

若 A 秩亏损，即 $A = U\Sigma V^\top$ 的秩 $r < n$，则 A 可表示为

$$A = [U, U_1] \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} [V, V_1]^\top = U\Sigma V^\top$$

这里

$$[U, U_1] \in \mathbb{R}^{m\times m}, \qquad [V, V_1] \in \mathbb{R}^{n\times n}$$

是正交矩阵。

$$\begin{aligned} \|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 &= \left\| \begin{bmatrix} U^\top \\ U_1^\top \end{bmatrix} (A\boldsymbol{x} - \boldsymbol{b}) \right\|_2^2 \\ &= \left\| \begin{bmatrix} U^\top \\ U_1^\top \end{bmatrix} (U\Sigma V^\top \boldsymbol{x} - \boldsymbol{b}) \right\|_2^2 \\ &= \left\| \begin{bmatrix} \Sigma V^\top \boldsymbol{x} - U^\top \boldsymbol{b} \\ U_1^\top \boldsymbol{b} \end{bmatrix} \right\|_2^2 \\ &= \|\Sigma V^\top \boldsymbol{x} - U^\top \boldsymbol{b}\|_2^2 + \|U_1^\top \boldsymbol{b}\|_2^2 \end{aligned}$$

从上面的式子可知当

$$\Sigma V^{\intercal}\boldsymbol{x} = U^{\intercal}\boldsymbol{b},\ \text{或者}\ \boldsymbol{x} = V\Sigma^{-1}U^{\intercal}\boldsymbol{b} + V_1\boldsymbol{z}$$

时 $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$ 达到极小，这里用到了

$$V^{\intercal}V_1\boldsymbol{z} = 0, \forall \boldsymbol{z}.$$

因为 V 和 V_1 相互正交，所以

$$\|\boldsymbol{x}\|_2^2 = \|V\Sigma^{-1}U^{\intercal}\boldsymbol{b}\|_2^2 + \|V_1\boldsymbol{z}\|_2^2$$

则

$$\begin{aligned}\min_{\boldsymbol{x}} \|\boldsymbol{x}\|_2^2 &= \min_{\boldsymbol{x}} \left\{\|V\Sigma^{-1}U^{\intercal}\boldsymbol{b}\|_2^2 + \|V_1\boldsymbol{z}\|_2^2\right\} \\ &= \|V\Sigma^{-1}U^{\intercal}\boldsymbol{b}\|_2^2\end{aligned}$$

亦即当 $\boldsymbol{z} = 0$ 时 $\|\boldsymbol{x}\|_2$ 达到极小。

最小二乘问题的极小模解为

$$\boldsymbol{x} \quad = \quad V\Sigma^{-1}U^{\mathsf{T}}\boldsymbol{b} = A^{+}\boldsymbol{b}.$$

此处

定义 (Moore-Penrose 逆 （pseudo-inverse 伪逆，广义逆))

假设 $A \in \mathbb{R}^{m\times n}$ 有奇异值分解 $A = U\Sigma V^{\mathsf{T}}$，则 A 的伪逆定义为

$$A^{+} = V\Sigma^{-1}U^{\mathsf{T}}.$$

易验证

$$A^{+}A \quad = \quad V\Sigma^{-1}\Sigma V^{\mathsf{T}} = VI_rV^{\mathsf{T}} = \sum_{i=1}^{r}\boldsymbol{v}_i\boldsymbol{v}_i^{\mathsf{T}}$$

$$AA^{+} \quad = \quad U\Sigma\Sigma^{-1}U^{\mathsf{T}} = UI_rU^{\mathsf{T}} = \sum_{i=1}^{r}\boldsymbol{u}_i\boldsymbol{u}_i^{\mathsf{T}}$$

$$A = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathsf{T}}, \qquad A^{+} = \sum_{i=1}^{r} \frac{1}{\sigma_i} \boldsymbol{v}_i \boldsymbol{u}_i^{\mathsf{T}},$$

$$AA^{+}A = A, \qquad A^{+}AA^{+} = A^{+}$$

且 AA^{+} 和 $A^{+}A$ 是对称矩阵。

当 A 列满秩时，最小二乘解为

$$\begin{aligned} \boldsymbol{x} &= (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\boldsymbol{b} \\ &= (V\Sigma^2 V^{\mathsf{T}})^{-1}A^{\mathsf{T}}\boldsymbol{b} \\ &= V\Sigma^{-2}V^{\mathsf{T}}V\Sigma U^{\mathsf{T}}\boldsymbol{b} \\ &= V\Sigma^{-1}U^{\mathsf{T}}\boldsymbol{b} \\ &= A^{+}\boldsymbol{b}. \end{aligned}$$

最小二乘问题的条件数

假定测量数据有误差，亦即实际计算的是 $\boldsymbol{b}+\boldsymbol{\delta b}$，则对最小二乘解有什么影响？

因为

$$(\boldsymbol{x}+\boldsymbol{\delta x})=V\Sigma^{-1}U^T(\boldsymbol{b}+\boldsymbol{\delta b}),$$

所以有

$$\boldsymbol{\delta x}=V\Sigma^{-1}U\boldsymbol{\delta b}.$$

而

$$\|V\Sigma^{-1}U\boldsymbol{\delta b}\|_2\leq\|\Sigma^{-1}\|_2\|\delta\boldsymbol{b}\|_2=\delta\boldsymbol{b}/\sigma_r,$$

其中 σ_r 是最小奇异值。

Q：最小二乘问题是否是病态问题？

低秩逼近–Low-Rank Approximation

令 $\mathcal{M}_{m,n}^{(r)}$ 是秩为 r 的 $m \times n$ 阶矩阵，设 $A \in \mathcal{M}_{m,n}^{(r)}$。想求 $B \in \mathcal{M}_{m,n}^{(k)}$，使得

$$\|A-B\|_F = \min_{rank(C)=k} \|A-C\|_F, \quad 或 \quad \|A-B\|_2 = \min_{rank(C)=k} \|A-C\|_2.$$

二范数下的低秩逼近

设

$$A_k = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathsf{T}}, \quad k < r,$$

则 $$\min_{rank(B)=k} \|A-B\|_2 = \|A-A_k\|_2 = \sigma_{k+1}.$$

为求解

$$\|A - B\|_F = \min_{rank(C)=k} \|A - C\|_F,$$

考虑

$$A = U\Sigma V^\intercal, \quad A_k = U\Sigma_k V^\intercal,$$

其中

$$\Sigma_k = \begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_k & & \\ & & & 0 & \\ & & & & \ddots \\ & & & & & 0 \end{bmatrix}$$

所以

$$\begin{aligned} \|A - A_k\|_F^2 &= \|U(\Sigma - \Sigma_k)V^\intercal\|_F^2 = \|\Sigma - \Sigma_k\|_F^2 \\ &= \sigma_{k+1}^2 + \cdots + \sigma_r^2 \end{aligned}$$

如果想找 A_k 使得

$$\|A - A_k\|_F^2 \le \epsilon^2, \ \ \mathrm{rank}(A_k) = \min$$

则 $A_k = U\Sigma_k V^\intercal$ 有

$$\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \cdots + \sigma_r^2.$$

若

$$\sigma_{k+1}^2 + \cdots + \sigma_r^2 \le \epsilon^2, \quad \sigma_k^2 + \cdots + \sigma_r^2 > \epsilon^2,$$

则 A_k 是最优解，且

$$\|A^+ - A_k^+\|_F^2 = \left(\frac{1}{\sigma_{k+1}^2} + \cdots + \frac{1}{\sigma_r^2} \right)$$

数据挖掘的主要工具：降维

降维的主要目标不仅仅是为了减小数据的数量（维度），而是

- 在进行下一步的数据分析[如人脸识别等]前，尽可能的去掉数据的噪音和冗余信息。
- 提取重要的“特征”和“参数”。

定义 (数据降维)

对数据 $X = [x_1, \cdots, x_n] \in \mathbb{R}^{m\times n}$ 求其低维的表示 $Y = [y_1 \cdots, y_n] \in \mathbb{R}^{d\times n}$。

数据降维可通过构造映射：

$$\Phi : x \in \mathbb{R}^m \longrightarrow y \in \mathbb{R}^d,$$

使其满足

$$\Phi_i(x_i) = y_i, \quad i = 1, \cdots, n.$$

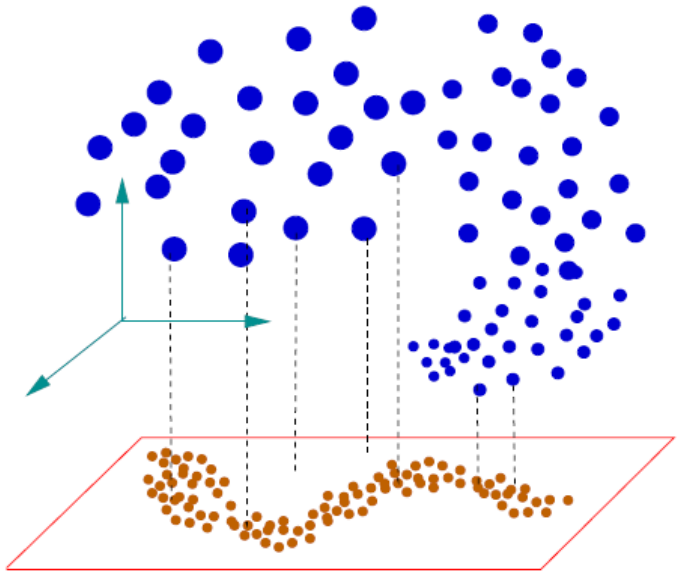

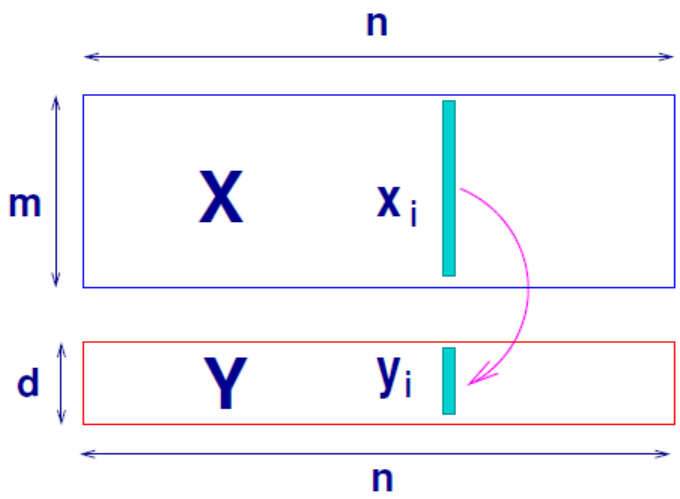

- Φ 可能是线性的：$y_i = W^{\mathsf{T}} x_i$，即 $Y = W^{\mathsf{T}} X$；
- Φ 也有可能是非线性的（隐式）；
- Φ 要求满足一定的要求：如距离最小，方差最大等。

主成分分析

主成分分析是求 W 使得投影数据的方差最大，即

$$\max_{W\in\mathbb{R}^{m\times d},W^{\intercal}W=I}\sum_{i=1}^{n}\left\|\boldsymbol{y}_i-\frac{1}{n}\sum_{j=1}^{n}\boldsymbol{y}_j\right\|_2^2,\quad \boldsymbol{y}_i=W^{\intercal}\boldsymbol{x}_i.$$

此问题和求如下的极大值问题等价：

$$\mathbf{Trace}\left[W^{\intercal}(X-\boldsymbol{\mu}\boldsymbol{e}^{\intercal})(X-\boldsymbol{\mu}\boldsymbol{e}^{\intercal})^{\intercal}W\right],\quad \boldsymbol{\mu}=\frac{1}{n}\sum_{i=1}^{n}\boldsymbol{x}_i.$$

而 W 是协方差矩阵的主特征向量，同时也是 $\overline{X}=X-\boldsymbol{\mu}\boldsymbol{e}^{\intercal}$ 的左奇异向量。

主成分分析-Principal components analysis（PCA）

低秩逼近可以用来做主成分分析，主成分分析是一种分析、简化数据集的技术。

定义 (主成分分析)

*PCA*的数学定义是：一个正交变换，把数据变换到一个新的坐标系中，使得这一数据的任何投影的第一大方差在第一个坐标（称为第一主成分）上，第二大方差在第二个坐标（第二主成分）上，依次类推。

主成分分析经常用于减少数据集的维数，同时保持数据集中的对方差贡献最大的特征。其方法主要是通过对协方差矩阵进行特征分解，以得出数据的主成分（即特征向量）与它们的权值（即特征值或奇异值）。

如图所示，通过正交变换将X-Y坐标映射到signal和noise上：

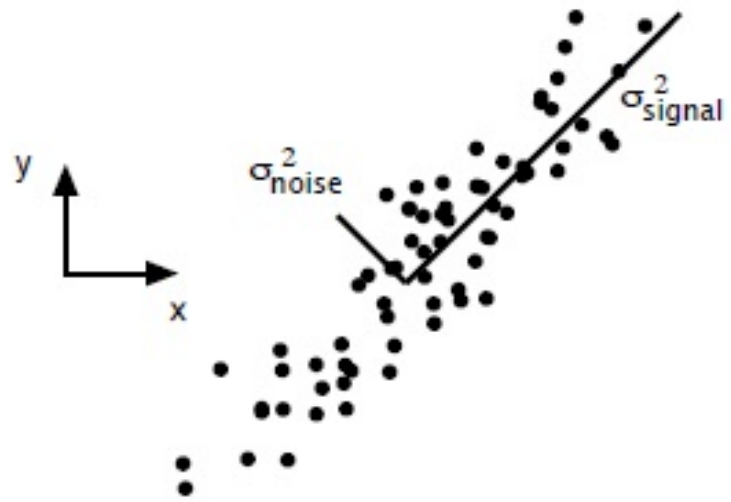

一般来说，方差大的方向是信号的方向，方差小的方向是噪声的方向，在数据挖掘中或者数字信号处理中，往往要提高信号与噪声的比例，也就是信噪比。上图中通过坐标变换后，找出方差最大的方向为第一个坐标（signal），然后在其正交的平面上找出方差最大的方向为第二个坐标（noise）。这样就可以通过选取最大的 k个坐标方向来达到对维度（特征）的提炼。

在 PCA中，投影向量 $\boldsymbol{w}^{(i)}$ 是第 i 个特征值 λ_i 对应的特征向量：

$$XX^{\mathsf{T}} = W\Lambda W^{\mathsf{T}}, \quad \text{这里 } W = [\boldsymbol{w}^{(i)}, \cdots, \boldsymbol{w}^{(m)}]$$

数据矩阵 $X \in \mathbb{R}^{m\times n}$ 有分解

$$X = U\Sigma V^{\mathsf{T}},$$

其中

$$U \in \mathbb{R}^{m\times r}, \quad \Sigma = \mathrm{d}iag[\sigma_1, \cdots, \sigma_r], \quad V \in \mathbb{R}^{n\times r}.$$

则

$$XX^{\mathsf{T}} = U\Sigma V^{\mathsf{T}} V\Sigma U^{\mathsf{T}} = U\Sigma^2 U^{\mathsf{T}}.$$

亦即

$$W = U, \lambda_i = \sigma_i^2.$$

X 有近似的 SVD,

$$X_{m\times n} \approx U_{m\times d}\Sigma_{d\times d}V^{\mathsf{T}}_{d\times n}$$

PCA可将维数 m 进行提炼，降维成 $d(d<n)$。

PCA降维

因为 $U^{\mathsf{T}}_{d\times m}U_{m\times d} = I$，则

$$\begin{aligned} U_{d\times m}X_{m\times n} &\approx U^{\mathsf{T}}_{d\times m}U_{m\times d}\Sigma_{d\times d}V^{\mathsf{T}}_{d\times n} \\ &= \Sigma_{d\times d}V^{\mathsf{T}}_{d\times n} \\ &= Y_{d\times n} \end{aligned}$$

这样通过SVD实现了PCA的坐标系变换和降维。

3D 数据

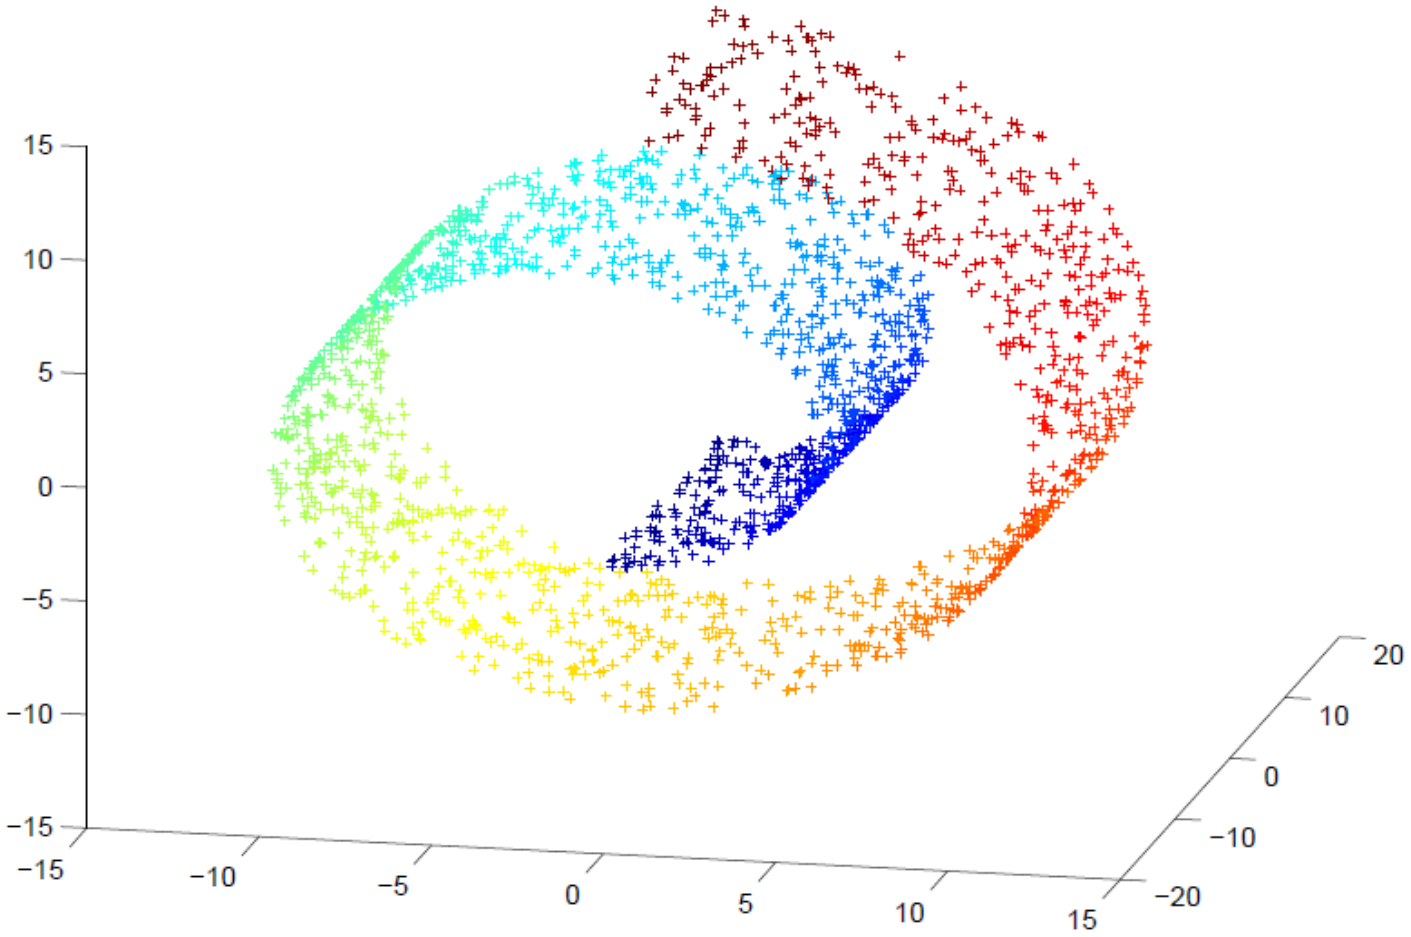

2D降维

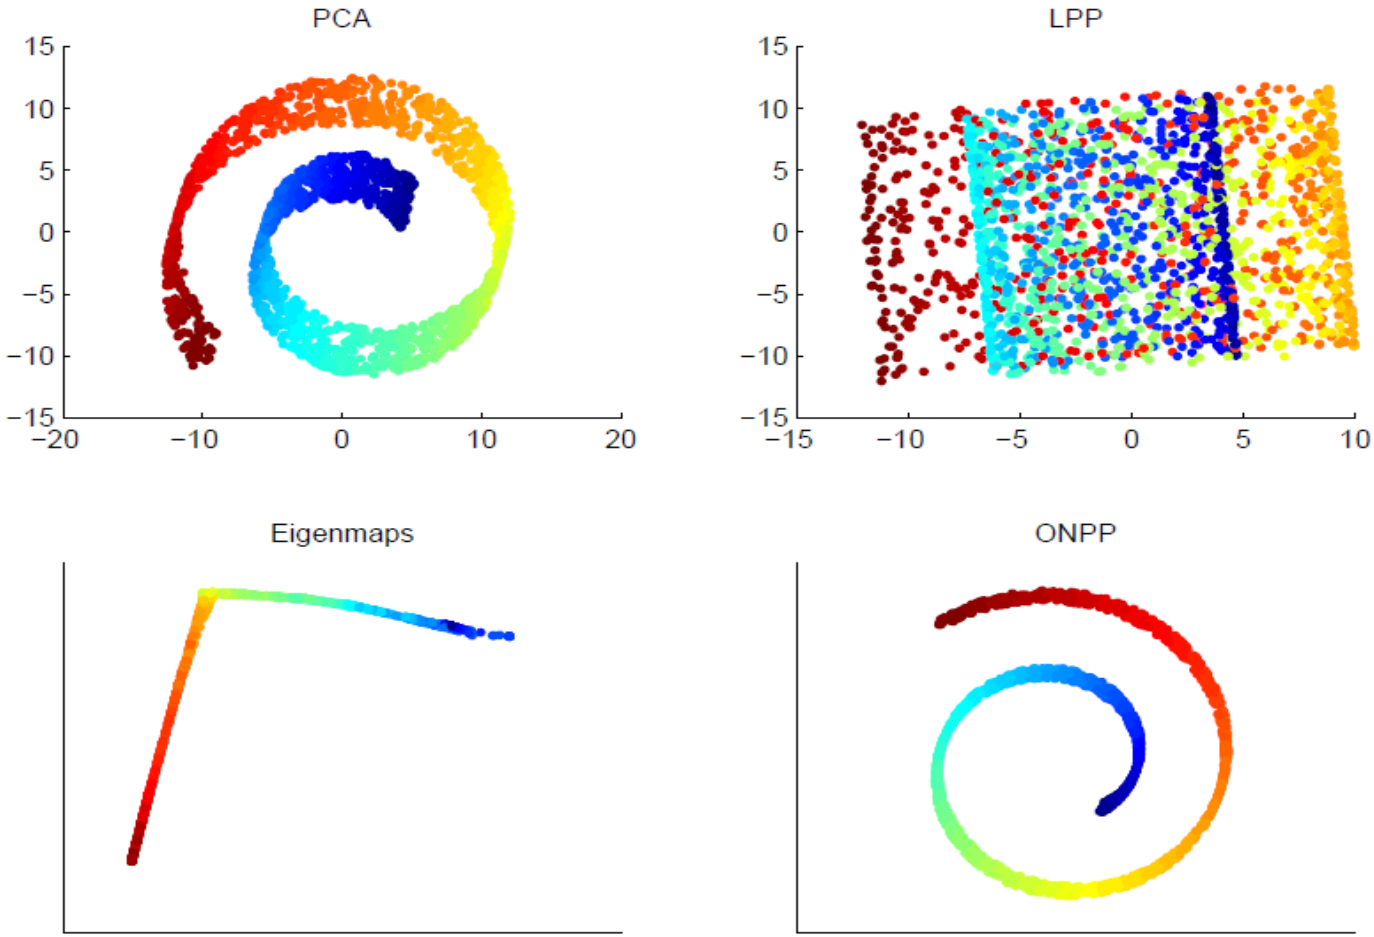

SVD 压缩

此外，SVD还可以进行数据的压缩

$$\begin{aligned} X_{m\times n}V_{n\times d} &\approx U_{m\times d}\Sigma_{d\times d}V^{\mathsf{T}}_{d\times n}V_{n\times d} \\ &= U_{m\times d}\Sigma_{d\times d} = \tilde{X}_{m\times d} \end{aligned}$$

如此则将 n 个数据压缩成 d 个数据。
压缩可以理解为，将一些相似的数据采样合并在一起，或者将一些没有太大价值的采样去掉。

可以看出，其实PCA几乎可以说是对SVD的一个包装，如果实现了SVD，那也就实现了PCA了，而且SVD可以得到两个方向的PCA，如果对 XX^{T} 进行特征值的分解，只能得到一个方向的PCA。

其中一个应用就是图像处理。

可以把$n \times n$的灰度图视为灰度强度的$n \times n$的矩阵。下面的命令先读入一个图像，把它转化成灰度图，最后把图像转化为矩阵。

```
A = imread('koala.jpg');  % read image from a file
A = rgb2gray(A);    % convert from color to grayscale
A = im2double(A);   % convert to double precision matrix
imshow(A);   % display the image in a window
```

下面的命令计算A的SVD，用奇异值分解去计算其秩r的最佳逼近，并给出图像。

```
[U, S, V] = svd(A);
for r = [1 2 5 10 25 50 100 298]
= U(:, 1:r) * S(1:r, 1:r) * V(:, 1:r)';
imshow(Ar);
pause;
imwrite(Ar, sprintf('koala-%d.jpg', r));
end
```

主成分分析在图像压缩和人脸识别等领域有重要的应用。

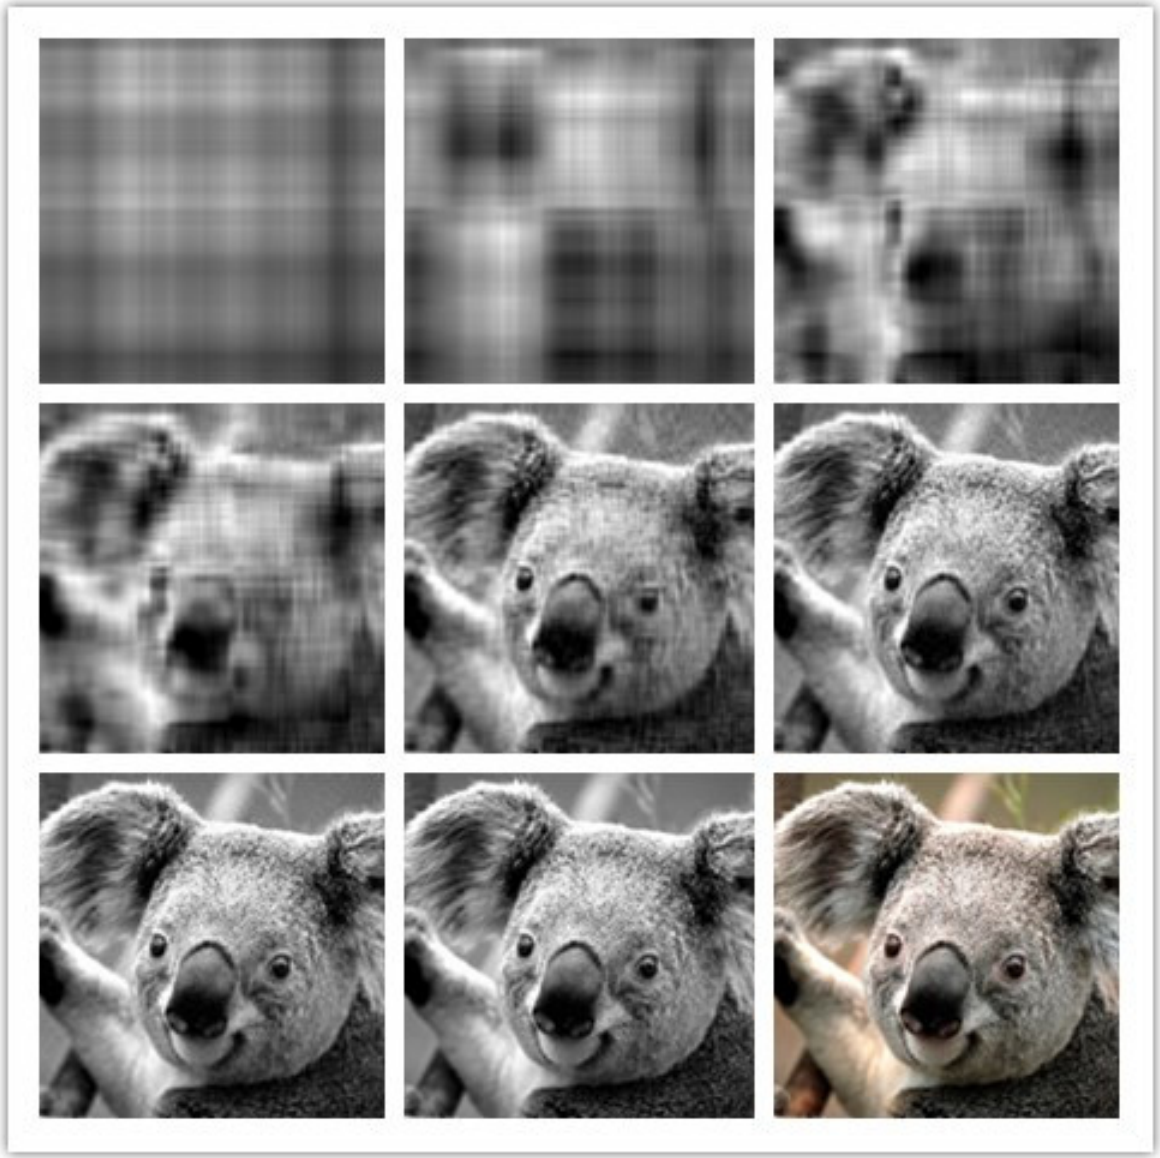

图: $k = 1, 2, 5, 10, 25, 50, 100, 298$

Matlab命令svds

- s = svds(A) returns a vector of the six largest singular values of matrix A.
- s = svds(A,k) returns the k largest singular values.
- s = svds(A,k,sigma) returns k singular values based on the value of sigma. For example, svds(A,k,'smallest') returns the k smallest singular values.
- s = svds(A,k,sigma,opts) additionally specifies options using a structure.
- s = svds(Afun,n,___) specifies a function handle Afun instead of a matrix A.
- [U,S,V] = svds(___) returns the left singular vectors U, diagonal matrix S of singular values, and right singular vectors V.
- [U,S,V,flag] = svds(___) also returns a convergence flag. If flag is 0, then all the singular values converged.

计算稀疏矩阵最大和最小奇异值

计算稀疏矩阵的最大奇异值

```
A = delsq(numgrid('C',15));
s = svds(A)
s =
7.8666
7.7324
7.6531
7.5213
7.4480
7.3517
```

计算稀疏矩阵的最小奇异值

```
A = delsq(numgrid('C',15));
s =svds(A,5,'smallest')
s =
0.5520
0.4787
0.3469
0.2676
0.1334
```

具体可以在Matlab命令窗口敲： help svds 看帮助。

虽然多项式逼近有很多优点，但是因为多项式具有振荡的特性，这就常常导致误差的界远远 大于平均误差。

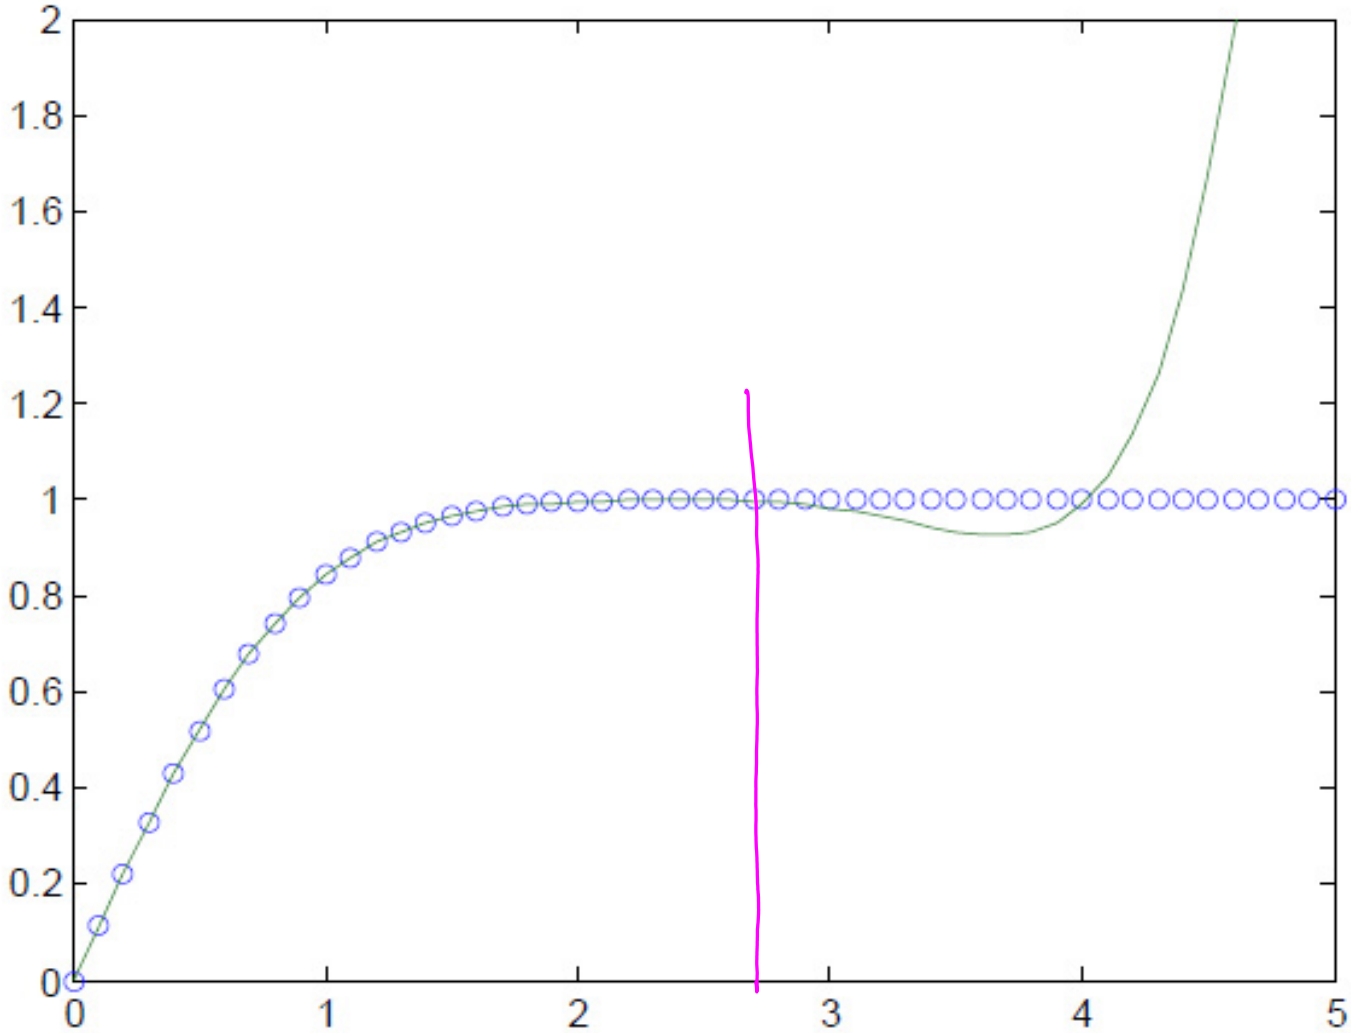

$\lim_{x\to 0} f(x) = +\infty$, $\lim_{x\to +\infty} f(x) = 0$，任何一个多项式或者多项式插值都不具有这样的性质。

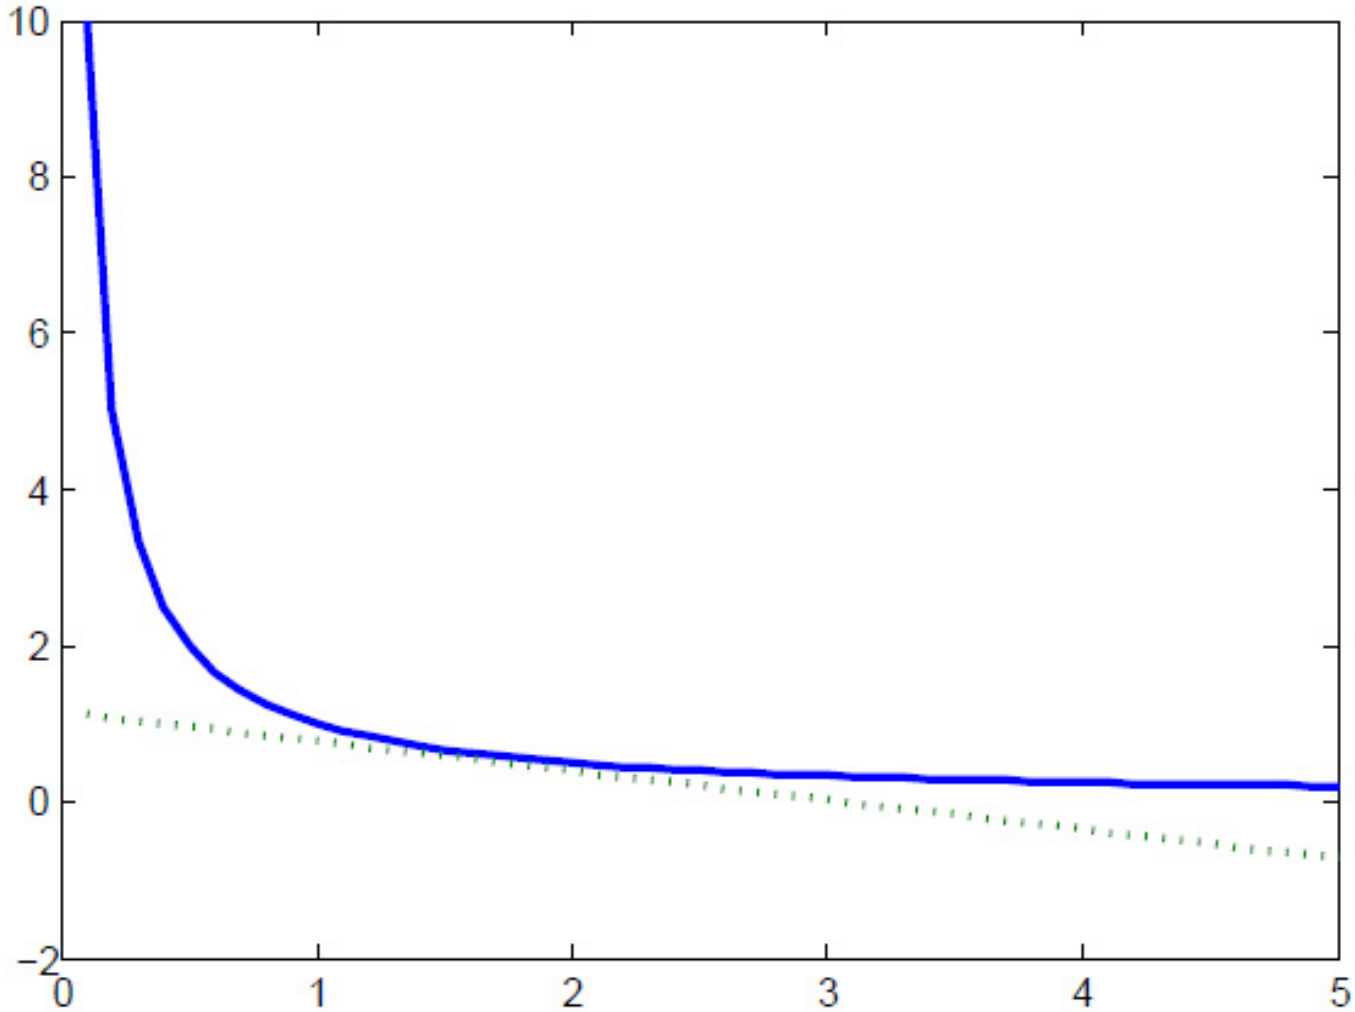

首先定义有理分式

$$R_{n,m}(x) = \frac{P_n(x)}{Q_m(x)},$$

其中

$b_0 = 1$.

$$P_n(x) = \sum_{k=0}^{n} a_k x^k, \quad Q_m(x) = \sum_{k=0}^{m} b_k x^k$$

分别是 n 次和 m 次多项式。$R_{n,m}$ 有 $m+n+1$ 个自由度。函数 $R_{n,m}$ 的全体记为 $R(n,m)$。

定义 (有理插值)

给定 $m+n+1$ 对点列 $(x_i, f(x_i)), i = 0, \cdots, m+n$，若 $R_{n,m}(x) \in R(n,m)$ 满足

$$R_{n,m}(x_i) = f(x_i), \quad i = 0, 1, \cdots, m+n.$$

则称 $R_{n,m}$ 为点列 $(x_i, f(x_i))$ 的有理插值。

设 $f(x)$ 在 $x=0$ 的Taylor展开为

$$f(x)=\sum_{k=0}^{n}\frac{1}{k!}f^{(k)}x^k+\frac{f^{(n+1)}(\xi)}{(n+1)!}x^{n+1},$$

而 f 的部分和

$$S_n=\sum_{k=0}^{n}\frac{1}{k!}f^k(0)x^k$$

是 $f(x)$ 的多项式逼近。且满足

$$f^{(k)}(0)=S_n^{(k)}(0), k=0,1,2,\cdots,n. \tag{0.6}$$

类似可以定义有理函数 $R_{m,n}(x)$ 使得它满足条件(0.6)，这就是Padé逼近。

定义 (Padé逼近)

设 $f(x) \in C^N[-a,a], N = n+m+1$，如果有理函数

$$R_{n,m} = \frac{a_0 + a_1 x + \cdots + a_n x^n}{1 + b_1 x + \cdots + b_m x^m} = \frac{P_n(x)}{Q_m(x)}, \tag{0.7}$$

其中 $P_n(x)$ 与 $Q_m(x)$ 互质，且满足

$$R_{n,m}^{(k)}(0) = f^{(k)}(0), \quad k = 0, 1, \cdots, n+m. \tag{0.8}$$

或者

$$f(x) - R_{n,m} = f(x) - \frac{P_n(x)}{Q_m(x)} = O(x^N).$$

称 $R_{n,m}$ 为 $f(x)$ 在 $x = 0$ 处的 (n,m) 阶*Padé*逼近。

Padé逼近是Taylor展开多项式逼近的推广，当 $Q_m(x) = 1$ 时，就是Taylor展开。

对已知函数

$$f(x) \in C^N[a,b], N = n+m+1,$$

如何构造Padé逼近 $R_{n,m}$?

$$R_{n,m}(x) = \frac{a_0 + a_1 x + \cdots + a_n x^n}{1 + b_1 x + \cdots + b_m x^m} = \frac{P_n(x)}{Q_m(x)}$$

有 $n+m+1$ 个未知数

$$a_0, a_1, \cdots, a_n, \quad b_1, b_2, \cdots, b_m,$$

有 $n+m+1$ 个方程:

$$R_{n,m}^{(k)}(0) = f^{(k)}(0), k = 0, 1, \cdots, n+m$$

这样就可以根据方程确定未知数。

根据定义有下面的等价的定理：

定理

设 $f(x)$ 充分光滑，$R_{n,m}(x)$ 是 $f(x)$ 的*Padé*逼近，则有

$$f(x)Q_m(x) - P_n(x) = \sum_{j=n+m+1}^{\infty} c_j x^j.$$

证明：$f(x)Q_m(x) - P_n(x) = \sum_{j=0}^{\infty} c_j x^j$，其中

$$c_j = \frac{d^j}{dx^j}\left(f(x)Q_m(x) - P_n(x)\right)\Big|_{x=0}.$$

$$= \frac{d^j}{dx^j}\left(f(x)Q_m(x)\right)\Big|_{x=0} - P_n^{(j)}(0)$$

$$= \sum_{i=0}^{j} \binom{j}{i} f^{(i)}(0) Q_m^{(j-i)}(0) - P_n^{(j)}(0)$$

若 $j \le n+m$，则：

$f^{(j)}(0) = R_{n,m}^{(j)}(0)$, 插值条件.

记 $c_j = \sum_{i=0}^{j} \binom{j}{i} R_{n,m}^{(i)}(0) Q_m^{(j-i)}(0) - P_n^{(j)}(0)$

$$= \frac{d^j}{dx^j}\left(R_{n,m}(x) Q_m(x)\right)\Big|_{x=0} - P_n^{(j)}(0)$$

$$= \frac{d^j}{dx^j}\left(\frac{P_n}{Q_m} Q_m\right)\Big|_{x=0} - P_n^{(j)}(0)$$

$$= P_n^{(j)}(0) - P_n^{(j)}(0) = 0. \qquad j \le n+m.$$

证毕

实际上根据上面的定理，如果

$$f(x) = \sum_{j=0}^{\infty} c_j x^j$$

则有

$$(c_0 + c_1 x + \cdots)(1 + b_1 x + \cdots + b_m x^m) - (a_0 + a_1 x + \cdots + a_n x^n) = c_{n+m+1} x^{n+m+1} + \cdots$$

比较 x^j 的系数就有

$$\begin{cases} x^0 & c_0 - a_0 = 0, \\ x^1 & b_1 c_0 + c_1 - a_1 = 0, \\ x^2 & b_2 c_0 + b_1 c_1 + c_2 - a_2 = 0 \\ \vdots & \\ x^n & b_m c_{n-m} + b_{m-1} c_{n-m+1} + \cdots + c_n - a_n = 0 \end{cases}$$

$$\begin{cases} x^{n+1} & b_m c_{n-m+1} + b_{m-1} c_{n-m+2} + \cdots + b_1 c_n + c_{n+1} = 0, \\ x^{n+2} & b_m c_{n-m+2} + b_{m-1} c_{n-m+3} + \cdots + b_1 c_{n+1} + c_{n+2} = 0 \\ \vdots & \\ x^{n+m} & b_m c_n + b_{m-1} c_{n+1} + \cdots + b_1 c_{n+m-1} + c_{n+m} = 0 \end{cases}$$

写成矩阵的形式就有

$$\begin{bmatrix} 1 & 0 & \cdots & 0 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 & \cdots & 0 & -c_0 \\ 0 & 0 & \cdots & 0 & 0 & \cdots & -c_0 & -c_1 \\ \vdots & \vdots & \ddots & 1 & -c_{n-m} & \cdots & -c_{n-2} & -c_{n-1} \\ 0 & 0 & \cdots & 0 & -c_{n-m+1} & \cdots & -c_{n-1} & -c_n \\ 0 & 0 & \cdots & 0 & -c_{n-m+2} & \cdots & -c_n & -c_{n+1} \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & -c_n & \cdots & -c_{n+m-2} & -c_{n+m-1} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \\ b_m \\ b_{m-1} \\ \vdots \\ b_1 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \\ c_{n+1} \\ c_{n+2} \\ \vdots \\ c_{n+m} \end{bmatrix}$$

从方程的结构可以看出，若记 m 阶方阵 $\mathbf{H}$ 为

$$\mathbf{H} = \begin{bmatrix} -c_{n-m+1} & \cdots & -c_{n-1} & -c_n \\ -c_{n-m+2} & \cdots & -c_n & -c_{n+1} \\ \vdots & \ddots & \vdots & \vdots \\ -c_n & \cdots & -c_{n+m-2} & -c_{n+m-1} \end{bmatrix}$$

若 $\mathbf{H}$ 非奇异，则由上面的方程组可以看出解存在唯一，且 $b_1, \cdots, b_m$ 可从子方程得到

$$\mathbf{H}\boldsymbol{b} = \tilde{\boldsymbol{c}}$$

其中

$$\begin{aligned} \boldsymbol{b} &= (b_m, b_{m-1}, b_1)^{\mathsf{T}}, \\ \tilde{\boldsymbol{c}} &= (c_{n+1}, c_{n+2}, \cdots, c_{n+m})^{\mathsf{T}} \end{aligned}$$

解出 $\boldsymbol{b}$ 之后代入前面的方程就可以求出 $a_0, a_1, \cdots, a_n$。

Padé表

实际应用的时候把各阶Padé逼近列成一张表，称为Padé表。

$n \backslash m$	0	1	2	3	4	$\cdots$
0	(0,0)	(0,1)	(0,2)	(0,3)	(0,4)	$\cdots$
1	(1,0)	(1,1)	(1,2)	(1,3)	(1,4)	$\cdots$
2	(2,0)	(2,1)	(2,2)	(2,3)	(2,4)	$\cdots$
3	(3,0)	(3,1)	(3,2)	(3,3)	(3,4)	$\cdots$
4	(4,0)	(4,1)	(4,2)	(4,3)	(4,4)	$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$

表中第一列就是 $f(x)$ 的Taylor展开的部分和。

求 $f(x)=e^x$ 的Padé逼近 $R_{3,2}$。

解： e^x 的Taylor展开

$$
\begin{aligned}
e^x &= 1+x+\frac{1}{2}x^2+\frac{1}{6}x^3+\frac{1}{24}x^4+\frac{1}{120}x^5+\cdots, \\
Q_2(x) &= 1+b_1x+b_2x^2, \\
P_3(x) &= a_0+a_1x+a_2x^2+a_3x^3.
\end{aligned}
$$

则关于 b_1, b_2 的方程为

$$
\begin{cases}
x^4 & \frac{1}{2}b_2+\frac{1}{6}b_1+\frac{1}{24}=0, \\
x^5 & \frac{1}{6}b_2+\frac{1}{24}b_1+\frac{1}{120}=0.
\end{cases}
$$

解得

$$
b_1=-\frac{2}{5}, b_2=\frac{1}{20}.
$$

则关于 $a_0, \cdots, a_3$ 得方程为

$$\begin{cases} x^3 & \frac{1}{6} + \frac{1}{2}b_1 + b_2 = a_3, \\ x^2 & \frac{1}{2} + b_1 + b_2 = a_2, \\ x & 1 + b_1 = a_1, \\ x^0 & 1 = a_0, \end{cases}$$

得

$$a_0 = 1, a_1 = \frac{3}{5}, a_2 = \frac{3}{20}, a_3 = \frac{1}{60}.$$

$$\Longrightarrow \qquad R_{3,2}(x) = \frac{P_3(x)}{Q_2(x)} = \frac{60 + 36x + 9x^2 + x^3}{60 - 24x + 3x^2}.$$

考察 $x = 0.5$，则

$$\begin{aligned} R_{3,2}(0.5) &= 1.648718, \\ e^{0.5} &= 1.648721, \\ S_5(0.5) &= 1.648698. \end{aligned}$$

Padé逼近比Taylor级数展开计算结果要好。

$n \backslash m$	0	1	2	3
0	1	$\frac{1}{1-x}$	$\frac{2}{2-2x+x^2}$	$\frac{6}{6-6x+3x^2-x^3}$
1	$1+x$	$\frac{2+x}{2-x}$	$\frac{6+2x}{6-4x+x^2}$	$\frac{24+6x}{24-18x+6x^2-x^3}$
2	$\frac{2+2x^2}{2}$	$\frac{6+4x+x^2}{6-2x}$	$\frac{12+6x+x^2}{12-6x+x^2}$	$\frac{60+24x+3x^2}{60-36x+9x^2-x^3}$
3	$\frac{6+6x+3x^2+x^3}{6}$	$\frac{24+18x+16x^2+x^3}{24-6x}$	$\frac{60+36x+9x^2+x^3}{60-24x+3x^2}$	$\frac{120+60x+12x^2+x^3}{120-60x+12x^2-x^3}$

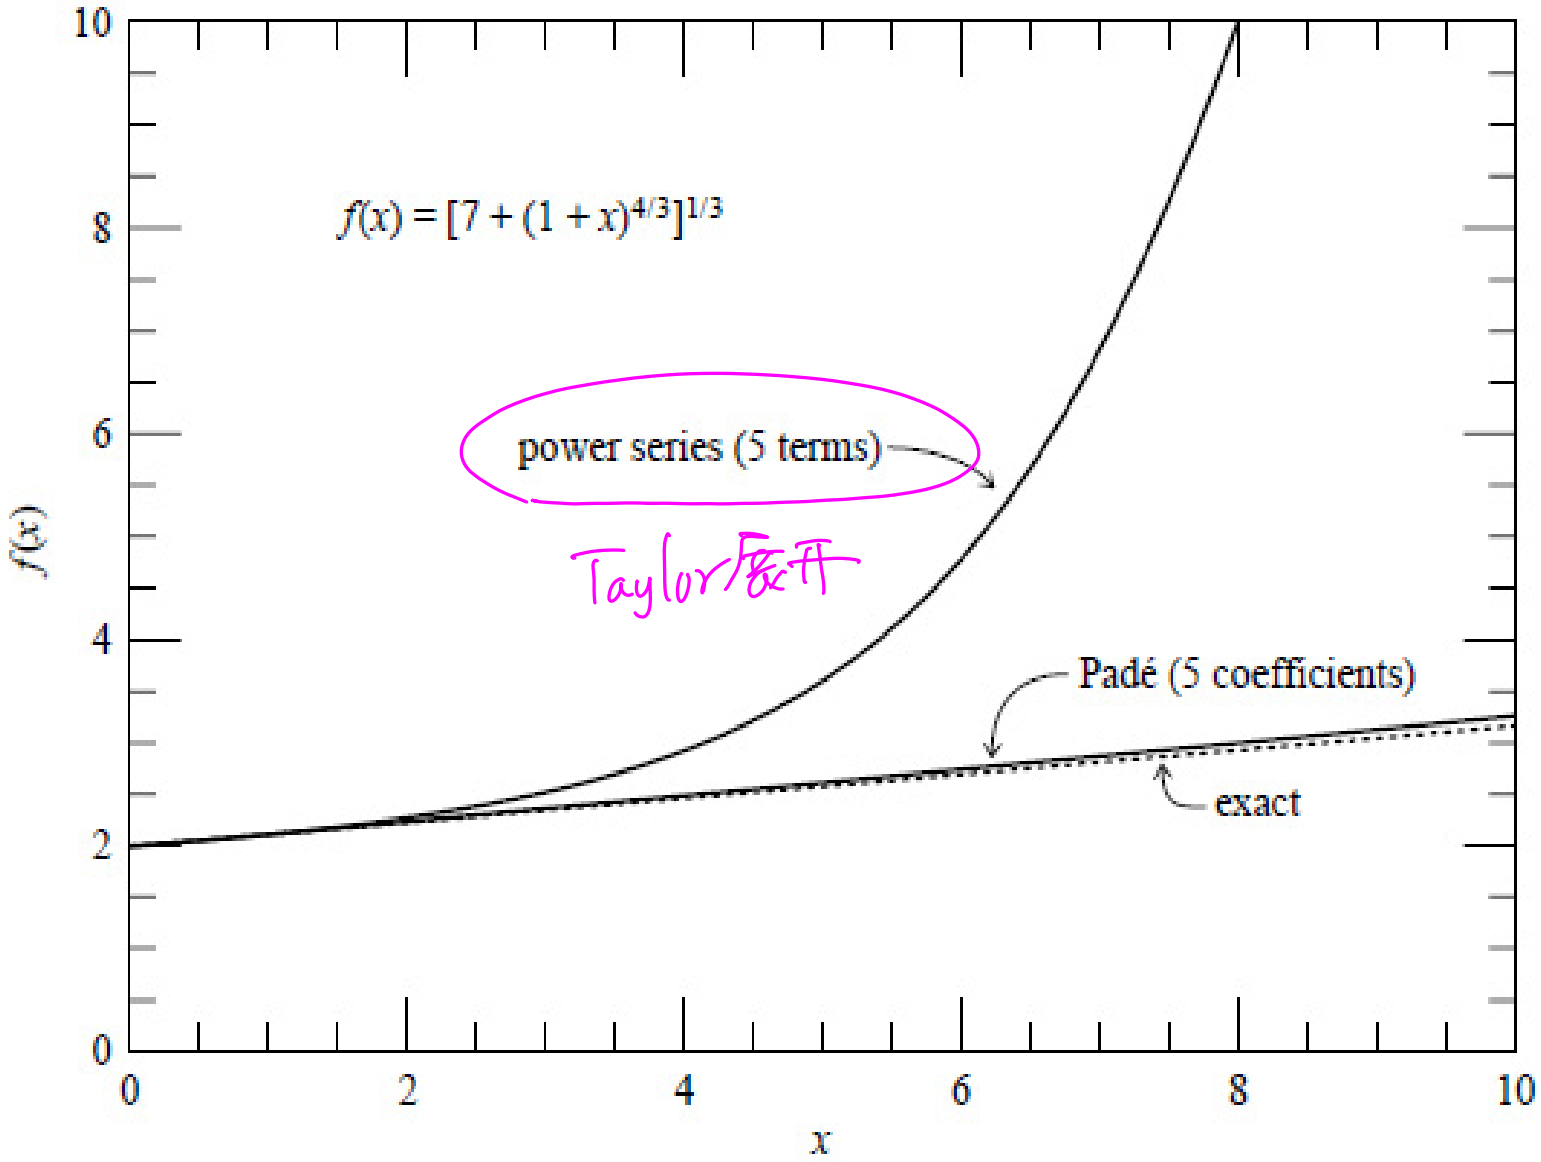
$f(x) = [7 + (1 + x)^{4/3}]^{1/3}$
power series (5 terms)
Taylor展开
Padé (5 coefficients)
exact
$f(x)$
x
0
2
4
6
8
10