第六章 代数特征值问题

殷东生
yindongsheng@tsinghua.edu.cn

清华大学数学数学基础教学中心

2025年秋季学期

代数特征值问题

定义

设 $A \in \mathbb{C}^{n\times n}$，若存在非零向量 $\boldsymbol{x} \in \mathbb{C}^n$ 和 $\lambda \in \mathbb{C}$，满足 $A\boldsymbol{x} = \lambda\boldsymbol{x}$，称 λ 为特征值，$\boldsymbol{x}$ 为相应的特征向量。

特征多项式

- 特征多项式

$$f(\lambda) = \det(\lambda I - A) = \lambda^n + c_1\lambda^{n-1} + \cdots + c_{n-1}\lambda + c_n$$

则 λ 是 A 的特征值当且仅当 λ 是特征多项式 $f(\lambda) = 0$ 的根。

- n 阶复系数多项式方程在复数域上有 n 个根。

- 高次代数方程的求根是病态问题，一般不能用直接法求解多项式方程的根，因此特征值问题的数值方法只能是迭代法。
- 但是反过来，为了求多项式

$$q(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \cdots + a_1\lambda + a_0$$

的根，可以把 $q(\lambda)$ 看成它的友矩阵

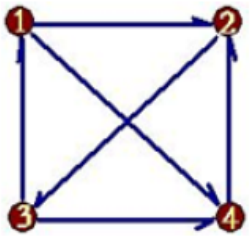
$$\begin{bmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ & 1 & \cdots & 0 & -a_2 \\ & & \ddots & \vdots & \vdots \\ & & & 1 & -a_{n-1} \end{bmatrix}$$

的特征多项式，这是一个上 Hessenberg 阵，可以用 QR 迭代求解其特征值。

Google的网页排序

- 如何度量网页本身的重要性呢?
  - 互联网上的每一篇html文档除了包含文本、图片、视频等信息外，还包含了大量的链接关系，利用这些链接关系，能够发现某些重要的网页





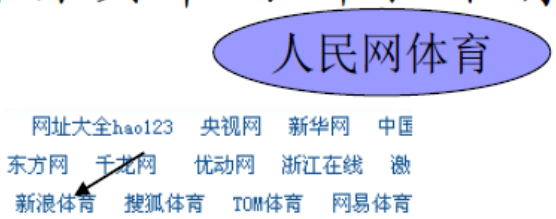
网页是节点，网页间的链接关系是边

  - 直观地看，某网页A链向网页B，则可以认为网页A觉得网页B有链接价值，是比较重要的网页。
  - 某网页被指向的次数越多，则它的重要性越高；越是重要的网页，所链接的网页的重要性也越高。

Google的网页排序

- 如何度量网页本身的重要性呢?
  - 比如，新华网体育在其首页中对新浪体育做了链接，人民网体育同样在其首页中对新浪体育做了链接

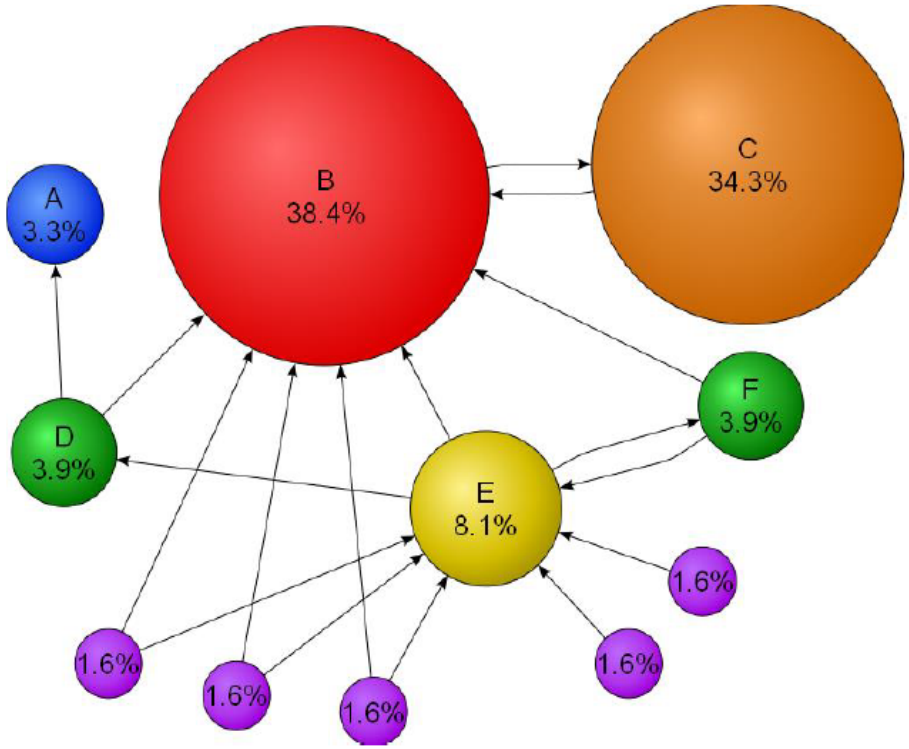




  - 可见，新浪体育被链接的次数较多；同时，人民网体育和新华网体育也都是比较“重要”的网页，因此新浪体育也应该是比较“重要”的网页。

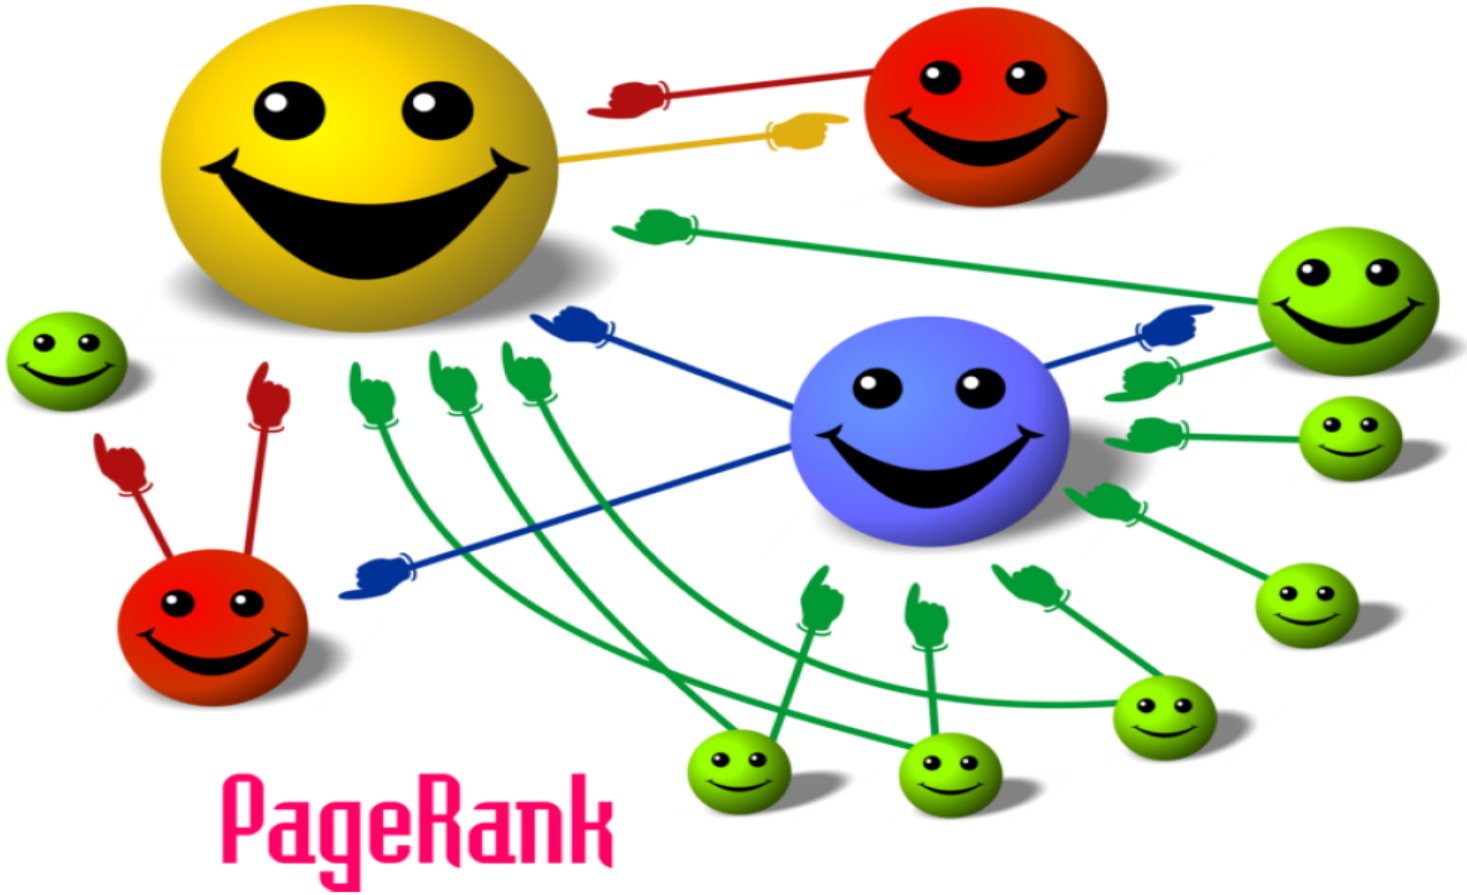
Google的网页排序

- 一个更加形象的图



链向网页E的链接远远大于链向网页C的链接，但是网页C的重要性却大于网页E。这是因为因为网页C被网页B所链接，而网页B有很高的重要性。

Pagerank算法原理：



PageRank的简单计算

- 一个由只有4个页面组成的集合：A，B，C和D，若所有页面都链向A，那么A的PR（PageRank）值将是B，C及D的和

$$PR(A) = PR(B) + PR(C) + PR(D).$$

- 若B也有链接到C，且D也有链接到包括A的3个页面。一个页面不能投票2次，所以B给每个页面半票。同样，D投出的票只有三分之一算到了A上。

$$PR(A) = \frac{PR(B)}{2} + \frac{PR(C)}{1} + \frac{PR(D)}{3}.$$

- 换言之，根据链出总数平分一个页面的PR值。

$$PR(A) = \frac{PR(B)}{L(B)} + \frac{PR(C)}{L(C)} + \frac{PR(D)}{L(D)}.$$

一般情形，网页u的PR值可表示为

$$PR(u) = \sum_{v \in B_u} \frac{PR(v)}{L(v)},$$

$\vec{u} = B\vec{u}$

亦即u的PR值依赖于所有链接到u的网页集合B_u。
实际的网络链接环境没有这么理想化，PageRank有两个问题

- Rank leak，一个独立的网页如果没有外出的链接就会产生等级泄露；
- Rank sink，整个网页中紧密链接成环的网页没有外出的链接；

解决方案：随机浏览模型。假定用户从一个随机的网页开始浏览，不断点击当前网页的链接开始下一次浏览，直到其厌倦，开始了随机浏览。随机上网者用以上 方式访问一个新网页的概率就是该网页的PageRank值。这种方式更接近与用户浏览网页的行为，且可以保证PageRank的具有唯一值。

简言之，其计算原理如下：

- 互联网是一个有向图；
- 每一个网页是图的一个顶点；
- 网页间的每一个链接是图的一个有向边；



- 用邻接矩阵来表示图，定义邻接矩阵为G，若网页j到i有超链接，则$g_{ij}=1$，反之$g_{ij}=0$；
- N个网页的邻接矩阵为$N\times N$的$0,1$ 方阵；
- 记矩阵G的行、列和分别是

$$c_j = \sum_i g_{ij} \quad \text{链出链接数;}$$

$$r_i = \sum_j g_{ij} \quad \text{链入链接数}$$

- 假定在上网浏览网页并选择下一个网页的过程与过去浏览的网页无关，而仅依赖于当前的网页。则这一选择过程可视为一个有限状态、离散时间的随机过程，其状态转移概率用Markov链描述。
- 定义转移概率矩阵$A = (a_{ij})$:

$$a_{ij} = \frac{g_{ij}}{c_j}, \quad i,j = 1, \cdots, n$$

- 正则Markov链存在平稳分布α满足

$$A\alpha = \alpha, \quad \sum_{i=1}^{n} x_i = 1$$

- α表示在极限状态（转移次数趋于无穷）下各网页被访问的概率分布；α定义为网页的PageRank向量，x_i表示第i个网页的PR值。

力学中的特征值问题

美国数学家斯特让（G..Strang）在其经典教材《线性代数及其应用》中这样介绍了特征值作为频率的物理意义，他说：

大概最简单的例子（我从不相信其真实性，虽然据说1831年有一桥梁毁于此因）是一队士兵通过桥梁的例子。传统上，他们要停止齐步前进而要散步通过。这个理由是因为他们可能以等于桥的特征值之一的频率齐步行进，从而将发生共振。就像孩子的秋千那样，你一旦注意到一个秋千的频率，和此频率相配，你就使频率荡得更高。一个工程师总是试图使他的桥梁或他的火箭的自然频率远离风的频率或液体燃料的频率；而在另一种极端情况，一个证券经纪人则尽毕生精力于努力到达市场的自然频率线。特征值是几乎任何一个动力系统的最重要的特征。

- 应力分析：主应力是应力张量矩阵的特征值，主方向是特征向量的方向。
- 对多自由度机械结构作振动分析时，其特征值给出振动的自然频率，特征向量给出振动行为。

塔科马海峡吊桥（Tacoma Narrows Bridge)

- 塔科马海峡吊桥是位于美国华盛顿州塔科马的悬索桥。
- 第一条桥于1938年开始建造，为了减低造价，把桥面设计的厚度从25呎减至8呎（2.4米），该桥于1940年7月1日通车，但在启用后数个星期，桥面便开始出现上下摆动。有鉴及此，有关人员在支柱上安装摄录机，以便观测摆动。同时也吸引了不少驾车人士慕名而来，感受其振荡威力的刺激，一些大风的日子，其桥面摆动幅度甚至可达五英尺之多。
- 其后桥面的波动幅度不断增加，工程人员尝试加建缆索及液压缓冲装置去试图减低波动，但不成功。
- 在持续数个月的摆动之下，桥梁最终于同年11月7日倒塌，其过程获得全程记录。当天早上，桥面的上下摆动突然停止，取而代之的是出现左右的扭力摆动，当时有两人被困在桥上，后来也成功逃离现场，然后桥面在数分钟内陆续崩塌。

主成分分析(PCA, Principal Component Analysis)

主成分分析

- 主成分分析经常用于减少数据集的维数，同时保持数据集中的对方差贡献最大的特征。其方法主要是通过对协方差矩阵进行特征分解，以得出数据的主成分（即特征向量）与它们的权值（即特征值或奇异值）。
- PCA的数学定义是：一个正交变换，把数据变换到一个新的坐标系中，使得这一数据的任何投影的第一大方差在第一个坐标（称为第一主成分）上，第二大方差在第二个坐标（第二主成分）上，依次类推。
- 一般来说，方差大的方向是信号的方向，方差小的方向是噪声的方向，在数据挖掘中或者数字信号处理中，往往要提高信号与噪声的比例，也就是信噪比。

协方差(Convariance)

协方差(Covariance)用于衡量两个变量的总体误差。设两个随机变量 X 和 Y 的期望值分别为 $\mathbb{E}_X[x]$和 $\mathbb{E}_Y[y]$，则其协方差定义为：

$$\mathrm{Cov}_{X,Y}[x,y] = \mathbb{E}_{X,Y}[(x - \mathbb{E}_X(x))(y - \mathbb{E}_Y(y))]$$

方差是协方差的一种特殊情况，即当两个变量是相同时：

$$\mathrm{Var}_X(x) = \mathrm{Cov}_{X,X}[x,x] = \mathbb{E}[(x - \mathbb{E}[x])^2]$$

协方差可以等价写为

$$\mathrm{Cov}[x,y] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y].$$

协方差从随机标量推广到随机向量，则得到协方差定义：

$$\mathrm{Cov}[\boldsymbol{x},\boldsymbol{y}] = \mathbb{E}[\boldsymbol{x}\boldsymbol{y}^\intercal] - \mathbb{E}[\boldsymbol{x}]\mathbb{E}[\boldsymbol{y}^\intercal] = \mathrm{Cov}[\boldsymbol{y},\boldsymbol{x}]^\intercal \in \mathbb{R}^{n\times m}, \boldsymbol{x} \in \mathbb{R}^n, \boldsymbol{y} \in \mathbb{R}^m.$$

协方差矩阵

- 若 $\boldsymbol{x} \in \mathbb{R}^n$，其均值向量 $\boldsymbol{\mu} \in \mathbb{R}^n$，则

$$
\begin{aligned}
\mathrm{Var}_X[\boldsymbol{x}] &= \mathrm{Cov}_X[\boldsymbol{x}, \boldsymbol{x}] \\
&= \mathbb{E}_X[(\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^{\mathsf{T}}] \\
&= \mathbb{E}_X[\boldsymbol{x}\boldsymbol{x}^{\mathsf{T}}] - \mathbb{E}_X[\boldsymbol{x}]\mathbb{E}_X[\boldsymbol{x}]^{\mathsf{T}} \\
&= \begin{bmatrix}
\mathrm{Cov}[x_1, x_1] & \mathrm{Cov}[x_1, x_2] & \cdots & \mathrm{Cov}[x_1, x_n] \\
\mathrm{Cov}[x_2, x_1] & \mathrm{Cov}[x_2, x_2] & \cdots & \mathrm{Cov}[x_2, x_n] \\
\vdots & \vdots & \ddots & \vdots \\
\mathrm{Cov}[x_n, x_1] & \mathrm{Cov}[x_n, x_2] & \cdots & \mathrm{Cov}[x_n, x_n]
\end{bmatrix}
\end{aligned}
$$

  称为协方差矩阵。

- 两个随机变量 X, Y 之间的相关性定义为

$$
\mathrm{corr}[x, y] = \frac{\mathrm{Cov}[x, y]}{\sqrt{\mathrm{Var}[x]\mathrm{Var}[y]}}.
$$

样本协方差矩阵

假设有数据集 $\mathcal{X} = \{\boldsymbol{x}_1, \cdots, \boldsymbol{x}_N\}, \boldsymbol{x}_i \in \mathbb{R}^n$，并假定其均值为 $\mathbf{0}$，则其协方差矩阵为

$$S := \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{x}_i \boldsymbol{x}_i^{\mathsf{T}}.$$

定义投影向量 $\boldsymbol{u}_1$，且 $\|\boldsymbol{u}_1\|_2 = 1$，则每个 $\boldsymbol{x}_i$ 的投影为 $\boldsymbol{u}_1^{\mathsf{T}} \boldsymbol{x}_i$，投影后的方差

$$\begin{aligned} \mathrm{Var}_1 &= \frac{1}{N} \sum_{i=1}^{N} (\boldsymbol{u}_1^{\mathsf{T}} \boldsymbol{x}_i)^2 = \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{u}_1^{\mathsf{T}} \boldsymbol{x}_i \boldsymbol{x}_i^{\mathsf{T}} \boldsymbol{u}_1 \\ &= \boldsymbol{u}_1^{\mathsf{T}} \left(\frac{1}{N} \sum_{i=1}^{N} \boldsymbol{x}_i \boldsymbol{x}_i^{\mathsf{T}} \right) \boldsymbol{u}_1 = \boldsymbol{u}_1^{\mathsf{T}} S \boldsymbol{u}_1 \end{aligned}$$

这里 S 是样本的协方差矩阵。

主成分分析的数学形式

因此PCA等价于如下约束优化问题

$$\max_{\boldsymbol{u}_1} \quad \boldsymbol{u}_1^{\mathsf{T}} S \boldsymbol{u}_1$$
$$s.t \quad \|\boldsymbol{u}_1\|_2 = 1.$$

利用拉格朗日乘子法，引入标量 λ_1 变为如下无约束优化问题：

$$\max_{\boldsymbol{u}_1, \lambda_1} \left\{ \boldsymbol{u}_1^{\mathsf{T}} S \boldsymbol{u}_1 + \lambda_1 (1 - \boldsymbol{u}_1^{\mathsf{T}} \boldsymbol{u}_1) \right\}$$

其极值条件为梯度为零，即

$$S\boldsymbol{u}_1 = \lambda_1 \boldsymbol{u}_1$$

这就转换成一个矩阵特征值分解问题。将特征值从大到小排列，保留前 M 个特征向量，即实现了从原来 n 维空间到 M 维新空间的降维。

定理 (Gershgorin圆盘定理)

设 $A = (a_{ij}) \in \mathbb{C}^{n\times n}$，则特征值

$$\lambda \in \bigcup_{i=1}^{n} D_i,$$

其中 D_i 为复平面上以 a_{ii} 为中心 $r_i = \sum_{j=1, j\neq i}^{n} |a_{ij}|$ 为半径的圆盘，即

$$D_i \overset{def}{=} \left\{ z \in \mathbb{C} \middle| |z - a_{ii}| \leq r_i \right\},\ i = 1, \cdots, n$$

注记

圆盘定理可以从矩阵的元素估计特征值所在的范围。矩阵的 n 个特征值均落在 n 个圆盘上，但是不一定每个圆盘都有一个特征值。

证明：设 λ 是 A 的特征值，则：

$$\det(\lambda I - A) = 0, \quad \lambda I - A \text{ 奇异}.$$

若 $\lambda \notin \bigcup_{i=1}^{n} D_i$，则：

$$|\lambda - a_{ii}| > \sum_{j=1, j\neq i}^{n} |a_{ij}|, \quad 1 \le i \le n.$$

这说明 $\lambda I - A$ 严格对角占优，非奇异，

这与 λ 是 A 的特征值矛盾.

则 $\exists\, i$，s.t.

$$|\lambda - a_{ii}| \le \sum_{j=1, j\neq i}^{n} |a_{ij}|.$$

∎

定理 (第2圆盘定理)

设上述定理的 n 个圆盘中有 m 个圆盘构成一个连通域 S，且 S 与其余 $n-m$ 个圆盘严格分离，则 S 中恰有 m 个特征值，其中重特征值按其重数重复计算。

注记

设 $A=(a_{ij})$，$B=\mathrm{diag}(\alpha_1,\cdots,\alpha_n)$，其中 $\alpha_i\neq 0$，则 A 与

$$B^{-1}AB=\left(\frac{a_{ij}\alpha_j}{\alpha_i}\right)$$

相似变换保特征值.

有相同的特征值。适当的选取 B，可使某个圆盘半径相对地减小，更易估计。当然也可能使其他的某些圆盘半径变大。

例 (圆盘估计的变化)

$$A = \begin{bmatrix} 0.9 & 0.01 & 0.12 \\ 0.01 & 0.8 & 0.13 \\ 0.01 & 0.02 & 0.4 \end{bmatrix}$$

解: A的三个圆盘为

$$D_1 = \{z \big| |z - 0.9| \le 0.13\}, \quad D_2 = \{z \big| z - 0.8| \le 0.14\}$$
$$D_3 = \{z \big| |z - 0.4| \le 0.03\}.$$

D_1, D_2 和 D_3 严格分离，则 D_3 必有一实特征值。为估计另外两个特征值，缩小 D_1, D_2 的半径。 取 $B = \mathrm{diag}(1, 1, 0.1)$，则

$$B^{-1}AB = \begin{bmatrix} 0.9 & 0.01 & 0.012 \\ 0.01 & 0.8 & 0.013 \\ 0.1 & 0.2 & 0.4 \end{bmatrix}$$

则新的圆盘 $\overline{D}_1 = \left\{z \middle| |z - 0.9| \le 0.022\right\}, \overline{D}_2 = \left\{z \middle| |z - 0.8| \le 0.023\right\}, \overline{D}_3 = \left\{z \middle| |z - 0.4| \le 0.3\right\}$。

幂法

- 设 A 是可对角化的，其特征值满足

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|,$$

对应的特征向量 $\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_n$ 是 $\mathbb{R}^n$ 的一组基。

- 对任意的初始向量

$$\boldsymbol{\nu}^{(0)} = \alpha_1 \boldsymbol{x}_1 + \alpha_2 \boldsymbol{x}_2 + \cdots + \alpha_n \boldsymbol{x}_n, \ \alpha_1 \neq 0.$$

有

$$A^k \boldsymbol{\nu}^{(0)} = \lambda_1^k \left[\alpha_1 \boldsymbol{x}_1 + \sum_{i=2}^{n} \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \boldsymbol{x}_i \right]$$

因为 $|\lambda_1| > |\lambda_i|$, $i = 2, \cdots n$.

则 $\lim_{k\to\infty} \left(\frac{\lambda_i}{\lambda_1}\right)^k \to 0$ $\to$ $\|\alpha_1 \lambda_1^k x_1\| = 1$.

$A^k y^{(0)} \to \alpha_1 \lambda_1^k x_1$, $k \to \infty$.

若 $|\lambda_1| > 1$, 则 $\lambda_1^k \to \infty$.

若 $|\lambda_1| < 1$, 则 $\lambda_1^k \to 0$.

? 归一化

- 对任意向量 $\boldsymbol{z} = (z_1, \cdots, z_n)^{\mathsf{T}}$，定义

$$\max(\boldsymbol{z}) = z_i,\ |z_i| = \|\boldsymbol{z}\|_\infty,\ |z_j| < \|\boldsymbol{z}\|_\infty,\ \forall j < i.$$

唯一性

- 对任意 $\alpha \in \mathbb{R}$，$\boldsymbol{z} \in \mathbb{R}^n$，有

$$\max(\alpha \boldsymbol{z}) = \alpha \max(\boldsymbol{z}).$$

幂迭代算法

幂迭代法的算法可写为

$$\begin{cases} \boldsymbol{\nu}^{(0)} = \dfrac{\boldsymbol{\mu}}{\max \boldsymbol{\mu}} \\ \boldsymbol{z}^{(k)} = A\boldsymbol{\nu}^{(k-1)} \\ m_k = \max(\boldsymbol{z}^{(k)}) \\ \boldsymbol{\nu}^{(k)} = \dfrac{\boldsymbol{z}^{(k)}}{m_k}, \end{cases} \quad k = 1, 2, \cdots$$

初值归化

迭代

归一化

因为

$$\boldsymbol{\nu}^{(k)} = \frac{A\boldsymbol{\nu}^{(k-1)}}{m_k} = \frac{A^k\boldsymbol{\nu}^{(0)}}{\prod_{i=1}^{k} m_i}$$

$\nu^{(k-1)} = \dfrac{A\nu^{(k-2)}}{m_{k-1}}$, $\nu^{(k-2)} = \dfrac{A\nu^{(k-3)}}{m_{k-2}}$.

所以 $\boldsymbol{\nu}^{(k)}$ 和 $A^k\boldsymbol{\nu}^{(0)}$ 平行。

幂迭代法的收敛性

而 $\max(\boldsymbol{\nu}^{(k)}) = 1$, 则

$$\boldsymbol{\nu}^{(k)} = \frac{A^k \boldsymbol{\nu}^{(0)}}{\max(A^k \boldsymbol{\nu}^{(0)})}$$

$$\Rightarrow \max(A^k \boldsymbol{\nu}^{(0)}) = \prod_{i=1}^{k} m_i$$

$$\boldsymbol{\nu}^{(k)} \to \frac{\boldsymbol{x}_1}{\max \boldsymbol{x}_1}$$

$$\boldsymbol{z}^{(k)} = A\frac{A^{k-1}\boldsymbol{\nu}^{(0)}}{\max(A^{k-1}\boldsymbol{\nu}^{(0)})}$$

$$m_k \to \max\left(A\frac{\boldsymbol{x}_1}{\max \boldsymbol{x}_1}\right) = \max\left(\frac{\lambda_1 \boldsymbol{x}_1}{\max \boldsymbol{x}_1}\right) = \lambda_1.$$

收敛速度

$$
\begin{aligned}
m_k &= \frac{\max\left(A^k \boldsymbol{\nu}^{(0)}\right)}{\max\left(A^{k-1} \boldsymbol{\nu}^{(0)}\right)} \\
&= \lambda_1 \frac{\max\left(\alpha_1 \boldsymbol{x}_1 + \sum_{i=2}^{n} \alpha_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \boldsymbol{x}_i\right)}{\max\left(\alpha_1 \boldsymbol{x}_1 + \sum_{i=2}^{n} \alpha_i \left(\frac{\lambda_i}{\lambda_1}\right)^{k-1} \boldsymbol{x}_i\right)} \\
&= \lambda_1 \left[1 + O\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right)\right] \to \lambda_1
\end{aligned}
$$

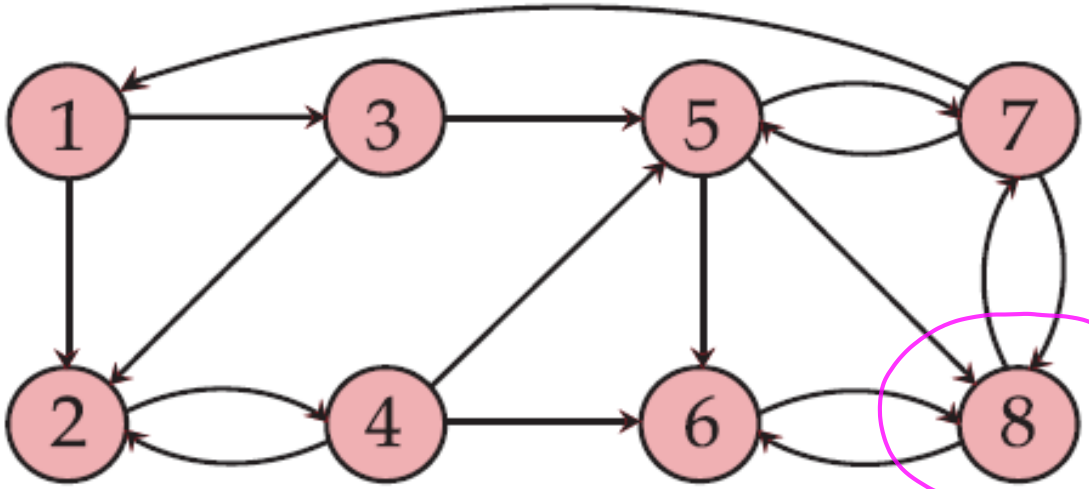
$$
\Longrightarrow \quad \frac{|m_{k+1} - \lambda_1|}{|m_k - \lambda_1|} \approx \left|\frac{\lambda_2}{\lambda_1}\right|, \quad \text{线性收敛!}
$$

注记

幂迭代法一般用来求解主特征值。如果矩阵没有主特征值，则方法无法使用。如果迭代初值 $\boldsymbol{\nu}^{(0)}$ 不含主特征值对应的特征向量 $\boldsymbol{x}_1$，即 $\alpha_1 = 0$，则算法亦不适用。更多的时候，幂迭代法是在已知主特征值的情况下用来求解主特征向量。

$$A^k v^{(0)} = \alpha_1 \lambda_1^k x_1 + \alpha_2 \lambda_2^k x_2$$

PageRank的转移矩阵



$$H=\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 1/3 & 0 \\ 1/2 & 0 & 1/2 & 1/3 & 0 & 0 & 0 & 0 \\ 1/2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/3 & 0 & 0 & 1/3 & 0 \\ 0 & 0 & 0 & 1/3 & 1/3 & 0 & 0 & 1/2 \\ 0 & 0 & 0 & 0 & 1/3 & 0 & 0 & 1/2 \\ 0 & 0 & 0 & 0 & 1/3 & 1 & 1/3 & 0 \end{bmatrix},$$

→随机矩阵

PangRank的计算

主特征值1对应的主特征向量经过迭代可得

I^0	I^1	I^2	I^3	I^4	$\cdots$	I^{60}	I^{61}
1	0	0	0	0.0287	$\cdots$	0.06	0.06
0	0.5	0.25	0.1667	0.0833	$\cdots$	0.0675	0.0675
0	0.5	0	0	0	$\cdots$	0.03	0.03
0	0	0.5	0.25	0.1667	$\cdots$	0.0675	0.0675
0	0	0.25	0.1667	0.1111	$\cdots$	0.0975	0.0975
0	0	0	0.25	0.1806	$\cdots$	0.2025	0.2025
0	0	0	0.0833	0.0972	$\cdots$	0.18	0.18
0	0	0	0.0833	0.3333	$\cdots$	0.295	0.295

这就是对应网页的PageRank值。

逆幂迭代法

如果矩阵 $A \in \mathbb{R}^{n\times n}$ 特征值满足

$$|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_{n-1}| > |\lambda_n| > 0$$

则 A^{-1} 的特征值满足

$$|\lambda_n^{-1}| > |\lambda_{n-1}^{-1}| \geq \cdots \geq |\lambda_1^{-1}|$$

则有逆幂迭代法

$$\begin{cases} \boldsymbol{\nu}^{(0)} &= \boldsymbol{\mu}/\max \boldsymbol{\mu} \\ A\boldsymbol{z}^{(k)} &= \boldsymbol{\nu}^{(k-1)} \\ m_k &= \max(\boldsymbol{z}^{(k)}) \\ \boldsymbol{\nu}^{(k)} &= \boldsymbol{z}^{(k)}/m_k, \end{cases}$$

$k = 1, 2, \cdots$.

逆幂法的收敛性

对逆幂迭代法

$$\begin{aligned} \boldsymbol{\nu}^{(k)} &\to \frac{\boldsymbol{x}_n}{\max \boldsymbol{x}_n}, \\ m_k &= \lambda_n^{-1}\left[1+O\left(\left|\frac{\lambda_n}{\lambda_{n-1}}\right|^k\right)\right] \to \lambda_n^{-1} \end{aligned}$$

Q: 逆幂迭代法可以求最小的特征值，如何求中间的特征值？

A: 若中间的特征值与其他的特征值分离，则可通过原点位移技巧来求！

原点位移技巧

设通过分析知 A 有一单特征值 λ_i 与一个确定的数 q 最接近，即

$$0 < |\lambda_i - q| \ll |\lambda_j - q|,\ j \neq i.$$

$\lambda_i - q$ 是 $A - qI$ 的绝对最小特征值.

而 $(A - qI)^{-1}$ 的特征值为

$$\frac{1}{\lambda_1 - q}, \frac{1}{\lambda_2 - q}, \cdots, \frac{1}{\lambda_i - q}, \cdots, \frac{1}{\lambda_n - q},$$

此时 $\dfrac{1}{(\lambda_i - q)}$ 是 $(A - qI)^{-1}$ 的主特征值。则对 $\boldsymbol{\nu}^{(0)} = \sum_{j=1}^{n} \alpha_j \boldsymbol{x}_j$ 进行逆幂迭代可得

$$(A - qI)^{-k} \boldsymbol{\nu}^{(0)} = \sum_{j=1}^{n} \frac{\alpha_j}{(\lambda_j - q)^k} \boldsymbol{x}_j$$

则对 $A - qI$ 进行逆幂迭代

$$\begin{cases} \boldsymbol{\nu}^{(0)} = \boldsymbol{\mu}/\max \boldsymbol{\mu} \\ (A-qI)\boldsymbol{z}^{(k)} = \boldsymbol{\nu}^{(k-1)} \\ m_k = \max(\boldsymbol{z}^{(k)}) \\ \boldsymbol{\nu}^{(k)} = \dfrac{\boldsymbol{z}^{(k)}}{m_k}, \end{cases} \quad k = 1, 2, \cdots$$

$z^{(k)} = (A-qI)^{-1} v^{(k-1)}$

QR迭代 $A = A_1$.

$$\begin{cases} A_k = Q_k R_k \\ A_{k+1} = R_k Q_k \end{cases}$$

$Q_k^T A_k Q_k = Q_k^T Q_k R_k Q_k = R_k Q_k = A_{k+1}$

$Q^T Q = I$, $Q^T = Q^{-1}$ I 正交相似

可得

$$\begin{aligned} m_k &\to (\lambda_i - q)^{-1}, \\ \boldsymbol{\nu}^{(k)} &\to \frac{\boldsymbol{x}_i}{\max(\boldsymbol{x}_i)}. \end{aligned}$$

幂法求特征值的思路：

- 确定 q：圆盘定理，或若 $\boldsymbol{x}$ 为近似特征向量，取 $q = \frac{(A\boldsymbol{x},\boldsymbol{x})}{(\boldsymbol{x},\boldsymbol{x})}$。
- 原点位移的逆幂迭代法。

定义 (Householder 变换)

设 $\boldsymbol{w} \in \mathbb{R}^n$，且 $\|\boldsymbol{w}\|_2 = 1$，则称

$$P = I - 2\boldsymbol{w}\boldsymbol{w}^{\mathsf{T}}$$

$P^T = P$

为Householder矩阵，其表示变换称为Householder变换。

Householder矩阵有如下性质

1. $P^{\mathsf{T}} = P$，Householder矩阵为对称阵；
2. $P^{\mathsf{T}}P = I$，Householder矩阵为正交阵；
3. 几何解释：镜面反射矩阵，初等反射矩阵；
4. $\|P\boldsymbol{x}\|_2 = \|\boldsymbol{x}\|_2$。
5. 对任意 $\boldsymbol{x}$ 和 $\boldsymbol{v}$，满足 $\|\boldsymbol{x}\|_2 = \|\boldsymbol{v}\|_2$，令

$$\boldsymbol{w} = \frac{\boldsymbol{x} - \boldsymbol{v}}{\|\boldsymbol{x} - \boldsymbol{v}\|_2} \Longrightarrow P\boldsymbol{x} = \boldsymbol{v}.$$

$P^TP = (I-2ww^T)(I-2ww^T)$

$= I - 4ww^T + 4w(w^Tw)w^T$

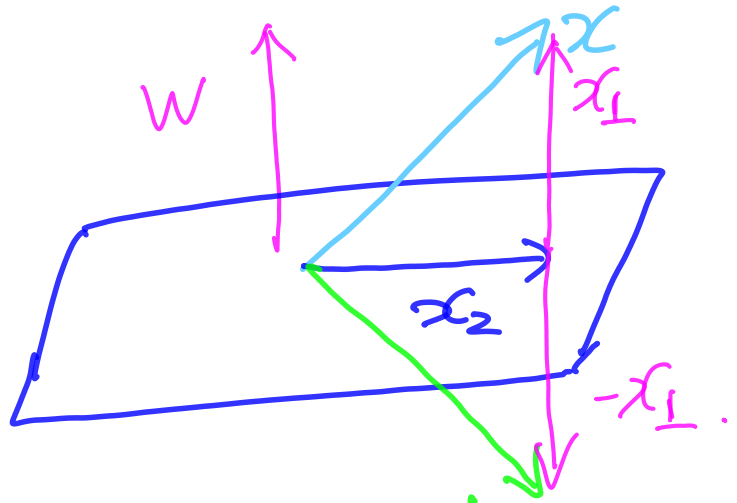
$= I - 4ww^T + 4ww^T \quad \|w\|_2^2 = 1$

$= I.$

③ 设 $x = x_1 + x_2$,

其中 $x_1 = \alpha w$, $x_2 \perp w$

$\alpha = x_1^T w$, $|\alpha| = \|x_1\|_2$.



$$Px = (I - 2ww^T)(x_1 + x_2)$$

$$= (x_1 + x_2) - 2w(w^T x_1)\alpha \quad (w^T x_2 = 0)$$

$$= (x_1 + x_2) - 2\alpha w = (x_1 + x_2) - 2x_1$$

$$= x_2 - x_1$$

⑤ $w \parallel x_1$, $x_1 \parallel (x - Px)$

$v = Px$

$\|w\|_2 = 1$, 取 $w = \dfrac{x - Px}{\|x - Px\|_2} = \dfrac{x - v}{\|x - v\|_2}$

对 $\boldsymbol{x} \neq 0$，可找到Householder变换，使得

$$\boldsymbol{P}\boldsymbol{x} = k\boldsymbol{e}_1.$$

可取

$$\begin{aligned} \boldsymbol{u} &= \boldsymbol{x} - k\boldsymbol{e}_1, \\ \boldsymbol{w} &= \frac{\boldsymbol{u}}{\|\boldsymbol{u}\|_2}. \end{aligned}$$

设 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^{\mathsf{T}}$，则

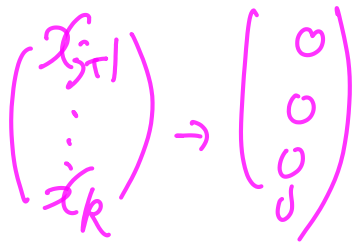
$$\boldsymbol{u} = (x_1 - k, x_2, \cdots, x_n)^{\mathsf{T}}$$

由于 $|k| = \|\boldsymbol{x}\|_2$。可取

$$k = -\operatorname{sgn}(x_1)\|\boldsymbol{x}\|_2$$

则有

$$
\begin{aligned}
\boldsymbol{u} &= \Big(x_1 + \mathbf{sgn}(x_1)\|\boldsymbol{x}\|_2, x_2, \cdots, x_n\Big) \\
\|\boldsymbol{u}\|_2^2 &= 2\|\boldsymbol{x}\|_2\Big(\|\boldsymbol{x}\|_2 + |x_1|\Big), \\
\beta &= \Big[\|\boldsymbol{x}\|_2(\|\boldsymbol{x}\|_2 + |x_1|)\Big]^{-1} \\
P &= I - \frac{2\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}}{\|\boldsymbol{u}\|_2^2} = I - \beta\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}
\end{aligned}
$$



类似可将接连几个分量变为零，设

$$\boldsymbol{x} = (x_1, \cdots, x_{j-1}, x_j, \cdots, x_k, x_{k+1}, \cdots, x_n)^{\mathsf{T}}$$

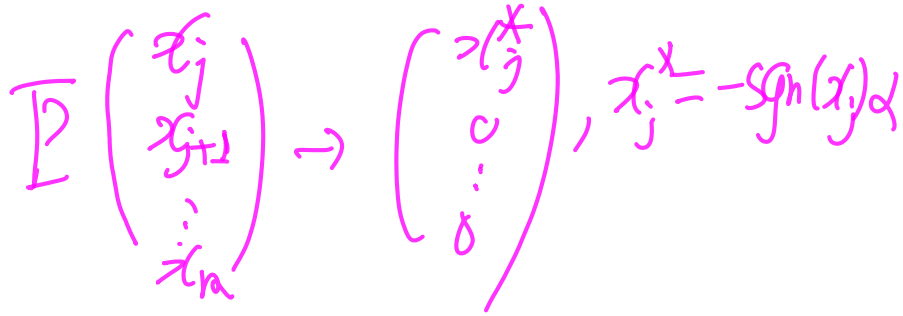
欲将其变成一个从 $j+1$ 指标到 k 指标都为零的向量，可以取

$$\boldsymbol{u} = (0, \cdots, 0, x_j + \mathbf{sgn}(x_j)\alpha, x_{j+1}, \cdots, x_k, 0, \cdots, 0)^{\mathsf{T}}$$

Householder矩阵

其中

$$\alpha = (x_j^2 + \cdots + x_k^2)^{1/2}$$



于是

$$\|\boldsymbol{u}\|_2^2 = 2\alpha(\alpha + |x_j|)$$

由此确定的Householder矩阵为

$$P = I - \frac{2\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}}{\|\boldsymbol{u}\|_2^2} = \begin{bmatrix} I_{j-1} & 0 & 0 \\ 0 & \bar{P} & 0 \\ 0 & 0 & I_{n-k} \end{bmatrix}$$



并且

$$P\boldsymbol{x} = (x_1, \cdots, x_{j-1}, -\mathbf{sgn}(x_j)\alpha, 0, \cdots, 0, x_{k+1}, \cdots, x_n)^{\mathsf{T}}$$

例

求Householder矩阵 P 使得 $P\boldsymbol{x} = k\boldsymbol{e}_1$，其中 $\boldsymbol{x} = (3,5,1,1)^{\mathsf{T}}$。

解：计算 $\|\boldsymbol{x}\|_2 = 6$，则取 $k = -6$，而

$$\begin{aligned} \boldsymbol{u} &= \boldsymbol{x} - k\boldsymbol{e}_1 = (9,5,1,1)^{\mathsf{T}}, \\ \|\boldsymbol{u}\|_2^2 &= 108, \\ \beta &= [\|\boldsymbol{x}\|_2(\|\boldsymbol{x}\|_2 + |x_1|)]^{-1} = \frac{1}{54} \end{aligned}$$

所以相应的Householder矩阵为

$$P = I - \beta\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}} = \frac{1}{54}\begin{bmatrix} -27 & -45 & -9 & -9 \\ -45 & 29 & -5 & -5 \\ -9 & -5 & 53 & -1 \\ 9 & -5 & -1 & 53 \end{bmatrix}$$

二维旋转矩阵

对某个 θ，记 $s = \sin\theta$，$c = \cos\theta$，

$$J(\theta) = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix}$$

为一正交阵。若 $\boldsymbol{x} \in \mathbb{R}^2$，则 $\boldsymbol{Jx}$ 表示将向量 $\boldsymbol{x}$ 顺时针旋转 θ 角所得到的向量。

如何将一个向量 $(x_1, x_2)^\mathsf{T}$ 变成另一个向量 $(y_1, y_2)^\mathsf{T}$，使得 $y_2 = 0$。

- 若 $x_2 = 0$，则 $c = 1$，$s = 0$；
- 若 $x_2 \neq 0$，$|x_2| \geq |x_1|$，考虑将向量 $\mathbf{sgn}(x_2)(x_1, x_2)^\mathsf{T}$ 旋转 $\theta \in (0, \pi)$ 角，变为平行于 x-轴的向量，于是

$$c = \cos\theta = \frac{\mathbf{sgn}(x_2)x_1}{(x_1^2 + x_2^2)^{1/2}},$$

$$s = \sin\theta = \frac{\mathbf{sgn}(x_2)x_2}{(x_1^2 + x_2^2)^{1/2}} > 0,$$

因而若记

$$t = c/s = \frac{x_1}{x_2}$$

$|x_2| > |x_1|$

则

$$s = (1+t^2)^{-\frac{1}{2}},\ c = st$$

- 若 $x_2 \neq 0,\ |x_2| < |x_1|$，考虑将向量 $\mathbf{sgn}(x_1)(x_1, x_2)^\mathsf{T}$ 旋转 $\theta \in (-\frac{\pi}{2}, \frac{\pi}{2})$ 角，变为平行于 x-轴的向量，于是

$$c = \cos\theta = \frac{\mathbf{sgn}(x_1)x_1}{(x_1^2+x_2^2)^{1/2}} > 0,\ s = \sin\theta = \frac{\mathbf{sgn}(x_1)x_2}{(x_1^2+x_2^2)^{1/2}},$$

因而若记

$$t = s/c = \frac{x_2}{x_1}$$

$|x_1| > |x_2|$ 避免大数除小数.

则

$$c = (1+t^2)^{-\frac{1}{2}},\ s = ct.$$

Given 矩阵

现在将它推广到 n 维情况

$$J(i,k,\theta) = \begin{bmatrix} 1 & & & & & & & & \\ & \ddots & & & & & & & \\ & & 1 & & & & & & \\ & & & c & \cdots & s & & & \\ & & & & 1 & & & & \\ & & & \vdots & \ddots & \vdots & & & \\ & & & & & 1 & & & \\ & & & -s & \cdots & c & & & \\ & & & & & & 1 & & \\ & & & & & & & \ddots & \\ & & & & & & & & 1 \end{bmatrix} \begin{matrix} \\ \\ \\ \\ \\ i \\ \\ k \\ \\ \\ \end{matrix}$$



称为Givens矩阵或Givens变换。

Givens 矩阵为正交矩阵，设

$$\boldsymbol{x} \in \mathbb{R}^n,\ \boldsymbol{y} = J(i,k,\theta)\boldsymbol{x},$$

则 $\boldsymbol{y}$ 的分量为

$$(y_i, y_k)^{\mathsf{T}} = J(x_i, x_k)^{\mathsf{T}},\quad y_j = x_j (j \neq i,k)$$

于是当 $x_i^2 + x_k^2 \neq 0$ 时，要将第 k 个分量变为零，可以左乘 $J(i,k,\theta)$，其中 c 和 s 确定如下

1. 若 $x_k = 0$，则 $c = 1, s = 0$;
2. 若 $x_k \neq 0,\ |x_k| \geq |x_i|$,

$$t = c/s = \frac{x_i}{x_k},\ s = (1+t^2)^{-\frac{1}{2}},\ c = st$$

3. 若 $x_k \neq 0,\ |x_k| < |x_i|$,

$$t = s/c = \frac{x_k}{x_i},\ c = (1+t^2)^{-\frac{1}{2}},\ s = ct$$

注记

$J(i,k,\theta)\boldsymbol{x}$ 只改变 $\boldsymbol{x}$ 的第 i,k 分量， $J(i,k,\theta)A$ 只改变 A 的第 i,k 行。同理 $AJ(i,k,\theta)^\intercal$ 只改变 A 的第 i,k 列。$J(i,k,\theta)AJ(i,k,\theta)^\intercal$ 只改变 A 的第 i,k 行和第 i,k 列。

例

求 *Givens* 矩阵 $J(2,4,\theta)$ 使得对 $\boldsymbol{x}=(1,2,3,4)^\intercal\in\mathbb{R}^4$ 有 $J(2,4,\theta)\boldsymbol{x}$ 的第*4*个分量为零。

解： 取 $i=2,k=4$， 则

$$t=\frac{1}{2},s=\sin\theta=\frac{2}{\sqrt{5}},c=\cos\theta=\frac{1}{\sqrt{5}},$$

所以

$$J(2,4,\theta)=\begin{bmatrix}1&0&0&0\\0&\frac{1}{\sqrt{5}}&0&\frac{2}{\sqrt{5}}\\0&0&1&0\\0&-\frac{2}{\sqrt{5}}&0&\frac{1}{\sqrt{5}}\end{bmatrix},J(2,4,\theta)\boldsymbol{x}=\begin{bmatrix}1\\2\sqrt{5}\\3\\0\end{bmatrix}$$

定理 (QR分解定理)

设$A \in \mathbb{R}^{n\times n}$，则存在正交阵 Q，使得 $A = QR$，且当 R 的对角元均为正时，分解唯一。

注记

实际上按照 *Givens* 变换或者 *Householder* 变换方法作出的分解 $A = QR$ 中 R 的元素不一定是正的。设 $R = [r_{ij}]$，只要令

$$D = \operatorname{diag}\left(\frac{r_{11}}{|r_{11}|}, \cdots, \frac{r_{nn}}{|r_{nn}|}\right),$$

D正交矩阵.

则 $\overline{Q} = QD$ 为正交阵，$\overline{R} = D^{-1}R$ 为对角元是 $|r_{ii}|$ 的上三角阵。$A = \overline{Q}\overline{R}$ 便是唯一的*QR*分解。

R对角元为正，A非奇异，$A^TA = (QR)^TQR = R^TQ^TQR = R^TR$

对称正定

Cholesky分解.

例

求矩阵 $A=\begin{bmatrix}4 & 4 & 0\\ 3 & 3 & -1\\ 0 & 1 & 1\end{bmatrix}$ 的QR分解，使 R 的对角线元素为正。

解：先用Givens变换，A 的第1列为 $(4,3,0)^{\intercal}$，所以

$$J(1,2,\theta_{12})=\begin{bmatrix}\frac{4}{5} & \frac{3}{5} & 0\\ -\frac{3}{5} & \frac{4}{5} & 0\\ 0 & 0 & 1\end{bmatrix},J(1,2,\theta_{12})A=\begin{bmatrix}5 & 5 & -\frac{3}{5}\\ 0 & 0 & -\frac{4}{5}\\ 0 & 1 & 1\end{bmatrix}$$

则 $P_1=J(1,2,\theta)$，P_1A 的第2列后两个元素为 $(0,1)^{\intercal}$，因此

$$P_2=J(2,3,\theta_{23})=\begin{bmatrix}1 & 0 & 0\\ 0 & 0 & 1\\ 0 & -1 & 0\end{bmatrix},P_2P_1A=\begin{bmatrix}5 & 5 & -\frac{3}{5}\\ 0 & 1 & 1\\ 0 & 0 & \frac{4}{5}\end{bmatrix}$$

R 对角元为正

$Q=(P_2P_1)^{\intercal}$

此时 $R = P_2P_1A$ 是一个上三角阵，且对角线元素为正，则

$$Q = (P_2P_1)^\mathsf{T} = \begin{bmatrix} \frac{4}{5} & 0 & \frac{3}{5} \\ \frac{3}{5} & 0 & -\frac{4}{5} \\ 0 & 1 & 0 \end{bmatrix}$$

$(P_2P_1)^\mathsf{T}(P_2P_1A) = (P_2P_1)^\mathsf{T}R$

$A = QR$

满足 $A = QR$。

也可用Householder变换，对 A 的第1列 $\boldsymbol{a}_1$，有

$$k = -5, \boldsymbol{u} = (4+5, 3, 0)^\mathsf{T} = (9, 3, 0)^\mathsf{T}, \|\boldsymbol{u}\|_2^2 = 90, \beta = \frac{1}{45}$$

则

$$P_1 = I - \beta\boldsymbol{u}\boldsymbol{u}^\mathsf{T} = \begin{bmatrix} -\frac{4}{5} & -\frac{3}{5} & 0 \\ -\frac{3}{5} & \frac{4}{5} & 0 \\ 0 & 0 & 1 \end{bmatrix}, P_1A = \begin{bmatrix} -5 & -5 & \frac{3}{5} \\ 0 & 0 & -\frac{4}{5} \\ 0 & 1 & 1 \end{bmatrix},$$

则 P_1A 的第1列对角线以下元素为0。

对 $\begin{bmatrix} 0 & -\frac{4}{5} \\ 1 & 1 \end{bmatrix}$ 的第1列做Householder变换有 $\overline{P} = \begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix}$ 所以

$$P_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & -1 & 0 \end{bmatrix}, P_2P_1A = \begin{bmatrix} -5 & -5 & \frac{3}{5} \\ 0 & -1 & -1 \\ 0 & 0 & \frac{4}{5} \end{bmatrix}$$

这里 $R = P_2P_1A$ 是上三角阵，而

$$Q = (P_2P_1)^{\mathsf{T}} = \begin{bmatrix} -\frac{4}{5} & 0 & \frac{3}{5} \\ -\frac{3}{5} & 0 & -\frac{4}{5} \\ 0 & -1 & 0 \end{bmatrix}$$

满足 $A = QR$，但是 R 的对角线元素并非都是正的，令 $\overline{D} = \mathrm{diag}(-1, -1, 1)$，则

$$\overline{Q} = \begin{bmatrix} \frac{4}{5} & 0 & \frac{3}{5} \\ \frac{3}{5} & 0 & -\frac{4}{5} \\ 0 & 1 & 0 \end{bmatrix}, \overline{R} = \overline{D}^{-1}R = \begin{bmatrix} 5 & 5 & -\frac{3}{5} \\ 0 & 1 & 1 \\ 0 & 0 & \frac{4}{5} \end{bmatrix}$$

定理 (谱分解)

设 $A \in \mathbb{R}^{n\times n}$ 可对角化，即存在非奇异的 X 使得

$$X^{-1}AX = D, \quad D = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix}$$

当且仅当 A 有 n 个线性无关的特征向量。令

$$X = [\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_n]$$

则

$$AX = XD \Longleftrightarrow A\boldsymbol{x}_i = \lambda_i \boldsymbol{x}_i, \quad 1 \le i \le n.$$

定理 (Schur 分解)

对任意的矩阵 $A \in \mathbb{R}^{n\times n}$，存在一个酉矩阵

$$U \in \mathbb{C}^{n\times n}: \quad U^{\mathrm{H}}U = UU^{\mathrm{H}} = I, \quad U^{\mathrm{H}} = \overline{U}^{\mathsf{T}}$$

使得

$$U^{\mathrm{H}}AU = \begin{bmatrix} * & * & * \\ & * & * \\ & & * \end{bmatrix} = R \in \mathbb{C}^{n\times n}$$

酉相似变换不畏惧舍入误差，不放大 A 中已有误差：

$$U^{\mathrm{H}}(A+E)U = U^{\mathrm{H}}AU + U^{\mathrm{H}}EU$$

而

$$\|U^{\mathrm{H}}EU\|_2 = \|E\|_2.$$

一般矩阵相似变换的风险

- 而一般的矩阵 X 作相似变换：

$$X^{-1}(A+E)X = X^{-1}AX + X^{-1}EX$$

$$\|X^{-1}EX\| \leq \|X^{-1}\|\|E\|\|X\|.$$

- 若 X 非常病态，即

$$\|X\| \cdot \|X^{-1}\| \gg 1 \Longrightarrow \|X^{-1}EX\| \gg \|E\|.$$

一般的相似变换具有潜在的不稳定性，应该尽量避免。

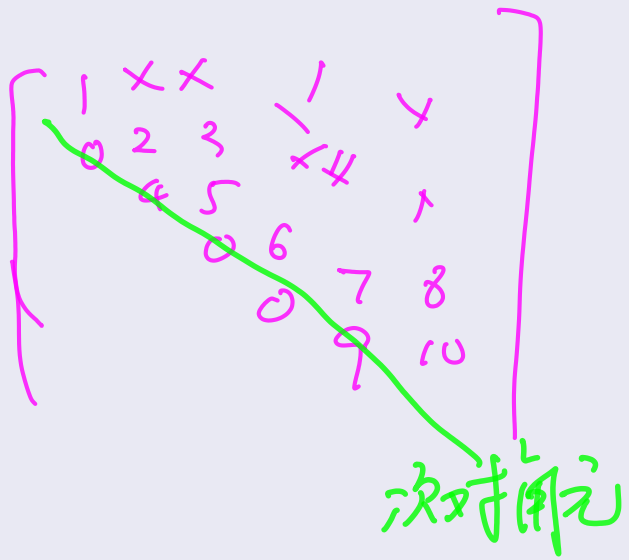
但是复矩阵 U 有不少缺点：

- 计算量和存储量显著增加，
- 会破坏问题本身的性质和结构。

定理 (实Schur分解定理)

- 设 $A \in \mathbb{R}^{n\times n}$，则存在正交阵 $Q \in \mathbb{R}^{n\times n}$，使得

$$Q^{\mathsf{T}}AQ = \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ & R_{22} & \cdots & R_{2m} \\ & & \ddots & \vdots \\ & & & R_{mm} \end{bmatrix}$$



其中每个 R_{ii} 是 1×1 或 2×2的。

- 若是 1×1 的，其元素就是 A 的特征值。
- 若是 2×2 的，R_{ii} 的特征值是 A 的一对共轭的复特征值。

QR迭代的目标是实Schur标准型.

在用迭代法求解特征值时，需要通过正交相似变换可以把矩阵 A 化为一种特殊的形式，即上Hessenber矩阵，它更接近实Schur分解的形式，对这种特殊形式的矩阵用数值方法求特征值会减少计算量。

定义 (上Hessenberg矩阵)

若 $B = (b_{ij}) \in \mathbb{R}^{n\times n}$，当 $i > j+1$ 时有

$$b_{ij} = 0,$$

则称 B 为上*Hessenberg*矩阵。而且若 B 的次对角元素

$$b_{i,i-1} \neq 0, i = 2, \cdots, n,$$

则称其为 不可约的上*Hessenberg*矩阵。

若 $A \in \mathbb{R}^{n\times n}$，它的第 j 列为

$$\boldsymbol{a}_j = (a_{1j}, \cdots, a_{jj}, a_{j+1,j}, \cdots, a_{nj})^{\mathsf{T}}$$

可以选择 $n-j$ 阶的Householder阵 $\bar{P}_j$，使得

$$\bar{P}_j \begin{bmatrix} a_{j+1,j} \\ a_{j+2,j} \\ \vdots \\ a_{nj} \end{bmatrix} = \begin{bmatrix} * \\ 0 \\ \vdots \\ 0 \end{bmatrix} \Longrightarrow P_j = \begin{bmatrix} I_j & \\ & \bar{P}_j \end{bmatrix} = I - \frac{2\boldsymbol{u}_j\boldsymbol{u}_j^{\mathsf{T}}}{\|\boldsymbol{u}_j\|_2^2} \in \mathbb{R}^{n\times n}.$$

使得

$$P_j\boldsymbol{a}_j = (a_{1j}, \cdots, a_{jj}, -\mathbf{sgn}(a_{j+1,j})\alpha, 0, \cdots, 0)^{\mathsf{T}}$$

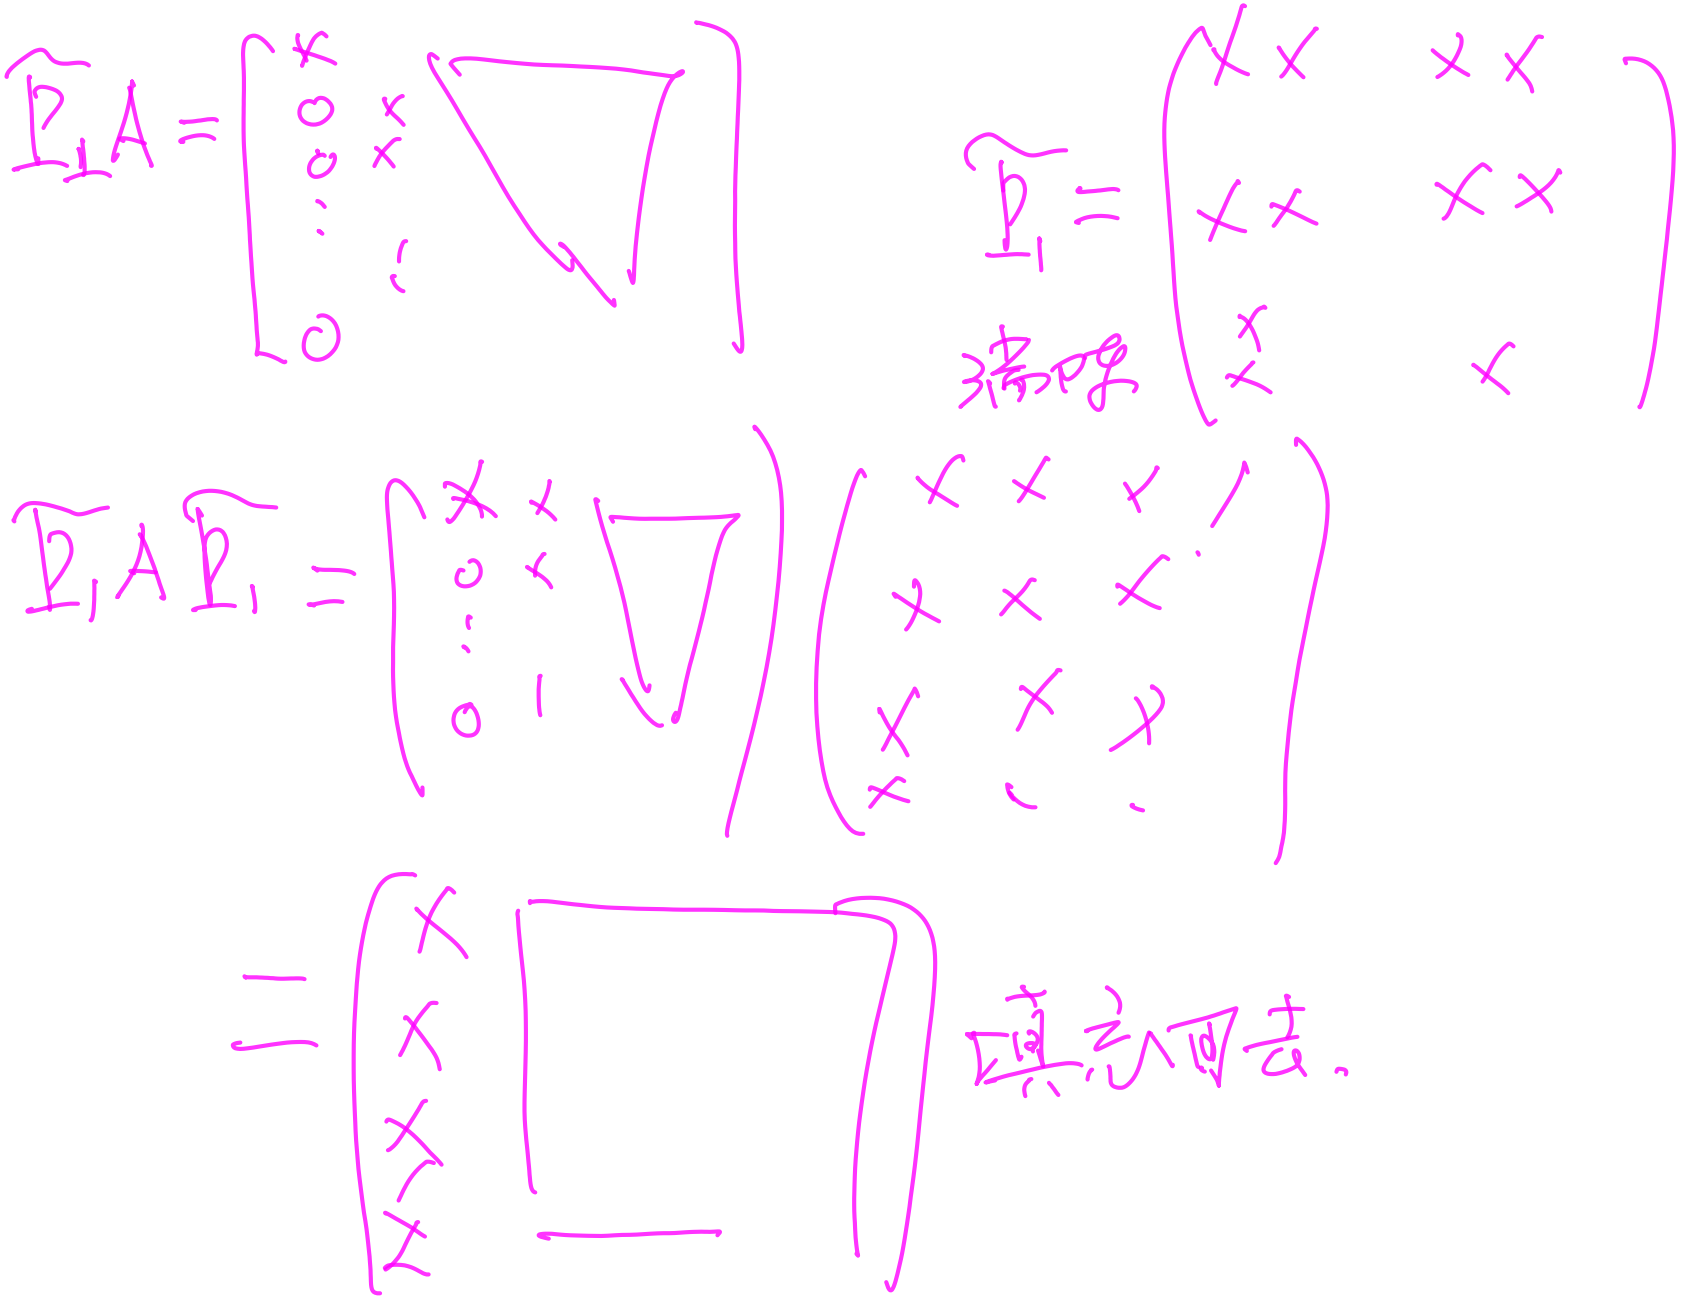
其中

$$\begin{aligned} \alpha &= (a_{j+1,j}^2 + \cdots + a_{nj}^2)^{1/2} \\ \boldsymbol{u}_j &= (0, \cdots, 0, a_{j+1,j} + \mathbf{sgn}(a_{j+1,j})\alpha, a_{j+2,j}, \cdots, a_{nj})^{\mathsf{T}} \end{aligned}$$

因而如此逐次左乘 $P_1, P_2, \cdots$，可将 A 次对角线以下的元素都化为零。为求 A 的特征值，应对 A 作相似变换。第一次作 $P_1 A P_1^{-1} = P_1 A P_1$：

$$
(P_1 A)P_1 = \begin{bmatrix} * & * & * & \cdots & * & * \\ * & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \end{bmatrix}
$$

$$
= \begin{bmatrix} * & * & * & \cdots & * & * \\ * & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & * & * & \cdots & * & * \\ 0 & * & * & \cdots & * & * \end{bmatrix}
$$



设 $k-1$ 步Householder正交相似变换后

$$
\begin{aligned}
A^{(k)} &= (P_1 \cdots P_{k-1})^{\mathsf{T}} A (P_1 \cdots P_{k-1}) \\
&= \begin{bmatrix} B_{11} & B_{12} & C_{11} & C_{12} \\ B_{21} & B_{22} & C_{21} & C_{22} \\ 0 & b_1 & D_{11} & D_{12} \\ 0 & \boldsymbol{b}_2 & D_{21} & D_{22} \end{bmatrix}
\end{aligned}
$$

其中

$\begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$ 为上Hessenberg矩阵。

设 $\bar{P}_k$ 为 $n-k$ 阶Householder阵，使得

$$
\bar{P}_k \begin{bmatrix} b_1 \\ \boldsymbol{b}_2 \end{bmatrix} = \begin{bmatrix} \hat{b}_1 \\ \mathbf{0} \end{bmatrix}
$$

则 n 阶Householder矩阵 $P_k = \begin{bmatrix} I & \\ & \bar{P}_k \end{bmatrix}$ 使

$$A^{(k+1)} = P_k^{\mathsf{T}} A^{(k)} P_k$$

形式为

$$\begin{aligned} A^{(k+1)} &= (P_1 \cdots P_k)^{\mathsf{T}} A (P_1 \cdots P_k) \\ &= \begin{bmatrix} B_{11} & B_{12} & \hat{C}_{11} & \hat{C}_{12} \\ B_{21} & B_{22} & \hat{C}_{21} & \hat{C}_{22} \\ 0 & \hat{b}_1 & \hat{D}_{11} & \hat{D}_{12} \\ 0 & 0 & \hat{D}_{21} & \hat{D}_{22} \end{bmatrix} \begin{bmatrix} I & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & * & * \\ 0 & 0 & * & * \end{bmatrix} \\ &= \begin{bmatrix} B_{11} & B_{12} & \tilde{C}_{11} & \tilde{D}_{12} \\ B_{21} & B_{22} & \tilde{C}_{21} & \tilde{C}_{22} \\ 0 & \hat{b}_1 & \tilde{D}_{11} & \tilde{D}_{12} \\ 0 & \mathbf{0} & \tilde{D}_{21} & \tilde{D}_{22} \end{bmatrix} \end{aligned}$$

此过程可以一直进行至 $n-2$ 步，即将 A 通过相似变换化为上Hessenberg矩阵

$$A^{(n-1)} = \begin{bmatrix} a_{11}^{n-1} & a_{12}^{n-1} & \cdots & a_{1,n-1}^{n-1} & a_{1n}^{n-1} \\ a_{21}^{n-1} & a_{22}^{n-1} & \cdots & a_{2,n-1}^{n-1} & a_{2n}^{n-1} \\ & a_{32}^{n-1} & \cdots & a_{3,n-1}^{n-1} & a_{3n}^{n-1} \\ & & \ddots & \vdots & \vdots \\ & & & a_{n,n-1}^{n-1} & a_{nn}^{n-1} \end{bmatrix}.$$

若 $A = A^T$，则 $(Q^TAQ)^T = Q^TA^TQ = Q^TAQ$

如果 A 是对称阵，则 $A^{(n-1)}$ 是一个对称的三对角阵。

定理

对任意的矩阵 $A \in \mathbb{R}^{n\times n}$，存在正交矩阵 Q 使

$$B = Q^TAQ$$

为一个上*Hessenberg*矩阵。

Householder 相似变换化为上 Henssenber 阵

- 设矩阵 $A \in \mathbb{R}^{n\times n}$，其列为 $\boldsymbol{a}_j, 1 \le j \le n$。
- 则对$j = 1, 2, \cdots, n-2$，确定 $n-j$ 阶Householder阵 $\bar{P}_j$，使得通过相似变换将 $\boldsymbol{a}_j$ 的次对角元以下元素下变为零：

$$\bar{P}_j \begin{bmatrix} a_{j+1,j} \\ a_{j+2,j} \\ \vdots \\ a_{nj} \end{bmatrix} = \begin{bmatrix} * \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$P_j = \begin{bmatrix} I_j & \\ & \bar{P}_j \end{bmatrix}$$

$$P_j^{\mathsf{T}} A P_j \Rightarrow A$$

- 此算法计算量约为 $\frac{5n^3}{3}$。

把矩阵

$$A = \begin{pmatrix} 1 & 5 & 7 \\ 3 & 0 & 6 \\ 4 & 3 & 1 \end{pmatrix}$$

变为上Hessenberg形式。

解： 选Householder阵 $P \in \mathbb{R}^{3\times 3}$ 使得

$$P(1,3,4)^{\mathsf{T}} = (1,*,0)^{\mathsf{T}}.$$

则取 $\alpha = (3^2+4^2)^{\frac{1}{2}} = 5$，$\boldsymbol{u} = (0,8,4)^{\mathsf{T}}$，$\|\boldsymbol{u}\|_2^2 = 80$，

$$P = I - \frac{\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}}{40} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -0.6 & -0.8 \\ 0 & -0.8 & 0.6 \end{bmatrix}$$

$$PAP = \begin{bmatrix} 1.00 & -8.60 & 0.20 \\ -5.00 & 4.96 & -0.72 \\ 0 & 2.28 & -3.96 \end{bmatrix}$$

也可对矩阵做Givens变换，对 A 的第一列构造Givens矩阵 $J(2,3,\theta)$ 使得 $J(2,3,\theta)(1,3,4)^{\mathsf{T}} = (1,*,0)^{\mathsf{T}}$，则

$$J(2,3,\theta) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0.6 & 0.8 \\ 0 & -0.8 & 0.6 \end{bmatrix}, \quad J(2,3,\theta) \begin{bmatrix} 1 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ 0 \end{bmatrix}$$

令 $Q = [J(2,3,\theta)]^{\mathsf{T}}$，则

$$Q = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0.6 & -0.8 \\ 0 & 0.8 & 0.6 \end{bmatrix}$$

有

$$Q^{\mathsf{T}}AQ = \begin{bmatrix} 1 & 8.6 & 0.2 \\ 5 & 4.96 & 0.72 \\ 0 & -2.28 & -3.96 \end{bmatrix}$$

基本QR算法

实矩阵A可分解为 $A = QR$，其中 Q 为正交阵，R 为上三角阵。若规定 R 的对角元为正，则 QR 分解是唯一的。令

$$B = RQ \Rightarrow B = Q^{\mathsf{T}}AQ = Q^{-1}AQ,$$

B 和 A 相似，有相同的特征值。

如果对 B 继续做如上运算，则有

基本QR算法

$$\begin{cases} A_1 &= A, \\ A_k &= Q_k R_k, \quad (A_k\text{的QR分解}) \\ A_{k+1} &= R_k Q_k, \quad \text{逆序相乘} \end{cases}$$

定理

QR算法产生的序列 $\{A_k\}$ 满足

1. $A_{k+1} = Q_k^{\mathsf{T}} A_k Q_k$；
2. $A_{k+1} = \bar{Q}_k^{\mathsf{T}} A \bar{Q}_k$，其中 $\bar{Q}_k = Q_1 Q_2 \cdots Q_k$；
3. $A^k = \bar{Q}_k \bar{R}_k$，其中 $\bar{R}_k = R_k \cdots R_2 R_1$。

证明：(1) $Q_k^T A_k Q_k = Q_k^T Q_k R_k Q_k = R_k Q_k = A_{k+1}$.

(2) $A_{k+1} = Q_k^T A_k Q_k = Q_k^T Q_{k-1}^T A_{k-1} Q_{k-1} Q_k$

$= \cdots = Q_k^T Q_{k-1}^T \cdots Q_1^T A_1 Q_1 Q_2 \cdots Q_k$

$= \bar{Q}_k^T A \bar{Q}_k$

(3) $\bar{Q}_k \bar{R}_k = Q_1 Q_2 \cdots (Q_k R_k) R_{k-1} \cdots R_1$，其中 $Q_k R_k = A_k$

$$= Q_1 Q_2 \cdots Q_{k-1} A_k R_{k-1} \cdots R_1$$

$$= \overline{Q}_{k-1} A_k \overline{R}_{k-1} \qquad A_k = \overline{Q}_{k-1}^T A \overline{Q}_{k-1}$$

$$= \overline{Q}_{k-1} \overline{Q}_{k-1}^T A \overline{Q}_{k-1} \overline{R}_{k-1}$$

$$= A \overline{Q}_{k-1} \overline{R}_{k-1}$$

$$= A A \overline{Q}_{k-2} \overline{R}_{k-2}$$

$$= A^{k-1} Q_1 R_1 A = A^k$$

$$A^k = A^k I = A^k [e_1 \cdots e_n] = [A^k e_1 \; A^k e_2 \cdots A^k e_n]$$

$A^k e_i \to \lambda_1 x_1$, 幂法.

对上Hessenberg 阵 H，选择 θ_i，用Givens矩阵 $J(i,i+1,\theta_i)$ 左乘 H，将第 $i+1$ 行第 i 列的元素变为 0。

$$H=\begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1i} & \cdots & h_{1,n-1} & h_{1n} \\ h_{21} & h_{22} & \cdots & h_{2i} & \cdots & h_{2,n-1} & h_{2n} \\ & \ddots & \ddots & \vdots & & \vdots & \vdots \\ & & \ddots & h_{ii} & \cdots & h_{i,n-1} & h_{in} \\ & & & h_{i+1,i} & \cdots & h_{i+1,n-1} & h_{i+1,n} \\ & & & & \ddots & \vdots & \vdots \\ & & & & & h_{n,n-1} & h_{nn} \end{bmatrix}$$

即

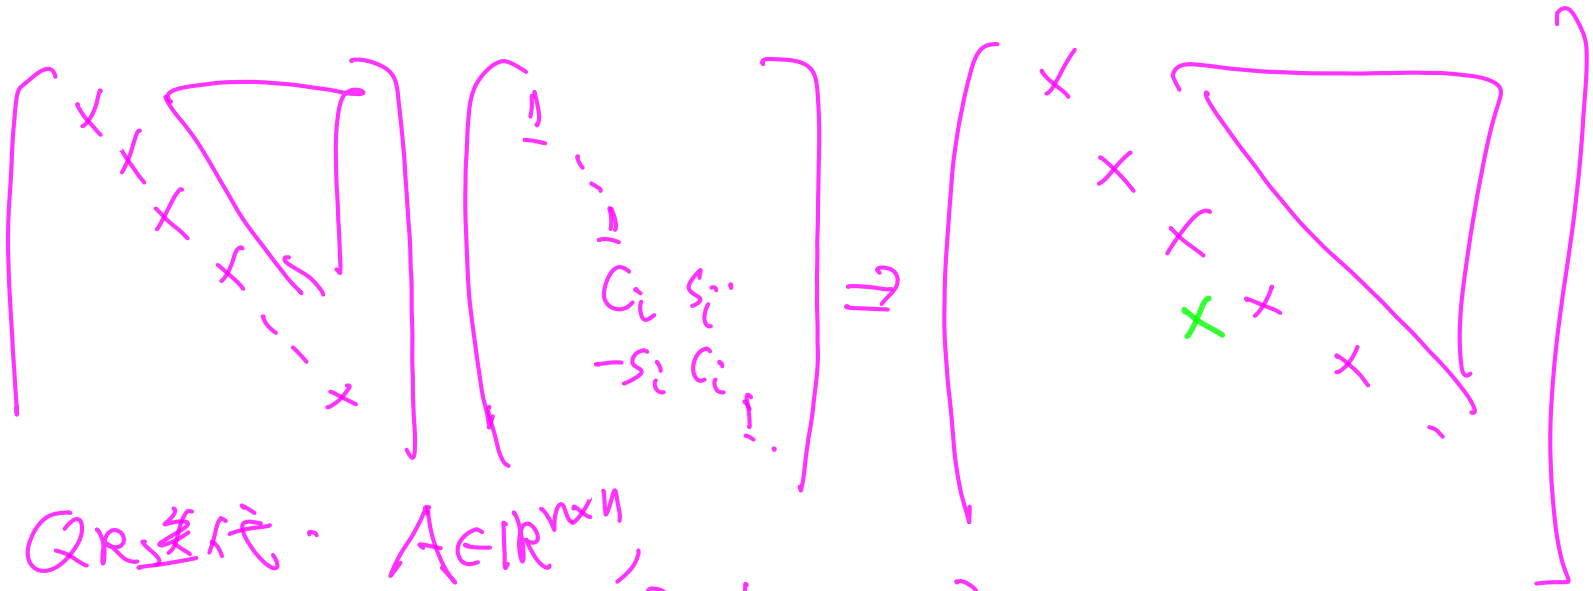
$$J(\theta_i)\begin{bmatrix} h_{ii} \\ h_{i+1,i} \end{bmatrix}=\begin{bmatrix} * \\ 0 \end{bmatrix}$$

$$J(\theta_i)=\begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & c_i & s_i & \\ & & -s_i & c_i & \\ & & & & 1 \\ & & & & & \ddots \\ & & & & & & 1 \end{bmatrix}$$

如此 $n-1$ 次操作之后得到上三角阵 R，

$$Q^{\mathsf{T}}H=R,\ Q^{\mathsf{T}}=J(n-1,n,\theta_{n-1})\cdots J(1,2,\theta_1).$$

H 为一上Hessenberg矩阵，由于$QH = R$，作 QR 迭代时，下一步计算 $H_2 = RQ$，容易验证 RQ 是一个上Hessenberg矩阵。因而QR算法保持 H 的上Hessenberg结构。



QR迭代：$A \in \mathbb{R}^{n\times n}$，

一系列的 Householder 变换把 A 变为上 Hessenberg 矩阵 H.

对 H 利用 Givens 变换进行 QR 分解迭代.

同样考虑上Hessenberg矩阵，假设每次QR迭代中产生的 H_k 都是不可约的，不然

$$H_k = \begin{bmatrix} H_{11} & H_{12} \\ 0 & H_{22} \end{bmatrix}, \quad \det H_k = \det H_{11} \cdot \det H_{22}.$$

可分为两个小规模矩阵的特征值问题。

- 假设 H 的特征值排列成 $|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|$ 则 H_k 的第 j 个次对角元收敛速度决定于 $\left|\frac{\lambda_{j+1}}{\lambda_j}\right|$，其越小，收敛越快。
- 因而可以借鉴幂法的想法，考虑 $H - \mu I$ 的特征值，使得将其特征值重新排列后 $|\lambda_1 - \mu| \geq |\lambda_2 - \mu| \geq \cdots \geq |\lambda_n - \mu|$ 使得 $\left|\frac{\lambda_{j+1} - \mu}{\lambda_j - \mu}\right|$ 尽可能小。

基于此思想，有如下的原点位移方法

原点位移 QR 迭代

$$\begin{cases} H_k - \mu I = Q_k R_k, (H_k - \mu I\text{的QR分解}) \\ H_{k+1} = R_k Q_k + \mu I,\ k = 1, 2, \cdots \end{cases}$$

若 μ 为 H 的一个特征值，则

$$R_k = Q_k^{\mathsf{T}}(H_k - \mu I)$$

为奇异阵。若 H_k 不可约，则 $r_{nn}^{(k)} = 0$，从而 H_{k+1} 的最后一行为

$$(0, \cdots, 0, \mu)$$

于是求得其一个特征值 μ。

1. 第1种原点位移的QR迭代

$$\begin{cases} \mu_k = h_{nn}^{(k)}, \\ H_k - \mu_k I = Q_k R_k, (H_k - \mu I \text{的QR分解}) \\ H_{k+1} = R_k Q_k + \mu_k I, \ k = 1, 2, \cdots \end{cases}$$

实schur标准型

$$\begin{matrix} h_{n-1,n-1} & h_{n-1,n} \\ h_{n,n-1} & h_{nn}^{(k)} \end{matrix}$$

收敛判别准则可取如下两者之一

$$|h_{n,n-1}^{(k)}| \le \epsilon ||H_1||_\infty$$

$$|h_{n,n-1}^{(k)}| \le \epsilon (|h_{nn}^{(k)}| + |h_{n-1,n-1}^{(k)}|)$$

2. 第2种原点位移的QR迭代选 μ_k 为

$$\begin{bmatrix} h_{n-1,n-1}^{(k)} & h_{n-1,n}^{(k)} \\ h_{n,n-1}^{(k)} & h_{n,n}^{(k)} \end{bmatrix}$$

的特征值中接近 $h_{nn}^{(k)}$ 中的一个。

用第2种原点位移的QR迭代求解矩阵

$$A=\begin{bmatrix}3&1&0\\1&3&1\\0&1&3\end{bmatrix}=\begin{bmatrix}a_1^{(1)}&b_2^{(1)}&0\\b_2^{(1)}&a_2^{(1)}&b_3^{(1)}\\0&b_3^{(1)}&a_3^{(1)}\end{bmatrix}$$ 的特征值。

解：A 已经是一个上Hessenberg矩阵的形式，首先求出

$$\begin{bmatrix}a_2^{(1)}&b_3^{(1)}\\b_3^{(1)}&a_3^{(1)}\end{bmatrix}=\begin{bmatrix}3&1\\1&3\end{bmatrix}$$

的特征值 $\lambda_1=4,\lambda_2=2$。则两个特征值和 $a_3^{(1)}$ 的距离一样，选取 $\mu_1=2$ 来做位移，则

$$A_2=A-\mu_1 I=\begin{bmatrix}d_1&b_2^{(1)}&0\\b_2^{(1)}&d_2&b_3^{(1)}\\0&b_3^{(1)}&d_3\end{bmatrix}=\begin{bmatrix}1&1&0\\1&1&1\\0&1&1\end{bmatrix}$$

用Givens变换作QR分解，首先把 $b_2^{(1)}$ 变为零，则Givens矩阵

$$J(1,2,\theta)A_2 = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} \sqrt{2} & \sqrt{2} & \frac{\sqrt{2}}{2} \\ 0 & 0 & \frac{\sqrt{2}}{2} \\ 0 & 1 & 1 \end{bmatrix} = A_2^{(1)}$$

下一步的Givens变换

$$J(2,3,\theta)A_2^{(1)} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & -1 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{2} & \sqrt{2} & \frac{\sqrt{2}}{2} \\ 0 & 0 & \frac{\sqrt{2}}{2} \\ 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} \sqrt{2} & \sqrt{2} & \frac{\sqrt{2}}{2} \\ 0 & 1 & 1 \\ 0 & 0 & -\frac{\sqrt{2}}{2} \end{bmatrix}$$

则 $R^{(1)} = J(2,3,\theta)A_2^{(1)}$，而

$$Q^{(1)} = J(1,2,\theta)^{\mathsf{T}} J(2,3,\theta)^{\mathsf{T}} = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & 0 & -\frac{\sqrt{2}}{2} \\ 0 & 1 & 0 \end{bmatrix}$$

所以

$$A^{(2)} = R^{(1)}Q^{(1)} = \begin{bmatrix} 2 & \frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 1 & -\frac{\sqrt{2}}{2} \\ 0 & -\frac{\sqrt{2}}{2} & 0 \end{bmatrix}$$

$A^{(2)} = R^{(1)}Q^{(1)} + \lambda_1 I$

上述过程完成一步QR迭代。下一步迭代先确定位移因子为

$$\begin{bmatrix} a_2^{(2)} & b_3^{(2)} \\ b_3^{(2)} & a_3^{(2)} \end{bmatrix} = \begin{bmatrix} 1 & -\frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & 0 \end{bmatrix}$$

的特征值 $\lambda_2 = \frac{1}{2} \pm \frac{\sqrt{3}}{2}$，所以取 $\mu_2 = \frac{1}{2} - \frac{\sqrt{3}}{2}$ 为最靠近 $a_3^{(2)} = 0$ 的特征值，再做一次QR迭代有

$$A^{(3)} = \begin{bmatrix} 2.6720277 & 0.37597448 & 0 \\ 0.37597448 & 1.4736080 & 0.030396964 \\ 0 & 0.030396964 & -0.047559530 \end{bmatrix}$$

此时 $b_3^{(3)} = 0.030396964$ 可以认为很小，接近于零。则

$$\lambda_3 \approx 1.5864151 = \mu_1 + \lambda_2 = 2 + \frac{1-\sqrt{3}}{2}.$$

删除第3行和第三列有

$$B^{(3)} = \begin{bmatrix} 2.6720277 & 0.37597448 \\ 0.37597448 & 1.4736080 \end{bmatrix}$$

它的特征值为 $\mu_1 = 2.7802140, \mu_2 = 1.3654218$。把位移加上可得

$$\lambda_1 \approx 4.4141886, \quad \lambda_2 \approx 2.9993964$$

而矩阵 A 的特征值的准确值为

$$\lambda_1 = 4.41420, \quad \lambda_2 = 3.00000, \quad \lambda_3 = 1.58579$$

仅仅两次迭代就有4位有效数字的精度。

把矩阵化为上Hessenberg矩阵的形式计算量为 $O(n^3)$，而接下来的用Givens 变换对矩阵进行 QR分解的计算量为 $O(n^2)$。对称阵可以化成三对角阵。所以预先化成上Hessenberg矩阵的优点：

1. 对一般的矩阵，每步QR迭代的工作量为 $O(n^2)$，而实对称矩阵为 $O(n)$。
2. 矩阵接近于上三角阵，只需要几步QR迭代。
3. 若第一次对角线上有零元素，则Hessenberg矩阵为分块的，可以将此问题分解为规模更小的问题。

由此可见QR迭代可分为两种情况

对称阵 $\longrightarrow$ 三对角阵 $\longrightarrow$ 对角阵

一般矩阵 $\longrightarrow$ Hessenberg矩阵 $\longrightarrow$ 实 Schur标准型

QR方法的计算量

- 对实对称矩阵若只计算特征值工作量为 $4n^3/3$，如果还要计算特征向量则还需 $9n^3$ 的计算量。
- 对一般的矩阵，只计算特征值的计算量为 $10n^3$，如果还需计算特征向量，则工作量大约为 $25n^3$。

QR迭代是计算矩阵全部特征值及特征向量的有效方法，但是它有一定的缺点，即在约化和后续迭代的过程中必须对整个矩阵进行操作。

1. 当 n 很大时，计算量太大。
2. 当 n 很大时，如果只求几个特征值和特征向量，方法的优势不明显。
3. 矩阵为大型稀疏矩阵时，由于相似变换产生了许多要存储的非零元素，方法的存储量太大。

Krylov子空间方法