No.

Date . .

样本空间

一. 样本空间定义

样本空间是一个集合，要求其元素互斥且完整，记为 Ω

$\Omega=\{1,\{1,2\}\}$ 不是样本空间

二. 事件

事件为样本空间的子集

A^c、$\bar{A}$ 对立事件、补事件

$A=B$ $A\cup B$、$A\cap B$ 的发生

三. 概率律 $P(\ )$

1. 定义：$P(A)$ 表示 A 的信念度，即 A 事件发生的概率测度

2. 公理

对于有限元素 Ω，事件 $A\in\Omega$，有：

① $P(A)\geq 0$ ② $P(\Omega)=1$ ③ 若 $A\cap B=\phi$，则 $P(A\cup B)=P(A)+P(B)$

$P(A\cup B)=P(A)+P(B)-P(A\cap B)=P(A)+P(A^c\cap B)$

$P(A\cup B\cup C)=P(A)+P(A^c\cap B)+P(A^c\cap B^c\cap C)$

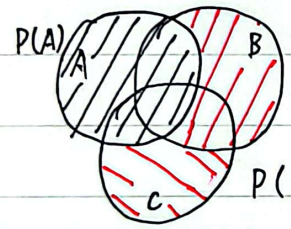

$P(A^c\cap B)$

$P(A^c\cap B^c\cap C)$

☆ 排除 B 中可能已有的 A ⇔ B 的范围下与 A 的并，不用担心非 A、非 C 的重叠

四. 古典概型

定义：离散均匀概率

五. 几何概率

定义：连续均匀概率

$$m(A)=\int_A 1\,dx_1\,dx_2\cdots dx_r$$

六. 排列数

有序样本表示：( )　　无序样本的表示：[ ]

No.

Date

例：$\Omega = \{w : w = (a_1, a_2, \dots, a_n),\ a_i \in \{1, 2, \dots, M\}\}$

则 $\#(\Omega) = M^n$

☆ $\Omega = \{w : w = [a_1, a_2, \dots, a_n],\ a_i \in \{1, 2, \dots, M\}\}$

则 $\#(\Omega) = \binom{n+M-1}{n} = \dfrac{(n+M-1)(n+M-2)\cdots M}{n!}$

若 $A \subset \Omega$，且 $\#(\Omega) = n$，则 $\#(A) = 2^n = \binom{n}{0} + \binom{n}{1} + \binom{n}{2} + \cdots + \binom{n}{n}$

$P(A \cup B) = P(A) + P(B) \Leftrightarrow A \cap B = \emptyset$

$P(A - B) = P(A/B) = P(A) - P(B) \Leftrightarrow B \subset A$

No.

Date . .

二. 古典概型与条件概率

一. 非特殊个体的抽取概率

袋中有 n 个白球与 m 个黑球，无放回抽取 k 个球，第 k 次抽中的概率？

前 k 个要抽的球比例未知，考虑偏号.

二. 事件的关系与运算

交换律: $A\cup B=B\cup A$

结合律: $A\cup(B\cup C)=(A\cup B)\cup C$ $\quad A\cap(B\cap C)=(A\cap B)\cap C$

分配律: $A\cup(B\cap C)=(A\cup B)\cap(A\cup C)$ $\quad A\cap(B\cup C)=(A\cap B)\cup(A\cap C)$

不能随意改变集合运算次序

三. 加法公式

$$P\left(\bigcup_{i=1}^{n}A_i\right)=\sum_{k=1}^{n}(-1)^{k-1}\cdot P_k,\quad P_k=\sum_{1\le j_1<\cdots<j_k\le n}P(A_{j_1}\cdots A_{j_k})$$

$$P(A\cup B)=P(A)+P(B)-P(A\cap B)$$

$$P(A\cup B\cup C)=P(A)+P(B)+P(C)-P(A\cap B)-P(B\cap C)-P(A\cap C)+P(A\cap B\cap C)$$

加法公式项数较多，能运用到的情况为对称情景.

n 封信随机分配到 n 封信箱，全部不对的概率为？

设 A_i 为第 i 个信分配正确

$$P\left(\bigcup_{i=1}^{n}A_i\right)=\binom{n}{1}P(A_1)+\binom{n}{2}\cdot(-1)^1\cdot P(A_1A_2)+\cdots+\binom{n}{n}(-1)^{n-1}\cdot P(A_1\cdots A_n)$$

其中 $P(A_1A_2\cdots A_k)=\dfrac{P_{n-k}^{n-k}}{P_n^n}=\dfrac{(n-k)!}{n!}$

四. 条件概率

$$P(A|B)=\frac{P(A\cap B)}{P(B)}\qquad P\left(\bigcap_{i=1}^{n}A_i\right)=P(A_1)\cdot\prod_{i=2}^{n}P(A_i|A_1\cdots A_{i-1})$$

全概率公式：设 $\{A_i\}$ 是 Ω 的一个分割，则 $P(B)=\sum_{i=1}^{n}P(B|A_i)\cdot P(A_i)$

贝叶斯公式：设 $\{A_i\}$ 是 Ω 的一个分割，则 $P(A_i|B)=\dfrac{P(B|A_i)\cdot P(A_i)}{\sum_{k=1}^{n}P(B|A_k)\cdot P(A_k)}$

KOKUYO

No.

Date · ·

第3讲 递推模型. 独立性. 样本相空间

一. 递推模型：事件发生一次后改变了事件的初始条件

① 不改变递推概率

例：甲有本金 a 元，赢 b 元后不赌，输光后不赌，求输光概率 $q(a)$.（赢的概率为 p）

分析：甲每次进行一局，均会改变初始条件，而已知 $q(0)$ 与 $q(a+b)$，则用递推.

解：$q(a)=pq(a+1)+qq(a-1)$

$\therefore q(a)-q(a-1)=\cdots=q(1)-q(0)=q(1)-1$

$\because q(0)=1,\ q(a+b)=0$

$\therefore \cdots$

② 改变递推概率

例：口袋中有 b 个黑球，r 个红球，任取一个放回后放入相同颜色 a 个，设 B_i = 第次取到黑球，求 $P(B_k)$.

分析：一样的改变初值模型，但未知 $P(B_k)$ 与 $P(B_{k-1})$, $P(B_{k+1})$ 关系，则从初开始推.

解：$P(B_1)=\frac{b}{b+r}$ $P(B_2)=\frac{b}{b+r}\cdot\frac{b+a}{b+r+a}+\frac{r}{b+r}\cdot\frac{b}{b+r+a}=\frac{b}{b+r}$

$\because P(B_k)=\frac{b}{b+r}$

二. 事件的独立性

1. "独立性定义"：事件 B 的发生并未给 A 带来信息，即 $P(A|B)=P(A)$

若 $P(AB)=P(A)\cdot P(B)$ [视为分两步完成]，则 A 与 B 独立.

推论：不可能事件，必然事件与任何事件都独立

若 A, B 独立，则 A^c, B 间与 A^c, B^c 之间独立

注意：独立与相交完全不同

2. 条件独立性

定义：设 $P(C)>0$，若 $P(AB|C)=P(A|C)\cdot P(B|C)$，则称 A 与 B 在给定条件下 C 独立.

注意：条件独立性与独立性无关

理解：条件独立改变了事件的样本空间，与独立相比两种情况是完全不同的实验.

No.

Date

3. 一组事件的独立性 —组事件的分步发生性

直观定义：任选其中一些事件，不能提供任何关于剩下事件的信息

定义：(考虑) 若对任意非空子集 $S \subset \{1,2,\dots,n\}$，有 $P(\bigcap_{i\in S} A_i) = \prod_{i\in S} P(A_i)$，

则 $A_1, A_2, \dots, A_n$ 相互独立　　任取几个 A_i

4. 两两独立

定义：若 $P(A_i \cap A_j) = P(A_i)\cdot P(A_j)$，$i,j \in \{1,2,\dots,n\}$，则 $A_1, A_2, \dots, A_n$ 相互独立 两两独立

注意：两两独立不能保证相互独立.

5. 独立性小结

独立. 条件独立. 两两独立. 相互独立

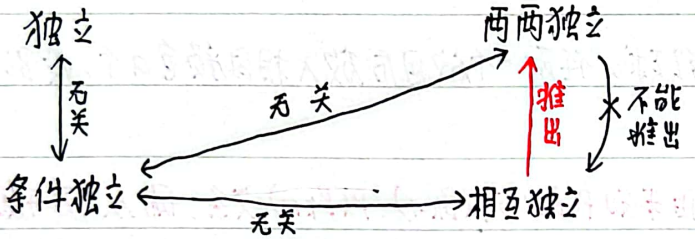

总结：独立性没有传递性，只能一个一个去验证！

n个事件相互独立，要验证 C_n^2 次 $C_n^2 + C_n^3 + \cdots + C_n^n$ 次，即 $(2^n - n)$ 次.

两两独立，要验证 C_n^2 次

4个事件 A, B, C, D

两两独立：$P(AB) = P(A)\cdot P(B)$，$P(AC) = P(A)\cdot P(C)$ …

相互独立：$P(AB) = P(A)\cdot P(B)$，$P(AC) = P(A)\cdot P(C)$ …

$P(ABC) = P(A)\cdot P(B)\cdot P(C)$，$P(ABD) = P(A)\cdot P(B)\cdot P(D)$ …

$P(ABCD) = P(A)\cdot P(B)\cdot P(C)\cdot P(D)$.

三个事件独立：既包含两两独立，又包含 $P(ABC) = P(A)\cdot P(B)\cdot P(C)$

三. 概率空间

1. 不可测集：设 $\Omega = [-2,2]$，定义点集 A，则 $P(A)$ 不存在.

若 $P(A)$ 存在，可得 $\begin{cases} P(A) > 0 \\ P(A) = 0 \end{cases}$，矛盾. (矛盾点来源于实数的无限细分的性)

因此样本空间的概率要由样本依据概率空间确定法则去定义.

No.

Date . .

2. 概率空间定义：

设 Ω 是样本空间，$\mathcal{F}$ 表示 Ω 的某些子集构成的集合(等维度)，若 $\mathcal{F}$ 满足：

1. $\Omega \in \mathcal{F}$，$\phi \in \mathcal{F}$ ("$\mathcal{F}$ 的上下界")　注意：若 $A, B \in \mathcal{F}$，则 $A \cap B \in \mathcal{F}$

2. 若 $A \in \mathcal{F}$，则 $A^c \in \mathcal{F}$　$\because (A \cap B)^c = A^c \cup B^c$　满足交、并、补仍属于 $\mathcal{F}$

3. 若 $A_n \in \mathcal{F}$，$n = 1, 2, \dots$，则 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$　$\therefore A \cap B = (A^c \cup B^c)^c$

则称 $\mathcal{F}$ 是 Ω 上的一个事件域 或 σ-域 或 σ-代数，称 $\mathcal{F}$ 中的元素为事件，称 $(\Omega, \mathcal{F})$ 为可测空间.

理解：为了解决同维度的问题，首先将 $\mathcal{F}$ 定义为样本空间 Ω 的某些子集构成的集合.

其次，$\mathcal{F}$ 之间的元素随不同事件的问题研究而改变，因此要定义好 $\mathcal{F}$ 中的元素.

即事件 —— 这是该问题的特征，也是基本事件，是"不可再分的事件".

最后，除了不可再分割的基础事件外，$\mathcal{F}$ 全集概率空间还要包含由基本事件得到的其它事件.

交：要求 1, 3 条成立.　补：要求 2 条成立.　基本事件不考虑并集.

$\mathcal{F}$：依问题而变化的 σ-代数，σ 代数有：

1. $\mathcal{F} = \{\Omega, \phi\}$，平凡的 σ-代数 (问题只研究样本空间发生与否)

2. $\mathcal{F} = \{\Omega$ 的所有子集$\}$，最大的 σ-代数 (把 Ω 中所有事件视为基本事件)

   $= 2^{\Omega}$ (有 2^n 个子集，也写作 幂集)

3. $\mathcal{F} = \{\Omega, \phi, A, A^c\}$，包含(由)定义的基本事件 A 的最小 σ-代数.

   记为 $\mathcal{F} = \sigma(\{A\})$

4. 对固定的 Ω，能构造出无穷多个 Ω 的 σ-代数.

Ω 的任意子集未必是事件，只有 $\mathcal{F}$ 中的元素才叫事件，事件可以作为概率的自变量

思考：$\mathcal{F}$、G 是两个 σ-域，问 $\mathcal{F} \cup G$ 是 σ-域吗？

不是，某些情况不满足事件的交集，交集无法在 $\mathcal{F} \cup G$ 中找到.

总结：Ω 是(做)样本空间，$\mathcal{F}$ 是 Ω 的 σ-域，$\mathcal{F}$ 中的元素可作为概率 P 的自变量.

除了找出 $\mathcal{F}$ 的基本事件，还要有基本事件交与补的结果.

$\mathcal{F}$：解决了 Ω 中元素不能分配概率的问题.

确定 $\mathcal{F}$：①确定基本元素是什么，基本元素：彼此完全无交集，对于已知的 $\mathcal{F}$ 元素，确保它们是完全不相交的，若相交，求出基本的并集与事件关于并集的补集.

②若互不相交的元素有 N 个，则一定含有 $2N$ 个元素于 $\mathcal{F}$ 中.

No.

Date

概率测度(*)：

设$(\Omega, \mathcal{F})$是可测空间，P是定义在$\mathcal{F}$上的函数，若

1.（非负性）对任意的$A \in \mathcal{F}$，$P(A) \geq 0$

2.（完全性）$P(\Omega)=1$　　（性质8定义即可，一般不会错）

3.（可列可加性），对不相交的$A_1, A_2, \dots$，有

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_i)$$

则称P为$\mathcal{F}$上的(以概率测度，简称概率，称$(\Omega, \mathcal{F}, P)$为概率空间，

在构造概率空间时，写明Ω，$\mathcal{F}$，P，其中P可写出定义式，也可写出关系式，

$P(\ )$中的自变量除了Ω，$\varnothing$之外都要说明是多少(可以是互推式)

4. 概率的连续性

① 事件列的单调性

若$A_1 \subset A_2 \subset A_3 \subset \dots$，则称事件列$\{A_i, i=1,2,\dots\}$单增，

理解：事件类似于数列，数列单调是指元素大小，事件单调是指事件面积大小，

② 事件列的极限

对于单增序列$\{A_i\}$，$\lim\limits_{n\to\infty} A_n = \bigcup\limits_{i=1}^{\infty} A_i$　（定义式）

对于单减序列$\{A_i\}$，$\lim\limits_{n\to\infty} A_n = \bigcap\limits_{i=1}^{\infty} A_i$

③ 概率的连续性

若$\{A_i\}$为单增列，则 $P(\lim\limits_{n\to\infty} A_i) = \lim\limits_{n\to\infty} P(A_n)$

若$\{B_j\}$为单减列，则 $P(\lim\limits_{j\to\infty} B_j) = \lim\limits_{j\to\infty} P(B_j)$

No.

Date . .

第4讲 随机变量

回顾：概率空间 $(\Omega, \mathcal{F}, P)$

Ω：样本空间 $\mathcal{F}$：Ω的σ域，由感兴趣的基本互不发N个事件通过交、并、补(完成)构成。含有2^N个元素。

P：定义在事件域$\mathcal{F}$上。 σ域：原定义域基本事件的交、并、补

一. 随机变量

作用：将样本空间Ω映射到实数轴，本质是函数映射。

简化记法：$X=5 \Leftrightarrow \{\omega | X(\omega)=5\}$

随机变量：即实验结果的代称，X既可指代函数值，又可指代事件，看与谁作比较

定义：设$(\Omega, \mathcal{F})$为可测空间，若Ω上的函数$X(\omega)$满足：

对$\forall x \in \mathbb{R}$，$\{\omega | X(\omega) \leq x\} \in \mathcal{F}$

则称$X(\omega)$是为$(\Omega, \mathcal{F})$上的随机变量，将$X(\omega)$简记为X

理解：此条性质的本质是为了察明$X(\omega)=x$方程的解ω是否含(从)于$\mathcal{F}$

简化判断方法：对于每一个$X(\omega)$值，其定义域ω若包含于$\mathcal{F}$，则可断定关于$X(\omega)$方程的解均含于$\mathcal{F}$内，即$X(\omega)$定义域含于$\mathcal{F}$，是合法的随机变量。

更一般地，探讨每段函数值对应的自变量，若函数值图形不平行于X轴，任选y值讨论即可。

$X(\omega)$是如何定义的，不用写明，说明$X(\omega)$表示含义即可，可用文字叙述。

二. Borel 集 (博雷尔集)

1. 用$\mathbb{R}$表示全体实数，$\mathcal{C}$表示$\mathbb{R}$中左开右闭的子区间全体，即$\mathcal{C}=\{(a,b]\}$，令$\mathcal{B}=\sigma(\mathcal{C})$，称$\mathcal{B}$为Borel域，$\mathcal{B}$的元素为Borel集。

理解：$\mathcal{B}$是许多定义在数轴上区间、点集的集合，$\mathcal{B}=\sigma(\mathcal{C})$，则任两个$\mathcal{C}$作交、并、补的集合均在$\mathcal{B}$内

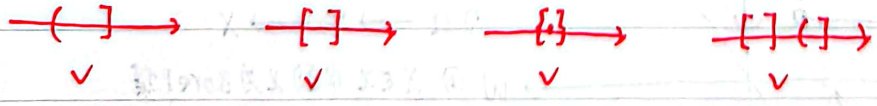

非Borel集的例子：$[0,1]$上所有互不能加减有理数的无理数集合。特征：无限多的点集集合，不能用数学符号有限通过交、并、补得到。

No.

Date

性质1. 设 X 是可测空间 $(\Omega, \mathcal{F})$ 上的随机变量，则对任意的 Borel 集 A，有

$$\{X \in A\} \equiv \{\omega \mid X(\omega) \in A\} \in \mathcal{F}$$

理解：Borel 集作为 X 的值域，能有效规避解出的 ω 可能是无数个点集的情况，避免了无法分配概率的情形。

性质2. 若 $(\Omega, \mathcal{F}, P)$ 是概率空间，对 Borel 集 A，$\{X \in A\}$ 一定是事件，

即 $(\Omega, \mathcal{F}, P)$ 的研究转变为了 $(\mathbb{R}, \mathcal{B}, P)$

$\mathbb{R}$：X 值域；$\mathcal{B}$：约束条件

$\Omega \xrightarrow{\text{等维构建}} \mathcal{F} \xrightarrow{\text{等维定义}} X$　　例如 X 值域为 $\mathbb{R}$，则 $X \in A$ 中的 A 也要与 $\mathbb{R}$ "等维"，即为 Borel 集。

三. 随机变量的函数

1. Borel 可测函数定义：

设 $\varphi(x)$ 是 $\mathbb{R}$ 上的实函数（将 $\mathbb{R}$ 映射为 $\mathbb{R}$），若 $\{x \mid \varphi(x) \le a\} \in \mathcal{B}$ 对任意实数 a 成立，则它是 $(\mathbb{R}, \mathcal{B})$ 上的随机变量，也称 Borel 可测函数。

理解：$\varphi(x)$ 的解集为 Borel 集，不会有解集是无限点集的情况。

2. 定理：若 X 是可测空间 $(\Omega, \mathcal{F})$ 上的随机变量，$g(x)$ 是可测函数，则 $Y = g(X)$ 是 $(\Omega, \mathcal{F})$ 上的随机变量。

3. 可测函数实例：连续函数、阶梯函数、单调函数及线性组合是可测函数。

类似地，若 $X_1, X_2, \ldots, X_n$ 是 $(\Omega, \mathcal{F})$ 随机变量，$g(x_1, x_2, \ldots, x_n)$ 是 n 元可测函数，则 $Y = g(X_1, \ldots, X_n)$ 是 $(\Omega, \mathcal{F})$ 上的随机变量。

四则运算、极限、变换、复合、$\max\{X, Y\}$、e^X、$|X|^p$ 均为随机变量。

总结：对 X，可以进行非直接说明无限点集集合的定义，所得仍为随机变量。

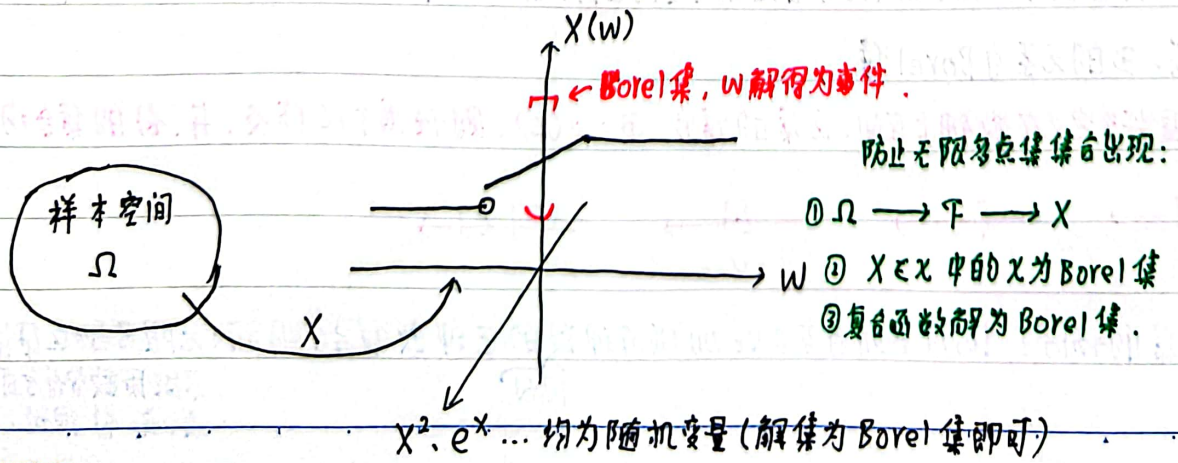

No.

Date . .

四. 随机变量的独立性

1. 定义(相互独立性): 设 $X_1, X_2, \dots, X_n$ 是 $(\Omega, \mathcal{F})$ 上的随机变量. 若对任意实数 $x_1, x_2, \dots, x_n$ 有:

$$P(X_1 \le x_1, X_2 \le x_2, \dots, X_n \le x_n) = P(X_1 \le x_1) \cdot P(X_2 \le x_2) \cdots P(X_n \le x_n)$$

则称随机变量 $X_1, \dots, X_n$ 相互独立.

理解: 随机变量独立, 实际上是函数的独立, 即各个函数的事件互不提供信息.

2. 独立序列

定义: 若对任意的 n, $X_1, \dots, X_n$ 相互独立, 则称 $\{X_i\}$ 相互独立, 称 $\{X_i\}$ 为独立序列.

独立序列任一子集均相互独立.

3. 定理1: 设 $X_1, \dots, X_n$ 相互独立, 则对任意 Borel 集 $A_1, \dots, A_n$, 事件

$$\{X_1 \in A_1\}, \dots, \{X_n \in A_n\} \text{ 相互独立.}$$

4. 定理2: 设随机变量 $X_1, \dots, X_n$ 相互独立, $g_1(x), \dots, g_n(x)$ 为一元可测函数

$\psi(x_1, \dots, x_k)$ 是 k 元可测函数, 则

① 随机变量 $g_1(x_1), \dots, g_n(x_n)$ 相互独立

② $\psi(X_1, \dots, X_k)$, $X_{k+1}, \dots X_n$ 相互独立.

理解: 对于随机变量 X, $g(X)$ 是新的随机变量. 一定有 $g(x)$ 的事件解含于 X 的事件解.

例: $aX+b$ 原保留 aX^2 可能有压缩信息.

(X 是定义域, X 的值域为 $(-\infty, +\infty)$, $g(x)$ 的 X 解一定含于其中.

KOKUYO

No.

Date . .

第5讲 离散型随机变量

一. 离散型随机变量

定义：若随机变量 X 只取有限个值，则或可列个，则 X 是离散随机变量，

概率分布列

定义：设 X 为离散型随机变量，称

$$P(X=x_k)=p_k$$

为 X 的概率分布，称 $\{p_k\}$ 为分布列。

若 $\{p_k\}$ 规律性不明显，写为

X	x_1	x_2	$\cdots$
P	p_1	p_2	$\cdots$

二. 两点分布 $B(1,p)$ （Bernouli 分布）

定义：若 X 只取 0 或 1，概率分布为 $P(X=1)=p=1-P(X=0)$，则称 X 服从两点分布，

记作 $X\sim B(1,p)$，或 $X\sim B(p)$

分布列：

X	0	1
P	$1-p$	p

三. 二项分布 $B(n,p)$

1. 定义：若随机变量 X 的概率分布为：

$$P(X=k)=\binom{n}{k}p^k\cdot(1-p)^{n-k}$$

则称 X 服从二项分布，记为 $X\sim B(n,p)$

理解：二项分布起源于二项式定理，有多(n)次实验，每次实验仅两种结果

若随机变量 $X_1,\dots,X_n$ 相互独立，且均服从两点分布 $B(1,p)$，则设 $S=X_1+X_2+\cdots+X_n$ 表示，

则 $S=X_1+X_2+\cdots+X_n$ 表示 n 次独立试验结果，且 $S\sim B(n,p)$

2. 若随机变量 X,Y 相互独立，且 $X\sim B(n,p)$，$Y\sim B(m,p)$，则 $X+Y\sim B(n+m,p)$

注意：二项分布中，每组某事件发生与否只能取 1 或 0，即 X_i 只能是 1 或 0，$X=n$ 代表发生了 n 次，

这种对应关系是由二项分布的定义式决定的。

若模型与事实有联系，$X=n$ 只能代表 n 个独立事件发生了 n 次

二项分布对应的事件：多次重复实验（二项式），只有两种结果，且 $X=k$ 代表某事件发生 k 次。

KOKUYO

No.

Date . .

3. 性质：设 $P(X=k)=b(k,n,p)$，则

$$\frac{b(k,n,p)}{b(k+1,n,p)}=\frac{\binom{n}{k}p^k(1-p)^{n-k}}{\binom{n}{k+1}p^{k+1}(1-p)^{n-k-1}}=\frac{n\cdot(n-1)\cdots(n-k+1)}{k!}\cdot\frac{(k+1)!}{n(n-1)\cdots(n-k)}\cdot\frac{1-p}{p}$$

$$=\frac{k+1}{n-k}\cdot\frac{1-p}{p}\xrightarrow{\text{提取1}}1+\frac{k+1-kp-p-np+kp}{(n-k)p}=1+\frac{k+1-p-np}{(n-k)p}$$

①若 $k>(1+n)p-1$，则 $b(k,n,p)>b(k+1,n,p)$，说明

（判断哪一项数列项最大时，不像函数限制严格，可以作差/比，注意是 $a_{n+1}-a_n$ 或 a_{n+1}/a_n，这样所得结果判断方法与函数导数一样）

$$\frac{b(k+1,n,p)}{b(k,n,p)}=\frac{(n-k)p}{(k+1)(1-p)}\xrightarrow{\text{提取1}}1+\frac{np-kp-k-1+kp+p}{(k+1)(1-p)}=1+\frac{np+p-k-1}{(k+1)(1-p)}$$

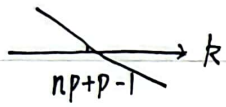

∴原图像为

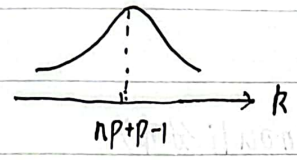

对应到数项图像为

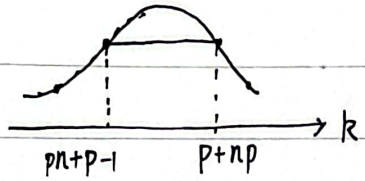

∵二项分布最大可能值 k_0 存在，$k_0=\begin{cases}np+p-1\text{ 或 }p+np & (p+np\text{为整数})\\ [p+np] & (p+np\text{为小数})\end{cases}$

小结：判断数项级数最大项的方法：

①确定大致图形，借用导函数与原函数的关系：依据导函数判断原函数的图像，核心是在于导函数的正负，因此数项级数的极值点不受倍数影响，只要定义式为 $a_{n+1}-a_n$ 或 $\frac{a_{n+1}}{a_n}-1$，则可求出极值点 n_0

②确定最大项：在找出极值点 n_0 后，含义是 $a_{n_0+1}=a_{n_0}$，而其中具体情况视 n_0 的值确定，

即 $b(k_0,n,p)$ 为二项分布的中心项

No.

Date

四. 几何分布

1. 定义：若随机变量 X 满足：

$$P(X=k)=(1-p)^{k-1}\cdot p$$

则称 X 服从参数 p 的几何分布，记为 $X\sim G(p)$

理解：几何分布名字来源于几何级数，即(等差数列)&等比数列.

若对映到具体事件，则是第 k 次成功的概率为 $P(X=k)$ (恰好)

2. 无记忆性

取正整数值的随机变量 $X\sim G(p)$ 的充要的条件是 X 无记忆性，即对每个 $k\geq 1$

$$P(X=k+1\mid X>k)=P(X=1)$$

无记忆性：之前事件发生与否不会影响到这一次的发生，对一个事件而言.

与独立性的区别：独立性：$P(X=k+1\mid X>k)=P(X=k+1)$，对两个事件而言

(级)几何分布的定义是直到成功的次数，与之前的有关.

随机变量的无记忆性：之前发生的事与当下的事无关(暗含独立性)，只不过用随机变量的形式给出.

即 $P(X=k\mid X>k-1)=P(X=1)=p$ (发生与否和之前无关)

(*) 五. 巾自其斤卡分布

甲向一个目标射击，直到击中 r 次为止，用 X 表示射击停止时的次数，则

$$P(X=k)=\binom{k-1}{r-1}p^r(1-p)^{k-r}$$

六. 超几何分布 $\sim H(n,M,N)$ (超：针对两个)

1. 定义：若随机变量 X 满足

$$P(X=k)=\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$$

则称 X 服从超几何分布，记作 $X\sim H(n,M,N)$

H(选多少(是实际变动)，有几个，总数为)

2. H与B

(H)λ 在 M 与 N 充分大的情况下，H可用B近似.

KOKUYO

No.

Date

设 $X \sim H(n, M, N)$，$Y \sim B(n, p)$

则当 M, N 充分大，$P(X=k) = P(Y=k) = C_n^k p^k (1-p)^{n-k}$，其中 $p = \frac{M}{N}$ $\lim_{N\to\infty} \frac{M}{N}$

（即认为拥取后对原系统无影响）

七. 泊松分布 (λ)

1. 定义：若随机变量 X 满足

$$P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

则称 X 服从参数为 λ 的泊松分布，记为 $X \sim P(\lambda)$，λ 是正常数.

2. 推导：实际上若 $X \sim B(n, \frac{\lambda}{n})$

则当 $n \to \infty$ 时，$X \sim P(\lambda)$

$$P(X=k) = \lim_{n\to\infty} C_n^k \cdot (\frac{\lambda}{n})^k (1-\frac{\lambda}{n})^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

$= \lim$

记忆技巧：泊松分布实际上是对函数的逼近.

$X=k$ 可视为用 k 阶（离 $x=0$ 越远）展开式逼近，即 $\frac{\lambda^k}{k!}$，λ 是导函数，固有属性.

逼近的函数是 e^x e^{-x}（$k \uparrow$，$p \downarrow$），则修正因子 $\frac{\lambda^k}{k!}$ 乘上目标函数 $e^{-\lambda}$ 即为结果.

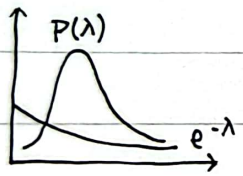

$$P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

3. 与实际的联系：计算发生概率与时间或正比的随机事件.

如：一天有 24 辆车经过，则在 1h 内最可能看到几辆车？

解：$X \sim B(n, \frac{1}{n}) \sim P(1)$ ∴ $P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$

n：无限小份时间；$\frac{1}{n}$：有份时间的经过数量；$\frac{\lambda^k}{k!}$：修正因子；$e^{-\lambda}$：实际逼近函数

$$P(X=k) = C_n^k (\frac{1}{n})^k (1-\frac{1}{n})^{n-k} = \frac{1}{k!} \cdot e^{-1}$$

八. 随机变量的函数

设 $Y=g(X)$，则 Y 的分布列计算公式为：

$$P_Y(y) = P(Y=y) = \sum_{\{x|g(x)=y\}} P_X(x)$$

（由 $Y=y$ 解出 X，再计算概率之和）

直接求和理由：每个 y 值下方的 x 对应都是不相容的 w

（有数学运算符的随机变量可视为数字，没回收到与题事件相关联的 x 是关键）

No.

Date . .

第6讲 离散(数)型随机变量的期望(与方差)

一. 期望

设 X 有概率分布 $p_j = P(X=x_j)$

只要级数 $\sum_{j=1}^{\infty} |x_j| p_j$ 收敛，则称 $E(x) = \sum_{j=1}^{\infty} p_j x_j$ 为 X 的数学期望或均值

(为什么绝对收敛？防止当 x_j 变换时出问题，期望算不出)

$E(x)$ 是 X 分布的质心

二. 常见离散型的期望

$X \sim B(1,p)$，则 $E(x) = p$

$X \sim B(n,p)$，则 $E(x) = np$

$X \sim P(\lambda)$，则 $E(x) = \lambda$ ①

$X \sim G(p)$，则 $E(x) = \frac{1}{p}$ ②

① : $E(x) = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} e^{-\lambda} = \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda}$

$= e^{-\lambda} \cdot \sum_{k=0}^{\infty} \frac{\lambda^k}{(k-1)!}$ 令

设 $f(\lambda) = \sum_{k=0}^{\infty} \frac{\lambda^k}{(k-1)!}$ $\therefore f$

$= \lambda$

② : $E(x) = \sum_{k=1}^{\infty} k \cdot p^k (1-p)^{k-1}$

$= p \sum_{k=1}^{\infty} k(1-p)^{k-1}$ 令 $= p(1-p)$

设 $f(p) = \sum_{k=1}^{\infty} k(1-p)^{k-1}$ $\therefore \int f(p)\,dp = \sum_{k=1}^{\infty} \left(\int k(1-p)^{k-1} dp\right) = \sum_{k=1}^{\infty} -(1-p)^k = -\sum_{k=1}^{\infty} (1-p)^k$

$\therefore f(p) = \left(\frac{p-1}{p}\right)' = \frac{p-p+1}{p^2} = \frac{1}{p^2}$

$= -(1-p) \cdot \frac{1-(1-p)^k}{1-1+p}$ $(k \to \infty)$

$\therefore E(x) = \frac{1}{p}$.

$= \frac{p-1}{p}$

三. 随机变量函数的期望

1. 分布列的求法：更换 X 分布列表头，再将相同项合并

2. 期望的求法：设 $Y = f(X)$，则 $E(Y) = \sum_{x} f(x_i) \cdot p_i$

3. 线性变量的期望：设 $Y = aX + b$，则 $E(Y) = aE(x) + b$

理解：期望是一系列点的"质心"，对于不改变空间特征的线性拉缩，质心符合线性拉缩。

而对于 X^2、X^3 这些高次函数扭曲了空间，导致计算结果不具形式上的关系。

4. 多个随机变量 $Z = g(X,Y)$ $P_Z(z_0) = \sum_{\{(x,y) \mid g(x,y)=z_0\}} P(X=x, Y=y)$ [由函数解 $Z=g(X,Y)$ 的定义，$X=x$ 与 $Y=y$ 需同时满足]

$P_Z(z_0) = \sum_{x} \sum_{y} g(x,y) P_{xy}(x_0,y)$

Z 的期望：$E(Z) = \sum_{x} \sum_{y} g(x,y) \cdot P_{X,Y}(x,y)$ 其中 $P_{X,Y}(x,y) = P(X=x \text{ 且 } Y=y) = P(X=x, Y=y)$

若 $g(X,Y)=aX+bY+c$，则 $E(aX+bY+c)=aE(X)+bE(Y)+c$

推广 $E(f(X)+g(Y))=E(f(X))+E(g(Y))$

理解：在计算 $E(g(X,Y))$ 时，X与Y实际上是两个维度的变量，互为常数。而当 $g(X,Y)$ 的形式为 $Y\cdot X$ 或 X^Y 等用Y扭曲了X的空间时，不可以直接拆分，而是要考虑Y对X的扭曲度。即只能从定义出发，固定X，求解出扭曲度Y（X与Y是具有隐函数形式的）。

对于 $E(aX+bY+c)$，由于对自个变量的扭曲均为常数，因此 $E(aX+bY+c)=aE(X)+bE(Y)+c$

对于 $E(f(X)+g(Y))$，相对X，Y是X的隐函数，用 $E(f(x)+g(x))=E(f(x))+E(g(x))$ 可得 $E(f(X)+g(Y))=E(f(X))+E(g(Y))$

小结：期望的线性性 $E(aX+b)=aE(X)+b$ （空间均匀膨胀）

$E(f(x)+g(x))=E(f(x))+E(g(x))$ （$f(x_0)p_i+g(x_0)p_i=(f(x_0)+g(x_0))p_i$）

$E(aX+bY+c)=aE(X)+bE(Y)+c$ （均匀膨胀）

卷积：若 $Z=X+Y$，则称Z的分布列为X与Y分布列的卷积（卷积：遍历历之意）

$$P_Z(z_0)=P(X+Y=z_0)=\sum_X P(X=X,Y=z_0-X)$$

泊松分布的可加性：若X与Y相互独立，且 $X\sim P(\lambda_1)$，$Y\sim P(\lambda_2)$，则 $X+Y\sim P(\lambda_1+\lambda_2)$

证明：$P(Z=k)=\sum_{x=0}^{k} P(X=x)P(Y=k-x)=\cdots$

理解：若X与Y相互独立，其充七时间内总的出现次数为两者之和 $\lambda_1+\lambda_2$，自然服从 $P(\lambda_1+\lambda_2)$

例：一盒N张带序号的盒子，从中放回抽取，收集k张不同序号，其期望抽取几次？

分析：计算期望，一般而言均为写出分布列，再依定义计算，但分布列是不可能写出的，想到递推关系式。

$E(X=k)=E(X=k-1)$ 由 $X=k-1$ 到 $X=k$ 记为事件 M_k，$M_k\sim G(\frac{N-k+1}{N})$

$\therefore E(X=k)=E(X=k-1)+E(M_k)=E(X=k-1)+\frac{N}{N-k+1}$ $\because E(1)=1$

$\therefore E(X=k)=\sum_{i=2}^{k}\frac{N}{N+1-i}+1=\sum_{i=1}^{k}\frac{N}{N+1-i}=N\cdot\sum_{i=1}^{k}\frac{1}{N+1-i}$

$=N\cdot\sum_{i=N-k+1}^{N}\frac{1}{i}=N\cdot\left(\sum_{m=1}^{N}\frac{1}{m}-\sum_{m=1}^{N-k}\frac{1}{m}\right)\sim N\cdot[\ln(N+1)-\ln(N-k+1)]$

$\left(\sum_{x=1}^{k}\frac{1}{x}\sim\ln(x+1)\right.$，由于 $\ln(x+1)$ $\left.\ln\frac{x+1}{x}\sim\frac{1}{x}\right)$

总结：对于抽取了m张带序号的后面，会改变题设条件，此为递推的根本原因。

No.

Date . .

第6讲 离散型随机变量的方差与多个随机变量的联合分布列

一. 方差定义与性质

1. 定义：若 $\mu = E(X)$ 有限，则称 $E(X-\mu)^2$ 为 X 的方差，记为 $Var(X)$ （variable）

理解：方差是一个数学期望，"去中心"化的期望

数值大小反映了 X 在期望附近的集中度

2. 等价计算式：$E(X) = E(X^2) - (E(X))^2$

证明：$E(X-\mu)^2 = E(X^2) - 2\mu E(X) + \mu^2 = E(X^2) - \mu^2 = E(X^2) - (E(X))^2$

理解：$(X-\mu)^2$ 表示离中心的距离，可以概率权重表示整体的离散度。

$$S^2 = \sum_{i=1}^{k} p_i (x_i - \mu)^2 = E(X-\mu)^2$$

$E(X^2)$：表现上整体位置平方值 $(E(X))^2$ 中点平方值

方差：数据相对均值的偏离度平方，$S^2 = E(X^2) - (E(X))^2 = E(X-\mu)^2$

二. 常见分布的方差

1. $X \sim B(p) \sim B(1,p)$ $E(X) = p$ $E(X-\mu)^2 = p\cdot(1-p)^2 + (1-p)\cdot p^2 = p^2 - p^3 + p - 2p^2 + p^3 = p(1-p)$

or $E(X-\mu)^2 = E(X^2) - (E(X))^2 = E(X) - p^2 = p - p^2 = p(1-p)$

2. $X \sim B(n,p)$ $E(X) = np$ $E(X-\mu)^2 = np(1-p)$

3. $X \sim B(n, \frac{p}{n})\ (n\to\infty) \sim P(\lambda)$ $E(X) = \lambda$ $E(X-\mu)^2 = \lambda$

4. $X \sim G(p)$ $E(X) = \frac{1}{p}$ $Var(X) = \frac{1-p}{p^2}$ （级数求和中，多项求导以等比项处理。{ 估次差：的手数 多比项指数的调整。

三. 多个随机变量的联合分布列

1. 定义 n 维随机向量：若 $X_1, X_2, \dots, X_n$ 为 $(\Omega, \mathcal{F}, P)$ 上的随机变量，则称 $\vec{X} = (X_1, \dots, X_n)$ 是 $(\Omega, \mathcal{F}, P)$ 上的 n 维随机向量。（元素间的样本空间与概率律相通，取值可相互联系）

2. 联合分布列：（定义 $\omega \to \mathbb{R}^n$）：若 $\vec{X}$ 所有不同取值是 $\vec{x}(j_1, j_2, \dots, j_n) = (X_1(j_1), X_2(j_2), \dots, X_n(j_n))$

则称：$P_{j_1, j_2, \dots, j_n} = P(\vec{X} = \vec{x}(j_1, \dots, j_n))$ 是 X 的联合分布列。

注意：$P_{a_1, a_2, \dots, a_n}$ 的概率刻画的事件是 $X_1 = a_1, X_2 = a_2, \dots, X_n = a_n$ 同时满足的事件。

KOKUYO

No.

Date

二维联合分布列的表格形式：

P_{ij}	y_1	y_2	…	y_n	$\{p_i\}$ → X的边缘分布列
x_1					p_1
x_2					p_2
⋮					⋮
x_n					p_n
$\{q_j\}$ ← Y的边缘分布列	q_1	q_2	…	q_n	$\Sigma=1$

设 $\vec{x}$ 的联合分布列为 $P_{j_1,j_2,\dots,j_n}$

则称 $P(X_1=x_1(j_1), X_2=x_2(j_2), \dots, X_k=x_k(j_k))$

$= \sum_{j_{k+1},\dots,j_n} P_{j_1,j_2,\dots,j_n}$ 为 $\vec{x}$ 的边缘分布列.

理解：(k)联合分布列的原有形式是n维空间中的一个体，而边缘列是其在其中(n-k)维面/线的边缘分布.

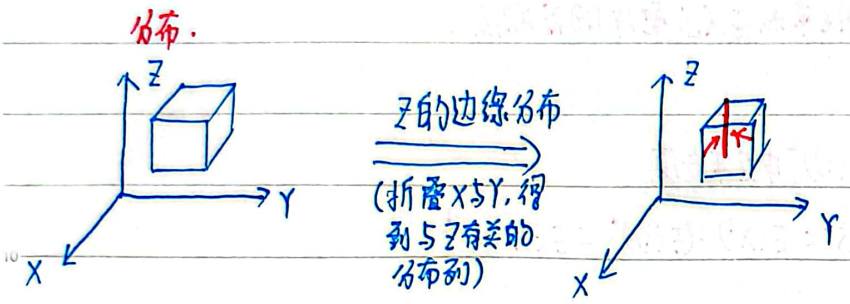

对于二元的联合分布列 P_{ij}，X的边缘分布列为 $P(X=i)=\sum_y P(X=i, Y=y)$

or 固定 $X=i$，求出 $P(X=i)$ 的表达式.

No.

Date

第7讲 多项分布、条件概率分布、全期望定理、连续型随机变量

一. 多项分布

1. 设 $A_1, \dots, A_r$ 是 S 的完备事件组，对 S 进行(S) n次独立重复试验，用 X_i 表示 A_i 发生的次数，则 $(X_1, X_2, \dots, X_r)$ 的概率分布为 $P(X_1=k_1, \dots, X_r=k_r) = C_n^{k_1} C_{n-k_1}^{k_2} \cdots C_{k_r}^{k_r} \cdot p_1^{k_1} p_2^{k_2} \cdots p_r^{k_r}$

$$= \frac{n!}{k_1! \cdots k_r!} p_1^{k_1} \cdots p_r^{k_r}$$

2. 边缘分布：若 $1 \le m < n$，则 $(X_1, \dots, X_m)$ 的边缘分布为

$$P(X_1=k_1, X_2=k_2, \dots, X_m=k_m) = \frac{n!}{k_1! \cdots k_m!\, k!} p_1^{k_1} \cdots p_m^{k_m} p^k$$

其中 $k = n - \sum_{i=1}^{m} k_i \qquad p = 1 - \sum_{i=1}^{m} p_i$

计算公式：$P_{k_1 k_2 \cdots k_m} = \sum_{k_{m+1}+\cdots+k_n = 1-\sum_{i=1}^{m} k_i} P(X_1=k_1, \dots, X_r=k_r)$

边缘分布的计算可用逐用求和计算，即以边缘分布列是相关变量的概率分布，因此在计算时要以相关变量取值为未知数，对条件"降阶"，即让其余条件和为1. 对于仅含 n 个随机变量，若求 n-1 个变量的边缘分布列，可尝试求和. 而对于 (n-m) 个变量的边缘分布列，则必重新考虑条件求出. 因为原条件是 n 个随机变量的分布列，只能一次对单一变量求和，进行逐一降一的操作.

例：已知 $P_{xyz} = x+y+z$，求 $P(X=i)$ X、Y 的边缘分布列.

$$P(X=i, Y=j) = \sum_z P_{ijz} = \sum_z (i+j+z)$$

求 X 的边缘分布列：$P(X=i) = \sum_{y,z} P_{iyz} = \sum_y \sum_z P_{iyz}$

降阶的过程遵循一级一级降阶原则，为了消除某个变量的影响，需要先固定其余项为未知数的前提下求出消去此项的概率公式. 如 $P(i,j,x,y,z) = \sum_x \sum_y \sum_z P(i,j,x,y,z)$，多变量求和互不影响.

二. 独立性

设 $X=(X_1, \dots, X_n)$ 有概率分布 $P_{j_1, \dots, j_n} = P(X=x(j_1, \dots, j_n))$，则 $X_1, \dots, X_n$ 相互独立的充要条件为：

对 $\forall (x_1(j_1), x_2(j_2), \dots, x_n(j_n))$，有 $P(X_1=x_1(j_1), \dots, X_n=x_n(j_n)) = \prod_{i=1}^{n} P(X_i=x_i(j_i))$

以等号的形式给出了小于号情形的原始定义

No.

Date

三. 条件概率分布

1. 定义：对每个固定的 j，称 $P(X=x_i \mid Y=y_j) = \dfrac{P(X=x_i, Y=y_j)}{P(Y=y_j)} = \dfrac{p_{ij}}{q_j}$ 为给定条件 $Y=y_j$ 下 X 的条件分布列.

2. X, Y 独立的充要条件是：对 $\forall i,j \geq 1$，有 $P(X=x_i \mid Y=y_j) = P(X=x_i)$

遍历整个取值

例：超市顾客数为 N，每人消费能力 $X \sim P(\lambda)$，且 X 与 N 无关，设 S 为总营业额，求 $P(S=k \mid N)$

$P(S=k \mid N) = P(S=k \mid N=m) = P(S_m=k)$，$S_m = X_1 + X_2 + \cdots + X_m \sim P(m\lambda)$

$\therefore P(S_m=k) = \dfrac{(m\lambda)^k}{k!} e^{-m\lambda}$　　$\therefore P(S=k \mid N) = \dfrac{(N\lambda)^k}{k!} e^{-N\lambda}$

四. 全期望定理

1. 设 $A_1, \ldots, A_n$ 是 Ω 的一个分割，则 $E(X) = \sum_{i=1}^{n} E(X \mid A_i) P(A_i)$

2. $P_{X \mid A_i}(x) = P(X=x_j \mid I_{A_i}=1) = \dfrac{P(X=x_j, A_i)}{P(A_i)}$，$I_{A_i}(w) = \begin{cases} 1 & w \in A \\ 0 & w \notin A \end{cases}$　$\{I_{A_i}=1\} = A_i$

事件 A_i

例：

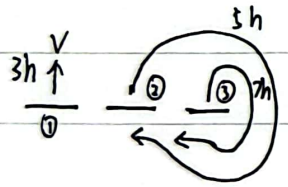

等概率选择一扇门，求通过的用时期望 $E(X)$

解：设选①②③分别为 A_1, A_2, A_3

则 $E(X) = E(X \mid A_1) \cdot \frac{1}{3} + E(X \mid A_2) \frac{1}{3} + E(X \mid A_3) \cdot \frac{1}{3}$

$= 1 + \frac{1}{3}E(X) + \frac{1}{3}E$

$= 1 + \frac{1}{3}(E(X)+5) + \frac{1}{3}(E(X)+7) \Rightarrow E(X) = 15h$

本质上还是事件的发生对整个模型有影响.

全概率公式期望的理解：对每个事件 X_j，用 $A_1, \ldots, A_n$ 去分割，求和后仍为 X_j.

No.

Date . .

五. 连续型随机变量

1. 定义：设随机变量 X，若存在非负函数 $f(x)$，使得对 $\forall a<b$，$P(a<X\le b)=\int_a^b f(x)dx$，则称 X 是连续型随机变量，$f(x)$ 是 X 的概率密度函数.

理解：若 X 是随机变量，则 X 有连续的取值，那么 X 对应一个概率函数 $F(X)$，有 $P(a<X\le b)=F(b)-F(a)$ 且 $F(x)$ 是连续的. 概率密度函数即为 $F(x)$ 的导数，$P(a<X\le b)=\int_a^b f(x)dx$

概率(或密度函数)：反映各个 X 取值附近的概率大小. 只有积分可以体现，积分结果函数受限于区间长度，无法直观反映概率密度，概率密度函数能直观反映某一点的概率大小，纵使点的概率为 0

性质：设 $f(x)$ 是 X 的概率密度，则　　(密度：每个 x_0 对应一个概率值，构成概率空间)

① $\int_{-\infty}^{+\infty} f(x)=1$　② $P(X=a)=0$　③ $P(a<X\le b)=P(a\le X\le b)$　④ 对任意的 Borel 集 A，有 $P(X\in A)=\int_A f(x)dx$

讨论：① X 是随机变量，但 $X=X(w)$ 不一定是连续函数(样本空间是集合，无拓扑，也无连续的意义)

② $\int_{-\infty}^{+\infty} f(x)dx=1$，但 $f(x)$ 在定义域内未必有界

③ $f(x)$ 是定义在 R 上的，要写明整个 R 对应的函数值.

概率密度函数：概率/长度的函数，能直观体现 x_0 附近的密度大小(概率发生大小).

用密度函数计算概率，要乘上该密度下的长度，其实就是积分.

$$\rho(x)=\lim_{\Delta x\to 0}\frac{P(x_0<X<x_0+\Delta x)}{\Delta x}\Rightarrow \rho(x)=f(x)$$，是各点的密度.

密度 $\Rightarrow$ 概率：积分

2. 数学期望

设 X 有概率密度 $f(x)$，若 $\int_{-\infty}^{+\infty}|x|f(x)dx$ 收敛，则称 $E(x)=\int_{-\infty}^{+\infty}xf(x)dx$ 为 X 的数学期望.

每一个 x_0 对应的微元概率 $f(x_0)$ 乘上 x_0 即为每一微元的期望，可称为期望密度. $E(x)$=期望密度积分.

与离散情形相同，均为 $x_0f(x_0)$，只是对于(随)连续随机变量 X，要积分.

方差：$Var(x)=E(X^2)-[E(x)]^2=\int_{-\infty}^{+\infty}x^2f(x)dx-\left(\int_{-\infty}^{+\infty}xf(x)dx\right)^2$

六. 常见的连续随机型变量

1. 均匀分布　$X\sim U(a,b)$　(uniform)

定义：对 $a<b$，若 X 的概率密度为 $f(x)=\begin{cases}\frac{1}{b-a} & x\in(a,b)\\ 0 & x\notin(a,b)\end{cases}$，则称 X 服从 (a,b) 上的均匀分布，记作 $X\sim U(a,b)$

$f(x)$ 也可以写为 $f(x)=\frac{1}{b-a}I_{(a,b)}(x)$　$I_{(a,b)}(x)$：是(随机变量)函数，X 是数值　I：示性函数(变量)

表示 I 示性 (a,b)

No.

Date . .

期望：$E(X)=\int_a^b \frac{1}{b-a}x\,dx=\frac{a+b}{2}$

方差：$Var(X)=E(X^2)-(EX)^2=\frac{(b-a)^2}{12}$　　$Var(X)=E(X-\mu)^2=\int_{-\infty}^{+\infty}f(x)(x-E(X))\,dx$

更一般地，对 $\forall$ Borel集 A，若 $m(A)=\int_A 1\,dx<\infty$，即 A 的测度存在，若 X 的密度为

$$f(x)=\begin{cases}\frac{1}{m(A)} & x\in A\\ 0 & x\notin A\end{cases}$$

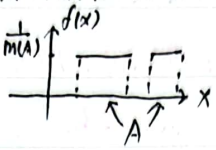

分段常数

则称 X 服从 Borel集 A 上的均匀分布，

记作 $X\sim U(A)$，A 为集合.

对任意 Borel集 B，$P(B)=\frac{m(A\cap B)}{m(A)}$（转化为测度长度之比）

2. 指数分布　$X\sim E(\lambda)$

定义：若 X 超过某个值的概率随值的增加而指数递减，即 $P(X\geq a)=e^{-\lambda a}$ $(\forall a\geq 0)$

则 X 是指数分布的.

非负随机变量 X：若概率密度为 $f(x)$　$P(X<0)=0$

对非负随机变量 X，若概率密度为 $f(x)=\lambda e^{-\lambda x}$ $(x\geq 0)$，则称 X 是指数随机变量. 当然，λ 一定大于0，$\lambda>0$

理解：$X\sim E(\lambda)$，X 服从关于 λ 的指数分布.（是指么？）在现实问题中关心的是 $P(X\leq a)$，而非 $P(x)$，因此

$P(X\leq a)=e^{-\lambda a}$. 对应的概率密度函数为

在实际情形中，研究的变量 x 通常大于0. 如果是指数分布，只说是递减的指数分布.

$$f(X\geq a)=e^{-\lambda a}=\int_a^{+\infty}f(x)dx \Rightarrow f(a)=\lambda e^{-\lambda a}$$

密度函数为 $f(x)=\lambda e^{-\lambda x}$.

期望若 $X\sim E(\lambda)$，则 $f(x)=\lambda e^{-\lambda x}$（积分不改变指数函数型，$\lambda$ 为正值，保证积分结果为 $e^{-\lambda x}$）

$$E(x)=\int_0^{+\infty}\lambda x e^{-\lambda x}dx=\frac{1}{\lambda}\int_0^{+\infty}te^{t}dt=\frac{1}{\lambda}\cdot(-\int_0^{+\infty}t\,de^{-t})=\frac{1}{\lambda}\cdot(-te^{-t}|_0^{+\infty}+\int_0^{+\infty}e^{-t}dt)$$

$$=\frac{1}{\lambda}\int_0^{+\infty}e^{-t}dt=\frac{1}{\lambda}\cdot e^{-t}|_{+\infty}^{0}=\frac{1}{\lambda}$$

$E(X^2)=\frac{2}{\lambda^2}$　$Var(X)=\frac{1}{\lambda^2}$

无记忆性：对 $\forall s,t\geq 0$，有 $P(X>s+t\mid X>s)=P(X>t)$

↳ 无记忆性：之前发生与否对之后而言是新的开始（不是没有影响）

即 $P(X>s\mid X>t)=P(X>s-t)$

以 t 时为新开始的值.

（指数型：找准新开始值是 t or $t+1$）

失效率：单位时间长度的失效概率 $\lim_{\Delta t\to 0}\frac{P(t\leq X\leq t+\Delta t\mid X>t)}{\Delta t}$

在 t 时刻经过 Δt 时间后失效的概率：

① 已正常(X 工作量 t 时刻

② Δt 时间后失效，即有 $t<X<t+\Delta t$

因此为 $P(t<X<t+\Delta t\mid X>t)$

$$\lim_{\Delta t\to 0}\frac{P(t\leq X\leq t+\Delta t\mid X\geq t)}{\Delta t}$$

$$=\lim_{\Delta t\to 0}\frac{e^{-\lambda(t)}-e^{-\lambda(t+\Delta t)}}{\Delta t\cdot e^{-\lambda t}}$$

$$=\lim_{\Delta t\to 0}\frac{1-e^{-\lambda\Delta t}}{\Delta t}=\lim_{\Delta t\to 0}-\frac{-\lambda\Delta t}{\Delta t}=\lambda$$

即有时刻的失效率不随时间改变（无记忆性）

No.

Date

第8讲 随机变量函数、正态分布、概率分布函数

一. 随机变量函数的数学期望

定理：设X是随机变量，若X有概率密度函数 $f(x)$，实函数 $g(x)$ 使得 $\int_{R^n}|g(x)|f(x)dx<+\infty$

则称 $Y=g(x)$ 有数学期望，且 $E(Y)=\int_{-\infty}^{+\infty}g(x)f(x)dx$

例：设 $X\sim U(0,\frac{\pi}{2})$，计算 $E(Y)$ $(Y=\cos X)$

（避免计算Y的分布情况，直接把将 $E(Y)$ 计算式中的Y换为X）

$$E(Y)=\int_{-\infty}^{+\infty}\cos x\cdot f(x)dx$$

$$\left(=\int_{-}^{+\infty}\right)_x\left(=\int_{-\infty}^{+\infty}\right)_x=\int_0^{\frac{\pi}{2}}\cos x\cdot\frac{2}{\pi}dx=\frac{2}{\pi}$$

二. 正态分布 $N(\mu,\sigma^2)$ N: normal （高斯分布、钟型分布）

1. 定义：若X的密度函数为 $f(x)=\frac{1}{\sigma\sqrt{2\pi}}\cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$，则称X服从参数 (μ,σ^2) 的正态分布.

记作 $X\sim N(\mu,\sigma^2)$.

2. 若 $X\sim N(\mu,\sigma^2)$，则 $E(x)=\mu$，$Var(x)=\sigma^2$，概率最大值为 $\frac{1}{\sigma\sqrt{2\pi}}$

μ：决定概率分布中心 σ：决定函数形状.

3. 标准正态分布

若 $X\sim N(0,1)$，则称X服从标准正态分布.

实际上，对 $\forall X\sim N(\mu_1,\sigma_1)$，其特征值都能由 $N(\mu_2,\sigma_2)$ 转化而来，因此定义最简单参数的正态分布：$\mu=0$，$\sigma=\sigma^2=1$ 为标准正态分布，由对应关系，快速计算出 $N(\mu,\sigma)$

其概率密度函数 $\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$

$\varphi(x)$ 确实为密度函数：$\int_{-\infty}^{+\infty}\varphi(x)dx=1$ 证明技巧：对于 e^{x^2} 型积分，用极坐标变换配凑出 ρe^{ρ^2}

证：$\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx\cdot\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy$

$=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\frac{1}{2\pi}\cdot e^{-\frac{x^2+y^2}{2}}dxdy$

$=\int_0^{2\pi}d\varphi\cdot\int_0^{+\infty}\frac{1}{2\pi}\cdot e^{-\frac{\rho^2}{2}}\rho d\rho d\varphi$

$=\frac{1}{2}\int_0^{+\infty}e^{-\frac{\rho^2}{2}}d\rho^2$

$=-e^{-\frac{\rho^2}{2}}\Big|_0^{+\infty}=1$

$f(x)$ 也是密度函数.

证：$\int_{-\infty}^{+\infty}\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$

$=\frac{1}{\sqrt{\pi}}\cdot\int_{-\infty}^{+\infty}e^{-t^2}dt$

$\because\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}\cdot e^{-\frac{x^2}{2}}dx=1$ $\therefore\int_{-\infty}^{+\infty}e^{-\frac{x^2}{2}}d\frac{x}{\sqrt{2}}=\sqrt{\pi}$

$\therefore$ 原式 $=1$

No.

Date

4. 若 X 数学期望存在，且 $f(x+\mu)=f(x-\mu)$，则 $E(x)=\mu$

证：$E(x)=\int_{-\infty}^{+\infty} xf(x)dx = \mu+\int_{-\infty}^{+\infty}(x-\mu)f(x)dx$

$(x-\mu)f(x) = -[\ ]_x$ $(x-\mu)f(x)$ 为奇函数 $\therefore E(x)=\mu$

三. 高阶矩

定义：设 X 是随机变量，m 是正整数．称 $E(X^m)$ 为 X 的 m 阶原点矩，称 $E(X-EX)^m$ 为 X 的 m 阶中心矩．

当 $m>2$，统一称为高阶矩

$m=2$ 的中心矩：$E(X-EX)^2$：方差．

(矩) 理解：矩：$r\times F=M$，借用力学中矩的概念，来以 m 次方即为 m 阶矩．中心矩：到 E(x) 的矩

原点矩：到原点的矩

四. 概率分布函数

1. 定义：对随机变量 X，称 X 的函数 $F(x)=P(X\le x)$ $(x\in\mathbb{R})$ 为 X 的概率分布函数，或累积分布函数．

理解：直接表达出 X 在各点取值的概率函数为"概率分布函数"，直接描绘变量的概率取值．

为了使其斜率为正有意义，定义以 $-\infty$ 为其起点，刻画变量的概率分布．

2. 从概率分布列计算 F(x)：F(x) 是单调不减的阶梯函数，在每个 x_j 处有跳跃 p_j．

分布列对 F(x) 的影响在于值的突变，因此由 $F(x_i+\Delta x)-F(x_i-\Delta x)=P(x_i)$ 确定 F(x) 表达式，是分段的．

也称 F(x) 是分布列 $\{p_i\}$ 的分布函数．

从 F(x) 计算概率分布列：考虑突变点

* 3. 若 $F(x)=\sum_{k=1}^{\infty} p_k H(x-x_k)$，则 F(x) 是离散的．$H(x)=I_{[0,+\infty)}(x)$

即 F(x) 斜率存在时为 0

4. 连续型随机变量的 F(x)：

若 X 是连续型随机变量，已知 f(x)，则 $F(x)=P(X\le x)=\int_{-\infty}^{x} f(t)dt$ $(x\in\mathbb{R})$

性质：F(x) 是连续函数，且有 $f(x)=F'(x)$，称 F(x) 是 f(x) 的分布函数．

No.

Date · ·

例：标准正态分布的分布函数 $X\sim N(0,1)$

$\Phi(x)=\int_{-\infty}^{x}\varphi(x)dx=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$

$\varphi(t)$ 关于 $x=0$ 对称，则一定有 $\Phi(x)+\Phi(-x)=1$

对一般的正态分布，$X\sim N(\mu,\sigma^2)$，有

$P(X\le a)=\int_{-\infty}^{a}\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$ 令 $y=[\frac{1}{\sqrt{2}\sigma}(x-\mu)]$

$(=\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{a}e\,dx$ $(P(X\le a)=\frac{1}{\sqrt{\pi}}\cdot\int dx$

$P(X\le a)=\frac{1}{\sqrt{\pi}}\cdot\int_{-\infty}^{\frac{a-\mu}{\sqrt{2}\sigma}}e$

$P(X\le a)=\int_{-\infty}^{a}\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$，令 $y=\frac{x-\mu}{\sigma}$（向 $N(0,1)$ 靠近）

$=\frac{1}{\sqrt{2\pi}}\cdot\int_{-\infty}^{\frac{a-\mu}{\sigma}}e^{-\frac{y^2}{2}}dy$

$=\Phi(\frac{a-\mu}{\sigma})$

3σ 原则：$P(|X-\mu|\le 3\sigma)=P(\mu-3\sigma\le X\le\mu+3\sigma)=\Phi(3)-\Phi(-3)=2\Phi(3)-1=99.73\%$

使产品 X 落在 $(\mu-3\sigma,\mu+3\sigma)$ 区间内，降低 σ 的值，使 99.73% 的产品是合格品。

对于固定正态分布的实际情形，要使 3σ 范围内的产品是合格品（固定范围），则要降低 σ

例：几何随机变量与指数随机变量的关系

①若 $X_1\sim G(p)$，则 $F_1(x)=P(X_1\le x)=\int dx$ 记 $n=[x]$，

则 $F_1(x)=P(X_1\le n)=\sum_{k=1}^{n}P(1-P)^{k-1}=1-(1-P)^n$

②若 $X_2\sim e(\lambda)$，则 $F_2(x)=P(X_2\le x)=\int_{-\infty}^{x}\lambda e^{-\lambda x}dx=1-e^{-\lambda x}$

③（设 $\delta=-\frac{\ln(1-p)}{\lambda}$ $\therefore e^{-\lambda\delta}=1-p$，有 $F_1(n)=F_2(n\delta)$）

当 $F_1(x)=F_2(x)$ 时，有 $\frac{x}{n}=-\frac{\ln(1-p)}{\lambda}$ F Const，代入 $e^{-\lambda x}=(1-p)^n$，说明两者含义一致（关于 x 的等价）

即若 $e^{-\lambda x}=(1-p)^n$，一定有 $F_1(x)=F_2(x)$，说明它者是一次（当 $x=\delta n$，当 n 可视为连续时，时齐模型为指数随机分布。

③ 设 $\delta=-\frac{\ln(1-p)}{\lambda}$ 则 $e^{-\lambda\delta}=1-p$ 有 $F_1(n)=F_2(n\delta)$ $\delta X_1\sim X_2$

（$x=n\delta$，x：第 x 次发生，n：第 n 次发生，δ 相差一个比例系数，两者有关联）

KOKUYO

No.

Date

例：抛硬币，正得0.5；反转转盘，得0~1元均匀分布金额，设X为奖金，问F(x)=？

$$F(x)=\begin{cases}0 & x\le 0\\ 0.5x & 0<x<0.5\\ 0.75 & x=0.5\\ 0.5x+0.5 & x>0.5,x<1\\ 1 & x\ge 1\end{cases}$$

5. F(x)的性质：① F(x)单调非降 ② F(x)右连续 ③若F不连续，X必为非连续；若F连续，X不一定为连续随机变量.

6. F(x)的断解：间断点为不连续变量引起
F(x)若有导函数且连续，则在此段上由连续变量引起，且$F'(x)=f(x)$

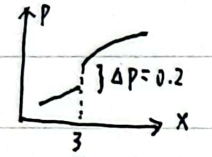

则 $P(X=3)=0.2$

当$X\ge 3$时是连续的X变量，有f(x)存在.

7. 随机变量函数的分布

若g(x)是连续函数，已知$Y=g(x)$，$f(x)$，求Y的密度函数$h(y)$.

$\left(F_Y(y)=\int_{-\infty}^{+\infty} g(x)f(x)dx\right)_x$ $F_Y(y)=P(Y\le y)=P(g(x)\le y)=P(x\in B)=\int_B f(x)dx$

$h(y)=[F_Y(y)]'$

密度函数是分布函数的导数，对于变量函数，给定的是集合间的复杂关系，因此只能从分布函数入手.

对于y的分布函数，仿照离散型的做法，求解$g(x)\le y$得到关系式.

例：设$X\sim N(\mu,\sigma^2)$，证明$Y=\frac{X-\mu}{\sigma}\sim N(0,1)$.

求y的密度函数→分布函数→以y作参数求解x→得到分布函数.

例：设$X\sim N(0,1)$，求$Y=X^2$的$f(y)$.

(牢记连续型变量的分布函数定义) $F_Y(y)=P(X^2\le y)=P(-\sqrt{y}<X<\sqrt{y})=2\Phi(\sqrt{y})-1$

$f(y)=(F_Y(y))'=(2\Phi(\sqrt{y})-1)'=2\varphi(\sqrt{y})\cdot\frac{1}{2}\cdot\frac{1}{\sqrt{y}}=\frac{1}{\sqrt{y}}\varphi(\sqrt{y})=\frac{1}{\sqrt{y}}\cdot\frac{1}{\sqrt{2\pi}}\cdot e^{-\frac{y}{2}}=\frac{1}{\sqrt{2\pi y}}e^{-\frac{y}{2}}$

技巧：对于随机自变量为N分布的 ① $\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$ $\Phi(x)=\int_{-\infty}^{x}\varphi(t)dt$ 若$X\sim N(\mu,\sigma^2)$，则

$P(X\le a)=\Phi\left(\frac{a-\mu}{\sigma}\right)$ $a-\mu$：x=a到中心的距离，σ：比例修正因子

② 对于自变量为正态分布的函数，若求其密度，要利用$\int_B f(x)dx$；实际上最后还要对其求导，更好利用φ与Φ函数求解，且易查表.

③ 若求$F_X(x)=\int_{-\infty}^{x}\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$，实际上不好积分出来，要写为$\Phi(x)$的形式，$F_X(x)=\Phi\left(\frac{x-\mu}{\sigma}\right)$

No.

Date

第9讲 随机变量函数的求解，随机向量的分布及概率密度

一. 随机变量函数密度的求解

1. 普适方法：若 $Y=g(X)$，且 X 有概率密度 $f(x)$，则 Y 的密度函数求解法为：

$$\begin{pmatrix}① & F_X(x)=\int_{-\infty}^{x} f(x)\,dx \\ ② & \end{pmatrix}_X \quad \begin{pmatrix}① & F_Y(y)=\int_{\{x:g(x)\le y\}} g(x)f(x)\,dx \\ ② & \end{pmatrix}_X$$

① $F_Y(y)=\int_{\{x:g(x)\le y\}} f(x)\,dx$ → 技巧：不用积出来，下一步会再回去。

② $f_Y(y)=[F_Y(y)]'$

理解：求解随机变量函数的概率要求到能体现概率关系的量：分布函数，注意分布函数之间连的关系。即是基本事件，本质为基本事件 $g(x)\le y$ 的求解。

2. 线性变换结论：若 $Y=aX+b$，则 $f_Y(y)=\frac{1}{|a|}f_X\left(\frac{y-b}{a}\right)$ （对坐标轴的线性变换）

证明：$F_Y(y)=\int_{-\infty}^{\frac{y-b}{a}} f_X(x)\,dx$ $(a>0)$ 或 $-\int_{-\infty}^{\frac{y-b}{a}} f_X(x)\,dx$ $(a<0)$

则 $f_Y(y)=\frac{1}{|a|}\cdot f_X\left(\frac{y-b}{a}\right)$

理解：线性变换不改变空间的均匀性，若要求 $f_Y(y)$，即往回找寻原图形的位置 $\frac{y-b}{a}$，注意坐标轴伸缩对微元面积的影响，对 y_0，$x_0=\frac{y-b}{a}$，对 Δy，$\Delta x=\frac{\Delta y}{a}$，即要乘以系数 $\frac{1}{|a|}$（恒为正）。

注意与正态分布的区别：若 $X\sim N(\mu,\sigma^2)$，则 $P(X\le a)=\Phi\left(\frac{a-\mu}{\sigma}\right)$，此处无系数 $\frac{1}{\sigma}$，是因为 Φ 是标准分布函数，与 σ_X 无关。

例：$r>0$，且 $X\sim U(0,2\pi)$，求 $Y=r\cos X$ 的概率密度

解：设 $r\cos X\le y$ $\therefore \cos X\le\frac{y}{r}$ $\therefore X\in[\arccos\frac{y}{r},\pi]\cup[\pi,2\pi-\arccos\frac{y}{r}]$

注意：求解反三角函数时，小心 $y=\arccos x$ 的定义域为 $[0,\pi]$，$\arccos x$ 中的 x 是 $[0,\pi]$ 内变化的。若求解在 $y=\cos x$ 中求解 x 时不在 $[0,\pi]$，则要利用平移关系，用 $\arccos x_0$ 的形式表示解。

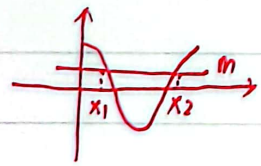

$x_1=\arccos m$

$x_1+x_2=2\pi \Rightarrow x_2=2\pi-\arccos m$ 要小心 $\arccos x$ 的有意义取值范围。

$\therefore P_Y(y)=P(Y\le y)=P(r\cos X\le y)=\int_{\arccos\frac{y}{r}}^{2\pi-\arccos\frac{y}{r}}\frac{1}{2\pi}\,dx$

则 $f_Y(y)=\frac{1}{2\pi}\cdot\left[\frac{1}{\sqrt{1-\frac{y^2}{r^2}}}\cdot\frac{1}{r}+\frac{1}{\sqrt{1-\frac{y^2}{r^2}}}\cdot\frac{1}{r}\right]=\frac{1}{2\pi}\cdot 2\cdot\frac{1}{\sqrt{r^2-y^2}}=\frac{1}{\pi\sqrt{r^2-y^2}}$

No.

Date

二. 随机向量及其分布

1. 联合概率分布函数

定义：设 $\vec{x}=(X_1,\dots,X_n)$ 为随机向量，称 $\mathbb{R}^n$ 上的 n 元函数 $F(x_1,\dots,x_n)=P(X_1\le x_1,\dots,X_n\le x_n)$ 为 $\vec{x}$ 的联合概率分布函数，简称分布函数或联合分布。

单个变量的：$F(a)=P(X\le a)$

也记为 $F(\vec{x})=P(\vec{X}\le\vec{x})$

2. 应用：依据 $F(\vec{x})$ 求解特定区间的概率

已知 $F(x,y)$，则 $F(x)=F(x,+\infty)$，$F(y)=F(+\infty,y)$

则 $F(a\le X\le b,\ c\le Y\le d)=F(a\le X\le b,\ Y\le d)-F(a\le X\le b,\ Y\le c)$

$=F(b,d)-F(a,d)-F(b,c)+F(a,c)$

$F(x,y)$：已知区域 $(-\infty,x]\times[-\infty,y]$ 的概率

3. 边缘分布

定义：对 $1\le k<n$，$S_k=\{i_1,i_2,\dots,i_k\}$ 为指标集，称 $X_{S_k}=(X_{i_1},X_{i_2},\dots,X_{i_k})$ 的联合分布

$$F_k(X_{i_1},X_{i_2},\dots,X_{i_k})=P(X_{i1}\le x_{i1},\dots,X_{in}\le x_{in})=P(X_{ij}\le x_{ij},\ j\in S_k,\ X_{it}\le+\infty,\ t\in S_k^c)$$

为 $F(X_1,\dots,X_n)$ 的 k 维边缘分布。

边缘分布：其中某几个变量的分布函数。关键是降维，即让不用的随机变量取 $\mathbb{R}$。对于边缘分布函数，即求多元函数的累次极限（互不相干）

$F(X_1,\dots,X_n)$ 有 2^n-2 个的k边缘分布。

4. 独立性

设 $(X_1,\dots,X_n)$ 有联合分布 $F(X_1,\dots,X_n)$，X_i 有边缘分布 $F_i(X_i)$。则 $X_1,\dots,X_n$ 相互独立当且仅当

$$F(X_1,\dots,X_n)=F(X_1)\cdots F(X_n)$$

No.

Date . .

三. 联合概率密度

1. 连续型随机向量

设 $\vec{x}=(x_1,\dots,x_n)$ 是随机变量，若对 $\mathbb{R}^n$ 中的任一子立方体 $D=\{(x_1,\dots,x_n)\mid a_i\le x_i\le b_i,\ 1\le i\le n\}$，有 $P(\vec{X}\in D)=\int_D f(x_1,\dots,x_n)\,dx_1\cdots dx_n=\int_D f(\vec{x})\,d\vec{x}$，就称 $\vec{x}$ 是连续型随机向量。

对任意 n 维 Borel 集 B 有：$P(\vec{x}\in B)=\int_B f(\vec{x})\,d\vec{x}$

2. 应用：依据 $f(\vec{x})$ 求解特定变量的概率密度

（本质上依然是降维。对连续型密度函数，降维的方法为 $\int_{-\infty}^{+\infty}dx_i$）

设 (X,Y) 有联合密度 $f(x,y)$，则 X 与 Y 分别有概率密度 $\int_{-\infty}^{+\infty}f(x,y)\,dy$、$\int_{-\infty}^{+\infty}f(x,y)\,dx$

（更一般地，设 $f(\vec{x})$ 是 $\vec{x}$ 的概率密度，对 $1\le k<n$，令 $\mathbb{R}^k$ 中的 $\vec{x}_k$

3. 边缘密度

被积函数 $f_k(x_1,\dots,x_k)=\int_{\mathbb{R}^{n-k}}f(x_1,\dots,x_n)\,dx_{k+1}\cdots dx_n$ 是 $(x_1,\dots,x_n)$ 的联合密度，也称为 $\vec{x}$ 的边缘密度。

例：设 (X,Y) 在单位圆 $D=\{(x,y)\mid x^2+y^2\le 1\}$ 中均匀分布，求 X、Y 的概率密度。

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,dy=\int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}}\frac{1}{\pi}\,dy=\frac{2}{\pi}\sqrt{1-x^2}$$

4. 连续型随机向量的独立性

定理：对每个 $i\ (1\le i\le n)$，随机变量 X_i 有概率密度 $f_i(x_i)$，则 $X_1,\dots,X_n$ 相互独立的充分必要条件为随机向量 $\vec{x}=(x_1,\dots,x_n)$ 的联合密度 $f(x_1,\dots,x_n)=f_1(x_1)\cdots f_n(x_n)$

No.

Date

第10讲 二元正态分布

一. 二元正态分布

1. 定义：设 μ_1，μ_2 是常数，σ_1、σ_2 是正常数，$\rho \in (-1,1)$ 中的常数，若随机向量 (X,Y) 有概率密度

$$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}-\frac{2\rho(x-\mu_1)(y-\mu_1)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}$$

则称 (X,Y) 服从二元正态分布，记为 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$

回忆：$X\sim N(\mu,\sigma^2)$：$f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

对于二元联合分布，σ 修正为 $\sigma\sqrt{1-\rho^2}$（当 $\rho=0$，变量间无关）. 对于单独项，$\sigma\to\sigma\sqrt{1-\rho^2}$

对于交叉项，$\sigma\to\frac{\sigma}{\rho}$

$f(x,y)=$ $f(x)=$ $f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

$$f(x,y)=\frac{1}{\sigma_1\sigma_2 2\pi\sqrt{1-\rho^2}}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)}-\frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)}+\frac{(x-\mu_1)(y-\mu_2)\rho}{\sigma_1\sigma_2(1-\rho^2)}}$$

若 $\rho=0$，$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}-\frac{(y-\mu_2)^2}{2\sigma_2^2}}$

简写形式：$f(\vec{x})=\frac{1}{2\pi\sqrt{|\Sigma|}}\exp\left\{-\frac{1}{2}(\vec{x}-\mu)^T\Sigma^{-1}(\vec{x}-\mu)\right\}$　$\vec{x}=\begin{pmatrix}x\\y\end{pmatrix}$，$\mu=\begin{pmatrix}\mu_1\\\mu_2\end{pmatrix}$，$\Sigma=\begin{pmatrix}\sigma_1^2&\rho\sigma_1\sigma_2\\\rho\sigma_1\sigma_2&\sigma_2^2\end{pmatrix}$

$$=\frac{1}{\sqrt{|\Sigma|}2\pi}e^{-\frac{(\vec{x}-\mu)^T\Sigma^{-1}(\vec{x}-\mu)}{2}}\qquad \Sigma=\begin{pmatrix}\sigma_1^2&\rho\sigma_1\sigma_2\\\rho\sigma_1\sigma_2&\sigma_2^2\end{pmatrix}$$

小结：矩阵形式：$f(\vec{x})=\frac{1}{2\pi\sqrt{|\Sigma|}}e^{-\frac{(\vec{x}-\mu)^T\Sigma^{-1}(\vec{x}-\mu)}{2}}$，其中 $\Sigma=\begin{pmatrix}\sigma_1^2&\rho\sigma_1\sigma_2\\\rho\sigma_1\sigma_2&\sigma_2^2\end{pmatrix}$　$|\Sigma|=\sigma_1^2\sigma_2^2-\rho^2\sigma_1^2\sigma_2^2$

$$\Sigma^{-1}=\begin{pmatrix}\frac{1}{\sigma_1^2(1-\rho^2)}&-\frac{\rho}{\sigma_1\sigma_2(1-\rho^2)}\\-\frac{\rho}{\sigma_1\sigma_2(1-\rho^2)}&\frac{1}{\sigma_2^2(1-\rho^2)}\end{pmatrix}$$

一般形式：$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2(1-\rho^2)}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)}-\frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)}+\frac{(x-\mu_1)(y-\mu_2)\rho}{\sigma_1\sigma_2(1-\rho^2)}}$

只有交叉项有正/负相关调制

$\sqrt{1-\rho^2}$ 作为修正因子修正 ρ 以 σ_1、σ_2

2. 概率等高线

$$\text{设 } f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)}-\frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)}+\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2(1-\rho^2)}\rho}=\text{Const}$$

则等高线为 $-\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)}-\frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)}+\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2(1-\rho^2)}\rho=C$

$\xrightarrow{①}\begin{cases}x'=x-\mu_1\\y'=y-\mu_2\end{cases}$　$\frac{x^2}{2\sigma_1^2(1-\rho^2)}+\frac{y^2}{2\sigma_2^2(1-\rho^2)}-\frac{xy\rho}{\sigma_1\sigma_2(1-\rho^2)}=C$　设 $2\sigma_1^2(1-\rho^2)=A$，$2\sigma_2^2(1-\rho^2)=B$，$\sigma_1\sigma_2(1-\rho^2)\cdot\frac{1}{\rho}=C$

$\longrightarrow\frac{x^2}{A}+\frac{y^2}{B}-\frac{xy}{C}=M$　为椭圆

$\xrightarrow{②}\begin{cases}x'=x\cos\alpha+y\sin\alpha\\y'=-x\sin\alpha+y\cos\alpha\end{cases}$　$x'y'=y^2\sin\alpha\cos\alpha-x^2\cos^2\alpha\sin^2\alpha+xy\cos2\alpha$　设 $\cos2\alpha=0$

No.

Date

结论：若 $\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)} - \frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)} + \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2(1-\rho^2)}\rho = c^2$

则

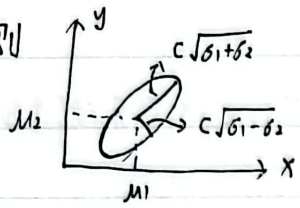

☆概率等高线的矩阵求解法

$f(x,y) = \frac{1}{2\pi|\Sigma|}\cdot e^{-\frac{X^T\Sigma^{-1}X}{2}} = C$，其中 $\Sigma = \begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}$，$\vec{x} = \begin{pmatrix}x\\y\end{pmatrix}$

求等高线 $\Leftrightarrow X^T\Sigma^{-1}X = C$ 画出图形　　$y^Ty = C$ 是圆，化简的最终目标

Σ 为实对称阵，其逆不容易求解。(假设 $\sigma_1 = \sigma_2 = \sigma$

$\Sigma = \sigma^2\begin{pmatrix}1 & \rho\\ \rho & 1\end{pmatrix}$ 要用谱分解求逆。

特征值：$A\vec{x} = \lambda\vec{x} \Leftrightarrow (A-\lambda I)\vec{x} = \vec{0}$ 非零解 $\Leftrightarrow |A-\lambda I| = 0$ (方程(无逆)

$\begin{vmatrix}1-\lambda & \rho\\ \rho & 1-\lambda\end{vmatrix} = (1-\lambda)^2-\rho^2 = 0 \Rightarrow 1-\lambda = \pm\rho$，$\lambda = 1\pm\rho$

$\lambda = 1-\rho$ $\begin{pmatrix}\rho & \rho\\ \rho & \rho\end{pmatrix}\vec{x} = \vec{0}$ 设 $\vec{x} = \begin{pmatrix}x\\y\end{pmatrix}$，有 $x=y$ $\therefore \vec{x}_1 = \begin{pmatrix}\frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2}\end{pmatrix}$

$\lambda = 1+\rho$ $\begin{pmatrix}-\rho & \rho\\ \rho & -\rho\end{pmatrix}\vec{x} = \vec{0}$ $\therefore \vec{x}_2 = \begin{pmatrix}\frac{\sqrt{2}}{2}\\ -\frac{\sqrt{2}}{2}\end{pmatrix}$

$\therefore A\cdot\begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix} = A\begin{pmatrix}1-\rho & \\ & 1+\rho\end{pmatrix}$　　$\therefore A\cdot\begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix} = \begin{pmatrix}1-\rho & \\ & 1+\rho\end{pmatrix}\begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix}$

$\therefore A\cdot(\vec{x}_1,\vec{x}_2) = (\lambda_1\vec{x}_1, \lambda_2\vec{x}_2) = (\vec{x}_1,\vec{x}_2)\begin{pmatrix}\lambda_1 & \\ & \lambda_2\end{pmatrix}$

$\therefore A = (\vec{x}_1,\vec{x}_2)\begin{pmatrix}\lambda_1 & \\ & \lambda_2\end{pmatrix}(\vec{x}_1,\vec{x}_2)^T = \begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix}\begin{pmatrix}1-\rho & \\ & 1+\rho\end{pmatrix}\begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix} = P\Lambda P^T$

$\therefore \vec{x}^T\cdot\Sigma^{-1}\cdot\vec{x} = \vec{x}^T\cdot\sigma^{-2}\cdot P\Lambda^{-1}P^T\cdot\vec{x} = \sigma^{-2}\cdot\vec{x}^T P\Lambda^{-\frac{1}{2}}\cdot\Lambda^{-\frac{1}{2}}P^T\vec{x}$

$\therefore \Lambda^{-\frac{1}{2}}P^T\vec{x} = \vec{y}$ 为圆方程　$\Lambda^{\frac{1}{2}}\vec{y}$　$P\Lambda^{\frac{1}{2}}\vec{y} = \vec{x}$

$\Lambda^{\frac{1}{2}} = \begin{pmatrix}\frac{1}{\sqrt{1-\rho}} & \\ & \frac{1}{\sqrt{1+\rho}}\end{pmatrix}\cdot\begin{pmatrix}\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}\\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2}\end{pmatrix}\begin{pmatrix}x\\y\end{pmatrix} = \begin{pmatrix}m\\n\end{pmatrix}$

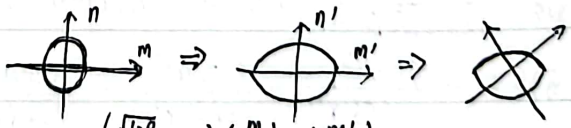

$\begin{pmatrix}\sqrt{1-\rho} & \\ & \sqrt{1+\rho}\end{pmatrix}\begin{pmatrix}m\\n\end{pmatrix} = \begin{pmatrix}m'\\n'\end{pmatrix}$

$m' = m\sqrt{1-\rho}$

No.

Date . .

椭圆长轴长：$\sqrt{c(1+\rho)}$ 短轴长：$\sqrt{c(1-\rho)}$

随着ρ↗，相关性↗，等高椭圆越来接近于"线"，$\frac{长}{短}$↗

定理：设$(X,Y)\sim N(\mu_1,\mu_2,\sigma_1,\sigma_2,\rho)$，则X与Y无关的充分必要性条件是$\rho=0$

KOKUYO

No.

Date

第10讲 联合分布与联合密度(条件、边缘)、随机向量函数

一. 联合分布与联合密度

已知联合密度 $f(x,y)$, 求 $F(x,y)$: $F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y} f(u,v)\,du\,dv$

已知 $F(x,y)$, 求 $f(x,y)$: $f(x,y)=\dfrac{\partial^2 F(x,y)}{\partial x\partial y}$

理解: 联合分布函数的 X与Y: 在由 $f(x)$ 与 $f(y)$ 求 $f(x,y)$ 过程中, 不论 X与Y是否有关联, $f(x,y)$ 是去掉相关性后得到的结论, X与Y一定互不关联, 即使 X与Y有关联, $f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy$ 成立.

$f_X(x)$ 的理解: 将事件概率与X连系在一起, 具体体现为, X的值代表事件, 而事件的概率计算由"密度"的积分算法决定, 即 $P(x_1\le X\le x_2)=\int_{x_1}^{x_2} f_X(x)\,dx$, 牢记区间 x_1 与 x_2 之间 X的值就为 $f(x)$ 的定义域.

二. 条件分布函数、密度函数

1. 定义: (离散型: $P(X|Y)=\dfrac{P(XY)}{P(Y)}$, $P(X=x_i|Y=y_j)=\dfrac{P(X=x_i\text{且}Y=y_j)}{P(Y=y_j)}$)

连续型: $P(X\le x|Y=y)$, 在y的条件下求X的分布关系.

理解: 抓住条件概率中约束条件 $Y=y$ 的含义, 等价于主动将概率空间变为一维的进行考虑

$$P(X\le x|Y=y)=\int_{-\infty}^{x}\frac{f(\quad)}{f_Y(y)}$$

定义: 设 (X,Y) 有联合密度 $f(x,y)$, Y有边缘密度 $f_Y(y)$, 称 $P(X\le x|Y=y)=\dfrac{\int_{-\infty}^{x} f(s,y)\,ds}{f_Y(y)}$ $(x\in\mathbb{R})$ 为给定条件 $Y=y$ 下, X的条件分布函数, 简称条件分布, 记作 $F_{X|Y}(x|y)$

$$F_{X|Y}(x|y_0)=P(X\le x|Y=y_0)=\frac{\int_{-\infty}^{x} f(s,y_0)\,ds}{f_Y(y_0)}=\frac{\int_{-\infty}^{x} f(s,y_0)\,ds}{\int_{-\infty}^{+\infty} f(x,y_0)\,dx}$$

称 $f_{X|Y}(x|y_0)=\dfrac{f(x,y_0)}{f_Y(y_0)}=\dfrac{f(x,y_0)}{\int_{-\infty}^{+\infty} f(x,y_0)\,dx}$ 为给定条件 $Y=y_0$ 下, X的条件密度.

[反过来] $f_{Y|X}(a|b)=\dfrac{f(a,b)}{f_X(b)}=\dfrac{f(a,b)}{\int_{-\infty}^{+\infty} f(b,s)\,ds}$, 显然 $\int_{\mathbb{R}}\dfrac{f(a,b)}{f_X(b)}\,da=1$

2. 条件密度与条件分布的关系:

$$F_{X|Y}(x,y)=P(X\le x,Y=y)=\int_{-\infty}^{x} f_{X|Y}(s,y)\,ds=\frac{\int_{-\infty}^{x} f(s,y)\,ds}{\int_{-\infty}^{+\infty} f(x,y)\,dx}$$

若 $F_{X|Y}(x,y)$ 关于X连续, 且导数连续, 则 $f_{X|Y}(x,y)=\begin{cases}F'_{X|Y}(x,y) & \text{偏导存在}\\ 0 & \text{其它}\end{cases}$

X与Y独立的充要条件: $F_{X|Y}(x,y)=F_X(x)\Leftrightarrow f(x,y)=f(x)\cdot f(y)$

KOKUYO

No.

Date

例1. 设 $(X,Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 求 $X=X$ 下 Y 的条件密度.

解: $f(x,y) = \frac{1}{\sigma_1 \sigma_2 2\pi\sqrt{1-\rho^2}} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2(1-\rho^2)} - \frac{(y-\mu_2)^2}{2\sigma_2^2(1-\rho^2)} + \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2(1-\rho^2)}\rho}$

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)} = \frac{f(x,y)}{\int_{-\infty}^{+\infty} f(x,y)dy}$$

※结论: 若 $(X,Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则 X 边缘分布: $X \sim N(\mu_1, \sigma_1^2)$, Y 的边缘分布 $Y \sim N(\mu_2, \sigma_2^2)$

因为 ρ 是联合关系的体现, 各自参量就为 μ, σ^2

$$= \frac{1}{\sigma_2\sqrt{2\pi(1-\rho^2)}} e^{-\frac{(y-\mu_X)^2}{2(1-\rho^2)\sigma_2^2}}, \text{ 其中 } \mu_X = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x-\mu_1)$$

说明 $Y|_{X=x} \sim N\left(\mu_2 + \rho\frac{\sigma_1}{\sigma_2}(x-\mu_1), \sigma_2^2(1-\rho^2)\right)$

技巧: 对 $\int_{-\infty}^{+\infty} e^{-\frac{(x-a)^2}{b}} dx$ 积分求解时, 运用 N 分布结论. 设 $X \sim N(a, \frac{b}{2})$,

则 $\int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi b}} \cdot e^{-\frac{(x-a)^2}{b}} dx = 1$

若 X 与 Y 独立, $\rho=0$, 则 $f_{Y|X}(y|x) = f_Y(y)$

例2. 设 $Y \sim \Gamma(\alpha, \beta)$, 概率密度为 $f_Y(y) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$ $(y>0)$. 当 $Y=y$ 时, $(X|Y=y) \sim \varepsilon(y)$. 求 X 的分布?

解: $(X|Y=y) \sim \varepsilon(y) \Rightarrow f_{X|Y}(x|y) = y e^{-yx} \Rightarrow \frac{f(x,y)}{f_Y(y)} = y e^{-yx}$ $(x>0)$

$\therefore f(x,y) = y e^{-xy} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$

补充: Γ 函数. 用于解决多项式与 $e^{-\lambda x}$ 积分反复分布的问题.

定义: $\boxed{\Gamma(\alpha) = \int_0^\infty t^\alpha e^{-t} dt}$ $\Gamma(\alpha) = \int_0^{+\infty} t^{\alpha-1} e^{-t} dt$ $(\alpha>0)$

递推性质: $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt = -\int_0^\infty t^{\alpha-1} de^{-t} = \int_0^\infty e^{-t} dt^{\alpha-1} = (\alpha-1)\cdot\int_0^\infty t^{\alpha-2} e^{-t} dt = (\alpha-1)\Gamma(\alpha-1)$

$\boxed{\therefore \Gamma(\alpha) = \Gamma!}$ $\therefore \Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1)$

$\therefore f_X(x) = \int_0^{+\infty} f(x,y)dy = \boxed{y e^{-}}^{\prime} \int_0^{+\infty} y^\alpha \cdot e^{-\beta y} \cdot e^{-xy} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} dy = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \int_0^{+\infty} y^\alpha \cdot e^{-y(\beta+x)} dy$

$= \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{(x+\beta)^{\alpha+1}} \cdot \int_0^\infty t^\alpha e^{-t} dt = \frac{\beta^\alpha}{(x+\beta)^{\alpha+1}} \cdot \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} = \frac{\alpha\beta^\alpha}{(x+\beta)^{\alpha+1}}$ $(x>0)$

No.

Date

随机向量的函数

1. 已知 $f(x,y)$，求 $Z=g(X,Y)$ 的概率密度函数？

对于单变量的密度函数，避免"求导"微分关系寻找，可先求分布函数。

$f(x,y)$ 定义 X 与 Y 的取值，$Z=g(X,Y)$ 将 Z 的取值与 $g(X,Y)$ 联系起来。

通用做法：$F_Z(z)=P(Z\le z)=P(g(X,Y)\le z)=\iint_D f(x,y)\,dxdy$ 其中 $D:\{(x,y)\mid g(x,y)\le z\}$.

$$f_Z(z)=\frac{dF_Z(z)}{dz}$$

2. 例：设 (X,Y) 为单位正方形 $(0,1)\times(0,1)$ 的均匀分布，有联合密度 $f(x,y)$，可验证 (X,Y) 独立，求 $Z=g(X,Y)=\frac{Y}{X}$ 的密度函数？

解：$F_Z(z)=P(\frac{Y}{X}\le z)=P(Y\le zX)=\int_{y\le zx} f(x,y)\,dxdy$.

3. 例：Rayleigh 分布：设 (X,Y) 独立且服从 $N(0,1)$，求 $Z=\sqrt{X^2+Y^2}$ 的分布.

$$F_Z(z)=\int_{\sqrt{x^2+y^2}\le z} f(x,y)\,dxdy=z\,e^{-\frac{z^2}{2}}$$

4. 特殊情形：考虑 $Z=X+Y$ $(X_1+X_2+\cdots+X_n)$

设 (X,Y) 有联合密度 $f(x,y)$，则 $Z=X+Y$ 有密度函数 $f_Z(z)=\int_{-\infty}^{\infty} f(x,z-x)\,dx$ (注意 x 范围)

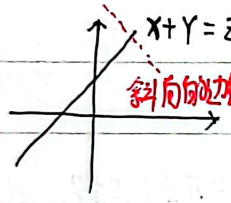

理解：$f_Z(z_0)$ 指满足 $X+Y=z_0$ 的所有点列概率叠加

求 f_Z 函数类似于曲线积分.

$$f_Z(z_0)=\int^{+\infty} f_Z(z_0)=P(X+Y=z_0)=\int_{-\infty}^{+\infty} f(x,z_0-x)\,dx$$

推广：($Z=aX+bY$ 有联合密度，$Z=aX+bY+c$ 有密度 $f_Z(z_0)=$"$P(aX+bY+c=z_0)$"$=\int_{-\infty}^{+\infty} f(x,\frac{z_0-c-ax}{b})\,dx$

证 $F_Z(z_0)=P(aX+bY+c\le z_0)=\iint_D f(x,y)\,dxdy=\int_{-\infty}^{+\infty}\int_{-\infty}^{\frac{z_0-c-ax}{b}} f(x,y)\,dxdy$

$\because Y=\frac{z-c-ax}{b}$ $\therefore F_Z(z_0)=\int_{-\infty}^{+\infty}\int_{-\infty}^{\frac{z_0-c-ax}{b}} f(x,\frac{z-c-ax}{b})\,dx\,d\frac{z-c-ax}{b}$

$$=\int_{-\infty}^{+\infty}\left(\int_{-\infty}^{\frac{z_0-c-ax}{b}}\right)$$

$$=\int_{-\infty}^{\frac{z_0-c-ax}{b}}\left[\int_{-\infty}^{+\infty} f(x,\frac{z-c-ax}{b})\,dx\right]d\frac{z-c-ax}{b}=\int$$

$Z=X-Y$ 有密度函数 $f_Z(z)=\int_{-\infty}^{+\infty} f(x,x-z)\,dx$

只针对 $X+Y$，$X-Y$ 有斜向边缘分布的简化算法.

例：设 X,Y 独立 $\sim U(0,1)$，求 $Z=X+Y$ 的 $f_Z(z_0)$？

解：$f_Z(z_0)=\int_{-\infty}^{+\infty} f(x,z_0-x)\,dx=\int_0^1 f$ $\because f(x,y)=f(x)\cdot f(y)=1$ $(x,y\in(0,1))$

$=\int_0^1 1\,dx=1$ (x) 未考虑到 $y=z_0-x$ 的范围. (设 $0<z_0-x<1\Rightarrow 1-z_0<x<z_0$)

$\begin{cases}0<x<1\\ 0<z_0-x<1\Rightarrow z_0-1<x<z_0\end{cases}$ 此方法并不好.

(若 $z_0<0$，$f_Z(z_0)=0$ 若 $0<z_0<1$，$f_Z(z_0)=\int_0^{z_0}1\,dx=z_0$ 若 $1<z_0<2$，$f_Z(z_0)=\int_{1-z_0}^{1}1\,dx=z_0-2$)

KOKUYO

No.

Date

用积分二重：$F_Z(z)=P(X+Y\le z)$ 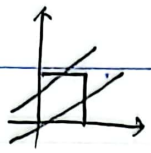 简单情况下 V

5. 从 (X,Y) 到 (U,V)

定理：设 $U=u(X,Y)$，$V=v(X,Y)$，D区域满足 $P((U,V)\in D)=1$，若D上函数 $X_i=x_i(U,V)$，$Y_i=y_i(U,V)$，$i=1,\dots,n$

使得：① $(U,V)\in D$，有 $\{U=u,V=v\}=\bigcup_{i=1}^{n}\{X=x_i,Y=y_i\}$，

② Δ_i：$\begin{cases}X_i=x_i(U,V)\\Y_i=y_i(U,V)\end{cases}$ 是D的可逆映射，即存在连续偏导数，且 $\left|\frac{\partial(x_i,y_i)}{\partial(u,v)}\right|\neq 0$，$(U,V)\in D$（$i=1,\dots,n$）

③ $i=1,\dots,n$ 时 $D_1,\dots,D_n$ 不相交

则 (U,V) 有联合密度 $g(U,V)=\begin{cases}\sum_{i=1}^{n} f(x_i(u,v),y_i(u,v))\cdot\left|\frac{\partial(x_i,y_i)}{\partial(u,v)}\right| & (U,V)\in D\\ 0 & (U,V)\in D^c\end{cases}$

理解：对于可逆映射 $\begin{cases}U=u(X,Y)\\V=v(X,Y)\end{cases}$，（可逆：在整个区域内 $\left|\begin{matrix}\frac{\partial u}{\partial x} & \frac{\partial u}{\partial y}\\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y}\end{matrix}\right|\neq 0$），若已知 $f(x,y)$，则求解 U,V 的密度函数 $g(u,v)$ 方法为：

① 对于 u,v，求解 x,y．② $dudv=A\,dxdy$，③ 其中 $A=\left|\det\begin{pmatrix}\frac{\partial u}{\partial x} & \frac{\partial u}{\partial y}\\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y}\end{pmatrix}\right|$

③ 则 $g(u,v)\cdot A=f(x,y)$（可理解为归一化）

回忆：对于 $y=ax+b$ 变换，$dy=a\,dx$ $\therefore f_Y(y)|a|=f_X\left(\frac{y-b}{a}\right)$

小结：对于求解函数向量的密度：

① 对于最终仅一个变量的情形，用分布函数（避开微分讨论，有时微分非可逆）求解，

注意密度函数的定义域定义：将定义域与随机变量值对应起来

② 对于可逆映射，用 Jacobi 矩阵，找出判别可逆区域，画好图后求出反函数，最后由归一化列出等式，

③ 对于降维映射，用分布函数求解．设 $\begin{cases}X=x(u,v,w)\\Y=y(u,v,w)\end{cases}$ 则 $F(x,y)=P(x(u,v,w)\le x,y(u,v,w)\le y)$，判分 u,v,w 上的区域 D_1,D_2，在 D_1,D_2 内用密度函数积分三重，最后求偏导．

例：设 X,Y 独立，且 $X\sim N(0,1)$，$Y\sim(0,1)$．(R,Θ) 由极坐标变换 $\begin{cases}X=R\cos\Theta\\Y=R\sin\Theta\end{cases}$ 给出，求 (R,Θ) 联合密度．

解：$\left.\begin{matrix}dx\,dy=R\,dR\,d\Theta\\ f(x,y)\text{ 已知}\\ \text{可逆}\end{matrix}\right\}$ $g(R,\Theta)=f(R\cos\Theta,R\sin\Theta)\cdot R=\frac{1}{2\pi}\cdot r e^{-\frac{r^2}{2}}$

（设 $dR\,d\Theta=1$，则 $dx\,dy=R$）

R 的分布函数：$F_R(R)=P(R\le r)$ $F_R(r)=F_R(R\le r)=F_R(\sqrt{x^2+y^2}\le r)$

例：设 U,V 独立，$V,U\sim U(0,1)$，定义 $\begin{cases}X=\sqrt{-2\ln U}\cos(2\pi V)\\Y=\sqrt{-2\ln U}\sin(2\pi V)\end{cases}$，则 X,Y 独立，且服从 $N(0,1)$？

No.

Date

第11讲 次序统计量、随机变量的期望与方差、标准化、重要不等式、协方差

一. 次序统计量

1. 定义：设 $X_1, X_2, \dots, X_n$ 是随机变量. 对 $w \in \Omega$，将 $X_1(w), X_2(w), \dots, X_n(w)$ 从小到大排列得到 $X_{(1)}(w) \le X_{(2)}(w) \le \cdots \le X_{(n)}(w)$，称 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 为 $X_1, X_2, \dots, X_n$ 的次序统计量.

例：$\Omega = (0,1)$，设 $X_1(w) = 1-w$ $X_2(w) = w$

则 $X_{(1)}(w) = \begin{cases} w & w \in (0, 0.5] \\ 1-w & w \in (0.5, 1) \end{cases}$

理解：对于 $X_1, \dots, X_n$，其次序统计量是对任意 $w \in \Omega$ 都成立的. 自然地，$X_{(1)}$ 的定义不会发生改变.

性质：设 $X_1, \dots, X_n$ 是独立同分布（即有公共的分布函数 $F(x)$ 与密度函数 $f(x)$），则 $(X_{(1)}, \dots, X_{(n)})$ 的联合分布 $F_n(x_1, \dots, x_n)$ 是连续的.

理解：独立同分布：适用于多个相同但独立的实际事件，它们自个本身有分布 $f(x)$. 对于 $X_{(n)}$（最小值），其定义域是 n 维向量，与原随机变量 X_i 相同，只是说对一个任意的 n 维向量，找出最小 $X_i(w)$ 作为 $X_{(1)}$

对于具有公共变量的 $X_1, \dots, X_n$，可以简洁地写出自个变量表示的表达式.

对于具有 n 维独立变量的 $X_1, \dots, X_n$，不能写出表达式，直接把 $X_{(1)}$ 视为一组 n 维定义域下的最小变量值函数即可

结论1. 对于 $-\infty \le a < x_1 < \cdots < x_k < b \le \infty$，有 $\int_{a<x_1<\cdots<x_k<b} f_1(x_1)\cdots f_k(x_k)\,dx_1\cdots dx_k = \frac{[F(b)-F(a)]^k}{k!}$，

其中 $f_i(x)$ 是 $X_{(i)}(w)$ 的密度函数，$F(x)$ 是 $X_{(i)}(w)$ 的分布函数.

理解：$x_1 < x_2 < \cdots < x_k$ 是 $X_{(i)}(w)$ 有概率的前提条件. 对于 $X_{(1)}, \dots, X_{(n)}$ 都等于一个 n 维的特定值.

有 k! 种实际情况，则 (A)k，而自种基本情况是等可能的. 若 $F(\vec{x}) = \int \vec{f}(\vec{x})\,dx_n$，$F(\vec{x})$ 代表总的可能概率

则 $n!\int_{a<x_1<x_2<\cdots<x_n<b} f(x_1)\cdots f(x_n)\,dx_1\cdots dx_n = F(b)-F(a)$

对于自种基本情况（分面之后），概率为 $[F(b)-F(a)]^k$，则 $k!\cdot\int_{a<x_1<\cdots<x_k<b} f(x_1)\cdots f(x_k)\,dx_1\cdots dx_k = [F(b)-F(a)]^k$

结论1. 对于独立同分布的 $X_1, \dots, X_n$，设密度函数为 $f(x)$，分布函数为 $F(x)$，

则 $\int_{a<x_1<\cdots<x_n<b} f(x_1)\cdots f(x_n)\,dx_1\cdots dx_n = \frac{[F(b)-F(a)]^n}{n!}$

理解：$a<x_1<\cdots<x_n<b$ 是 $X_1, \dots, X_n$ 取值的一种特殊排列，若无序，则积分为 $[F(b)-F(a)]^n$，特定排列概率重除以 $A_n^n = n!$

方用：对于 $a<x_1<\cdots<x_n<b$ 而言，积分区域与前一个变量均有关，考虑将其变为无关的情况，$\begin{cases} a<x_1<b \\ \vdots \\ a<x_n<b \end{cases}$，取其中一种排序即可.

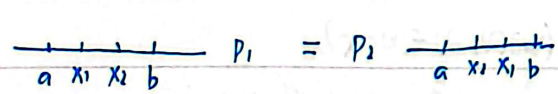

因此可以解除 x 之间的相互作用.

No.

Date . .

结论2. $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 有联合密度

$$g(x_1, x_2, \dots, x_n) = \begin{cases} n!\, f(x_1)\cdots f(x_n) & x_1 < x_2 < \cdots < x_n \\ 0 & \text{其他} \end{cases}$$

理解：若 $x_1, x_2, \dots, x_n$ 是独立且等可能的，则最小值取 x_1，第二小值取 x_2 … 最大值取 x_n 有 $A_n^n = n!$ 种分配次序方式（分配的基础：独立），且不同分配方式概率算可能，因此为 $n!\, f(x_1)\cdots f(x_n)$.

结论3. $X_{(k)}$ 有密度 $g_k(x_k) = n \cdot C_{n-1}^{k-1} f(x_k) \cdot [F(x_k)]^{k-1} [1-F(x_k)]^{n-k}$

$(g_k(x_k) = n \cdot f(x_k) \cdot A)$ 理解：唯一限制条件是第 k 小的变量取值为 x_k.

对于互不相干的坐标轴，其余变量要满足 $x_1 < x_2 < \cdots < x_k < \cdots < x_n$ 即可，

$X_k = x_k$ 概率为 $n \cdot f(x_k)$　　$X_1 < X_2 < \cdots < X_{k-1} < x_k$ 概率为 $\dfrac{[F(x_k)]^{k-1}}{(k-1)!} \cdot A_{n-k}^{k-1}$

$X_k < X_{k+1} < \cdots < X_n$ 概率为

$X_k = x_k$ 概率为 $n f(x_k)$，有 $(k-1)$ 个变量小于 x_k 概率为 $C_{n-1}^{k-1} [F(x_k)]^{k-1}$，

有 $(n-k)$ 个变量大于 x_k 的概率为 $[1-P(x_k)]^{n-k}$

$\therefore g_k(a) = n \cdot f(a) \cdot C_{n-1}^{k-1} [F(a)]^{k-1} \cdot [1-F(a)]^{n-k}$　（独立变量（坐标轴上每个往复）都可用曲线积分）

结论4. 对 $k_1 < k_2$，$(X_{(k_1)}, X_{(k_2)})$ 有联合密度

$$g(x_{k_1}, x_{k_2}) = \frac{n!}{(k_1-1)!\,(k_2-k_1-1)!\,(n-k_2)!} \cdot [F(x_{k_1})]^{k-1} [F(x_{k_2}) - F(x_{k_1})]^{k_2-k_1-1} \cdot [1-F(x_{k_2})]^{n-k_2} f(x_{k_1}) \cdot f(x_{k_2})$$

$g(x_{k_1}) \cdot g_{x_{k_1}, x_{k_2}}(a,b) = n \cdot A_n^2 \cdot f(a) \cdot f(b) \cdot C_{n-2}^{k_1-1} [F(a)]^{k_1-1} \cdot C_{n-k_1-1}^{k_2-k_1-1} [F(b)-F(a)]^{k_2-k_1-1} \cdot [1-F(b)]^{n-k_2}$

$A_n^2 \cdot C_{n-2}^{k_1-1} \cdot C_{n-k_1-1}^{k_2-k_1-1} = n(n-1) \cdot \dfrac{(n-2)!}{(n-k_1-1)!\,(k_1-1)!} \cdot \dfrac{(n-k_1-1)!}{(k_2-k_1-1)!\,(n-k_2)!} = \dfrac{n!}{(k_1-1)!\,(k_2-k_1-1)!\,(n-k_2)!}$

例：对于 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$，$P(X_{(1)} \le X) = 1 - P(X_{(1)} > X) = 1 - \prod_{i=1}^{n} P(X_i > X) = 1 - (1-F(X))^n$

$P(X_{(n)} \le X) = 1 - \prod_{i=1}^{n} F(X) = 1 - F^n(X)$.

小结：注意：一组独立同分布 $X_1, \dots, X_n$，大于 x_0 的概率 $P_1 = \prod_{i=1}^{n} P(X_i > x_0)$

$x_0 < x_1 < \cdots < x_n$ 的概率 $P_2 = \dfrac{\prod_{i=1}^{n} P(X_i > x_0)}{n!}$

例：某教室有4只灯泡，更换为24只后为何坏的概率更大了？

解：设分别第 i 个灯泡寿命为 X_i，$X_i \sim E(\lambda)$，独立同分布.

设 $X = \min\{X_1, \dots, X_4\}$，$Y = \min\{X_1, \dots, X_{24}\}$

$\therefore P_1(X \le a) = 1 - P(X > a) = 1 - \prod_{i=1}^{4} P(X_i > a) = 1 - e^{-4\lambda a}$

$P_2(Y \le a) = 1 - e^{-24\lambda a}$

对于固定的 a，$P_1 - P_2 = e^{-24\lambda a} - e^{-4\lambda a} < 0$

$\therefore P_1 < P_2$　即24只坏的概率更大.

$(X_i \sim E(\lambda)$，则 $E(X) = \frac{1}{\lambda})$

↓ 与几何分布 $Y \sim G(\lambda)$ 一样，$E(Y) = \frac{1}{\lambda}$

No.

Date

二. 随机变量的期望

1. 设 $X=(X_1, X_2, \dots, X_n)$ 是随机向量，若 X 有联合分布函数 $F(x)$，则 $Y=g(X)$ 有数学期望

$$E(Y)=E(g(X))=\int_{R^n} g(x)\,dF(x)$$

理解：期望一定是单个一元随机变量的期望值，向量变量没有期望值，若有只能降维分析，不可避免映射为一个变量。

$\int_{R^n} dF(x)$ 表示对自个微元 $dF(x)$ 积分。

例：设 $X\sim N(0,1)$，α 是常数，求 $E(|X|^\alpha)$

解：$E(|X|^\alpha)=\int_{-\infty}^{+\infty}|x|^\alpha\cdot\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx$ 对于 α 幂次与指数负对数相乘，想到 $\Gamma(\alpha)=\int_0^{+\infty}t^{\alpha-1}e^{-t}dt$

设 $\frac{x^2}{2}=t$ $E|X|^\alpha=\int_0^{+\infty}(2t)^{\frac{\alpha}{2}}\cdot\frac{1}{\sqrt{2\pi}}e^{-t}d\sqrt{2t}=\int_0^{+\infty}\sqrt{2^\alpha}\cdot t^{\frac{\alpha}{2}}\cdot\frac{1}{\sqrt{2\pi}}e^{-t}\cdot\frac{1}{2}\cdot\frac{1}{\sqrt{2t}}\cdot 2\,dt$

$$=\sqrt{\frac{2^{\alpha-2}}{\pi}}\cdot\int_0^{+\infty}t^{\frac{\alpha-1}{2}}e^{-t}dt=\sqrt{\frac{2^{\alpha-2}}{\pi}}\cdot\Gamma\left(\frac{\alpha+1}{2}\right)\quad(\alpha>-1)$$

例：已知 (X,Y) 联合密度为 $f(x,y)$，求 $E(X)$。 考虑为 $g(x,y)=x$

$E(X)=\left(\int_{-\infty}^{+\infty}\right)_x\iint x f(x,y)\,dxdy$ 期望：则以有一点一个值，相比来是多维的。

2. 性质：

① $E(C)=C$ （没有变量，处处都为 C）

② $|E(X)|\le E|X|$ （积分性质）

③ $E(aX+bY)=aE(X)+bE(Y)$

④ $X\le Y$（即 $P(X\le Y)=1$）$\Rightarrow E(X)\le E(Y)$（积分性质）

⑤ 若 X 与 Y 独立，则 $E(XY)=E(X)\cdot E(Y)$（积分拆分）

注意：$E(X)$ 只跟与 $f_X(x)$ 有关，基本定义式是 $E(X)=\int x f_X(x)\,dx$

实际上若已知的是 $f(x,y)$，可考虑为 $g(x,y)=x$，则 $E(X)=\int x f(x,y)\,dxdy$。

（$E(X)=\int x f_X(x)dx=\int x f(x,y)\,dxdy$）

$E(A)$ 中，对应的概率密度为 $A\cdot f_A(a)$。因为 A 是事件对应的值，其基本事件由 $f_A(a)$ 联系。

例：若 $E|X|=0$，则 $P(X=0)=1$。

No.

Date

三. 方差 $Var(X)=\sigma^2(X)$

性质：① $Var(aX+b)=a^2Var(X)$

② $Var(X)=E(X-M)^2=E(X^2)-[E(X)]^2$

③ $Var(X)=E(X-M)^2\leq E(X-C)^2$ $(\forall C\in\mathbb{R})$（离均值的距离相对最近）

④ $Var(X)=0 \Leftrightarrow X=M$ a.s. （a.s. = almost surely，几乎处处）

⑤ $X_1, X_2, \dots, X_n$ 相互独立，则

$Var(\sum_{k=1}^{n} X_k)=\sum_{k=1}^{n} Var(X_k)$ 独立变量的线性和方差等于分别的方差和

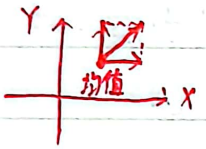

满足勾股定理.

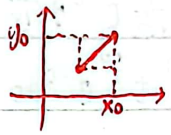

四. 标准化

记 $Var(X)=E(X-M)^2$ 为X的方差，记作 $\sigma^2(X)$，称 $\sigma(X)=\sqrt{Var(X)}$ 为X的标准差

设 $Y=\frac{(X-EX)}{\sqrt{VarX}}$，则 $EY=0$，$Var(Y)=1$，称Y为X的标准化.

例如：设 $X\sim N(M,\sigma^2)$，则 $Y=\frac{X-E(X)}{\sqrt{Var(X)}}\sim N(0,1)$. $P(X\leq a)=\Phi(\frac{a-M}{\sigma})$

五. 不等式

1. Markov不等式：对于随机变量X和$\varepsilon>0$，有 $P(|X|>\varepsilon)\leq\frac{E|X|^\alpha}{\varepsilon^\alpha}$ $(\alpha>0)$

2. Chebyshev不等式：对于随机变量X，有 $P(|X-EX|\geq\varepsilon)\leq\frac{Var(X)}{\varepsilon^2}$

理解：描述随机变量X围绕取值范围的概况率公式为此不等式为上述两种. 左边是描述条件的，$P(|X|\geq\varepsilon)$，

右边是计算公式，与期望非负合α成正比，与条件非负合的α成反比.

对于有意义的不等式，数据离中心各为超过ε的概况率与方差成正比，与条件平方成反比.

3. 内积不等式：$|E(XY)|\leq\sqrt{EX^2EY^2}$ 等号成立的充要条件是存在不全为0的常数a,b，使得 $aX+bY=0$ a.s.

内积：$\vec{a}\cdot\vec{b}\leq|\vec{a}|\cdot|\vec{b}|$ 视向量为随机变量的期望

No.

Date

六. 协方差

1. 定义：设 $\mu_X = EX$ 和 $\mu_Y = EY$ 存在，当 E 存在，称 $E[(X-\mu_X)(Y-\mu_Y)]$ 为 X, Y 的协方差。

记为 $cov(X,Y)$ 或 σ_{XY}。当 $cov(X,Y)=0$，X, Y 不相关。

2. 相关系数（标准化的协方差）

$$\rho_{XY} = corr(X,Y) = \frac{cov(X,Y)}{\sqrt{var(X)}\sqrt{var(Y)}}$$ （标准化：无单位化）

理解：方差描述离散程度。协方差反映两个变量的离散相依程度。若协方差为0，说明两个变量表出的空间为0，即无关。

或：遍历一次 X 与 Y，定义 $X-E(X)$ 与 $Y-E(Y)$ 为新变量。若无关，则 E(新变量之积)为0。

3. 性质

① $cov(X,X) = var(X)$　② $cov(X,Y) = cov(Y,X)$

③ $cov(X,Y) = E(XY) - E(X)\cdot E(Y)$ 常用计算公式

记忆：$var(X) = E(X^2) - [E(X)]^2$，对于协方差而言，$E(X^2) \to E(XY)$　$[E(X)]^2 = E(X)\cdot E(Y)$

④ 若 C 为常数，则 $cov(X,C)=0$（无关）

⑤ 双线性：$cov(aX+bY, Z) = a\,cov(X,Z) + b\,cov(Y,Z)$ 其本质上是固定另不动的期望线性。

⑥ $var(X_1+X_2) = var(X_1) + var(X_2) + 2\,cov(X_1, X_2)$

已知相关性参量协方差，可计算两个变量的和方差。联想 $(a+b)^2 = a^2+b^2+2ab$ 公式，协方差反映交叉项大小。

例：多项分布　设 $(X_1, X_2, \dots, X_n) = Multinomial(n, \vec{p})$，$\vec{p} = (p_1, \dots, p_n)$，$\sum_{i=1}^{k} p_i = 1$，求 $cov(X_i, X_j) = ?$

分析：$cov(X_i, X_j) = E(X_iX_j) - E(X_i)E(X_j)$，对于离散的情形，$E(X_iX_j)$ 不好求。

离散情形没有联合的 $P_{X_i, X_j}(m,n)$ 是可以求，但 $E(X_i, X_j)$ 的数列求和不容易。

解：对于多次连续重复的离散实验，求期望时或协方差时尝试用线性拆分性质

将 X_i, X_j 拆分为单次：设 Z_{ti} 代表第 t 次抽取 i 号球，$Z_{ti} = \int_0^1$（增加一个次序的下标）

$X_i = \sum_{t=1}^{n} Z_{ti}$　$X_j = \sum_{t=1}^{n} Z_{tj}$　$\therefore cov(X_i, X_j) = \left(\sum_{t=1}^{n} cov(Z_{ti}\right)_x \sum_{t=1}^{n}\sum_{t'=1}^{n} cov(Z_{ti}, Z_{t'j})$

$cov(Z_{ti}, Z_{t'j})$ 代表单次协方差。

① $t \neq t'$，实验独立。$cov(Z_{ti}, Z_{t'j}) = 0$

② $t = t'$，$\begin{cases} i=j & cov(Z_{ti}, Z_{t'j}) = var(Z_{ti}) = p_i(1-p_i) \\ i\neq j & cov(Z_{ti}, Z_{tj}) = E(Z_{ti}Z_{tj}) - E(Z_{ti})E(Z_{tj}) = -E(Z_{ti})E(Z_{tj}) = -p_ip_j \end{cases}$

$\therefore$ 原式 $= -np_ip_j + np_i(1-p_i)$

4. 若 (X,Y) 为二元正态分布，则 $cov(X,Y) = \rho\sigma_1\sigma_2$　$cov(X,Y) = E(XY) - E(X)E(Y) = E(XY)$

No.

Date

小结：二元正态分布的性质

设 $X, Y \sim (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$

↳ 回忆：$\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$，组合矩阵中的交叉项为协方差。

① $aX+bY \sim (a\mu)$ 线性组合为正态分布，$\mathrm{cov}(X,Y) = \rho\sigma_1\sigma_2$

设 $Z = aX+bY$ $\therefore E(Z) = aE(X)+bE(Y) = a\mu_1+b\mu_2$ $\mathrm{var}(Z) = \mathrm{var}(aX+bY) = \mathrm{var}(aX)+\mathrm{var}(bY)+2\mathrm{cov}(aX,bY)$

$\mathrm{var}(Z) = \mathrm{var}(aX)+\mathrm{var}(bY)+2\mathrm{cov}(aX,bY) = a^2\cdot\sigma_1^2+b^2\sigma_2^2+2ab\,\mathrm{cov}(X,Y) = a^2\sigma_1^2+b^2\sigma_2^2+2ab\cdot\rho\sigma_1\sigma_2$

避免积分算 $f_Z(z)$

② 边缘分布为正态分布

对于联合正态分布，其线性叠加变量不用积分便可得出。

5. 对于二元正态分布，独立 $\Longleftrightarrow$ 不相关 （$\rho=0$）

对于一般二元分布，独立 $\Rightarrow$ 不相关 ($\rho=0$)

独立是对自个总性质的描述
相关性是用协方差描述数据的总体状况，只是一个视角。
对于二元正态分布，分布型已知，则可用一个数据指整体。

七. 相关性

1. 设 ρ_{XY} 是 X,Y 的相关系数，则 $|\rho_{XY}| \le 1$（内积不等式）（类比于线性回归的相关系数范围）

理解：X,Y 的更强相关性是线性相关，若为线性相关，ρ_{XY} 等价于 $\mathrm{var}(X) = 1$

2. $|\rho_{XY}| = 1 \Leftrightarrow$ 存在常数 a,b,c 不全为0 有 $aX+bY=c$ a.s.

X,Y 不相关 $\not\Rightarrow$ 相互独立

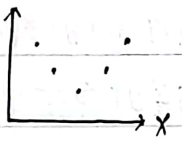

$E(XY)-E(X)E(Y)=0$，但不独立

例：(X,Y) 在单位圆中均匀分布，则 X,Y 不相关，也不独立。

解：$\mathrm{cov}(X,Y) = E(XY)-E(X)E(Y) = 0$

$f(x,y) \neq f(x)\cdot f(y)$

No.

Date

第12讲 随机向量的数学期望与协方差矩阵、条件概率与期望

一. 随机向量的数学期望与协方差矩阵

1. 设 $\vec{X}=(X_1, X_2, \dots, X_n)$ 为随机向量，若对每个 i，$M_i=EX_i$ 存在，则称 $\vec{X}$ 的数学期望存在.

定义 (M_i)，$\vec{m}=E\vec{X}=(EX_1, EX_2, \dots, EX_n)$

对于随机矩阵 $Y=\begin{pmatrix} X_{11} & \cdots & X_{1n} \\ \vdots & \ddots & \vdots \\ X_{m1} & \cdots & X_{mn} \end{pmatrix}$，定义其数学期望 $EY=\begin{pmatrix} EX_{11} & \cdots & EX_{1n} \\ \vdots & \ddots & \vdots \\ EX_{m1} & \cdots & EX_{mn} \end{pmatrix}$

2. 若 $\vec{X}$ 协方差矩阵：将 $\vec{X}$ 中的每个项的协方差用矩阵方式给出

若 $\vec{X}$ 的期望存在，称 $E=[(\vec{X})]$，$\Sigma=E[(\vec{X}-\vec{m})^T(\vec{X}-\vec{m})]=(\sigma_{ij})$ 为 $\vec{X}$ 的协方差矩阵

σ_{ij}：X_i 与 X_j 的协方差，求矩阵不用记形式，一个个算即可

二. 条件概率

1. 随机变量与事件的三种条件概率

条件：可以为变量/事件　分子：可以为事件/变量

(1) 设 A、B 为事件，X、Y 为随机变量

① $P(A|B)=\dfrac{P(A\cap B)}{P(B)}$

② 离散：$P(\{X=x_i\})\neq 0$　$P(X=x_i|A)=\dfrac{P(\{X=x_i\}\cap A)}{P(A)}$

连续：$f_{X|\{X\in A\}}(x)=\dfrac{f_X(x)}{P(\{X\in A\})}$　↙ 基于离散情形，是密度函数在改变

③ $f_{X|Y}(x|y)=\dfrac{f(x,y)}{f_Y(y)}$

总结：所有的条件概率均可写为 $f_{X|M}(x|m)=\dfrac{f(X=x, M=m)}{f(M=m)}$

条件：归一化，除以其概率

分子：取变量与条件的并集.

2. 全概率公式

设 $A_1, \dots, A_n$ 构成 Ω 一个分割

① $P(B)=\sum_{i=1}^{n} P(B|A_i)\cdot P(A_i)$　② $P_X(x)=\sum_{i=1}^{n} P_{X|A_i}(x)\cdot P(A_i)$　$f_X(x)=\sum_{i=1}^{n} f_{X|A_i}(x)\cdot P(A_i)$

③ $P_X(x)=\sum_{i=1}^{n} P_{X|Y_i}(x|y)P_{Y_i}(y)$　$f_X(x)=\int f_{X|Y}(x|y)\cdot f_Y(y)\,dy$

3. 贝叶斯公式

设 $A_1, \dots, A_n$ 构成 Ω 的一个分割，B 是一个事件，且 $P(B)>0$，$P(A_i)>0$

则 $P(A_i|B)=\dfrac{P(B|A_i)\cdot P(A_i)}{\sum_{k=1}^{n} P(B|A_k)\cdot P(A_k)}$

KOKUYO

No.

Date

三. 条件期望

1. 离散：给定 $Y=y_i$ 下，X 的期望 $m(y_i)=E(X|Y=y_i)=\sum_{j=1}^{\infty}x_j P(X=x_j|Y=y_i)$

2. 连续：$m(y)=E(X|Y=y)=\int_{-\infty}^{+\infty}x\cdot f_{X|Y}(x|y)\,dx$

定义：设 (X,Y) 为随机向量，$E|X|<\infty$，若 $m(y)=E(X|Y=y)$，则称随机变量 $m(Y)$ 为给定条件 Y 时 X 的条件期望，记为 $E(X|Y)$

$E(X|Y)$ 中，Y 为条件，X 为期望，是关于 Y 的随机变量。

例：设 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$，求 $E(X|Y)$ 与 $E(Y|X)$？

$E(X|Y)=\int_{-\infty}^{+\infty}x\cdot f_{X|Y}(x|y)\,dx$

3. 若条件为事件，则 $E(X|A)=\frac{E(XI_A)}{P(A)}=\frac{E(X\cdot I_A)}{P(A)}$

→ $E(XI_A)$：I_A 为示性函数，是 A 的自变量范围。若 $I_A=I(x,y)$，则

$E(XI_A)=\iint x\,I(x,y)f(x,y)\,dxdy$

把 I_A 看为一个函数，可有效解决范围问题。

$E(XI_{(x,y)})=\iint xI_{(x,y)}f(x,y)\,dxdy$

$E(XI_{(x)})=\int xI_{(x)}f(x)\,dx$

$P(X<Y)$ = 所有满足点的积分

也视为 $E(I_{\{X<Y\}})$，即 $\iint I_{(x,y)}f(x,y)\,dxdy$

事件的期望：密度函数在相应点的积分。

例：设 $X\sim\mathcal{E}(\lambda)$，对 $a>0$，证明 $E(X-a|X>a)=E(X)$ （$\mathcal{E}(\lambda)$ 的无记忆性）

$$E(X-a|X>a)=E(X|X>a)-a=\frac{\int_a^{+\infty}x\lambda e^{-\lambda x}dx}{\int_a^{+\infty}\lambda e^{-\lambda x}dx}$$

（or，设 $X|X>a=Y$，$Y\sim$ ）or，设 $X-a|X>a=Y\sim\mathcal{E}(\lambda)$，即证 $E(Y)=$

若 $X\sim\mathcal{E}(\lambda)$，则 $Y=X-a|X>a\sim\mathcal{E}(\lambda)$

$$f_Y(y)=f_X(y+a)\big|f_{X|\{X>a\}}(y+a)=\frac{\lambda e^{-\lambda(y+a)}}{e^{-\lambda a}}=\lambda e^{-\lambda y}$$

仍为一个随机变量，只是受拉压变换

例：设 X,Y 独立，$X\sim\mathcal{E}(\lambda)$，$Y\sim\mathcal{E}(\mu)$，求 $E(X|X<Y)$

$$E(X|X<Y)=\frac{\iint_M xf(x,y)\,dxdy,M:\{x<y\}}{\iint_D f(x,y)\,dxdy,D:\{x<y\}},\ \boxed{\text{or } f_X},\ \text{or } f_{X|X<Y}(x)=\frac{f_X(x)}{P(X<Y)}\quad(x<y)$$

例：设 X,Y 独立同分布，$X\sim P(\lambda)$，求 $E(X+Y|X)$，$E(X|X+Y)$

$E(X+Y|X)=E(X|X)+E(Y|X)=X+E(Y|X)=X+E(Y)=X+\lambda$

$E(X|X)=\sum$ 或 $\int$ $=$ $E(X|X)$：以相应概率取 X，则 $E(X|X)=X\cdot 1=X$

例：设 $Y\sim\Gamma(\alpha,\beta)$ $(\alpha>1)$，$f_Y(y)=\frac{\beta^\alpha}{\Gamma(\alpha)}y^{\alpha-1}e^{-\beta y}$ $(y>0)$，已知 $Y=y$，$X\sim\mathcal{E}(y)$，求 $E(X|Y)=\frac{1}{y}$ $E(Y|X)=\frac{\alpha+1}{X+\beta}$

$X<Y$ 是事件，用事件的简便法记算，Y 会遍历整个 $(0,+\infty)$，因此 $X<Y$ 的条件要放在 $f(x,y)$ 上考虑。

小结：已知 $f(x,y)$：$f_{X|X<a}(x)=\frac{f(x)}{P(X<a)}$ $(0<x<a)$

$$f_{X|X<Y}(x)=\frac{f(x\cdot I_{\{x<y\}})}{P(X<Y)}=\frac{f_X(X=x\text{ 且 }X<Y)}{P(X<Y)}=\frac{\int_x^{+\infty}f(x,y)\,dy}{P(X<Y)}$$

$X<Y$：事件，遍历 Y 的定义域

$f_{X|Y}(x)=\frac{f(x,y)}{f_Y(y)}$

No.

Date

第13讲 条件期望性质、全期望定理、最佳预测、条件方差、矩母函数

一. 条件期望性质

1. X, Y 独立时，$E[g(X)|Y] = Eg(X)$

2. $[E(X|Y)]^2 \le E(X^2|Y)$ （相减为方差大于0）

3. $E[h(Y)g(X)|Y] = h(Y)E[g(X)|Y]$

4. $E[E(g(X)h(Y)|Y)] = E(g(X)h(Y))$ 简记为：对条件求期望等于不约束

   $E[E(g(X)h(Y)|m(Y))] = E[g(X)h(Y)]$ 只要对条件求期望，就等价为约束解除

例：X, Y 为独立同分布，$X \sim P(\lambda)$，求 $E(X|X+Y)$

解：$E(X|X+Y) = \iint x \cdot f_{X|X+Y}(x|x+y)\,dx\,dy$

$f_{X|X+Y}(x|x+y) = \dfrac{f(x,y)}{f_{X+Y}(x+y)}$

$f_{X+Y}(x+y) = f_Z(z) = \int_x$

$E(X+Y|X+Y) = X+Y$

$E(X|X+Y) = E(Y|X+Y) = \dfrac{X+Y}{2}$

对于条件为线性合的期望，要到加和。

二. 全期望定理

1. 设 $A_1, \dots, A_n$ 为 Ω 的一个分割，则

(离散)：$E(X) = \sum_{i=1}^{n} E(X|A_i)P(A_i)$ 期望等于值的加和

(连续)：$E(X) = \sum_{i=1}^{n}{}_x$ $f_X(x) = \sum_{i=1}^{n} f_{X|A_i}(x) \cdot P(A_i)$

$$E(X) = \int_R x f(x)\,dx = \int_R x \cdot \left(\sum_{i=1}^{n} P(A_i) f_{A_i}(x)\right) dx = \sum_{i=1}^{n} P(A_i) E(X|A_i)$$

结论：全期望定理下连续与离散相同，都是对区域上的特征数加权求和。

概率分布、密度可加权求和，期望也一样，是线性系统。

☆ 例：设 $X = \sum_{i=1}^{c} X_i$，$X_i|P_i \sim B(n_i, p_i)$，$P_1, P_2, \dots, P_c$ 独立同分布，已知 $EP_i = P$，$\mathrm{Var}\,P_i = \lambda$，$\sum_{i=1}^{c} n_i = n$，求 EX.

$$EX = \sum_{i=1}^{c} E(X_i) \left(= \sum_{i=1}^{c}\sum_{k=1}^{c} E(X_i|P_k) = \sum_{i=1}^{c}\sum_{k=1}^{c} n_i P_k = nP\right)_X$$

$$= \sum_{i=1}^{c}\sum_{k=1}^{c} E(X_i|P_k)P(P_k)$$ 由局部到整体要乘以占比系数。

$$= \sum_{i=1}^{c}\sum_{k=1}^{c} n_i P_k P(P_k) = nP$$

KOKUYO

No.

Date

三. 最佳预测

1. 条件期望的投影解释：设 X、Y 为随机变量，$E[(X-E(X|Y))h(Y)]=0$

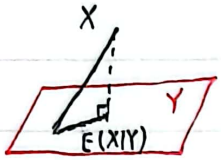

2. 设 $m(Y)=E(X|Y)$，对任意 $g(Y)$，有 $E[X-m(Y)]^2 \le E[X-g(Y)]^2$

即用 Y 预测 X，使用 $m(Y)=E(X|Y)$ 是最佳方案，X 与 m(Y) 的(条件)方差最小

理解：预测的含义：对于给定的 Y，只方便求 $E(X|Y)$，而无法直接得出 Y 下 X 的相关条件值。

不断改变 Y，得到一系列 X 的期望 m(Y)，由此总结出 X 的大致分布，是预测的含义。

用 $E(X|Y)$ 一个特征数字估值 X，误差最小。

例：设 $(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$，有 $E(X|Y)=\mu_1+\rho\frac{\sigma_1}{\sigma_2}(Y-\mu_2)$ 是 Y 的线性组合，称为最 X 的线性预测。对正态分布，最佳预测等于最佳线性预测，若 $E(X|Y)=\mu_1$，则 X、Y 独立

X 不易测量 ⇒ 由 $E(X|Y)$ 描出 X 的分布，存在一定误差。

四. 条件方差

1. 定义：$Var(X|Y)=E[[X-E(X|Y)]^2|Y]=u(Y)$

（条件期望 → 附加条件，在 Y 下计算误差）

理解：类似于 $Var(X)=E(X-\mu)^2$，$Var(X|Y)=E[[X-E(X|Y)]^2|Y]$

2. 计算式：$Var(X|Y)=E[Var]_X$ 求解方法：先算 $E(X|Y)=m(y)$，得到 X 先算 $f(x|y)$，求解 $E(X|Y)$，再计算 $E(\cdot^2|Y)$

2. 全方差法则：$Var(X)=E[Var(X|Y)]+Var(E(X|Y))$ → 不同于条件期望的加权求和，方差是平方系统。

作用：用 X、Y 自带附加条件分布特征计算 X 的特征。

要用条件期望方差与条件方差期望计算。
先对方差求期望，回归"类似于"消去条件"，再加上补差项，即期望的方差。

3. 作用：解决求和上限是随机变量的问题

例：设学生人数为 Y，X_i 是每位学生发论文数量，X 是总论文数量，已知 X_i 独立同分布，若 $E(X_i)$、$E(Y)$、$Var(X_i)$、$Var(Y)$ 已知，求 $E(X)$ 与 $Var(X)$

解：$E(X)=\sum_{i=1}^{Y}E(X_i)=YE(X_i)$，$Var(X)=YVar(X_i)$ ⇒ Y 是一个变量，未知的。⇒ 考虑条件期望与方差，将 Y 放入二元分布中

$E(X)=YE(X_i)$　$E(X|Y)=YE(X_i)$　$E(X)=\sum_Y E(X|Y)P(Y)=E(X_i)E(Y)$

$Var(X)=E(Var(X|Y))+Var(E(X|Y))=E(YVar(X))+Var(X)\,Var(YE(X_i))=Var(X)E(Y)+[E(X_i)]^2Var(Y)$

No.

Date . .

例：设 $X=\sum_{i=1}^{c} X_i$，$X_i|P_i \sim B(n_i, P_i)$，$P_1, P_2, \dots, P_n$ 独立同分布，已知 $EP_i=p$，$\text{var}P_i=\lambda$，$\sum_{i=1}^{c} n_i=n$，求 $\text{var}(X)$

解：$\text{var}(X)=E(\text{var}(X|Y))+\text{var}(E(X|Y))$

$\text{var}(X|Y)=$

$\text{var}(X)=\sum_{i=1}^{c}\text{var}(X_i)$

$\text{var}(X_i)=E(\text{var}(X_i|P_i))+\text{var}(E(X_i|P_i))$

$\text{var}(X_i|P_i)=n_iP_i(1-P_i)$　$E(\text{var}(X_i|P_i))=E(n_iP_i(1-P_i))=n_iE(P_i(1-P_i))=n_i\cdot EP_i-n_iEP_i^2$

$=n_i\cdot p-n_i(\lambda+p^2)$

$E(X_i|P_i)=n_iP_i$　$\text{var}(E(X_i|P_i))=\text{var}(n_iP_i)=n_i^2\lambda$

$\therefore \text{var}(X)=\sum_{i=1}^{c}(n_i(p-\lambda-p^2)+n_i^2\lambda)=(p-\lambda-p^2)n+\sum_{i=1}^{c}n_i^2\lambda$ 或写为 $\underline{np(1-p)}+\underbrace{(\sum_{i=1}^{c}n_i^2-n_i)\lambda}_{\text{多余方差}}$

五. 矩母函数

1. 定义：设 X 为随机变量，称 $M_X(s)=E(e^{sX})$ 为 X 的矩母函数

理解：矩的含义：$E(X)$、$E(X^2)$、$E(X^3)$… 矩是期望值，产生矩的函数称为矩母函数，

矩母函数是一个期望，要具备求导后产生 "n 阶导产生 x^n 项的功能，则想到 $e^{sx}=f(s)$

(Eg $M_X(s)=E(e^{sX})=\int_{-\infty}^{+\infty}e^{sx}f(x)\,dx$

$M_X(s)=\sum_{n=0}^{\infty}\frac{s^n}{n!}M_X(s)=\sum_j e^{sx_j}P(x=x_j)$

不是所有变量都有矩母函数

2. 性质：设 $M_X(s)=E(e^{sX})$ 存在，则

① $\left.\frac{dM_X(s)}{ds}\right|_{x=0}=E(X)$

② $\left.\frac{d^nM_X(s)}{ds^n}\right|_{x=0}=E(X^n)$

③ $Y=aX+b$ 的矩母函数 (Eg $M_Y(s)=E(e^{s(ax+b)})=e^{sb}\cdot \underbrace{M_X(as)}_{E(e^{as\cdot X})}$

④ $EX^k=M^{(k)}(0)$，$M_X(s)$

☆ ⑤ 若 $X_1, \dots, X_n$ 相互独立，则 $Y=X_1+X_2+\cdots+X_n$ 矩母函数为 (Eg $M_Y(s)=M_{X_1}(s)\cdots M_{X_n}(s)$

线性运算可以直接写出矩母函数　应用：复杂求差积，可直接算出 EY^k、$\text{var}(Y)$

$EY=EX_1+\cdots+EX_n$　$EY^2=E(X_1+\cdots+X_n)^2$ 求 想到矩母函数，设 $X_1+\cdots+X_n$ 为整体，求出 $M_Y(s)$

No.

Date

3. 混合分布中的应用

若 $(Y \perp\!\!\!\perp X \mid A_1) = Y$，$X \mid A_2 = Z$，且 A_1, A_2 为 Ω 的分割，

则 $X \sim P(A_1)Y + P(A_2)Z$，$f_X(x) = f(Y) \cdot P(A_1) + f(Z) \cdot P(A_2)$

↳ Y, Z 可同时发生，违反假定。　　↳ 方法用全概率公式

若 $M_S(x) = P_1 M$，$M_X(s) = P_1 M_Y(s) + P_2 M_Z(s)$，则 $f_X(x) = f_Y(y) \cdot P_1 + f_Z(z) \cdot P_2$

$\Leftrightarrow X = P_1 Y + P_2 Z$

理由：$M_X(s) = P_1 M_Y(s) + P_2 M_Z(s)$ 代表 $EX, EX^2 \cdots EX^n$ 有求和关系，说明密度函数是加权的，不是随机变量加权。

No.

Date

第14讲 正态分布的矩母函数、随机数个问题、特征函数、三个收敛、大数定律、中心极限定理

一、正态分布的矩母函数

1. 标准正态分布的矩母函数

设 $X\sim N(0,1)$，则 $M_X(s)=E(e^{sX})=\int_{-\infty}^{+\infty}e^{sx}\cdot\frac{1}{\sqrt{2\pi}}\cdot e^{-\frac{x^2}{2}}dx=\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}\cdot e^{-\frac{1}{2}(x-s)^2}\cdot e^{\frac{1}{2}s^2}dx=e^{\frac{s^2}{2}}$

☆ $M_X(s)=e^{\frac{s^2}{2}}$

总结：处理 $\int e^{x}dx$、$\int e^{x^2}dx$ 的方法：

$\Gamma(n)=\int_0^{+\infty}t^{n-1}e^{-t}dt$　　$\Gamma(n)=(n-1)\Gamma(n-1)=\boxed{n!}^{(n-1)!}$　☆ $\Gamma(0)=0!=1$　$\Gamma(\frac{1}{2})=\sqrt{\pi}$

例：$\Gamma(\frac{5}{2})=\frac{3}{2}\Gamma(\frac{3}{2})=\frac{3}{4}\Gamma(\frac{1}{2})=\frac{3\sqrt{\pi}}{4}$

$\Gamma(n)=\int_0^{+\infty}t^{n-1}e^{-t}dt=\int_0^{+\infty}(n-1)!\,e^{-t}dt=(n-1)!$

当 $n>0$，$\Gamma(n)=\boxed{n!}^{(n-1)!}$　当 $n<0$，利用 $(n-1)\Gamma(n-1)=\Gamma(n)$

☆ 简记为：$\Gamma(n)$ 的形式？在计算 $\Gamma(n)$ / 写出 $\Gamma(n)$ 时，要对 n 讨论！ $\begin{cases}\Gamma(n)=(n-1)!\\ \Gamma(n)=\int_0^{+\infty}t^{n-1}e^{-t}dt\end{cases}$

$\Gamma(1)=\Gamma(0)=0!=1$　$\Gamma(\frac{1}{2})=\sqrt{\pi}$

$\int e^{x^2}dx$：转化为正态分布

2. 正态分布的线性组合是正态分布

① 设 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2)$，设 $Z=aX+bY+c$

则 Z 仍是正态分布：$\begin{cases}E(Z)=a\mu_1+b\mu_2+c\\ Var(Z)=Var(aX+bY+c)=Var(a(X+m)+bY)=Var(aX)+Var(bY)+2Cov(a(X+m),bY)\\ \qquad\qquad =a^2\sigma_1^2+b^2\sigma_2^2\end{cases}$

则 $Z\sim N(a\mu_1+b\mu_2+c,a^2\sigma_1^2+b^2\sigma_2^2)$

② 设 $(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$，设 $Z=aX+bY+c$

则 $E(Z)=a\mu_1+b\mu_2+c$　$(Var(Z)=Var(aX+bY)+Var(c)+Cov(aX+bY),$

$Var(Z)=Var(aX+bY+c)=Var(aX+bY)=a^2\sigma_1^2+b^2\sigma_2^2+2Cov(aX,bY)=a^2\sigma_1^2+b^2\sigma_2^2+2ab\,Cov(X,Y)$

$\therefore Z\sim N(a\mu_1+b\mu_2+c,a^2\sigma_1^2+b^2\sigma_2^2)$，与 ρ 无关！　$\because\rho=\frac{Cov(X,Y)}{\sigma_1\sigma_2}$

$\therefore Var(Z)=a^2\sigma_1^2+b^2\sigma_2^2+2ab\sigma_1\sigma_2\rho$

$\therefore Z\sim N(a\mu_1+b\mu_2+c,a^2\sigma_1^2+b^2\sigma_2^2+2ab\sigma_1\sigma_2\rho)$

设 $X_1,\dots,X_m$ 相互独立，$X_j\sim N(\mu_j,\sigma_j^2)$

则 $Y=X_1+\cdots+X_m=N(\sum_{k=1}^{m}\mu_k,\sum_{k=1}^{m}\sigma_k^2)$

注意：$Y=X_1-X_2\sim N(\mu_1-\mu_2,\sigma_1^2+\sigma_2^2)$

小结：对一般的处理方法：① 求 $Z=X+Y$ 的特殊值 $E(Z)$、$Var(Z)$：利用期望/方差的加加性质，或 $M_Z(s)$

② 求 Z 的分布列：$\begin{cases}\text{正态分布：利用①}\\ \text{其它分布：利用 } f(z)=\int_{-\infty}^{+\infty}f(x,z-x)\,dx\end{cases}$

No.

Date

二. 随机个数问题

对于总数是随机变量的情况，利用条件期望/方差公式 $\begin{cases} E(X)=E(E(X|Z)) \\ Var(X)=E(Var(X|Z))+Var(E(X|Z)) \end{cases}$

矩母函数与对应的随机变量可一一确定，因此可依据 $E(X)$ 求出分布密度。

例：小明找书，书店有区家无穷家，有书的概率为 P，每家寻找时间 $X_i \sim \varepsilon(\lambda)$ 且独立，求找到书的时间的分布是？

解：设总时间为 Y，找了 N 家，

$X_i \sim \varepsilon(\lambda)$，$N \sim G(P)$

$E(Y|N)=\sum_k Nk$ $E(Y|N)=NEX_i$ （无法得出 Y 的分布）

用矩母：$M_Y(S)=E(e^{YS})=E(E(e^{YS}|N))$

$E(e^{YS}|N)=(E(e^{X_iS}))^n=\frac{\lambda^n}{(\lambda-S)^n}$

$M_Y(S)=E[(\frac{\lambda}{\lambda-S})^n]=\sum_{n=1}^{\infty}(\frac{\lambda}{\lambda-S})^n\cdot(1-P)^{n-1}\cdot P=\sum_{n=1}^{\infty}\frac{\lambda P}{\lambda-S}\cdot[\frac{\lambda(1-P)}{\lambda-S}]^{n-1}=a\sum_{n=1}^{\infty}b^{n-1}=a\cdot\frac{1}{1-b}$

$\left(=\frac{ab}{1-b}=\frac{\lambda P}{\lambda-S}\cdot\frac{\lambda(1-P)}{\lambda-S}\cdot\frac{\lambda-S}{\lambda P-S}=\frac{\lambda^2P(1-P)}{(\lambda-S)(\lambda P-S)}\right)_X$ $=\frac{\lambda P}{\lambda-S}\cdot\frac{\lambda-S}{\lambda P-S}=\frac{\lambda P}{\lambda P-S}$

可知 $Y \sim \varepsilon(P\lambda)$

三. 特征函数

1. 定义：对随机变量 X，称 $\phi(t)=E(e^{iXt})=E\cos(tX)+iE\sin(tX)$ $t\in R$ 为 X 的特征函数。

理解：特征函数是变量的考研刻画，由于期望有许多性质，重期望等良好性质，则用一个期望代表此随机变量 X，具体形式是引入欧拉公式中的指数形式。

期望中的函数要有界（考研刻画），且方便求出 X，则利用 $\sin x$、$\cos x$，统一起来即为 e^{iXt}

2. 性质：设 $\phi(t)=E(e^{iXt})$

① $\phi(0)=E(1)=1$ $\phi(-t)=\overline{\phi(t)}$（共轭）[实际上，$e^{i\varphi}$ 共轭为 $e^{-i\varphi}$，无论是何种虚数形式，把 i 的系数变号就为共轭]

② $\phi_{ax+b}(t)=E(e^{it(ax+b)})=e^{itb}\cdot E(e^{itaX})=e^{itb}\cdot\phi_X(at)$

③ 若 $X_1,\dots,X_k$ 相互独立，则 $Y=X_1+\cdots+X_n$ 特征函数为 $\phi_Y(t)=\prod_{i=1}^{k}\phi_{X_i}(t)$

No.

Date

3. 常见变量类型的特征函数

离散：$B(n,p)$、$G(p)$、$P(\lambda)$　连续：$U(a,b)$、$E(\lambda)$、$N(\mu,\sigma^2)$

★ ① $X\sim B(n,p)$

$$\phi(t)=E(e^{itX})=\sum_{k=0}^{n}e^{itk}\cdot p^k\cdot(1-p)^{n-k}\cdot C_n^k=\sum_{k=0}^{n}C_n^k\cdot e^{itk}\cdot p^k(1-p)^{n-k}=(pe^{it}+1-p)^n$$

② $X\sim G(p)$

$$\phi(t)=E(e^{itX})=\sum_{k=1}^{\infty}e^{itk}\cdot p(1-p)^{k-1}=p\cdot\sum_{k=1}^{\infty}e^{it}\cdot(e^{it}-pe^{it})^{k-1}=pe^{it}\cdot\frac{1}{1+pe^{it}-e^{it}}=\frac{p}{e^{-it}+p-1}$$

③ $X\sim P(\lambda)$

$$\phi(t)=E(e^{itX})=\sum_{k=0}^{\infty}e^{itk}\cdot\frac{\lambda^k}{k!}e^{-\lambda}=e^{-\lambda}\cdot\sum_{k=0}^{\infty}\frac{(e^{it}\cdot\lambda)^k}{k!}=e^{-\lambda}\cdot e^{e^{it}\cdot\lambda}=e^{\lambda(e^{it}-1)}$$

④ $X\sim U(a,b)$

$$\phi(t)=E(e^{itX})=\int_a^b e^{itx}\cdot\frac{1}{b-a}dx=\frac{1}{(b-a)it}e^{it(b-a)}$$

⑤ $X\sim E(\lambda)$

$$\phi(t)=E(e^{itX})=\int_0^{+\infty}e^{itx}\cdot\lambda e^{-\lambda x}dx=\lambda\cdot\int_0^{+\infty}e^{(it-\lambda)x}dx=\frac{\lambda}{it-\lambda}\cdot(-1)=\frac{\lambda}{\lambda-it}$$

⑥ $X\sim N(\mu,\sigma^2)$

$$\phi(t)=E(e^{itX})=\int_{-\infty}^{+\infty}e^{itx}\cdot\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx=\cdots$$

此：标准正态分布的 $\phi(t)$：设 $Y\sim N(0,1)$，则 $\phi(t)=E(e^{itY})=E(e^{Yit})=M_Y(t)=e^{-\frac{t^2}{2}}$

注意：若 $Y\sim N(0,1)$，$\begin{cases}E(e^{Yt})=M_Y(t)=e^{\frac{t^2}{2}}\ (\text{不收敛})\\ \phi(t)=E(e^{itY})=e^{-\frac{t^2}{2}}\ (\text{收敛})\end{cases}$ 只是在原基础上把归一化因子 $\frac{1}{\sqrt{2\pi}}$ 去掉，其余没变

则若 $X\sim N(\mu,\sigma^2)$，$\frac{X-\mu}{\sigma}=Y$

$$\begin{cases}E(e^{XS})=M_X(s)=E(e^{(\sigma Y+\mu)s})=e^{\mu s}\cdot M_Y(\sigma s)=e^{\mu s}\cdot e^{\frac{\sigma^2s^2}{2}}\\ \phi(t)=E(e^{itX})=E(e^{it(\sigma Y+\mu)})=e^{it\mu}\cdot\phi(\sigma t)=e^{it\mu}\cdot e^{-\frac{\sigma^2t^2}{2}}\end{cases}$$

4. 特征函数与矩的关系

特征函数与矩都是从对随机变量的刻画等效表述，可以相互转化。

$$E(e^{itX})=E(e^{itX+1})=E\left(1+itX-\frac{1}{2}t^2X^2+o(t^2)\right)=1+itE(X)-\frac{1}{2}t^2E(X^2)+o(t^2)$$

5. 混合分布的特征函数

设分布函数 $F_1(x),\dots,F_m(x)$ 特征函数为 $\phi_1(x),\dots,\phi_m(x)$，$\lambda_i>0$ 且 $\sum_{k=1}^{m}\lambda_k=1$，

则 $\sum_{k=1}^{m}\lambda_kF_k$ 有特征(值)函数 $\sum_{k=1}^{m}\lambda_k\phi_k(t)$。

分布/密度函数的叠加代表混合模型，与随机变量的加和不一致

KOKUYO

No.

Date

四. 三个收敛

1. 依分布收敛

若 $F(x)$ 的连续点 x，有 $\lim_{n\to\infty} F_n(x) = F(x)$，则称 X_n 依分布收敛到 X，记作 $X_n \xrightarrow{d} X$，或称 F_n 弱收敛到 F，记为 $F_n \xrightarrow{w} F$

理解：$X_n \to X$，说两个随机变量最终是极限相同，有不同的依据。对于弱收敛，只用 $F(X_n) \to F(X)$ $(n\to\infty)$ 即可。

2. 依概率收敛

(设 $\{X_n\}$ 独立同分布，$X_n \sim X$)

若对 $\forall \varepsilon > 0$，有 $\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0$，则称 X_n 依概率收敛到 X，记作 $X_n \xrightarrow{P} X$

3. 几乎处处收敛

若 $P(\lim_{n\to\infty} X_n = X) = 1$，则称 X_n 几乎处处收敛到 X，记作 $X_n \xrightarrow{a.s.} X$

关系：

$X_n \xrightarrow{d} X$　$\lim_{n\to\infty} F(X_n) = F(X)$　与 X 取值无关

$\Downarrow$

$X_n \xrightarrow{P} X$　$\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0$　与 X 取值有关，允许邻域内波动

$\Downarrow$

$X_n \xrightarrow{a.s.} X$　$P(\lim_{n\to\infty} X_n = X) = 1$

五. 大数定律

1. 弱大数定律

设 $\{X_n\}$ 独立同分布，则 $\frac{1}{n}\cdot\sum_{k=1}^{n} X_k \xrightarrow{P} EX_1$

理解：在实际场景中只能知道几个 $X_{n,k}$ 的值，要想评估出 X 的具体期望，则 $\lim_{n\to\infty} \frac{1}{n}\cdot\sum_{k=1}^{n} X_k$

即 $\lim_{n\to\infty} P(|\frac{1}{n}\sum_{k=1}^{n} X_k - EX| \geq \varepsilon) = 0$

引入置信度的不等式：利用 Chebyshev：$P(|X-EX| \geq \varepsilon) \leq \frac{var(X)}{\varepsilon^2}$

(设 $X = \frac{1}{n}\sum X_k$　$X = \lim_{n\to\infty} \frac{1}{n}\cdot\sum_{k=1}^{n} X_k$　则 $var(X) = \frac{1}{n}\sum$　设 $X_n = \frac{1}{n}\cdot\sum_{k=1}^{n} X_k$

则 $X = \lim_{n\to\infty} X_n$　$E(X) = \sum$，$var(X) = \frac{1}{n^2}\cdot n\, var(X_1)$

$\therefore P(|X_n - EX| \geq \varepsilon) \leq \frac{1}{\varepsilon^2}\cdot\frac{1}{n}\cdot var(X_1)$

计算收敛速度的方法：Chebyshev 不等式：$P(|X-EX| \geq \varepsilon) \leq \frac{var(X)}{\varepsilon^2}$

(不引入极限) 设 $X = \frac{1}{n}\cdot\sum_{k=1}^{\infty} X_k$　则 $EX = \frac{1}{n}\cdot n\,E(X_1) = E(X_1)$　$var(X) = var(\frac{1}{n}\cdot\sum_{k=1}^{\infty} X_k) = \frac{1}{n^2}\cdot n\cdot var(X_1)$

则 $P(|\frac{1}{n}\cdot\sum_{k=1}^{\infty} X_k - EX_1| \geq \varepsilon) \leq \frac{1}{\varepsilon^2 n}\cdot var(X_1)$，即 $P(|X - EX_1| \geq \varepsilon) \leq \frac{var(X_1)}{\varepsilon^2 n}$，$X$ 是平均值。

No.

Date

六. 中心极限定理

(设 $X_1, X_2, \cdots, X_n$ 独立同分布，设 $S_n = X_1 + \cdots + X_n$)

设 $\{X_n\}$ 独立同分布，$E(X)=M$，$\text{var}(X)=\sigma^2$，则

$\frac{1}{\sigma\sqrt{n}}\sum_{k=1}^{n}(X_k-M) \xrightarrow{d} N(0,1)$，或 $\lim_{n\to\infty}\sum_{k=1}^{n}(X_k-M) = N(0, n\sigma^2)$，或 $\lim_{n\to\infty}\sum_{k=1}^{n}X_k = N(nM, n\sigma^2)$

理解：若已知 n 个 X_n 的值，则它们与中心期望 M 的差服从规律分布，设 $\sum_{k=1}^{n}(X_k-M) = \sqrt{f(n)}\, Y_n$

则 $\lim_{n\to\infty} Y_n \sim N(0, n\sigma^2)$

若 X_k 是独立且同分布的，$EX_k = a$，$\text{var}(X_k) = b$，则求和为 $(\lim_{n\to\infty})\sum_{k=1}^{n}X_k = Y_k \xrightarrow{d} N(na, nb)$

(简单地把均值与方差加和，且是正态分布)。

应用：调查。设 X_k 为统计量，则其求和的随机变量 $Y_n = \sum_{k=1}^{n}X_k \xrightarrow{d} N(nEX, n\,\text{var}(X))$

$\lim_{n\to\infty}F(Y_n) = F(Z)$，其中 $Z \sim N(nEX, n\text{var}(X))$

例：设人群中学过概率论的比例为 f，随机抽 n 个人，用 X_i 表示第 i 个人是否学过，$X_i=1$（学过），$X_i=0$（没有）

则 X_i 如何表示出 f？

解：由 Chebyshev 不等式：$P(|X-EX|>\varepsilon) \le \frac{\text{var}(X)}{\varepsilon^2}$

设 $X = \frac{1}{n}\cdot\sum_{k=1}^{n}X_k$ 则 $EX = f$ $\boxed{\text{var}(X) = f(1-f) \le \frac{1}{4}}$ $\text{var}(X) = \frac{1}{n}f(1-f) \le \frac{1}{4n}$

$\therefore P(|X-f|>\varepsilon) \le \frac{1}{4n\varepsilon^2}$

若取误差率 < 1%，置信度 > 95%

则 $P(|X-f| \ge \frac{1}{100}) \le \frac{10000}{4n} = \frac{2500}{n} < \frac{1}{20}$ $\therefore n > 50000$

or，直接用公式：$P(|X-EX| \ge \varepsilon) \le \frac{\text{var}(X_1)}{\varepsilon^2 n}$ 其中 $X = \frac{1}{n}\cdot\sum_{k=1}^{n}X_k$

则 $P(|X-f| \ge \frac{1}{100}) < \frac{f(1-f)}{\varepsilon^2\cdot n} < \frac{1}{4n\varepsilon^2} = \frac{10000}{4n} < 5\%$

从中心极限定理考虑：

中心极限定理：$\sum_{k=1}^{n}X_k \xrightarrow{d} N(nM, n\sigma^2)$

$\frac{1}{n}\sum_{k=1}^{n}X_k \sim N(M, \frac{\sigma^2}{n})$

$\therefore P(|\frac{1}{n}\sum_{k=1}^{n}X_k - M| \le \frac{1}{100}) = P(\frac{\sqrt{n}}{\sigma}|\frac{1}{n}\cdot\sum_{k=1}^{n}X_k - M| \le \frac{\sqrt{n}}{\sigma 100})$

$= P(|Z| \le \frac{\sqrt{n}}{100\sigma})$ $Z \sim N(0,1)$ $\because \sigma = \sqrt{f(1-f)} \le \sqrt{\frac{1}{4}} = \frac{1}{2}$

$\ge P(|Z| \le \frac{\sqrt{n}}{50}) = P(|Z| \le \frac{\sqrt{n}}{50})$ 若 $P(|Z| \le \frac{\sqrt{n}}{50}) > \frac{19}{20}$

则 $\Phi(\frac{\sqrt{n}}{50}) = \frac{39}{40}$ $\frac{\sqrt{n}}{50} = 1.96$ $n = 9604$

小结：统计类问题涉及多个结果相加取平均的情况，即调查。

KOKUYO

No.

Date

已知 $\left(\frac{1}{n}\cdot\sum_{k=1}^{n}X_k-\mu\right)\downarrow$ $\frac{1}{n}\cdot\sum_{k=1}^{n}X_k \xrightarrow{d} EX$ 一定是成立的，关键是收敛速度是多少？

① Chebyshev不等式：(普通大概率估计) $P(|X-EX|\geq\varepsilon)\leq\frac{var(X)}{\varepsilon^2}$

变形得：$P(|X-EX_1|>\varepsilon)\leq\frac{var(X_1)}{n\varepsilon^2}$，其中 $X=\frac{1}{n}\cdot\sum_{k=1}^{n}X_k$；$\varepsilon$：误差 $\frac{var(X_1)}{n\varepsilon^2}$：概率

② 中心极限定理：给出了 $X=\frac{1}{n}\sum_{k=1}^{n}X_k$ 的分布具体形状，结果比①一定精确

$\sum_{k=1}^{n}X_k \sim N(nEX_1, n\,var(X))$ ← 与 $X_1+X_2+\cdots+X_n$ 一样，简单的方差求和

计算技巧：$P\left(\left|\frac{1}{n}\sum_{k=1}^{n}X_k-EX_1\right|\leq\varepsilon\right)$

$=P\left(\frac{\sqrt{n}}{\sqrt{var(X)}}\left|\frac{1}{n}\sum_{k=1}^{n}X_k-EX_1\right|\leq\frac{\sqrt{n}\varepsilon}{\sqrt{var(X)}}\right)$

$Z\sim N(0,1)$

回顾：计算 $X\sim N(\mu,\sigma^2)$ 的相关概率时，都有可以转为 $N(0,1)$ 的过程：

$P(X\leq a)=P(X-\mu\leq a-\mu)=P\left(\frac{X-\mu}{\sigma}\leq\frac{a-\mu}{\sigma}\right)=\Phi\left(\frac{a-\mu}{\sigma}\right)$