《概率论》

Lecture 1. 概率模型.

1. 样本空间.

随机试验所有可能结果的集合 Ω.

↓

互斥、完整、有限/无限.

2. 概率.

事件：样本空间的子集.

概率：分配到事件上，刻画事件发生的可能性

3. 概率模型 $\begin{cases} \text{样本空间 } \Omega \\ \text{概率 } P. \end{cases}$

概率公理：

1. 非负：$P(A) \geq 0 \quad \forall A \subset \Omega$
2. 归一：$P(\Omega) = 1$
3. 可加：$A \cap B = \emptyset$ 时 $P(A \cup B) = P(A) + P(B)$.

加强：可列可加性：$A_1 \cdots A_n \cdots$ 互不相交.

则 $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{k=1}^{+\infty} P(A_k)$.

利用公理 $\Rightarrow$ 性质.

① $P(\emptyset) = 0$. proof: $\Omega = \Omega \cup \emptyset \cup \emptyset \cup \cdots$

$\Rightarrow P(\Omega) = P(\Omega) + P(\emptyset) + P(\emptyset) + \cdots$

$\Rightarrow P(\emptyset) = 0$.

② 有限可加：令 $A_{n+1} = A_{n+2} = \cdots = \emptyset$.

则 $P(\bigcup_{k=1}^{n} A_k) = P(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} P(A_k) = \sum_{k=1}^{n} P(A_k)$.

③ $P(A^C) = 1 - P(A)$

proof: $A \cap A^C = \emptyset \quad A \cup A^C = \Omega$

$\Rightarrow P(A) + P(A^C) = P(\Omega) = 1$

④ $A \subset B \Rightarrow P(A) \leq P(B)$.

proof: $B = A \cup (B \setminus A) \quad A \cap (B \setminus A) = \emptyset$

$\Rightarrow P(B) = P(A) + P(B \setminus A) \geq P(A)$.

推论：① $P(B \setminus A) = P(B) - P(A)$ 若 $A \subset B$

② $P(A) \in [0,1]$

⑤ $P(A \cup B) \leq P(A) + P(B)$

proof:

$P(A \cup B) = P(AB^C) + P(A^C B) + P(AB)$

$= P(A) + P(A^C B) \leq P(A) + P(B)$.

$= P(A) + P(B) - P(AB)$.

推论：

① $P(\bigcup_{i=1}^{n} A_i) \leq \sum_{i=1}^{n} P(A_i)$

② $P(\bigcup_{i=1}^{\infty} A_i) \leq \sum_{i=1}^{\infty} P(A_i)$

⑥ 容斥原理：

$$P(\bigcup_{i=1}^{n} A_i) = \sum_{1 \leq i \leq n} P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) + \cdots + (-1)^{n-1} P(A_1 A_2 \cdots A_n)$$

容斥原理的证明：

proof：① $n=1$，$P(A_1)$

② $n=2$ $P(A_1\cup A_2)=P(A_1)+P(A_2)-P(A_1\cap A_2)$

③ 设 $n-1$ 成立 $n=n$ 时，

$$P(\bigcup_{k=1}^{n}A_k)=P(A_n\cup(\bigcup_{k=1}^{n-1}A_k))$$

$$=P(A_n)+P(\bigcup_{k=1}^{n-1}A_k)-P(A_n\cap(\bigcup_{k=1}^{n-1}A_k))$$

$$=P(A_n)+P(\bigcup_{k=1}^{n-1}A_k)-P(\bigcup_{k=1}^{n-1}(A_n\cap A_k))$$

$$=P(A_n)+P(\bigcup_{k=1}^{n-1}A_k)+(-1)P(\bigcup_{k=1}^{n-1}A_kA_n).$$

归纳假设：$P(\bigcup_{k=1}^{n}A_k)=(-1)^0\sum_{k=1}^{n}P(A_k)+(-1)^1\sum_{1\le i<j\le n}P(A_iA_j)+\cdots+(-1)^{n-1}P(A_1\cdots A_n)$.

对上式用归纳假设：

$$\underline{(-1)^0\sum_{k=1}^{n-1}P(A_k)}+\underline{(-1)^1\sum_{1\le i<j\le n-1}P(A_iA_j)}+\cdots+(-1)^{n-2}P(A_1\cdots A_{n-1})$$

$$+\underline{(-1)^1\sum_{k=1}^{n-1}P(A_kA_n)}+(-1)^2\sum_{1\le 整数\le n-1}P(A_iA_jA_n)+\cdots+(-1)^{n-1}\sum_{\cdots}$$

$$+(-1)^nP(A_1A_2\cdots A_n)+\underline{P(A_n)}$$

$$=\sum_{k=1}^{n}P(A_k)+(-1)\sum_{1\le i<j\le n}P(A_iA_j)+\cdots+(-1)^nP(A_1\cdots A_n).$$

得证 #.

我们利用容斥原理可以解决一经典问题：错戴帽 = n个人有n个帽子，每个人都没戴自己帽子的概率

令：设 B_i 为第 i 个人戴对帽子

$$P(\bar{A})=P(\bigcup_{i=1}^{n}B_i)$$

$$=\sum_{i=1}^{n}P(B_i)+(-1)\sum_{1\le i<j\le n}P(B_iB_j)+\cdots+(-1)^{n-1}P(B_1\cdots B_n).$$

$P(B_i)=\frac{1}{n}$

$P(B_iB_j)=\frac{1}{n}\frac{1}{n-1}$

$\cdots P(B_{i_1}\cdots B_{i_r})=\frac{1}{n}\frac{1}{n-1}\cdots\frac{1}{n-r+1}$.

中间项：$(-1)^{r-1}C_n^r\frac{(n-r)!}{n!}=\frac{(-1)^{r-1}}{r!}$

那么：$=n\cdot\frac{1}{n}+(-1)C_n^2\frac{1}{n}\frac{1}{n-1}+\cdots+(-1)^{n-1}\frac{1}{n!}$

$=1-\frac{1}{2}+\frac{1}{3!}+\cdots+\frac{(-1)^{n-1}}{n!}$

那么 $P(A)=\frac{1}{2}-\frac{1}{3!}+\frac{1}{4!}+\cdots+\frac{(-1)^n}{n!}$ $n\to\infty$ 时 $\longrightarrow\frac{1}{e}$.

⑦ (Bonferroni's inequality):

$$P(\bigcup_{i=1}^{n} A_i) \geq \sum_{1\leq i\leq n} P(A_i) - \sum_{1\leq i<j\leq n} P(A_iA_j).$$

proof: ① $n=1$. $P(A_1) \geq P(A_1)$ ✓

② $n=2$ $P(A_1\cup A_2) = P(A_1)+P(A_2)-P(A_1A_2)$ ✓

③ 设 $n=k-1$ 时: $P(\bigcup_{i=1}^{k-1} A_i) \geq \sum_{1\leq i\leq k-1} P(A_i) - \sum_{1\leq i<j\leq k-1} P(A_iA_j)$.

则 $n=k$ 时: $P(\bigcup_{i=1}^{k} A_i) = P(A_k \cup (\bigcup_{i=1}^{k-1} A_i))$

$$= P(A_k) + P(\bigcup_{i=1}^{k-1} A_i) - P(A_k \cap (\bigcup_{i=1}^{k-1} A_i))$$

$$= P(A_k) + P(\bigcup_{i=1}^{k-1} A_i) - P(\bigcup_{i=1}^{k-1} (A_iA_k))$$

$$\overset{\text{归纳假设}}{\geq} \sum_{1\leq i\leq k} P(A_i) - \sum_{1\leq i<j\leq k-1} P(A_iA_j) - P(\bigcup_{i=1}^{k-1} (A_iA_k))$$

又由于: $P(\bigcup_{i=1}^{k-1} B_i) \leq \sum_{i=1}^{k-1} P(B_i)$

那么: $P(\bigcup_{i=1}^{k-1} (A_iA_k)) \leq \sum_{i=1}^{k-1} P(A_iA_k)$.

那么上式进一步 $\geq \sum_{1\leq i\leq k} P(A_i) - \sum_{1\leq i<j\leq k-1} P(A_iA_j) - \sum_{i=1}^{k-1} P(A_iA_k)$.

$$= \sum_{1\leq i\leq k} P(A_i) - \sum_{1\leq i<j\leq k} P(A_iA_j).$$

归证. #

⑧ Kounias's inequality:

$$P\left(\bigcup_{i=1}^{n} A_i\right) \le \min_{k}\left\{\sum_{1\le i\le n} P(A_i) - \sum_{i:i\neq k} P(A_i\cap A_k)\right\}$$

proof: 由于考虑对于 k 的最小值成立.

我们只需考虑对于任意给定的 k.

都有 $P\left(\bigcup_{i=1}^{n} A_i\right) \le \sum_{1\le i\le n} P(A_i) - \sum_{i\neq k} P(A_i A_k)$.

① $n=1$ 时 $P(A_1) \le P(A_1)$

② $n=2$ 时 $P(A_1\cup A_2) = P(A_1)+P(A_2)-P(A_1A_2) \le P(A_1)+P(A_2)-P(A_1A_2)$

③ $n=k-1$ 时 设 $P\left(\bigcup_{i=1}^{n-1} A_i\right) \le \sum_{1\le i\le n-1} P(A_i) - \sum_{i\neq k} P(A_iA_k)$.

则 $P\left(\bigcup_{i=1}^{n} A_i\right) = P(A_n) + P\left(\bigcup_{i=1}^{n-1} A_i\right) - P\left(\bigcup_{i=1}^{n-1}(A_iA_n)\right)$

$$\le P(A_n) + P(A_1)+\cdots+P(A_{n-1}) - \sum_{i\neq k} P(A_iA_k) - P\left(\bigcup_{i=1}^{n-1}(A_iA_n)\right)$$

$$= \sum_{1\le i\le n} P(A_i) - \sum_{i\neq k} P(A_iA_k) \quad ⑧$$

i从

我们考虑 $P\left(\bigcup_{i=1}^{n} A_i\right) = P\left(A_k \cup \left(\bigcup_{i\neq k} A_i\right)\right)$ X

$$= P(A_k) + P\left(\bigcup_{i\neq k} A_i\right) - P\left(\bigcup_{i\neq k}(A_i\cap A_k)\right)$$

$$\le P(A_k) + \sum_{i\neq k} P(A_i) - \sum_{i\neq k} P(A_kA_i).$$

$$= \sum_{i=1}^{n} P(A_i) - \sum_{i\neq k} P(A_iA_k) \quad \text{即右式} \quad \#$$

修正: $\bigcup_{i=1}^{n} A_i = A_k \cup \left(\bigcup_{i\neq k}(A_i\setminus A_k)\right)$

$$P\left(\bigcup_{i=1}^{n} A_i\right) = P(A_k) + P\left(\bigcup_{i\neq k}(A_i\setminus A_k)\right)$$

$$\le P(A_k) + \sum_{i\neq k} P(A_i\setminus A_k)$$

而 $P(A\setminus B) = P(A) - P(AB)$

$$= P(A_k) + \sum_{i\neq k}\left[P(A_i) - P(A_iA_k)\right]$$

$$= \sum_{i=1}^{n} P(A_k) - \sum_{i\neq k} P(A_iA_k) \quad \text{证毕 原命题.} \quad ⑧.$$

⑨. 求证 $P(\bigcap_{i=1}^{\infty} A_i) \geq 1 - \sum_{i=1}^{\infty} P(A_i^c)$

proof: $P(\bigcap_{i=1}^{\infty} A_i) = 1 - P((\bigcap_{i=1}^{\infty} A_i)^c)$

$= 1 - P(\bigcup_{i=1}^{\infty} A_i^c)$

$\geq 1 - \sum_{i=1}^{\infty} P(A_i^c)$ #

总结技巧：
- 拆成互斥条合 → 利用差余
- 数学归纳
- 取补集.

Lecture 2. 概率空间. 条件概率.

我们从两个问题开始：

Q1："可列可加"可放宽是"任意可加"吗？

Q2：任意一个样本空间的子集都可分配概率吗？ ⟶ 即上述问题是否存在不可测的集合

概率测度下

Q1：

$\Omega = \{(x,y) \mid 0 \le x,y \le 1\}$

$P(\Omega) = P\left(\bigcup_{x,y} \{(x,y)\}\right) = \sum_{x,y} P(\{(x,y)\}) = \sum_{x,y} 0 = 0 \neq 1$

不行.

Q2. 我们希望构造出一个集合 E. $P(E)$不能被非负实数表示.

[E不可测] proof: Vitali 集.

$\Omega = [-2,2]$ $P(A) = \dfrac{\text{length}(A)}{\text{length}(\Omega)}$ $P(A)$ 满足 非负 归一 可列可加.

下构造 E：

- E 有无数个元素. [否则在几何概型下取0] $\Rightarrow$
- E 不是全集. [否则 $P(E)=1$]

① 定义等价关系. $x \sim y \iff x-y \in \mathbb{Q}$.

② $x \sim y$ 分割 $\mathbb{R}$ 或 $[0,1]$：

$\forall x \in [0,1]$ $\tilde{x} = \{y \in [0,1] : y \sim x\}$ (等价类).

易知：若 x_1 不是 x_2 的等价类，则 $\tilde{x_1} \cap \tilde{x_2} = \emptyset$

③ 从每个等价类中取 一个 元素 构成 E.

E 不可测：如可测：$[0,1] = \bigcup_{x \in E} \tilde{x}$ 且 $\tilde{x}$ 可测.

由假设

⟶ 不可测 = 可测 · 可测. 矛盾!

取 $E_n = r_n + E := \{x + r_n \mid x \in E\}$

for $r_n \in [-1,1] \cap \mathbb{Q}$.

可见：① $m \neq n$ 时 $E_m \cap E_n = \emptyset$.

② $[0,1] \subset \bigcup_{n=1}^{\infty} E_n \subset [-1,2]$

则：$0 < P([0,1]) \le P\left(\bigcup_{n=1}^{\infty} E_n\right) \le P([-1,2]) < \infty$.

由可列可加：$0 < P([0,1]) \le \sum_{n=1}^{\infty} P(E_n) \le P([-1,2]) < \infty$.

⟶ 矛盾. (ZKS 证明 $P(E) > 0$

KKS 证明 $P(E) = 0$.) △

我们补充说明“可证”中的两点：

① $m \neq n$ 时 $E_m \cap E_n = \emptyset$.

proof: 若 $\exists\ y \in E_m \cap E_n$

则 $\left.\begin{matrix} y - r_m \in E \\ y - r_n \in E \end{matrix}\right\}$ 而 $r_n - r_m \in \mathbb{Q}$ $\Rightarrow (y-r_m) \sim (y-r_n)$

且 $r_m \neq r_n$

$\Rightarrow (y-r_m) \neq (y-r_n)$

这说明 E 包含了 $\tilde{x}$ 的 2个 不同元. 矛盾!

② $[0,1] \subset \bigcup_{n=1}^{\infty} E_n \subset [-1,2]$

proof: $\forall\ x \in [0,1]$ $\exists\ y \in \tilde{x}$ 使得 $y \in E$. $x - y \in [-1,1] \cap \mathbb{Q}$

此即 $\exists\ r_k$. $r_k = x - y$. 则 $x = r_k + y \in E_k$.

那么 $[0,1] \subset \bigcup_{n=1}^{\infty} E_n$.

而 $r_n \in [-1,2]$ $E \subset [0,1]$ 则 $\bigcup_{n=1}^{\infty} E_n \subset [-1,2]$.

围绕 这两个问题，我们必须追问：① 对于已定义的概率，什么集合才能确定对应的概率？

如 古典几何概型

② 对于未定义的概率，我们应在何范围内定义概率的度量？

⇒ 事件域 与 概率空间

引出一个代数 ← 必经思路1：要包含我们关心的基本事件

必经思路2：不能引入不可测集

1. 概率空间.

集合类：样本空间中某些子集构成的集合（集合的集合）.

如：$\{A \mid A \subset [-2,2]\}$ 包含 $[-2,2]$ 的所有子集

A_1, A_2, A_3 $\tilde{A} = \{A_1, A_2, A_3\}$ 包含3个子集.

不可测集，给定几何概型，无法定义概率的集合.

⇒ 必须在恰当的集合类上定义概率

↑

事件域 $\mathcal{F}$（事件域 $\mathcal{F}$ 是一个集合类）

我们希望在 $\mathcal{F}$ 上，① $P(\Omega)$ 存在 ② $P(A)$ 可度量时 $P(A^c)$ 可度量 ③ $P(A_n)$ 可~时 $P(\bigcup_{n=1} A_n)$ 也可~

由此定义 **事件域**：

设 Ω 是样本空间，$\mathcal{F}$ 表示 Ω 的某些子集构成的集合.

若 $\mathcal{F}$ 满足：① $\Omega \in \mathcal{F}$ ② $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$ ③ $A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$.

则称 $\mathcal{F}$ 是 Ω 上的事件域（σ域 / σ-代数）. $\mathcal{F}$ 中的集合：事件.

注1：由②③可知 $\mathcal{F}$ 对 $\cap$ 也封闭，进一步 $A \setminus B = A \cap B^c \Rightarrow$ 对差集也封闭

注2：最小的 $\mathcal{F} = \{\emptyset, \Omega\}$ 最大的 $\mathcal{F} = \{\Omega \text{的全体子集}\} \xlongequal{\Delta} 2^{\Omega}$

注3：对于固定的 Ω，$\mathcal{F}$ 可不同. 注4：$(\Omega, \mathcal{F})$ 称为 可测空间.

△

我们应从"生成"的观点看事件域：

先有一个集合类 $\mathcal{A}=\{[a,b]\mid a\in R,\ b\in R\}$ （所有闭区间的集合）

再考虑 $\mathcal{A}$ 生成的事件域

↓

包含 $\mathcal{A}$ 的事件域的交集 $\sigma(\mathcal{A})$ [也就是，包含 $\mathcal{A}$ 的最小的事件域]

例如：$\mathcal{A}=\{A\}\Rightarrow \sigma(\mathcal{A})=\{A, A^C, \Omega, \emptyset\}$

$\mathcal{A}=\{A,B\}\Rightarrow \sigma(\mathcal{A})=?$

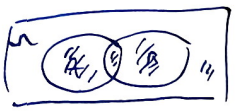

我们先看到4个互不相交的部分：

A^CB^C　AB^C　AB　A^CB　且其并集为 Ω.

$\sigma(\mathcal{A})$ 包含4者的"任意并"

$2^4=16$ 个

eg: Ω. $\emptyset$. A. A^C　B　B^C　AB　AB^C　A^CB　A^CB^C　$A\cup B$. $A^C\cup B$. $A\cup B^C$. $A^C\cup B^C$.

$AB\cup A^CB^C$　$AB^C\cup A^CB$.　共16个.

对于 $\mathcal{A}=\{[a,b]\mid a\in R,\ b\in R\}$ 我们称 $\sigma(\mathcal{A})$ 为 Borel 域 $\mathcal{B}$

$\mathcal{B}$ 中集合为 Borel 集.

Borel 域中集合均是可测. 也即：在几何概型下有概率.

概率空间：Ω 是样本空间　F 是 Ω 上的事件域.　P 是定义在 F 上的函数

若 P 满足：① $P(A)\geq 0$ $\forall A\in F$　② $P(\Omega)=1$　③ $P(\bigcup_{n=1}^{\infty}A_n)=\sum_{n=1}^{\infty}P(A_n)$

其中 $A_i\in F$　$A_i\cap A_j=\emptyset$ ($i\neq j$).

称 P 是 F 上的概率测度　简称 概率.

(Ω, F, P) 为 概率空间.

一些概率空间的例子：

① 有限概率空间。 $\Omega=\{w_1,\cdots w_m\}$ F 由 Ω 一切子集构成。

$\forall A\in F$ $P(A)=\sum_{w_j\in A} p_j$ 其中 $p_j\geq 0$. $\sum_{j=1}^{m} p_j=1$.

(Ω,F,P) 构成概率空间。 当 $p_j=\frac{1}{m}$ 时是古典概率空间。

② 可列概率空间。 把上述 $\sum_{j=1}^{m} p_j=1$ 改成 $\sum_{j=1}^{\infty} p_j=1$ 即可。

③ 一维几何概率空间： $\Omega\in R$. Ω 可求长。 $m(\Omega)\in(0,+\infty)$ 长度。 有限，$\neq 0$.

则 $F=\mathcal{B}\cap\Omega:=\{B\cap\Omega\mid B\in\mathcal{B}\}$

定义 $P(A)=\frac{m(A)}{m(\Omega)}$ 则 (Ω,F,P) 构成 几何概率空间

研究至此，我们必须了解 $\mathcal{B}$ (Borel域) 是什么。 Borel集有哪些。

我们知道，Borel域是由 R 中闭区间生成的事件域。(包含所有闭区间的最小事件域)

Borel集有哪些？ ① $[a,b)=\bigcup_{n=1}^{\infty}[a,b-\frac{1}{n}]$

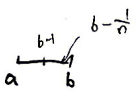

$=\bigcap_{n=1}^{\infty}[a-\frac{1}{n},b)$ $\Rightarrow$ 总结：

① 任何开集
② 任何闭集
③ 任何半开半闭
④ 任何单点集
⑤ Q. $R\setminus Q$.

② $(-\infty,b]=\bigcup_{n=1}^{\infty}[-n,b]$

③ $\{b\}=[a,b]\cap[a,b)^c$

Borel域的另外定义： $\mathcal{A}=\{(-\infty,x]\mid x\in R\}$ $\sigma(\mathcal{A})=\mathcal{B}$

proof: $\tilde{\mathcal{A}}=\{(-\infty,x]:x\in R\}$ $\tilde{\mathcal{B}}=\{[a,b]:a,b\in R\}$. 下证 $\sigma(\tilde{\mathcal{A}})=\sigma(\tilde{\mathcal{B}})$

① $\sigma(\tilde{\mathcal{A}})\subseteq\sigma(\tilde{\mathcal{B}})$

注：$\forall x\in R$, $(-\infty,x]=\bigcup_{n=1}^{\infty}[-n,x]$ $\Rightarrow$ $\tilde{\mathcal{A}}$ 的所有对在 $\sigma(\tilde{\mathcal{B}})$ 中

其中 $[-n,x]\in\tilde{\mathcal{B}}$

从而 $(-\infty,x]\in\sigma(\tilde{\mathcal{B}})$ $\Rightarrow\sigma(\tilde{\mathcal{A}})\overset{\Delta}{\subseteq}\sigma(\tilde{\mathcal{B}})$

② $\sigma(\tilde{\mathcal{B}})\subseteq\sigma(\tilde{\mathcal{A}})$

$(a,b]=(-\infty,b]\setminus(-\infty,a]$

而 $\sigma(\tilde{\mathcal{A}})$ 是包含 $\tilde{\mathcal{A}}$ 的最小域 而 $[a,b]=\bigcap_{n=1}^{\infty}(a-\frac{1}{n},b]$ #

在讨论 Borel 集时，我们有 $[a,b]=\bigcup_{n=1}^{\infty}[a,b-\frac{1}{n}]$

$=\lim_{n\to\infty}[a,b-\frac{1}{n}]$

从事件发生角度 事件的（集合的）极限运算：

① $A_1\subset A_2\subset\cdots$ 即 $\{A_n\}_{n=1}^{\infty}$ 单增. 记为 $\lim_{n\to\infty}A_n=\bigcup_{i=1}^{\infty}A_i$

② $A_1\supset A_2\supset\cdots$ $\{A_n\}_{n=1}^{\infty}$ 单减. $\lim_{n\to\infty}A_n=\bigcap_{i=1}^{\infty}A_i$

事件的极限与概率的极限可交换吗？

2. 概率的连续性

对于上述①：$A_i\uparrow\Rightarrow A_n=A_1\cup(A_2-A_1)\cup\cdots(A_i-A_{i-1})\cup\cdots$

$\Rightarrow A_n=A_1\cup_{i=2}^{\infty}(A_i-A_{i-1})$

由于列可加性：

$P(\lim_{n\to\infty}A_n)=\lim_{n\to\infty}\sum_{i=2}^{n}\big(P(A_i)-P(A_{i-1})\big)+P(A_1)$

$=\lim_{n\to\infty}P(A_n)$. 由定义②

若集合不单调，依照数列上极限的构造：$\limsup_{n\to\infty}x_n=\lim_{n\to\infty}\sup_{k\ge n}\{x_k\mid k\ge n\}$

先取上确界，后取下确界

$=\inf_{n\ge1}\sup_{k\ge n}x_k$.

我们构造事件列的上极限：

$\limsup_{n\to\infty}A_n=\bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty}A_k$. 记为 B_n. $B_n=\bigcup_{k=n}^{\infty}A_k$ $B_{n+1}=\bigcup_{k=n+1}^{\infty}A_k$

$\Rightarrow B_{n+1}\subseteq B_n.\Rightarrow\{B_n\}\downarrow$

其中包含：$w\in\limsup_{n\to\infty}A_n\Rightarrow\forall n,\ w\in\bigcup_{k=n}^{\infty}A_k$

$\Rightarrow$ 无论从 $K=?$ 开始看，w 总出现在后面某个中

$\Rightarrow\limsup_{n\to\infty}A_n=\{w\in\Omega:$ w 属于无穷多个 $A_i\}$ 因此 A_n 上极限也写成 A_n i.o.

(infinitely often)

下极限同理：$\liminf_{n\to\infty}A_n=\bigcup_{n=1}^{\infty}\bigcap_{k=n}^{\infty}A_k$. 记为 B_n. $B_n\subseteq B_{n+1}$

若 $w\in\liminf_{n\to\infty}A_n\Rightarrow\exists n_0,\ w\in\bigcap_{k=n_0}^{\infty}A_k$.

$\Rightarrow$ 去掉 n_0-1 后，后面的所有集合都包含 w. $\lim_{n\to\infty}A_n$ 也写成 A_n a.s.

[almost surely]

$\liminf_{n\to\infty}A_n=\{w\in\Omega:$ w 属于除有限个之外的所有 $A_i\}$

我们有： $P(\limsup_{n\to\infty} A_n) \geq \limsup_{n\to\infty} P(A_n)$.

$P(\liminf_{n\to\infty} A_n) \leq \liminf_{n\to\infty} P(A_n)$.

上在内，上更大

下在内，下更小.

proof: $P(\limsup_{n\to\infty} A_n) = P(\bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} A_k) = P(\bigcap_{n=1}^{\infty} B_n)$ $\{B_n\}\downarrow$

$= P(\lim_{n\to\infty} B_n) = \lim_{n\to\infty} P(B_n)$.

而由单调性： $P(B_n) \geq P(A_k)\ \forall k \geq n$.

从而 $P(B_n) \geq \sup_{k\geq n} P(A_k)$ 代入即得 #.

易知： $\liminf_{n\to\infty} A_n \subseteq \limsup_{n\to\infty} A_n$.

事件最终发生　　事件无穷多次发生

从定义来看，任取 $x \in \liminf_{n\to\infty} A_n = \bigcup_{n=1}^{\infty}\bigcap_{k=n}^{\infty} A_k$.

$\exists n_0$. $x \in \bigcap_{k=n_0}^{\infty} A_k$.

$\Rightarrow \forall k \geq n_0$ $x \in A_k$.

$\Rightarrow \forall n$. 我们总能找到 k. $k \geq \max(n, n_0)$ 使得 $x \in A_k$.

$\Rightarrow x \in \bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} A_k$. 二者相互包含 $\{A_i\}$ 极限存在.

Borel-Cantelli 引理：

Part 1. $\sum_{n=1}^{\infty} P(A_n) < \infty \Rightarrow P(\limsup_{n\to\infty} A_n) = 0$. 几乎不可能有无限多事件同时发生

Part 2: $\sum_{n=1}^{\infty} P(A_n) = \infty$ 且 $\{A_n\}$ 相互独立 $\Rightarrow P(\limsup_{n\to\infty} A_n) = 1$. 几乎肯定有无限多事件会发生

proof: $P(\limsup_{n\to\infty} A_n) = P(\bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} A_k) = P(\bigcap_{n=1}^{\infty} B_n) \overset{B_n\downarrow}{=\!=} P(\lim_{n\to\infty} B_n) = \lim_{n\to\infty} P(B_n)$

$= \lim_{n\to\infty} P(\bigcup_{k=n}^{\infty} A_k) \leq \lim_{n\to\infty} \sum_{k=n}^{\infty} P(A_k) = 0$ (Cauchy 准则)

$\lim_{n\to\infty} e^{-\sum_{k=n}^{\infty} P(A_k)} \to 0$.

$\because e^x \geq -x+1$ //

proof: 我们考虑反面：

$P(\limsup_{n\to\infty} A_n) = \lim_{n\to\infty} P(\bigcup_{k=n}^{\infty} A_k)$

则其反为： $\lim_{n\to\infty} P(\overline{\bigcup_{k=n}^{\infty} A_k}) = \lim_{n\to\infty} P(\bigcap_{k=n}^{\infty} \overline{A_k}) \overset{独立性}{=\!=} \lim_{n\to\infty} \prod_{k=n}^{\infty} P(\overline{A_k}) = \lim_{n\to\infty} \prod_{k=n}^{\infty} (1-P(A_k)) \leq \lim_{n\to\infty} \prod_{k=n}^{\infty} e^{-P(A_k)}$

2. 条件概率

设：$[\Omega, \mathcal{F}, P]$ 是概率空间。$A, B \in \mathcal{F}$，$P(A) > 0$，

定义，在 A 发生的条件下 B 发生的概率为 $P(B|A) = \dfrac{P(AB)}{P(A)}$.

下面说明 $P(\cdot|A)$ 也是一个概率测度.

① $P(B|A) \geq 0$ ✓

② $P(\Omega|A) = \dfrac{P(A\Omega)}{P(A)} = \dfrac{P(A)}{P(A)} = 1$ ✓

③ 可列可加：$P\left(\bigcup_{k=1}^{\infty} B_k | A\right) = \sum_{k=1}^{\infty} P(B_k|A)$ 其中 $B_i \cap B_j = \emptyset$.

proof：$P\left(\bigcup_{k=1}^{\infty} B_k | A\right) \xlongequal{\text{定义}} \dfrac{P\left(A \cap \left(\bigcup_{k=1}^{\infty} B_k\right)\right)}{P(A)}$

$= \dfrac{P\left(\bigcup_{k=1}^{\infty} (A \cap B_k)\right)}{P(A)}$

由于 B_k 两两不交，$A \cap B_k$ 两两不交

由 P 的可列可加性 $\dfrac{\sum_{k=1}^{\infty} P(AB_k)}{P(A)}$

$\xlongequal{\text{定义}} \sum_{k=1}^{\infty} P(B_k|A)$.

也就是说：$P(\cdot|A)$ 也满足 P 的一切性质

由条件概率定义式：$P(AB) = P(A)P(B|A)$

→ 乘法公式：$P(A_1A_2\cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1A_2)\cdots P(A_n|A_1\cdots A_{n-1})$

其中 $P(A_1A_2\cdots A_{n-1}) > 0$.

证：$P(A_1) \geq P(A_1A_2) \geq \cdots \geq P(A_1A_2\cdots A_{n-1}) > 0$.

从而各项有意义.

全概率公式：

(Ω, F, P) 是概率空间. $B, A_i \in F$. $P(A_i) > 0$. $\{A_i\}$是Ω的一个分割

$\Omega = \bigcup_{i=1}^{n} A_i \quad A_i \cap A_j = \emptyset$.

即为： $P(B) = P(A_1)P(B|A_1) + \cdots + P(A_n)P(B|A_n)$.

proof: $P(B) = P\left(\bigcup_{k=1}^{n}(BA_k)\right) = \sum_{k=1}^{n} P(BA_k) = \sum_{k=1}^{n} P(A_k)P(B|A_k)$.

由于到可加性，n 换成 ∞ 亦成立.

贝叶斯公式：已知 $\{P(B|A_i)\}_{i=1}^{n}$ 求 $P(A_i|B)$. 其中 $P(B) > 0$ $P(A_i) > 0$.

$$P(A_i|B) = \frac{P(A_iB)}{P(B)} = \frac{P(A_i)P(B|A_i)}{\sum_{k=1}^{n} P(A_k)P(B|A_k)}.$$

"逆向概率"：初始认知 + 新证据 = 修正后概率.

事件域的应用：

某人写了 n 封信，寄给 n 个人。

(1) 没有一封信寄对的概率 $q_0 = ?$

(2) 恰有 r 个信正确的概率 $q_r = ?$

解：(1) $P(\text{都错}) = 1 - P(\text{至少一个对})$　用 B_i 表示第 i 个信正确

$$= 1 - P\left(\bigcup_{i=1}^{n} B_i\right)$$

$P(B_i) = \frac{1}{n}$　$P(B_{i_1} B_{i_2}) = \frac{1}{n}\frac{1}{n-1}$　…　$P(B_{i_1} \cdots B_{i_r}) = \frac{1}{n}\frac{1}{n-1}\cdots\frac{1}{n-r+1}$

$$= \frac{(n-r)!}{(n-r)!\, n(n-1)\cdots(n-r+1)} = \frac{(n-r)!}{n!}$$

而：$P\left(\bigcup_{i=1}^{n} B_i\right)$ 容斥原理：

$$\frac{1}{1!} + (-1)^1\frac{1}{2!} + (-1)^2\frac{1}{3!} + \cdots + (-1)^{n-1}\frac{1}{n!}$$

于是 $q_0^{(n)} = \sum_{k=0}^{n} \frac{(-1)^k}{k!}$　当 $n \to \infty$ 时 $q_0^{(n)} \to \frac{1}{e}$

面对于 r：选法数为 C_n^r

而 $C_n^r \frac{(n-r)!}{n!}$

$$= \frac{n!}{r!(n-r)!}\frac{(n-r)!}{n!} = \frac{1}{r!}$$

(2) 恰有 r 个对 ⇒ 先看恰好 $\{1,2,\cdots,r\}$ 对　$\{r+1,\cdots,n\}$ 错。

$$P\left(\left(\bigcap_{i=1}^{r} B_i\right) \cap \left(\bigcap_{i=r+1}^{n} B_i^c\right)\right)$$

（$\bigcap_{i=1}^{r} B_i$ 记为 A；$\bigcap_{i=r+1}^{n} B_i^c$ 记为 C）

$$= P(A)\,P(C \mid A) = P(A)\cdot q_0(n-r)$$

$P(A)$：r 个对

$P(C \mid A)$：后续 $n-r$ 个全错

而 $P(A)$ 是 $\frac{1}{n}\cdot\frac{1}{n-1}\cdots\frac{1}{n-r+1} = \frac{(n-r)!}{n!}$

选法数：$C_n^r = \frac{n!}{r!(n-r)!}$

$$\Rightarrow q_r = \frac{n!}{r!(n-r)!}\cdot\frac{(n-r)!}{n!}\, q_0(n-r) = \frac{1}{r!}\cdot q_0(n-r) = \frac{1}{r!}\sum_{k=0}^{n-r}\frac{(-1)^k}{k!}$$

Lecture 3. 独立性,

1. 事件的独立性：

Def $(\Omega, \mathcal{F}, P)$ 是概率空间，$A, B \in \mathcal{F}$.

若 $P(AB) = P(A)P(B)$ 则称 A 与 B 独立，($A \perp B$).

注：① $\emptyset$ 与 Ω 与任何事件独立.（从而也提供不了任何信息）.

② A 与 B 独立 $\Rightarrow$ $\bar{A}$ 与 B / A 与 $\bar{B}$ / $\bar{A}$ 与 $\bar{B}$ 独立.

仅证一个： $P(AB) = P(A)P(B)$

则 $P(\bar{A})P(B) = P(\bar{A}B)$

LHS $= (1-P(A))P(B)$ RHS $= P(B) - P(AB)$ 得证 #

例题： A, B 互斥，$P(A) = P(B) > 0$ AB 独立否？

$P(AB) = 0$ $\neq \left(P^2(A) > 0\right)$ 不独立.

2. 事件的 条件独立性

Def： $(\Omega, \mathcal{F}, P)$ 是概率空间，$A, B, C \in \mathcal{F}$, $P(C) > 0$

若 $P(AB|C) = P(A|C)P(B|C)$ 则称 A 与 B 在给定 C 之下条件独立.

事件的独立性 与 条件独立性 有关吗？

$$P(AB(C) = P(A|C)P(B|C) \iff \frac{P(ABC)}{P(C)} = \frac{P(AC)}{P(C)}\frac{P(BC)}{P(C)}$$

$$\iff P(ABC)P(C) = P(AC)P(BC).$$

从而： $P(AB) = P(A)P(B) \Rightarrow P(ABC)P(C) = P(AC)P(BC)$

反过来：$\begin{cases} H_1: \text{第一次正面} \\ H_2: \text{第二次正面} \end{cases}$ $= P(AC)P(BC)$

假如 A, B, C 三者都独立 得证.

考虑掷硬币： A：第一次正面 B：第二次正面 C：第一与第二次不同

还是证明 (3.9 向上) $\mapsto$ B

$P(H_1|B)P(H_2|B) = P(H_1 \cap H_2|B)$

但是： $P(H_1)P(H_2) \neq P(H_1, H_2)$

从而经构造 A, B, C 不是三者独立的：

正反验合

$P(AB) = P(A)P(B)$ ✓

$P(ABC) = 0$ 而 $P(AC) = \frac{1}{2}\cdot\frac{1}{2} \neq \frac{1}{4}$

$P(BC) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4}$

$P(B)\times 0.9 + P(\bar{B})\times 0.1$

△

清华大学 Tsinghua University
姓名：
班级：
Lecture 4. 随机事件

3，多个事件的相互独立性

Def：$(\Omega, \mathcal{F}, P)$ 是概率空间，$A_1 \cdots A_n \in \mathcal{F}$.

若对任意非空子集 $S \subset \{1, 2, \cdots n\}$

$$P\left(\bigcap_{i\in S} A_i\right) = \prod_{i\in S} P(A_i)$$

则称 $A_1, A_2 \cdots A_n$ 相互独立.

例如：A_1, A_2, A_3 相互独立 $\Leftrightarrow$ $P(A_1A_2) = P(A_1)P(A_2)$

$P(A_1A_3) = P(A_1)P(A_3)$

$P(A_2A_3) = P(A_2)P(A_3)$

$P(A_1A_2A_3) = P(A_1)P(A_2)P(A_3)$

为什么要这么复杂？能不能 $P(A_1A_2\cdots A_n) = P(A_1)P(A_2)\cdots P(A_n)$ 呢？

反例：掷两次色子 $\Omega = \{(i,j) \mid 1\le i\le 6, 1\le j\le 6\}$

A_1：第一次掷 1,2,3

A_2：二次 3,4,5　　$P(A_1A_2A_3) = 0$

A_3：和为9.　　$P(A_1) = \frac{1}{2}$

能不能改成 $\forall i \neq j$，$P(A_iA_j) = P(A_i)P(A_j)$ [即 A_i, A_j 两两独立]

反例：掷硬币，A_1：第一次 +　　$P(A_1) = \frac{1}{2}$　$P(A_2) = \frac{1}{2}$　$P(A_3) = \frac{1}{2}$

A_2：第二次 +

A_3：一、二不同　　$P(A_1A_2) = \frac{1}{4}$　$P(A_1A_3) = \frac{1}{4}$　$P(A_2A_3) = \frac{1}{4}$

但，$P(A_1A_2A_3) = 0$ ☆.

Lecture 4. 随机变量.

一. 随机变量 是 样本空间 到 $\mathbb{R}$ 的映射.

条件: 对一个概率空间 (Ω, F, P) 而言. $X(\omega)$ 是 Ω 上的 随机变量

对于实数域的某个子集 B. $X \in B$ 对应样本空间的一个子集

$$X^{-1}(B) := \{\omega \mid X(\omega) \in B\}$$

$$P(X \in B) = P(X^{-1}(B)) \Rightarrow \boxed{X^{-1}(B) \in F}$$

因此: Step 1: 对于实数域某个子集 B. $X \in B$ 的概率记为 $P(X^{-1}(B))$

$$X^{-1}(B) := \{\omega \mid X(\omega) \in B\} \quad \text{从而} \quad X^{-1}(B) \in F$$

Step 2: 希望: $\forall$ 子集 A. $A \in \mathcal{B}$ (即 Borel 域里的 Borel 集)

↑ 之前(1) $X \in \mathbb{R}$ 的概率都能计算

Step 3: 可以证明: 只要要求 $\forall A \in \{(-\infty, x] \mid x \in \mathbb{R}\}$ $X^{-1}(A) \in F$

Def: 随机变量

设 (Ω, F, P) 为概率空间. 若 Ω 上实函数 $X(\omega)$ 满足:

$$\forall x \in \mathbb{R}. \quad \{\omega \mid X(\omega) \le x\} \in F$$

则称. $X(\omega)$ 为随机变量. 简记为 X.

定理 1.1. $(\Omega, \mathcal{F}, P)$ 为概率空间 X 是 Ω 上的随机变量

则：对于任意的 Borel 集 B，有：$\{X \in B\} := \{\omega \mid X(\omega) \in B\} \in \mathcal{F}$。

proof：对 $B \subset \mathbb{R}$，令 $X^{-1}(B) = \{\omega \mid X(\omega) \in B\}$　　$\tilde{\mathcal{B}} = \{B \mid X^{-1}(B) \in \mathcal{F},\ B \subset \mathbb{R}\}$

我们希望 $\mathcal{B} \subset \tilde{\mathcal{B}}$

逻辑：

条件：$\forall x \in \mathbb{R}, \ldots \{\omega \mid X(\omega) \le x\} \in \mathcal{F}$

要证：$\forall B \in \mathcal{B}, \{\omega \mid X(\omega) \in B\} \in \mathcal{F}$

即证 $\mathcal{C}_X$ 是良定的.

proof：① X 的性质是 $\forall x \in \mathbb{R}$ $\{\omega \mid X(\omega) \le x\} \in \mathcal{F}$

那么 $\mathcal{A} = \{(-\infty, x] \mid x \in \mathbb{R}\} \subset \tilde{\mathcal{B}}$

$\tilde{\mathcal{B}} = \{B \mid X^{-1}(B) \in \mathcal{F},\ B \subseteq \mathbb{R}\}$

条件 $\Longleftrightarrow \{(-\infty, x]\} \in \tilde{\mathcal{B}}$

σ 代数？

即 $\tilde{\mathcal{B}}$ 包含了 $\mathcal{A}$.

proof：我们要 $\tilde{\mathcal{B}}$ 是 σ 域 从而 $\mathcal{B} \subseteq \tilde{\mathcal{B}}$

① $\mathbb{R}$ 是否 $\in \tilde{\mathcal{B}}$ ？

$X^{-1}(\mathbb{R}) = \{\omega \mid X(\omega) \in \mathbb{R}\} = \Omega \in \mathcal{F}$

从而 $\mathbb{R} \in \tilde{\mathcal{B}}$

② 若 $A \in \tilde{\mathcal{B}}$，是否 $A^c \in \tilde{\mathcal{B}}$ ？

proof：$A \in \tilde{\mathcal{B}}$ 即 $X^{-1}(A) = \{\omega \mid X(\omega) \in A\} \in \mathcal{F}$.

那么 $X^{-1}(A^c) = \{\omega \mid X(\omega) \in A^c\} = \left[\{\omega \mid X(\omega) \in A\}\right]^c = \left(X^{-1}(A)\right)^c$

由 $X^{-1}(A) \in \mathcal{F}$ 知 $\left(X^{-1}(A)\right)^c \in \mathcal{F}$ 从而 $A^c \in \mathcal{F}$

$\tilde{\mathcal{B}} = \{B \mid X^{-1}(B) \in \mathcal{F},\ B \subset \mathbb{R}\}$

简记：定义 $\tilde{\mathcal{B}}$ = 逆像属于 $\mathcal{F}$ 的全体子集.

由我们对 X 的认识：$\{X(\omega) \le x\} \in \mathcal{F}$

于是 $(-\infty, x]$ 的逆像 $\in \mathcal{F}$

于是 $(-\infty, x] \in \tilde{\mathcal{B}}$

下面①②③说明 $\tilde{\mathcal{B}}$ 是个 σ-代数

且 $(-\infty, x] \in \tilde{\mathcal{B}}$

而 $\mathcal{B}$（Borel 域）是包含 $(-\infty, x]$ 的最小 σ-代数

故 $\mathcal{B} \subseteq \tilde{\mathcal{B}}$

也就是：任何一个 Borel 域中的集合 B 都一定有 $\{X^{-1}(B) \in \mathcal{F}\}$

也即 概率可测

③ 若 $A_1, \ldots, A_n, \ldots \in \tilde{\mathcal{B}}$ 是否 $\bigcup_{n=1}^{\infty} A_n \in \tilde{\mathcal{B}}$ ？

$A_i \in \tilde{\mathcal{B}}$ 即 $X^{-1}(A_i) = \{\omega \mid X(\omega) \in A_i\} \in \mathcal{F}$

那么 $X^{-1}\left(\bigcup_{n=1}^{\infty} A_n\right) = \{\omega \mid X(\omega) \in \bigcup_{i=1}^{\infty} A_i\}$

$= \bigcup_{i=1}^{\infty} \{\omega \mid X(\omega) \in A_i\}$

$= \bigcup_{n=1}^{\infty} X^{-1}(A_i) \in \mathcal{F}$

从而 $\mathcal{B} \subseteq \tilde{\mathcal{B}}$ 即 $\mathcal{A} \subseteq \tilde{\mathcal{B}} \Rightarrow \mathcal{A}$ 是 σ 域 #

定理1.1 的理解. 把 R 看成映射后的样本空间. $\mathcal{B}$ 是 R 上.

若 $B \in \mathcal{B}$ 有 $X^{-1}(B) \in \mathcal{F}$

$\longrightarrow$ 映射后的概率空间为 $(R, \mathcal{B}, P)$.

像集在 Borel 域中
那么原像集在事件域中.
而事件域中定义了概率测度.
于是存在概率测.

对 Borel 可测函数.

若对于任意 $x \in R$. f(实函数) 满足 $f^{-1}((-\infty, x]) := \{t \mid f(t) \le x\} \in \mathcal{B}$.

则称 f 为 Borel 可测函数.

定理1.2, $(\Omega, \mathcal{F}, P)$ 为概率空间. X 为 Ω 上随机变量 f 为可测函数

$\Longrightarrow$ $Y = f(X)$ 也是随机变量.

proof: 对于任意给定的 x.

$$\{w \mid Y \le x\} = \{w \mid f(X) \le x\} = \{w \mid X \le f^{-1}(x)\}$$

$f^{-1}(x)$ 表示 $f^{-1}((-\infty, x]) = \{t \mid f(t) \le x\}$

由于 f 可测: $f^{-1}(x) \in \mathcal{B}$ (x).

对于 $\{w \mid X \le f^{-1}(x)\}$ 由于

proof: 对于任意给定的 x.

$\{w \mid Y(w) \le x\} = \{w \mid f(X(w)) \le x\}$

令 B 表示: $\{t \mid f(t) \le x\}$
B 是 Borel 集 (由 f 可测)

$= \{w \mid X(w) \in B\}$

f 可测, $B \in \mathcal{B}$ (定理1.1) $\Rightarrow$ $\{X \in B\} \in \mathcal{F}$ (由定理1.1)

$\forall x \in R$.
因此: $\{w \mid Y(w) \le x\} \in \mathcal{F}$.

从而 Y 是随机变量. #

△

推广：$X_1 \cdots X_n$ 为随机变量　　$g(X_1 \cdots X_n)$ 为 n 元可测函数

$\Rightarrow Y = g(X_1, \cdots X_n)$ 也是随机变量.

$aX+bY$.　XY.　$\frac{X}{Y}$

- $\sup_n X_n$　$\inf_n X_n$.　$\limsup_n X_n$　$\liminf_n X_n$.　$\lim_n X_n$
- $\max\{X, Y\}$　e^X.　X^+　X^-　$|X|^p$.
- 复合函数　…

二. 随机变量的独立性：

Def $X_1 \cdots X_n$ 为 $(\Omega, \mathcal{F}, P)$ 上的随机变量，$\forall x_1 \cdots x_n \in \mathbb{R}$

若：$P\{X_1 \le x_1, X_2 \le x_2, \cdots X_n \le x_n\} = P\{X_1 \le x_1\} \cdots \cdot P\{X_n \le x_n\}$

则称 $X_1 \cdots X_n$ 独立.

补充：相互独立 $\Rightarrow$ 两两独立.

$$P\{X_1 \le x_1, X_2 \le x_2, X_3 \le x_3\} = P\{X_1 \le x_1\} P\{X_2 \le x_2\} P\{X_3 \le x_3\}$$

$$\rightarrow P\{X_1 \le x_1, X_2 \le x_2\} = P\{X_1 \le x_1\} P\{X_2 \le x_2\}$$

pf: $P\{X_1 \le x_1, X_2 \le x_2\} = P\{X_1 \le x_1, X_2 \le x_2, X_3 \in \mathbb{R}\}$

$$= P\{X_1 \le x_1, X_2 \le x_2, \bigcup_{n=1}^{\infty} \{X_3 \le n\}\}$$

$$= P\{\bigcup_{n=1}^{\infty} \{X_1 \le x_1, X_2 \le x_2, X_3 \le n\}\}$$

$$= \lim_{n \to \infty} P\{X_1 \le x_1, X_2 \le x_2, X_3 \le n\}$$

$$= \lim_{n \to \infty} P\{X_1 \le x_1\} P\{X_2 \le x_2\} P\{X_3 \le n\}$$

$$= P\{X_1 \le x_1\} P\{X_2 \le x_2\} P\{\lim_{n \to \infty} X_3 \le n\}$$

$$= P\{X_1 \le x_1\} P\{X_2 \le x_2\} P\{\bigcup_{n=1}^{\infty} \{X_3 \le n\}\}$$

$$= P\{X_1 \le x_1\} P\{X_2 \le x_2\} P\{X_3 \in \mathbb{R}\}$$

$$= P\{X_1 \le x_1\} P\{X_2 \le x_2\} \cdot 1 = RHS$$

△

补充 2. 定理 2.1

$X_1 \cdots X_n$ 相互独立 $\Leftrightarrow$ $\forall$ Borel 集 $B_1 \cdots B_n$

$\{X_1 \in B_1\}$ -- $\{X_n \in B_n\}$ 相互独立

定理 2.2.

$X_1 \cdots X_n$ 相互独立 $g_1 \cdots g_n(x)$ 一元实可测函数 $\varphi(x_1 \cdots x_k)$ 为 k 元 ~

① $g_1(X_1) \cdots g_n(X_n)$ 相互独立

② $\varphi(X_1 \cdots X_k)$ 与 $X_{k+1} \cdots X_n$ 相互独立.

即: (X_1, X_2, X_3, X_4) 相互独立. $\Rightarrow$ $\frac{X_2}{X_1^2}$ 与 $\frac{X_3+X_4}{2}$ 相互独立

Def 独立序列 与 独立同分布

独立序列 → $X_1 \cdots X_n$ 相互独立

$\forall n \geq 1$

$\{X_i\}$ 为独立序列

独立同分布 → $X_1 \cdots X_n$ 相互独立 且 概率测度相同.

三、离散型随机变量

Def 离散型随机变量：X 只取有限/可列个值 $x_1 \cdots x_k \cdots$

且 X 为随机变量

Def 概率~~分布~~质量函数 PMF / 分布列

X	x_1	x_2	$\cdots$
P	p_1	p_2	$\cdots$

$p_k \geq 0$ $\sum_{k=1}^{\infty} p_k = 1$.

来三：

1. 两点分布（Bernoulli 分布）

X	0	1
P	$1-p$	p

2、二项分布（Binomial 分布）

$$P(X=k) = C_n^k p^k (1-p)^{n-k}, \quad k=0,1,\cdots n.$$

$p \in (0,1)$ $X \sim B(n,p)$.

① 若 $X_1 \cdots X_n \overset{iid}{\sim} B(1,p)$ $\Rightarrow X = X_1 + \cdots + X_n \sim B(n,p)$

② 若 $X_1 \sim B(n,p)$ $X_2 \sim B(m,p)$ 且 相互独立

$\Rightarrow X = X_1 + X_2 \sim B(n+m,p)$.

注释1. 二项分布取最大值的 k：$k_0 = \lfloor (n+1)p \rfloor$ 或 $(n+1)p, (n+1)p-1$

3. 几何分布 $P(X=k) = (1-p)^{k-1}p \quad k=1,2,\cdots$

↗ 一直射击，直至射中.

$X \sim G(p)$.

定理 3.2 几何分布的无记忆性：

$$P(X=m+n \mid X>n) = P(X=m)$$

proof: $P(X=m+n \mid X>n) = \dfrac{P(X=m+n)}{P(X>n)}$

$$= \frac{(1-p)^{m+n-1}p}{1-P(X\le n)}$$

$$= \frac{(1-p)^{m+n-1}p}{1-[p+p(1-p)^1+\cdots+p(1-p)^{n-1}]}$$

$$= \frac{(1-p)^{m+n-1}}{\frac{1}{p}-[1+(1-p)^1+\cdots+(1-p)^{n-1}]}$$

$\dfrac{1\cdot(1-p)^n}{1-(1-p)} = \dfrac{(1-p)^n}{p}$

$$= \frac{(1-p)^{m+n-1}p}{1-(1-p)^n}$$

$\dfrac{(1-p)^n p\cdot[1+\cdots]}{1-(1-p)^n p}$

$$= \frac{(1-p)^{m+n-1}p}{P(X>n)} \quad P(X>n) = \sum_{k=n+1}^{\infty}(1-p)^{k-1}p$$

$$= \frac{(1-p)^{m+n-1}p}{(1-p)^n} = (1-p)^{m-1}p = P(X=m) \quad \#.$$

拓展： X 有无记忆性 且 X 取正整数值 $\Longrightarrow$ ~~不是答~~ $X \sim G(p)$.

proof: $P(X=m+n \mid X>n) = P(X=m) \quad \forall m \geq 1 \quad n \geq 1$ 成立.

$\Rightarrow$ $P(X>m+n \mid X>n) = P(X>m)$

$p_k = P(X>k)$ 即： $p_{m+n} = p_m \cdot p_n$. $\forall m \geq 1 \quad n \geq 1$

$\Rightarrow p_k = p_1^k$

$$P(X=k) = P(X>k-1) - P(X>k)$$
$$= p_{k-1} - p_k$$
$$= p_1^{k-1} - p_1^k = p_1^{k-1}(1-p_1)$$

令 $1-p_1=q$ $\boxed{(1-q)^{k-1}q}$ 此即 $G(q)$ #

4. 帕斯卡分布： 直到击中 r 次， $p \in (0,1)$ 总之数.

$$P(X=k) = C_{k-1}^{r-1} p^r (1-p)^{k-r}. \quad k=r, r+1, \cdots$$

5. 负二项分布 直到 击中 r 次 $p \in (0,1)$ 成功 失败的之数.

$$P(X=k) = C_{k+r-1}^{r-1} p^r (1-p)^{k-1}(1-p) = C_{k+r-1}^{r-1} p^r (1-p)^k \quad k=0,1,2\cdots$$

$Y \sim NB(r,p)$

清华 Weiyang College

6. 泊松分布 (Poisson)

$X_n \sim B(n, p_n)$ $\quad P(X_n=k) = C_n^k p_n^k (1-p_n)^{n-k}$ $\quad \lim_{n\to\infty} np_n = \lambda$

$$\Rightarrow \lim_{n\to\infty} P(X_n=k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

proof: $P(X_n=k) = C_n^k p_n^k (1-p_n)^{n-k}$

$$= \frac{\overbrace{n(n-1)\cdots(n-k+1)}^{k\text{个}}}{k!} p_n^k (1-p_n)^{n-k}$$

$$= \frac{1}{k!}\left(\frac{p_n}{1-p_n}\right)^k (1-p_n)^n \, n(n-1)\cdots(n-k+1)$$

$$= \frac{1}{k!} \frac{(np_n)^k}{(1-p_n)^k} \left[1\right]\left[1-\frac{1}{n}\right]\cdots\left[1-\frac{k}{n}+\frac{1}{n}\right](1-p_n)^n$$

$$= \frac{(np_n)^k}{k!} (1)\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{k-1}{n}\right) (1-p_n)^{n-k} \left(1-\frac{np_n}{n}\right)^n (1-p_n)^{-k}$$

$\xrightarrow{n\to\infty}$ $\frac{\lambda^k}{k!} e^{-\lambda}$ #

$$e^{-np_n} \approx \left(1-\frac{np_n}{n}\right)^n.$$

Poisson 分布: $P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$ $\quad k=0,1,2\cdots$

$X \sim P(\lambda)$ $\quad \lambda > 0$.

作业纸

班级： 姓名： 学号： 科目： 第 页

Lecture 5 随机变量及其概率分布之一

一. 连续型随机变量：

Def： 若 ∃非负函数 $f(x)$，使得 $\forall a<b$，$P(a<X\le b)=\int_a^b f(x)\,dx$

则称 X 是连续型随机变量。$f(x)$ 为 X 的概率密度函数，PDF

注意：连续型随机变量指的是概率 = 某个函数积分的随机变量。

$f(x)$ 的特点：① $f(x)\ge 0$

② $\int_{-\infty}^{+\infty} f(x)=1$

$f(x)$ 不一定有界：$f(x)=\frac{1}{\sqrt{x}}$ $x\in(0,1]$

任意单点概率为0：$P(X=a)\le P(X\in(a-\varepsilon,a])=\int_{a-\varepsilon}^{a} f(x)\,dx$

当 $\varepsilon\to 0$ 时 $\to 0$

1. 指数分布：$f(x)=\begin{cases}\lambda e^{-\lambda x} & x\ge 0\\ 0 & x<0\end{cases}$ $\lambda>0$ $X\sim Exp(\lambda)$

常用结论：$P(X\ge a)=e^{-\lambda a}$ $\forall a\ge 0$

无记忆性：$P(X>s+t\mid X>s)=P(X>t)$

$\forall s,t\ge 0$.

无记忆性是指数分布的充要条件（在连续型非负随机变量中）

Proof：$P(X>s+t\mid X>s)=P(X>t)$

$\Longleftrightarrow P(X>s+t)=P(X>s)P(X>t)$

记 $G(k)=P(X>k)$

于是：$G(s+t)=G(s)G(t)$

取对数：$\log G(s+t)=\log G(s)+\log G(t)$

$\Rightarrow \log G(x)=[\log G(1)]\,x$

$\Rightarrow G(x)=e^{-\lambda x}$ $\lambda=-\log P(X>1)$

#

2. 正态分布: $N(\mu, \sigma^2)$

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x\in R. \quad X\sim N(\mu,\sigma^2)$$

当 $X\sim N(0,1)$ 时 $\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$ $x\in R$

记 $\Phi(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$

① $f(x)$ 关于 x 对称 ② $f(\mu)=\frac{1}{\sqrt{2\pi}\sigma}$ 是最大值.

③ $F(x)$ 形如:

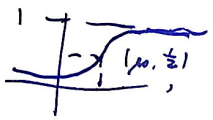

于是 $F(x)+F(\mu-x)=1$

3. 均匀分布

$$f(x)=\begin{cases}\frac{1}{b-a} & x\in(a,b)\\ 0 & x\notin(a,b)\end{cases} \qquad X\sim U(a,b).$$

二. 概率分布函数.

Def: 对于一随机变量 X. $F(x)=P(X\le x)$, $x\in R$.

称为 X 的分布函数 CDF

① $F(x)\uparrow$

② $F(+\infty)=1$ $F(-\infty)=0$

③ $F(x)$ 右连续 (因为定义中 $P(X\le x)$)

proof: ②: $F(+\infty)=P\left(X\in\lim_{n\to\infty}(-\infty,n]\right)=P(X\in R)=1$

$$F(-\infty)=P\left(X\in\lim_{n\to\infty}(-\infty,-n]\right)=P(X\in\emptyset)=0.$$

③ $\lim_{n\to\infty}F(x+\frac{1}{n})=\lim_{n\to\infty}P(X\le x+\frac{1}{n})$ $P(X\in(-\infty,x])=F(x)$

$$=P\left(\bigcap_{n=1}^{+\infty}\{X\le x+\tfrac{1}{n}\}\right)$$

连续是随机变量的"连续"就是 $F(x)$ 连续.

作业纸

班级： 姓名： 学号： 科目： 第 页

三. CDF. PMF/PDF 的 相互关系 (★)

分类：

① 离散型： PMF ⇌ CDF 可互推！

例： 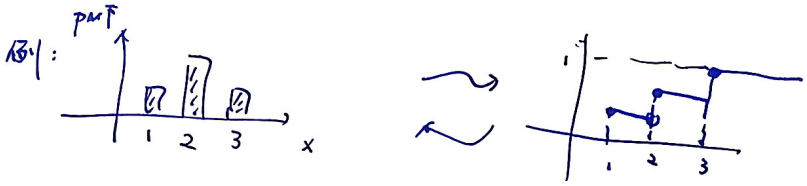

② 连续型： PDF ⟶ CDF

从左往右： $F(x)=\int_{-\infty}^{x} f(t)\,dt$ ✓

从右往左： 必须要求 $f(x)$ 连续点： $f(x)=F'(x)$

对于其余点：不可测，不关心，实际做题 令其 $=0$ 即可。

WEIYANG COLLEGE TSINGHUA UNIVERSITY
清华大学未央书院

作业纸

班级： 姓名： 学号： 科目： 第 页

Lecture 6. 再谈 随机变量及其概率分布总收

① 已知：连续型随机变量 $X \Rightarrow F(x)$ 连续

$\Leftarrow$?

逆命题 是错的！ Cantor 分布

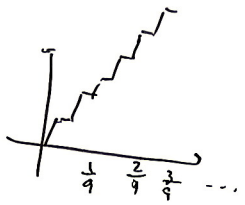

写不出 $f(x)$

但 $F(x)$ 不连续 $\Rightarrow$ X 一定不是连续型随机变量

② 对于 $\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$ $\rightsquigarrow$ $\Phi(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$

正态分布的标准化：$X\sim N(\mu,\sigma^2)$ 时 $\Rightarrow$ $\frac{X-\mu}{\sigma}\sim N(0,1)$

即：$P(X\le a)=\Phi\left(\frac{a-\mu}{\sigma}\right)$.

正态分布的 3σ 方则：$P(|X-\mu|\le 3\sigma)=\Phi(3)-\Phi(-3)=99.73\%$

当观测值落在 $\mu\pm 3\sigma$ 之外 $\Rightarrow$ 异常值.

③ CDF 的其他作用，探讨 离散 和 连续 随机变量 的关系.

例如 $G(p)$ 与 $E(\lambda)$

$X_1\sim E(\lambda)$：$F(x_1)=1-e^{-\lambda x_1}$ $x_1>0$

$X_2\sim G(p)$：$F(x_2)=1-(1-p)^n$ $n=[x_2]$

$F(x_1)=F(x_2)$ 时 $\Rightarrow$ $e^{-\lambda x_1}=(1-p)^n$

$\Rightarrow$ $x_1=-\ln\frac{(1-p)}{\lambda}[x_2]$

记 $\delta=-\ln\frac{(1-p)}{\lambda}$

$\Rightarrow$ $x_1=\delta x_2$

即：$F_1(n\delta)=G(n)$

二. 随机向量。

Def: n维随机向量:

$X_1 \cdots X_n$ 都是 (Ω, F, P) 上的随机变量，则称 $X = (X_1 \cdots X_n)$ 是 (Ω, F, P) 的 n维随机向量

Def: 联合概率分布函数: joint CDF:

$\vec{X} = (X_1 \cdots X_n)$ 是随机向量

则: $F(x_1, x_2, \cdots x_n) = P(X_1 \le x_1, X_2 \le x_2, \cdots X_n \le x_n)$

是 $\vec{X}$ 的联合概率分布函数. (联合分布).

① $F(x_1 \cdots x_n)$ 是 R^n 上的 为连记函数

② $F(x_1 \cdots x_n)$ 关于 x_k: 单调非减

③ $F(\vec{x}) = P(\vec{X} \le \vec{x}) \Leftrightarrow X_j \le x_j \quad \forall j = 1, 2 \cdots n.$

独立性: 若 $X_1 \cdots X_n$ 相互独立

定义: $P(X_1 \le x_1, \cdots X_n \le x_n) = P(X_1 \le x_1) \cdots P(X_n \le x_n)$

此即 $F(X_1, X_2, \cdots X_n) = F_1(x_1) \cdots F_n(x_n)$

其中 F_1 $F_2 \cdots$ F_n 表示 $x_1 \cdots x_n$ 的概率分布函数

Def: 边沿分布:

$\forall 1 \le k < n$, $S_k = \{i_1 \cdots i_k\}$ 为指标集 $\vec{X}_{S_k} = (X_{i_1}, X_{i_2}, \cdots X_{i_k})$

$F_k(x_{i_1}, \cdots x_{i_k}) = P(X_{i_1} \le x_{i_1}, \cdots X_{i_k} \le x_{i_k})$

$= P(X_j \le x_j, j \in S_k, X_t \le \infty, t \in S_k^C)$

称为 $(x_1 \cdots x_n)$ 的 k-维 边沿分布

注意: 边沿分布 就是 舍不研究的 对象 (S_k^C 中的变量) 趋于 $+\infty$.

于是: 边沿 可由 联合 唯一确定!

作业纸

班级： 姓名： 学号： 科目： 第 页

反过来 $F_X(x)$ $F_Y(y)$ 不能确定 $F_{X,Y}(x,y)$

例如：考虑 2个正态分布 函数 $X\sim N(\mu_1,\sigma_1^2)$

$Y\sim N(\mu_2,\sigma_2^2)$

$X+Y\sim ?N$

X

事实上：$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}e^{-\frac{1}{2}\left(\frac{\frac{(x-\mu_1)^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}-2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right)}{1-\rho^2}\right)}$

与 ρ 有关. 当 $\rho=1$ 时 退化为 $Y=a+bX$.

$F(x,y)=P(X\le x, Y\le y)=\Phi\left(\min\left(\frac{x-\mu_1}{\sigma_1},\frac{y-\mu_2}{\sigma_2}\right)\right)$

所以：边缘 $\not\Rightarrow$ 联合. Copula 函数：$C(\cdot):[0,1]^n\to[0,1]$

$F(x_1\cdots x_n)=C\left(F_{x_1}(x_1),\cdots F_{x_n}(x_n)\right)$

基本认识：边缘 $\not\Rightarrow$ 联合

$\not\Leftarrow$

三. 离散型随机向量

Def: $X_1 \cdots X_n$ 都是离散型随机变量 $\Rightarrow \vec{X}$ 是 $\sim$

$P(X_1=x_1, X_2=x_2, \cdots X_n=x_n)$ 称为 $\vec{X}$ 的联合分布列: joint pmf.

① $P(X_1=x_1, \cdots X_n=x_n) \geq 0$

② $\sum_{x_1} \sum \sum \cdots \sum_{x_n} P = 1$

表格法: 二维情形列表:

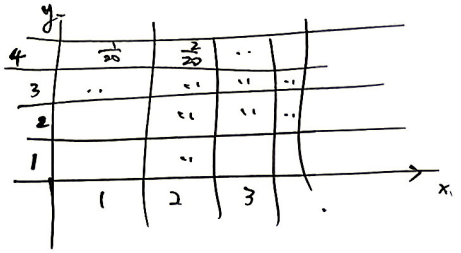

找出对应格点求和即可.

联合 $\Rightarrow$ 边际:

Def: $\vec{X} = (X_1 \cdots X_n)$ 为离散型随机向量.

则 $P(X_{j1}=x_{j1}, \cdots X_{jk}=x_{jk})$

$= \sum_{x_{jk+1} \cdots x_{jn}} P(X_1=x_1 \cdots X_n=x_n)$

就是把其余变量求和

边际 $\not\Rightarrow$ 联合

如:

X \ Y	0	1	
0	0.5		0.5
1		0.5	0.5
	0.5	0.5	

X \ Y	0	1	
0		0.5	0.5
1	0.5		0.5
	0.5	0.5	

joint pmf $\rightarrow$ joint CDF: 求和

$\leftarrow$: $P(X=3, Y=3) = F(3,3) - F(2,3) - F(3,2) + F(2,2)$

即 $p_{ij} = F(x_i, x_j) - F(x_i, x_{j-1}) - F(x_{i-1}, x_j) + F(x_{i-1}, x_{j-1})$

独立性: $P(X_1=x_1, \cdots X_n=x_n) = \prod_{i=1}^{n} P(X_i=x_i)$

即: 联合 pmf = 边际 pmf 之积

利用 $p_{ij} = F_{ij} - F_{i,j-1} - F_{i-1,j} + F_{i-1,j-1}$ 立得.

作业纸

班级： 姓名： 学号： 科目： 第 页

四 连续型随机向量.

Def: 对于 $\vec{X}=(X_1,\cdots X_n)$ 若 $\exists$ 非负的 $f(x_1\cdots x_n)$

使得 $D=\{(x_1\cdots x_n)\mid a_i<x_i\le b_i \quad 1\le i\le n\}$

$$P(\vec{X}\in D)=\int_{\text{区域}\to n\text{维面积}} f(x_1\cdots x_n)\,dx_1\cdots dx_n=\int_D f(\vec{x})\,d\vec{x}$$

则称 $\vec{X}$ 是连续型随机向量

$f(\vec{x})$ 是联合密度. joint PDF

联合概率分布函数 —多元函数的积分

联合 $\Rightarrow$ 边缘: $f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy$ $\quad f_Y(y)=\int_{-\infty}^{+\infty} f(x,y)\,dx$

proof:

$$\begin{aligned}P(X\le x_1)&=P(\lim_{n\to\infty}\{X\le x,\ Y\le n\})\\&=\lim_{n\to\infty}\int_{-\infty}^{x_1}\int_{-\infty}^{n} f(x,y)\,dy\,dx\\&=\int_{-\infty}^{x_1}\left(\lim_{n\to\infty}\int_{-\infty}^{n} f(x,y)\,dy\right)dx\\&=\int_{-\infty}^{x_1} f_X(x)\,dx.\end{aligned}$$

此即：连续型随机向量的每个维度都是连续型随机变量.

反过来则不一定. 反例: $X\sim N(0,1)$

$Y\sim N(0,1)$ $\quad\rightarrow (X,Y)$ 的联合分布在 $y=x$ 上 无 joint PDF

$\rho=1$

边缘 $\not\Rightarrow$ 联合.

又：边缘函数：$(X_{j_1}\cdots X_{j_k})$ 的边缘密度是：

$$f_k(x_{j_1}\cdots x_{j_k})=\int_{R^{n-k}} f(x_1\cdots x_n)\,dx_{j_{k+1}}\cdots dx_{j_n}.$$

joint PDF → joint CDF

利用 $F(x_1 \cdots x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(\vec{x})\, d\vec{x}$

joint CDF ⋯⋯→ joint PDF

若在 (x,y) 邻域内：F_x F_y F_{xy} F_{yx} 都连续

$$f(x,y) = F_{xy} = F_{yx}$$

因此，我们不作一维的对称. 给出CDF再求导的PDF

求联合的 PDF 我们用其他方法.

独立性：若 $f(x_1 \cdots x_n) = f_1(x_1) \cdots f_n(x_n)$ 则 $x_1 \cdots x_n$ 相互独立.

联合 PDF = 边际 PDF 之积 $\Leftrightarrow$ 独立

二元正态：$f(x,y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left(\left(\frac{x-\mu_1}{\sigma_1}\right)^2 + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 - 2\frac{\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}\right)\right)$

记作 $(X,Y) \sim (\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$ $\rho \in (-1,1)$

若已知 $f(x,y)$ 为二元正态 $\Rightarrow$ $f_X(x)$ 也一定是一元正态，且参数是 (μ_1, σ_1^2)
$f_Y(y)$ (μ_2, σ_2^2)

独立 $\Leftrightarrow$ $\rho = 0$

向量形式：令 $\vec{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ $\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$ $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$

$$f(\vec{x}) = \frac{1}{\sqrt{(2\pi)^2 |\Sigma|}} \exp\left(-\frac{1}{2}(\vec{x}-\mu)^T \Sigma^{-1} (\vec{x}-\mu)\right)$$

作业纸

班级： 姓名： 学号： 科目： 第 页

Lecture 7. 随机变量函数的分布

~ 向量 ~

一. 随机变量函数.

Case 1：函数是：$Y=g(X)$ 也是函数

于是 对于每个 x，求对应 y 的值，并附上概率即可.

例：

X	-2	-1	0	1	3
P	0.1	0.2	0.3	0.2	0.2

$\Rightarrow$ $Y=X^2$

Y	0	1	4	9
P	0.3	0.4	0.1	0.2

Case 2：连续型.

1. $Y=g(X)$ 也是连续型随机变量 $\Rightarrow$ 先求 Y 的 CDF，再求导得 PDF

$$F_Y(y)=P(Y\le y)=P(g(X)\le y)$$

$$f_Y(y)=F_Y'(y)$$

例：$X\sim N(0,1)$ $Y=X^2$

Step 1：Y 的范围 ≥ 0

Step 2：$\forall y>0$ $F_Y(y)=P(Y\le y)=P(-\sqrt{y}\le X\le\sqrt{y})$

$$=\Phi(\sqrt{y})-\Phi(-\sqrt{y})$$

$$=2\Phi(\sqrt{y})-1$$

Step 3：$\Rightarrow$ $f_Y(y)=2\varphi(\sqrt{y})\frac{1}{2\sqrt{y}}=\frac{1}{\sqrt{2\pi y}}e^{-\frac{y}{2}}$, $y>0$

WEIYANG COLLEGE TSINGHUA UNIVERSITY
清华大学未央书院

2. 公式法：对于 单调情形

$Y=g(X)$　$g(x)$ 严格单调

开始：$F_Y(y)=P(g(X)\le y)=P(X\le g^{-1}(y))=F_X(g^{-1}(y))$

$\Rightarrow$ $f_Y(y)=f_X(g^{-1}(y))\left|(g^{-1}(y))'\right|$ ← 这个是对 y 的导数.

这个过程理解成：

Step 1：反解 $X=g^{-1}(Y)$

Step 2：公式：$f_Y(y)=f_X(\underset{\text{把 } x=g^{-1}(y) \text{ 代入}}{g^{-1}(y)})\boxed{|x'(y)|}$ ← 洗完有化对值.

↑ 添加一个 x 对 y 的导数

例：$X\sim U(0,1)$　$Y=X^2$

$f_X(x)=1$　$x\in[0,1]$

↓

$x=\sqrt{y}$ 单调（在 $[0,1]$ 上）

↓

x 对 y：$\frac{1}{2\sqrt{y}}$

$f_Y(y)=1\cdot\frac{1}{2\sqrt{y}}$　$Y\in[0,1]$

$=\frac{1}{2\sqrt{y}}$　$y\in(0,1)$.

3. 若在 D 上不单调 $\Rightarrow$ 把 D 分拆成 $D_1\cdots D_n$

把 D_i 内 $f(h_i(y))\left|h_i'(y)\right|$ 求出后 求和.

（常用 ★）

总结：求 $g(X)$ 分布
- $g(X)$ 离散 $\Rightarrow$ 求和
- $g(X)$ 连续
  - 通法 $\Rightarrow$ $F_Y(y)$ $\xrightarrow{\text{求}}$ $f_Y(y)$
  - 公式法 $\Rightarrow$ 反解 + 代入 + 求导

POF

作业纸

班级： 姓名： 学号： 科目： 第 页

二. 随机向量函数

$g(x)$ 可能是一维，也可能是多维.

$Z = X+Y$

$(U,V) = (X,Y)$ A

Part 1：一维情形.

Case 1. 通法：$F_Z(z) = P(Z(x,y) \le z) = \iint_D f(x,y)\,dxdy$. 然后求导得 $f_Z(z)$

例：$R = \sqrt{X^2+Y^2}$ $X,Y \overset{iid}{\sim} N(0,1)$

$R \ge 0$ 则 $\forall r > 0$ $F_R(r) = P(\sqrt{X^2+Y^2} \le r)$

$$= \iint_{x^2+y^2 \le r^2} \frac{1}{2\pi} \exp\left(-\frac{1}{2}(x^2+y^2)\right) dxdy$$

$$\overset{\text{极坐标}}{=\!=} \int_0^{2\pi} d\theta \int_0^r \frac{1}{2\pi} e^{-\frac{1}{2}r^2} r\,dr$$

$$= \int_0^r r e^{-\frac{r^2}{2}} dr$$

于是 $f_R(r) = r e^{-\frac{r^2}{2}}$, $r \ge 0$.

此为 Rayleigh 分布.

有时候讨论参数范围，

例：$X,Y \overset{iid}{\sim} N(0,1)$ 求 $Z = \frac{X}{Y}$ 分布

$z \in R$. $F_Z(z) = P(Z \le z) = P(\frac{X}{Y} \le z)$

$= P(X \le Yz, Y>0) + P(X \ge Yz, Y<0)$

$= \int_0^{+\infty} dy \int_{-\infty}^{yz} \varphi(x)\varphi(y)\,dx + \int_{-\infty}^{0} dy \int_{yz}^{+\infty} \varphi(x)\varphi(y)\,dx$

$= \int_0^{+\infty} \Phi(yz)\varphi(y)\,dy + \int_{-\infty}^{0} (1-\Phi(yz))\varphi(y)\,dy$

$f_Z(z) = \int_0^{+\infty} \varphi(yz)\varphi(y)\,y\,dy + \int_{-\infty}^{0} -\varphi(yz)\,y\,\varphi(y)dy$

$= 2\int_0^{+\infty} \varphi(yz)\varphi(y)\,y\,dy$

$= \frac{1}{\pi(1+z^2)}$ $z \in R$.

Cauchy 分布.

清华大学未央书院

Case 2. 卷积公式 分为四类：

(1) $Z = X+Y$ （反解 y）

即 $f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x)\,dx = \int_{-\infty}^{+\infty} \overbrace{f(z-y, y)}^{\text{反代}x}\,dy$

(2) $Z = X-Y$ $f_Z(z) = \int_{-\infty}^{+\infty} f(x, x-z)\,dx = \int_{-\infty}^{+\infty} f(z+y, y)\,dy$.

(3) $Z = XY$ $f_Z(z) = \int_{-\infty}^{+\infty} f(x, \frac{z}{x})\frac{1}{|x|}\,dx = \int_{-\infty}^{+\infty} f(\frac{z}{y}, y)\frac{1}{|y|}\,dy$

(4) $Z = \frac{Y}{X}$ $f_Z(z) = \int_{-\infty}^{+\infty} f(x, zx)|x|\,dx$

① 步骤：反解 y. 代入 $f(x, \underbrace{y}_{y(z,x)})$

求 y 对 z 的偏导后 x 的绝对值.

② (1)、(2) 是卷积公式

(3)(4) 不叫卷积公式. 但省下来节省时间.

③ 注意 $\int_{-\infty}^{+\infty}$ 上下限. 当首换 $y = z-x$ 后. 要根据 $f(x,y)$ 的区域 得来 y 从而 上下限 全变成关于 z 的式子.

作业纸

班级： 姓名： 学号： 科目： 第 页

II、 二维情况：

$Y=g(X)$

$\begin{pmatrix} X \\ Y \end{pmatrix} \longrightarrow \begin{pmatrix} U \\ V \end{pmatrix}$ 回顾一维： $f_Y(y) = f_X(x(y))\,|x'(y)|$

二维： $\begin{cases} u = u(x,y) \\ v = v(x,y) \end{cases} \rightsquigarrow \begin{cases} x = x(u,v) \\ y = y(u,v) \end{cases}$

则： $g(u,v) = f(x(u,v), y(u,v)) \left| \dfrac{\partial(x,y)}{\partial(u,v)} \right|$

即：先反解代入，再求 $|J|$

例：$X, Y \overset{iid}{\sim} N(0,1)$

(R,Θ) 为极坐标，$R \geq 0$，$\Theta \in [0, 2\pi]$

求 $f_{R,\Theta}(r,\theta)$

解：反解： $X = R\cos\Theta$, $Y = R\sin\Theta$ $\Rightarrow |J| = R$.

于是，$g_{R,\Theta}(r,\theta) = f(r\cos\theta, r\sin\theta)\, r$

$= \frac{1}{2\pi} \exp\left(-\frac{1}{2}r^2\right) r$ 其中 $r \geq 0$，$\theta \in [0, 2\pi]$

由于 $g_{R,\Theta}(r,\theta) = \frac{r}{2\pi} e^{-\frac{r^2}{2}}$

$\Rightarrow$

$g_R(r) = r e^{-\frac{r^2}{2}}$ $r \geq 0$ Rayleigh 分布

$g_\Theta(\theta) = \frac{1}{2\pi}$ $\theta \in [0, 2\pi]$ $\sim U(0, 2\pi)$

且 R 与 Θ 独立。

WEIYANG COLLEGE TSINGHUA UNIVERSITY 清华大学未央书院

有了以上铺垫，

再看二元正态分布：

$$\vec{X}=\begin{pmatrix}X_1\\X_2\end{pmatrix} \qquad f(x_1,x_2)=\frac{1}{2\pi}e^{-\frac{x_1^2+x_2^2}{2}}=\frac{1}{2\pi}\exp\left(-\frac{1}{2}x^Tx\right)$$

$$\vec{Y}=\begin{pmatrix}Y_1\\Y_2\end{pmatrix}=\vec{\mu}+A\begin{pmatrix}X_1\\X_2\end{pmatrix} \quad A\text{可逆} \quad \vec{\mu}=\begin{pmatrix}\mu_1\\\mu_2\end{pmatrix}$$

则：$\vec{Y}$的联合密度函数为：$\vec{X}=A^{-1}(\vec{Y}-\vec{\mu})$

$$g(y_1,y_2)=f(A^{-1}(\vec{Y}-\vec{\mu}))\,|A^{-1}|$$

$$=\frac{1}{2\pi}\exp\left(-\frac{1}{2}\left[(y-\mu)^T(A^T)^{-1}A^{-1}(y-\mu)\right]\right)|A^{-1}|$$

$$=\frac{1}{|A|2\pi}\exp\left(-\frac{(y-\mu)^T(AA^T)^{-1}(y-\mu)}{2}\right)$$

令 $\Sigma=AA^T$ 于是，$=\frac{1}{2\pi|\Sigma|}\exp\left(-\frac{1}{2}(y-\mu)^T\Sigma^{-1}(y-\mu)\right)$

作业纸

班级： 姓名： 学号： 科目： 第 页

Lecture 8. 条件概率分布

Def：离散随机变量的条件概率分布

$$P(X=x_i \mid Y=y_j) = \frac{P(X=x_i, Y=y_j)}{P(Y=y_j)} = \frac{p_{ij}}{q_j} = \frac{p_{ij}}{\sum_i p_{ij}} \quad i=1,2,\cdots$$

为给定 $Y=y_j$ 下 X 的条件分布列：conditional pmf

例：甲向目标射击，命中率为 $p=1-q$，射击之间相互独立。

X 表示第一次击中时总射击次数，Y 表示第二次击中时总射击次数。

求 $Y|X=x \sim ?$，$X|Y=y \sim ?$

解：由已知：要求条件分布 ⇝ 联合分布 边缘分布

对于相距：$P(X=i) = q^{i-1}p \quad i \geq 1$

$$P(Y=j) = p^2 q^{j-2} C_{j-1}^{1} = p^2 (j-1) q^{j-2} \quad j \geq 2.$$

① ② …… $j-1$ 中选 1 次。

$$P(X=i, Y=j) = q^{i-1}p \cdot q^{j-i-1}p = q^{j-2}p^2 \quad j \geq i+1.$$

于是：$P(Y=j \mid X=i) = \frac{q^{j-2}p^2}{q^{i-1}p} = pq^{j-i-1}$ 这里 $G(p)$

$$P(X=i \mid Y=j) = \frac{q^{j-2}p^2}{p^2(j-1)q^{j-2}} = \frac{1}{j-1} \quad j \geq i+1, \ 1 \leq i \leq j-1$$

WEIYANG COLLEGE TSINGHUA UNIVERSITY 清华大学未央书院

独立性： $P(X=x_i \mid Y=y_j) = P(X=x_i) \quad \forall i,j.$

Def： 条件概率分布之数，条件概率之变.

$$f_{X|Y}(x|y) = \frac{f(x,y)}{f_Y(y)} = \frac{f(x,y)}{\int_{-\infty}^{+\infty} f(x,y)\,dx} \quad x \in R \text{ 为给定 } y \text{ 下 } X \text{ 的条件概率密度.}$$

$$P(X \le x \mid Y=y) = \frac{\int_{-\infty}^{x} f(s,y)\,ds}{f_Y(y)} \quad x \in R \text{ 为给定 } y \text{ 下 } X \text{ 的条件分布}$$

积之 已 条件 $=$ 联合 / 边沿.

积之性： $f(x,y) = f_X(x) f_Y(y) = f_{X|Y}(x|y) f_Y(y).$

对于已定分布： 记 $X=x$ 时.

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)} = \frac{1}{\sigma_2\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{(y-\mu_X)^2}{2(1-\rho^2)\sigma_2^2}\right)$$

$$\mu_X = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x-\mu_1).$$

$\Rightarrow$ X.Y 服从 联合正态 时. 条件分布 也 正态

作业纸

班级： 姓名： 学号： 科目： 第 页

课程中期总结：

一、概率空间 $(\Omega, \mathcal{F}, P)$

P：$\begin{cases} P(A) \geq 0 \\ P(\Omega) = 1 \\ \text{可列可加} \end{cases}$

$\mathcal{F}$：① $\Omega \in \mathcal{F}$

② $A \in \mathcal{F} \Rightarrow A^C \in \mathcal{F}$

③ $A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$

这部分要求：① 会证概率的一些性质

（利用 取补集，归纳，拆成互斥合…）

② 会求 $\sigma(\mathcal{A})$ 中集合个数（对于简单的 $\mathcal{A}$）

③ 理解 $\sigma(\mathcal{A})$ 包含 $\mathcal{A}$ 的最小事件域

二、概率的连续性：

对：事件列的极限：$A_1 \subset A_2 \subset \cdots$ $\{A_n\}\uparrow \Rightarrow \lim\limits_{n\to\infty} A_n = \bigcup_{n=1}^{\infty} A_n$.

$A_1 \supset A_2 \supset \cdots$ $\{A_n\}\downarrow \Rightarrow \lim\limits_{n\to\infty} A_n = \bigcap_{n=1}^{\infty} A_n$.

上极限：$\limsup\limits_{n\to\infty} A_n = \bigcap_{n=1}^{\infty}\bigcup_{k=n}^{\infty} A_k = \{w \mid w \text{ 属于无穷多个 } A_i\}$ A_n i.o. infinitely often

下极限：$\liminf\limits_{n\to\infty} A_n = \bigcup_{n=1}^{\infty}\bigcap_{k=n}^{\infty} A_k = \{w \mid w \text{ 属于除有限个之外的所有 } A_i\}$

A_n a.s. almost surely

① 会利用 C_P 证一些不等式.

② 知道并会用 Borel-Cantelli 引理. $\begin{cases} \sum_{n=1}^{\infty} P(A_n) < \infty \Rightarrow P(\limsup\limits_{n\to\infty} A_n) = 0 \\ \sum_{n=1}^{\infty} P(A_n) = \infty \text{ 且 } \{A_n\} \text{ 相互独立} \Rightarrow P(\limsup\limits_{n\to\infty} A_n) = 1. \end{cases}$

三. 条件概率、全概率公式、Bayes 公式

此部分 很容易出 概率证推. 要善于找出 概率(事件)

四. 独立性: ① $A \perp B \Rightarrow \bar{A} \perp B \quad A \perp \bar{B} \quad \bar{A} \perp \bar{B}$

事件 ② 条件独立性: $P(AB|C) = P(A|C)P(B|C)$

此与 事件独立性 $P(AB) = P(A)P(B)$

互不蕴含

③ 相互独立 $\Rightarrow$ 两两独立

$\not\Leftarrow$

随机变量: $P(X_1 \le x_1, \cdots X_n \le x_n) = P(X_1 \le x_1) \cdots P(X_n \le x_n)$

$\forall x_1, \cdots x_n \in R.$

© 相互独立 $\not\Rightarrow$ 两两独立

④ $\Leftrightarrow$ $\forall$ Borel 集. $\{X_1 \in B_1\} \cdots \{X_n \in B_n\}$ 相互独立.

⑤ $X_1 \cdots X_n$ 相互 $\perp$ $g_1(x) \cdots g_n(x)$ 为 一元 可测 函数.

$g_1(X_1) \cdots g_k(X_k)$ 相互 $\perp$

$\varphi(X_1 \cdots X_k)$ 与 $X_{k+1} \cdots X_n$ 相互

作业纸

班级： 姓名： 学号： 科目： 第 页

五 PMF. PDF. CDF. joint. marginal ...

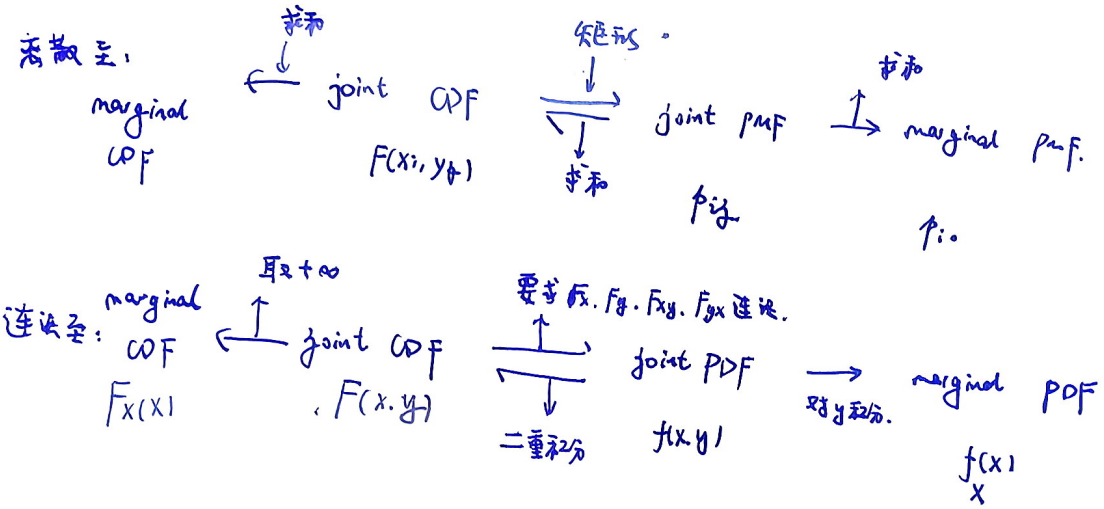

条件: 条件 $=$ 联合 / 边缘.

常用用此式 $f(x,y) = f_{X|Y}(x|y) f_Y(y)$

求 $f(x,y)$ 或 $f_{X|Y}(x|y)$.

六. 变量代换 离散即求和. 不写.

① $Y = g(X)$
- 通法: $F_Y(y) \rightsquigarrow f_Y(y)$
- 单调 $\Rightarrow$ 反解 $x = x(y)$ $\rightarrow$ $f_Y(y) = f_X(x(y)) x'(y)$

② $Z = z(x,y)$ $\rightarrow$ 分类讨论. 二重积分. $F_Z(z) \overset{求导}{\rightsquigarrow} f_Z(z)$
- 卷积公式 $\begin{cases} x+y \\ x-y \\ \frac{x}{y} \\ x \cdot y \end{cases}$

③ $\begin{pmatrix} u \\ v \end{pmatrix} : \begin{pmatrix} x \\ y \end{pmatrix}$ 反解: $x = x(u,v)$, $y = y(u,v)$ 求 $|J|$ $f(u,v) = f(x(u,v), y(u,v)) |J|$.

WEIYANG COLLEGE TSINGHUA UNIVERSITY 清华大学未央书院

Lecture 9. 期望. 分位数

Part I 期望.

Def 1.1. 离散型的期望.

$P(X=x_j)=p_j \quad j=1,2\cdots$ 若 $\sum_{j=1}^{+\infty}|x_j|p_j<+\infty$ 则称 $E(X)=\sum_{j=1}^{+\infty}x_jP(X=x_j)$ 为 X 的期望

常用: $P(X\in A)=E(1_A(\omega))$ 示性函数的期望是概率

Def 1.2 连续型 ~

X 有概率密度 $f(x)$ 若 $\int_{-\infty}^{+\infty}|x|f(x)dx<+\infty \Rightarrow E(X)=\int_{-\infty}^{+\infty}xf(x)dx$ 为期望

不存在的情形: Cauchy 分布 $f(x)=\frac{1}{\pi(1+x^2)}$ $x\in R$.

Def 1.3. 统一表达, 期望是新测度下的积分.

若 X 的分布函数是 $F(x)$ 则 $E(X)=\int_R x\,dF(x)$

$\int_R x\,dF(x)$ 看成 $F(x)$ 定义了一个新的概率测度.

$(a,b]$ 长度 $b-a \longrightarrow P(X\in(a,b])=F(b)-F(a)$

下standard 这个积分的定义:

Step 1: 旧 = 新 (特殊情形)

均匀分布 $\cup\sim U(0,1)$

dx: 相同

$dF(x)$:

Step 2: 旧 $\overset{\text{近似}}{\Longrightarrow}$ 简单新

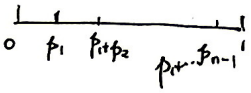

Step 3. 一般的 X:

a.s. 收敛

记 $X_n=\sum_{k=1}^{n\cdot 2^n}x_k I(x_k\le X<x_{k+1})$ 注意 $\{X_n\}$ 且 $n\to+\infty$ X

且 $x_{k+1}-x_k=\frac{1}{2^n}$

$E(X)=\int_R x\,dF_X(x) \overset{\text{def}}{=} \lim_{n\to\infty}E(X_n)=\lim_{n\to\infty}\sum_k x_k P(X_n=x_k)$

$=\lim_{n\to\infty}\sum_k x_k P(x_k\le X<x_{k+1})$ 这是 Lebesgue 积分 $\sum_k x_k p_k$.

$\|$

设 $P(X=x_k)=p_k$ A_k 长度为 p_k

$X(u)=\sum_k x_k I(u\in A_k)$

$E(X)=\int_R x\,dF_X(x) \overset{\text{def}}{\underset{\Delta}{=}} \int_R \sum_k x_k I(u\in A_k)\,dF_u(u)=\sum_k x_k\int_{A_k}1\,dF_u(u)$

Part II 期望的性质

班级：

Thm 2-1 基本性质：

① $E[C]=C$

② $E[aX+bY]=aE[X]+bE[Y]$

③ X, Y 独立时 $E[XY]=E[X]E[Y]$

proof: ① $E[C]=C$ 显然.

② $E[aX+bY] \overset{def}{=} \int_\Omega (aX+bY)\,dP$

$= a\int_\Omega X\,dP + b\int_\Omega Y\,dP$

$= aE[X]+bE[Y]$

此式要求 $E[X]$ $E[Y]$ 均有限 · 这里用到了 Lebesgue 积分的线性性. 不证.

③ $E[XY]=\iint_R xy\,dF_{X,Y}(x,y)$

由独立性：$dF_{X,Y}(x,y)=dF_X(x)\,dF_Y(y)$

若 $X\geq 0$, $Y\geq 0$ 上式 $= \int_R \left(\int_R xy\,dF_X(x)\right) dF_Y(y) = E[X]E[Y]$

若一般情形：$\begin{cases} X=X^+-X^- \\ Y=Y^+-Y^- \end{cases}$

$XY = X^+Y^+ - X^+Y^- - X^-Y^+ + X^-Y^-$

利用 ② 得证 毕

Thm 2.2 X 为随机变量，有分布函数 $F(x)$

$g(x)$ 满足 $\int_R |g(x)| \, dF(x) < \infty$

则 $Y = g(X)$ 有数学期望，$E(Y) = E(g(X)) = \int_R g(x) \, dF(x)$

更一般地：(X, Y) 有联合分布 $F(x,y)$ 且 $g(x,y)$ 满足 $\int_{R^2} |g(x,y)| \, dF(x,y) < \infty$

$\Rightarrow Z = g(X,Y)$ 有数学期望

$E(Z) = E(g(X,Y)) = \int_{R^2} g(x,y) \, dF(x,y)$

我们把 $E(X) = \int_{-\infty}^{+\infty} x f(x) \, dx$ 的 x 换成 $g(x)$。$E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) \, dx$ 对于多元也成立。

例：$X \sim U[0, \frac{\pi}{2}]$ 求 $E(\cos X)$

解：$f_X(x) = \frac{2}{\pi}$ $E(\cos X) = \int_0^{\frac{\pi}{2}} \cos x \frac{2}{\pi} \, dx = \frac{2}{\pi}$

$E(g(X)) \neq g(E(X))$ 如：$g = x^2$ $E(X^2) \neq (E(X))^2$

Thm 2.3. $E(X) = \mu$ $E(X^2) < \infty$ 则 $E((X-\mu)^2) < E((X-C)^2)$ $\forall C \neq \mu$.

proof: $f(C) = E(X^2 - 2CX + C^2) = E(X^2) - 2CE(X) + C^2$

$f'(C) = 2C - 2E(X) = 0 \rightarrow C = E(X) \Rightarrow$ 最小值，

$f''(C) = 2 > 0$ 即 $C = E(X)$ 使得 $f(C) = E[(X-C)^2]$ 取最小值.

直线是 在残差之下 $E(X)$ 是对 Y 的最佳(常数)估计 记为 $E(X) = \arg\min_{C \in R} E(X-C)^2$

△

Thm 2.4 设 X 有 f(x) m 是中位数. 则 $m = \arg\min_{c \in R} E|X-c|$

班级:

proof: $g(c) = E[|X-c|]$

$$= \int_{-\infty}^{+\infty} |x-c| f(x)\,dx$$

$$= \int_{-\infty}^{c} (c-x) f(x)\,dx + \int_{c}^{+\infty} (x-c) f(x)\,dx$$

$$g'(c) = \int_{-\infty}^{c_0} f(x)\,dx + \int_{c_0}^{+\infty} -f(x)\,dx$$

$$= 0$$

$$\Rightarrow \int_{-\infty}^{c_0} f(x)\,dx = \int_{c_0}^{+\infty} f(x)\,dx$$

$$P(X \le c_0) = 1 - P(X \le c_0)$$

$$\Rightarrow \boxed{P(X \le c_0) = \frac{1}{2}}$$

这个 c_0 就是最佳估计 (c_0 是中位数 m).

Part II. 分位数

Def. 对于 $p\in(0,1)$ 记 $F^{-1}(p)=\inf\{x\mid F(x)\geq p\}$ 也有说成 $\sup\{x$

称 $F^{-1}(p)$ 为 $F(x)$ 的反函（X 的分位数）

二者完全等价

是左连续的.

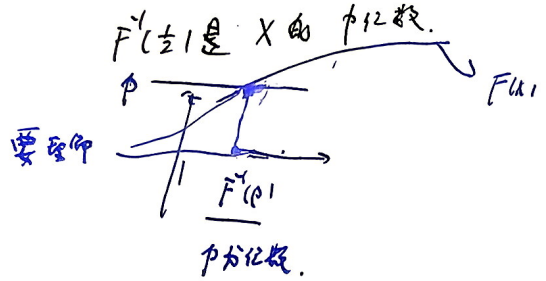

X 是连续型随机变量时 $F^{-1}(p)$ 即 $F(x)$ 的逆.

$F(F^{-1}(p))=p$ $\quad F^{-1}(p)\leq t \iff p\leq F(t)$.

Thm 3.1. 从均匀分布到任意分布 利用逆函数生成随机数!

$X\sim U(0,1)$ $F(x)$ 是 X 的分布函数 则 $Y=F^{-1}(X)\sim F$ $\quad F(x)=\begin{cases}1 & x\geq 1\\ x & x\in(0,1)\\ 0 & 0\end{cases}$

proof: $F_Y(y)=P\{Y\leq y\}=P\{F^{-1}(X)\leq y\}=P\{X\leq F(y)\}$

$=F_X(F(y))=F(y)$.

Y 的分布函数是 $F(x)$.

服从 $U(0,1)$ 的随机数 $\Longrightarrow$ 生成 服从任意分布的随机数

核心定理：设 $F(x)=P(X\leq x)$ 且 $F(x)$ 严格↑

那么：生成 $U\sim U(0,1)$ $X=F^{-1}(U)$ 这样的 X 服从分布 F.

$F_X(x)=x$

$f_X(x)=1$ 此即 $U(0,1)$

X

$\|$

$\forall x\in(0,1)$

反过来. 给定一个服从任意连续分布的 Y. 分布函数为 $F_Y(y)$

那么 $X=F(y)$ 一定服从 $U(0,1)$ $F_X(x)=P\{X\leq x\}=P\{F(y)\leq x\}=P\{y\leq F^{-1}(x)\}=F(F^{-1}(x))$

已有服从均匀分布的 X. 怎么生成服从指数分布 $E(\lambda)$ 的 Y ?

回顾之前的探索：从 $U(0,1)$ $\xrightarrow{生成}$ 任意分布 $F(x)$ ： $Y = F^{-1}(X)$

解： $X \sim U(0,1)$

$Y \sim E(\lambda)$

$F = 1 - e^{-\lambda x}$ 令 $Y = \frac{1}{-\lambda}\ln(1-X)$ 即可. #.

F^{-1} ?

$y = 1 - e^{-\lambda x}$

$1 - y = e^{-\lambda x}$

$x = \frac{\ln(1-y)}{-\lambda}$

Lecture 10. 方差. 协方差.

Part I. 方差.

Def. $E[(X-E(X))^2]$ 称为 X 的方差, 记作 $Var(X)$. $D(X)$

$$D(X) = E((X-E(X))^2) = E(X^2) - (E(X))^2$$

性质: ① $D(C)=0$

② $D(aX+b) = a^2 D(X)$

③ $D(X+Y) \overset{X \perp Y}{=\!=} D(X) + D(Y)$

标准化: $Y = \dfrac{X-E(X)}{\sqrt{D(X)}}$

Part II. 协方差.

Def: $E[(X-E(X))(Y-E(Y))]$ 称为 X 与 Y 的协方差. $Cov(X,Y)$

$$Cov(X,Y) = E(XY) - E(X)E(Y)$$

性质: ① $Cov(X,C)=0$

② $Cov(aX+bY+C, Z) = aCov(X,Z) + bCov(Y,Z)$

③ $Cov(X,Y) \overset{X \perp Y}{=\!=} 0$

$$D(X+Y) = D(X) + D(Y) + 2Cov(X,Y).$$

协方差 不反映 差异的 强弱 只反映 是否 / 正/负相关.

△

相关系数：当 $D(X)$ $D(Y)>0$ 且有限时

$$\operatorname{Cov}\left(\frac{X-E(X)}{\sqrt{D(X)}}, \frac{Y-E(Y)}{\sqrt{D(Y)}}\right) = E\left[\frac{(X-E(X))(Y-E(Y))}{\sqrt{D(X)D(Y)}}\right] - E\left(\frac{X-E(X)}{\sqrt{D(X)}}\right)E\left(\frac{Y-E(Y)}{\sqrt{D(Y)}}\right)$$

$$= E\left[\frac{(X-E(X))(Y-E(Y))}{\sqrt{D(X)D(Y)}}\right]$$

$$= \frac{\operatorname{Cov}(X,Y)}{\sqrt{D(X)D(Y)}}$$

$\Rightarrow$ Def: $\dfrac{\operatorname{Cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = \rho$ 称为 X, Y 的相关系数. 记作 $\operatorname{Corr}(X,Y)$.

Corr 可比.

易知：$\rho=0 \Leftrightarrow \operatorname{Cov}(X,Y)=0 \Leftrightarrow$ 不相关 $\Leftrightarrow$ 不线性相关 $\Leftarrow$ 独立.

$\not\Rightarrow$

班级：Lecture 回顾

Lecture 11. 条件期望、条件方差.

回顾 条件分布 $p(x|y)$

Def: 离散， $p(X=x_i|Y=y_j) = \frac{p_{ij}}{q_j}$ $i=1,2\cdots$

j 固定

连续， $f_{X|Y}(x|y) = \frac{f(x,y)}{f_Y(y)} = \frac{f(x,y)}{\int_{-\infty}^{+\infty} f(x,y)\,dx}$ $Y=y$ 固定.

设 $(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$ 求 X 的条件分布.

则: $f(x,y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left(\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right) + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right)}$

$$\int_{-\infty}^{+\infty} f(x,y)\,dx = \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{\frac{-1}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1} - \rho\left(\frac{y-\mu_2}{\sigma_2}\right)\right)^2 + (1-\rho^2)\left(\frac{y-\mu_2}{\sigma_2}\right)^2}$$

$$= \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{\frac{-1}{2(1-\rho^2)}\left[\frac{x-\mu_1}{\sigma_1}\right]^2 - \frac{1}{2}\left(\frac{y-\mu_2}{\sigma_2}\right)^2}$$

$$= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}\left(\frac{y-\mu_2}{\sigma_2}\right)^2} \int_{-\infty}^{+\infty} e^{\frac{-1}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1}\right)^2} dx$$

$$\frac{\int_{-\infty}^{+\infty} e^{\frac{-1}{2(1-\rho^2)}\left(\frac{x}{\sigma_1}\right)^2} d\left(\frac{x}{\sigma_1}\right)}{\int_{-\infty}^{+\infty} e^{\frac{-x^2}{2(1-\rho^2)}} dx} = \int \frac{\pi}{\frac{1}{2(1-\rho^2)}} = \sqrt{2\pi(1-\rho^2)}$$

$$= \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{1}{2}\left(\frac{y-\mu_2}{\sigma_2}\right)^2}$$

$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} = 1$

$\Rightarrow \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} = \sqrt{2\pi}$

△

班级：

条件期望

Def：

$$f_{X|Y}(x|y) = \frac{\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right) + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]}}{\frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{1}{2}\left(\frac{y-\mu_2}{\sigma_2}\right)^2}}$$

$$= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} \exp \square$$

计算 $\square$：$-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right) + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 - \frac{(1-\rho^2)(y-\mu_2)^2}{\sigma_2^2}\right]$

内计：$\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right) + \frac{\rho^2(y-\mu_2)^2}{\sigma_2^2}$

$$= \left(\frac{x-\mu_1}{\sigma_1} - \frac{\rho(y-\mu_2)}{\sigma_2}\right)^2$$

原式 $= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} \exp\left(\frac{-1}{2(1-\rho^2)}\left[\frac{x-\mu_1}{\sigma_1} - \frac{\rho(y-\mu_2)}{\sigma_2}\right]^2\right)$

对应参数：$\mu' = \mu_1 + \rho\frac{\sigma_1}{\sigma_2}(y-\mu_2)$

$\sigma'^2 = \sigma_1^2(1-\rho^2)$

$$\boxed{X|Y \sim N\left(\mu_1 + \rho\frac{\sigma_1}{\sigma_2}(y-\mu_2),\ \sigma_1^2(1-\rho^2)\right)}$$

$X|Y=y \sim N\left(\mu_X + \rho\frac{\sigma_X}{\sigma_Y}(y-\mu_Y),\ \sigma_X^2(1-\rho^2)\right)$

条件期望

Def： $\sum_{i=1}^{\infty} |x_i| \, p(X=x_i \mid Y=y) < \infty \Rightarrow E(X \mid Y=y) = \sum_{i=1}^{\infty} x_i \, p(X=x_i \mid Y=y)$

为给定条件 $Y=y$ 下 X 的期望

$$\int_{-\infty}^{+\infty} |x| \, f_{X|Y}(x|y) \, dx < \infty \Rightarrow E(X \mid Y=y) = \int_{-\infty}^{+\infty} x \, f_{X|Y}(x|y) \, dx.$$

为 $\sim$

一般情况：y 给定时 $F_{X|Y=y}(x|y)$ 对应的期望 $E(X \mid Y=y) = \int x \, d F_{X|Y=y}(x|y)$

性质：也包括：$E(X \mid X=x) = x$

$$E(aX+bY \mid Z=z) = a E(X \mid Z=z) + b E(Y \mid Z=z)$$

$$E(h(Y) g(X) \mid Y=y) = h(y) E(g(X) \mid Y=y)$$ ← 这个常用

$X \perp Y$，$E(X \mid Y=y) = E(X)$　　$E(Y \mid X=x) = E(Y)$

例：$X \sim P(\lambda)$　求 $E(X+Y \mid X=x) = ?$
$Y \sim P(\lambda)$　$X \perp Y$

← 做条件期望题目时 一定要先想性质，不要先想公

解：$E(X+Y \mid X=x) = E(X \mid X=x) + E(Y \mid X=x)$

$= x + E(Y)$

$= x + \lambda$

例：$(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$　　求 $X|Y \sim N(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y-\mu_2), \ldots)$

$E(X \mid Y=y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y-\mu_2)$

班级：

Pet 1.2.

$X \sim U[0,1]$ $\quad Y = \begin{cases} 0 & X<0.5 \\ 1 & X \geq 0.5 \end{cases}$

$E[X|Y=y]$

① $y=0$ 时： $P(X \leq x | Y=0) = P(X \leq x | X<0.5) = 2x \quad x \in (0, 0.5)$

$\Rightarrow f_{X|Y=0}(x|y) = 2 \quad x \in (0, 0.5)$

$E(X|Y=0) = \int_0^{0.5} 2x \, dx = \frac{1}{4}$

② $y=1$ 时： $P(X \leq x | Y=1) = P(X \leq x | X>0.5) = \frac{x-0.5}{0.5} = 2x-1 \quad x \in (0.5, 1)$

$\Rightarrow f_{X|Y=1}(x|y=1) = 2 \quad x \in (0.5, 1)$

$E(X|Y=1) = \int_{0.5}^{1} 2x \, dx = \frac{2}{2}\left[1 - \frac{1}{4}\right] = \frac{\frac{3}{2}}{2} = \frac{3}{4}$

于是： $E(X|Y=y) = \begin{cases} \frac{1}{4} & y=0 \\ \frac{3}{4} & y=1. \end{cases}$

Def 1.2. (X,Y) 为随机向量. $E|X|$ 存在. $m(y) = E(X|Y=y)$

称 $m(Y)$ 为给定 Y 时 X 的条件期望 $E(X|Y)$

$m(y) = E(X|Y=y)$ 是关于 y 的函数

$E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$

例: $X,Y \overset{iid}{\sim} P(\lambda)$ 求 $E(X+Y|X)$

给定 $X=x$ 下 $E(X+Y|X=x) = x+\lambda$

$\Rightarrow E(X+Y|X) = X+\lambda$

再求 $E(X|X+Y)$ λ: $P(X=k) = \frac{\lambda^k}{k!}e^{-\lambda}$ $k=0,1,\cdots$

$P(X=k|X+Y=n) \overset{X+Y\sim P(2\lambda)}{=\!=} \frac{P(X=k, X+Y=n)}{P(X+Y=n)} = \frac{P(X=k, Y=n-k)}{P(X+Y=n)}$

$= \frac{\frac{\lambda^k}{k!}e^{-\lambda}\cdot\frac{\lambda^{n-k}}{(n-k)!}e^{-\lambda}}{e^{-2\lambda}\frac{(2\lambda)^n}{n!}}$ 2λ: $P(X+Y=k) = \frac{(2\lambda)^k}{k!}e^{-2\lambda}$

$= \frac{n!}{k!(n-k)!}\frac{\lambda^k\lambda^{n-k}}{(2\lambda)^n} = \frac{n!\lambda^n}{k!(n-k)!2^n\lambda^n} = \frac{n!}{2^n\cdot k!(n-k)!} = \frac{C_n^k}{2^n}$

此注明: $X|X+Y=n \sim B(\frac{1}{2}, n)$

$E(X|X+Y=n) = \frac{n}{2}$ $\Rightarrow$ $\boxed{E(X|X+Y) = \frac{X+Y}{2}}$

△

班级：
学号 姓

例：$(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$ $E(X|Y)=?$

解：在 $Y=y$ 给定时，

$$X|Y=y \sim N\left(\mu_1+\rho\frac{\sigma_1}{\sigma_2}(y-\mu_2),\ (1-\rho^2)\sigma_1^2\right)$$

把 $E(X|Y=y)=\mu_1+\rho\frac{\sigma_1}{\sigma_2}(y-\mu_2)$

$$\Rightarrow E(X|Y)=\mu_1+\rho\frac{\sigma_1}{\sigma_2}(Y-\mu_2).$$

结论：(X,Y) 服从联合正态 $\Rightarrow E(X|Y)$ 是关于 Y 的线性函数.

例：$X\sim N(0,1)$ $Y=X^2$ $\Rightarrow$ $E(Y|X)=?$

解：$X\sim N(0,1)$ $E(X^2|X)=X^2$

Thm 1.2 重期望公式：

$$E(E(X|Y))=E(X)$$

$$LHS=E[m(Y)]=\sum_y m(y)P_Y(y)$$

$$=\sum_y E(X|Y=y)P_Y(y)$$

$$=\sum_y\left(\sum_x x P_{X|Y}(x|y)\right)P_Y(y)$$

$$=\sum_x x\sum_y P_{X|Y}(x|y)P_Y(y)$$

$$=\sum_x x P_X(x)$$

$$=E(X)=RHS.$$

例：① 3h 坐 ② 5h 回到原点 ③ 7h 原点

Y表示结果.

$E(X)$

$E(E(X|Y))$

$$E(X)=3\times\frac{1}{3}+\left(\frac{E(X)+5}{3}+\frac{E(X)+7}{3}\right).$$

$$=1+\frac{2E(X)+12}{3}\Rightarrow E(X)=15$$

作为预测的条件期望：

$E[Y^2] < \infty$ $m(X) = E[Y|X]$ 则对于任何其他函数 $g(X)$

$$E(Y - m(X))^2 \le E(Y - g(X))^2$$

且当且仅当 $g(X) = m(X)$ 几乎处处成立时取等。

这就是说，在 L^2 损失下：$m(X) = E[Y|X]$ 可最好地预测 Y

Def 2.1 条件方差

$E[(Y - E(Y|X))^2 | X]$ 存在 $\Rightarrow$ 给定 X 下 Y 的方差。 $Var(Y|X)$

$$Var(Y|X=x) = E\left((Y - E(Y|X=x))^2 \,\middle|\, X = x\right)$$

全方差公式：$Var(Y) = E(Var(Y|X)) + Var(E(Y|X))$

方差 = 组内方差的期望 + 组间均值的方差。

噪声方差 + X方差

注：$Y = I(X \le 1)$ $Y \sim B(1, \frac{1}{2})$

$X|Y=0 \sim U(0,1)$ $E(X|Y=0) = \frac{1}{2}$

$Var(X|Y=0) = \frac{1}{12}$

$X|Y=1 \sim U(1,3)$ $E(X|Y=1) = 2$

$Var(X|Y=1) = \frac{1}{3}$

例：

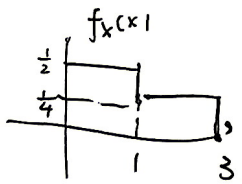

求其方差。

$$E(X^2) = \int_0^1 \frac{1}{2}x^2\,dx + \int_1^3 \frac{1}{4}x^2\,dx$$

$$= \frac{1}{3}\cdot\frac{1}{2}[1] + \frac{1}{4}\cdot\frac{1}{3}[27-1] = \frac{1}{6} + \frac{26}{12} = \frac{1}{6} + \frac{13}{6} = \frac{7}{3}$$

注：$D(X) = E(X^2) - [E(X)]^2$

$$E(X) = \int_0^1 \frac{1}{2}x\,dx + \int_1^3 \frac{1}{4}x\,dx$$

$$= \frac{1}{2}\cdot\frac{1}{2}x^2\Big|_0^1 + \frac{1}{4}\cdot\frac{1}{2}x^2\Big|_1^3$$

$$= \frac{1}{4} + \frac{1}{8}[9-1] = \frac{5}{4}$$

$\Rightarrow D(X) = \frac{7}{3} - \left(\frac{5}{4}\right)^2 = \frac{7}{3} - \frac{25}{16}$

$\frac{9}{10} + \frac{5}{24} = \frac{37}{48}$

$= \frac{37}{48}$.

$\frac{112}{51}$

$\frac{16}{7}$

$\frac{112}{75}$

△

Lecture. 12. 母函数. 矩母函数.

Def. 1.1. 母函数. P.G.F.

$$g(s) = E(s^X) = \sum_{k=0}^{+\infty} s^k p(X=k) \qquad s\in[-1,1]$$

其中 X 的取值 $\{0, 1, 2, \cdots\}$ 的随机变量.

① $g(1) = E(1) = 1$

$$g'(1) = \sum_{k=0}^{+\infty} k s^{k-1} p(X=k)\Big|_{s=1} = \sum_{k=0}^{+\infty} k p(X=k) = EX$$

② $p(X=k) = \frac{g^{(k)}(0)}{k!}$ (由 Taylor 展开)　概率母函数 $\xleftrightarrow{1:1}$ 分布列

③ $X_1 \cdots X_n$ 相互独立　$g_i(s) = E(s^{X_i})$　$Y = X_1 + \cdots + X_n$.

$$\Rightarrow g_Y(s) = g_1(s)\cdots g_n(s) \qquad s\in[-1,1]$$

常见母函数：

A. $B(n,p)$

$$g(s) = E(s^X) = \sum_{k=0}^{n} s^k C_n^k p^k (1-p)^{n-k} = (q+ps)^n$$

B. $P(\lambda)$

$$g(s) = E(s^X) = \sum_{k=0}^{+\infty} s^k \frac{e^{-\lambda}\lambda^k}{k!} = e^{\lambda(s-1)}$$

C. $G(p)$

$$g(s) = E(s^X) = \sum_{k=1}^{+\infty} s^k p q^{k-1} = \frac{sp}{1-sq}.$$

概率母函数的应用：

A. 利用 PGF 求 PMF.

$\frac{g^{(k)}(0)}{k!} = p(X=k)$ 或幂级数展开后取 s^k 前系数.

B. 利用 PGF 求期望.

eg. $Y = X_1 + \cdots + X_n$　$X_1 \cdots X_n$ 相互独立 $\sim P(\lambda_i)$.

$$\Rightarrow g_i(s) = E(s^{X_i}) = e^{\lambda_i(s-1)}$$

$$\Rightarrow g_Y(s) = e^{(\lambda_1+\cdots+\lambda_n)(s-1)}$$

$$\Rightarrow Y \sim P(\lambda_1+\cdots+\lambda_n)$$

C. 有时候不用 Taylor 展开 (无法直接判断类型).

$Y = X_1 + \cdots + X_n$　$X_i \sim G(p) \Rightarrow g_i(s) = \frac{sp}{1-sq}$

$$\Rightarrow g_Y(s) = \left(\frac{sp}{1-sq}\right)^n$$

希望展开为 s 的幂级数

△

$$g_Y(s)=\frac{(ps)^m}{(1-qs)^m}=p^m s^m (1-qs)^{-m}$$

$$\frac{m(m+1)\cdots(m+j-1)}{2}(-qs)^2$$

$$\text{泰勒 } (1-qs)^{-m}=1+mqs+\frac{m(m+1)}{2}q^2s^2+\cdots+\frac{m(m+1)\cdots(m+j-1)}{j!}s^j q^j+\cdots$$

$$\Rightarrow g_Y(s)=p^m s^m \sum_{j=0}^{+\infty}\frac{m\cdots(m+j-1)}{j!}s^j q^j \qquad \frac{(m+j)!}{m!}$$

$$=p^m s^m \sum_{j=0}^{+\infty} C_{m+j-1}^{m-1} s^j q^j$$

$$=p^m \sum_{j=0}^{+\infty} C_{m+j-1}^{m-1} s^{j+m} q^j$$

$$\overset{令\ j+m=k}{=\!=} p^m \sum_{k=m}^{+\infty} C_{k-1}^{m-1} s^k q^{k-m}$$

$$=\sum_{k=m}^{+\infty} p^m q^{k-m} C_{k-1}^{m-1} s^k$$

故 即 $P(Y=k)=C_{k-1}^{m-1}p^m q^{k-m}$, $k=m, m+1, \ldots$

这是 Pascal 分布.

逆推：可用 $g(s)$ 求 EX $EX^2 \Rightarrow D(X)$

解， $EX=g'(1)$ $\quad g(s)=E(s^X)$ $\quad g'(s)=E(Xs^{X-1})$

$EX^2=g''(1)+g'(1)$ $\quad g''(s)=E(X(X-1)s^{X-2})$

$=EX^2-X+EX$ ✓

$\rightarrow D(X)=g''(1)+g'(1)-g'^2(1)$

Def 1.2 多维母函数.

$g(s,t)=E(s^X t^Y)=\sum_{i=0}^{\infty}\sum_{k=0}^{\infty} p_{ik}s^i t^k \quad s,t\in[-1,1]$

性质： ① $|g(s,t)|\le g(1,1)=1$

② $g(s,1)=g_X(s)$ $\quad g(1,t)=g_Y(t)$

③ $g(s,t)=g_X(s)\,g_Y(t) \Leftrightarrow$ 独立

④ $p_{jk}=\frac{1}{j!k!}\frac{\partial^{j+k}g(s,t)}{\partial s^j \partial t^k}$

Def 2.1 矩母函数 M.G.F.

$M_X(t) = E(e^{sX})$ 就是把 $g_X(s)$ 的 s 换成 e^s.

Thm 2.1.

1. $E(X^k) = M^{(k)}(0)$

2. 若存在 $a>0$ 使得 $\forall s \in (-a, a)$ $M(s)$ 存在 $\Rightarrow$ $M(s)$ 唯一决定 X 的分布函数

3. $Y = aX+b \Rightarrow M_Y(s) = e^{sb} M(sa)$

4. $X_1 \cdots X_n$ 相互独立 $\Rightarrow$ $Y = X_1 + \cdots + X_n$ $M_Y(s) = M_{X_1}(s) \cdots M_{X_n}(s)$.

Proof: ① $M_X(t) = E(e^{sX}) = E\left(1 + sX + \cdots + \frac{s^n X^n}{n!} + \cdots\right)$

$= 1 + E(X)s + \cdots + \frac{E(X^n)}{n!} s^n$

把 s^n 前系数 $\frac{E(X^n)}{n!}$ 由 Taylor 系数 $M^{(k)}(0) = E(X^k)$.

② $E(e^{s(aX+b)}) = E(e^{asX} e^{bs}) = e^{bs} E(e^{asX}) = e^{bs} M(sa)$.

④ 略

常见离散型分布

① $B(n,p) \Rightarrow g(s)=(q+ps)^n$

$\Rightarrow m(s)=(q+pe^s)^n$

② $P(\lambda) \Rightarrow M(s)=e^{\lambda(e^s-1)}$

③ $G(p) \Rightarrow g(s)=\frac{ps}{1-sq}$

$M(s)=\frac{e^s p}{1-e^s q}$.

④ $U(a,b)$

$\Rightarrow M(s)=\int_a^b e^{sx}\frac{1}{b-a}dx=\frac{e^{bs}-e^{as}}{s(b-a)}$.

应用：

A 利用 MGF 求矩.

$\Rightarrow M^{(k)}(0)=E(X^k)$

例：

X	2	3	5
P	$\frac{1}{2}$	$\frac{1}{6}$	$\frac{1}{3}$

$\Rightarrow g(s)=E(s^X)=\frac{1}{2}s^2+\frac{1}{6}s^3+\frac{1}{3}s^5$

$\Rightarrow M(s)=\frac{1}{2}e^{2s}+\frac{1}{6}e^{3s}+\frac{1}{3}e^{5s}$

$\Rightarrow E(X^2)=2+\frac{8}{6}+\frac{25}{3}=\frac{71}{6}$

例：$E(\lambda)$：$M(s)=\frac{\lambda}{\lambda-s}$

$EX=\left(\frac{\lambda}{\lambda-s}\right)'=\frac{\lambda}{(\lambda-s)^2}\Big|_{s=0}=\frac{1}{\lambda}$

$EX^2=\left(\frac{\lambda}{(\lambda-s)^2}\right)'=\frac{2\lambda}{(\lambda-s)^3}\Big|_{s=0}=\frac{2}{\lambda^2}$

⑤ $E(\lambda)$

$M(s)=E(e^{sX})=\int_0^{+\infty}e^{sx}\lambda e^{-\lambda x}dx=\frac{\lambda e^{(s-\lambda)x}}{s-\lambda}\Big|_0^{+\infty}=\frac{\lambda}{\lambda-s}$.

其中 $s<\lambda$

⑥ $N(0,1) \longrightarrow N(\mu,\sigma^2)$

↓

$M(s)=\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}x^2}e^{sx}dx$

$=\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}(x-s)^2}e^{\frac{1}{2}s^2}dx$

$=e^{\frac{1}{2}s^2}$

↓ $Z=\sigma X+\mu$

$M_Z(s)=E(e^{s(\sigma X+\mu)})=e^{s\mu}e^{\frac{1}{2}\sigma^2 s^2}=e^{\mu s+\frac{1}{2}\sigma^2 s^2}$

B 利用 MGF 判断类型.

如：已知 $Z\sim N(\mu,\sigma^2) \Rightarrow M(s)=e^{\mu s+\frac{\sigma^2}{2}s^2}$

例：$X\sim N(\mu_1,\sigma_1^2)$ $Y\sim N(\mu_2,\sigma_2^2)$ $X\perp Y$

$U=X+Y$

$\Rightarrow M_U(s)=M_X(s)M_Y(s)$

$=e^{(\mu_1+\mu_2)s+\frac{(\sigma_1^2+\sigma_2^2)s^2}{2}}$

$\Rightarrow U\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$

班级：

Lect.

Lecture 13. 特征函数. 大数定律 (I)

一. 特征函数.

Def 1.1

$$\phi(t) := E(e^{itX}) = E[\cos(tX) + i\sin(tX)] \quad t \in R$$

为 X 的特征函数.

Thm 1.1.

1. $|\phi_X(t)| = |E(e^{itx})| \le E(|e^{itx}|) = E(1) = 1$ 这说明 对任意 X. 任意 t. $\phi_X(t)$ 总存在

2. $\phi_X(0) = E(e^0) = 1$

若 X 的 k 阶矩存在. 则 可由 · $\phi_X^{(k)}(t) = E(|iX|^k e^{itX}) = i^k E(X^k e^{itX})$

令 $t=0$ $\Rightarrow$ $\phi_X^{(k)}(0) = i^k E(X^k)$ 求出 k 阶矩

3. 若有 $\phi_{X_k}(t)$ $X_1 \cdots X_n$ 相互独立. $\Longrightarrow$ $\phi_Y(t) \overset{Y=X_1+\cdots+X_n}{=\!=} \prod_{k=1}^{n} \phi_{X_k}(t)$ (这是个单向定理).

右边来示一定成立

4. $\phi_{aX+b}(t) = E(e^{it(aX+b)}) = e^{itb} E(e^{itaX}) = e^{itb} \phi_X(at)$

常见特征函数，为方便查找 下面列出常用的 PGF. MGF. CF.

	PGF $\xrightarrow{s\text{换成}e^s}$	MGF $\xrightarrow{s\text{换成}it}$	CF
	$g(s)=E(s^X)$	$M(s)=E(e^{sX})$	$\phi(t)=E(e^{itX})$
B(n,p)	$(q+ps)^n$	$(q+pe^s)^n$	$(q+pe^{it})^n$
P(λ)	$e^{\lambda(s-1)}$	$e^{\lambda(e^s-1)}$	$e^{\lambda(e^{it}-1)}$
G(p)	$\frac{sp}{1-sq}$	$\frac{e^s p}{1-e^s q}$	$\frac{e^{it}p}{1-e^{it}q}$
U[a,b]	X	$\frac{e^{bs}-e^{as}}{(b-a)s}$	$\frac{e^{bit}-e^{ait}}{it(b-a)}$
E(λ)	X	$\frac{\lambda}{\lambda-s}$	$\frac{\lambda}{\lambda-it}$
$N(\mu,\sigma^2)$	X	$e^{\mu s+\frac{\sigma^2 s^2}{2}}$	$e^{i\mu t-\frac{\sigma^2 t^2}{2}}$
Cauchy	X	X	$e^{-\lvert t\rvert}$

Cauchy 分布的 $\phi(t)$：标准 Cauchy (0,1) $\Rightarrow f(x)=\frac{1}{\pi(1+x^2)}$ $x\in R$.

则：$\phi(t)=E(e^{itx})=\int_{-\infty}^{+\infty}\frac{e^{itx}}{\pi(1+x^2)}dx$

（$t>0$ 取上半，$t<0$ 取下半）

用复变函数方法：

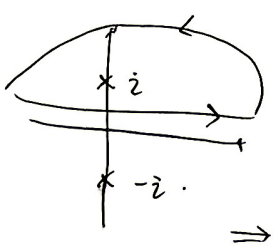

$\int_L+\int_{C_R}=2\pi i\,\mathrm{Res}(i,-t)$

$=2\pi i\,\frac{e^{-t}}{\pi 2i}=e^{-t}$

Jordan引理 $=0$

$\Rightarrow \boxed{\phi(t)=e^{-|t|}}$

二. C.F.的应用.

A. 用C.F.求分布.

特征函数 $\overset{1:1}{\Longleftrightarrow}$ 分布

反证法：

$$\frac{P(X=a)+P(X=b)}{2}+P(X\in(a,b))=\lim_{c\to\infty}\int_{-c}^{c}\frac{e^{-ita}-e^{-itb}}{it}\phi(t)\,dt$$

$\forall a<b$ 成立.

若 $F(x)$, $G(x)$ $\xrightarrow{\text{特征函数}}$ $\phi(t)$ 则 $F(x)$ $G(x)$ 在连续点取值相同.

进而 $F(x)$ $G(x)$ 单调无跳. 至多在可数个 $F(x)$ $G(x)$ 不同.

B. 用C.F. $\xrightarrow{\text{极限}}$ CDF极限. [中心极限定理证明]

Thm: X_n 的分布函数为 $F_n(x)$. 对应 $\phi_n(t)$

若: ① $\lim_{n\to\infty}\phi_n(t)=\phi(t)$ ② $\phi(t)$ 在0处连续.

$\Longrightarrow$ 设 $\phi(t)$ 为 X 对应的特征函数

且 $X_n\xrightarrow{d}X$ d: 依分布收敛.

即: $F_n(x)\xrightarrow{n\to\infty}F(x)$.

有了 $E(X^k)$ $\xrightarrow{\text{判定}}$ $\phi(t)$"确定" $\longrightarrow$ 分布确定.

$\uparrow$ 引理: $E[|X|^n]<\infty$ 时: $\phi(t)=E(e^{itX})=E\left(\sum_{k=0}^{+\infty}\frac{(itX)^k}{k!}\right)=\sum_{k=0}^{+\infty}E(X^k)\frac{(it)^k}{k!}$

$$\phi(t)=1+itE(X)-\frac{1}{2}t^2E(X^2)+o(t^2)$$

C. 独立性

$\bar{X} = (X_1 \cdots X_n)$ 为 随机向量.

$\phi(\bar{t}) = E(e^{i\bar{t}^T\bar{X}})$ $\quad \bar{t}=(t_1 \cdots t_n) \in R^n$.

Thm. $\bar{X}$ $(X_1 \cdots X_n)$ 相互独立 $\Longleftrightarrow$ $\phi_{\bar{X}}(\bar{t}) = \phi_1(t_1) \cdots \phi_n(t_n)$

注意：这与 Thm 1.1 不同. 这里 $\underbrace{X_1+\cdots+X_n}_{\downarrow}$，这里 $\underbrace{(X_1 \cdots X_n)}_{\downarrow}$

还是随机变量. 随机向量

因此 1-1 的 $\not\Rightarrow$ 独立

另 这里 $\Longleftrightarrow$ 收敛.

D. 理解： Fourier 变换. 用 $\{e^{itx}\}_{t=-\infty}^{+\infty}$ 这一组标准正交基 表达 $\phi(t)$.

三. 大数之律

Def 2.1 依概率收敛：

$\forall \varepsilon>0$ 若 $\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0$ 则称随机变量序列 $\{X_n\}$ 依概率收敛 X

即： $X_n \xrightarrow{P} X$

注：这个可以为 $\lim_{n\to\infty} P(|X_n - X| > 0) = 0$

因为： $X_n = \frac{1}{n}$ $P=1$ $\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0 \Rightarrow X_n = \frac{1}{n} \xrightarrow{P} 0$

但之： $\lim_{n\to\infty} P(|X_n - X| > 0) = 1$

也就之说，$\lim_{n\to\infty} P(|X_n - X| > 0)$ 这个条件有强.

引理：Markov 不等式：

$$P(|X| \geq \varepsilon) \leq \frac{E(|X|^\alpha)}{\varepsilon^\alpha} \quad \alpha > 0.$$

proof:

$$P(|X| \geq \varepsilon) = E(1_{\{|X| \geq \varepsilon\}})$$

$$= E(1_{\{|X|^\alpha \geq \varepsilon^\alpha\}})$$

$$\leq E\left(\frac{|X|^\alpha}{\varepsilon^\alpha} 1_{\{|X|^\alpha \geq \varepsilon^\alpha\}}\right)$$

$$\leq E\left(\frac{|X|^\alpha}{\varepsilon^\alpha}\right) = \frac{E(|X|^\alpha)}{\varepsilon^\alpha}.$$

这四个相当超级的证明.

推论 → Chebyshev 不等式： $P(|X - EX| \geq \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}$

取 $\alpha = 2$. 原定理改为中心矩即得.

△

Thm 2.1 WLLN. 弱大数定律

① $\{X_n\}$ iid

② $Var(X_1)$ 存在

$\Rightarrow \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} E(X_1)$

当 n 很大时，我们有很大的概率认为 $\frac{1}{n}\sum_{i=1}^{n} X_i$ 很接近 $E(X_1)$

样本均值 总体的均

proof: $\forall \varepsilon > 0$ $P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - E(X_1)\right| \geq \varepsilon\right)$

$\underset{\text{Chebyshev}}{\leq} \frac{Var\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)}{\varepsilon^2} \overset{iid}{=} \frac{Var(X_1)}{n\varepsilon^2} \xrightarrow{n\to\infty} 0.$

一些加注：

Markov: $Var\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) \xrightarrow{n\to\infty} 0$ 时，

上述 $P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - E(X_1)\right| \geq \varepsilon\right) \leq \frac{Var\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)}{\varepsilon^2} \xrightarrow{n\to\infty} 0$

也即：$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} \frac{1}{n}\sum_{i=1}^{n} E(X_i)$

样本均值 期望的值

Khinchin: $\left[\begin{array}{l} ① \text{ 独立同分布} \\ ② \text{ 期望存在} \end{array}\right] \Rightarrow \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} E(X_1)$

对于常数列而言 $X_n \xrightarrow{p} c \iff X_n \xrightarrow{d} c$

proof: 设 X_i 的特征函数为 $\phi(t)$

则：$\frac{1}{n}\sum_{i=1}^{n} X_i = \frac{S_n}{n} \Rightarrow E\left(e^{i\frac{S_n}{n}t}\right) = E\left(e^{i\frac{X_1+\cdots+X_n}{n}t}\right) = E\left(e^{i\frac{X_1}{n}t}\right)\cdots E\left(e^{i\frac{X_n}{n}t}\right) = \left[\phi\left(\frac{t}{n}\right)\right]^n$

$\Rightarrow \phi_{\frac{S_n}{n}}(t) = \left[\phi\left(\frac{t}{n}\right)\right]^n \overset{n\to\infty}{=\!=} \left[1 + iE(X_1)\frac{t}{n} + o\left(\frac{1}{n}\right)\right]^n$

$\frac{S_n}{n} \xrightarrow{p} E(X_1)$ 即 $E(X_1)$ 的常数

令 $n\to\infty$：$\phi_{\frac{S_n}{n}}(t) \xrightarrow{n\to\infty} \underbrace{e^{iE(X_1)t}}_{\text{退化 } E(X_1) \text{ 的特征函数}} \Rightarrow \frac{S_n}{n} \xrightarrow{d} E(X_1)$

Lecture 14 强大数之律. 中心极限之理.

Def 1.1 几乎处处收敛.

$\{X_n\}$为一随机变量序列 X为一随机变量 $P(\lim_{n\to\infty} X_n = X) = 1 \Rightarrow \{X_n\}$几乎处处收敛到 X

$X_n \xrightarrow{a.s.} X$

对比： a.s. 与 $\xrightarrow{P}$

w：稻粒 I_i：稻粒色香合格 P：不合格的面积 $\to 0$ (充效)

$X_n(w)$：经过n次改良后色香合格 a.s.：每个稻粒都应趋于合格 (做到)

$X(w) \equiv 1$：全部合格.

例： $\Omega = [0,1]$ $\mathcal{F} = \mathcal{B} \cap [0,1]$ P取之为概率

对$\forall n \geq 1$. $1 \leq k \leq 2^{n-1}$ $X_{2^{n-1}+k-1}(w) = \begin{cases} 1 & w \in \left[\frac{k-1}{2^{n-1}}, \frac{k}{2^{n-1}}\right) \\ 0 & \text{else} \end{cases}$

$X(w) \equiv 0$

Q.1: $P(|X_{2^{n-1}+k-1}(w) - X(w)| \geq \varepsilon) = P\left(w \in \left[\frac{k-1}{2^{n-1}}, \frac{k}{2^{n-1}}\right)\right] = P\left(\frac{1}{2^{n-1}}\right)$

取$n \to \infty$ 方式 $\to 0$

X_1 : $[0,1)$

X_2 : $[0,\frac{1}{2})$ $[\frac{1}{2},1) \to X_3$ ...

类似一个不断取帧的扫描仪

但之：

$\forall w \in [0,1)$

每个n的状态 总有一个稻粒使得 $X_n(w) = 1$ $\Rightarrow$ 对无穷个n. 使得 $X_n(w) = 1$

于是 $X_n(w) \not\to 0$ a.s.

班级：

hm 1.1.

下先生 几乎处处收敛的判准：

A. 记：$X_n \xrightarrow{a.s.} X \iff P(\limsup_{n\to\infty} |X_n - X| > 0) = 0$

$\iff \forall \varepsilon > 0 \quad P\left(\bigcap_{k=1}^{+\infty} \bigcup_{n=k}^{+\infty} \{|X_n - X| \geq \varepsilon\}\right) = 0.$

$\iff$ "差" 大于 ε，发生的次数为无穷多次 的概率为0

B. Borel - Cantelli （最常用）

用Borel－Cantelli 对于独立的随机变量 可以给出 a.s. 收敛的充要条件：

也可写成 $P\left(\bigcup_{n=1}^{+\infty} \bigcap_{k=n}^{+\infty} B_k\right) = 1$

B_k：$|X_k - X| \leq \varepsilon$

☆ $\sum_{n=1}^{+\infty} P(|X_n - X| > \varepsilon) < \infty$ 则 $X_n \xrightarrow{a.s.} X$

令 $A_i = \{|X_i - X| \geq \varepsilon\}$

表示误差事件.

proof：$B_m = \bigcup_{n=m}^{+\infty} A_n$. $B_m \downarrow$ $B_m \to \bigcap_{m=1}^{+\infty} \bigcup_{n=m}^{+\infty} A_n = \overline{\lim_{n\to\infty}} A_n$. 若：① $\sum P(A_i) < \infty$

则由第一引理

$P(A_n \text{ i.o.}) = 0$

即 A_n 至少出现有限次.

使得"发生误差"的概率为0

$\Rightarrow P(B_m) \leq \sum_{n=m}^{\infty} P(A_n) \xrightarrow{m\to\infty} 0$ （因为 $\sum_{n=1}^{+\infty} P(A_n) < \infty$）

$\Rightarrow P(\overline{\lim_{n\to\infty}} A_n) = \lim_{m\to\infty} P(B_m) = 0.$

于是 $X_n \xrightarrow{a.s.} X$

② $\sum P(A_i) = \infty$. 由 X_i iid

知 A_i iid

由第二引理 $P(A_n \text{ i.o.}) = 1$

于是 $X_n \xrightarrow{a.s.} X$

A_n："发生无穷多次"的概率 $= 0$. 由此 -#

C. 单调列到 + P收敛.

设 $\{X_n\}$ 个 且 依P收敛到 X 则 $X_n \xrightarrow{a.s.} X$

proof：

$\forall \varepsilon > 0 \quad \lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0$

由单调性：$P(\sup_{k \geq n} |X_k - X| \geq \varepsilon) = 0$. 从而 n 于收敛

Thm 1-1. $X_n \xrightarrow{a.s.} X$ 可推出 $X_n \xrightarrow{P} X$

proof: 设 $C = \{\omega \mid \lim_{n\to\infty} X_n(\omega) \to X(\omega)\}$ 由 $X_n \xrightarrow{a.s.} X \Rightarrow P(C)=1$

要证 $B_n = \{\omega \mid |X_n(\omega) - X(\omega)| < \varepsilon\}$ 由 $X_n \xrightarrow{P} X$: $\forall \varepsilon>0$ $P(B_n) \to 1$ $(n\to\infty)$

① $\lim_{n\to\infty} X_n(\omega) = X(\omega)$ 即: $\forall \varepsilon>0$ $\exists K$. $\forall n \geq K$ $|X_n(\omega) - X(\omega)| < \varepsilon$.

即: $\forall \varepsilon>0$ $\omega \in \bigcup_{k=1}^{+\infty} \bigcap_{n=k}^{+\infty} B_n$

即: $C \subset \bigcup_{k=1}^{+\infty} \bigcap_{n=k}^{+\infty} B_n$. 而 $P(C)=1$ $\Rightarrow$ $P(\bigcup_{k=1}^{+\infty} \bigcap_{n=k}^{+\infty} B_n) = 1$

$\Rightarrow \lim_{n\to\infty} P(B_n) = 1$. (利用 $P(\overline{\lim_{n\to\infty} B_n}) = \lim_{n\to\infty} P(\overline{B_n}) \leq \varliminf_{n\to\infty} P(B_n) \leq 1$)

#

Thm 1-2 强大数之律

$\{X_k\}$ 独立同分布. $E|X_1| < \infty$. 则 $\frac{1}{n}\sum_{k=1}^{n} X_k \xrightarrow{a.s.} E(X_1)$ ☆ 与弱相比，条件从 存在 变为 期望存在.

结论 从 以P收敛 变为 a.s. 收敛.

强大数之律: $\frac{1}{n}\sum_{k=1}^{n} X_k \xrightarrow{a.s.} \mu$ 时. 我的猜测 $E(X_k)=\mu$

Khinchin ~ : $\frac{1}{n}\sum_{k=1}^{n} X_k - a_n \xrightarrow{P} 0$ 时. 且 $a_n \to \mu$ 时. 我的猜测 $E|X_k|<\infty$.

例: $X = X_1 X_2 \cdots$ i.i.d

$P(X=m) = P(X=-m) = \frac{C}{2m^2 \ln m}$ $m \geq 3$

则 $\frac{1}{n}\sum_{k=1}^{n} X_k \xrightarrow{P} 0$ 但 X_k 期望不存在.

依 P 收敛 { $P(|X_n - X| \geq \varepsilon)$; 用定义或换元

a.s. 收敛 : Borel-Cantelli

依分布收敛 { 对分布列研究 ; 对 $\varphi_n(t)$ 研究 ; 对 $F_n(t)$ 研究 ; CLT

Def 2.1 依分布收敛

$Y_n \xrightarrow{\text{分布}} F_n(x)$

$Y \xrightarrow{\text{分布}} F(x)$

若在 $F(x)$ 连续点 x, $\lim_{n\to\infty} F_n(x) = F(x)$

则称 $Y_n \xrightarrow{d} Y$

$F_n \xrightarrow{w} F$

Thm 2.1. 中心极限定理

$\{X_k\}$ iid. $E(X_i) = \mu$ $Var(X_i) = \sigma^2 < \infty$

$S_n = X_1 + \cdots + X_n$.

则 $\dfrac{S_n - E(S_n)}{\sqrt{Var(S_n)}} \xrightarrow{d} N(0,1)$

此结论存在：例：$M_n = \dfrac{X_1 + \cdots + X_n}{n}$ $X_i \overset{iid}{\sim}$ Cauchy

则 $M_n \sim$ Cauchy.

pf: $\varphi_{X_1}(t) = E(e^{itX_1}) = e^{-|t|}$

$\varphi_{M_n}(t) = E\left(e^{it\frac{X_1+\cdots+X_n}{n}}\right)$

$= \left[E\left(e^{it\frac{X_1}{n}}\right)\right]^n$

$= \left(e^{-|\frac{t}{n}|}\right)^n = e^{-|t|}$

于是 $M_n \sim$ Cauchy.

☺ $\dfrac{S_n - E(S_n)}{\sqrt{Var(S_n)}} = \dfrac{1}{\sqrt{n}} \sum_{k=1}^n \dfrac{(X_k - \mu)}{\sigma} = \dfrac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$

$Y_k = \dfrac{X_k - \mu}{\sigma}$ iid 且 $E(Y_1) = 0$ $Var(Y_1) = \dfrac{\sigma^2}{\sigma^2} = 1$

即证. $\dfrac{1}{\sqrt{n}} \sum_{k=1}^n Y_k \xrightarrow{d} N(0,1)$

Epic, $\dfrac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$ 的特征函数 $\xrightarrow{n\to\infty} e^{-\frac{1}{2}t^2}$

$= \left[\varphi_{Y_1}\left(\dfrac{t}{\sqrt{n}}\right)\right]^n = \left[E\left(e^{i\frac{t}{\sqrt{n}}Y_1}\right)\right]^n = \left[1 + 0 + \dfrac{E(Y_1^2)}{2}\, i^2 \dfrac{t^2}{n} + o\left(\dfrac{t^2}{n}\right)\right]^n$

$= \left[1 - \dfrac{1}{2}\dfrac{t^2}{n} + o\left(\dfrac{t^2}{n}\right)\right]^n \xrightarrow{n\to\infty} e^{-\frac{1}{2}t^2}$

连续性修正

↑ $S_n \sim B(n,p)$ 时也一样.

应用: $P(k \leq S_n \leq m) \approx \Phi\left(\dfrac{m+0.5-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\dfrac{k-0.5-np}{\sqrt{np(1-p)}}\right)$

例: $n = 1600$ 人 $\frac{3}{4}$ 会看电视. "会在比赛 ≥ 20" 的概率 ≤ 0.1

解: $S = X_1 + \cdots + X_{1600}$ $E(S) = 1200$ $Var(S) = 300$

于是: $P(S \leq m - 200) = P\left(\dfrac{S-1200}{10\sqrt{3}} \leq \dfrac{m-1400}{10\sqrt{3}}\right) \overset{\text{修正}}{\approx} \Phi\left(\dfrac{m-1400+0.5}{10\sqrt{3}}\right) \leq 0.1$

$m \geq 1377.31 \approx 1377$