概率论小班讲义

2099

2022 年 12 月 31 日

特别声明：本文档**不能代替课本和课堂 ppt**，复习应当优先按照课堂内容和课本进行。由于讲义的编写时间较短，目前仍然是 beta 版本，难免有错误，欢迎指正。

1 概率和事件

Definition 1 概率测度

设 $(\Omega, \mathcal{F})$ 为可测空间，$\mathbb{P}$ 是定义在 $\mathcal{F}$ 上的函数。若 $\mathbb{P}$ 满足下面三个条件：

1. 非负性：$\forall A \in \mathcal{F}, \mathbb{P}(A) \geq 0$

2. 归一性（完全性）：$\mathbb{P}(\Omega) = 1$

3. 可列可加性：对 $\mathcal{F}$ 中互不相交的事件 $A_1, A_2, ...$，有

$$\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) \tag{1}$$

则称 $\mathbb{P}$ 为 $\mathcal{F}$ 的概率测度，简称概率，称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。

Q1：有 $\Omega, \mathbb{P}$ 了，$\mathcal{F}$ 是干什么的？

$\mathcal{F}$ 是我们关心的所有事件的集合，$\mathbb{P}$ 作为一个映射，它的定义域是 $\mathcal{F}$，值域是区间 [0,1]。

为什么 $\mathbb{P}$ 不定义在 Ω 上？Ω 只是所有试验结果的集合，比如扔骰子，六个面分别对应 1 到 6，$\Omega = \{1, 2, 3, 4, 5, 6\}$。但如果我们关心的事是“扔骰子，向上的面为奇数”，这个事显然不能用 Ω 里这六个元素中的任何一个表示，所以定义概率这个映射不能以 Ω 作为定义域。遇到这样的情况，我们自然的选择是从 Ω 里挑几个元素，组成一个新的集合，这个从 Ω 里挑出部分（或全部）元素构成的新的集合就叫做**事件**。概率是定义在**事件**上的映射，为了严格地去给它规定一个定义域，我们把所有我们关注的事件拼成一个集合，这就是 $\mathcal{F}$。

太长不看版：Ω 是所有试验结果的集合，一个**事件**是 Ω 的一个子集，我们所关心的全部事件的集合是 $\mathcal{F}$，概率是定义在 $\mathcal{F}$ 上的映射。

（实际上 $\mathcal{F}$ 就是为了保证定义完备的一个工具人，在工科概率论里的存在感很低 hhh）

Q2：$\Omega = \{1, 2, 3, 4, 5, 6\}$，$\sigma(\{1, 2, 3, 4\}, \{3, 4, 5, 6\})$ 是一个什么样的集合？

零分的标准答案：$\{\{1, 2, 3, 4\}, \{3, 4, 5, 6\}\}$。注意 $\sigma(A)$ 表示的是“包含 A 的最小事件域”，这里面肯定不只有 A。（提醒回看教材/ppt）

Definition 2 条件概率：$\mathbb{P}(A) > 0$ 时有：

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(AB)}{\mathbb{P}(A)} \tag{2}$$

Q3：$\mathbb{P}(B|A)$ 一定大于 $\mathbb{P}(B)$ 吗？

体感上会觉得加上条件，样本空间小了，占比大了，条件概率大于无条件概率。
实际上当 $B \subset A$ 时，确实有 $\mathbb{P}(B|A) = \frac{\mathbb{P}(AB)}{\mathbb{P}(A)} = \frac{\mathbb{P}(B)}{\mathbb{P}(A)} \geq \mathbb{P}(B)$
但是不尽然，如果 $AB = \emptyset$，$\mathbb{P}(B|A) = 0 \leq \mathbb{P}(B)$。所以这二者没有绝对的大小关系。

关于条件概率的记号，写成竖杠很清晰，还有另一种写法是把条件写在角标处。这种写法平时不太常用，但是如果遇到多重条件的情况，这样的写法非常好用。比如条件概率有一条无序性，说的是条件的先后不会影响条件概率的大小。即

$$\mathbb{P}(A|BC) = \mathbb{P}((A|B)|C) = \mathbb{P}((A|C)|B) \tag{3}$$

这个表达虽然能看懂，实际证明的时候却极其容易引起混淆。不妨试试下面的写法：

$$\mathbb{P}(A|BC) = \mathbb{P}_C(A|B) = \mathbb{P}_B(A|C) \tag{4}$$

这样看起来会更清晰一些。读者可以试一试分别用这两种记号证明这个性质。

Theorem 1 乘法公式：$\mathbb{P}(A) \geq 0$ 时有：

$$\mathbb{P}(AB) = \mathbb{P}(A)\mathbb{P}(A|B) \tag{5}$$

Theorem 2 全概率公式：$\{A_i\}, i = 1, 2, ..., n$ 是 Ω 的一个分割，$\mathbb{P}(A_i) \geq 0$，则有：

$$\mathbb{P}(B) = \mathbb{P}(A_1)\mathbb{P}(B|A_1) + ... + \mathbb{P}(A_n)\mathbb{P}(B|A_n) \tag{6}$$

Theorem 3 贝叶斯公式：

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(AB)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)} \tag{7}$$

贝叶斯公式，很多地方写的往往比较复杂，其实可能就是对分母又进行了全概率公式的展开。至于究竟要不要展开分母，视情况而定。

Definition 3 一组事件的独立性：
设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间，$A_1, ..., A_n \in \mathcal{F}$，若对任意非空子集 $S \subset 1, 2, ..., n$ 都有：

$$\mathbb{P}(\bigcap_{i \in S} A_i) = \prod_{i \in S} \mathbb{P}(A_i) \tag{8}$$

解读：任取事件集合中任意个数的事件，这些事件都满足交集的概率等于概率的乘积，则该事件集合中所有事件相互独立。一般情况下，我们只要考虑三个事件的独立性就够了。

2 随机变量

2.1 随机变量基础内容

Definition 4 随机变量

设 $(\Omega,\mathcal{F})$ 为可测空间，如果 Ω 上的函数 $X(\omega)$ 满足：$\forall x\in R,\{\omega|X(\omega)\leq x\}\in\mathcal{F}$，则称 $X(\omega)$ 为 $(\Omega,\mathcal{F})$ 上的随机变量，简称随机变量。

随即变量的本质是一个从样本空间到实数的映射（注意是样本空间 Ω 而不是事件域 $\mathcal{F}$）。将随机变量与实数或者其它随机变量建立相等或者不等的关系，即可构成一个事件（相当于划出了一个样本空间的子集，这个子集就是一个事件。提示：回看事件的定义）。比如 X 是随机变量，$X=0$ 就是一个事件，$X\leq 0$ 也是一个事件。一个或许需要注意的例子是 $X=Y$ 这个表达，这个式子出现在概率里可能会让人无从下手（$\mathbb{P}(X\leq Y)$，两边都是随机变量，考虑大小关系需要两头都考虑?），但是改成 $X-Y\leq 0$，就能清晰地看出这是一个事件（$\mathbb{P}(X-Y\leq 0)$，左边是个随机变量的组合，右边是一个数字，这不很明显是事件嘛）。当看不太懂表达式时，可以试着分离变量，让随机变量和常数分列等号/不等号的两端。

太长不看版：随机变量是映射，定义域是 Ω 而不是 $\mathcal{F}$。给定随机变量的取值/划定随机变量的范围相当于分割 Ω，构造其子集，也就是事件。概率定义在事件上。

Definition 5 随机变量独立性

$X_1,...,X_n$ 是 $(\Omega,\mathcal{F})$ 上随机变量，如果对任意实数 $x_1,...,x_n$ 有

$$\mathbb{P}(X_1\leq x_1,...,X_n\leq x_n)=\mathbb{P}(X_1\leq x_1)...\mathbb{P}(X_n\leq x_n) \tag{9}$$

则随机变量 $X_1,...,X_n$ 相互独立。

2.2 离散随机变量

2.2.1 两点分布

$X\sim B(1,p)$，则分布列为 $\mathbb{P}(X=0)=1-p,\mathbb{P}(X=1)=p$，更一般地写成 $\mathbb{P}(X=x)=(1-p)^{1-x}p^x,\quad x=0,1$

$E(X)=p,Var(X)=p(1-p)$

2.2.2 二项分布

$X\sim B(n,p)$，分布列为

$$\mathbb{P}(X=k)=\binom{n}{k}p^k(1-p)^{n-k},k=0,1,...,n \tag{10}$$

$E(X)=np,Var(X)=np(1-p)$

二项分布具有可加性，若 $X\sim B(m,p),Y\sim B(n,p)$ 且 X 与 Y 相互独立（独立性非常重要!），则 $Z=X+Y\sim B(m+n,p)$。由此，二项分布 $B(n,p)$ 也可以看成是 n 个相互独立的两点分布 $B(1,p)$ 加和而来。

2.2.3 几何分布

$X \sim G(p)$，分布列为

$$\mathbb{P}(X=k)=(1-p)^{k-1}p \tag{11}$$

$E(X)=\frac{1}{p}, Var(X)=\frac{1-p}{p^2}$

几何分布具有无记忆性，这是个**充要条件**：

Theorem 4 取正整数值的随机变量 $X \sim G(p)$ 的充分必要条件是 X 具备无记忆性，即 $\forall k \geq 1$：

$$\mathbb{P}(X=k+1|X>k)=\mathbb{P}(X=1) \tag{12}$$

2.2.4 帕斯卡分布

帕斯卡分布和负二项分布其实应当严格地区分开来，但是很多课程并不区分这两个分布，很多课里面说的“负二项分布”实际上都是帕斯卡分布（这两个分布列其实也没有本质区别）。

X 服从帕斯卡分布，若

$$\mathbb{P}(X=k)=\binom{k-1}{r-1}(1-p)^{k-r}p^r, k=r,r+1,... \tag{13}$$

$E(X)=\frac{r}{p}, Var(X)=\frac{r(1-p)}{p^2}$

举例：2099 一直打音游，打同一首曲目，每次成功收歌的概率都是 p，2099 收歌 r 次之后就算打完了不打了。用 X 表示 2099 打完了的时候总共尝试的次数，则 X 服从帕斯卡分布。

r=1 时，帕斯卡分布就是几何分布（怎么会有人收了歌还要继续坐牢啊）。r=k 的帕斯卡分布可以由 k 个相互独立的几何分布相加而得到。

2.2.5 负二项分布

在上述例子中，令 $Y=X-r$，则 Y 是 2099 打完了的时候，收歌失败的次数。

Y 服从负二项分布，若

$$\mathbb{P}(Y=k)=\binom{k+r-1}{r-1}(1-p)^k p^r, k=0,1,... \tag{14}$$

记作 $Y \sim NB(r,p)$

请自行计算期望和方差。

2.2.6 超几何分布

$X \sim H(n,M,N)$，则

$$\mathbb{P}(X=k)=\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}} \tag{15}$$

$E(X)=n\frac{M}{N}, Var(X)=n\frac{M(N-M)(N-n)}{N^2(N-1)}$

2.2.7 负超几何分布 (optional)

在包含 N 个元素的总体当中，M 个是红的，N-M 个是黑的。每次无放回随机抽一个元素，直到抽到 r 个红元素位置，此时共抽取了 k 个黑元素的概率服从负超几何分布。

$X \sim NH(M,N,r)$，若

$$\mathbb{P}(X=k)=\frac{\binom{k+r-1}{k}\binom{N-k-r}{M-r}}{\binom{N}{M}}, k=0,1,...,N-M \tag{16}$$

2.2.8 泊松分布

$X \sim \mathcal{P}(\lambda)$，若

$$\mathbb{P}(X=k)=\frac{\lambda^k}{k!}e^{-\lambda}, k=0,1,2,... \tag{17}$$

$E(X)=\lambda, Var(X)=\lambda$

泊松分布的含义：一段时间内某件事发生的次数。这里大部分教材说的很模糊，2099 尝试表达一下自己的理解。

众所周知 2099 打音游，打音游的时候最怕来微信消息，但是 2099 大渣男有一百个私戳一千个群，时不时就蹦出来微信消息。一首歌两分半，2099 想算一下这两分半里面他收到的微信消息条数的分布列。

2099 先把这两分半分成 n 份，这个 n 要尽可能大，大到不要在两分半/n 这么短的时间内同时蹦出来了两条消息。n 很大分的很细的时候，就可以认为每一小段时间内只有两种结果：来了一条消息，或者没有来消息。

现在又假设 2099 把他的鱼塘调教的很好，每一小段时间内都有相等的概率来一条消息，并且每小段时间来不来消息相互独立。也就是说每小段时间内来消息的个数都服从相互独立的、参数为 p 的伯努利分布（分段分的很多，这个 p 很小）。把第 n 端时间消息条数记作 X_n，那总的消息条数 Y 就是 $Y=\sum_{i=1}^{n}X_i$。显然这个 $Y \sim B(n,p)$。

但是二项分布太难算了！2099 忙着回消息不想算组合数，想搞点近似处理。现在的条件是 **n 很大，p 很小**，而且 2099 身经百战见得多了知道平均一首歌的时间能来 λ 条消息，也就是 $E(Y)=\lambda$，这就有了个额外的条件：$np=\lambda$（这很重要！）。现在干脆就让 n 趋于无穷，我们试试能够得到什么：

$$\lim_{n\to\infty}\mathbb{P}(Y=k)=\lim_{n\to\infty}\binom{n}{k}p^k(1-p)^{n-k}=\frac{1}{k!}\lim_{n\to\infty}n(n-1)...(n-k+1)(\frac{\lambda}{n})^k(1-\frac{\lambda}{n})^n(1-\frac{\lambda}{n})^{-k} \tag{18}$$

稍加化简就得到了

$$\lim_{n\to\infty}\mathbb{P}(Y=k)=\frac{\lambda^k}{k!}e^{-\lambda} \tag{19}$$

这就得到了泊松分布的分布列。

上述过程也是能够用泊松分布近似二项分布的一个简单的证明。从推导中也能看出这个假设的条件是：**n 很大，p 很小，且二者相乘的值固定**，这里尤其要注意 p 很小这个条件，如果 n 很大 p 不太小，就要考虑用正态分布去近似了。

(2099 的实际情况是，打音游的时候会关闭消息通知)

2.3 连续随机变量

2.3.1 连续随机变量的基础内容

Definition 6 连续随机变量

设随机变量 X，如果存在非负函数 $f_X(x)$ 使得 $\forall a < b$，

$$\mathbb{P}(a < X \leq b) = \int_a^b f_X(x)dx \tag{20}$$

则称 X 是连续随机变量，$f_X(x)$ 是 X 的概率密度函数 *(PDF)*

密度函数并不唯一，任意改变有限个点上面的取值并不会改变积分的值。但一般来讲我们总还是希望密度函数是连续的，如果密度函数连续，有一些处理连续型随机变量的土办法可以使用，我们会在分布函数的那一部分进行说明。

2.3.2 均匀分布

区间 $[a,b]$ 上的均匀分布的密度函数为：

$$f(x) = \frac{1}{b-a} I(x \in [a,b]) \tag{21}$$

$E(X) = \frac{a+b}{2}, Var(X) = \frac{(a-b)^2}{12}$

这里面写到了示性函数 $I(x \in [a,b])$，这个函数在括号内条件得到满足时取值为 1，不满足时取值为 0（即：当 $x \in [a,b]$ 时该函数值为 1，$x \notin [a,b]$ 时该函数值为 0）。在表达概率密度函数时使用示性函数（而不是写成大括号 + 分段函数的形式）是一个好的习惯，我们会在讨论独立性的时候讨论为什么。

示性函数的记号有很多种，各种书、各种 ppt 上不尽相同。我个人推荐写成 $I(A)$ 这种，其中 A 是一个事件。这样写的含义是，A 发生则为 1，不发生则为 0。把一切相关的信息写在这个事件里，而不要列出各种上标下标。

记号的清晰性是本讲义一直强调的，比如 X 的密度函数，我一贯坚持将其写成 $f_X(x)$，而不是只把 x 写在函数的小括号里。将随机变量符号写在函数的角标出能够非常清晰地说明这是谁的密度函数。当有多个随机变量时，我们可以放心地写成 $f_X(x), f_Y(y), f_Z(z)$ 这样的形式而不必担心引起任何混淆。密度函数的标号不必是 f，不同的课程似乎有不同的习惯，但我强烈建议不管是什么标号，都把随机变量写在角标处。

2.3.3 指数分布

$X \sim \mathcal{E}(\lambda)$，若

$$f_X(x) = \lambda e^{-\lambda x} I(x > 0), \lambda > 0 \tag{22}$$

$E(X) = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$

指数分布有些像是连续情况的几何分布，它也有无记忆性，而且同样是充分必要条件：

Theorem 5 设 X 是连续非负随机变量，则 X 服从指数分布的充要条件是 X 具有无记忆性，即：

$$\forall s,t \geq 0, \mathbb{P}(X > s+t | X > s) = \mathbb{P}(X > t) \tag{23}$$

2.3.4 正态分布

$X \sim \mathcal{N}(\mu, \sigma)$，若

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} exp(-\frac{(x-\mu)^2}{2\sigma^2}) \tag{24}$$

$E(X) = \mu, Var(X) = \sigma^2$

没有写示性函数，就意味着该式在整个实数轴上成立。

标准正态 $\mu = 0, \sigma = 1$

2.3.5 Gamma 分布 (optional)

设 $\alpha, \lambda > 0$，$X \sim \Gamma(\alpha, \lambda)$，若

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} I(x > 0) \tag{25}$$

其中 $\Gamma(.)$ 是 Gamma 函数，这个函数在一些场景的计算时可能会遇到，推荐了解：

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx \tag{26}$$

三个性质：(a)$\Gamma(n) = (n-1)!$，n 为正整数；(b)$\Gamma(\alpha+1) = \alpha\Gamma(\alpha), \alpha > 0$；(c)$\Gamma(\frac{1}{2}) = \sqrt{\pi}$。

当 $\alpha = 1$ 时，Gamma 分布就是指数分布。r 个独立同分布的指数分布 $\mathcal{E}(\lambda)$ 相加得到的分布为 $\Gamma(r, \lambda)$。由此请自行推导期望和方差

2.3.6 卡方分布 (Chi-squared distribution)

n 个相互独立的标准正态分布的平方和是自由度为 n 的卡方分布。即令

$$X = Z_1^2 + ... + Z_n^2 \tag{27}$$

则 $X \sim \chi_n^2$。

密度函数：卡方分布是特殊的 Gamma 分布，$\chi_n^2 = \Gamma(\frac{n}{2}, \frac{1}{2})$。

2.3.7 Student's t 分布

设 $Z \sim \mathcal{N}(0,1)$，$X \sim \chi_n^2$，且 X 与 Z 独立。令 $T = \frac{Z}{\sqrt{X/n}}$，则 $T \sim t_n$

$n = 1$ 时为 Cauchy 分布，该分布性质特殊，期望不存在。

2.3.8 F 分布 (Fisher Snedecor distribution)

设有独立同分布的随机变量 $X_i \sim \mathcal{N}(0,1), i = 1, 2, ..., m$ 和 $Y_j \sim \mathcal{N}(0,1), j = 1, 2, ..., n$，令

$$F = \frac{(\sum_{i=1}^m X_i^2)/m}{(\sum_{j=1}^n Y_j^2)/n} \tag{28}$$

则 $F \sim F(m, n)$

2.4 分布函数、密度函数及拓展

Definition 7 *分布函数 (distribution function)*

对随机变量 X，称 x 的函数

$$F_X(x) = \mathbb{P}(X \leq x), x \in R \tag{29}$$

为 X 的**概率分布函数**或累积分布函数，简称为**分布函数** *(CDF)*。

对于连续随机变量自然有：

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^{x} f_X(t)dt \tag{30}$$

离散随机变量会得到阶梯状的分布函数。当然对于既不离散也不连续的随机变量，也能定义出分布函数（随机变量的定义保证了分布函数的良定义）。任何随机变量都可定义分布函数。

分布函数的性质：

1. $F_X(x)$ 单调非降；
2. $F_X(-\infty) = \lim_{x\to-\infty} F_X(x) = 0, F_X(+\infty) = \lim_{x\to+\infty} F_X(x) = 1$；
3. $F_X(x)$ 是右连续的。

右连续是小于等于符号决定的，如果是小于号，则是左连续。我不知道有没有课程定义了左连续的分布函数，但是即使那样定义也是合理的。但是在这个讲义里我们总是讨论右连续的分布函数。

Q4：如何用分布函数表示 $\mathbb{P}(a \leq X \leq b)$？

立刻写出：$F_X(b) - F_X(a)$，那么恭喜，这就是零分的标准答案。

上面这个式子对应的是 $\mathbb{P}(a < X \leq b)$，$X = a$ 这一点的概率就这样被吃掉了？连续的时候是对的，但是一般情况下自然不对。正确的写法应当使用左极限：

$$\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a^-) \tag{31}$$

有了分布函数的定义后，我们可以对 2.3.1 处所说的“土办法”给出一个说明了。

Theorem 6 *连续随机变量在区间微元上的概率*

对连续随机变量 X，我们关注它在一段小区间上的特征，即

$$\mathbb{P}(x < X \leq x + \Delta x) = F_X(x + \Delta x) - F_X(x) \tag{32}$$

对于其密度函数 $f_X(x)$，如果它是分布函数的导函数，则有一阶近似

$$\mathbb{P}(x < X \leq x + \Delta x) = F_X(x + \Delta x) - F_X(x) \approx f_X(x)\Delta x \tag{33}$$

在极限情况下等号严格成立，我们形式化地记作：

$$\mathbb{P}(x < X \leq x + dx) = F_X(x + dx) - F_X(x) \approx f_X(x)dx \tag{34}$$

这里本来要放的是单点的定义，但是那样定义不严谨而且很容易出错，而小区间上的概率则是严格成立的。我们会在讨论随机变量函数的分布时用到它。

2.5 随机变量函数的分布

核心研究的问题：$Y = g(X)$（注意是大写 X，表示随机变量），已知 X 的分布，考虑 Y 的分布。

核心要点：随机变量作为映射的本质。如果能写成 $Y = g(X)$，那它们一定对应着相同的样本空间 Ω，在相同的样本空间上，相同的事件对应相同的概率。

离散型随机变量的函数分布比较简单，几乎只需要单纯换元即可。下面主要讨论连续型的情况。

2.5.1 通用方法：使用分布函数转化

如果 $g(.)$ 单调递增且反函数 $g^{-1}(.)$ 存在，则

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y)) \tag{35}$$

一般的情况需要具体问题具体分析，但是核心的要点在于把函数转化为概率表达式，之后利用处理事件的方法来处理概率即可。

非单调函数要注意事件“一对多”的可能。以卡方分布 Y 为例，$X \sim \mathcal{N}(0,1)$，$Y = X^2$，若要用 CDF 转化计算，则：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) \tag{36}$$

这样的情况在分布函数转化容易看出，但是在后面讲的密度函数转化中会一次又一次坑惨不少人。

2.5.2 连续随机变量：密度函数的转化

Theorem 7 连续随机变量密度函数互化

设 X 的概率密度 $f_X(x)$，$D \subset R, Y = g(X), \mathbb{P}(Y \in D) = 1$，如果

1. 对 $y \in D$，$\{Y = y\} = \bigcup_{i=1}^{n} \{X = h_i(y)\}$；
2. 每个 $h_i(y)$ 是 D 到其值域 D_i 的可逆映射，在 D 内有连续的导数；
3. $D_1, D_2, ..., D_n$ 互不相交；

则 Y 的密度函数为：

$$f_Y(y) = \sum_{i=1}^{n} f_X(h_i(y)) |h_i'(y)| I(y \in D) \tag{37}$$

这里复杂的求和号都是针对多值对应来的。实际上这个公式是为了严谨而写，如果只为了记忆，可以直接忽略这些条件，写成：

$$f_Y(y) = \sum f_X(x) |\frac{dx}{dy}| \tag{38}$$

如果 $g(.)$ 严格单调，则更加方便：

$$f_Y(y) = f_X(x) |\frac{dx}{dy}| \tag{39}$$

下面我们尝试利用 Theorem6 解释这件事。

考虑 $Y = g(X)$，其中 $g(.)$ 严格单调递增并且有反函数。之前说过，Y 和 X 都是在相同样本空间 Ω 上的映射。现在我们考虑事件 $x < X \leq x + dx$，这是一个事件，对应着样本空间的一个子集。然后我们再

考虑 $g(x) < g(X) \leq g(x+dx)$，这和上面描述的显然是一个事件。现在令 $y = g(x)$，那这个事件就可以写成 $y < Y \leq y + dy$。

既然描述的是同一个事件，那么它们的概率当然是一样的。于是有：

$$\mathbb{P}(y < Y \leq y + dy) = \mathbb{P}(x < X \leq x + dx) \tag{40}$$

现在我们利用式 (34)，就得到了

$$f_Y(y)dy = f_X(x)dx \tag{41}$$

“移项”就得到了 (39)（学数学的老哥看完应该已经气疯了）。注意我们刚刚讨论的是 $g(.)$ 严格单调递增的情况，如果是单调递减的，那就需要加一个负号来保证密度函数为正。更方便的记法则是干脆直接加上绝对值。

借助这个框架，我们尝试解释 (38)，也就是最坑人的多值对应的情况。现在考虑 $g(.)$ 不再是一个严格单调函数的情况，此时一个 Y 的取值能够对应多个 X 的取值。也就是说，事件 $y < Y \leq y + dy$ 对应了多个事件 $x_1 < X_1 \leq x_1 + dx, x_2 < X_2 \leq x_2 + dx, ..., x_n < X_n \leq x_n + dx$。那么有

$$\mathbb{P}(y < Y \leq y + dy) = \sum_{i=1}^{n} \mathbb{P}(x_i < X \leq x_i + dx) \tag{42}$$

相应地就有

$$f_Y(y)dy = \sum_{i=1}^{n} f_X(x_i)dx \tag{43}$$

“移项”就得到了 (38)

2.6 随机向量

随机向量这部分涉及联合分布、边缘分布、条件分布等，记号混淆是最大的问题。我们通过定义逐步梳理这一部分所用到的记号。

Definition 8 *n 维随机向量*

如果 $X_1, ..., X_n$ 都是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量，称 $\boldsymbol{X} = (X_1, ..., X_n)$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 n 维随机向量，简称随机向量。

Definition 9 *联合分布函数*

设 $\boldsymbol{X} = (X_1, ..., X_n)$ 是随机向量，称 $\mathbb{R}^n$ 上的 n 元函数

$$F(x_1, x_2, ..., x_n) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, ..., X_n \leq x_n) \tag{44}$$

为 $\boldsymbol{X}$ 的联合概率分布函数，简称分布函数或者联合分布。

推荐写法：仍然推荐把随机变量的符号写在角标，除非随机变量的个数太多了。比如 X, Y, Z 的联合分布，我仍然习惯写成 $F_{XYZ}(x, y, z)$。这里 XY 写在一起不会引起混淆，如果真的相乘，那应当合成一个随机变量，那就不是联合分布了。

Definition 10 边缘分布

对 $1 \leq k < n, S_k = \{i_1, i_2, ..., i_k\}$ 为指标集，称 $\boldsymbol{X}_{S_k} = (X_{i_1}, X_{i_2}, ..., X_{i_k})$ 的联合分布为 $F(x_1, x_2, ..., x_n)$ 的 k 维边缘分布。

边缘分布由联合分布唯一确定，反之不成立。

计算边缘分布，只需要在联合分布函数中，让出现在联合分布而没有出现在边缘分布里的变量趋于无穷即可。比如已知 X, Y, Z, W 的联合分布 $F_{XYZW}(x, y, z, w)$，那 X, Y 的联合分布就是 $F_{XY}(x, y) = \lim_{z,w \to +\infty} F_{XYZW}(x, y, z, w)$。

2.6.1 离散随机向量

离散随机向量是每一个分量都是离散随机变量的随机向量，可以定义联合分布列 $\mathbb{P}(X_1 = x_1, ..., X_n = x_n)$ 和对应的边缘分布列。从联合分布推边缘分布只需对没有出现在边缘分布的自变量求和。

一个经典的例子是多项分布：

Definition 11 多项分布

设 $A_1, ..., A_r$ 是试验 S 的完备事件组。对试验 S 进行 n 次独立重复试验时，用 X_i 表示 A_i 发生的次数，则 $(X_1, ..., X_r)$ 的概率分布是

$$\mathbb{P}(X_1 = k_1, ..., X_r = k_r) = \frac{n!}{k_1!...k_r!} p_1^{k_1} ... p_r^{k_r} \tag{45}$$

其中 $k_i \geq 0, p_i = \mathbb{P}(A_i), \sum_{i=1}^{r} k_i = n$

多项分布的边缘分布列：对 $1 \leq m < n$，$(X_{j_1}, X_{j_2}, ..., X_{j_m})$ 的边缘分布为

$$\mathbb{P}(X_{j_1} = k_1, ..., X_{j_m} = k_m) = \frac{n!}{k_1!...k_m!k!} p_{j_1}^{k_1} ... p_{j_m}^{k_m} q^k \tag{46}$$

其中 $k = n - \sum_{i=1}^{m} k_i, q = 1 - \sum_{i=1}^{m} p_{j_i}$。

如果上述边缘分布只剩下一项，那多项分布将退化为二项分布。

2.6.2 连续随机向量

连续随机向量也可以定义联合密度函数 $f(x_1, ..., x_n)$，边缘密度可以通过联合密度积分得到。若 X, Y, Z, W 的联合密度为 $f_{XYZW}(x, y, z, w)$，则 X, Y 的边缘密度 $f_{XY}(x, y) = \iint_{\mathbb{R}^2} f_{XYZW}(x, y, z, w) dz dw$

多元正态分布是一个典型的例子，这里不详细展开了。

2.6.3 条件分布

Definition 12 条件分布

设 $X_1, ..., X_n$ 是随机向量，$S_k = \{i_1, i_2, ..., i_k\}$ 为指标集，称 $\boldsymbol{X}_{S_k} = (X_{i_1}, X_{i_2}, ..., X_{i_k})$ 的联合分布为 $F(x_1, x_2, ..., x_n)$ 的 k 维条件分布，当且仅当

$$\mathbb{P}(X_{i_1} = x_{i_1}, ..., X_{i_k} = x_{i_k} | X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n}) = \frac{\mathbb{P}(X_{i_1} = x_{i_1}, ..., X_{i_k} = x_{i_k}, X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n})}{\mathbb{P}(X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n})} \tag{47}$$

其中 $1 \leq k < n$，$S_k = \{i_1, i_2, ..., i_k\}$ 为指标集。

Hey copilot! Are u the very ai *that will take over the world? I'm not sure if I should be scared or not.*

解释一下上面发生了什么，当我打开 vscode，把鼠标点在 subsection{条件分布 } 后面的时候，代码辅助 ai，copilot，帮我写下了这一整段定义。上一行的斜体是我吃惊之余写下前半行后 copilot 续的完整的句子，显然她知道我在想什么！

先不说 ai 的事，回到定义。上面这个定义是完整的，但是略显复杂，我们最常用的算式还是下面这两个：

离散随机变量：

$$\mathbb{P}(X=x|Y=y)=\frac{\mathbb{P}(X=x,Y=y)}{\mathbb{P}(Y=y)} \tag{48}$$

连续随机变量：

$$f_{X|Y}(x,y)=\frac{f_{XY}(x,y)}{f_Y(y)} \tag{49}$$

注意这里连续型条件密度的记号：$f_{X|Y}(x,y)$，而不是 $f_{X|Y}(x|y)$，这是因为条件密度是关于 x 和 x 的联合密度的函数，符号里面就应该规规矩矩地写成 (x,y)，$(x|y)$ 这个记号虽然能明白是什么意思，但总还是不规范的。当然优化记号的目的是不引起混淆，写成 $f_{X|Y}(x|y)$ 当然清晰，但是一定不要写成 $f(x|y)$。总是在每一个函数后面加上下标，这样就不会引起混淆了。

在了解了条件分布后，我们可以讨论关于独立性的问题了。

Theorem 8

对离散随机变量 X,Y，二者独立的充要条件为

$$\mathbb{P}(X=x_i|Y=y_j)=P(X=x_i),\quad \forall i,j\geq 1 \tag{50}$$

这等价于

$$\mathbb{P}(X=x_i,Y=y_i)=\mathbb{P}(X=x_i)\mathbb{P}(Y=y_i) \tag{51}$$

离散型随机向量判断独立性一般比较简单，我们重点关注连续型随机向量的情况：

Theorem 9

对连续随机变量 X,Y，二者独立的充要条件为，$\forall y\in\{y|f_Y(y)>0\}$

$$f_{X|Y}(x,y)=f_X(x),\quad \forall x\in\mathbb{R} \tag{52}$$

这等价于

$$f_{XY}(x,y)=f_X(x)f_Y(y),\quad \forall x,y\in\mathbb{R} \tag{53}$$

当然，判断独立性并不一定非要计算边缘分布，我们有如下的定理：

Theorem 10

对于任意的随机变量 X,Y，若存在函数 $g(x),h(y)$，使得

$$f_{XY}(x,y)=g(x)h(y),\quad \forall x,y\in\mathbb{R} \tag{54}$$

则 X,Y 独立。

这个定理的意思是，如果我们能找到一个函数，使得 X,Y 的联合分布可以写成两个函数的乘积，那么 X,Y 就是独立的。这里注意 x,y 的取值范围是整个实数轴，使用示性函数表达密度函数的好处再一次体现了出来。使用示性函数就能够把取值范围作为函数囊括进 $g(x),h(y)$ 中，如果不能囊括进去，那就不独立。比如单位圆上的均匀分布 $f_{XY}(x,y)=\frac{1}{\pi}I(x^2+y^2\leq 1)$，虽然前面能拆开，但是示性函数 $I(x^2+y^2\leq 1)$ 是无论如何不能拆成两个分别关于 x 和 y 的函数的乘积的，所以这个分布里面的 X 和 Y 就不是独立的。

2.6.4 随机向量函数的分布

和之前随机变量函数的分布那部分类似，我们的核心研究的问题是：$\boldsymbol{Y}=g(\boldsymbol{X})$，已知 $\boldsymbol{X}$ 的分布，考虑 $\boldsymbol{Y}$ 的分布。注意这里 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 的维数是可能不相同的。

一般的情形仍然是通过分布函数，把随机变量化为事件进行考虑，不过这样做一般比较麻烦。我们主要考虑以下几个特殊情形：

1. $Z=X+Y$：卷积公式

对于离散情况

$$P_Z(z)=\mathbb{P}(X+Y=z)=\sum_x \mathbb{P}(X=x,Y=z-x) \tag{55}$$

如果 X,Y 独立，则

$$P_Z(z)=\sum_x \mathbb{P}(X=x)\mathbb{P}(Y=z-x)=\sum_x P_X(x)P_Y(z-x) \tag{56}$$

此时 Z 的分布列为 X 和 Y 的分布列的卷积。

对于连续情况：设 (X,Y) 的联合分布为 $f_{XY}(x,y)$，则 $Z=X+Y$ 的密度函数为

$$f_Z(z)=\int_{-\infty}^{\infty} f_{XY}(x,z-x)dx \tag{57}$$

如果 X,Y 独立，则

$$f_Z(z)=\int_{-\infty}^{\infty} f_X(x)f_Y(z-x)dx \tag{58}$$

这里能体现出将随机变量写在下标的好处，即使括号里面的内容再变，我们也总是知道这是谁的密度函数。

2. 多个函数的联合密度

严格的定理很复杂，在这里不在完整列出。在二维且一一对应的情况下，读者只需要知道它有如下的形式：

$$f_{UV}(u,v)=f_{XY}(x,y)|det(\frac{\partial(x,y)}{\partial(u,v)})| \tag{59}$$

其中，(X,Y) 是随机变量，$U=u(X,Y),V=v(X,Y)$ 是 (X,Y) 的一一对应映射 $X,Y\xrightarrow{u,v}U,V$。关于这件事的理解，我们再次尝试拓展 Theorem6，定义

$$\mathbb{P}(x<X\leq x+dx,y<Y\leq y+dy)=f_{XY}(x,y)d(x,y) \tag{60}$$

这里的 $f_{XY}(x,y)$ 同样是由分布函数求导（二阶偏导）得到的那个“好的”密度函数。和 (41) 类似地有

$$f_{UV}(u,v)d(u,v) = f_{XY}(x,y)d(x,y) \tag{61}$$

“移项”然后把 d 改成 ∂ 就得到了 (59) 式（数学老哥估计再次被气晕）。由于密度函数应当是正的，所以加一个绝对值。

这样的理解可以处理一对多的情况，像 (42) 那样：如果 $(U,V) = (u,v)$ 对应着多组 $(X,Y) \in \{(x_1,y_1),...,(x_n,y_n)\}$，那么 (61) 式就化为

$$f_{UV}(u,v)d(u,v) = \sum_{i=1}^{n} f_{XY}(x_i,y_i)d(x_i,y_i) \tag{62}$$

相应地 (59) 式也变为

$$f_{UV}(u,v) = \sum_{i=1}^{n} f_{XY}(x_i,y_i)|det(\frac{\partial(x_i,y_i)}{\partial(u,v)})| \tag{63}$$

特别留意，二维的这种“一对多”不是那么容易一眼看出的，需要仔细识别！一维情况 $Y = X^2$ 好认，二维最经典的 $U = X^2 + Y^2, V = \frac{X}{Y}$ 却每一次都在坑人。对于一个 (U,V)，如果有 (X,Y) 与之对应，那么 $(-X,-Y)$ 也与之对应。如果不放心计算的结果对不对，可以在算完之后检查一下密度函数的归一性。如果不归一，就要检查是否存在“一对多”了。

以上是二元随机向量到二元随机向量的函数，如果是二元到一元，可以构造一个辅助的变量，比如要算 $U = g(X,Y)$，但是现在没有 V，我就随便指定 $V = X$（或者任何便于计算的其它形式），算出 U,V 的联合密度函数，然后积分得到 U 的边缘分布。虽然这不是最简单的方法，但它大部分情况下都能得到正确结论。

3 次序统计量

次序统计量主要是理解概念然后背公式，一些班可能不讲，讲过的班如果需要的话可以回看课件，这里只列出部分性质。

Definition 13 次序统计量

设 $X_1, X_2, ..., X_n$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量，对 $\omega \in \Omega$，将 $X_1(\omega), X_2(\omega), ..., X_n(\omega)$ 从小到大排列得到

$$X_{(1)}(\omega) \le X_{(2)}(\omega) \le ... \le X_{(n)}(\omega) \tag{64}$$

称 $X_{(1)}, X_{(2)}, ..., X_{(n)}$ 为 $X_1, X_2, ..., X_n$ 的次序统计量。

Theorem 11 次序统计量的联合密度

$(X_{(1)}, X_{(2)}, ..., X_{(n)})$ 有联合密度

$$g(x_1, ..., x_n) = n! \prod_{i=1}^{n} f(x_i) I(x_1 < ... < x_n) \tag{65}$$

这里不把变量写角标了，太麻烦了……知道是什么意思就可以了……

Theorem 12 次序统计量的边际密度

$X_{(k)}$ 有密度

$$g_{X_{(k)}}(x_k) = n\binom{n-1}{k-1}[F(x_k)]^{k-1}[1-F(x_k)]^{n-k}f(x_k) \tag{66}$$

还有两条不列了，摆烂 TAT

虽然这里的大部分内容是记忆性质，但是最大值最小值的分布是必须要掌握形式和证明方法的。这里证明最大值的分布，最小值的分布可以类似得出。

Proof 1 最大值分布

设 $X_1, X_2, ..., X_n$ 是独立同分布的随机变量,其共同的密度函数记作 $F_X(x)$,记 $Y = \max\{X_1, X_2, ..., X_n\}$,则有:

$$F_Y(y) = \mathbb{P}(\max\{X_1, X_2, ..., X_n\} \le y) = \mathbb{P}(X_1 \le y, ..., X_n \le y) = \prod_{i=1}^{n}\mathbb{P}(X_i \le y) = \prod_{i=1}^{n}F_X(y) = F_X^n(y) \tag{67}$$

独立性保证了第二个等号可以拆开，同分布保证了最后一个等号的 n 次方。

4 p 分位数和随机变量的生成

4.1 p 分位数

p 分位数主要会在统计推断中用到，这里只列出定义和一些性质，具体的推导过程可以参考课件。

Definition 14 随机变量的 p 分位数

设 X 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量，$p \in (0,1)$，则称 X 的 p 分位数为

$$F^{-1}(p) = \inf\{x \in \mathbb{R} | \mathbb{P}(X \le x) \ge p\} \tag{68}$$

通常用 ξ_p 表示。

Theorem 13 p 分位数的性质

1. $F^{-1}(p)$ 单调非降;
2. $F^{-1}(F(x)) \le x, \quad \forall x \in \mathbb{R}$;
3. $F(F^{-1}(p)) \ge p, \quad \forall p \in (0,1)$;
4. $F^{-1}(p)$ 是左连续的;
5. $F^{-1}(p) \le t \Leftrightarrow p \le F(t)$;
6. 如果 F 是连续的，则 $F(F^{-1}(p)) = p, \quad \forall p \in (0,1)$。

p 分位数在概率论部分了解即可，统计部分中会用的多一些。

4.2 随机变量的生成

Theorem 14 产生服从分布函数 $F(x)$ 的随机变量

设 $X \sim \mathcal{U}(0,1)$，$F(x)$ 是连续分布函数，则

$$Y = F^{-1}(X) \sim F \tag{69}$$

即，按照上式生成的 Y 是服从分布函数 $F(x)$ 的。

这件事应该相当好证明。说说我们为什么需要这件事：如果想用计算机生成一个随机变量的话，我们要知道它生成一个均匀分布已经够困难了，你还像让它直接生成服从各种分布的？简直是太反计算机了，copilot 看了都落泪。所以我们就用上面的方法，通过能够生成的均匀分布，生成我们想要的分布的随机变量。

5 期望和方差

5.1 基础内容

5.1.1 期望

Definition 15 离散随机变量的期望

设 X 有概率分布

$$\mathbb{P}(X = x_i), i = 1, 2, ... \tag{70}$$

如果 $\sum_{i=1}^{\infty} |x_j| \mathbb{P}(X = x_j) < +\infty$，则称

$$E(X) = \sum_{i=1}^{\infty} x_j \mathbb{P}(X = x_j) \tag{71}$$

为 X 的数学期望。

Definition 16 连续随机变量的期望

如果连续随机变量 X 的密度函数是 $f_X(x)$，如果

$$\int_{-\infty}^{+\infty} |x| f_X(x) dx < +\infty \tag{72}$$

则

$$\int_{-\infty}^{+\infty} x f_X(x) dx < +\infty \tag{73}$$

为 X 的数学期望。

定义里面对绝对收敛的要求是为了保证换序求和的正确性。

这里我们能够再次看到在密度函数的表达里引入示性函数的好处：我们可以放心地对整个实数轴积分，示性函数会提醒我们实际的积分范围。

Theorem 15 期望的性质

设 $E|X| < +\infty, E|Y| < +\infty$，$a, b, C$ 为实数，则

1. $E(C) = C$;

2. $|E(X)| \leq E|X|$;

3. $E(aX + bY) = aE(X) + bE(Y)$（期望的线性性质）;

4. X 和 Y 独立，则 $E(XY) = E(X)E(Y)$。

Theorem 16 复合函数的期望（懒人公式）

设 $\boldsymbol{X} = (X_1, X_2, ..., X_n)$ 是随机向量，$\boldsymbol{x} = (x_1, x_2, ..., x_n) \in \mathbb{R}^n$。如果 $\boldsymbol{X}$ 有联合分布函数 $F(\boldsymbol{x})$，实函数 $g(\boldsymbol{x})$ 使得

$$\int_{\mathbb{R}^n} |g(\boldsymbol{X})| dF(\boldsymbol{x}) < \infty \tag{74}$$

则 $Y = g(\boldsymbol{X})$ 有数学期望

$$E(Y) = E(g(\boldsymbol{X})) = \int_{\mathbb{R}^n} g(\boldsymbol{x}) dF(\boldsymbol{x}) \tag{75}$$

如果是连续随机变量，联合密度函数为 $f(\boldsymbol{x})$ 上式可以写成

$$E(Y) = E(g(\boldsymbol{X})) = \int_{\mathbb{R}^n} g(\boldsymbol{x}) f(\boldsymbol{x}) d\boldsymbol{x} \tag{76}$$

注意如果有多个随机变量,这就是个重积分,有多少个变量就是几重积分。比如 $E(X^2) = \int_{\mathbb{R}} x^2 f_X(x) dx$，而 $E(XY^2) = \int_{\mathbb{R}^2} xy^2 f_{XY}(x, y) dxdy$

通过懒人公式和示性函数的一些技巧，我们能够得到一个通过联合密度计算概率的方法。考虑下面的问题：

Q5：已知 (X, Y) 的联合密度函数 $f_{XY}(x, y)$，计算 $g(X, Y) \geq 0$ 的概率。

常规的方法是算出 $Z = g(X, Y)$ 的分布，然后计算概率，但是懒人公式让我们可以通过几何图形的方法去“偷懒”：我们可以画出 $g(x, y) \geq 0$ 的区域和密度函数 $f_{XY}(x, y)$ 的非零区域的交集 D，再在 D 上对密度函数积分，即

$$\mathbb{P}(g(X, Y) \geq 0) = \iint_D f_{XY}(x, y) dxdy \tag{77}$$

其中 $D = \{(x, y) | g(x, y) \geq 0, f_{XY}(x, y) > 0\}$。这件事情的证明首先要用到如下的技巧：

$$\mathbb{P}(g(X, Y) \geq 0) = E(I(g(X, Y) \geq 0)) \tag{78}$$

即：概率等于示性函数的期望。在包含了随机变量的表达式后，示性函数也具有了随机性。由于示性函数的取值只能是 0 或 1，它服从两点分布（此时应称“示性变量”），期望就是它等于 1 的概率，而示性函数等于 1 等价于其括号内的条件成立，也就是说期望就是括号内条件成立的概率，这便是上面的公式 (78)。

有了 (78)，利用懒人公式，我们立刻就能得到

$$E(I(g(X, Y) \geq 0)) = \iint_{g(x,y) \geq 0} f_{XY}(x, y) dxdy \tag{79}$$

这就得到了 (77)。实际上把 $g(x,y)\geq 0$ 写在角标和把 D 写在角标是一样的，把 D 写在角标只是为了计算的时候清晰一些。

5.1.2 方差

有了期望的定义，我们能够方便地定义方差：

Definition 17 随机变量的方差

如果随机变量 X 的期望 $E(X)$ 有限，则称 $E(X-E(X))^2$ 为 X 的方差，记作 $var(X)$ 或 σ_X^2。当 $var(X)<\infty$ 时，称 X 方差有限。

常用计算公式：1. 定义式 $var(X)=E(X-E(X))^2$；2. 等价表达 $var(X)=E(X^2)-E^2(X)$。

Theorem 17 方差的性质

设 $var(X)<\infty$，则

1. $var(aX+b)=a^2var(X), a,b\in\mathbb{R}$；
2. $var(X)=E(X-E(X))^2\leq E(X-c)^2, \forall c\in\mathbb{R}$（这条性质的意义是：期望是均方意义下的最佳估计）；
3. $X_1,...,X_n$ 相互独立，则 $var(\sum_{k=1}^n X_k)=\sum_{k=1}^n var(X_k)$（不独立则要计算协方差）。

关于标准化：

Definition 18 标准差

若随机变量 X 的方差 $var(X)<\infty$，则 $\sigma_X=\sqrt{var(X)}$ 为 X 的标准差

Definition 19 标准化

若随机变量 X 的方差 $var(X)<\infty$，令 $Y=\frac{X-E(X)}{\sqrt{var(X)}}$，则 $E(Y)=0, var(Y)=1$，此时称 Y 是 X 的标准化。

5.1.3 不等式

主要介绍 Markov 不等式，Chebyshev 不等式，内积不等式和 Jensen 不等式。

Theorem 18 *Markov* 不等式

对随机变量 X 和 $\epsilon>0$ 有

$$\mathbb{P}(|X|\geq\epsilon)\leq\frac{E|X|^\alpha}{\epsilon^\alpha}, \alpha>0 \tag{80}$$

Theorem 19 *Chebyshev* 不等式

$$P(|X-E(X)|\geq\epsilon)\leq\frac{var(X)}{\epsilon^2} \tag{81}$$

Theorem 20 内积不等式

设 $E(X^2)<\infty, E(Y^2)<\infty$，则有

$$|E(XY)|\leq\sqrt{E(X^2)E(Y^2)} \tag{82}$$

等号成立当且仅当存在不全为零的常数 a,b，使得 $aX+bY=0\quad a.s.$。

Theorem 21 *Jensen* 不等式

设 $\psi(.)$ 是 $\mathbb{R}$ 上的下凸函数，且 X 和 $\psi(X)$ 都有有限的期望，则有

$$\psi(E(X)) \leq E(\psi(X)) \tag{83}$$

对严格的下凸函数，等号成立当且仅当 $X = E(X) \quad a.sx$

对于 Jensen，如果凸的方向相反，则不等号方向相反。

Markov 不等式可以有一个简洁而富有技巧的证明，以下列出：

Proof 2 *Markov* 不等式的证明

$$P(|X| \geq \epsilon) = E(I(|X| \geq \epsilon)) = E(I(|X|^\alpha \geq \epsilon^\alpha)) \leq E(\frac{|X|^\alpha}{\epsilon^\alpha} I(|X|^\alpha \geq \epsilon^\alpha)) \leq E(\frac{|X|^\alpha}{\epsilon^\alpha}) = \frac{E|X|^\alpha}{\epsilon^\alpha} \tag{84}$$

等号 *1* 利用了示性函数的性质：概率等于示性变量的期望，在前面的 *Q5* 和 *(78)* 中已有说明。

5.2 条件期望

5.2.1 条件在事件上的期望

先考察条件在事件上的随机变量：

离散：$p_{X|A}(x) = \mathbb{P}(X = x|A) = \frac{\mathbb{P}(\{X=x\} \cap A)}{\mathbb{P}(A)}$

连续：$\mathbb{P}(X \in B|A) = \int_B f_{X|A}(x)dx$

可以分别用这些定义来定义事件上的条件期望。

Definition 20 事件上的条件期望

离散型：若 $\sum_{i=1}^{\infty} |x_i| \mathbb{P}(X = x_i|A) < \infty$，则定义 $E(X|A) = \sum_{i=1}^{\infty} x_i \mathbb{P}(X = x_i|A)$

连续型：若 $\int_{\mathcal{R}} |x| f_{X|A}(x|A)dx < \infty$，则定义 $E(X|A) = \int_{\mathcal{R}} x f_{X|A}(x)dx$

定义很直白，计算也很简单：

Theorem 22 条件期望的计算

设 $\mathbb{P}(A) > 0$，$E(X|A)$ 存在，则

$$E(X|A) = \frac{E(XI(A))}{\mathbb{P}(A)} \tag{85}$$

有了条件期望的定义，我们可以有全期望定理。

Theorem 23 全期望定理

设 $A_1, ...A_n$ 构成 Ω 的一个分割，则

$$E(X) = \sum_{i=1}^{n} E(X|A_i)\mathbb{P}(A_i) \tag{86}$$

5.2.2 条件在随机变量上的期望

Definition 21 条件在随机变量上的期望

设 (X,Y) 是随机向量，$E|X|<\infty$，如果 $m(y)=E(X|Y=y)$，就称随机变量 $m(Y)$ 为给定 Y 时 X 的条件期望，记作 $E(X|Y)$。

这个定义很简单，它直接给出了条件期望的算法：算出条件在单点 $Y=y$ 的期望 $m(y)$，然后把所有的 y 用 Y 代替，就得到了条件期望。但是要注意的是，条件在随机变量上的条件期望不再是一个数字，而是一个随机变量了。既然是随机变量，我们可以再给它求一次期望，这就有了重期望公式。

Definition 22 重期望公式

设 X,Y 是随机变量，则

$$E[E(X|Y)]=E(X) \tag{87}$$

这是由全期望公式自然而然得到的结论。

除此之外，条件期望还有很多性质。看到这里可能会有一些乱花渐欲迷人眼，我们只挑出其中比较重要的等式性质来讲：

Theorem 24 条件期望的性质

设 X,Y 是随机变量，$g(x),h(y)$ 是实函数，$E|X|<\infty, E|g(X)|<\infty$，又设随机变量 $X_1,X_2,...,X_n$ 的期望有限，则

1. $E(h(Y)g(X)|Y)=h(Y)E(g(X)|Y)$；
2. $E[E(g(X)|Y)]=E(g(X))$；
3. 若 X,Y 独立，则 $E(g(X)|Y)=E(g(X))$；
4. $E(c+\sum_{i=1}^{n}c_iX_i|Y)=c+\sum_{i=1}^{n}c_iE(X_i|Y)$。

一个需要单独列出的性质是：

Theorem 25 设 X,Y 是随机变量，$h(x)$ 是实函数，若 $E(X^2)<\infty, E(h^2(Y))<\infty$，则

$$E[(X-E(X|Y))h(Y)]=0 \tag{88}$$

之所以单独列出，是因为这个公式在 2099 统推期中证明题完全没思路事救了 2099 的小命……

证明不难，自行完成。这个式子实际上说的是期望的几何意义：$E(X|Y)$ 是 X 在 Y 的张成空间上的投影，根据矢量的减法，$X-E(X|Y)$ 就是那条垂直于 Y 张成空间的线，它自然和张成空间内的任何组合 $h(Y)$ 垂直（乘积的期望为 0）

期望的几何意义就不在这里展开了，大部分班应该都不讲。

5.2.3 条件方差

Definition 23 条件方差

如果 $E\{[X-E(X|Y)]^2|Y\}$ 存在，则称它为给定 Y 下 X 的条件方差，记作 $var(X|Y)$。

Theorem 26 全方差法则

$$var(X)=E[var(X|Y)]+var[E(X|Y)] \tag{89}$$

5.3 协方差和相关系数

Definition 24 协方差

设 $E(X),E(Y)$ 存在，当 $E|(X-E(X))(Y-E(Y))|<\infty$ 时，称

$$E[(X-E(X))(Y-E(Y))]$$

为随机变量 X,Y 的协方差，记作 $cov(X,Y)$。

协方差的一些性质可以用来简化运算。

Theorem 27 协方差的一些性质可以用来简化运算

1. $cov(X,X)=var(X)$;
2. $cov(X,Y)=E(XY)-E(X)E(Y)$;
3. 双线性：$cov(cX,Y)=c\cdot cov(X,Y)$，$cov(X,Y+Z)=cov(X,Y)+cov(X,Z)$
4. $var(X_1+X_2)=var(X_1)+var(X_2)+2cov(X_1,X_2)$

协方差的双线性性质非常常用，需要有足够的敏感性，能够联想到。最典型的例子，$Z=X+Y$，算 $Cov(X,Z)$。不要吭哧吭哧就开始算 $E(XZ)$ 这种东西了，直接把 $Z=X+Y$ 带进去然后用双线性性质造它就完了。

典型协方差计算案例就是多项分布，$cov(X_i,X_j)=-np_ip_j,\quad i\neq j$

Definition 25 相关系数

当 $0<var(X)\cdot var(Y)<\infty$ 时，称

$$\frac{cov(X,Y)}{\sqrt{var(X)var(Y)}} \tag{90}$$

为随机变量 X,Y 的相关系数 *(Pearson's correlation)*，记作 $corr(X,Y)$。

留意相关与独立的联系。相关系数是描述线性相关程度的，不相关不一定独立（比如 $X\sim\mathcal{U}[-1,1],Y=X^2$，两个随机变量具有函数关系，但是相关系数是 0），但是独立一定意味着不相关。

一个或许需要注意的例子是多元正态分布。设 $\boldsymbol{X}=(X_1,X_2,...,X_n)$ 服从多元正态分布，显然每一个 X_i 都服从正态分布。在 $X_1,X_2,...,X_n$ 这一组分布中，如果两个分布不相关，则两个分布独立。特别注意这里的限制条件：**一组多元正态分布**。不是随便拿来两个正态分布，就能由不相关推出独立的。一个典型的例子是 $X\sim\mathcal{N}(0,1)$，随机变量 Y 分别以二分之一的概率等于 X 或者 $-X$。这个 Y 确实是正态分布，而且和 X 不相关，但显然这两个分布是不独立的。这里核心的要点就在于，(X,Y) 并不是一个二元正态分布。

6 特征函数系列

特征函数系列，主要需要掌握的是概率母函数和矩母函数的定义和性质，尤其是矩母函数。主要需要掌握的内容我认为是“随机变量个随机变量相加”这种情形的处理。当然诸如期望方差的计算、独立性判断等内容，此处只是使用另一种方法的延拓，应当不作为重点。

6.1 概率母函数

Definition 26 概率母函数

设 X 是取非负整数值的随机向量，称

$$g_X(s) = E(s^X) = \sum_{j=0}^{\infty} s^j \mathbb{P}(X = j), \quad s \in [-1, 1] \tag{91}$$

为 X 的概率母函数。此处约定 $0^0 = 1$。

Theorem 28 概率母函数的性质

设 X 是取非负整数值的随机向量，$g(s)$ 是 X 的概率母函数，$g^{(k)}(s)$ 是 $g(s)$ 的 k-阶导数，则

1. $\mathbb{P}(X = k) = \frac{g^{(k)}(0)}{k!}, \quad k = 0, 1, 2, ...$;
2. $E(X) = g^{(1)}(1)$;
3. 若 $E(X) < \infty$，则 $var(X) = g^{(2)}(1) + g^{(1)}(1) - [g^{(1)}(1)]^2$。
4. 如果 $X_1, X_2, ..., X_n$ 是相互独立的随机变量，且 $g_{X_i}(s) = E(s^{X_i})$ 是 X_i 的概率母函数，则 $Y = X_1 + X_2 + ... + X_n$ 的概率母函数为 $g_Y(s) = \prod_{i=1}^{n} g_{X_i}(s)$。
5. 概率母函数与概率分布列相互唯一决定。

性质的证明可以参考课件。下面列出几个分布的概率母函数：

1. 二项分布 $B(n, p)$：$g(s) = (q + sp)^n$，其中 $q = 1 - p$;
2. 泊松分布 $P(\lambda)$：$g(s) = e^{\lambda(s-1)}$;
3. 几何分布 $G(p)$：$g(s) = \frac{sp}{1-sq}$（可以用这个推导帕斯卡分布的概率母函数）;

概率母函数一个比较特色的应用在于随机变量个随机变量的求和。

Theorem 29 随机变量个随机变量的求和

1. 设 X_j 是一列独立同分布的非负整值随机变量，且其共同的概率母函数为 $\psi_X(s)$;
2. 设 N 为取正整数值的随机变量，且 N 的概率母函数为 $\psi_N(s)$;
3. N 与 X_j 相互独立;

则随机变量 $W = X_1 + X_2 + ... + X_N$ 的概率母函数为 $\psi_W(s) = \psi_N(\psi_X(s))$。

这个证明最好要会，详细参考课件。

考虑完随机变量，我们可以继续讨论随机向量的情况。随机向量的概率母函数的定义与随机变量的概率母函数类似，只是这里的指数是一个向量，而不是一个标量。

Definition 27 二维随机向量的概率母函数

设 (X,Y) 是二维、取值非负整数的随机向量，其分布列为 $p_{ik}=\mathbb{P}(X=i,Y=k),\quad i,k=0,1,2,...$，则称 (s,t) 的函数

$$g_{(X,Y)}(s,t)=E(s^Xt^Y)=\sum_{i=0}^{\infty}\sum_{k=0}^{\infty}s^it^k\mathbb{P}(X=i,Y=k) \tag{92}$$

为 (X,Y) 的概率母函数。

由此定义可以得到一些性质：

Theorem 30

设 $g(s,t)$ 是二维随机向量 (X,Y) 的概率母函数，则

1. $g_{aX+bY+c}(s)=s^cg_{XY}(s^a,s^b)$，其中 a,b,c 是常数；
2. $|g_{XY}(s,t)|\le g_{XY}(1,1)=1,\quad |s|\le 1,|t|\le 1$；
3. X,Y 独立，等价于 $g_{XY}(s,t)=g_X(s)g_Y(t),\quad \forall s,t$；
4. $g_{XY}(s,1)=g_X(s),\quad g_{XY}(1,t)=g_Y(t)$；
5. $$p_{ik}=\frac{1}{i!k!}\frac{\partial^{i+k}g_{XY}(s,t)}{\partial s^i\partial t^k}\bigg|_{s=t=0},\quad i,k=0,1,2,... \tag{93}$$
6. 如果 X,Y 期望存在，则
$$E(X)=\frac{\partial g_{XY}(s,t)}{\partial s}\bigg|_{s=t=1},\quad E(Y)=\frac{\partial g_{XY}(s,t)}{\partial t}\bigg|_{s=t=1} \tag{94}$$

方差的性质不再列出了。这些性质都是从定义和泰勒展开推出来的，再次提醒关注定义。

提问：为啥没有正态分布捏，因为正态分布是连续分布，概率母函数做不到哒。

6.2 矩母函数

Definition 28 矩母函数

设 X 是一个随机变量，称

$$M_X(s)=E(e^{sX}) \tag{95}$$

为 X 的矩母函数。

当 $\exists h>0,\quad \forall s\in(-h,h),\quad E(e^{sX})<\infty$ 时，我们称矩母函数存在。

Theorem 31 矩母函数的性质

设 X 是一个随机变量，$M_X(s)$ 是 X 的矩母函数，则

1. $Y=aX+b$，则 $M_Y(s)=e^{sb}M_X(sa)$；
2. $E(X^k)=M_X^{(k)}(0),\quad k=0,1,2,...$；

3. $M_X(0)=1$;

4. 当 X 仅取非负整值时，$\mathbb{P}(X=0)=\lim_{s\to-\infty}M_X(s)$;

5. 可逆性：如果存在一个正数 a，$\forall s\in[-a,a],\quad M_X(s)<\infty$，则矩母函数唯一确定 X 的分布。

6. 如果 $X_1,X_2,...,X_n$ 是独立的，且 $M_{X_i}(s)<\infty$，则 $Y=X_1+X_2+...$ 的矩母函数为

$$M_Y(s)=\prod_{i=1}^{n}M_{X_i}(s) \tag{96}$$

证明也都是从定义出发的。下面列出几个连续分布的矩母函数：

1. 指数分布 $\mathcal{E}(\lambda)$：$M_X(s)=\frac{\lambda}{\lambda-s}$;
2. 正态分布 $\mathcal{N}(\mu,\sigma^2)$：$M_X(s)=e^{\mu s+\frac{\sigma^2s^2}{2}}$;

与概率母函数类似，矩母函数也可以用来处理随机变量个随机变量的求和：

Theorem 32 设随机变量 $X_1,X_2,...,X_n$ 独立同分布，其共同的矩母函数为 $M_X(s)$，N 是一个区正整数值的随机变量，且独立于 $X_1,X_2,...,X_n$，令 $Y=X_1+...+X_N$，则 Y 的矩母函数为

$$M_Y(s)=M_N[ln(M_X(s))] \tag{97}$$

这个证明是需要简单说明一下的：

Proof 3

令 $Y=X_1+...+X_N$，则

$$\begin{aligned}E(e^{sY}|N=n)&=E(e^{s(X_1+...+X_n)}|N=n)\\&=E(e^{sX_1}e^{sX_2}...e^{sX_n})\\&=E(e^{sX_1})E(e^{sX_2})...E(e^{sX_n})\\&=M_X(s)^n\end{aligned}$$

由此知 $E(e^{sY}|N)=M_X(s)^N$

$$\begin{aligned}M_Y(s)&=E(e^{sY})\\&=E(E(e^{sY}|N))\\&=E(M_X(s)^N)\\&=\sum_{n=1}^{\infty}(M_X(s))^n\mathbb{P}(N=n)\end{aligned}$$

对比 $M_N(s)=E(e^{sN})$，就得到了 $M_Y(s)=M_N[ln(M_X(s))]$。

对随机向量也可以定义矩母函数，设 $\boldsymbol{X}=(X_1,X_2,...,X_n)$ 是一个随机向量，则 $\boldsymbol{X}$ 的矩母函数为

$$M_{\boldsymbol{X}}(s)=E(e^{s_1X_1+...+s_nX_n}) \tag{98}$$

6.3 特征函数

Definition 29 设 X 是一个随机变量，则 X 的特征函数为

$$\phi_X(t) = E(e^{itX}) = E(cos(tX)) + iE(sin(tX)) \tag{99}$$

特征函数一般是为了处理矩母函数处理不了的分布的，一些分布的矩母函数并不存在，而特征函数则总是与分布一一对应的。但是对那些不得不用特征函数进行处理的分布来说，各种问题的计算一般会非常复杂，考试也几乎不会涉及。这里不再列出特征函数的其它内容。

7 大数定律

7.1 大数定律的几种形式

Theorem 33 *弱大数律 (WLLN)*

设 X_n 是**独立同分布，方差有限**的随机变量序列，则 $\forall \epsilon > 0$

$$\lim_{n\to\infty} \mathbb{P}(|\bar{X}_n - E(X_1)| \geq \epsilon) = 0 \tag{100}$$

也称为 $\bar{X}_n$ 依概率收敛到 $E(X_1)$，记作

$$\bar{X}_n \xrightarrow{p} E(X_1) \tag{101}$$

其中 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$。

大数定律告诉我们，当 n 很大时，我们有很大的把握（但并非 100%）断言 $\bar{X}_n$ 的值会接近 $E(X_1)$。大数定律的证明似乎是要求掌握的，下面给出一个简单的证明。

Proof 4 *WLLN* 的证明

X_n 是**独立同分布，方差有限**的随机变量序列，由 *Chebyshev* 不等式

$$\begin{aligned}\mathbb{P}(|\bar{X}_n - E(X_1)| \geq \epsilon) &= \mathbb{P}(|\bar{X}_n - E(\bar{X})| \geq \epsilon) \\ &\leq \frac{var(\bar{X}_n)}{\epsilon^2} \\ &= \frac{var(X_1)}{n\epsilon^2} \to 0, \quad n \to +\infty\end{aligned}$$

弱大数定律是使用 Chebyshev 不等式对大样本性质的一个描绘，计算误差使用的也是 Chebyshev 不等式，可以用来估计样本量（参考初概 ppt 的例子）。但是这种误差的估计毕竟是十分保守的，中心极限定理会给我们更准确的估计。

大数定律的理论深化：条件放宽/结论加强。

首先，WLLN 的成立不一定需要方差有限，该条件可以适当放宽

Theorem 34 独立同分布条件下的拓展：充分必要条件

设 X_n 是独立同分布的随机变量序列，存在实数列 a_n，使得

$$\frac{1}{n}\sum_{k=1}^{n} X_k - a_n \xrightarrow{p} 0 \tag{102}$$

的**充分必要条件**是

$$n\mathbb{P}(|X_1| \geq n) \to 0 \tag{103}$$

此时可取 $a_n = E(X_1 I(|X_1| \leq n))$。

去掉独立同分布的条件还有 Markov 大数律，但是初概 ppt 上没有，等期末讲的时候再补充讲义吧。

其次，依概率收敛的结论不够强，方差有限的前提也过紧了。强大数律放宽了条件，并且得到了更强的结论

Theorem 35 *强大数律 (SLLN)*

设 X_n 是独立同分布的随机变量序列，则

1. 若 $E|X_1| < \infty$，则

$$\bar{X}_n \xrightarrow{a.s.} E(X_1) \tag{104}$$

2. 反之，若

$$\bar{X}_n \xrightarrow{a.s.} C \tag{105}$$

则 $E|X_1| < \infty$，且 $C = E(X_1)$。

其中 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$。记号 $\xrightarrow{a.s.}$ 表示**几乎处处收敛**。

强大数律的条件和结论是充分必要的。

7.2 分布的收敛模式

上一部分的讲义并没有展开说明收敛模式的区别，我们会在这里集中进行说明和区分，特别是依概率收敛和几乎处处收敛的区别。

Definition 30 依分布收敛（弱收敛）

对一列随机变量 $\{X_n\}$ 和一个随机变量 X，如果在 $F_X(x)$ 的连续点 x 处，有

$$\lim_{n\to\infty} \mathbb{P}(X_n \leq x) = F_X(x) \tag{106}$$

则称 X_n 依分布收敛于 X，记作 $X_n \xrightarrow{d} X$。

依分布收敛仅仅是分布的收敛，而不是随机变量的收敛，它是不在乎随机变量之间的相互联系的，只要分布函数的极限相等即可。

Definition 31 依概率收敛

如果 $\forall \epsilon > 0$，有

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \epsilon) = 0 \tag{107}$$

则称 X_n **依概率收敛**到 X，记作 $X_n \xrightarrow{p} X$。

依概率收敛是随机变量的收敛，它是在乎随机变量之间的相互联系的，只有随机变量之间的差值趋于 0，才能说随机变量收敛。

Definition 32 几乎处处收敛

如果

$$\mathbb{P}(\lim_{n\to\infty} X_n = X) = 1 \tag{108}$$

则称 X_n **几乎处处收敛**到 X，记作 $X_n \xrightarrow{a.s.} X$，或 $X_n \to X \quad a.s.$。式 *(105)* 的一个等价表述是：

$$\mathbb{P}\{\omega | \lim_{n\to\infty} X_n(\omega) = X(\omega)\} = 1 \tag{109}$$

几乎处处收敛则不止考查随机变量的概率特征，还考查其背后对应的样本空间特征，考查随机变量作为一个映射的性质。它比依概率收敛更加严格。

Definition 33 L_p 收敛

对 $p > 0$，如果

$$\lim_{n\to\infty} \mathbb{E}(|X_n - X|^p) = 0 \tag{110}$$

则称 X_n **在 L_p 下收敛**到 X，记作 $X_n \xrightarrow{L_p} X$。特别地当 p=2 时称为均方收敛。

L_p 收敛在初概里面并不要求。

定义了收敛模式，我们要讨论收敛模式之间的关系。wljj 课件上的图很好地展示了这些关系。

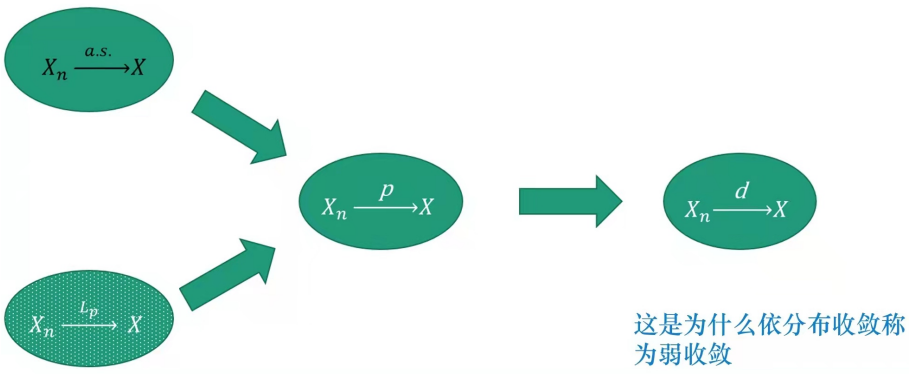


图 1: 四种收敛模式之间的关系

依分布收敛最弱，依概率收敛其次，几乎处处收敛和 L_p 收敛能推出前两者，但不能互推。由于 L_p 收敛在初概里面并不要求，我们不给出它和几乎处处收敛不能互推的反例。但是我们需要给出依概率收敛不能推出几乎处处收敛的一个例子。

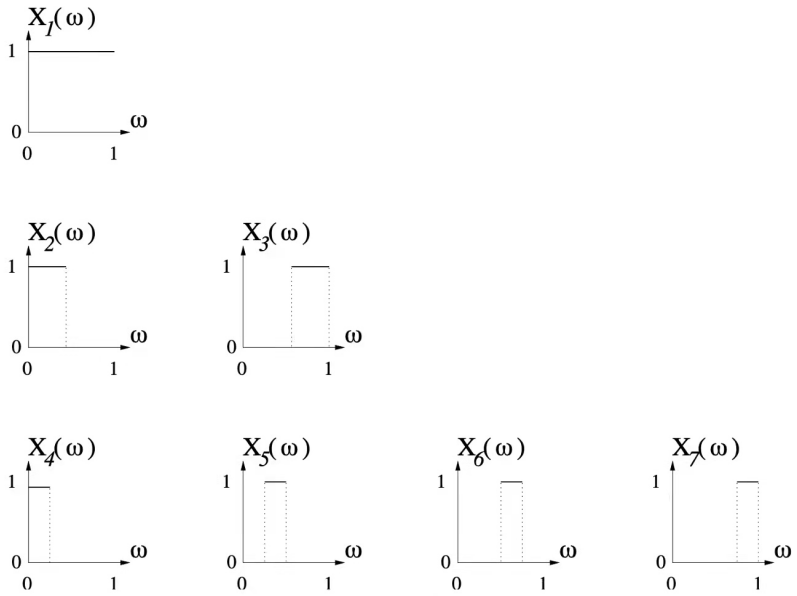


图 2: 依概率收敛不能推出几乎处处收敛

构造上面这样一个随机变量序列 X_n，这个序列除了 X_1 都是两点分布，而且等于 1 的概率 p 越来越小，趋近于 0。很容易得到 $\lim_{n\to\infty}\mathbb{P}(|X_n-0|\geq\epsilon)=0$，也就是依概率收敛。但是考查样本空间 Ω 上的任意一点 ω，不管 n 多大，ω 这个点的概率总会时不时变成一下 1，因此 $\lim_{n\to\infty}X_n(\omega)=0$ 不成立（这个极限不存在）。由于 ω 是任取的，所以对所有的 $\omega\in\Omega$ 都有 $\lim_{n\to\infty}X_n(\omega)=0$ 不成立，也就是 $\{\omega|\lim_{n\to\infty}X_n(\omega)=0\}$ 是个空集，那么

$$\mathbb{P}\{\omega|\lim_{n\to\infty}X_n(\omega)=0\}=0 \tag{111}$$

因此几乎处处收敛不成立。

收敛模式这里有一些常用的定理：

Theorem 36 连续映射定理

设 X 为随机变量，$\{X_n\}$ 为一随机变量序列，$g(.)$ 连续，则

1. $X_n\xrightarrow{a.s.}X\Rightarrow g(X_n)\xrightarrow{a.s.}g(X)$;
2. $X_n\xrightarrow{p}X\Rightarrow g(X_n)\xrightarrow{p}g(X)$;
3. $X_n\xrightarrow{d}X\Rightarrow g(X_n)\xrightarrow{d}g(X)$;

注意对 L_p 收敛这是不成立的。

Theorem 37 *Slutsky* 定理

设 $X_n\xrightarrow{d}X$，$Y_n\xrightarrow{d}c$，c 为常数，则

1. $X_n+Y_n\xrightarrow{d}X+c$;
2. $X_nY_n\xrightarrow{d}Xc$;

3. $X_n/Y_n \xrightarrow{d} X/c, \quad c \neq 0$。

用 Slutsky 定理可以证明 t 分布收敛到正态分布。

Theorem 38 连续性定理

设 X_n 的特征函数是 $\phi_n(t)$，X 的特征函数是 $\phi(t)$，则 $X_n \xrightarrow{d} X$ 的**充分必要条件**是

$$\lim_{n\to\infty} \phi_n(t) = \phi(t), \quad \forall t \in \mathbb{R} \tag{112}$$

这个定理被用在了 CLT 的证明上。

8 中心极限定理

写了两周的讲义终于要完结啦 ~ 下面是概率论和统计结合最紧密的知识点之一，常用于大样本推断的中心极限定理。

Theorem 39 中心极限定理

设 $\{X_n\}$ 是独立同分布的随机变量序列，其期望和方差均存在，期望为 μ，方差为 σ^2，记 $S_n = X_1 + ... + X_n$，则

$$\frac{S_n - E(S_n)}{\sqrt{var(S_n)}} \xrightarrow{d} N(0,1) \tag{113}$$

也就是

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} N(0,1) \tag{114}$$

记忆公式推荐按照式 (109) 进行记忆，这就是 Definition19 里提到的标准化形式。关于 n 究竟应该放在那里，可以从 S_n 进行推导。这增加不了多少运算，但是能提高记忆效率和准度，避免出错。

对 Theorem36 里描述的这个分布，在 n 充分大时 S_n 可以有近似分布：$\mathcal{N}(n\mu, n\sigma^2)$。

Theorem36 的一个变式是：如果 $M_n = (X_1 + ... + X_n)/n$，则

$$\frac{M_n - E(M_n)}{\sqrt{var(M_n)}} \xrightarrow{d} N(0,1) \tag{115}$$

M_n 的分布近似于 $\mathcal{N}(\mu, \sigma^2/n)$。这是平均值的近似分布，在统计推断中会用到。

中心极限定理的证明使用的是特征函数，具体的推导过程可以参考课件。

中心极限定理将分布近似为正态分布，这样会导致单点的概率被近似成了 0，这对离散的分布显然是不成立的。针对离散分布，可以有如下的一个修正定理：

Theorem 40 二项分布下中心极限定理的修正

设 $S_n \sim B(n,p)$，n 充分大，k, m 是非负整数，则

$$\mathbb{P}(k \leq S_n \leq m) \approx \Phi(\frac{m - np}{\sqrt{np(1-p)}}) - \Phi(\frac{k - np}{\sqrt{np(1-p)}}) \tag{116}$$

其修正形式为：

$$\mathbb{P}(k \leq S_n \leq m) \approx \Phi(\frac{m+1/2-np}{\sqrt{np(1-p)}}) - \Phi(\frac{k-1/2-np}{\sqrt{np(1-p)}}) \tag{117}$$

更重要的是，该修正形式可以用来计算单点的概率 $\mathbb{P}(S_n = k)$。对于其它离散随机变量，这样的修正同样适用。

写在最后，辨析一下二项分布的泊松近似和正态近似。对二项分布 $B(n,p)$，如果 n 很大、p 很小，二者乘积固定为 λ，则二项分布可以近似为泊松分布 $\mathcal{P}(\lambda)$。如果 n 很大、p 并不太小（接近 0.5），则二项分布可以近似为正态分布 $\mathcal{N}(np, np(1-p))$。

最后祝大家考试顺利 ~