清華大學
Tsinghua University

概率论与数理统计
期末小班辅导

2099

厚德載物
自强不息
Tsinghua

THU

清華大學

1. 事件概率

事件概率

事件概率

Definition 1 概率测度

设 $(\Omega, \mathcal{F})$ 为可测空间，$\mathbb{P}$ 是定义在 $\mathcal{F}$ 上的函数。若 $\mathbb{P}$ 满足下面三个条件：

1. 非负性：$\forall A \in \mathcal{F}, \mathbb{P}(A) \geq 0$
2. 归一性（完全性）：$\mathbb{P}(\Omega) = 1$
3. 可列可加性：对 $\mathcal{F}$ 中互不相交的事件 $A_1, A_2, \ldots$，有

$$\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) \tag{1}$$

则称 $\mathbb{P}$ 为 $\mathcal{F}$ 的概率测度，简称概率，称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。

Definition 2 条件概率：$\mathbb{P}(A) > 0$ 时有：

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(AB)}{\mathbb{P}(A)} \tag{2}$$

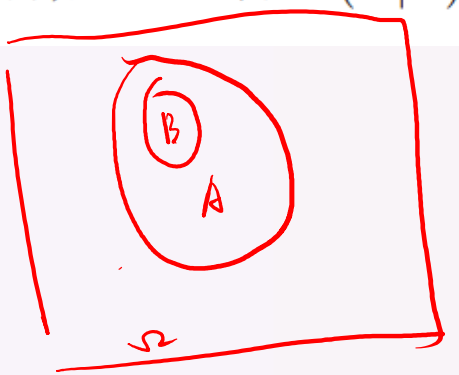
事件概率

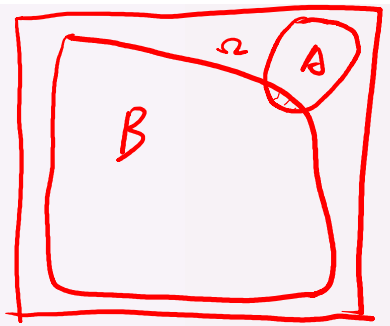
Q3：$\mathbb{P}(B|A)$ 一定大于 $\mathbb{P}(B)$ 吗？

体感上会觉得加上条件，样本空间小了，占比大了，条件概率大于无条件概率。

实际上当 $B \subset A$ 时，确实有 $\mathbb{P}(B|A) = \frac{\mathbb{P}(AB)}{\mathbb{P}(A)} = \frac{\mathbb{P}(B)}{\mathbb{P}(A)} \geq \mathbb{P}(B)$

但是不尽然，如果 $AB = \emptyset$，$\mathbb{P}(B|A) = 0 \leq \mathbb{P}(B)$。所以这二者没有绝对的大小关系。





事件概率

Theorem 1 乘法公式：$\mathbb{P}(A) \geq 0$ 时有：

$$\mathbb{P}(AB) = \mathbb{P}(A)\mathbb{P}(A|B) \tag{5}$$

Theorem 2 全概率公式：$\{A_i\}, i = 1, 2, ..., n$ 是 Ω 的一个分割，$\mathbb{P}(A_i) \geq 0$，则有：

$$\mathbb{P}(B) = \mathbb{P}(A_1)\mathbb{P}(B|A_1) + ... + \mathbb{P}(A_n)\mathbb{P}(B|A_n) \tag{6}$$

Theorem 3 贝叶斯公式：

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(AB)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)} \tag{7}$$

$= P(B|A)P(A) + P(B|\bar{A})P(\bar{A})$

贝叶斯公式，很多地方写的往往比较复杂，其实可能就是对分母又进行了全概率公式的展开。至于究竟要不要展开分母，视情况而定。

事件概率

Definition 3 一组事件的独立性：

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间，$A_1, ..., A_n \in \mathcal{F}$，若对任意非空子集 $S \subset 1, 2, ..., n$ 都有：

$$\mathbb{P}(\bigcap_{i \in S} A_i) = \prod_{i \in S} \mathbb{P}(A_i) \tag{8}$$

解读：任取事件集合中任意个数的事件，这些事件都满足交集的概率等于概率的乘积，则该事件集合中所有事件相互独立。

$P(ABC) = P(A)P(B)P(C)$

$\begin{cases} P(AB) = P(A)P(B) \\ \vdots \end{cases}$

事件概率——习题

判断下列结论是否正确，并简要说明理由：

（1） $P(A) \geq P(A \mid B)$.

$A=B=\emptyset$ $AB=\emptyset$

$0=P(AB)=P(A)P(B)>0$

（2）不存在既互斥也相互独立的事件 A, B.

（3）若 $P(ABC)=P(A)P(B)P(C)$，则 A, B, C 独立.

事件概率——习题

假设某医生考虑如下诊断方案：若有 80%的可能确定病人患此病就会建议病人手术；否则推荐做进一步的检查，该检查昂贵且痛苦. 现在该医生仅仅有 60%的把握认为小明患此病，因此推荐做了进一步的检查，该检查对于确有此病的患者给出阳性结果，而对健康人却不会给出阳性结果. 小明的检查结果呈阳性，正当要建议手术时，小明告诉医生他患有糖尿病. 这个消息带来了麻烦，尽管它并不影响医生一开始对小明患病的 60%的把握，但却影响了这个进一步检查项目的效果，该检查对于患有糖尿病却不患有这种疾病的人来说会有 30%的可能给出阳性结果. 问：此时医生是否应该仍旧建议手术？

A：阳性，B：患病

计算P(B|A)=P(A|B)P(B)/P(A)，用全概率公式表示P(A)。

不需要设糖尿病这个事件，这已经包含在A里了（糖尿病和B无关）。

$P(B|A) = \frac{P(A|B)P(B)}{P(A)} = 0.6$

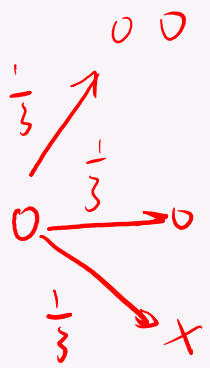
$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$

$0.6 \quad 0.3 \quad 0.4$

事件概率——习题

*有一个生物，1 分钟后有三种可能结果：死掉、保持原状或者分裂成两个，出现的概率都相同，而此后活着的该种生物都将以这种方式相互独立地进行下去，那么这种生物最终灭亡的概率是多少？

P.



$P=\frac{1}{3}\times 1+\frac{1}{3}\times P+\frac{1}{3}\times P^2$.

$P=1$

清華大學

2. 随机变量

随机变量、随机变量函数的分布、随机向量

随机变量

Definition 4 随机变量

设 $(\Omega, \mathcal{F})$ 为可测空间，如果 Ω 上的函数 $X(\omega)$ 满足：$\forall x \in R, \{\omega | X(\omega) \leq x\} \in \mathcal{F}$，则称 $X(\omega)$ 为 $(\Omega, \mathcal{F})$ 上的随机变量，简称随机变量。

Definition 6 连续随机变量

设随机变量 X，如果存在非负函数 $f_X(x)$ 使得 $\forall a < b$,

$$\mathbb{P}(a < X \leq b) = \int_a^b f_X(x)dx \tag{20}$$

则称 X 是连续随机变量，$f_X(x)$ 是 X 的概率密度函数 *(PDF)*

$X: \Omega \mapsto \mathbb{R}$

$P(X)$ ×

$P(X<0)$ √

$P(X=0)$

$P(X \in A)$

随机变量

2.2.1 两点分布

$X \sim B(1,p)$，则分布列为 $\mathbb{P}(X=0)=1-p, \mathbb{P}(X=1)=p$，更一般地写成 $\mathbb{P}(X=x)=(1-p)^{1-x}p^x, \quad x=0,1$

$E(X)=p, Var(X)=p(1-p)$

2.2.2 二项分布

$X \sim B(n,p)$，分布列为

$$\mathbb{P}(X=k)=\binom{n}{k}p^k(1-p)^{n-k}, k=0,1,...,n \tag{10}$$

$E(X)=np, Var(X)=np(1-p)$

二项分布具有可加性，若 $X \sim B(m,p), Y \sim B(n,p)$ 且 X 与 Y 相互独立（独立性非常重要！），则 $Z=X+Y \sim B(m+n,p)$。由此，二项分布 $B(n,p)$ 也可以看成是 n 个相互独立的两点分布 $B(1,p)$ 加和而来。

随机变量

2.2.3 几何分布

$X \sim G(p)$，分布列为

$$\mathbb{P}(X = k) = (1-p)^{k-1}p \tag{11}$$

$E(X) = \frac{1}{p}, Var(X) = \frac{1-p}{p^2}$

几何分布具有无记忆性，这是个**充要条件**：

Theorem 4 取正整数值的随机变量 $X \sim G(p)$ 的充分必要条件是 X 具备无记忆性，即 $\forall k \geq 1$：

$$\mathbb{P}(X = k+1 | X > k) = \mathbb{P}(X = 1) \tag{12}$$

随机变量

2.2.6 超几何分布

$X \sim H(n, M, N)$，则

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}} \tag{15}$$

$E(X) = n\frac{M}{N}, Var(X) = n\frac{M(N-M)(N-n)}{N^2(N-1)}$

随机变量

2.2.8 泊松分布

$X \sim \mathcal{P}(\lambda)$，若

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, ... \tag{17}$$

$E(X) = \lambda, Var(X) = \lambda$

随机变量

2.3.2 均匀分布

区间 $[a,b]$ 上的均匀分布的密度函数为：

$$f(x)=\frac{1}{b-a}I(x\in[a,b]) \tag{21}$$

$E(X)=\frac{a+b}{2}, Var(X)=\frac{(a-b)^2}{12}$

这里面写到了示性函数 $I(x\in[a,b])$，这个函数在括号内条件得到满足时取值为 1，不满足时取值为 0（即：当 $x\in[a,b]$ 时该函数值为 1，$x\notin[a,b]$ 时该函数值为 0）。在表达概率密度函数时使用示性函数（而不是写成大括号 + 分段函数的形式）是一个好的习惯，我们会在讨论独立性的时候讨论为什么。

随机变量

2.3.3 指数分布

$X \sim \mathcal{E}(\lambda)$，若

$$f_X(x) = \lambda e^{-\lambda x} I(x > 0), \lambda > 0 \tag{22}$$

$E(X) = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$

指数分布有些像是连续情况的几何分布，它也有无记忆性，而且同样是充分必要条件：

Theorem 5 设 X 是连续非负随机变量，则 X 服从指数分布的充要条件是 X 具有无记忆性，即：

$$\forall s, t \geq 0, \mathbb{P}(X > s + t | X > s) = \mathbb{P}(X > t) \tag{23}$$

随机变量

2.3.4 正态分布

$X \sim \mathcal{N}(\mu, \sigma)$，若

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} exp(-\frac{(x-\mu)^2}{2\sigma^2}) \tag{24}$$

$E(X) = \mu, Var(X) = \sigma^2$

没有写示性函数，就意味着该式在整个实数轴上成立。

标准正态 $\mu = 0, \sigma = 1$

随机变量

2.3.6 卡方分布 (Chi-squared distribution)

n 个相互独立的标准正态分布加和为自由度是 n 的卡方分布。即令

$$X = Z_1^2 + ... + Z_n^2 \tag{27}$$

则 $X \sim \chi_n^2$。
密度函数：卡方分布是特殊的 Gamma 分布，$\chi_n^2 = \Gamma(\frac{n}{2}, \frac{1}{2})$。

2.3.7 Student's t 分布

设 $Z \sim \mathcal{N}(0,1)$，$X \sim \chi_n^2$，且 X 与 Z 独立。令 $T = \frac{Z}{\sqrt{X/n}}$，则 $T \sim t_n$
$n = 1$ 时为 Cauchy 分布，该分布性质特殊，期望不存在。

2.3.8 F 分布 (Fisher Snedecor distribution)

设有独立同分布的随机变量 $X_i \sim \mathcal{N}(0,1), i = 1, 2, ..., m$ 和 $Y_j \sim \mathcal{N}(0,1), j = 1, 2, ..., n$，令

$$F = \frac{(\sum_{i=1}^{m} X_i^2)/m}{(\sum_{j=1}^{n} Y_j^2)/n} \tag{28}$$

则 $F \sim F(m, n)$

随机变量

Definition 7 分布函数 *(distribution function)*

对随机变量 X，称 x 的函数

$$F_X(x) = \mathbb{P}(X \leq x), x \in R \tag{29}$$

为 X 的**概率分布函数**或累积分布函数，简称为**分布函数** *(CDF)*。

对于连续随机变量自然有：

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^{x} f_X(t)dt \tag{30}$$

Q4：如何用分布函数表示 $\mathbb{P}(a \leq X \leq b)$?

立刻写出：$F_X(b) - F_X(a)$，那么恭喜，这就是零分的标准答案。

上面这个式子对应的是 $\mathbb{P}(a < X \leq b)$，$X = a$ 这一点的概率就这样被吃掉了？连续的时候是对的，但是一般情况下自然不对。正确的写法应当使用左极限：

$$\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a^-) \tag{31}$$

随机变量函数的分布

$X \Rightarrow g(X) \sim ?$

2.5 随机变量函数的分布

核心研究的问题：$Y = g(X)$（注意是大写 X，表示随机变量），已知 X 的分布，考虑 Y 的分布。

核心要点：随机变量作为映射的本质。如果能写成 $Y = g(X)$，那它们一定对应着相同的样本空间 Ω，在相同的样本空间上，相同的事件对应相同的概率。

离散型随机变量的函数分布比较简单，几乎只需要单纯换元即可。下面主要讨论连续型的情况。

随机变量函数的分布

2.5.1 通用方法：使用分布函数转化

如果 $g(.)$ 单调递增且反函数 $g^{-1}(.)$ 存在，则

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y)) \tag{35}$$

一般的情况需要具体问题具体分析，但是核心的要点在于把函数转化为概率表达式，之后利用处理事件的方法来处理概率即可。

非单调函数要注意事件“一对多”的可能。以卡方分布 Y 为例，$X \sim \mathcal{N}(0,1)$，$Y = X^2$，若要用 CDF 转化计算，则：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) \tag{36}$$

这样的情况在分布函数转化容易看出，但是在后面讲的密度函数转化中会一次又一次坑惨不少人。

随机变量函数的分布

Theorem 7 连续随机变量密度函数互化

设 X 的概率密度 $f_X(x)$，$D \subset R, Y = g(X), \mathbb{P}(Y \in D) = 1$，如果

1. 对 $y \in D$，$\{Y = y\} = \bigcup_{i=1}^{n} \{X = h_i(y)\}$；
2. 每个 $h_i(y)$ 是 D 到其值域 D_i 的可逆映射，在 D 内有连续的导数；
3. $D_1, D_2, ..., D_n$ 互不相交；

则 Y 的密度函数为：

$$f_Y(y) = \sum_{i=1}^{n} f_X(h_i(y))|h_i'(y)|I(y \in D) \tag{37}$$

随机变量函数的分布

这里复杂的求和号都是针对多值对应来的。实际上这个公式是为了严谨而写，如果只为了记忆，可以直接忽略这些条件，写成：

$$f_Y(y) = \sum f_X(x)|\frac{dx}{dy}| \tag{38}$$

如果 $g(.)$ 严格单调，则更加方便：

$$f_Y(y) = f_X(x)|\frac{dx}{dy}| \tag{39}$$

$f_Y(y)dy = f_X(x)dx$

随机向量

Definition 8 n 维随机向量

如果 $X_1, ..., X_n$ 都是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量，称 $\boldsymbol{X} = (X_1, ..., X_n)$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 n 维随机向量，简称随机向量。

Definition 9 联合分布函数

设 $\boldsymbol{X} = (X_1, ..., X_n)$ 是随机向量，称 $\mathbb{R}^n$ 上的 n 元函数

$$F(x_1, x_2, ..., x_n) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, ..., X_n \leq x_n) \tag{44}$$

为 $\boldsymbol{X}$ 的联合概率分布函数，简称分布函数或者联合分布。

2.6.2 连续随机向量

连续随机向量也可以定义联合密度函数 $f(x_1, ..., x_n)$,边缘密度可以通过联合密度积分得到。若 X, Y, Z, W 的联合密度为 $f_{XYZW}(x, y, z, w)$，则 X, Y 的边缘密度 $f_{XY}(x, y) = \iint_{\mathbb{R}^2} f_{XYZW}(x, y, z, w) dz dw$

多元正态分布是一个典型的例子，这里不详细展开了。

随机向量

Definition 12 条件分布

设 $X_1, ..., X_n$ 是随机向量，$S_k = \{i_1, i_2, ..., i_k\}$ 为指标集，称 $\boldsymbol{X}_{S_k} = (X_{i_1}, X_{i_2}, ..., X_{i_k})$ 的联合分布为 $F(x_1, x_2, ..., x_n)$ 的 k 维条件分布，当且仅当

$$\mathbb{P}(X_{i_1} = x_{i_1}, ..., X_{i_k} = x_{i_k} | X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n}) = \frac{\mathbb{P}(X_{i_1} = x_{i_1}, ..., X_{i_k} = x_{i_k}, X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n})}{\mathbb{P}(X_{i_{k+1}} = x_{i_{k+1}}, ..., X_{i_n} = x_{i_n})} \tag{47}$$

其中 $1 \leq k < n$，$S_k = \{i_1, i_2, ..., i_k\}$ 为指标集。

离散随机变量：

$$\mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)} \tag{48}$$

连续随机变量：

$$f_{X|Y}(x, y) = \frac{f_{XY}(x, y)}{f_Y(y)} \tag{49}$$

随机向量

Theorem 8

对离散随机变量 X, Y，二者独立的充要条件为

$$\mathbb{P}(X = x_i | Y = y_j) = P(X = x_i), \quad \forall i, j \geq 1 \tag{50}$$

这等价于

$$\mathbb{P}(X = x_i, Y = y_i) = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_i) \tag{51}$$

离散型随机向量判断独立性一般比较简单，我们重点关注连续型随机向量的情况：

Theorem 9

对连续随机变量 X, Y，二者独立的充要条件为，$\forall y \in \{y | f_Y(y) > 0\}$

$$f_{X|Y}(x, y) = f_X(x), \quad \forall x \subset \mathbb{R} \tag{52}$$

这等价于

$$f_{XY}(x, y) = f_X(x) f_Y(y), \quad \forall x, y \in \mathbb{R} \tag{53}$$

当然，判断独立性并不一定非要计算边缘分布，我们有如下的定理：

随机向量

Theorem 10

对于任意的随机变量 X, Y，若存在函数 $g(x), h(y)$，使得

$$f_{XY}(x, y) = g(x)h(y), \quad \forall x, y \in \mathbb{R} \tag{54}$$

则 X, Y 独立。

这个定理的意思是，如果我们能找到一个函数，使得 X, Y 的联合分布可以写成两个函数的乘积，那么 X, Y 就是独立的。这里注意 x, y 的取值范围是整个实数轴，使用示性函数表达密度函数的好处再一次体现了出来。使用示性函数就能够把取值范围作为函数囊括进 $g(x), h(y)$ 中，如果不能囊括进去，那就不独立。比如单位圆上的均匀分布 $f_{XY}(x, y) = \frac{1}{\pi} I(x^2 + y^2 \leq 1)$，虽然前面能拆开，但是示性函数 $I(x^2 + y^2 \leq 1)$ 是无论如何不能拆成两个分别关于 x 和 y 的函数的乘积的，所以这个分布里面的 X 和 Y 就不是独立的。

$f_{XY}(x,y) = \frac{1}{\pi} I(x^2+y^2 \leq 1)$ $I(x \leq y)$ $I(x \leq a, y \leq b)$ □

随机向量

1. $Z = X + Y$：卷积公式

对于离散情况

$$P_Z(z) = \mathbb{P}(X + Y = z) = \sum_x \mathbb{P}(X = x, Y = z - x) \tag{55}$$

如果 X, Y 独立，则

$$P_Z(z) = \sum_x \mathbb{P}(X = x)\mathbb{P}(Y = z - x) = \sum_x P_X(x)P_Y(z - x) \tag{56}$$

此时 Z 的分布列为 X 和 Y 的分布列的卷积。

对于连续情况：设 (X, Y) 的联合分布为 $f_{XY}(x, y)$，则 $Z = X + Y$ 的密度函数为

$$f_Z(z) = \int_{-\infty}^{\infty} f_{XY}(x, z - x)dx \tag{57}$$

如果 X, Y 独立，则

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x)dx \tag{58}$$

这里能体现出将随机变量写在下标的好处，即使括号里面的内容再变，我们也总是知道这是谁的密度函数。

随机向量

严格的定理很复杂，在这里不在完整列出。在二维且一一对应的情况下，读者只需要知道它有如下的形式：

$$f_{UV}(u,v) = f_{XY}(x,y)|det(\frac{\partial(x,y)}{\partial(u,v)})| \tag{59}$$

其中，(X,Y) 是随机变量，$U = u(X,Y), V = v(X,Y)$ 是 (X,Y) 的一一对应映射 $X,Y \xrightarrow{u,v} U,V$。关

这样的理解可以处理一对多的情况，像 (42) 那样：如果 $(U,V) = (u,v)$ 对应着多组 $(X,Y) \in \{(x_1,y_1),...,(x_n,y_n)\}$，那么 (61) 式就化为

$$f_{UV}(u,v)d(u,v) = \sum_{i=1}^{n} f_{XY}(x_i,y_i)d(x_i,y_i) \tag{62}$$

相应地 (59) 式也变为

$$f_{UV}(u,v) = \sum_{i=1}^{n} f_{XY}(x_i,y_i)|det(\frac{\partial(x_i,y_i)}{\partial(u,v)})| \tag{63}$$

随机向量

Proof 1 最大值分布

设 $X_1, X_2, ..., X_n$ 是独立同分布的随机变量，其共同的密度函数记作 $F_X(x)$，记 $Y = \max\{X_1, X_2, ..., X_n\}$，则有：

$$F_Y(y) = \mathbb{P}(\max\{X_1, X_2, ..., X_n\} \leq y) = \mathbb{P}(X_1 \leq y, ..., X_n \leq y) = \prod_{i=1}^{n} \mathbb{P}(X_i \leq y) = \prod_{i=1}^{n} F_X(y) = F_X^n(y) \tag{67}$$

独立性保证了第二个等号可以拆开，同分布保证了最后一个等号的 n 次方。

- 请自行推导最小值的分布函数。

$F_{\min} = P(\min\{X_i\} \leq y) = 1 - P(\min(X_i) > y) = 1 - \prod_{i=1}^{n} P(X_i > y)$

$= 1 - \prod_{i=1}^{n} (1 - P(X_i \leq y))$

$= 1 - (1 - F_X(y))^n$

随机变量——习题

甲乙两人约定在某个地点见面，如果两人到达的时间是独立的，且在下午 1 点至 2 点之间均匀分布.

（1） 请给出甲乙到达时间联合分布的概率密度函数.

（2） 求先到的人需要等待 10 分钟以上的概率.

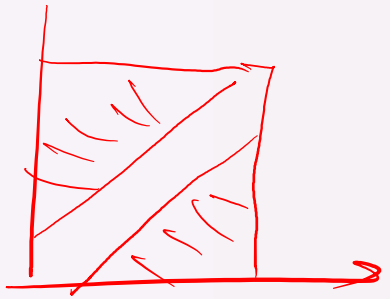
(1) X: 甲到达时间

Y: 乙

$f_{XY} = f_X f_Y$

(2) $|X-Y| \geq \frac{1}{6}$

$Z = |X-Y|$



随机变量——习题

直角坐标系中一个三角形区域的顶点坐标为 $(0,0)$， $(0,1)$ 和 $(1,0)$，在该区域

中随机取一点，其坐标记为 (X,Y).



$f_{XY}=2\,I(x>0)\,I(y>0)\,I(x+y<1)$

（1） 确定 X 和 Y 的联合分布；

（2） 计算 Y 的边际密度；

（3） 计算 X 的在给定 Y 值条件下的概率密度函数.

随机变量——习题

*一只昆虫产卵概率服从参数为 λ 的 Poisson 分布，而虫卵能发育成虫的概率为 p（$0<p<1$），又设每个虫卵是否发育成虫是彼此独立的. 证明：有 k 个后代的概率是服从参数为 λp 的 Poisson 分布.

X：卵数　$X \sim P(\lambda)$

Y：虫数　$Y|X=x \sim B(x,p)$

$Y \sim ?$

$$P(Y=k)=\sum_{x=k}^{\infty} P(Y=k|X=x)P(X=x)=\sum_{x=k}^{\infty}\binom{x}{k}p^k(1-p)^{x-k}\frac{\lambda^x}{x!}e^{-\lambda}$$

$$e^x=\sum_{i=0}^{\infty}\frac{x^i}{i!}$$

随机变量函数的分布

假设 $X \sim N(\mu,\sigma^2)$， $Y=e^X$ （对数正态分布）.

- 计算Y的密度函数

$Y=e^X$

$y=e^x \quad x=\ln y$

$$f_Y(y)=f_X(x)\left|\frac{dx}{dy}\right|$$

$$\left|\frac{dx}{dy}\right|=\left|\frac{1}{\frac{dy}{dx}}\right|$$

$$=f_X(x)\frac{1}{y}I(y>0)$$

$$=\frac{1}{x\sigma\sqrt{2\pi}}e^{-\frac{(\ln x-\mu)^2}{2\sigma^2}}I(x>0)$$

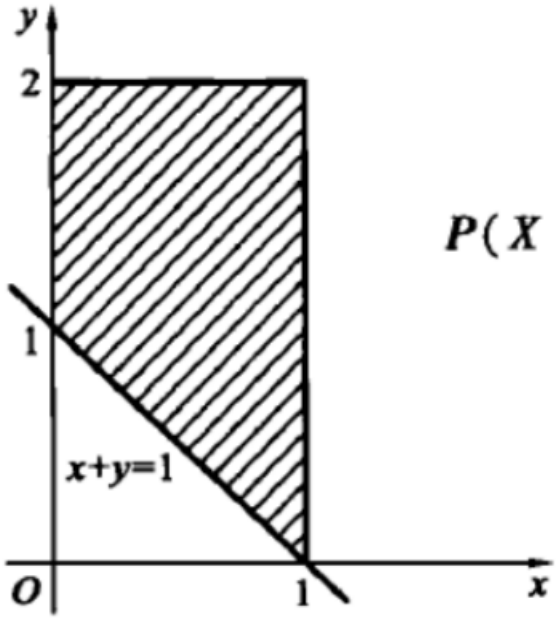
$$=f_X(\ln y)\frac{1}{y}I(y>0)$$

随机向量

12. 设二维随机变量(X,Y)的联合密度函数为

$$p(x,y)=\begin{cases}x^2+\dfrac{xy}{3}, & 0<x<1,0<y<2,\\ 0, & \text{其他.}\end{cases}$$

求$P(X+Y\geqslant 1)$. $Z=X+Y$ $P(Z\geq 1)$



$$P(X+Y\geqslant 1)=\int_0^1\int_{1-x}^2\left(x^2+\frac{xy}{3}\right)\mathrm{d}y\mathrm{d}x=\int_0^1\left(x^2y+\frac{x}{6}y^2\right)\Big|_{1-x}^{2}\mathrm{d}x$$

$$=\int_0^1\left(\frac{5}{6}x^3+\frac{4}{3}x^2+\frac{1}{2}x\right)\mathrm{d}x=\left(\frac{5}{24}x^4+\frac{4}{9}x^3+\frac{1}{4}x^2\right)\Big|_0^1=\frac{65}{72}.$$

随机向量

14. 设二维随机变量(X,Y)的联合密度函数如下，试问X与Y是否相互独立？

$24xy\,I(0<x<1)\,I(0<y<1)\,I(0<x+y<1)$

(4) $$p(x,y)=\begin{cases}24xy, & 0<x<1,0<y<1,0<x+y<1,\\ 0, & \text{其他.}\end{cases}$$

(5) $$p(x,y)=\begin{cases}12xy(1-x), & 0<x<1,0<y<1,\\ 0, & \text{其他.}\end{cases}$$

$12x(1-x)\,I(0<x<1)\quad y\,I(0<y<1)$

随机向量

6. 设 X 与 Y 的联合密度函数为

$$p(x,y)=\begin{cases}e^{-(x+y)}, & x>0,y>0,\\ 0, & \text{其他.}\end{cases}$$

试求以下随机变量的密度函数：

(1) $Z=(X+Y)/2$；　(2) $Z=Y-X$.

随机向量

16. 设随机变量 X 与 Y 独立同分布，其密度函数为

$$p(x)=\begin{cases}e^{-x}, & x>0,\\ 0, & x\leqslant 0.\end{cases}$$

(1) 求 $U=X+Y$ 与 $V=X/(X+Y)$ 的联合密度函数 $p(u,v)$；

(2) 以上的 U 与 V 独立吗？

解 (1) $\begin{cases}u=x+y,\\ v=x/(x+y)\end{cases}$ 的反函数为 $\begin{cases}x=uv,\\ y=u(1-v),\end{cases}$ 变换的雅可比行列式

$$J=\begin{vmatrix}\dfrac{\partial x}{\partial u} & \dfrac{\partial x}{\partial v}\\ \dfrac{\partial y}{\partial u} & \dfrac{\partial y}{\partial v}\end{vmatrix}=\begin{vmatrix}v & u\\ 1-v & -u\end{vmatrix}=-uv-u(1-v)=-u.$$

所以在 (U,V) 的可能取值范围 $\{u>0,0<v<1\}$ 内，有

$$p_{U,V}(u,v)=p_X(uv)p_Y(u(1-v))\,|-u|=e^{-uv}e^{-u(1-v)}u=ue^{-u}.$$

清華大學

3. 随机变量的数字特征

期望、方差、协方差、相关系数、条件期望E(X|Y)、不等式

期望

Definition 15 离散随机变量的期望

设 X 有概率分布

$$\mathbb{P}(X = x_i), i = 1, 2, ... \tag{70}$$

如果 $\sum_{i=1}^{\infty} |x_j| \mathbb{P}(X = x_j) < +\infty$，则称

$$E(X) = \sum_{i=1}^{\infty} x_j \mathbb{P}(X = x_j) \tag{71}$$

为 X 的数学期望。

Definition 16 连续随机变量的期望

如果连续随机变量 X 的密度函数是 $f_X(x)$，如果

$$\int_{-\infty}^{+\infty} |x| f_X(x) dx < +\infty \tag{72}$$

则

$$\int_{-\infty}^{+\infty} x f_X(x) dx < +\infty \tag{73}$$

为 X 的数学期望。

定义里面对绝对收敛的要求是为了保证换序求和的正确性。

这里我们能够再次看到在密度函数的表达里引入示性函数的好处：我们可以放心地对整个实数轴积分，示性函数会提醒我们实际的积分范围。

Theorem 15 期望的性质

设 $E|X| < +\infty, E|Y| < +\infty$，$a, b, C$ 为实数，则

1. $E(C) = C$;
2. $|E(X)| \leq E|X|$;
3. $E(aX + bY) = aE(X) + bE(Y)$（期望的线性性质）;
4. X 和 Y 独立，则 $E(XY) = E(X)E(Y)$。

期望

$Y=g(X)$ $E(Y)=E(g(X))=\int g(x) f_X(x) dx$

Theorem 16 复合函数的期望（懒人公式）

设 $\boldsymbol{X}=(X_1, X_2, ..., X_n)$ 是随机向量，$\boldsymbol{x}=(x_1, x_2, ..., x_n) \in \mathbb{R}^n$。如果 $\boldsymbol{X}$ 有联合分布函数 $F(\boldsymbol{x})$，实函数 $g(\boldsymbol{x})$ 使得

$$\int_{\mathbb{R}^n} |g(\boldsymbol{X})| dF(\boldsymbol{x}) < \infty \tag{74}$$

则 $Y=g(\boldsymbol{X})$ 有数学期望

$$E(Y)=E(g(\boldsymbol{X}))=\int_{\mathbb{R}^n} g(\boldsymbol{x}) dF(\boldsymbol{x}) \tag{75}$$

如果是连续随机变量，联合密度函数为 $f(\boldsymbol{x})$ 上式可以写成

$$E(Y)=E(g(\boldsymbol{X}))=\int_{\mathbb{R}^n} g(\boldsymbol{x}) f(\boldsymbol{x}) d\boldsymbol{x} \tag{76}$$

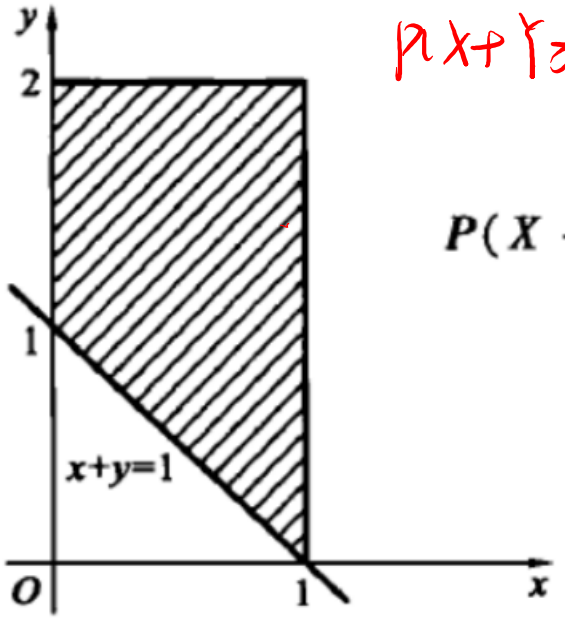
注意如果有多个随机变量，这就是个重积分，有多少个变量就是几重积分。比如 $E(X^2)=\int_{\mathbb{R}} x^2 f_X(x) dx$，而 $E(XY^2)=\int_{\mathbb{R}^2} xy^2 f_{XY}(x, y) dxdy$

随机向量

12. 设二维随机变量(X,Y)的联合密度函数为

$$p(x,y)=\begin{cases}x^2+\dfrac{xy}{3}, & 0<x<1,0<y<2,\\ 0, & \text{其他.}\end{cases}$$

求$P(X+Y\geqslant 1)$.



$P(X+Y\geq 1)=E(I_{(X+Y\geq 1)})\sim B(1,P(X+Y\geq 1))$

$=\iint_{\mathbb{R}^2} I_{(x+y\geq 1)} f_{XY}(x,y)\,dxdy$

$$P(X+Y\geqslant 1)=\int_0^1\int_{1-x}^2\left(x^2+\frac{xy}{3}\right)dydx=\int_0^1\left(x^2y+\frac{x}{6}y^2\right)\Big|_{1-x}^{2}dx$$

$$=\int_0^1\left(\frac{5}{6}x^3+\frac{4}{3}x^2+\frac{1}{2}x\right)dx=\left(\frac{5}{24}x^4+\frac{4}{9}x^3+\frac{1}{4}x^2\right)\Big|_0^1=\frac{65}{72}.$$

Q5：已知 (X,Y) 的联合密度函数 $f_{XY}(x,y)$，计算 $g(X,Y)\geq 0$ 的概率。

常规的方法是算出 $Z=g(X,Y)$ 的分布，然后计算概率，但是懒人公式让我们可以通过几何图形的方法去“偷懒”：我们可以画出 $g(x,y)\geq 0$ 的区域和密度函数 $f_{XY}(x,y)$ 的非零区域的交集 D，再在 D 上对密度函数积分，即

$$\mathbb{P}(g(X,Y)\geq 0)=\iint_D f_{XY}(x,y)dxdy \tag{77}$$

其中 $D=\{(x,y)|g(x,y)\geq 0, f_{XY}(x,y)>0\}$。这件事情的证明首先要用到如下的技巧：

$$\mathbb{P}(g(X,Y)\geq 0)=E(I(g(X,Y)\geq 0)) \tag{78}$$

即：概率等于示性函数的期望。在包含了随机变量的表达式后，示性函数也具有了随机性。由于示性函数的取值只能是 0 或 1，它服从两点分布（此时应称“示性变量”），期望就是它等于 1 的概率，而示性函数等于 1 等价于其括号内的条件成立，也就是说期望就是括号内条件成立的概率，这便是上面的公式 (78)。

有了 (78)，利用懒人公式，我们立刻就能得到

$$E(I(g(X,Y)\geq 0))=\iint_{g(x,y)\geq 0} f_{XY}(x,y)dxdy \tag{79}$$

这就得到了 (77)。实际上把 $g(x,y)\geq 0$ 写在角标和把 D 写在角标是一样的，把 D 写在角标只是为了计算的时候清晰一些。

方差

Definition 17 随机变量的方差

如果随机变量 X 的期望 $E(X)$ 有限，则称 $E(X-E(X))^2$ 为 X 的方差，记作 $var(X)$ 或 σ_X^2。当 $var(X)<\infty$ 时，称 X 方差有限。

常用计算公式：1. 定义式 $var(X)=E(X-E(X))^2$；2. 等价表达 $var(X)=E(X^2)-E^2(X)$。

Theorem 17 方差的性质

设 $var(X)<\infty$，则

1. $var(aX+b)=a^2var(X), a,b\in\mathbb{R}$；
2. $var(X)=E(X-E(X))^2\leq E(X-c)^2, \forall c\in\mathbb{R}$（这条性质的意义是：期望是均方意义下的最佳估计）；
3. $X_1,...,X_n$ 相互独立，则 $var(\sum_{k=1}^n X_k)=\sum_{k=1}^n var(X_k)$（不独立则要计算协方差）。

$\arg\min_c E(X-c)^2 = EX$

关于标准化：

Definition 18 标准差

若随机变量 X 的方差 $var(X)<\infty$，则 $\sigma_X=\sqrt{var(X)}$ 为 X 的标准差

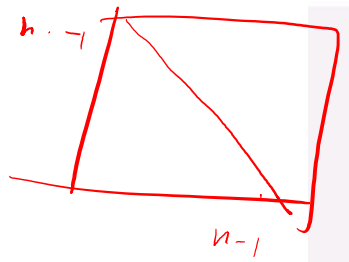
协方差

Definition 24 协方差

设 $E(X), E(Y)$ 存在，当 $E|(X-E(X))(Y-E(Y))| < \infty$ 时，称

$$E[(X-E(X))(Y-E(Y))]$$

为随机变量 X, Y 的协方差，记作 $cov(X,Y)$。



协方差的一些性质可以用来简化运算。

$$var\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} var(X_i) + 2\sum_{1 \le i < j \le n} cov(X_i, X_j)$$

$\frac{n(n-1)}{2}$

Theorem 27 协方差的一些性质可以用来简化运算

1. $cov(X,X) = var(X)$;
2. $cov(X,Y) = E(XY) - E(X)E(Y)$;
3. 双线性：$cov(cX,Y) = c \cdot cov(X,Y)$，$cov(X, Y+Z) = cov(X,Y) + cov(X,Z)$
4. $var(X_1 + X_2) = var(X1) + var(X_2) + 2cov(X_1, X_2)$

协方差的双线性性质非常常用，需要有足够的敏感性，能够联想到。最典型的例子，$Z = X + Y$，算 $Cov(X,Z)$。不要吭哧吭哧就开始算 $E(XZ)$ 这种东西了，直接把 $Z = X + Y$ 带进去然后用双线性性质造它就完了。

相关系数

Definition 25 相关系数

当 $0 < var(X) \cdot var(Y) < \infty$ 时，称

$$\frac{cov(X,Y)}{\sqrt{var(X)var(Y)}} \tag{87}$$

为随机变量 X, Y 的相关系数 *(Pearson's correlation)*，记作 $corr(X,Y)$。

留意相关与独立的联系。相关系数是描述线性相关程度的，不相关不一定独立（比如 $X \sim \mathcal{U}[-1,1], Y = X^2$，两个随机变量具有函数关系，但是相关系数是 0），但是独立一定意味着不相关。

条件期望（事件上的定义，上课没讲请忽略）

Definition 20 事件上的条件期望

离散型：若 $\sum_{i=1}^{\infty}|x_i|\mathbb{P}(X=x_i|A)<\infty$，则定义 $E(X|A)=\sum_{i=1}^{\infty}x_i\mathbb{P}(X=x_i|A)$

连续型：若 $\int_{\mathcal{R}}|x|f_{X|A}(x|A)dx<\infty$，则定义 $E(X|A)=\int_{\mathcal{R}}xf_{X|A}(x)dx$

定义很直白，计算也很简单：

Theorem 22 条件期望的计算

设 $\mathbb{P}(A)>0$，$E(X|A)$ 存在，则

$$E(X|A)=\frac{E(XI(A))}{\mathbb{P}(A)} \tag{82}$$

有了条件期望的定义，我们可以有全期望定理。

Theorem 23 全期望定理

设 $A_1,\dots A_n$ 构成 Ω 的一个分割，则

$$E(X)=\sum_{i=1}^{n}E(X|A_i)\mathbb{P}(A_i) \tag{83}$$

条件期望E(X|Y)

$$E(X|Y=y) = \int f_{X|Y}(x,y)\,dx = m(y)$$

Definition 21 条件在随机变量上的期望

设 (X,Y) 是随机向量，$E|X| < \infty$，如果 $m(y) = E(X|Y=y)$，就称随机变量 $m(Y)$ 为给定 Y 时 X 的条件期望，记作 $E(X|Y)$。$= m(Y)$

Definition 22 重期望公式

设 X, Y 是随机变量，则

$$E[E(X|Y)] = E(X) \tag{84}$$

条件期望E(X|Y)

Theorem 24 条件期望的性质

设 X, Y 是随机变量，$g(x), h(y)$ 是实函数，$E|X| < \infty, E|g(X)| < \infty$，又设随机变量 $X_1, X_2, ..., X_n$ 的期望有限，则

$E(X^2 Y^2 | X) = X^2 E(Y^2 | X)$

1. $E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$;
2. $E[E(g(X)|Y)] = E(g(X))$;
3. 若 X, Y 独立，则 $E(g(X)|Y) = E(g(X))$;
4. $E(c + \sum_{i=1}^{n} c_i X_i | Y) = c + \sum_{i=1}^{n} c_i E(X_i|Y)$。

一个需要单独列出的性质是：

Theorem 25 设 X, Y 是随机变量，$h(x)$ 是实函数，若 $E(X^2) < \infty, E(h^2(Y)) < \infty$，则

$$E[(X - E(X|Y))h(Y)] = 0 \tag{85}$$

不等式

Theorem 18 *Markov* 不等式

对随机变量 X 和 $\epsilon > 0$ 有

$$\mathbb{P}(|X| \geq \epsilon) \leq \frac{E|X|^{\alpha}}{\epsilon^{\alpha}}, \alpha > 0 \tag{77}$$

Theorem 19 *Chebyshev* 不等式

$$P(|X - E(X)| \geq \epsilon) \leq \frac{var(X)}{\epsilon^2} \tag{78}$$

Proof 2 *Markov* 不等式的证明

$$P(|X| \geq \epsilon) = E(I(|X| \geq \epsilon)) = E(I(|X|^{\alpha} \geq \epsilon^{\alpha})) \leq E(\frac{|X|^{\alpha}}{\epsilon^{\alpha}} I(|X|^{\alpha} \geq \epsilon^{\alpha})) \leq E(\frac{|X|^{\alpha}}{\epsilon^{\alpha}}) = \frac{E|X|^{\alpha}}{\epsilon^{\alpha}} \tag{81}$$

等号 *1* 利用了示性函数的性质：概率等于示性函数的期望，$\mathbb{P}(A) = E(I(A))$，这是一个常用的技巧，请读者自行证明。

期望、方差——习题

4. 假设 $X \sim N(\mu,\sigma^2)$，$Y=e^X$（对数正态分布）.

（1） 证明：对数正态分布的矩母函数不存在.

（2） 利用正态分布的矩母函数计算 Y 的各阶原点矩.

- 只计算Y的期望和方差即可

$$f_Y(y)=\frac{1}{y\sigma\sqrt{2\pi}}\exp\left(-\frac{(\ln y-\mu)^2}{2\sigma^2}\right)$$

$$E(Y)=E(e^X)=\int e^x\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$$

$$E(Y^2)=E(e^{2X}) \qquad E(Y^k)=E(e^{kX})$$

协方差——习题

2. 假设随机变量 X,Y 相互独立，且都服从标准正态分布.

（3） 令 $U=X+Y$，$V=X-Y$，求 (U,V) 的概率密度函数，并确定 U,V 是否独立.

$(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$ $\quad cov(X,Y)=0 \Leftrightarrow X\perp Y$

一个或许需要注意的例子是多元正态分布。设 $\boldsymbol{X}=(X_1,X_2,...,X_n)$ 服从多元正态分布，显然每一个 X_i 都服从正态分布。在 $X_1,X_2,...,X_n$ 这一组分布中，如果两个分布不相关，则两个分布独立。特别注意这里的限制条件：**一组多元正态分布**。不是随便拿来两个正态分布，就能由不相关推出独立的。一个典型的例子是 $X\sim\mathcal{N}(0,1)$，随机变量 Y 分别以二分之一的概率等于 X 或者 $-X$。这个 Y 确实是正态分布，而且和 X 不相关，但显然这两个分布是不独立的。这里核心的要点就在于，(X,Y) 并不是一个二元正态分布。

$(X,Y)\sim N(_____)$ $\quad U=\alpha_1X+\beta_1Y$ $\quad V=\alpha_2X+\beta_2Y$

$(X,U)\sim N$ $\quad (Y,V)\sim N$

$X\sim N(0,1)$ $\quad Y\sim N(0,1)$ $\quad cov(X,Y)=\frac{1}{2}cov(X,X)+\frac{1}{2}cov(X,-X)=0$ $\quad (U,V)\sim N$

$Y=ZX$

$Z=\begin{cases}-1, & p=\frac{1}{2}\\ 1, & p=\frac{1}{2}\end{cases}$ $\quad Z\perp X$

协方差——习题

24. 设随机变量 X 和 Y 独立同服从参数为 λ 的泊松分布，令

$$U = 2X + Y, \quad V = 2X - Y.$$

求 U 和 V 的相关系数 $\mathrm{Corr}(U,V)$.

解 因为

$$\mathrm{Var}(U) = \mathrm{Var}(2X + Y) = 4\mathrm{Var}(X) + \mathrm{Var}(Y) = 5\lambda,$$
$$\mathrm{Var}(V) = \mathrm{Var}(2X - Y) = 4\mathrm{Var}(X) + \mathrm{Var}(Y) = 5\lambda.$$

所以

$$\begin{aligned}\mathrm{Cov}(U,V) &= \mathrm{Cov}(2X + Y, 2X - Y)\\ &= \mathrm{Cov}(2X,2X) + \mathrm{Cov}(Y,2X) - \mathrm{Cov}(2X,Y) - \mathrm{Cov}(Y,Y)\\ &= 4\mathrm{Var}(X) - \mathrm{Var}(Y) = 3\lambda,\end{aligned}$$

由此得

$$\mathrm{Corr}(U,V) = \frac{\mathrm{Cov}(U,V)}{\sqrt{\mathrm{Var}(U)}\sqrt{\mathrm{Var}(V)}} = \frac{3\lambda}{5\lambda} = \frac{3}{5}.$$

协方差——习题*

- 1. 计算超几何分布的方差

2.2.6 超几何分布

$X \sim H(n, M, N)$，则

$$\mathbb{P}(X=k)=\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$$

$$E(X)=n\frac{M}{N}, Var(X)=n\frac{M(N-M)(N-n)}{N^2(N-1)}$$

$Y_i = \begin{cases} 1, & 第i次取到红球 \\ 0, & otherwise \end{cases}$ $i \in [1, n]$

$X = \sum_{i=1}^{n} Y_i$

$var(X) = var(\sum_{i=1}^{n} Y_i)$

$$(15) = \sum_{i=1}^{n} var(Y_i) + 2\sum_{1 \le i < j \le n} cov(Y_i, Y_j)$$

$Y_i \sim B(1, \frac{M}{N})$

$= n \cdot \frac{M}{N}(1-\frac{M}{N}) + 2 \cdot \frac{n(n-1)}{2}\left(\frac{M}{N}\frac{M-1}{N-1} - \left(\frac{M}{N}\right)^2\right)$

- 2. 计算无放回抽样中，样本均值的方差

3. （简单随机抽样）设总体的大小为 N，总体均值和方差分别为 μ, σ^2，X_i（$i=1,\cdots,n$）为简单随机样本（无放回抽取）.

（1） *证明：$E(X_i)=\mu$，$Var(X_i)=\sigma^2$.

（2） **证明：$E(\bar{X})=\mu$，$Var(\bar{X})=\frac{\sigma^2}{n}\left(\frac{N-n}{N-1}\right)$.

$cov(Y_i, Y_j)$

$= E(Y_i Y_j) - E(Y_i)E(Y_j)$

$E(Y_i Y_j) = P(Y_i Y_j = 1)$ $= \frac{M}{N} \cdot \frac{M-1}{N-1} - \left(\frac{M}{N}\right)^2$

$= P(Y_i = 1) P(Y_j = 1 \mid Y_i = 1)$

$= \frac{M}{N} \cdot \frac{M-1}{N-1}$

$H(n, M-1, N-1)$

不等式——习题

- 请默写切比雪夫不等式（？）

清華大學

随机变量序列的极限特征

大数定律、中心极限定理

大数定律

Theorem 33 弱大数律 *(WLLN)*

设 X_n 是独立同分布，方差有限的随机变量序列，则 $\forall \epsilon > 0$

$$\lim_{n\to\infty} \mathbb{P}(|\bar{X}_n - E(X_1)| \geq \epsilon) = 0 \tag{97}$$

也称为 $\bar{X}_n$ 依概率收敛到 $E(X_1)$，记作

$$\bar{X}_n \xrightarrow{p} E(X_1) \tag{98}$$

其中 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$。

大数定律告诉我们，当 n 很大时，我们有很大的把握（但并非 100%）断言 $\bar{X}_n$ 的值会接近 $E(X_1)$。大数定律的证明似乎是要求掌握的，下面给出一个简单的证明。

大数定律

Proof 4 *WLLN* 的证明

X_n 是**独立同分布，方差有限**的随机变量序列，由 *Chebyshev* 不等式

$$\begin{aligned}\mathbb{P}(|\bar{X}_n - E(X_1)| \geq \epsilon) &= \mathbb{P}(|\bar{X}_n - E(\bar{X})| \geq \epsilon) \\ &\leq \frac{var(\bar{X}_n)}{\epsilon^2} \\ &= \frac{var(X_1)}{n\epsilon^2} \to 0, \quad n \to +\infty\end{aligned}$$

弱大数定律是使用 Chebyshev 不等式对大样本性质的一个描绘，计算误差使用的也是 Chebyshev 不等式，可以用来估计样本量（参考初概 ppt 的例子）。但是这种误差的估计毕竟是十分保守的，中心极限定理会给我们更准确的估计。

大数定律

Theorem 35 强大数律 *(SLLN)*

设 X_n 是独立同分布的随机变量序列，则

1. 若 $E|X_1| < \infty$，则

$$\bar{X}_n \xrightarrow{a.s.} E(X_1) \tag{101}$$

2. 反之，若

$$\bar{X}_n \xrightarrow{a.s.} C \tag{102}$$

则 $E|X_1| < \infty$，且 $C = E(X_1)$。

其中 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$。记号 $\xrightarrow{a.s.}$ 表示**几乎处处收敛**。

强大数律的条件和结论是充分必要的。

中心极限定理

Theorem 39 中心极限定理

设 $\{X_n\}$ 是独立同分布的随机变量序列，其期望和方差均存在，期望为 μ，方差为 σ^2，记 $S_n = X_1 + ... + X_n$，则

$$\frac{S_n - E(S_n)}{\sqrt{var(S_n)}} \xrightarrow{d} N(0,1) \tag{110}$$

也就是

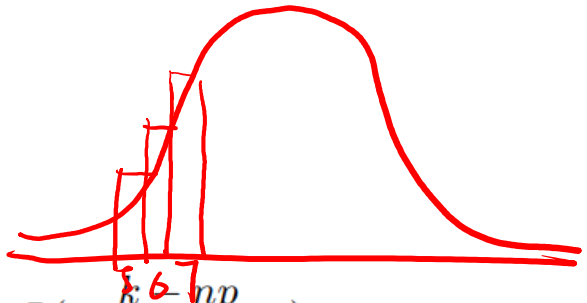
$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} N(0,1) \tag{111}$$

- 记忆：记住第一个式子（110），$var(S_n)$都会自己算。不建议记第二个。
- 理解：足够多独立同分布随机变量的加和近似为正态分布。

$B(100, 0.5) \xrightarrow{d} N(50, 25)$

中心极限定理

中心极限定理将分布近似为正态分布，这样会导致单点的概率被近似成了 0，这对离散的分布显然是不成立的。针对离散分布，可以有如下的一个修正定理：



Theorem 40 二项分布下中心极限定理的修正

设 $S_n \sim B(n,p)$，n 充分大，k,m 是非负整数，则

$$\mathbb{P}(k \le S_n \le m) \approx \Phi(\frac{m-np}{\sqrt{np(1-p)}}) - \Phi(\frac{k-np}{\sqrt{np(1-p)}}) \tag{113}$$

其修正形式为：

$$\mathbb{P}(k \le S_n \le m) \approx \Phi(\frac{m+1/2-np}{\sqrt{np(1-p)}}) - \Phi(\frac{k-1/2-np}{\sqrt{np(1-p)}}) \tag{114}$$

更重要的是，该修正形式可以用来计算单点的概率 $\mathbb{P}(S_n = k)$。对于其它离散随机变量，这样的修正同样适用。

中心极限定理——习题

14. （计算机实验）设 X_i（$i=1,\cdots,n$）为独立同分布随机变量，$\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$.

（1） 假设 $X_i \sim N(0,1)$，请分别对 $n=1,25,100,1000$ 模拟 $\overline{X}$ 的分布.

（2） 假设 $X_i \sim U(0,1)$，请分别对 $n=1,25,100,1000$ 模拟 $\overline{X}$ 的分布.

（3） 假设 X_i 的概率密度函数为 $f(x)=\frac{1}{\pi(1+x^2)}$，$x \in R$（Cauchy 分布），

请分别对 $n=1,25,100,1000$ 模拟 $\overline{X}$ 的分布. $E(X)=\infty$

观察以上的实验结果是否与中心极限定理相符，为什么？



清華大學

统计基础内容

统计基础内容

- 总体： 一个统计问题研究对象的全体。构成总体的每个成员称为 个体。简单说总体即为分布。
- 样本：从总体中随机抽样的部分个体组成的集合称为样本，样本 中的个体称为样品，样品的个数称为样本容量或样本量。简单随机抽样：(1)样本具有随机性 (2)样本之间相互独立。

统计基础内容

- 记号问题：$X_1, X_2, \ldots, X_n$是随机变量，是有随机性的，代指每一次抽样；$x_1, x_2, \ldots, x_n$ 是其抽样后的具体取值，没有随机性，就是一堆数字。
- $X_1, X_2, \ldots, X_n$的函数$T(X_1, X_2, \ldots, X_n)$称为统计量。
- 统计量的特性：不包含未知参数。已知总体可算出其分布，已知抽样结果可算出其具体数值$T(x_1, x_2, \ldots, x_n)$

统计基础内容

- 均值$\bar{X}$
- $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$
- 若总体分布为正态分布$N(\mu, \sigma^2)$，则均值也为正态分布：
- $E(\bar{X}) = \mu$
- $Var(\bar{X}) = \frac{\sigma^2}{n}$

统计基础内容

- 样本方差$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$
- 无偏性：若总体为正态分布，则$E(S^2) = \sigma^2$
- 区分μ已知的情况下的$S_\mu^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$

- 抽样定理：对正态总体$N(\mu, \sigma^2)$，有：
- 1. $\bar{X}$ 与S^2独立
- 2. $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
- 3. $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$

随机变量

2.3.6 卡方分布 (Chi-squared distribution)

n 个相互独立的标准正态分布加和为自由度是 n 的卡方分布。即令

$$X = Z_1^2 + ... + Z_n^2 \tag{27}$$

则 $X \sim \chi_n^2$。

密度函数：卡方分布是特殊的 Gamma 分布，$\chi_n^2 = \Gamma(\frac{n}{2}, \frac{1}{2})$。

2.3.7 Student's t 分布

设 $Z \sim \mathcal{N}(0,1)$，$X \sim \chi_n^2$，且 X 与 Z 独立。令 $T = \frac{Z}{\sqrt{X/n}}$，则 $T \sim t_n$

$n = 1$ 时为 Cauchy 分布，该分布性质特殊，期望不存在。

2.3.8 F 分布 (Fisher Snedecor distribution)

设有独立同分布的随机变量 $X_i \sim \mathcal{N}(0,1), i = 1, 2, ..., m$ 和 $Y_j \sim \mathcal{N}(0,1), j = 1, 2, ..., n$，令

$$F = \frac{(\sum_{i=1}^{m} X_i^2)/m}{(\sum_{j=1}^{n} Y_j^2)/n} \tag{28}$$

则 $F \sim F(m, n)$

清華大學

点估计

点估计、矩估计、极大似然估计、点估计的评价

点估计

- $X_1, X_2, \ldots, X_n$是来自某总体的样本，利用这些样本估计总体分布的参数θ。构造适当的统计量$\hat{\theta} = \theta(X_1, X_2, \ldots, X_n)$称为参数的点估计。
- 常用确定统计量的方法：矩估计和极大似然估计（其实基本只用极大似然）

矩估计

- 替换原理：$E(X) = f(\theta)$，而$E(X) \approx \bar{X}$，由此替换得到$\bar{X} = f(\hat{\theta})$，可解出$\hat{\theta}$
- 被估计的参数如果不止一个，如θ_1, θ_2，需要两个方程，考虑更高阶的矩：第一个方程仍为一阶矩$E(X) = f(\theta_1, \theta_2)$，第二个为二阶原点矩或者二阶中新矩（方差）：
- $E(X^2) = g(\theta_1, \theta_2), or\ Var(X) = h(\theta_1, \theta_2)$
- 例：用$X_1, X_2, \ldots, X_m$来估计两个参数均未知的二项分布$B(n, p)$

$$\begin{cases} \hat{np} = \bar{X} \\ \hat{n}\hat{p}(1-\hat{p}) = S^2 \end{cases}$$

极大似然估计

- 似然函数：联合密度函数，但这次我们关注θ
- $L(\theta; x_1, \dots, x_n) = \prod_{i=1}^{n} f(x_i; \theta)$
- “似然”不是概率，它不具备概率的三条性质；但是这个函数越大，估计的分布越接近真实的分布。使似然函数最大的参数值即为极大似然估计。$\hat{\theta}^{MLE} = \underset{\theta}{\operatorname{argmax}}\, L(\theta)$
- 如果是离散随机变量，上面的f是其分布列；连续型则为密度函数。
- 不好算！对数似然函数：$l(\theta) = lnL(\theta) = \sum_{i=1}^{n} lnf(x_i; \theta)$，用这个计算得到相同结果。

极大似然估计——练习

- 总体分布为X，$X_1, X_2, \ldots, X_n$是来自总体X的简单随机样本。在总体分布的形式如下时，求参数θ的极大似然估计$\hat{\theta}^{MLE}$。
- 1. $X \sim U(0, \theta)$

$$f_X(x) = \frac{1}{\theta} I(0 < x < \theta)$$

$$L(\theta) = \prod_{i=1}^{n} \frac{1}{\theta} I(0 < x_i < \theta) = \frac{1}{\theta^n} \prod_{i=1}^{n} I(0 < x_i < \theta)$$

$$= \frac{1}{\theta^n} \prod_{i=1}^{n} I(\theta \geq x_i)$$

$$= \frac{1}{\theta^n} I(\theta \geq \max\{x_i\})$$

$$\hat{\theta}^{mle} = \max\{x_i\}$$

极大似然估计——练习

- 总体分布为X，$X_1, X_2, \ldots, X_n$是来自总体X的简单随机样本。在总体分布的形式如下时，求参数λ的极大似然估计$\hat{\lambda}^{MLE}$。
- 2. $X \sim \varepsilon(\lambda)$

$$f_X(x) = \lambda e^{-\lambda x} I(x>0)$$

$$l(\lambda) = \ln L(\theta) = \sum_{i=1}^{n} (\ln \lambda + (-\lambda x_i))$$

$$\frac{dl(\lambda)}{d\lambda} = \sum_{i=1}^{n} \left(\frac{1}{\lambda} - x_i\right) = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0$$

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x}$$

极大似然估计——练习

$\hat{\sigma}^2 = T \quad \hat{\sigma} = \sqrt{T}$

- 总体分布为X，$X_1, X_2, \ldots, X_n$是来自总体X的简单随机样本。在总体分布的形式如下时，求参数(μ, σ^2)的极大似然估计$(\hat{\mu}, \hat{\sigma}^2)$。
- 3. $X \sim N(\mu, \sigma^2)$

$f(x|x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad \ln f(x|x) = -\ln\sqrt{2\pi}\sigma - \frac{(x-\mu)^2}{2\sigma^2}$

$$\begin{cases} \frac{d l(\mu,\sigma)}{d\mu} = 0 \Rightarrow -\sum_{i=1}^{n} \frac{(x_i-\mu)}{\sigma^2} = 0 \quad \hat{\mu} = \bar{x} \\ \frac{d l(\mu,\sigma)}{d\sigma} = 0 \Rightarrow \sum_{i=1}^{n}\left(-\frac{1}{\sigma} + \frac{(x-\mu)^2}{\sigma^3}\right) = 0 \end{cases}$$

$\hat{\sigma} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2}$

$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2$

$\hat{\sigma}^2 = \frac{n-1}{n} S^2 \quad E(\hat{\sigma}^2) = \frac{n-1}{n}\sigma^2$

极大似然估计——练习

X $f_X(x)=\lambda e^{-\lambda(x-\mu)}I(x\geq\mu)$

- 总体分布为X，$X_1,X_2,\ldots,X_n$是来自总体X的简单随机样本。在总体分布的形式如下时，求参数(θ_1,θ_2)的极大似然估计$(\hat{\theta}_1,\hat{\theta}_2)$。
- 4. $X\sim U(\theta_1,\theta_2)$

$$f_X(x)=\frac{1}{\theta_2-\theta_1}I(\theta_1<x_i<\theta_2)$$

$$L(\theta)=\frac{1}{(\theta_2-\theta_1)^n}\prod_{i=1}^{n}(\theta_1<x_i<\theta_2)$$

$$(\hat{\theta}_1,\hat{\theta}_2)=(\min(x_i),\max(x_i))$$

$$=\frac{1}{(\theta_2-\theta_1)^n}\prod_{i=1}^{n}I(\theta_1<x_i)\prod_{i=1}^{n}I(\theta_2>x_i)$$

$$=\frac{1}{(\theta_2-\theta_1)^n}I(\theta_1<\min(x_i))\,I(\theta_2>\max(x_i))$$

点估计的评价

- 无偏性：$E(\hat{\theta}) = \theta$
- 相合性：$\lim_{n\to\infty} E(\hat{\theta}) = \theta$，且$\lim_{n\to\infty} \mathrm{Var}(\hat{\theta}) = 0$
- 有效性：两个无偏估计，方差更小的更有效。

MSE



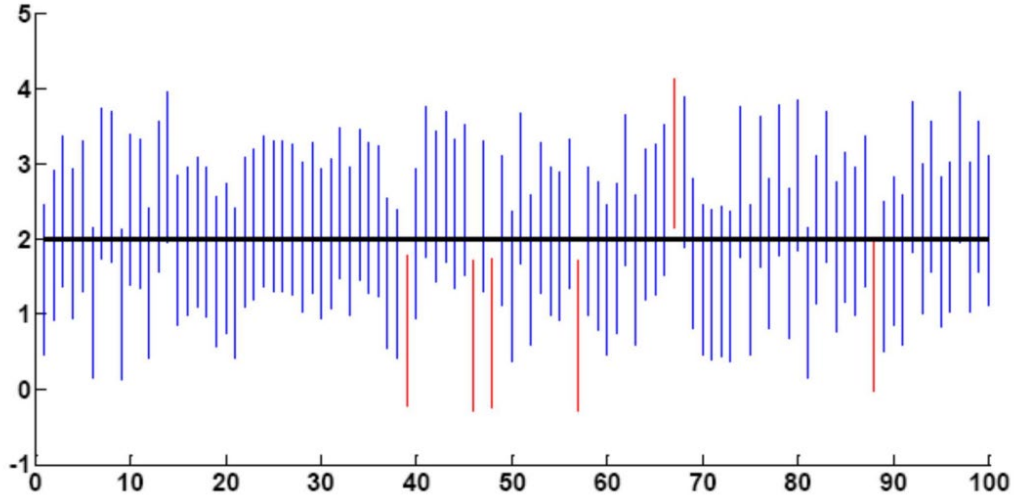
清華大學

区间估计

区间估计

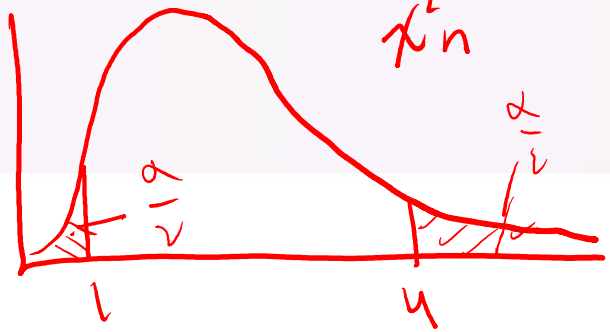
区间估计

- 两个统计量$\hat{\theta}_L < \hat{\theta}_U$组成区间$[\hat{\theta}_L, \hat{\theta}_U]$（也可以单侧区间估计），以此来估计参数$\theta$
- θ没有随机性，它是一个**确定但未知**的常数，随机性在$\hat{\theta}_L$和$\hat{\theta}_U$上。
- 置信水平为$1-\alpha$的含义：所得到的区间以至少$1-\alpha$的概率包含参数真值。



区间估计

- 枢轴量法：以双参数未知的正态总体均值的置信区间为例。
- 1. 枢轴量选取：$G=\frac{\bar{X}-\mu}{S/\sqrt{n}}\sim t(n-1)$；原则：枢轴量的值完全由抽样结果和未知参数值确定，枢轴量的分布完全确定（和样本量n有关也叫完全确定，但是不能和未知参数有关）
- 2. 适当选取常数l,u，对给定的α有$P(l\le G\le u)\ge 1-\alpha$。原则上要$u-l$最小，但这样在处理不对称分布的时候比较麻烦，一般加上一条$P(G\ge u)=P(G\le l)$保证两侧概率相等。这里t分布是对称分布无所谓，可以得到$l=t_{\alpha}(n-1),u=t_{1-\alpha}(n-1)$（这里注意$l$是负的）
- 3. 求解$l\le G\le u$，得到区间估计为$[\bar{X}-\frac{t_{1-\alpha}(n-1)S}{\sqrt{n}},\bar{X}-\frac{t_{\alpha}(n-1)S}{\sqrt{n}}]$





区间估计——习题

- 求双参数未知的正态分布中σ的区间估计

- 抽样定理：对正态总体$N(\mu,\sigma^2)$，有：
- 1. $\bar{X}$ 与S^2独立
- 2. $\bar{X}\sim N\left(\mu,\frac{\sigma^2}{n}\right)$
- 3. $\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$

清華大學

假设检验

假设检验基本流程、假设检验的两类错误、常见假设检验

假设检验基本流程

- 1. 建立假设 $H_0: \theta \in \Theta_0$ $v.s.$ $H_1: \theta \in \Theta_1$。 H_0一般是$\theta = \theta_0$, $\theta \leq \theta_0$, $\theta \geq \theta_0$中的一个，不会更加复杂；相应H_1一般是$\theta \neq \theta_0, \theta > \theta_0, \theta < \theta_0$中的一个。
- 2. 选择检验统计量T，确认其分布 ※

  拒绝域定义： $W = \{T \mid reject\ H_0\}$

  $\alpha = P\{T \in W \mid \theta = \theta_0\}$
- 3. 选择显著性水平α，$\alpha = \max\{P(reject\ H_0 \mid H_0\ is\ True)\}$，即$\alpha = \max\{P(T \in W \mid \theta \in \Theta_0)\}$，由此确认拒绝域（统计量形式决定其形式，显著性水平决定其范围）。
- 4. 根据实际数据计算统计量的值，根据其是否在拒绝域作出结论（在显著性水平α下拒绝H_0 /没有足够的证据在显著性水平α下拒绝H_0 ）

假设检验基本流程

- 1. 建立假设 $H_0: \theta \in \Theta_0$ $v.s.$ $H_1: \theta \in \Theta_1$。 H_0一般是$\theta = \theta_0$, $\theta \leq \theta_0$, $\theta \geq \theta_0$中的一个，不会更加复杂；相应H_1一般是$\theta \neq \theta_0, \theta \geq \theta_0, \theta \leq \theta_0$中的一个。
- 2. 选择检验统计量T，确认其分布 ※

  拒绝域定义： $W = \{T \mid reject\ H_0\}$

$\theta \leq \theta_0$ $P(\hat{\theta}^{obs} \leq \hat{\theta}) = p$

$\hat{\theta}$

- 3. 计算p值。p值定义：原假设成立的条件下，检验统计量的值比观测值更加偏离原假设的概率（的最大值）
- 4.选择显著性水平α，对比其和p值的大小。若p值小于α，则拒绝原假设。

假设检验的两类错误

	H_0 True	H_0 False
Accept H_0		Type II Error
Reject H_0	Type I Error	

- 第一类错误：假阴性（H_0 为真却拒绝H_0），错误概率
  $\alpha(\theta) = P(T \in W | \theta \in \Theta_0)$
- 第二类错误：假阳性（H_0 为假却接受H_0），错误概率
  $\beta(\theta) = P(T \in \bar{W} | \theta \in \Theta_1)$
- 第一类错误一般更加严重，需要避免。
- 回看显著性水平的定义$\alpha = \max\{P(T \in W \mid \theta \in \Theta_0)\}$，显著性水平的作用就是控制第一类错误的发生概率。

常见假设检验

- Z检验（也叫U检验）
- 检验正态总体$N(\mu,\sigma^2)$，其中μ未知，σ^2已知。
- 检验统计量$Z=\frac{\bar{X}-\mu_0}{\sigma^2/\sqrt{n}}\sim N(0,1)$
- 三种情况：
- $H_0:\mu=\mu_0\ \ v.s.\ H_1:\mu\neq\mu_0$ 拒绝域$\bar{X}\geq\mu_0+z_{1-\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$或$\bar{X}\leq\mu_0-z_{1-\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$
- $H_0:\mu\geq\mu_0\ \ v.s.\ H_1:\mu\leq\mu_0$ 拒绝域$\bar{X}\leq\mu_0-z_{1-\alpha}\frac{\sigma}{\sqrt{n}}$
- $H_0:\mu\leq\mu_0\ \ v.s.\ H_1:\mu\geq\mu_0$ 拒绝域$\bar{X}\geq\mu_0+z_{1-\alpha}\frac{\sigma}{\sqrt{n}}$
- 其中，$z_{1-\alpha}$为标准正态分布的下分位数。

常见假设检验

- T检验
- 检验正态总体$N(\mu,\sigma^2)$，其中μ和σ^2均未知。
- 检验统计量$T=\frac{\bar{X}-\mu_0}{S^2/\sqrt{n}}\sim t(n-1)$
- 三种情况：
- $H_0:\mu=\mu_0\ \ v.s.\ H_1:\mu\neq\mu_0$ 拒绝域$\bar{X}\geq\mu_0+t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}}$或$\bar{X}\leq\mu_0-t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}}$
- $H_0:\mu\geq\mu_0\ \ v.s.\ H_1:\mu\leq\mu_0$ 拒绝域$\bar{X}\leq\mu_0-t_{1-\alpha}(n-1)\frac{S}{\sqrt{n}}$
- $H_0:\mu\leq\mu_0\ \ v.s.\ H_1:\mu\geq\mu_0$ 拒绝域$\bar{X}\geq\mu_0+t_{1-\alpha}(n-1)\frac{S}{\sqrt{n}}$

假设检验基本流程——习题

假设总体服从 $P(\lambda)$（Poisson 分布），$X_1,\cdots,X_n$ 为其独立随机样本，考虑假设检验：$H_0:\ \lambda=\lambda_0$ v. s. $H_1:\ \lambda\neq\lambda_0$，请给出基于*大样本*方法的检验水平为 α 的检验.

THANK YOU

