初等概率论

# Lecture 10

# 协方差、相关

Bertsekas & Tsitsiklis Ch4 4.2

邓婉璐

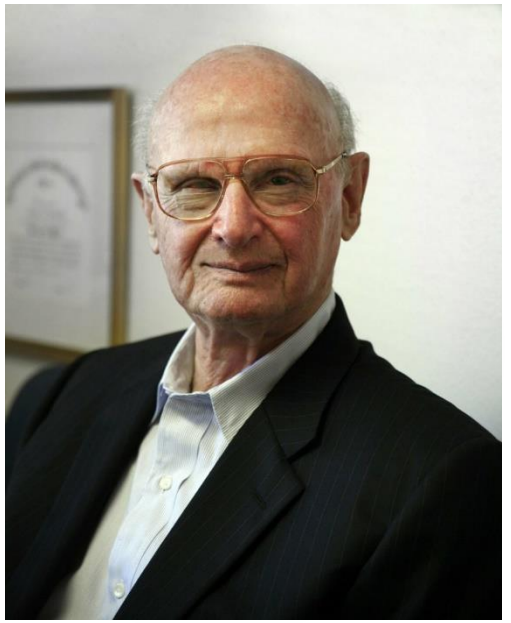
WANLUDENG@TSINGHUA.EDU.CN



清华大学统计学研究中心

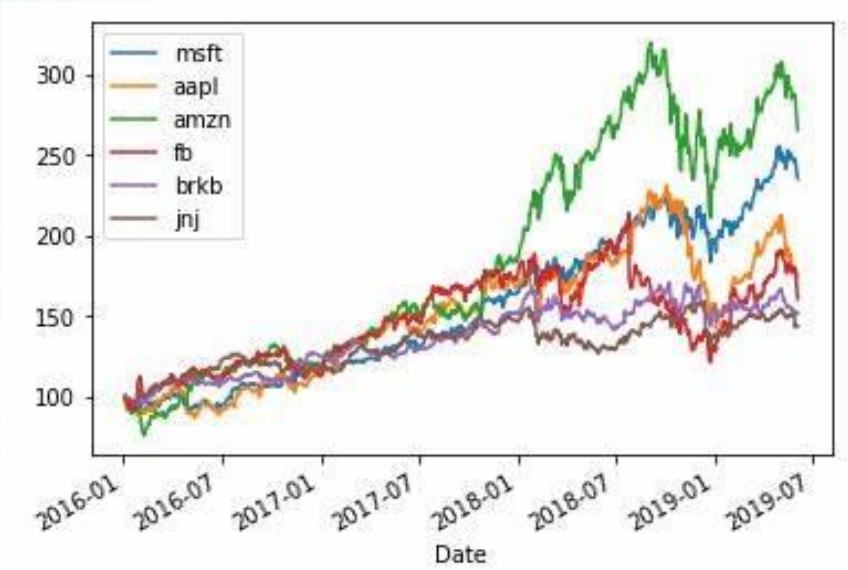
# 金融投资

- 资产组合，希望收益大、风险小
- 美国经济学家马考维茨1952年首次提出“现代资产组合理论”，并因此获得了1990年诺贝尔经济学奖.
  - 收益：资产组合的期望
  - 风险：资产组合的方差=每个资产的方差+资产之间的协方差



Harry Markowitz (1927- )

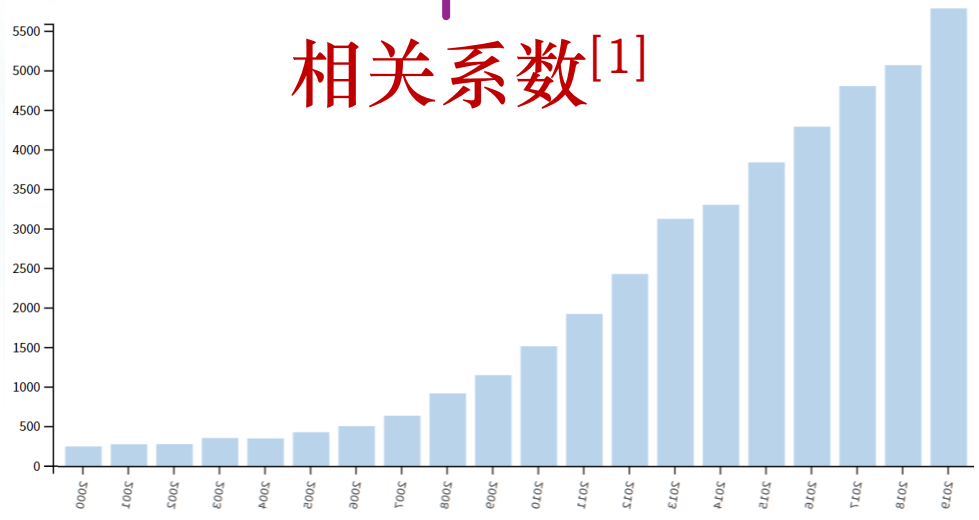


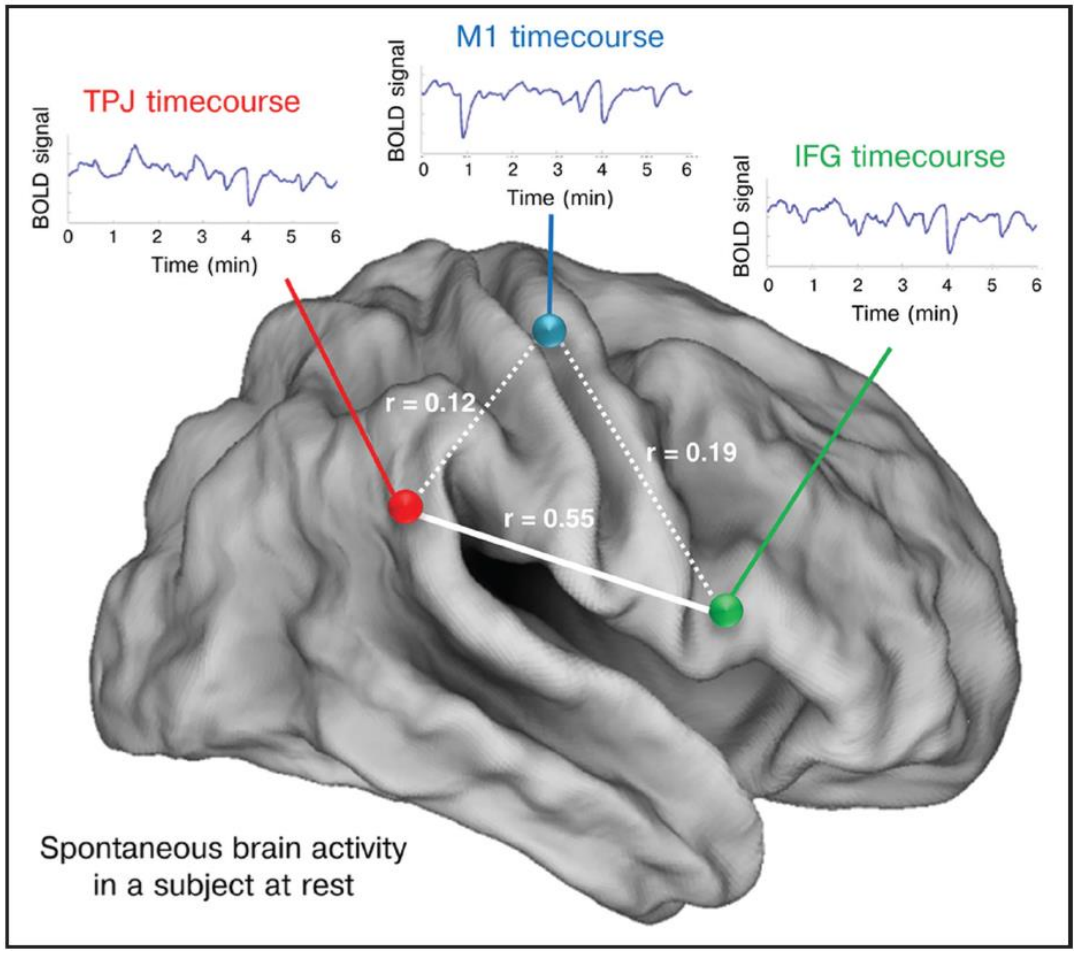


# 脑科学

- 大脑各部分是如何协作完成工作的?
- 如何刻画两个脑区信号变化之间的关系?
- 常用概念：功能连接(Functional connectivity)

相关系数[1]




[1] Tahedl M, etc. Functional Connectivity in Multiple Sclerosis: Recent Findings and Future Directions. *Front Neurol*. 2018, 9:828.

[2] Gillebert & Mantini. Functional Connectivity in the Normal and Injured Brain. *The Neuroscientist*. 2013,19:509-522.

# 目录



- 协方差定义及性质
- 相关系数定义
- 对协方差与相关系数的理解
- 小结

# 协方差定义及性质



# 温故而知新

抓住主要矛盾！

**概率空间**

$(\Omega, \mathcal{F}, P)$

概率$P(.)$

条件概率
$P_A(.) = P(.|A)$

独立

**随机变(向)量**

$X$, $\vec{X} = (X_1, X_2)$

分布列/概率密度 ---> 联合分布

边缘分布

累积分布 ---> 条件分布

$g(X)$ $g(\vec{X})$

**数值特征总结**

$EX$

?

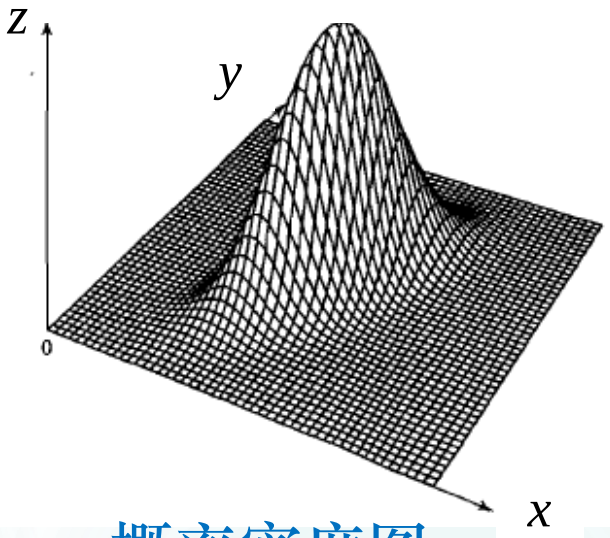
期望$EX$, 方差$Var(X) = E(X - EX)^2$

条件期望$m(y) \triangleq E(X|Y = y)$,

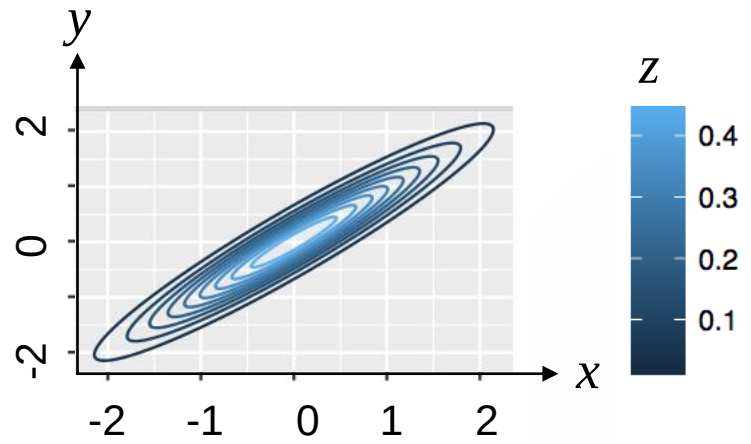
$E(X|Y) \triangleq m(Y)$

**如何定义一个数值特征来总结两个变量间的关系？**

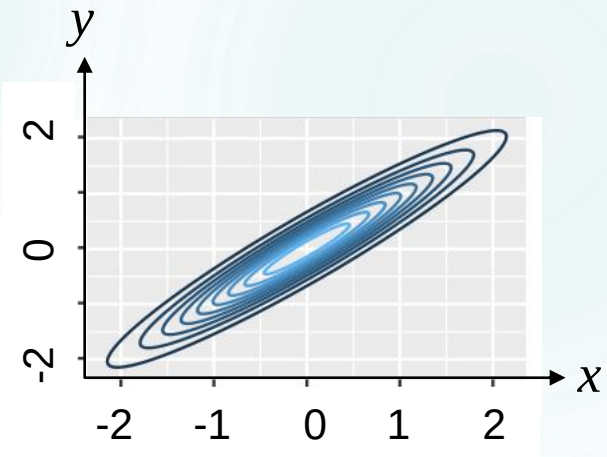
# 如何总结两变量间关系

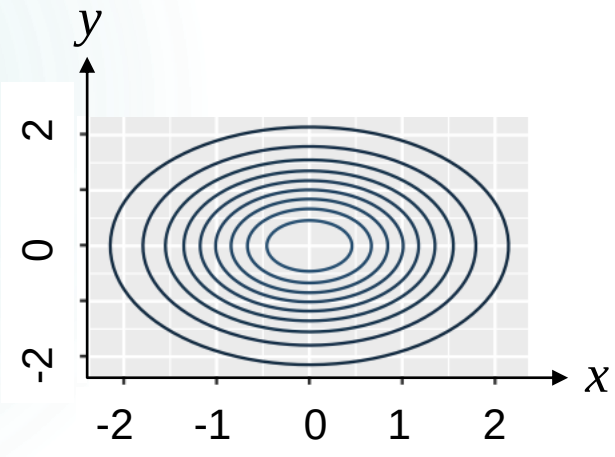



概率密度图

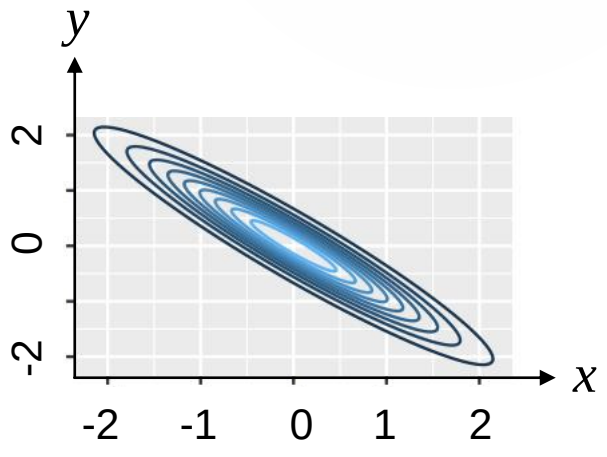



概率密度等高线图



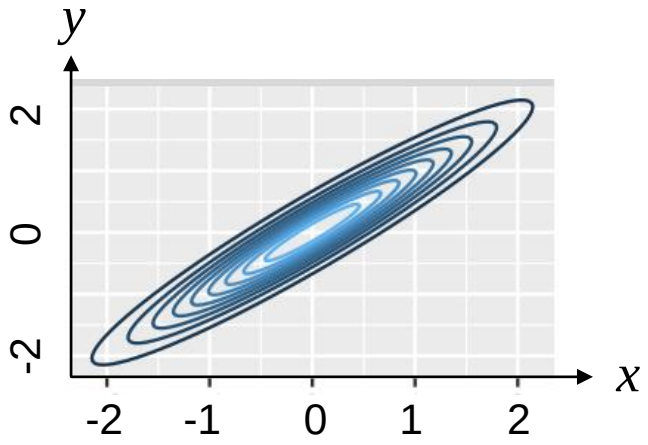

$g(X,Y)$ =?

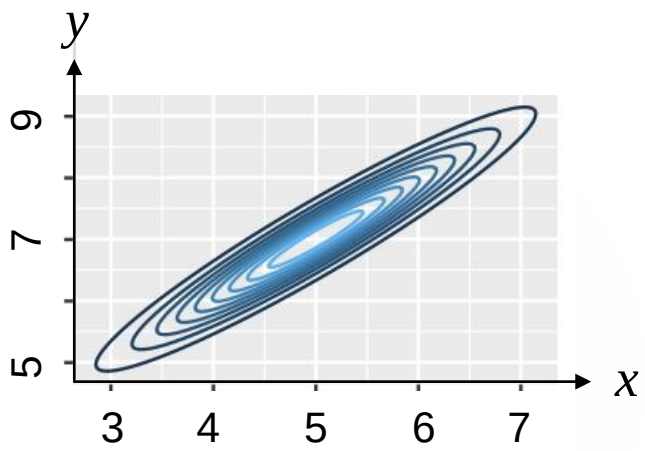


# 如何总结两变量间关系

- 平移：

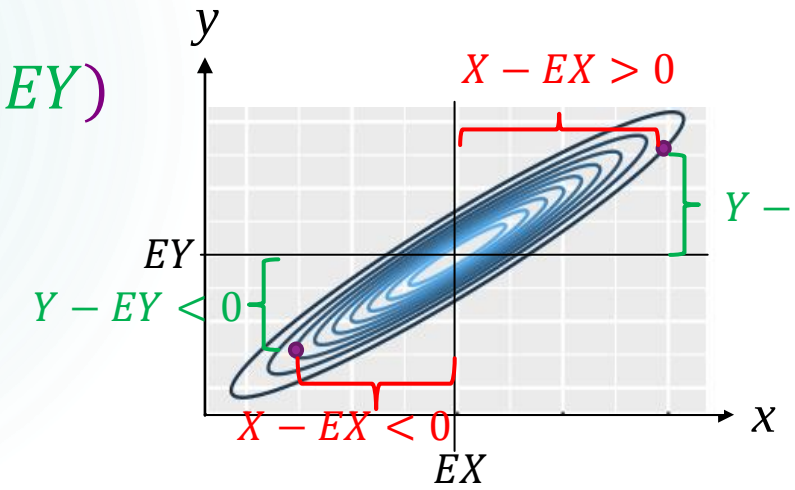
$g(X-EX, Y-EY)$

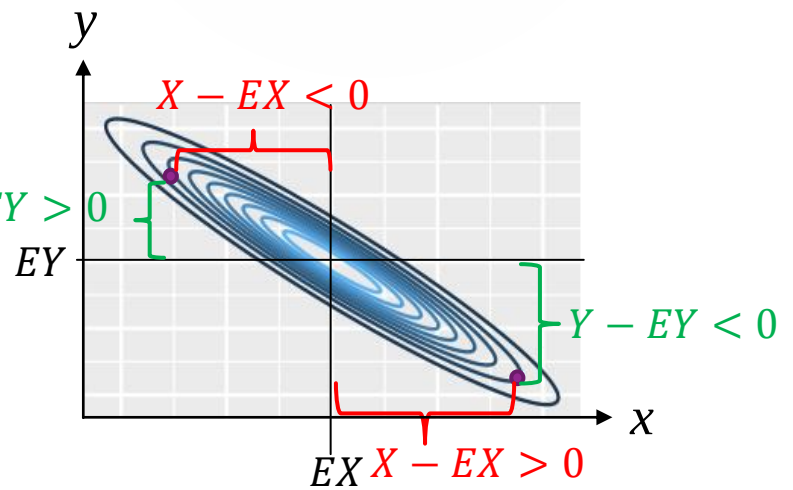



- 去除位置信息后：

$g(X,Y) \triangleq (X-EX)(Y-EY)$



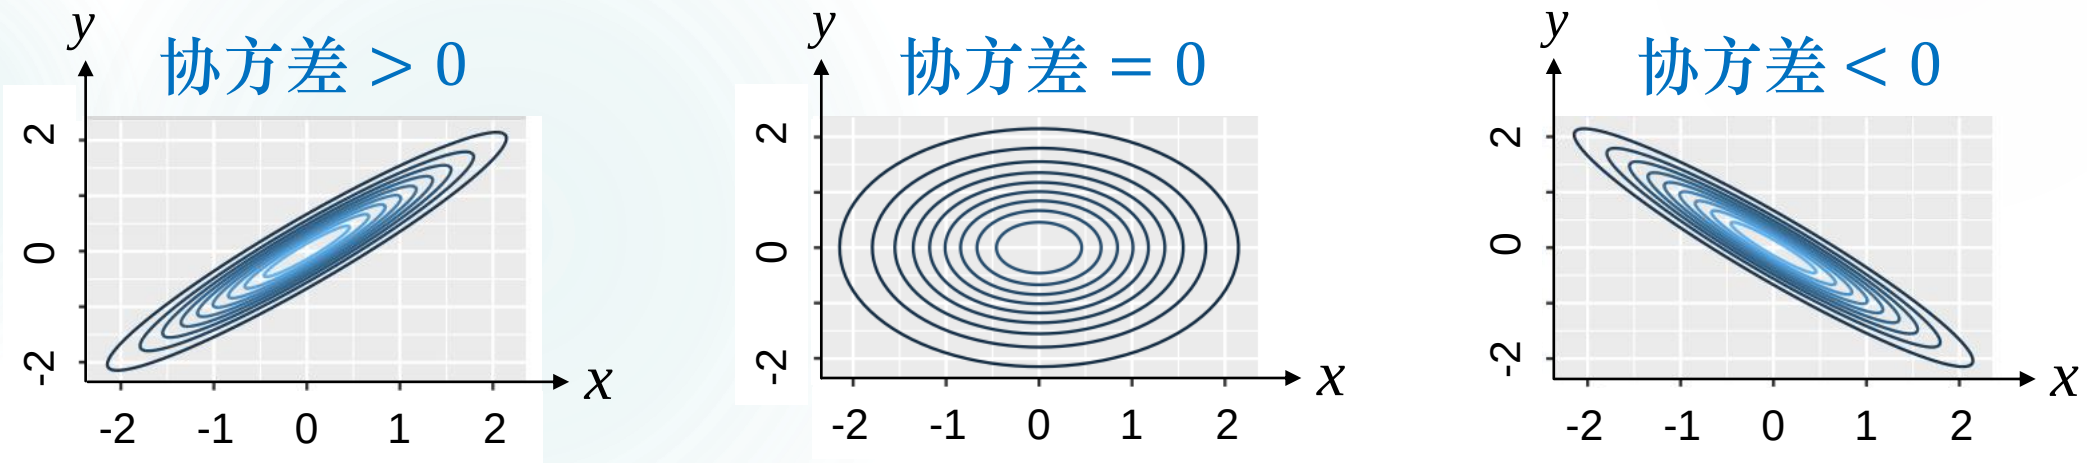
# 协方差

**定义 1.1 (协方差 (Covariance))**

设 $EX$ 和 $EY$ 存在, 当 $E|(X-EX)(Y-EY)|<\infty$ 时, 称

$$E[(X-EX)(Y-EY)]$$

为随机变量 $X,Y$ 的协方差 (covariance), 记作 $\mathrm{cov}(X,Y)$.




正相关　　不相关　　负相关

# 协方差

- **性质 1.1 (协方差性质)**
  1. $\mathrm{cov}(X,X) = \mathrm{var}(X)$;
  2. $\mathrm{cov}(X,Y) = \mathrm{cov}(Y,X)$;
  3. $\mathrm{cov}(X,Y)=E(XY)-(EX)(EY)$; (常用计算公式)
  4. 若$c$是某常数，则$\mathrm{cov}(X,c) = 0$;
  5. 双线性: $\mathrm{cov}(cX,Y) = c\,\mathrm{cov}(X,Y), \mathrm{cov}(X,Y+Z) = \mathrm{cov}(X,Y) + \mathrm{cov}(X,Z)$;
  6. $\mathrm{var}(X_1 + X_2) = \mathrm{var}(X_1) + \mathrm{var}(X_2) + 2\mathrm{cov}(X_1,X_2)$

- 本质上都基于期望的线性性质.

$$\begin{aligned}\mathrm{var}(X_1 + X_2) &= E[(X_1 + X_2) - E(X_1 + X_2)]^2 \\ &= E[(X_1 - EX_1) + (X_2 - EX_2)]^2 \\ &= E[(X_1 - EX_1)^2 + (X_2 - EX_2)^2 + 2(X_1 - EX_1)(X_2 - EX_2)] \\ &= \mathrm{var}(X_1) + \mathrm{var}(X_2) + 2\mathrm{cov}(X_1,X_2)\end{aligned}$$

# Review: 多项分布-经典离散型随机向量例



**例3.2（多项分布）**

同学们来自r个年级，雨课堂随机点名（有放回）。设$A_1, A_2, \dots, A_r$分别表示点到第1,2,...,r个年级的同学. 我们本堂计划进行$n$次点名，用$X_i$表示$A_i$发生的次数，（用归纳法可得）则$(X_1, \dots, X_r)$的概率分布是

$$\mathbb{P}(X_1 = k_1, \dots, X_r = k_r) = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$$

其中$k_i \geq 0, p_i = \mathbb{P}(A_i), \sum_{i=1}^{r} k_i = n.$

# 协方差



**例 1.1**

设$(X_1,\dots,X_k)\sim Multinomial(n,\vec{p}),\vec{p}=(p_1,\dots,p_k),\sum_{i=1}^{k}p_k=1$. 求$\mathrm{cov}(X_i,X_j)=?$

解.

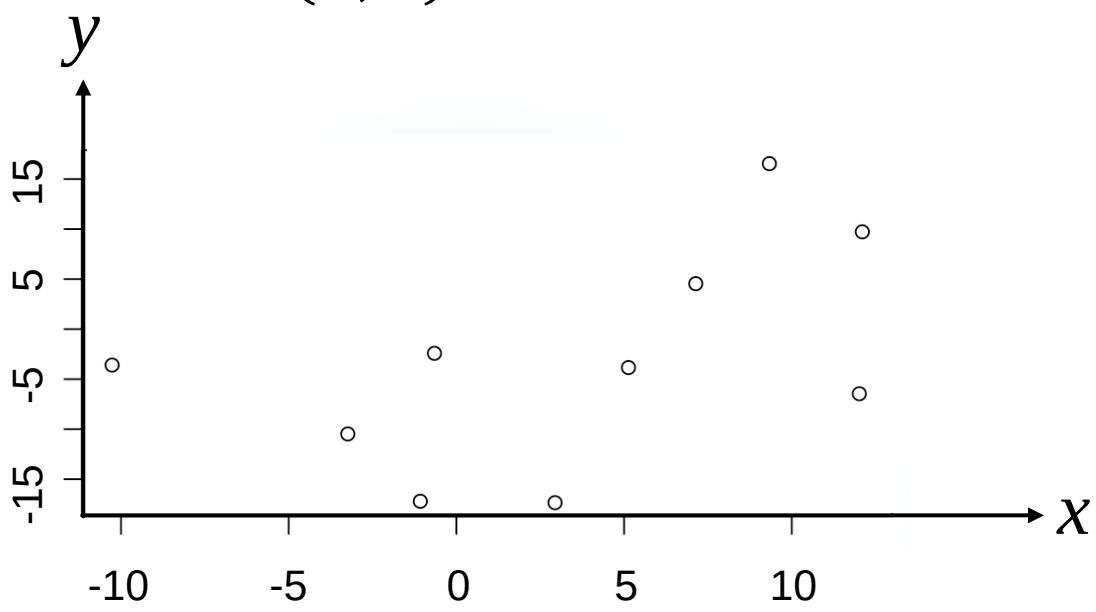
$i=j,\mathrm{cov}(X_i,X_j)=\mathrm{var}(X_i)=?;$

$i\neq j$, 以$\mathrm{cov}(X_1,X_2)$为例.

# 协方差的比较

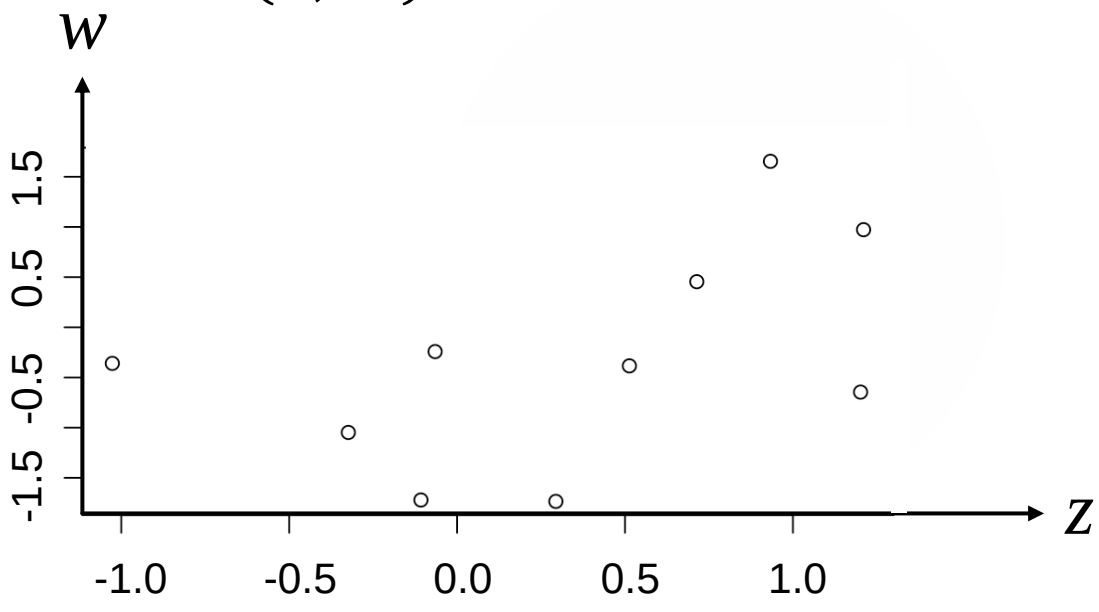
- 比较

$$\mathrm{cov}(X,Y)=42$$




$$X=10Z, Y=10W$$

$$\mathrm{cov}(Z,W)=0.42$$




$$\mathrm{var}(Z)=\mathrm{var}(W)=1$$

# 相关系数定义



# 相关系数

- 引入 $X, Y$ 的标准化

$$\frac{X - EX}{\sqrt{\mathrm{var}(X)}}, \qquad \frac{Y - EY}{\sqrt{\mathrm{var}(Y)}}.$$

则

$$\mathrm{cov}\left(\frac{X - EX}{\sqrt{\mathrm{var}(X)}}, \frac{Y - EY}{\sqrt{\mathrm{var}(Y)}}\right) = E\left[\left(\frac{X - EX}{\sqrt{\mathrm{var}(X)}}\right)\left(\frac{Y - EY}{\sqrt{\mathrm{var}(Y)}}\right)\right] = \frac{\mathrm{cov}(X, Y)}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}.$$

- **定义 1.2 (相关系数 (Correlation coefficient))**

  当 $0 < \mathrm{var}(X) \cdot \mathrm{var}(Y) < \infty$ 时, 称

$$\frac{\mathrm{cov}(X, Y)}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}$$

  为 $X, Y$ 的相关系数 (Pearson's correlation). 记作 $\mathrm{corr}(X, Y)$.



Karl Pearson (1857-1936)

# 相关系数



**例 1.3**

设 $(X,Y)\sim\mathcal{N}(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 则 $\mathrm{corr}(X,Y)=\rho$.

解.

不失一般性, 考虑标准联合正态分布. $(X,Y)$ 有联合密度

$$f(x,y)=\frac{1}{2\pi\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}[x^2-2\rho xy+y^2]\right\}.$$

则,

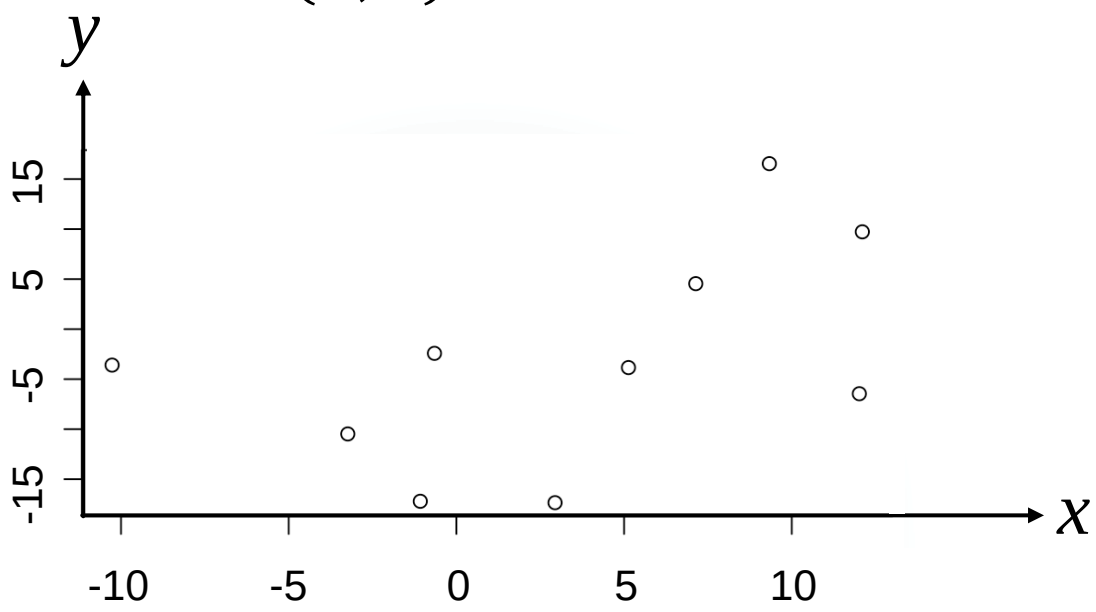
$$\mathrm{cov}(X,Y)=E(XY)-EX\cdot EY=\int_{R^2}xyf(x,y)dxdy-0\cdot 0=\rho.$$

这是为什么经常记作符号$\rho_{XY}$

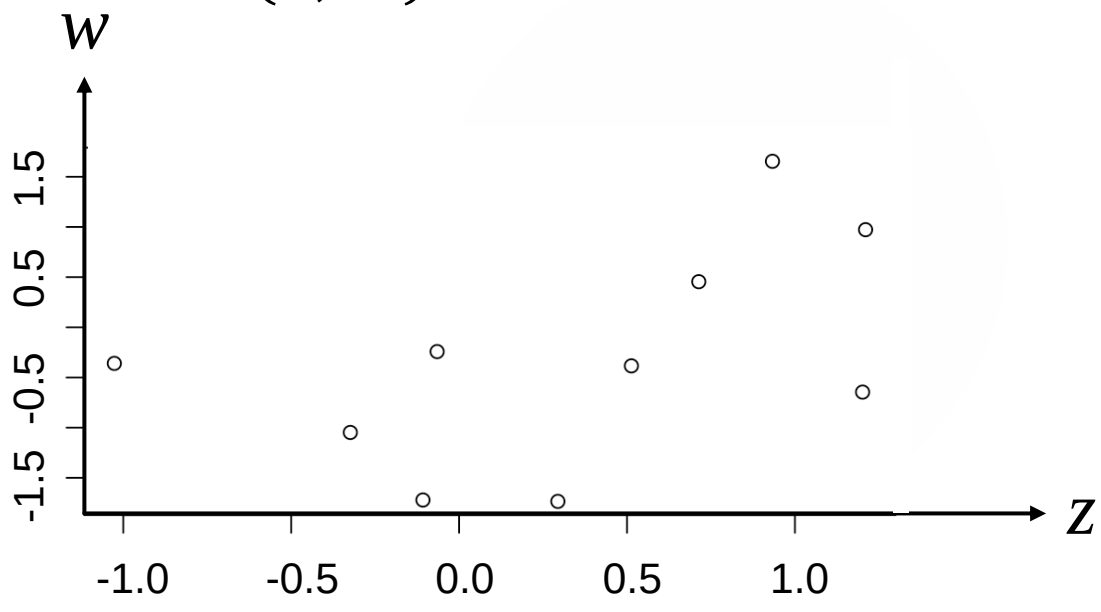
# 相关系数的比较

- 比较

$\mathrm{cov}(X,Y)=42$




$\mathrm{cov}(Z,W)=0.42$




$X=10Z, Y=10W$

$\mathrm{corr}(X,Y)=0.42$

$\mathrm{var}(Z)=\mathrm{var}(W)=1$

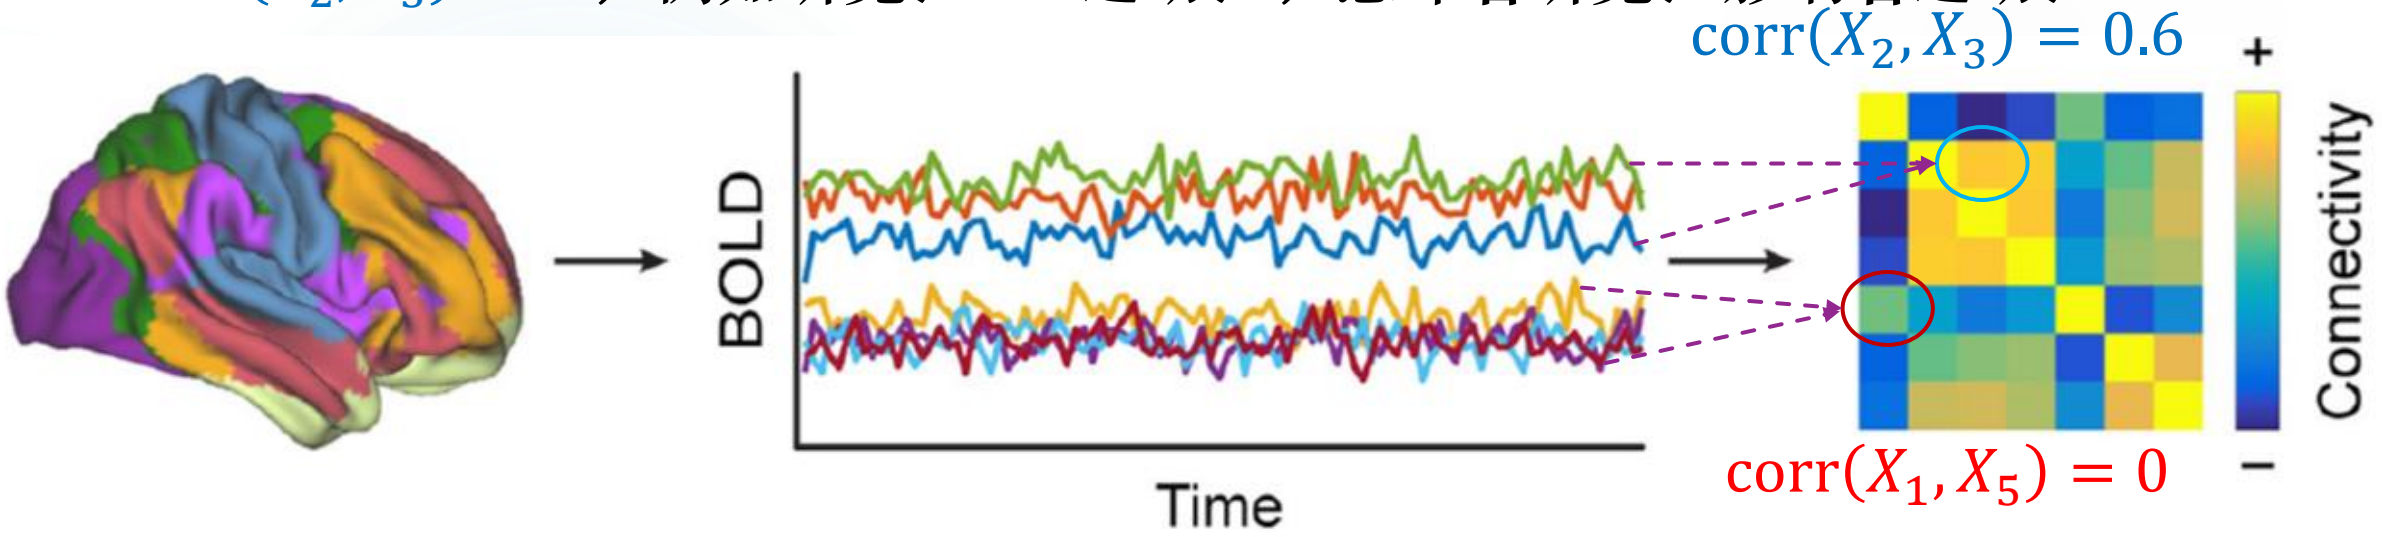
$\mathrm{corr}(Z,W)=0.42$

**相关系数具有可比性**

# 应用：脑影像数据分析



- 例如，$\mathrm{corr}(X_2, X_3) = 0.6 > \mathrm{corr}(X_1, X_5) = 0$，则前一对脑区功能连接更强.
- $\mathrm{corr}(X_1, X_5) = 0$，意味着这两个脑区功能没有关联?
- $\mathrm{corr}(X_2, X_3) \neq 0$，例如听觉区 vs 运动区，意味着听觉区影响着运动区?




图：用相关系数刻画功能连接的强弱



[1] Tahedl M, etc. Functional Connectivity in Multiple Sclerosis: Recent Findings and Future Directions. *Front Neurol.* 2018, 9:828.

# 深入理解



# 不相关与独立

- 独立意味着不相关?

**定理 1.1**

设 $X, Y$ 相互独立, 则有$X, Y$ 不相关, 即$\operatorname{cov}(X, Y) = 0.$

$$\operatorname{cov}(X, Y) = E[(X - EX)(Y - EY)] = E(X - EX) \cdot E(Y - EY) = 0$$

- 不相关意味着独立?

**若独立，则不相关**

# 相关系数

**例 1.3(续)**

设 $(X,Y)\sim\mathcal{N}(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 则 $\rho_{XY}=\rho$, 并且 $X,Y$ 独立 $\Leftrightarrow$ $X,Y$ 不相关.

解.

不失一般性, 考虑标准联合正态分布. $(X,Y)$ 有联合密度

$$f(x,y)=\frac{1}{2\pi\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}[x^2-2\rho xy+y^2]\right\}.$$

$$\operatorname{cov}(X,Y)=E(XY)=\int_{R^2}xyf(x,y)dxdy=\rho.$$

首先, $(\Rightarrow)$ $X,Y$ 独立，则$\rho=E(XY)=EX\cdot EY=0\cdot 0=0$

其次, $(\Leftarrow)$ 当 $\rho=0$ 时, 有

$$f(x,y)=\frac{1}{2\pi}\exp\left\{-\frac{1}{2}[x^2+y^2]\right\}$$

$$=\frac{1}{\sqrt{2\pi}}\exp\left\{-\frac{x^2}{2}\right\}\cdot\frac{1}{\sqrt{2\pi}}\exp\left\{-\frac{y^2}{2}\right\}.$$



# Review: 对期望的解读

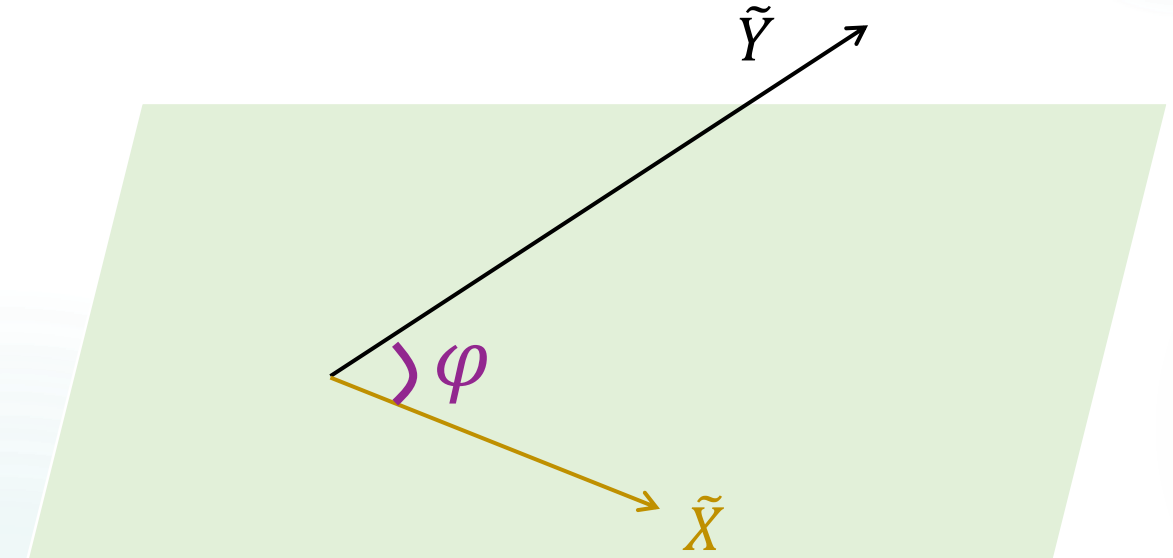
- 考虑$\tilde{X} = X - EX, \tilde{Y} = Y - EY$. 则$E\tilde{X} = 0,\ E\tilde{Y} = 0.$

$$\mathrm{corr}(X, Y) = \mathrm{corr}(X - EX, Y - EY)$$

| | $EY$ | $E(Y\|X)$ | $\mathrm{corr}(X, Y)$ |
|---|---|---|---|
| 代数 | $E(Y) = \int_R y dF(y)$. | $E(Y\|X) = m(X)$,<br>$m(x) = E(Y\|X = x)$. | $\mathrm{corr}(X, Y)$<br>$= \frac{E[(X - EX)(Y - EY)]}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}$ |
| 几何 | 重心 | 投影 | |
| 优化 | 常数中的最佳预测<br>$EY = \underset{c\in\mathbb{R}}{\mathrm{argmin}}\, E(Y - c)^2$. | $g(X)$中的最佳预测<br>$E(Y\|X) = m(X) =$<br>$\underset{g:\mathbb{R}\to\mathbb{R}}{\mathrm{argmin}}\, E[Y - g(X)]^2$. | |

# 相关系数的几何解释

$$\tilde{X} \longleftrightarrow \vec{a}$$
$$\tilde{Y} \longleftrightarrow \vec{b}$$
$$< \tilde{X}, \tilde{Y} > \triangleq E(\tilde{X}\tilde{Y}) \longleftrightarrow < \vec{a}, \vec{b} > \triangleq \vec{a} \cdot \vec{b}$$

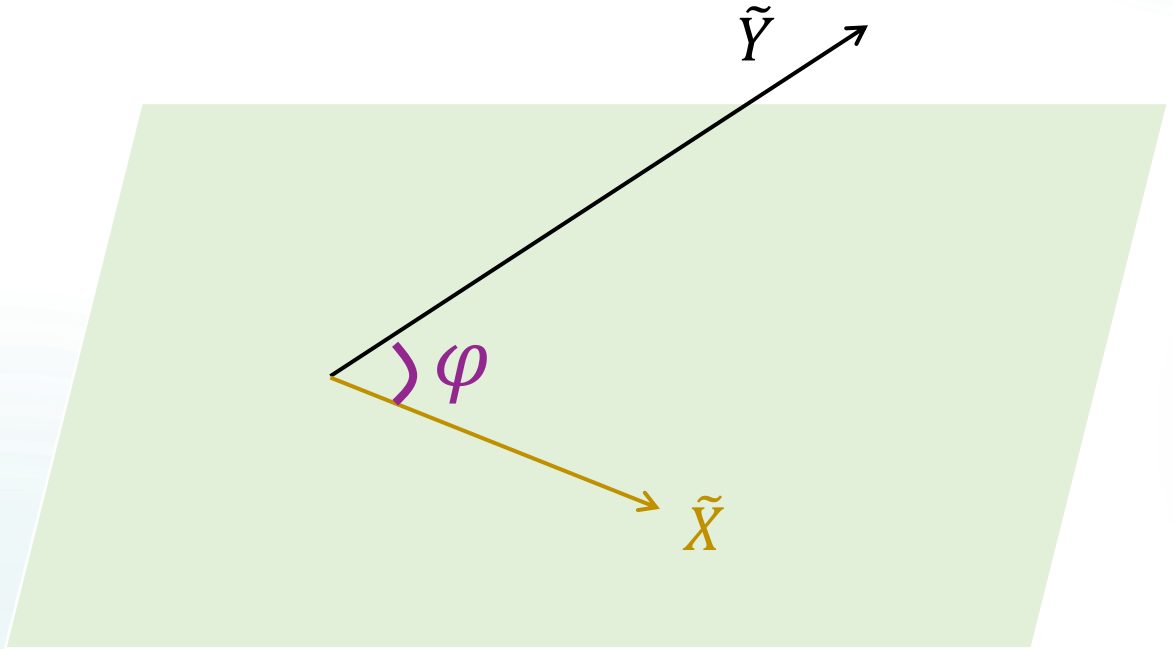



$$\mathrm{corr}(X,Y) = \mathrm{corr}(\tilde{X},\tilde{Y}) = \frac{\mathrm{cov}(\tilde{X},\tilde{Y})}{\sqrt{\mathrm{var}(\tilde{X})}\sqrt{\mathrm{var}(\tilde{Y})}} = \frac{E(\tilde{X}\tilde{Y})}{\sqrt{\mathrm{E}(\tilde{X}^2)}\sqrt{\mathrm{E}(\tilde{Y}^2)}} = \frac{< \tilde{X}, \tilde{Y} >}{|\tilde{X}| \cdot |\tilde{Y}|} = \cos(\varphi)$$

$|\mathrm{corr}(X,Y)| \le 1$; $|\mathrm{corr}(X,Y)| = 1$**等价于X, Y共线性**

# Review: 相关系数的几何解释

$$\begin{aligned} \tilde{X} &\longleftrightarrow \vec{a} \\ \tilde{Y} &\longleftrightarrow \vec{b} \\ <\tilde{X},\tilde{Y}> &\longleftrightarrow <\vec{a},\vec{b}> \\ \triangleq E(\tilde{X}\tilde{Y}) &\qquad\quad \triangleq \vec{a}\cdot\vec{b} \end{aligned}$$




$$\mathrm{corr}(X,Y) = \mathrm{corr}(\tilde{X},\tilde{Y}) = \frac{<\tilde{X},\tilde{Y}>}{|\tilde{X}|\cdot|\tilde{Y}|}$$

# 协方差和相关系数

**例 1.4**

设 $(X,Y)$ 在单位圆 $D=\{(x,y)|x^2+y^2\leq 1\}$ 内均匀分布，则 $X,Y$ 不相关，也不独立.

**解.**

$(X,Y)$ 有联合密度

$$f(x,y)=\frac{1}{\pi}I_D.$$

则

$$\begin{aligned}E(X)&=\int_{R^2}xf(x,y)dxdy\\&=\frac{1}{\pi}\int_{-1}^{1}\left(\int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}}xdx\right)dy=0.\end{aligned}$$

同理 $E(Y)=0$. 于是

$$\mathrm{cov}(X,Y)=\int_{R^2}xyf(x,y)dxdy=\frac{1}{\pi}\int_{-1}^{1}y\int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}}xdxdy=0.$$

# 归纳：不相关 ≠ 独立



▶ 不相关不一定独立!

不独立 ⟷ 关联
- 线性关联：Pearson相关系数
- 非线性关联：Spearman相关系数; 互信息(mutual information); …

▶ **定理 1.2**

设$\mathrm{corr}(X,Y)$是 $X,Y$ 的相关系数, 则

1. $|\mathrm{corr}(X,Y)| \le 1$;
2. $|\mathrm{corr}(X,Y)| = 1 \Leftrightarrow$

   存在常数 $a,b,c$, 使得 $aX + bY = c\ a.s.$ (几乎处处);

   此时称$X,Y$ 线性相关.

**定理4.2：内积不等式** 证明定理1.2的工具

设$EX^2 < \infty$和$EY^2 < \infty$, 则有

$$|E(XY)| \le \sqrt{EX^2 EY^2}.$$

等号成立的充分必要条件是存在不全为零的常数$a,b$使得$aX + bY = 0\ a.s.$

# 协方差与条件期望



**例 1.5**

设 $(X,Y)$ 服从二元正态分布. 当 $E(X|Y)=\mu$(常数), 证明 $X,Y$ 独立.

**证明.**

显然 $E(X)=E[E(X|Y)]=\mu$, 且

$$E[(X-\mu)Y]=E\big[E[(X-\mu)Y|Y]\big]=E\big[YE[(X-\mu)|Y]\big]$$
$$=E\big[Y[E(X|Y)-\mu]\big]=E[Y(\mu-\mu)]=0.$$

于是 $\mathrm{cov}(X,Y)=E[(X-\mu)(Y-EY)]=E[(X-\mu)Y]-E[(X-\mu)EY]$

$=0-E[(X-\mu)EY]=-E(X-\mu)\cdot EY=0.$

即$X,Y$ 不相关.

而二元正态分布下，独立等价于不相关.

因此， $X,Y$ 独立.

**思考题：对一般随机向量(X, Y)，若$E(Y\mid X)$为常数，是否意味着$X,Y$相互独立？**

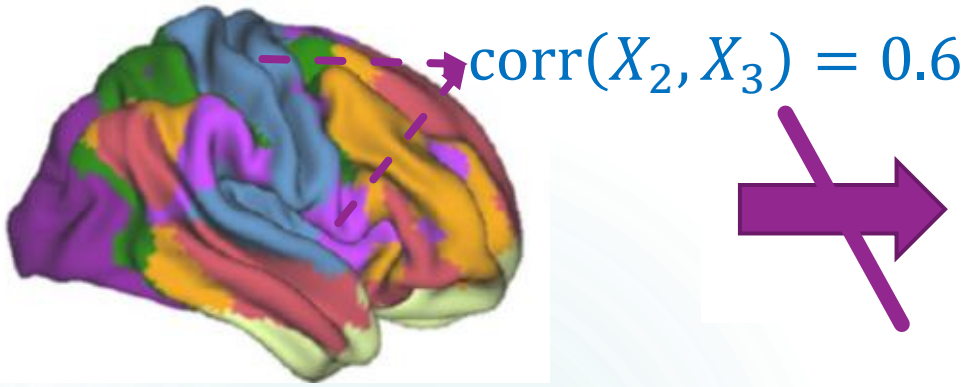
# 对期望的解读



| | $EY$ | $E(Y\|X)$ | $\mathrm{corr}(X,Y)$ |
|---|---|---|---|
| 代数 | $E(Y)=\int_R y dF(y)$. | $E(Y\|X)=m(X)$,<br>$m(x)=E(Y\|X=x)$. | $\mathrm{corr}(X,Y)$<br>$=\frac{E[(X-EX)(Y-EY)]}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}$ |
| 几何 | 重心 | 投影 | 夹角余弦 |
| 优化 | 常数中的最佳预测<br>$EY=\underset{c\in\mathbb{R}}{\mathrm{argmin}}\,E(Y-c)^2$. | $g(X)$中的最佳预测<br>$E(Y\|X)=m(X)=$<br>$\underset{g:\mathbb{R}\to\mathbb{R}}{\mathrm{argmin}}\,E[Y-g(X)]^2$. | 拟合直线中的最佳预测 $\rho\frac{\sqrt{\mathrm{var}(Y)}}{\sqrt{\mathrm{var}(X)}}=$<br>$\underset{b\in\mathbb{R}}{\mathrm{argmin}}\,E[(Y-EY)-b(X-EX)]^2$. |

# 相关是否意味着因果?

- 公鸡不打鸣，太阳照常升起






The ISME Journal (2019) 13:2647–2655
https://doi.org/10.1038/s41396-019-0459-z

ISME

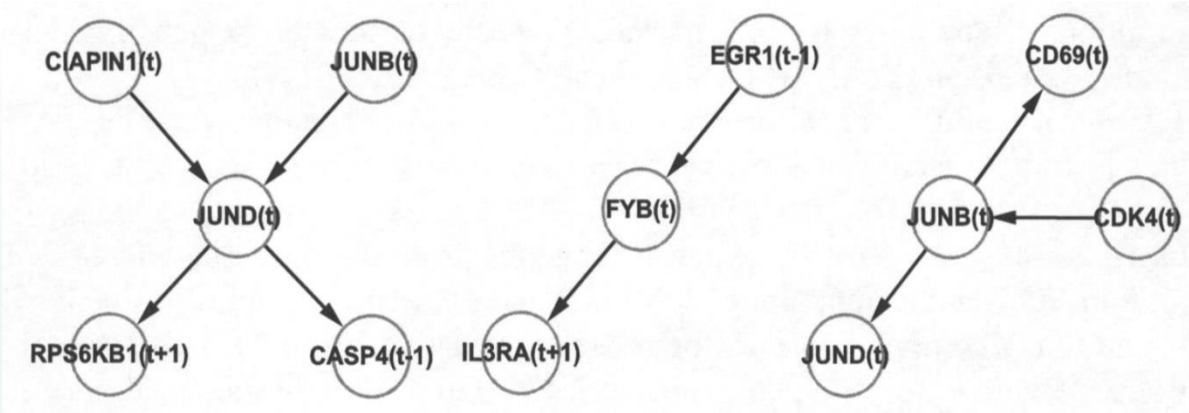
PERSPECTIVE

Use and abuse of correlation analyses in microbial ecology

- 思考：批判性；边界

# 相关是否可帮助认识因果?

- 例如，在完全数据、多元正态分布的假设下，我们基于协方差矩阵找到了小鼠Jurkat T-细胞激活的基因调节路径[1]. 有助于帮助我们进一步认识人类的急性T细胞白血病.




- 科普书籍：《The Book of WHY》, Judea Pearl (2011年图灵奖得主).
  (中译本：《为什么: 关于因果关系的新科学》)

[1] **Deng W**, Geng Z, Li H. Learning local directed acyclic graphs based on multivariate time series data. *Annals of Applied Statistics*. 2013;7(3):1249-1835.

# 随机向量的期望与协方差矩阵

留待之后介绍



# 随机向量的期望与协方差矩阵



- 设 $\mathbf{X}=(X_1,\ldots,X_n)$ 是随机向量，如果对每个 $i$，$\mu_i=EX_i$ 存在，就称 $\mathbf{X}$ 的数学期望存在，并且定义

$$\mu:=E\mathbf{X}=(EX_1,\ldots,EX_n)=(\mu_1,\ldots,\mu_n).$$

- 类似地，对随机矩阵

$$\mathbf{Y}=\begin{pmatrix}X_{11} & X_{12} & \cdots & X_{1n}\\ X_{21} & X_{22} & \cdots & X_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ X_{m1} & X_{m2} & \cdots & X_{mn}\end{pmatrix}$$

- 可以定义其数学期望

$$E\mathbf{Y}=\begin{pmatrix}EX_{11} & EX_{12} & \cdots & EX_{1n}\\ EX_{21} & EX_{22} & \cdots & EX_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ EX_{m1} & EX_{m2} & \cdots & EX_{mn}\end{pmatrix}.$$

# 随机向量的期望与协方差矩阵



- 设 $\mathbf{X}, \mathbf{Y}$ 如上定义，且数学期望都存在. 容易证明，对任何常数向量 $\mathbf{a} = (a_1, \ldots, a_n)$，常数矩阵 $\mathbf{A}_{k\times m}$，$\mathbf{B}_{n\times j}$，有
- 性质 2.1 (期望性质)
  1. $E(\mathbf{a}\mathbf{X}') = \mathbf{a}E\mathbf{X}'$;
  2. $(E\mathbf{Y})' = E(\mathbf{Y}')$;
  3. $E(\mathbf{A}\mathbf{Y}) = \mathbf{A}E(\mathbf{Y})$;
  4. $E(\mathbf{Y}\mathbf{B}) = E(\mathbf{Y})\mathbf{B}$;
  5. $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B}$;
- 本质上都基于期望的线性性质.
- 以后更常见的写法，是把向量都写成列向量.



# 随机向量的期望与协方差矩阵



**定义 2.1 (协方差矩阵 (Covariance Matrix))**

如果随机向量 $\mathbf{X}$ 的数学期望 $\mu = E\mathbf{X}$ 存在, 对每个分量 $X_i$ 的方差有限, 则称

$$\Sigma = E[(\mathbf{X} - \mu)'(\mathbf{X} - \mu)] = (\sigma_{ij})$$

为 $\mathbf{X}$ 的协方差矩阵, 其中 $\sigma_{ij} = \mathrm{cov}(X_i, X_j)$.

- 协方差矩阵 $\Sigma$ 是对称矩阵. 如果行列式 $\det(\Sigma) = 0$, 就称 $\Sigma$ 是退化的.

**定理 2.1**

设 $\Sigma$ 是 $\mathbf{X} = (X_1, \ldots, X_n)$ 的协方差矩阵, 则

1. $\Sigma$ 是非负定矩阵;
2. $\Sigma$ 退化的充要条件是存在不全为零的常数 $a_1, \ldots, a_n$ 使得

$$\sum_{i=1}^{n} a_i(X_i - EX_i) = 0 \qquad a.s.$$



# 随机向量的期望与协方差矩阵



- 证明.

任取一个 $n$ 维实向量 $\mathbf{a}=(a_1,\ldots,a_n)$, 有

$$\mathbf{a}\,\Sigma\mathbf{a}'=\sum_{i=1}^{n}\sum_{j=1}^{n}a_ia_j\sigma_{ij}=\sum_{i=1}^{n}\sum_{j=1}^{n}a_ia_jE\left[(X_i-EX_i)(X_j-EX_j)\right]$$

$$=E\left[\sum_{i=1}^{n}a_i(X_i-EX_i)\right]^2=\mathrm{var}\left[\sum_{i=1}^{n}a_i(X_i-EX_i)\right]\geq 0.$$

所以 $\Sigma$ 非负定. $\Sigma$ 退化的充要条件是存在非零向量 $\boldsymbol{a}$ 使得

$$\mathrm{var}\left[\sum_{i=1}^{n}a_i(X_i-EX_i)\right]=0.$$

即,

$$\sum_{i=1}^{n}a_i(X_i-EX_i)=0\quad a.s.$$

# 小结



# 小结

- 知识点
  - ✓ 掌握协方差、相关系数的基本定义
  - ✓ 能够利用定义/性质 解决/简化 计算/证明（通过应用例子进行训练）
  - ✓ 理解协方差、相关系数是变量间协同性的总结，能够对结果做出正确的解读 (e.g. 明确不相关与独立的关系; 特例: 正态分布)
  - 重点：应用；难点：理解
  - ✓ 了解随机向量的期望、方差矩阵的定义 (本课程仅要求二元)
- 技巧
  - ✓ 小的计算技巧: 利用对称性、示性函数简化计算
  - ✓ 高维不清楚时, 用简单二维情形来帮助理解