

概率论与数理统计

统计部分第3讲　参数区间估计

参数区间估计

- 点估计是用一个点（即一个数或随机变量）估计未知参数。顾名思义，区间估计就是用一个区间估计未知参数。
- 例如估计一个人的年龄在40至45岁之间，一个人的身高在1米75至1米80之间，估计产品的合格率在0.95至0.98之间。
- 区间估计考虑到了估计的误差，多少给人们以更大的信任感。区间估计的理论就是用明确的概率语言刻画这种“信任感”的意义，并给出得到区间估计的具体方法。

参数区间估计示例

例　样本 x_1, x_2, x_3, x_4 来自正态总体 $N(\mu, 1)$, 样本均值 $\bar{x}$ 是参数 μ 的一个点估计，

$[\bar{x}-1, \bar{x}+1]$ 即为 μ 的一个区间估计 。　$P(\bar{x}=\mu)=0$,　$\bar{x}-\mu \sim N\left(0, \frac{1}{4}\right)$。

$$P\left(\mu \in [\bar{x}-1, \bar{x}+1]\right) = P\left(\bar{x}-1 \le \mu \le \bar{x}+1\right)$$

$$= P\left(\mu-1 \le \bar{x} \le \mu+1\right)$$

$$= P\left(-1 \le \bar{x}-\mu \le 1\right) = P\left(-2 \le 2(\bar{x}-\mu) \le 2\right)$$

$$= \Phi(2) - \Phi(-2) \approx 0.9544$$

参数区间估计示例

例　样本 x_1, x_2, x_3, x_4 来自正态总体 $N(\mu, 1)$, 样本均值 $\bar{x}$ 是参数 μ 的一个点估计, $[\bar{x}-1, \bar{x}+1]$ 即为 μ 的一个区间估计 。　$P(\bar{x}=\mu)=0$,　$\bar{x}-\mu \sim N\left(0, \frac{1}{4}\right)$。

$$P(\mu \in [\bar{x}-1, \bar{x}+1]) = P(\bar{x}-1 \le \mu \le \bar{x}+1) = P(\mu-1 \le \bar{x} \le \mu+1)$$

$$= P(-1 \le \bar{x}-\mu \le 1) = P(-2 \le 2(\bar{x}-\mu) \le 2) = \Phi(2)-\Phi(-2) \approx 0.9544$$

$[\bar{x}-1, \bar{x}+1]$ 是 μ 的一个置信水平 0.9544 的区间估计, 也可说是置信水平 0.9 或 0.8的区间估计。给出的估计区间称为置信区间。置信水平可以取到的最大值称为置信系数。

置信水平的解释

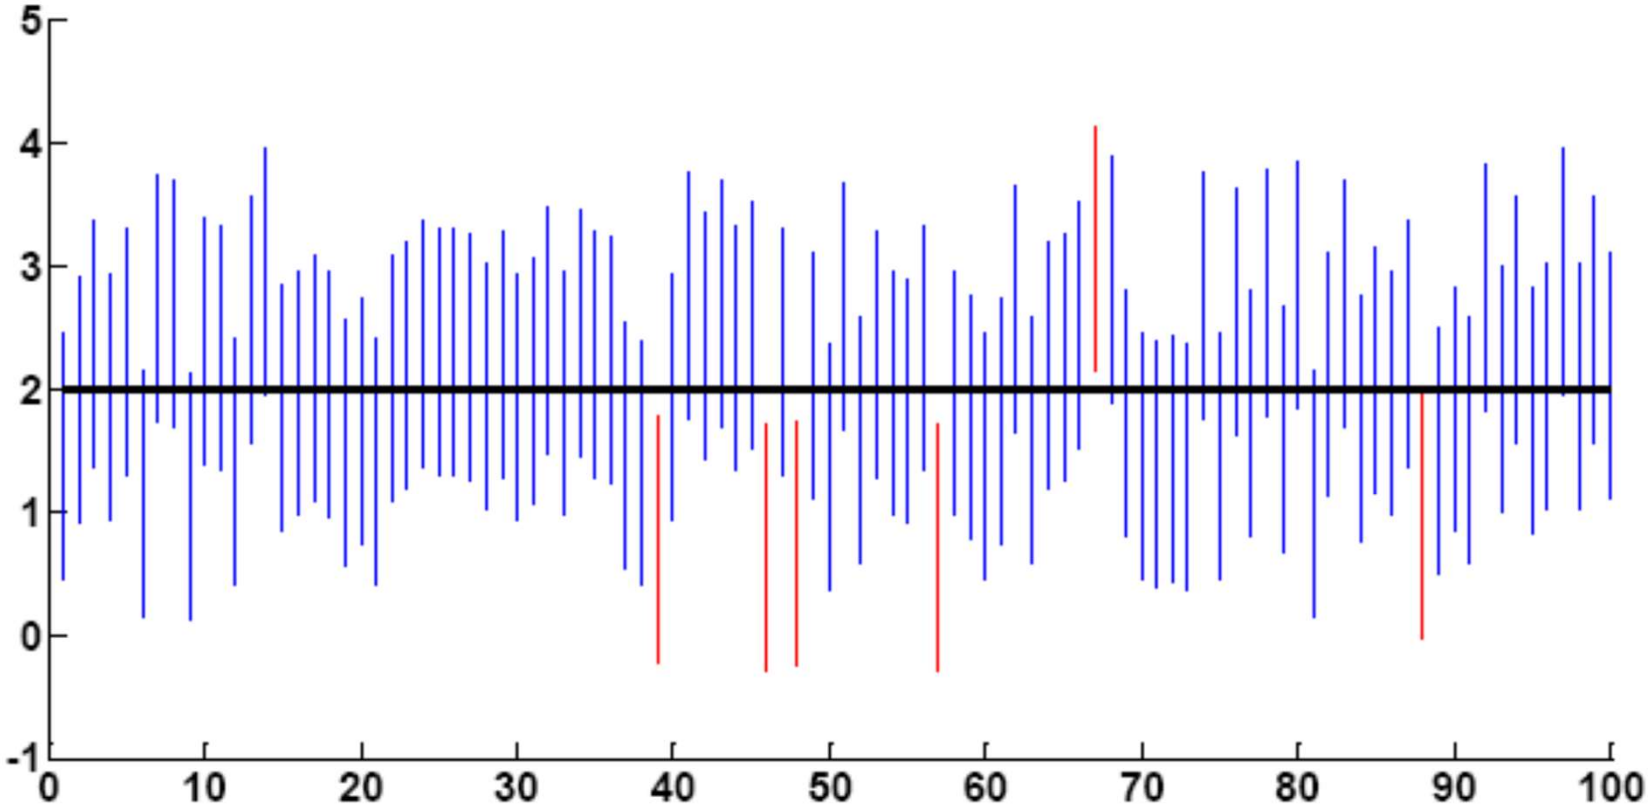
未知参数本身是确定的值，不带有随机性。随机性是由区间引入的。

一个置信水平$1-\alpha$的区间估计，其含义是：得到的随机区间至少以概率$1-\alpha$覆盖被估的参数。

考虑前面的问题。置信水平的含义是：每抽取 4 个样本得到一个区间估计，将这样的估计重复足够多次，至少$1-\alpha$比例的估计区间包含真实的μ值。这里置信系数是 0.9544，即大约 95.44%估计区间包含真实的μ值。

置信水平的解释（图示）

下图是重复100次估计的模拟结果。继续模拟，将估计重复10000次，结果442次估计区间没有包含μ的真实值2。当然，这些都是概率意义上的结果。具体的每一次估计，我们不会知道区间是否包含未知参数。



Script (Matlab):

```
n=4; m=100; mu=2; sigma=1;
% 设总体为N(mu,sigma^2), 样本容量n，重复估计m次

for k=1:m
    x(k,:)=sigma*(mu+randn(1,n));
    % randn是Matlab中生成N(0,1)随机数的命令
end

y=mean(x,2);  a=1;
hold on

for k=1:m
    if y(k)-a>mu | y(k)+a<mu
        plot([k,k],[y(k)-a,y(k)+a],'r','linewidth',2);
        % 没有覆盖参数的区间涂红色
    else
        plot([k,k],[y(k)-a,y(k)+a],'linewidth',2);      % 覆盖参数的区间涂蓝色
    end;
end

plot([1 m],[mu mu],'k','linewidth',3);                  % 以参数值画一条横线
```

参数区间估计定义

设 $x_1, x_2, \cdots, x_n$ 是来自总体 $X \sim F(x;\theta)$ 的样本，$\theta \in \Theta \subset R^1$ 为未知参数。

$I(x_1, x_2, \cdots, x_n)$ 是一个**随机区间**，由样本值完全确定。称该区间是参数 θ 的一个**置信水平**为 $1-\alpha$ $(0<\alpha<1)$ 的区间估计，是指

$P_\theta(\theta \in I(x_1, x_2, \cdots, x_n)) \geq 1-\alpha$，　$\forall \theta \in \Theta$。其中

$I = [\hat{\theta}_1(x_1, x_2, \cdots, x_n), \hat{\theta}_2(x_1, x_2, \cdots, x_n)]$　　（双侧）区间估计

$I = [\hat{\theta}_L(x_1, x_2, \cdots, x_n), +\infty)$　　$\hat{\theta}_L$：置信下界　（单侧区间估计）

$I = (-\infty, \hat{\theta}_U(x_1, x_2, \cdots, x_n)]$　　$\hat{\theta}_U$：置信上界　（单侧区间估计）

区间估计的两个基本要求：

1. 未知参数 θ 要以尽可能大的概率落在区间 $I(x_1, x_2, \cdots, x_n)$ 中；

2. 估计的精度要尽可能高。比如，在达到一定的置信水平的前提下，要求区间的长度尽可能小，或某种能体现这个要求的其他准则。

区间估计的构造方法

枢轴量法（双侧置信区间为例）

步骤 1　构造“枢轴量”（pivot），$G(x_1,\cdots,x_n,\theta)$，G 的值完全由样本值和未知参数确定，G 的分布不依赖于未知参数

步骤 2　适当选取两个常数 c、d，对给定的 α（$0<\alpha<1$），有

$$P(c \le G \le d) \ge 1-\alpha$$

步骤 3　求解 $c \le G(x_1,\cdots,x_n,\theta) \le d$，得到

$$\hat{\theta}_1(x_1,x_2,\cdots,x_n) \le \theta \le \hat{\theta}_2(x_1,x_2,\cdots,x_n)。$$

区间估计公式：总体$N\left(\mu,\sigma^2\right)$，$\sigma^2$已知，$\mu$未知，$x_1,x_2,\cdots,x_n$是简单随机样本，求$\mu$的$1-\alpha$置信区间。

解：μ的点估计$\bar{x}\sim N\left(\mu,\dfrac{\sigma^2}{n}\right)$，$\bar{x}-\mu$的分布与$\mu$无关，

$\dfrac{\bar{x}-\mu}{\sqrt{\dfrac{\sigma^2}{n}}}$可作为枢轴量，$Z=\dfrac{\bar{x}-\mu}{\sqrt{\dfrac{\sigma^2}{n}}}=\dfrac{\sqrt{n}\left(\bar{x}-\mu\right)}{\sigma}\sim N\left(0,1\right)$

$$\Phi\left(d\right)-\Phi\left(c\right)=P\left\{c\le\frac{\sqrt{n}\left(\bar{x}-\mu\right)}{\sigma}\le d\right\}=1-\alpha$$

确定c、d，使得置信区间尽可能短。

置信区间的选取

假设枢轴量的分布函数是 $F(x)$, 密度函数为 $p(x)$。则得到优化问题：

$\min\ d-c$

约束条件：$F(d)-F(c)=1-\alpha$

Lagrange乘子法

$$L(c,d;\lambda)=d-c+\lambda\left(F(d)-F(c)-1+\alpha\right)$$

$$\begin{cases}\dfrac{\partial L(c,d;\lambda)}{\partial c}=-1-\lambda p(c)=0\\ \dfrac{\partial L(c,d;\lambda)}{\partial d}=-1-\lambda p(d)=0 \quad\Rightarrow p(c)=p(d)\\ \dfrac{\partial L(c,d;\lambda)}{\partial \lambda}=F(d)-F(c)-1+\alpha=0\end{cases}$$

区间估计公式：总体$N(\mu,\sigma^2)$，σ^2已知，μ未知，$x_1,x_2,\cdots,x_n$是简单随机样本，求μ的$1-\alpha$置信区间。

$\dfrac{\bar{x}-\mu}{\sqrt{\dfrac{\sigma^2}{n}}}$可作为枢轴量，$Z=\dfrac{\bar{x}-\mu}{\sqrt{\dfrac{\sigma^2}{n}}}=\dfrac{\sqrt{n}(\bar{x}-\mu)}{\sigma}\sim N(0,1)$

$$\Phi(d)-\Phi(c)=P\left(c\le\frac{\sqrt{n}(\bar{x}-\mu)}{\sigma}\le d\right)=1-\alpha$$

确定c、d，使得置信区间尽可能短。

$$p(c)=p(d),\Phi(d)-\Phi(c)=1-\alpha$$

$$\Phi(d)=1-\frac{\alpha}{2},\quad \Phi(c)=\frac{\alpha}{2}$$

$$\Rightarrow\quad d=\Phi^{-1}\left(1-\frac{\alpha}{2}\right),\quad c=\Phi^{-1}\left(\frac{\alpha}{2}\right)$$

标准正态分布的$1-\dfrac{\alpha}{2}$分位数和$\dfrac{\alpha}{2}$分位数，$d=u_{1-\frac{\alpha}{2}}$，$c=u_{\frac{\alpha}{2}}=-u_{1-\frac{\alpha}{2}}$

（下侧）α 分位数

X 为一连续分布随机变量，如果 $P(X \le a) = \alpha$，a 称为（下侧）α 分位数

标准正态分布的α 分位点记为 u_α

n 个自由度的 χ^2 分布的α 分位点记为 $\chi^2_\alpha(n)$

n 个自由度的 t 分布的α 分位点记为 $t_\alpha(n)$

(m,n) 自由度的 F 分布的α 分位点记为 $F_\alpha(m,n)$

X 为一连续分布随机变量，如果 $P(X \ge a) = \alpha$，

a 称为上侧α 分位数

附表五　F 分布上侧分位数表　$\left(P\{F(n_1,n_2)>F_\alpha(n_1,n_2)\}=\alpha\right)$

$\alpha=0.10$

n_2 \ n_1	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	39.86	49.50	53.59	55.83	57.24	58.20	58.91	59.44	59.86	60.19	60.71	61.22	61.74	62.00	62.26	62.53	62.79	63.06	63.33
2	8.53	9.00	9.16	9.24	9.29	9.33	9.35	9.37	9.38	9.39	9.41	9.42	9.44	9.45	9.46	9.47	9.47	9.48	9.49
3	5.54	5.46	5.39	5.34	5.31	5.28	5.27	5.25	5.24	5.23	5.22	5.20	5.18	5.18	5.17	5.16	5.15	5.14	5.13
4	4.54	4.32	4.19	4.11	4.05	4.01	3.98	3.95	3.94	3.92	3.90	3.87	3.84	3.83	3.82	3.80	3.79	3.78	4.76
5	4.06	3.78	3.62	3.52	3.45	3.40	3.37	3.34	3.32	3.30	3.27	3.24	3.21	3.19	3.17	3.16	3.14	3.12	3.10
6	3.78	3.46	3.29	3.18	3.11	3.05	3.01	2.98	2.96	2.94	2.90	2.87	2.84	2.82	2.80	2.78	2.76	2.74	2.72
7	3.59	3.26	3.07	2.96	2.88	2.83	2.78	2.75	2.72	2.70	2.67	2.63	2.59	2.58	2.56	2.54	2.51	2.49	2.47
8	3.46	3.11	2.92	2.81	2.73	2.67	2.62	2.59	2.56	2.54	2.50	2.46	2.42	2.40	2.38	2.36	2.34	2.32	2.29
9	3.36	3.01	2.81	2.69	2.61	2.55	2.51	2.47	2.44	2.42	2.38	2.34	2.30	2.28	2.25	2.23	2.21	2.18	2.16
10	3.29	2.92	2.73	2.61	2.52	2.46	2.41	2.38	2.35	2.32	2.28	2.24	2.20	2.18	2.16	2.13	2.11	2.08	2.06
11	3.23	2.86	2.66	2.54	2.45	2.39	2.34	2.30	2.27	2.25	2.21	2.17	2.12	2.10	2.08	2.05	2.03	2.00	1.97
12	3.18	2.81	2.61	2.48	2.39	2.33	2.28	2.24	2.21	2.19	2.15	2.10	2.06	2.04	2.01	1.99	1.96	1.93	1.90
13	3.14	2.76	2.56	2.43	2.35	2.28	2.23	2.20	2.16	2.14	2.10	2.05	2.01	1.98	1.96	1.93	1.90	1.88	1.85
14	3.10	2.73	2.52	2.39	2.31	2.24	2.19	2.15	2.12	2.10	2.05	2.01	1.96	1.94	1.91	1.89	1.86	1.83	1.80
15	3.07	2.70	2.49	2.36	2.27	2.21	2.16	2.12	2.09	2.06	2.02	1.97	1.92	1.90	1.87	1.85	1.82	1.79	1.76
16	3.05	2.67	2.46	2.33	2.24	2.18	2.13	2.09	2.06	2.03	1.99	1.94	1.89	1.87	1.84	1.81	1.78	1.75	1.72
17	3.03	2.64	2.44	2.31	2.22	2.15	2.10	2.06	2.03	2.00	1.96	1.91	1.86	1.84	1.81	1.78	1.75	1.72	1.69
18	3.01	2.62	2.42	2.29	2.20	2.13	2.08	2.04	2.00	1.98	1.93	1.89	1.84	1.81	1.78	1.75	1.72	1.69	1.66

分位数练习

$X \sim N(0,1)$，则 $P(|X| < u_{0.975}) =$

$$P(|X| < u_{0.975}) = P(-u_{0.975} < X < u_{0.975})$$

$$= 1 - 0.025 \times 2 = 0.95$$

三大统计分布，卡方、t、F

I. $X_1, X_2, \cdots, X_n$ 独立同分布，服从 $N(0,1)$ 则

$Y = X_1^2 + \cdots + X_n^2 \sim \chi_n^2$ 或 $\chi^2(n)$，称为自由度为 n 的 χ^2 分布。

II. t 分布 $X_1 \sim N(0,1)$，$X_2 \sim \chi_n^2$，X_1, X_2 相互独立

$$t = \frac{X_1}{\sqrt{X_2 / n}} \sim t(n)$$，称为自由度为 n 的 t 分布。

III. F 分布 X_1, X_2 相互独立，$X_1 \sim \chi_m^2$，$X_2 \sim \chi_n^2$

$$F = \frac{X_1 / m}{X_2 / n} \sim F(m,n)$$，称为自由度为 m 与 n 的 F 分布。

统计抽样定理

设 $x_1, x_2, \cdots, x_n$ 是来自正态总体 $N\left(\mu, \sigma^2\right)$ 的样本，其样本均值和样本方差分别为：

$\bar{x} = \dfrac{x_1 + x_2 + \cdots + x_n}{n}$ 和 $s^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2$，则有

(1) $\bar{x}$ 与 s^2 相互独立

(2) $\bar{x} \sim N\left(\mu, \dfrac{\sigma^2}{n}\right)$

(3) $\dfrac{(n-1)\cdot s^2}{\sigma^2} \sim \chi^2(n-1)$

总体$X\sim N\left(\mu,\sigma^2\right)$,$\sigma^2$未知，求参数$\mu$的$1-\alpha$置信区间

$$\bar{x}\sim N\left(\mu,\frac{\sigma^2}{n}\right),\qquad \frac{\bar{x}-\mu}{\sigma/\sqrt{n}}\sim N(0,1)$$

$\bar{x}$ 与 s^2 相互独立，且 $\dfrac{(n-1)\cdot s^2}{\sigma^2}\sim\chi^2(n-1)$

$$\frac{\dfrac{\bar{x}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{(n-1)\cdot s^2}{\sigma^2}}}$$

$$\frac{\dfrac{\bar{x}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{(n-1)\cdot s^2}{\sigma^2}\Big/(n-1)}}=\frac{\bar{x}-\mu}{s/\sqrt{n}}=\frac{\sqrt{n}(\bar{x}-\mu)}{s}\sim t(n-1)$$

$$-t_{1-\frac{\alpha}{2}}(n-1)\le\frac{\sqrt{n}(\bar{x}-\mu)}{s}\le t_{1-\frac{\alpha}{2}}(n-1)$$

区间估计例题

$$\bar{x}-\frac{s}{\sqrt{n}}t_{1-\frac{\alpha}{2}}(n-1)\le\mu\le\bar{x}+\frac{s}{\sqrt{n}}t_{1-\frac{\alpha}{2}}(n-1)$$

例　总体 $N(\mu,\sigma^2)$，μ 未知，σ^2 未知，求 μ 的 $1-\alpha$ 置信区间。

枢轴量 $\dfrac{\sqrt{n}(\bar{x}-\mu)}{s}\sim t(n-1)\Rightarrow P\left(t_{\alpha/2}(n-1)\le\dfrac{\sqrt{n}(\bar{x}-\mu)}{s}\le t_{1-\alpha/2}(n-1)\right)=1-\alpha$

例 为估计某物体的质量，用一台天平测量 5 次，结果分别为（单位克）

5.52，　5.48，　5.64，　5.51，　5.43。　总体分布 $N(\mu,\sigma^2)$，μ 未知，σ^2 未知，估计

μ。　$\bar{x}=5.516$，　$s^2=\dfrac{1}{4}\sum_{k=1}^{5}(x_k-5.516)^2\Rightarrow s=0.078$。　$t_4(0.975)=2.776$，　μ 的置信

系数 0. 95 的区间估计为 $[5.419,5.613]$。

区间估计例题

例　$x_1,\cdots,x_m$ 来自正态总体 $N(\mu_1,\sigma_1^2)$，$y_1,\cdots,y_n$ 来自正态总体 $N(\mu_2,\sigma_2^2)$，μ_1、μ_2未知，σ_1^2、σ_2^2未知，求$\mu_2-\mu_1$的$1-\alpha$置信区间。

Behrens-Fisher 问题，统计学中至今没有完全求解的问题。

特殊情况$\sigma_1^2=\sigma_2^2=\sigma^2$未知时，

$$\bar{x}-\bar{y}\sim N\left(\mu_1-\mu_2,\left(\frac{1}{m}+\frac{1}{n}\right)\sigma^2\right),\qquad \frac{(m-1)s_x^2+(n-1)s_y^2}{\sigma^2}\sim\chi^2(m+n-2)$$

$$t=\sqrt{\frac{mn(m+n-2)}{m+n}}\,\frac{\bar{x}-\bar{y}-(\mu_1-\mu_2)}{\sqrt{(m-1)s_x^2+(n-1)s_y^2}}\sim t(m+n-2)。$$

$$\bar{x} \sim N\left(\mu_1, \frac{\sigma^2}{m}\right),\ \bar{y} \sim N\left(\mu_2, \frac{\sigma^2}{n}\right),\quad \bar{x}-\bar{y} \sim N\left(\mu_1-\mu_2, \frac{\sigma^2}{m}+\frac{\sigma^2}{n}\right)$$

$$\frac{(m-1)s_x^2}{\sigma^2} \sim \chi^2(m-1),\ \frac{(n-1)s_y^2}{\sigma^2} \sim \chi^2(n-1),\qquad \frac{(m-1)s_x^2}{\sigma^2}+\frac{(n-1)s_y^2}{\sigma^2} \sim \chi^2(m+n-2)$$

$$\frac{\dfrac{(\bar{x}-\bar{y})-(\mu_1-\mu_2)}{\sigma\sqrt{\dfrac{1}{m}+\dfrac{1}{n}}}}{\sqrt{\dfrac{(m-1)s_x^2+(n-1)s_y^2}{\sigma^2}\Big/(m+n-2)}} = \frac{\sqrt{m+n-2}}{\sqrt{\dfrac{1}{m}+\dfrac{1}{n}}}\cdot\frac{(\bar{x}-\bar{y})+(\mu_2-\mu_1)}{\sqrt{(m-1)s_x^2+(n-1)s_y^2}} \sim t(m+n-2)$$

区间估计例题，正态总体的方差估计

例. 总体 $X \sim N(\mu, \sigma^2)$,参数 μ 和 σ^2 均未知,求 σ^2 的 $1-\alpha$ 置信区间。

$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$ 可作为枢轴量

$$\left(\chi^2_{\frac{\alpha}{2}} \le \frac{(n-1)s^2}{\sigma^2} \le \chi^2_{1-\frac{\alpha}{2}} \right) = 1-\alpha$$

$$P\left(\frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}} \le \sigma^2 \le \frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}} \right) = 1-\alpha \quad \Rightarrow \quad \sigma^2 \in \left[\frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}}, \frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}} \right]$$

区间估计例题，正态总体的方差估计

例　$x_1,\cdots,x_m$ 来自正态总体 $N(\mu_1,\sigma_1^2)$，$y_1,\cdots,y_n$ 来自正态总体 $N(\mu_2,\sigma_2^2)$，

μ_1、μ_2 未知，σ_1^2、σ_2^2 未知，求 σ_1^2/σ_2^2 的区间估计。

$$\frac{(m-1)s_1^2}{\sigma_1^2}\sim\chi^2(m-1),\qquad \frac{(n-1)s_2^2}{\sigma_2^2}\sim\chi^2(n-1)$$

$$\Rightarrow\quad F=\frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2}\sim F(m-1,n-1)$$

参数的区间估计（指数分布总体）

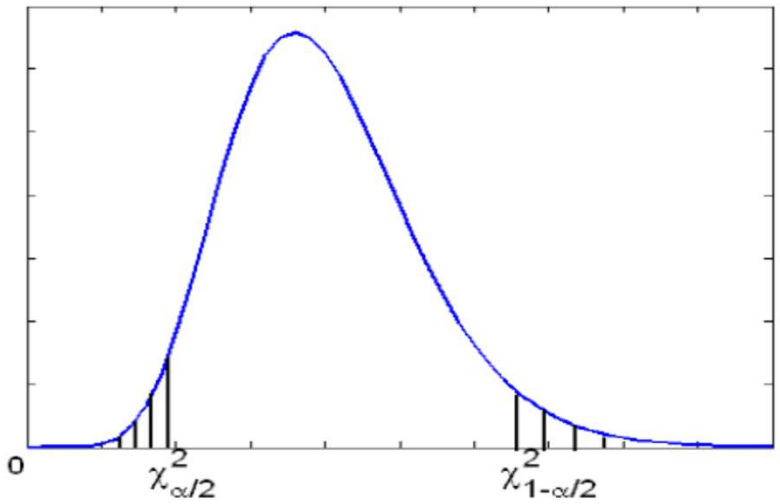
$x_1,\cdots,x_n$ 来自指数总体 $Exp(\lambda)$，求参数 λ 的区间估计，

可以证明 $X=2\lambda(x_1+\cdots+x_n)\sim\chi^2(2n)\Rightarrow 2n\lambda\,\bar{x}\sim\chi^2(2n)$

$$P\left(\chi^2_{\frac{\alpha}{2}}(2n)\le 2n\lambda\,\bar{x}\le\chi^2_{1-\frac{\alpha}{2}}(2n)\right)=1-\alpha$$

$$\Rightarrow \chi^2_{\frac{\alpha}{2}}(2n)\le 2n\lambda\,\bar{x}\le\chi^2_{1-\frac{\alpha}{2}}(2n)$$

$$\Rightarrow \lambda\in\left[\chi^2_{\frac{\alpha}{2}}(2n)\Big/2n\,\bar{x},\chi^2_{1-\frac{\alpha}{2}}(2n)\Big/2n\,\bar{x}\right]$$



区间估计例题

例. $x_1,\cdots,x_n$来自均匀总体$U(0,\theta)$,求参数θ的1−α置信区间,

参数θ的极大似然估计量为$\hat{\theta}=\max\{x_1,x_2,\cdots,x_n\}=x_{(n)}$

$$F_{x_{(n)}}(x,\theta)=\left(\frac{x}{\theta}\right)^n,\quad Y=\frac{x_{(n)}}{\theta},\quad F_Y(y)=P(Y<y)=P\left(\frac{x_{(n)}}{\theta}<y\right)=y^n$$

$\frac{x_{(n)}}{\theta}$可作为枢轴量,

$$P\left(c\le\frac{x_{(n)}}{\theta}\le d\right)=d^n-c^n=1-\alpha\Rightarrow\frac{x_{(n)}}{d}\le\theta\le\frac{x_{(n)}}{c}$$

可取 $d=1,c=\sqrt[n]{\alpha},\quad \theta\in\left[x_{(n)},\frac{x_{(n)}}{\sqrt[n]{\alpha}}\right]$

大样本区间估计

样本容量足够大时，可以利用渐近分布构造置信区间。

例 Behrens-Fisher 问题，$x_1,\cdots,x_m$ 来自正态总体 $N(\mu_1,\sigma_1^2)$，$y_1,\cdots,y_n$ 来自正态总体 $N(\mu_2,\sigma_2^2)$，μ_1、μ_2 未知，σ_1^2、σ_2^2 未知，求 $\mu_2-\mu_1$ 的区间估计。

$$\frac{\bar{x}-\bar{y}-(\mu_1-\mu_2)}{\sqrt{\sigma_x^2/m+\sigma_y^2/n}}\sim N(0,1),\qquad \frac{\bar{x}-\bar{y}-(\mu_1-\mu_2)}{\sqrt{s_x^2/m+s_y^2/n}}\sim N(0,1)$$

例　样本$X_1,\cdots,X_n$来自两点分布总体$b(1,p)$，求p的区间估计。

解：样本均值的期望、方差分别为 $E(\bar{X})=p$，$Var(\bar{X})=\dfrac{p(1-p)}{n}$

根据中心极限定理当n较大时，有近似分布

$\bar{X}\sim N\left(p,\dfrac{p(1-p)}{n}\right)$，　标准化后得到枢轴量　$\dfrac{\bar{X}-p}{\sqrt{\dfrac{p(1-p)}{n}}}\sim N(0,1)$，

$$P\left(\left|\frac{\bar{X}-p}{\sqrt{p(1-p)/n}}\right|\le u_{1-\frac{\alpha}{2}}\right)\approx 1-\alpha,\quad \text{即}\ \left(\bar{X}-p\right)^2\le u^2_{1-\frac{\alpha}{2}}\frac{p(1-p)}{n}$$

$$P\left(\left|\frac{\bar{X}-p}{\sqrt{p(1-p)/n}}\right|\le u_{1-\frac{\alpha}{2}}\right)\approx 1-\alpha,\quad \text{即}\ \left(\bar{X}-p\right)^2\le u^2_{1-\frac{\alpha}{2}}\frac{p(1-p)}{n},\ \text{解得}$$

$$\frac{1}{1+c}\left(\bar{X}+\frac{c}{2}-\sqrt{\frac{\bar{X}(1-\bar{X})}{n}u^2_{1-\frac{\alpha}{2}}+\frac{c^2}{4}}\right)\le p\le\frac{1}{1+c}\left(\bar{X}+\frac{c}{2}+\sqrt{\frac{\bar{X}(1-\bar{X})}{n}u^2_{1-\frac{\alpha}{2}}+\frac{c^2}{4}}\right)$$

其中 $c=\dfrac{u^2_{1-\frac{\alpha}{2}}}{n}$，当 n 较大时，c 的值很小可略去，得到参数 p 的 $1-\alpha$ 置信水平的近似估计区间 $\left[\bar{X}-u_{1-\frac{\alpha}{2}}\sqrt{\dfrac{\bar{X}(1-\bar{X})}{n}},\bar{X}+u_{1-\frac{\alpha}{2}}\sqrt{\dfrac{\bar{X}(1-\bar{X})}{n}}\right]$。

例 一个网络产品的运营商希望了解该产品在某个城市的用户占有率，进行了随机抽样调查，样本容量为 500，调查结果有 84 人是该产品的用户，求这个网络产品在该城市占有率的一个95%置信区间。

解：总体分布 $X \sim b(1,p)$，　样本均值 $\bar{X}=\dfrac{X_1+\cdots+X_{500}}{500}$

期望、方差分别为 $E(\bar{X})=p$，$Var(\bar{X})=\dfrac{p(1-p)}{n}=\dfrac{p(1-p)}{500}$

$$\frac{(\bar{X}-p)}{\sqrt{p(1-p)/500}} \sim N(0,1)，\left[\bar{X}-u_{0.975}\sqrt{\frac{\bar{X}(1-\bar{X})}{500}},\bar{X}+u_{0.975}\sqrt{\frac{\bar{X}(1-\bar{X})}{500}}\right]$$

$\bar{x}=\dfrac{84}{500}=0.168$，$u_{0.975}=1.96$，　近似估计区间为：$[0.135,0.201]$。

例 一个网络产品的运营商希望了解该产品在某个城市的用户占有率，进行了随机抽样调查，样本容量为 500，调查结果有 84 人是该产品的用户。根据抽样调查的信息，运营商希望得到参数 p 的 95%置信水平的区间估计，且估计区间长度不超过 0.02，问至少需要多大的样本容量？

解：参数 p 的 $1-\alpha$ 置信区间为 $\left[\bar{X}-u_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}},\ \bar{X}+u_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}}\right]$

估计区间长度不超过 0.02，即 $u_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{x}(1-\bar{x})}{n}}\le 0.01$。

$$n\ge\left(\frac{u_{1-\alpha/2}}{0.01}\right)^2\bar{x}(1-\bar{x})=\left(\frac{u_{0.975}}{0.01}\right)^2\bar{x}(1-\bar{x})=\left(\frac{1.96}{0.01}\right)^2 0.168(1-0.168)=5369.6$$

例 一个网络产品的运营商希望了解该产品在某个城市的用户占有率，希望得到参数 p 的 95%置信水平，且估计区间长度不超过 0.02 的区间估计，问在没有任何先验知识的情况下，至少需要多大的样本容量才能保证达到所希望的估计精度？

解：参数 p 的 $1-\alpha$ 置信区间为 $\left[\bar{X}-u_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}},\ \bar{X}+u_{1-\frac{\alpha}{2}}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}}\right]$

对任何 $\bar{X}\in(0,1)$，$\bar{x}(1-\bar{x})\le\frac{1}{4}$

$$n\ge\left(\frac{u_{1-\alpha/2}}{0.01}\right)^2\frac{1}{4}\ge\left(\frac{u_{1-\alpha/2}}{0.01}\right)^2\bar{x}(1-\bar{x}),\qquad n\ge\left(\frac{u_{0.975}}{0.01}\sqrt{\frac{1}{4}}\right)^2=9604$$

问题没有变，可是现在这个情况下估计的所需样本容量数比上一题多了不少。因为本题中先验信息少于上一题， 所以得到估计不如上题精确也是很自然的。一般而言，得到信息越多，越有可能得到更好的估计。

作 业（12月5日）

~~~~~~

习题6.6： 3，4，6，9，14，19

12月12日提交

~~~~~~

本讲配合的在线学习内容

第十二周课，第4节：伪随机数和随机模拟(10’36”)

12月10日，12月11日，第4次线上自测（60分钟）