

概率论与数理统计

统计部分第6讲　拟合优度检验，贝叶斯估计

考试补充要点说明

1. 30分填空，70分解答题

2. 客观题必须在考试结束前在雨课堂系统提交，然后处理主观题，主观题一律用手写，考试除监考和拍照上传，不允许使用任何电子设备

3. 腾讯会议考场，每个考场不超过20人。即便如此，也可能系统出现视频打开数量受限的情况。如果打不开视频，请尽快重试，如果还不行，则马上联系监考老师，转到备用考场。所以请同学们务必至少提前10分钟进入自己的腾讯会议考场，以免调整不及时耽误考试时间。

4. 今天下午发雨课堂问卷，统计到目前为止的缓考同学，然后确定正式考试的考场分配。

再看女士品茶问题

品尝正确的概率为 p，　$H_0: p \le \frac{1}{2}$ vs $H_1: p > \frac{1}{2}$

8杯饮料中MT与TM各4杯，选出其中的4杯MT，正确的杯数 X，

检验：$W = \{X = 4\}$

$$\begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ \frac{1}{70} & \frac{16}{70} & \frac{36}{70} & \frac{16}{70} & \frac{1}{70} \end{pmatrix}$$

水平为0.05的检验。显著性水平未被足量地使用

$$\max\left\{P\left(\text{拒绝}H_0 \mid H_0\text{为真}\right)\right\} = \frac{1}{70} < 0.05$$

随机化检验

- 随机化检验的实施过程为：
- 若$X=4$则拒绝原假设；若$X=3$，则先做一个成功概率为0.156的伯努利试验，如果试验成功，则拒绝原假设，否则接受原假设。
- 这样就补偿了未被足量地使用的显著性

K.Pearson 的χ^2检验（拟合优度检验）

设总体服从离散分布

X	x_1	$\cdots$	x_k
P	p_1	$\cdots$	p_k

进行n次独立地观测，k个取值出现的频次分别为$N_i\left(i=1,\cdots,k\right)$，则

$X=\sum_{i=1}^{k}\frac{\left(N_i-np_i\right)^2}{np_i}$ 近似服从自由度为 $k-1$的χ^2分布。

若需要通过样本估计s个参数，则 $X=\sum_{i=1}^{n}\frac{(N_i-Np_i)^2}{Np_i}$近似服从自由度$k-s-1$的卡方分布。

χ^2 检验实例

卢瑟福和盖革在 1910 年观察了放射性物质放出 α 粒子的个数的情况，共观察 $n=2608$ 次，每次观察间隔 7.5 秒，记录到达指定区域的 α 粒子数，共记录下 10094 个粒子，n_k 表示恰好记录到 k 个 α 粒子的观察次数。

k	0	1	2	3	4	5	6	7	8	9	≥10
n_k	57	203	383	525	532	408	273	139	45	27	16
$n\cdot\hat{p}_k$	54	211	407	525	508	394	254	140	68	29	17

现在希望检验这组数据是否来自于泊松分布。

设1次观察中出现的 α 粒子数为随机变量 X，共有2608次观测，所以1个粒子落入该次观察的概率是 $\frac{1}{2608}$，共记录下10094个粒子，$X\sim B\left(10094,\frac{1}{2608}\right)$

设1次观察中出现的α粒子数为随机变量 X，共有2608次观测，所以1个粒子落入该次观察的概率是 $\frac{1}{2608}$，共记录下10094个粒子，$X \sim B\left(10094, \frac{1}{2608}\right)$

根据泊松定理，$X \sim P(\hat{\lambda})$，其中 $\hat{\lambda} = \frac{10094}{2608} = 3.87$

泊松分布随机变量不同取值的概率

$$\hat{p}_i = \frac{\hat{\lambda}^i}{i!} e^{-\hat{\lambda}} \ (i = 0,1,\cdots,9), \quad \hat{p}_{10} = 1 - \sum_{i=0}^{9} \hat{p}_i$$

计算这组观测数据下卡方检验统计量的取值，$Y = \sum_{i=0}^{10} \frac{(N_i - N\hat{p}_i)^2}{N\hat{p}_i} = 12.88$，

$Y \sim \chi^2(9), \quad p = P(Y > 12.88) > 0.1,$

因此可以接受这组数据来自于参数$\hat{\lambda}$的分布。

某医院一个月内共有2878名婴儿出生，数据如下

小时	0	1	2	3	4	5	6	7	8	9	10	11
人数	127	139	143	138	134	115	127	113	126	122	121	119
小时	12	13	14	15	16	17	18	19	20	21	22	23
人数	130	125	112	97	115	94	99	97	100	119	127	139

一天之中婴儿的出生时刻是否均匀?

$$np_i = \frac{2878}{24} \approx 119.92, \quad \chi^2 = \sum_{i=0}^{23} \frac{\left(N_i - np_i\right)^2}{np_i} \approx 40.227$$

$$P\left(\chi^2(23) \geq 35.2\right) = 0.05$$

$$p\text{值} = P\left(\chi^2(23) \geq 40.227\right) = 1 - \text{chi2cdf}\left(40.227, 23\right) = 0.0145$$

独立性检验

拟合优度的χ^2检验还可以用来判断不同属性的相关性。

例 曾经有人统计了 6672 名学生使用左、右手的习惯，

	男	女	合
右	2780	3281	6061
左	311	300	611
合	3091	3581	6672

其中男性左手率为 0.1，女性左手率为 0.08，

试问使用左、右手的习惯是否与性别相关？

列联表检验（独立性检验）

$A \backslash B$	1	2	$\cdots$	j	$\cdots$	t	行合计
1	n_{11}	n_{12}	$\cdots$	n_{1j}	$\cdots$	n_{1t}	c_1
2	n_{21}	n_{22}	$\cdots$	n_{2j}	$\cdots$	n_{2t}	c_2
$\vdots$	.	.	.	.	.	.	$\vdots$
i	n_{i1}	n_{i2}	$\cdots$	n_{ij}	$\cdots$	n_{it}	c_i
$\vdots$	.	.	.	.	.	.	$\vdots$
s	n_{s1}	n_{s2}	$\cdots$	n_{sj}	$\cdots$	n_{st}	c_s
列合计	d_1	d_2	$\cdots$	d_j	$\cdots$	d_t	n

$$Y=\sum_{i=1}^{s}\sum_{j=1}^{t}\frac{\left(n_{ij}-n\cdot\frac{c_i}{n}\cdot\frac{d_j}{n}\right)^2}{n\cdot\frac{c_i}{n}\cdot\frac{d_j}{n}}=\sum_{i=1}^{s}\sum_{j=1}^{t}\frac{\left(nn_{ij}-c_id_j\right)^2}{nc_id_j}$$

近似服从自由度为 $(s-1)(t-1)$ 的χ^2分布

左右手习惯是否与性别相关

	男	女	合
右	2780	3281	6061
左	311	300	611
合	3091	3581	6672

$$Y = 5.65, \qquad \chi_1^2(0.05) = 3.841, \qquad \chi_1^2(0.01) = 6.635$$

女性左右率 0.08, 男性左右率 0.10

1936年瑞典对25263个家庭的小孩数与收入的调查表

小孩数\收入	0－1	1－2	2－3	≥3	行合计
0	2161	3577	2184	1636	9558
1	2755	5081	2222	1052	11110
2	936	1753	640	306	3635
3	225	419	96	38	778
4	39	98	31	14	182
列合计	6116	10928	5173	3046	25263

解： 计算 $Y=\sum_{i=1}^{s}\sum_{j=1}^{t}\frac{\left(nn_{ij}-c_i d_j\right)^2}{nc_i d_j}=568.6$

检验统计量 Y 近似服从 $4\times3=12$ 自由度的 χ^2 分布

$P\left(\chi^2(12)>32.9\right)=0.001$，检验的 p 值远远小于 0.001，拒绝原假设

三种信息

1. 总体信息

总体分布，例如：我国为了确认国产轴承寿命的分布服从威布尔分布，前后花了5年时间，处理了几千个数据才确定下来

2. 样本信息

3. 先验信息

贝叶斯估计 将未知参数 θ 看做随机变量

1. 确定参数 θ 的先验分布 $\pi(\theta)$

2. 总体分布为随机变量 θ去某个定值时，总体的条件概率函数，记为 $p(x|\theta)$

3. 确定样本 X 参数 θ 的联合概率函数 $h(x,\theta) = p(x|\theta)\pi(\theta)$

X 的边际概率函数 $m(x) = \int_{\Theta} h(x,\theta)d\theta = \int_{\Theta} p(x|\theta)\pi(\theta)d\theta$

4. 计算 X 条件下参数 θ 的条件分布，得到参数的后验分布

$$\pi(\theta|x) = \frac{h(x,\theta)}{m(x)} = \frac{p(x|\theta)\pi(\theta)}{\int_{\Theta} p(x|\theta)\pi(\theta)d\theta}$$

例1. 设某事件 A 的发生概率为 θ，对试验进行了n次独立观测，其中事件发生了X次，估计参数 θ

显然 $X|\theta \sim b(n,\theta)$

$$P(X=x|\theta)=\binom{n}{x}\theta^x(1-\theta)^{n-x},\quad x=0,1,2,\ldots,n$$

假设我们在试验前，对A没有什么了解，则通常使用

均匀分布 $U(0,1)$ 作为参数 θ 的先验分布。

X和θ的联合分布:

$$h(x,\theta)=p(x|\theta)\pi(\theta)=\binom{n}{x}\theta^x(1-\theta)^{n-x},$$

$(x=0,1,\ldots n,\qquad 0<\theta<1\ )$

例1. 设某事件 A 的发生概率为 θ，对试验进行了n次独立观测，其中事件发生了X次，估计参数 θ

X的边际分布 $m(x)=\int_0^1 h(x,\theta)d\theta=\binom{n}{x}\int_0^1 \theta^x(1-\theta)^{n-x}\,d\theta$

$$=\binom{n}{x}\frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

θ 的后验分布$(0<\theta<1)$

$$\pi(\theta|x)=\frac{h(x,\theta)}{m(x)}=\frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}\theta^{(x+1)-1}(1-\theta)^{(n-x+1)-1},$$

$\theta|x\sim Be(x+1,n-x+1)$

后验期望估计为 $\hat{\theta}=E(\theta|x)=\frac{x+1}{n+2}$,用经典方法得到的估计量为$\bar{\theta}=\frac{x}{n}$

Beta分布

Beta分布 $X \sim Be(a,b)$

$$p(x;a,b)=\begin{cases}\dfrac{x^{a-1}(1-x)^{b-1}}{B(a,b)}, & 0\le x\le 1\\ 0, & \text{其他}\end{cases}$$

Beta函数 $B(a,b)=\int_0^1 y^{a-1}(1-y)^{b-1}dy$

Gamma函数 $\Gamma(a)=\int_0^{+\infty} t^{a-1}e^{-t}dt,\quad B(a,b)=\dfrac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$

- $E(X)=\dfrac{a}{a+b},\quad Be(1,1)$ 即为 $U(0,1)$

Gamma分布 $X\sim Ga(\alpha,\lambda)$

Gamma函数 $\Gamma(a)=\int_0^{+\infty}t^{a-1}e^{-t}dt$,

$$p(x)=\begin{cases}\dfrac{\lambda^a}{\Gamma(a)}x^{a-1}e^{-\lambda x}, & x\geq 0\\ 0, & x<0\end{cases}$$

$$X\sim Ga(\alpha,\lambda),E(X)=\frac{\alpha}{\lambda}$$

$\alpha=1$时, $Ga(1,\lambda)=\mathbf{Exp}(\lambda)$; $\alpha=\frac{n}{2},\lambda=\frac{1}{2}$时, $Ga\left(\frac{n}{2},\frac{1}{2}\right)=\chi^2(n)$

Gamma分布可加性: $X\sim Ga(\alpha,\lambda)$, $Y\sim Ga(\beta,\lambda)$,

且X,Y相互独立, $X+Y\sim Ga(\alpha+\beta,\lambda)$

$$\chi^2(1)=Ga\left(\frac{1}{2},\frac{1}{2}\right),\quad \chi^2(n)=Ga\left(\frac{n}{2},\frac{1}{2}\right)$$

$$Exp(\lambda)=Ga(1,\lambda),\quad X_1+\cdots+X_n\sim Ga(n,\lambda)$$

Beta分布的性质

设随机变量 $X_1, X_2, \cdots, X_n$ 相互独立，且均服从$U(0,1)$，

顺序统计量 $X_{(1)} \le X_{(2)} \le \cdots \le X_{(n)}$

则 $X_{(r)} \sim Be(r, n-r+1)$，$X_{(s)} - X_{(r)} \sim Be(s-r, n-s+r+1)$

特别地，$min(X_1, X_2, \cdots, X_n) = X_{(1)} \sim Be(1, n)$；

而且，若$X_1, X_2, \cdots, X_n$独立，

$min(X_1, X_2, \cdots, X_n) \sim U(0,1)$，则 $X_1 \sim Be\left(1, \frac{1}{n}\right)$

例2. 设某事件 A 的发生概率为 θ，对试验进行了n次独立观测，其中事件发生了X次，假设θ 的先验分布为$Be(a,b)$, 估计θ

$$X|\theta \sim b(n,\theta), \quad P(X=x|\theta)=\binom{n}{x}\theta^x(1-\theta)^{n-x}, \quad x=0,1,\ldots,n$$

X和θ的联合分布:

$$h(x,\theta)=p(x|\theta)\pi(\theta)=\binom{n}{x}\theta^x(1-\theta)^{n-x}\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}$$

$$=\binom{n}{x}\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{x+a-1}(1-\theta)^{n-x+b-1}$$

X的边际分布

$$m(x)=\int_0^1 h(x,\theta)d\theta=\binom{n}{x}\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\frac{\Gamma(x+a)\Gamma(n-x+b)}{\Gamma(n+a+b)}$$

例2. 设某事件 A 的发生概率为 θ，对试验进行了n次独立观测，其中事件发生了X次，假设θ 的先验分布为$Be(a,b)$，估计θ

θ 的后验分布

$$\pi(\theta|x)=\frac{h(x,\theta)}{m(x)}=\frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n-x+b)}\theta^{x+a-1}(1-\theta)^{n-x+b-1}$$

$$\theta|x\sim Be(x+a,n-x+b)$$

后验期望估计为 $\hat{\theta}=E(\theta|x)=\frac{x+a}{n+a+b}$

$$\hat{\theta}=\frac{x+a}{n+a+b}=\frac{n}{n+a+b}\cdot\frac{x}{n}+\frac{a+b}{n+a+b}\cdot\frac{a}{a+b}$$